




ФИЗТЕХОВСКИЕ КУРСЫ

А. И. Лобанов, И. Б. Петров

Вычислительная математика

КУРС ЛЕКЦИЙ



А. И. ЛОБАНОВ, И. Б. ПЕТРОВ

ВЫЧИСЛИТЕЛЬНАЯ МАТЕМАТИКА

Курс лекций



Москва
ФИЗМАТКНИГА
2021

ББК 22.19
Л68
УДК 519.6

ЛОБАНОВ А. И., ПЕТРОВ И. Б. Вычислительная математика. Курс лекций. — М.: Физматкнига, 2021. — 476 с. — ISBN 978-5-89155-341-5.

В книге описываются математические основы численных методов решения задач вычислительной математики, математической физики, машинного обучения, а также вычислительные методы и алгоритмы, рассматриваются их свойства. В рамках вводного лекционного курса рассматриваются следующие важнейшие разделы вычислительной математики: теория погрешностей, методы линейной алгебры, решения систем линейных алгебраических уравнений, методы решения нелинейных уравнений и систем, методы аппроксимации функций в функциональных пространствах (метод наименьших квадратов, методы интерполяции), некоторые численные методы оптимизации, численные методы решения систем обыкновенных дифференциальных уравнений, в том числе жестких, основы теории разностных схем, методы их исследования на сходимость, аппроксимацию и устойчивость, численные методы решения уравнений в частных производных параболического, гиперболического и эллиптического типов.

Книга предназначена для студентов университетов высших технических учебных заведений, специализирующихся в области прикладной и вычислительной математики, а также для студентов других специальностей, связанных с численным моделированием (физических, химических, биологических, инженерных, экономических, геологических).

Интернет-магазин специализированной литературы
www.fizmatkniga.org

Уважаемые читатели! Если вы заметили в нашей книге опечатку или ошибку, пожалуйста, сообщите нам об этом по электронной почте publishers@mail.mipt.ru, в группу vk.com/fizmatkniga или по адресу 141701, Московская область, г. Долгопрудный, ул. Первомайская, д. 3А, Издательство «Физматкнига». Это поможет сделать следующие издания книги лучше!



9 785891 553415

© А. И. Лобанов, И. Б. Петров, 2021

ОГЛАВЛЕНИЕ

ПРЕДИСЛОВИЕ.....	8
------------------	---

ИСПОЛЬЗУЕМЫЕ ОБОЗНАЧЕНИЯ.....	11
-------------------------------	----

ЛЕКЦИЯ 1

ПРЕДМЕТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ. ОБУСЛОВЛЕННОСТЬ ЗАДАЧИ, УСТОЙЧИВОСТЬ АЛГОРИТМА, ПОГРЕШНОСТИ ВЫЧИСЛЕНИЙ. ЗАДАЧА ЧИСЛЕННОГО ДИФФЕРЕНЦИРОВАНИЯ	13
---	-----------

1.1. Введение	13
1.2. Необходимые сведения из теории погрешностей.....	15
1.3. Обусловленность задачи.....	17
1.4. Влияние конечной длины мантиссы и выбора вычислительного алгоритма на результаты вычислений	19
1.5. Экономичность вычислительного метода	22
1.6. Погрешность метода	23
1.7. Задача численного дифференцирования	24
1.8. Примеры решения задач.....	29

ЛЕКЦИЯ 2

ЧИСЛЕННОЕ РЕШЕНИЕ СИСТЕМ ЛИНЕЙНЫХ АЛГЕБРАИЧЕСКИХ УРАВНЕНИЙ.....	31
--	-----------

2.1. Постановка задачи	31
2.2. Согласованные нормы векторов и матриц	33
2.3. Обусловленность СЛАУ. Число обусловленности матрицы	36
2.4. Прямые методы решения СЛАУ.....	39
2.5. Итерационные методы решения СЛАУ	54
2.6. Вариационные итерационные методы	61
2.7. О спектральных задачах.....	67
2.8. Примеры решения задач.....	69

ЛЕКЦИЯ 3

ЧИСЛЕННОЕ РЕШЕНИЕ ПЕРЕОПРЕДЕЛЕННЫХ СЛАУ. МЕТОД НАИМЕНЬШИХ КВАДРАТОВ.....	76
---	-----------

3.1. Пример использования метода наименьших квадратов (МНК)	76
3.2. Примеры решения задач.....	84

ЛЕКЦИЯ 4

ЧИСЛЕННОЕ РЕШЕНИЕ НЕЛИНЕЙНЫХ АЛГЕБРАИЧЕСКИХ УРАВНЕНИЙ И СИСТЕМ..... 87

- 4.1. Сжимающие отображения. Итерации. Метод простых итераций (МПИ) 87
- 4.2. Метод Ньютона 92
- 4.3. О вариационных подходах к решению нелинейных систем уравнений 96
- 4.4. Метод Чебышёва построения итерационных процессов высшего порядка..... 96
- 4.5* Разностные отображения в нелинейной динамике..... 97
- 4.6. Примеры решения задач..... 108

ЛЕКЦИЯ 5

ВВЕДЕНИЕ В ЧИСЛЕННЫЕ МЕТОДЫ БЕЗУСЛОВНОЙ ОПТИМИЗАЦИИ 114

- 5.1. Поиск безусловного минимума функции 114
- 5.2. Методы спуска 120
- 5.3. Понятие о задачах линейного программирования 127
- 5.4. Задачи с решениями 129

ЛЕКЦИЯ 6

ИНТЕРПОЛЯЦИЯ ФУНКЦИЙ 132

- 6.1. Постановка задачи интерполяции 132
- 6.2. Кусочно-линейная интерполяция 133
- 6.3. Интерполяция обобщенными полиномами 134
- 6.4. Полиномиальная (алгебраическая) интерполяция..... 136
- 6.5. Теорема об остаточном члене интерполяции..... 137
- 6.6. Интерполяционный полином в форме Ньютона..... 139
- 6.7. Минимизация остаточного члена интерполяции 142
- 6.8. Обусловленность задачи интерполяции. Постоянная Лебега..... 143
- 6.9. Интерполяция с кратными узлами..... 144
- 6.10. Кусочно-многочленная глобальная интерполяция (сплайны)..... 147
- 6.11. В-сплайны 153
- 6.12. Интерполяция функций двух переменных 156
- 6.13. Примеры решения задач..... 157

ЛЕКЦИЯ 7

ЧИСЛЕННОЕ ИНТЕГРИРОВАНИЕ 162

- 7.1. Квадратурные формулы интерполяционного типа (формулы Ньютона–Котеса) 162
- 7.2. Оценка погрешности квадратурных формул 167
- 7.3. Квадратурные формулы Гаусса 171
- 7.4. Вычисление интегралов от функций с особенностями 175
- 7.5. Кратные интегралы..... 176
- 7.6. Идея метода Монте-Карло..... 178
- 7.7. Примеры решения задач..... 179

ЛЕКЦИЯ 8

ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ ЗАДАЧИ КОШИ ДЛЯ СИСТЕМ ОБЫКНОВЕННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ..... 183

8.1. Основные понятия.....	183
8.2. Методы Рунге–Кутты.....	188
8.3. Методы Адамса.....	201
8.4. Метод неопределенных коэффициентов для построения многошаговых методов численного решения задачи Коши.....	203
8.5. Оценка погрешности.....	207
8.6. Устойчивость методов Рунге–Кутты.....	210
8.7. Примеры решения задач.....	215

ЛЕКЦИЯ 9

ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ ЖЕСТКИХ СИСТЕМ ОБЫКНОВЕННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ..... 221

9.1. Явление жесткости. Предварительные сведения.....	221
9.2. Сингулярно-возмущенные задачи.....	227
9.3. Решение линейных ЖС ОДУ и вычисление матричной экспоненты...	231
9.4. Численные методы решения ЖС ОДУ. Семейства неявных методов Рунге–Кутты и Розенброка.....	233
9.5. Формулы «дифференцирования назад» и методы Гира. Представление Нордсика.....	238
9.6. Примеры решения задач.....	242

ЛЕКЦИЯ 10

ЧИСЛЕННОЕ РЕШЕНИЕ КРАЕВЫХ ЗАДАЧ ДЛЯ СИСТЕМ ОБЫКНОВЕННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ..... 247

10.1. Краевая задача для линейной системы ОДУ первого порядка.....	247
10.2. Метод дифференциальной прогонки.....	250
10.3. Понятие о жестких краевых задачах.....	252
10.4. Краевая разностная задача для обыкновенного дифференциального уравнения второго порядка.....	253
10.5. Численное решение нелинейных краевых задач.....	255
10.6. Краевые задачи на собственные значения для обыкновенных дифференциальных уравнений.....	261
10.7. Решение краевой задачи методом Фурье.....	263
10.8. Примеры решения задач.....	264

ЛЕКЦИЯ 11

ИССЛЕДОВАНИЕ РАЗНОСТНЫХ СХЕМ ДЛЯ ЭВОЛЮЦИОННЫХ УРАВНЕНИЙ НА УСТОЙЧИВОСТЬ И СХОДИМОСТЬ..... 269

11.1. Постановка некоторых задач для уравнений математической физики..	269
11.2. Основные определения — сходимость, аппроксимация, устойчивость..	273
11.3. Основные определения — сходимость, аппроксимация, устойчивость..	281
11.4. Примеры решения задач.....	293

ЛЕКЦИЯ 12

ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ УРАВНЕНИЙ ПАРАБОЛИЧЕСКОГО ТИПА 297

12.1. Постановки задач для некоторых линейных уравнений параболического типа	297
12.2. Простейшие разностные схемы для одномерного уравнения теплопроводности	300
12.3. Уравнение теплопроводности с переменным коэффициентом	305
12.4. Разностные схемы в пространстве неопределенных коэффициентов ...	309
12.5. Численные методы решения полулинейного уравнения теплопроводности	318
12.6. Квазилинейное уравнение теплопроводности	326
12.7. Многомерное линейное уравнение теплопроводности	330
12.8. Примеры решения задач	336

ЛЕКЦИЯ 13

ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ УРАВНЕНИЙ В ЧАСТНЫХ ПРОИЗВОДНЫХ ГИПЕРБОЛИЧЕСКОГО ТИПА 342

13.1. Простейшее линейное уравнение переноса	342
13.2. Линейные системы гиперболического типа с постоянными коэффициентами	344
13.3. Численные методы решения уравнений в частных производных гиперболического типа на примере уравнения переноса	347
13.4. Численные методы решения квазилинейного уравнения переноса	355
13.5. Аппроксимационная вязкость	357
13.6. Гибридные схемы (метод Р. П. Федоренко)	358
13.7. Схемы с уменьшением полной вариации (Total Variation Diminishing, схемы Хартена)	360
13.8. Идеи построения сеточно-характеристических методов и анализ разностных схем в пространстве неопределенных коэффициентов	363
13.9. Примеры решения задач	370

ЛЕКЦИЯ 14

ЧИСЛЕННОЕ РЕШЕНИЕ УРАВНЕНИЙ В ЧАСТНЫХ ПРОИЗВОДНЫХ ЭЛЛИПТИЧЕСКОГО ТИПА НА ПРИМЕРЕ УРАВНЕНИЙ ЛАПЛАСА И ПУАССОНА 384

14.1. Постановка задачи. Простейшая разностная схема «крест». Устойчивость схемы «крест»	384
14.2. Методы решения сеточных уравнений	389
14.3* Попеременно-треугольный итерационный метод	405
14.4. Сводка результатов по итерационным методам решения сеточных уравнений	409
14.5. Основные идеи многосеточного метода Р. П. Федоренко	410
14.6* Построение разностных схем для эллиптических уравнений на нерегулярных сетках. Монотонные схемы (подход А. С. Холодова)	412
14.7. Примеры решения задач	414

ПРИЛОЖЕНИЕ 1	
НЕОБХОДИМЫЕ СВЕДЕНИЯ ИЗ ФУНКЦИОНАЛЬНОГО	
АНАЛИЗА	422
 ПРИЛОЖЕНИЕ 2	
СИСТЕМЫ ОРТОГОНАЛЬНЫХ ПОЛИНОМОВ	439
 ПРИЛОЖЕНИЕ 3	
ТОЧНЫЕ РЕШЕНИЯ РАЗНОСТНЫХ УРАВНЕНИЙ	447
 ПРИЛОЖЕНИЕ 4	
НЕКОТОРЫЕ ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ СЛАУ	
С МАТРИЦАМИ СПЕЦИАЛЬНОГО ВИДА	457
 ПРИЛОЖЕНИЕ 5	
МНОЖЕСТВА И ОБОЛОЧКИ.....	470

ПРЕДИСЛОВИЕ

Многие важнейшие направления в науке и технике не могут успешно развиваться без знаний вычислительной математики, современных численных методов, компьютерных и суперкомпьютерных вычислений. В индустриально развитых странах в последние десятилетия наблюдается взрывной интерес к этим научным направлениям. Это связано, в первую очередь, с возросшей производительностью вычислительных систем, с появившимися возможностями суперкомпьютерного моделирования и применения методов машинного обучения.

За основу данной книги были взяты курсы вычислительной математики, которые в течение ряда лет читались студентам МФТИ. Слушатели этих курсов — не профессионалы-вычислители, а исследователи, специалисты в своих предметных областях. Но логика современного развития науки привела к тому, что успех исследования во многом определяется эффективностью применения вычислительной техники и численных методов. Особенно важное значение применение современных вычислительных методов и математического моделирования сейчас приобрело в таких актуальных областях фундаментальной и прикладной науки, как создание новой космической и авиационной техники, ядерная энергетика, геофизика, в частности, сейсмическая и электрическая разведка полезных ископаемых, в первую очередь, углеводородов, биотехнология, медицина, методы математического обучения и искусственного интеллекта, океанология и физика атмосферы. Без математического моделирования и вычислительного эксперимента трудно себе представить фундаментальные исследования в квантовой физике и химии, астрофизике, механике сплошных сред, распространении электромагнитных волн.

Современные численные методы и математические модели позволяют не только совершенствовать технологии и конструкции, но и значительно сокращать расходы и время разработки новой высокотехнологичной продукции за счет замены лабораторных и натурных испытаний вычислительными экспериментами. Такие методы дают не только возможность оптимизировать конструкции и технологические процессы, но и теоретически исследовать их свойства.

В силу быстрых изменений, происходящих сейчас в вычислительной математике, создать курс, полностью удовлетворяющий потребностям сегодняшнего дня, просто невозможно. Авторы

в рамках вводного курса ограничились основными идеями и методами, дающими основу для дальнейшей самостоятельной работы над связанными проблемами. Кроме того, в книгу включены некоторые идеи, методы, разделы, которые не являются обязательными и при первом прочтении могут быть опущены. Такие разделы помечены звездочками.

Изданная несколько лет назад книга авторов «Лекции по вычислительной математике»*) вызвала широкий отклик. За время, прошедшее с издания этой работы, стало ясно, что книга нуждается в значительных изменениях. Авторами были сокращены некоторые разделы, выходящие за рамки вводного курса. Другие разделы были подвергнуты значительной переработке. Общая логика изложения была унаследована от упомянутой работы.

В книге отражен лекционный курс. Отметим, что здесь термин «лекция» условен. В книгу практически входит годовой курс, число лекций в учебном году обычно составляет от 30 до 34. В предлагаемой книге лишь 14 лекций. Под лекцией здесь понимается тематический раздел, который может включать в себя материал нескольких реально читаемых лекций.

По мнению авторов, без самостоятельной реализации основных алгоритмов и простых вычислительных процедур невозможно глубокое понимание предмета. Поэтому изучение лекционного курса следует обязательно сочетать как с решением теоретических задач, так и с практическим знакомством со свойствами основных численных методов и алгоритмов при практической работе. Возможности для создания практикумов сейчас невероятно широки в силу распространения пакетов прикладных программ, как коммерческих, так и свободных. Без понимания того, как функционирует «начинка» данных пакетов, для решения каких задач пригодны те или иные методы, а какие методы данным задачам категорически «противопоказаны», невозможна эффективная деятельность специалистов.

Авторы выражают свою искреннюю благодарность всем коллегам по кафедре вычислительной математики МФТИ возникшим на ее базе кафедре информатики и вычислительной математики и кафедре вычислительной физики за внимание и помощь в работе.

*) Петров И. Б., Лобанов А. И. Лекции по вычислительной математике: Учебное пособие. — М: Интернет-Университет Информационных Технологий; БИНОМ, 2006.

Авторы многим обязаны своим учителям, которые передали им свои знания и любовь к предмету. Так, авторам посчастливилось слушать лекции профессоров В. С. Рябенского и Р. П. Федоренко. Эти ученые не только внесли выдающийся вклад в вычислительную математику, но и задали планку преподавания предмета на Физтехе. Они также оставили после себя выдающиеся книги по предмету, знакомство с которыми просто необходимо каждому грамотному специалисту.

Большое влияние на авторов оказало общение с основателем и первым заведующим кафедрой вычислительной математики академиком О. М. Белоцерковским. Под руководством другого заведующего академика А. С. Холодова на кафедре сформировались выдающиеся научные и педагогические школы в области вычислительной математики и информатики*). Некоторые идеи А. С. Холодова, в частности, об исследовании численных методов в пространствах неопределенных коэффициентов, авторы старались отразить в книге.

Профессор Е. Н. Аристова, доцент О. А. Пыркова, старший преподаватель В. Д. Иванов высказали ряд конструктивных замечаний и предложений по тексту. Авторы выражают им свою благодарность. Авторы также благодарят Л. С. Исаченко за техническую помощь при оформлении рукописи.

*) Лобанов А. И. Научные и педагогические школы Александра Сергеевича Холодова // Компьютерные исследования и моделирование. 2018. Т. 10. № 5. С. 561–579.

ИСПОЛЬЗУЕМЫЕ ОБОЗНАЧЕНИЯ

α_k, β_k — неопределенные коэффициенты при построении численной схемы с помощью метода неопределенных коэффициентов;

$\mathbf{A}\mathbf{u} = \mathbf{f}$ — система линейных алгебраических уравнений (СЛАУ);

$\mathbf{A}$ — матрица, a_{ij} — компонент матрицы, $\|\mathbf{A}\|$ — норма матрицы;

$\mathbf{E}$ — единичная матрица;

$\mathbf{u}$ — вектор, u_i — компонента вектора; $\|\mathbf{u}\|$ — норма вектора;

$\mathbf{u}^k$ — элемент итерационной последовательности или значение сеточной функции на k -м слое при использовании оператора послыоного перехода;

$\mathbf{r}^k$ — невязка приближения к решению СЛАУ, $\mathbf{r}^k = \mathbf{f} - \mathbf{A}\mathbf{u}^k$;

Δ — определитель квадратной матрицы;

Δ — дифференциальный оператор Лапласа;

$\lambda, \lambda(\mathbf{A})$ — собственное число матрицы (в жестких системах — собственное число, соответствующее мягкому спектру);

$\mathbf{w}_k$ — собственный вектор, соответствующий собственному числу λ_k ;

$\mathbf{D}_k$ — матричный итерационный параметр на k -й итерации (в канонической форме записи двухслойного итерационного метода);

τ_k — скалярный итерационный параметр на k -й итерации (в канонической форме записи двухслойного итерационного метода), τ — если параметр не зависит от номера итерации;

δ — вектор приращения, вектор погрешностей;

∇ — дифференциальный оператор градиент;

$\Phi(\mathbf{u})$ — функционал, целевая функция в задачах минимизации;

$\mathbf{H}$ — матрица Гильберта;

t, x — независимые переменные в задачах (как правило, x , если в задаче нет выделенного направления);

τ, h — конечные приращения независимых переменных, шаги сетки по соответствующим переменным;

$\varphi_k(t), \varphi_k(x)$ — базисные функции при разложении по функциональному базису;

$\varphi_k^N(t)$ — базисные функции (полиномы) при построении интерполяционного многочлена степени N в форме Лагранжа;

$R_N(t)$ — остаточный член интерполяции многочленом степени N ;

$L_N(t)$ — интерполяционный полином в форме Лагранжа степени N ;

$N_N(t)$ — интерполяционный полином в форме Ньютона степени N ;

$f(t_i, t_{i+1}, t_{i+2}, \dots, t_{i+k})$ — разделенная разность порядка k ;

$L(t)$ — функция Лебега (сетки), l_N — постоянная Лебега;

$S_m(t)$ — сплайн степени m , $S(t)$ — сплайн степени 3;

m_i — момент кубического сплайна (значение второй производной в узле i);

I — определенный интеграл;

b_k — вес квадратуры;
 u^τ — сеточная функция — решение разностной задачи;
 U^τ — проекция на сетку точного решения дифференциальной задачи;
 $L_\tau u^\tau = F_\tau$ — абстрактная форма записи разностной задачи, $L\tau$ — разностный оператор;

$Lu = F$ — абстрактная форма записи дифференциальной задачи, L — дифференциальный оператор (в случае уравнений в частных производных — линейный дифференциальный оператор);

Λ_j — элемент жесткого спектра матрицы Якоби при решении жестких систем ОДУ, Λ_0 — граница жесткого спектра, Ω_k — собственный вектор, соответствующий собственному числу Λ_k ;

λ_j — элемент мягкого спектра матрицы Якоби при решении жестких систем ОДУ, λ_0 — граница мягкого спектра, Λ_0/λ_0 — показатель жесткости системы;

$R(z)$ — функция устойчивости (z — безразмерный комплексный параметр — произведение собственного числа матрицы Якоби на сеточный шаг), разрешающий оператор.

Разностные операторы

$\Delta^+ u_k = u_{k+1} - u_k$ — оператор взятия разности вперед;
 $\Delta^- u_k = u_k - u_{k-1}$ — оператор взятия разности назад;
 $(\Delta^+ + \Delta^-) u_k = u_{k+1} - u_{k-1}$ — оператор взятия центральной разности;
 $\Delta^+ \Delta^- u_k = \Delta^- \Delta^+ u_k = u_{k+1} - 2u_k + u_{k-1}$ — оператор второй разности.

Обозначения А. А. Самарского

$$\Lambda_h u_k = \frac{\Delta^+ u_k}{h} = \frac{u_{k+1} - u_k}{h},$$

$$\Lambda_{\bar{h}} u_k = \frac{\Delta^- u_k}{h} = \frac{u_k - u_{k-1}}{h},$$

$$\Lambda_h^\circ u_k = \frac{(\Delta^+ + \Delta^-) u_k}{2h} = \frac{u_{k+1} - u_{k-1}}{2h},$$

$$\Lambda_{h\bar{h}} u_k = \frac{(\Delta^+ \Delta^-) u_k}{h^2} = \frac{u_{k+1} - 2u_k + u_{k-1}}{h^2}.$$

ПРЕДМЕТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ. ОБУСЛОВЛЕННОСТЬ ЗАДАЧИ, УСТОЙЧИВОСТЬ АЛГОРИТМА, ПОГРЕШНОСТИ ВЫЧИСЛЕНИЙ. ЗАДАЧА ЧИСЛЕННОГО ДИФФЕРЕНЦИРОВАНИЯ

Первая лекция носит вводный характер. На простейших примерах иллюстрируются понятия численного алгоритма, устойчивость и обусловленность задачи. На примере задачи численного дифференцирования вводится метод неопределенных коэффициентов для получения приближенных формул. Рассматривается некорректность задачи численного дифференцирования.

К л ю ч е в ы е с л о в а: алгоритм, обусловленность задачи, устойчивость алгоритма, погрешности вычислений, задача численного дифференцирования, метод неопределенных коэффициентов.

1.1. Введение

Первое применение вычислительных методов, возможно, принадлежит древним египтянам, которые умели вычислять диагональ квадрата за конечное количество действий. Они также могли находить квадратный корень из 2, скорее всего, с помощью алгоритма, в дальнейшем получившего название метода Ньютона:

$$u_{k+1} = \frac{1}{2} \left(u_k + \frac{2}{u_k} \right), \quad u_0 = 2.$$

С именем среднеазиатского врача, философа и математика Аль-Хоремзи связано понятие алгоритма. Разработкой вычислительных методов занимались Л. Эйлер (которому принадлежит, по-видимому, первый численный метод для решения обыкновенных дифференциальных уравнений), И. Ньютон, О. Л. Коши, Ж. Л. Лагранж, А. М. Лежандр, П.-С. Лаплас, А. Пуанкаре, П. Л. Чебышёв и многие другие известные математики. Решающую роль в развитии вычислительной математики как самостоятельной науки сыграли немецкий математик Карл Рунге и русский математик, механик и кораблестроитель А. Н. Крылов.

В наше время вычислительная математика получила значительный импульс в 1950-е годы, что было связано с развитием ядерной физики, механики полета, аэродинамики спускаемых кос-

мических аппаратов. В дальнейшем решались задачи, связанные не только с расчетами действия ядерного взрыва и обтеканием боеголовок стратегических ракет. Численные методы нашли свое применение в таких областях, как динамика атмосферы, термогидрография океана, физика плазмы, механика горных пород и ледников, синергетика, биомеханика, методы оптимизации, машинное обучение, математическая экономика и др. Наиболее наукоемки и требуют максимальных вычислительных ресурсов задачи физики, механики и электродинамики сплошных сред. К ним относятся системы уравнений в частных производных Эйлера, Лагранжа, Максвелла и др., кинетической теории газов (уравнения Власова, Берда), а также задачи многомерной оптимизации. Развитие многих вычислительных методов — заслуга ученых, неразрывно связанных с МФТИ. Среди них следует упомянуть академиков А. А. Дородницына, О. М. Белоцерковского, А. А. Самарского, А. С. Холодова, Б. Н. Четверушкина, членов-корреспондентов РАН Ю. П. Попова, С. П. Курдюмова, профессоров В. С. Рябенского, Э. Э. Шноля, Р. П. Федоренко, Л. А. Чудова, В. Ф. Дьяченко, И. М. Гельфанда, Г. А. Тирского, А. П. Фаворского.

Вычислительная математика отличается от других математических дисциплин и обладает специфическими особенностями.

1. Вычислительная математика имеет дело не только с непрерывными, но и с дискретными объектами. Так, наряду с отрезком прямой рассматривается система точек $\{t_k\}_{k=0}^K$, вместе с непрерывной функцией $f(x)$ — табличная функция $\{f_k\}_{k=0}^K$, вместе с первой производной — ее разностная аппроксимация; например,

$$\frac{f_{k+1} - f_k}{x_{k+1} - x_k}, \quad k = 0, 1, \dots, K-1, \quad x_{k+1} > x_k.$$

Такие замены, естественно, порождают погрешности метода.

2. В машинных вычислениях присутствуют числа с ограниченным количеством знаков после запятой из-за конечности длины мантииссы при представлении действительного числа в памяти ЭВМ. Другими словами, в вычислениях присутствует машинная погрешность (округления) ϵ_m . Это приводит к вычислительным эффектам, неизвестным, например, в классической теории обыкновенных дифференциальных уравнений, уравнений математической физики или в математическом анализе.

3. В вычислительной практике большое значение имеет *обусловленность задачи*, т. е. чувствительность ее решения к малым изменениям входных данных.

4. В отличие от «классической» математики выбор вычислительного алгоритма влияет на результаты вычислений. Кроме того, даже в рамках выбранного алгоритма результат будет зависеть от конкретного порядка выполнения операций в компьютере. Этот порядок определяется как конкретной программной реализацией, так и особенностями использованного компьютера.

5. Существенная черта численного метода — *экономичность* вычислительного алгоритма, т. е. минимизация числа элементарных операций при выполнении его на ЭВМ.

6. Погрешности при численном решении задач делятся на две категории: неустраняемые и устранимые. К первым относят погрешности, связанные с построением математической модели объекта и приближенным заданием входных данных, ко вторым — погрешности метода решения задачи и ошибки округления, которые являются источниками малых возмущений, вносимых в решение задачи.

Специфику машинных вычислений можно пояснить на нескольких элементарных примерах.

1.2. Необходимые сведения из теории погрешностей

Определение 1.1. Пусть u и u^* — соответственно точное и приближенное значение некоторой величины. Тогда абсолютной погрешностью приближения u^* называется величина $\Delta(u^*)$, удовлетворяющая неравенству

$$|u - u^*| \leq \Delta(u^*).$$

Определение 1.2. Относительной погрешностью называется величина $\delta(u^*)$, удовлетворяющая неравенству

$$\left| \frac{u - u^*}{u^*} \right| \leq \delta(u^*).$$

Обычно используется запись $u = u^*(1 \pm \delta(u^*))$.

Определение 1.3. Пусть искомая величина u является функцией параметров $t_1, \dots, t_n \in \Omega$, u^* — приближенное значение u . Тогда предельной абсолютной погрешностью называется

ся величина

$$D(u^*) = \sup_{(t_1, \dots, t_n) \in \Omega} |u(t_1, \dots, t_n) - u^*|.$$

Предельной относительной погрешностью называется величина $D(u^*)/|u^*|$.

Пусть $|t_j - t_j^*| \leq \Delta(t_j^*)$, $j = 1, \dots, n$ — приближенное значение $u^* = u(t_1^*, \dots, t_n^*)$. Предполагаем, что u — непрерывно дифференцируемая функция своих аргументов. Тогда, по формуле Лагранжа,

$$u(t_1, \dots, t_n) - u^* = \sum_{j=1}^n \gamma_j(\alpha)(t_j - t_j^*),$$

где $\gamma_j(\alpha) = u'_{t_j}(t_1^* + \alpha(t_1 - t_1^*), \dots, t_n^* + \alpha(t_n - t_n^*))$, $0 \leq \alpha \leq 1$.

Отсюда

$$|u(t_1, \dots, t_n) - u^*| \leq D_1(u^*) = \sum_{j=1}^n b_j \Delta(t_j^*),$$

где $b_j = \sup_{\Omega} |u'_{t_j}(t_1, \dots, t_n)|$.

Можно показать, что при малых $\rho = \sqrt{(\Delta(t_1^*))^2 + \dots + (\Delta(t_n^*))^2}$ эта оценка не может быть существенно улучшена. На практике иногда пользуются грубой (линейной) оценкой

$$|u(t_1, \dots, t_n) - u^*| \leq D_2(u^*), \quad \text{где } D_2(u^*) = \sum_{j=1}^n |\gamma_j(0)| \Delta(t_j^*).$$

Несложно показать, что:

а) $\Delta(\pm t_1^* \pm t_2^*, \dots, \pm t_n^*) = \Delta(t_1^*) + \Delta(t_2^*) + \dots + \Delta(t_n^*)$, предельная погрешность суммы или разности равна сумме предельных погрешностей.

б) Предельная относительная погрешность произведения или частного приближенного равна сумме предельных относительных погрешностей

$$\delta(t_1^* \dots t_m^* \cdot d_1^{*-1} \dots d_m^{*-1}) = \delta(t_1^*) + \dots + \delta(t_m^*) + \delta(d_1^*) + \dots + \delta(d_m^*).$$

1.3. Обусловленность задачи

Пример 1.1. Вычислить все корни алгебраического уравнения

$$x^4 - 8x^3 + 24x^2 - 32x + \underbrace{15.99999999}_8 = (x - 2)^4 - 10^{-8} = 0.$$

Точное решение задачи легко найти:

$$(x - 2)^2 = \pm 10^{-4}, \\ x_1 = 2.01; \quad x_2 = 1.99; \quad x_{3,4} = 2 \pm 0.01i.$$

Если компьютер работает при $\epsilon_m > 10^{-8}$, то свободный член в исходном уравнении будет округлен до 16.0. С точки зрения представления чисел с плавающей точкой, будет решаться уравнение $(x - 2)^4 = 0$, т. е. $x_{1,2,3,4} = 2$, что, очевидно, неверно. В данном случае малые погрешности в задании свободного члена $\approx 10^{-8}$ привели, независимо от метода решения, к погрешности в решении $\approx 10^{-2}$.

Пример 1.2. Решается задача Коши для обыкновенного дифференциального уравнения 2-го порядка:

$$u''(t) = u(t), \quad u(0) = 1, \quad u'(0) = -1.$$

Общее решение имеет вид

$$u(t) = 0.5[u(0) + u'(0)]e^t + 0.5[u(0) - u'(0)]e^{-t}.$$

При заданных начальных данных точное решение задачи: $u(x) = e^{-t}$, однако малая погрешность δ в их задании приведет к появлению члена δe^t , который при больших значениях аргумента может существенно исказить решение.

Пример 1.3. Пусть необходимо найти решение обыкновенного дифференциального уравнения

$$\dot{u} = 10u, \quad u = u(t), \\ u(t_0) = u_0, \quad t \in [0; 1].$$

Его решение: $u(t) = u_0 e^{10(t-t_0)}$, однако значение $u(t_0)$ известно лишь приближенно: $u(t_0) \approx u_0^*$, и на самом деле $u^*(t) = u_0^* e^{10(t-t_0)}$.

Соответственно, разность $u^* - u$ будет

$$u^* - u = (u_0^* - u_0) e^{10(t-t_0)}.$$

Предположим, что необходимо гарантировать некоторую заданную точность вычислений $\varepsilon > 0$ всюду на отрезке $t \in [0; 1]$. Тогда должно выполняться условие

$$|u^*(t) - u(t)| \leq \varepsilon.$$

Очевидно, что $\max_{t \in [0; 1]} |u^*(t) - u(t)| = |u^*(1) - u(1)| = |u_0^* - u_0| e^{10(1-t_0)}$.

Отсюда можно получить требования к точности задания начальных данных δ : $|u_0^* - u_0| < \delta$, $\delta \leq \varepsilon e^{-10}$ при $t_0 = 0$.

Таким образом, требование к заданию точности начальных данных оказываются в e^{10} раз выше необходимой точности результата решения задачи. Это требование, скорее всего, окажется нереальным.

Решение оказывается очень чувствительным к заданию начальных данных. Такого рода задачи называются *плохо обусловленными*.

Пример 1.4. Решением системы линейных алгебраических уравнений (СЛАУ)

$$\begin{cases} u + 10v = 11, \\ 100u + 1001v = 1101 \end{cases}$$

является пара чисел $\{1; 1\}$.

Изменив правую часть системы на 0.01, получим возмущенную систему

$$\begin{cases} u + 10v = 11.01, \\ 100u + 1001v = 1101 \end{cases}$$

с решением $\{11.01; 0.00\}$, сильно отличающимся от решения невозмущенной системы. Эта система также плохо обусловлена.

Пример 1.5. Рассмотрим полином

$$(x-1)(x-2)\dots(x-20) = x^{20} - 210x^{19} + \dots,$$

корни которого $x_1 = 1, x_2 = 2, \dots, x_{20} = 20$.

Положим, что коэффициент -210 при x_{19} увеличен на $\approx 10^{-7}$. В результате вычислений с 11-ю значащими цифрами получим совершенно иные корни: $x_1 = 1.00$; $x_2 = 2.00$; $x_3 = 3.00$; $x_4 = 4.00$; $x_5 = 5.00$; $x_6 = 6.00$; $x_7 = 7.00$; $x_8 = 8.01$; $x_9 = 8.92$; $x_{10,11} = 10.1 \pm 0.644i$; $x_{12,13} = 11.8 \pm 1.65i$; $x_{14,15} = 14.0 \pm 2.52i$; $x_{16,17} = 16.7 \pm 2.81i$; $x_{18,19} = 19.5 \pm 19.4i$; $x_{20} = 20.8$.

Причина значительного расхождения также заключается в плохой обусловленности задачи вычисления корней рассматриваемого выражения.

1.4. Влияние конечной длины мантиссы и выбора вычислительного алгоритма на результаты вычислений

Пример 1.6. Пусть необходимо вычислить значение выражения $\left(\frac{\sqrt{2}-1}{\sqrt{2}+1}\right)^3$. Избавившись от знаменателя, получаем $(\sqrt{2}-1)^6 = (3-2\sqrt{2})^3 = 99-70\sqrt{2}$.

Заменим иррациональное число $\sqrt{2}$ его рациональными приближениями: а) $\sqrt{2} \approx 7/5 = 1.4$; б) $\sqrt{2} \approx 17/12 = 1.41(6)$. Эти приближения можно трактовать как использование разной длины мантиссы для конечного представления иррациональной величины. Получим следующие результаты:

$\sqrt{2}$	$(\sqrt{2}-1)^6$	$(3-2\sqrt{2})^3$	$99-70\sqrt{2}$
7/5	0.004096	0.008000	1
17/12	0.005233	0.004630	-0.1(6)

Очевидно, что столь значительное различие в результатах вызвано влиянием ошибки округления в задании $\sqrt{2}$.

Пример 1.7. Вычисление функции $\sin x$ с помощью ряда Тейлора.

Из курса математического анализа известно, что функция $\sin x$ представляется своим рядом Тейлора:

$$\sin x = x - \frac{x^3}{3!} + \frac{x^5}{5!} - \frac{x^7}{7!} + \dots,$$

причем радиус сходимости ряда равен бесконечности — ряд сходится при любых значениях x .

Вычислим значения синуса при двух значениях аргумента. Пусть сначала $x = 0.5236$ (30°). Будем учитывать лишь те члены ряда, которые по абсолютной величине больше, чем 10^{-4} . Выполнив вычисления с четырьмя значащими цифрами, получим $\sin(0.5236) = 0.5000$, что соответствует принятой точности.

Пусть теперь $x = 25.66$ (1470°). Если вычисления по данной формуле проводить с восемью значащими цифрами, то получим абсурдный результат: $\sin(25.66) \approx 24$ (учитывались члены ряда большие, чем 10^{-8}).

Разумеется, выходом из создавшейся ситуации может быть использование формул приведения.

Пример 1.8. Вычисление функции e^x с помощью ряда Тейлора.

Из курса математического анализа известно, что экспонента представляется своим рядом Тейлора:

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots,$$

радиус сходимости этого ряда также равен бесконечности.

Приведем некоторые результаты расчетов (e_m^x — значения экспоненты, вычисленные на компьютере).

x	e^x	e_m^x
1	2.718282	2.718282
20	$4.8516520 \cdot 10^8$	$4.8516531 \cdot 10^8$
-1	0.3678795	0.3678794
-10	$4.5399930 \cdot 10^{-5}$	$-1.6408609 \cdot 10^{-4}$
-20	$2.0611537 \cdot 10^{-9}$	1.202966

Выходом из этой ситуации может быть использование для отрицательных аргументов экспоненты формулы

$$e^{-x} = \frac{1}{e^x} = \frac{1}{1 + x + \frac{x^2}{2!} + \dots}.$$

Естественно ожидать рост ошибок округления при вычислении рассматриваемой функции при больших значениях аргумента x .

В этом случае можно использовать формулу $e^x = e^{n+a} = e^n e^a$, где $n = [x]$.

Пример 1.9. Рассмотрим следующий метод вычисления интеграла

$$I_n = \int_0^1 x^n e^{1-x} dx, \quad n = 1, 2, \dots$$

Интегрирование по частям дает

$$\begin{aligned} I_n &= \int_0^1 x^n d(-e^{1-x}) - x^{n-1} e^{1-x} + \int_0^1 e^{1-x} d(x^n) = \\ &= -1 + \int_0^1 n x^{n-1} e^{1-x} dx, \end{aligned}$$

откуда следует $I_0 = \int_0^1 e^{1-x} dx = e - 1 \approx 1.71828$. $I_n = nI_{n-1} - 1$, $n \geq 1$. Тогда

$$\begin{aligned} I_1 &= 1 \cdot I_0 - 1 \approx 0.71828, & I_2 &= 2I_1 - 1 \approx 0.43656, \\ I_3 &= 3I_2 - 1 \approx 0.30968, & I_4 &= 4I_3 - 1 \approx 0.23872, \\ I_5 &= 5I_4 - 1 \approx 0.1936, & I_6 &= 6 \cdot I_5 - 1 \approx 0.16160, \\ I_7 &= 7I_6 - 1 \approx 0.13120, & I_8 &= 8I_7 - 1 \approx 0.00496, \\ I_9 &= 9I_8 - 1 \approx -0.55360, & I_{10} &= 10 \cdot I_9 - 1 \approx -6.5360. \end{aligned}$$

Очевидно, что отрицательные значения при $n = 9, 10$ не имеют смысла. Дело в том, что ошибка, сделанная при округлении I_0 до 6 значащих цифр, сохранилась при вычислении I_1 , умножилась на 2! при вычислении I_2 , на 3! — при вычислении I_3 и так далее, т. е. ошибка растет очень быстро, пропорционально $n!$.

Пример 1.10. Рассмотрим методический пример вычислений на модельном компьютере, обеспечивающем точность $\epsilon_m = 0.0005$. Проанализируем причину происхождения ошибки, например, при вычитании двух чисел, взятых с точностью до третьей цифры после десятичной точки $u = 1.001$, $v = 1.002$, разность которых составляет $\Delta = |v_m - u_m| = 0.001$.

В памяти машины эти же числа представляются в виде $u_M = u(1 + \delta_M^u)$, $v_M = v(1 + \delta_M^v)$, причем $|\delta_M^u| \leq \epsilon_M$ и $|\delta_M^v| \leq \epsilon_M$. Тогда $u_M - u \approx u\delta_M^u$, $v_M - v \approx v\delta_M^v$.

Относительная ошибка при вычислении разности $u_M - v_M$ будет равна

$$\delta = \frac{(u_M - v_M) - (u - v)}{(u - v)} = \frac{(u_M - u) - (v_M - v)}{(u - v)} = \frac{\delta_M^u - \delta_M^v}{(u - v)}.$$

Очевидно, что $\delta = \left| \frac{\delta_M^u - \delta_M^v}{\Delta} \right| \leq \frac{2\epsilon_M}{0.001} \approx 2000\epsilon_M = 1$, т.е. все значащие цифры могут оказаться неверными.

Пример 1.11. Рассмотрим рекуррентную последовательность $u_{i+1} = qu_i$, $i \geq 0$, $u_0 = a$, $q > 0$, $u_i > 0$.

Пусть при выполнении реальных вычислений с конечной длиной мантиссы на i -м шаге возникла погрешность округления, и вычисления проводятся с возмущенным значением $u_i^M = u_i + \delta_i$, тогда вместо u_{i+1} получим $u_{i+1}^M = q(u_i + \delta_i) = u_{i+1} + q\delta_i$, т.е. $\delta_{i+1} = q\delta_i$, $i = 0, 1, \dots$

Следовательно, если $|q| > 1$, то в процессе вычислений погрешность, связанная с возникшей ошибкой округления, будет возрастать (алгоритм неустойчив). В случае $|q| \leq 1$ погрешность не возрастает, и численный алгоритм устойчив.

1.5. Экономичность вычислительного метода

Пример 1.12. Пусть требуется вычислить сумму $S = 1 + x + x^2 + \dots + x^{1023}$ при $0 < x < 1$. Для последовательного вычисления x , $x^2 = x \cdot x$, ..., $x^{1023} = x^{1022} \cdot x$ необходимо проделать 1022 умножения, а затем столько же сложений.

Однако если заметить, что $S = \frac{1 - x^{1024}}{1 - x}$, то количество арифметических действий значительно уменьшается; в частности, для вычисления x^{1024} требуется всего 10 умножений: $x^2 = x \cdot x$; $x^4 = (x^2)^2$, ..., $x^{1024} = (x^{512})^2$.

Пример 1.13. Вычисления значений многочленов. Если вычислять значение многочлена $P(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$ «в лоб», т.е. вычислять значения каждого члена и суммировать, то окажется, что необходимо выполнить $(n^2 + [n/2])$ умножений

и n сложений. Кроме того, такой способ вычислений может привести к накоплению ошибок округления при вычислениях с плавающей точкой.

Его очевидным улучшением является вычисление каждого члена последовательным умножением на x . Такой алгоритм требует $2n - 1$ умножение и n сложений.

Еще более экономичным алгоритмом является хорошо известная в алгебре схема Горнера:

$$P(x) = (\dots((a_n x + a_{n-1})x + a_{n-2})x + \dots + a_0),$$

требуемая n операций сложения и n операций умножения. Этот метод был известен в средние века в Китае под названием Тянь-Юань и был заново открыт в Европе в начале XIX века англичанином Горнером и итальянцем Руффини.

Пример 1.14. Рассмотрим систему линейных алгебраических уравнений (СЛАУ) вида $\mathbf{A}\mathbf{u} = \mathbf{f}$, $\mathbf{u} = \{u_1, \dots, u_n\}^T$, $\mathbf{f} = \{f_1, \dots, f_n\}^T$, с трехдиагональной матрицей

$$\mathbf{A} = \begin{pmatrix} b_1 & c_1 & 0 & \dots & 0 \\ a_2 & b_2 & c_2 & \dots & 0 \\ 0 & a_3 & b_3 & c_3 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & 0 & a_n & b_n \end{pmatrix}.$$

Если проводить решение такой системы без учета специфической структуры матрицы (например, с помощью метода Гаусса), то количество арифметических действий будет порядка n^3 , если же учесть эту структуру, то количество операций можно уменьшить до n .

1.6. Погрешность метода

Оценим погрешность при вычислении первой производной при помощи формулы численного дифференцирования $f'(x) \approx \frac{f(x+h) - f(x)}{h}$, $f(x)$ — гладкая функция:

$$\frac{f(x+h) - f(x)}{h} = \frac{[f(x) + hf'(x) + O(h^2)] - f(x)}{h} = f'(x) + O(h),$$

где $O(h)$ есть погрешность метода. В данном случае под погрешностью метода понимается абсолютная величина разности $\left|f'(x) - \frac{f(x+h) - f(x)}{h}\right|$, которая составляет $O(h)$ (более точно $\frac{h}{2}f''(\xi)$, где $\xi \in [x; x+h]$).

Если же взять другой метод вычисления производной $f'(x) \approx \frac{f(x+h) - f(x-h)}{2h}$, то получим, что его погрешность составляет $O(h^2)$, это оказывается существенным при малых h . Однако уменьшать h до бесконечности не имеет смысла, что видно из следующего примера. Введем обозначения $M_0 = \max|f(x)|, \dots, M_k = \max|f^{(k)}(x)|$. Реальная погрешность при вычислении первой производной будет

$$\Delta = \frac{h}{2}M_2 + \frac{2M_0\epsilon_m}{h} = O(h) + O(h^{-1}),$$

поскольку абсолютная погрешность вычисления значения функции за счет машинного округления не превосходит $2M_0\epsilon_m/h$.

В этом случае можно найти оптимальный шаг h . Будем считать полную погрешность в вычислении производной Δ функцией шага h . Отыщем минимум этой функции. Приравняв производную $\Delta'_h(h)$ к нулю, получим оптимальный шаг численного дифференцирования

$$h_{\text{опт}} = 2\sqrt{\frac{M_0\epsilon_m}{M_2}}.$$

Выбирать значение h меньше оптимального не имеет смысла, так как при дальнейшем уменьшении шага суммарная погрешность начинает расти из-за возрастания вклада ошибок округления.

1.7. Задача численного дифференцирования

В §1.4 уже была введена простейшая формула численного дифференцирования. Рассмотрим задачу приближенного вычисления значения производной подробнее.

Пусть задана таблица значений x_i . В дальнейшем совокупность точек на отрезке, на котором проводятся вычисления, иногда будем называть *сеткой*, каждое значение x_i — *узлом сетки*. Пусть сетка — равномерная и расстояние между узлами равно h — *шагу сетки*. Пусть узлы сетки пронумерованы в порядке возрастания, т. е.

$$x_0 = a,$$

$$x_j = a + jh, \quad j = 0, 1, \dots, N.$$

Пусть $f(x_j) = f_j$ — функция, определенная в узлах сетки. Такие функции будут называться табличными (или сеточными) функциями. Считаем, кроме того, что рассматриваемая сеточная функция есть проекция (или ограничение) на сетку некоторой гладкой нужное число раз непрерывно дифференцируемой функции $f(x)$. По определению производной

$$f'(x) = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x},$$

тогда, если шаг сетки достаточно мал, по аналогии можно написать формулу в конечных разностях, дающую приближенное значение производной сеточной функции:

$$f'(x_j) \approx \frac{f(x_j + h) - f(x_j)}{h}. \quad (1.1)$$

Если параметр h достаточно мал, то можно считать полученное значение производной достаточно точным. Погрешность формулы (1.1) оценена в § 1.4. Как показано выше, при уменьшении шага сетки h ошибка будет уменьшаться, но при некотором значении h ошибка может возрасти до бесконечности. При оценке погрешности метода обычно считается, что все вычисления были точными. Но существует ошибка округления. При оценке ее большую роль играет машинный ϵ — мера относительной погрешности машинного округления, возникающей из-за конечной разрядности мантииссы при работе с числами в формате с плавающей точкой. Напомним, что по определению машинным ϵ называют наибольшее из чисел, для которых в рамках используемой системы вычислений выполнено $1 + \epsilon_m = 1$. Тогда абсолютная погрешность при вычислении значения функции (или представлении табличной функции) есть $f(x_j)\epsilon_m$. Максимальный вклад погрешностей округления при вычислении производной по формуле (1.1) будет $\max_j |f(x_j)| \epsilon_m h^{-1}$, тогда, когда члены в знаменателе (1.1) имеют ошибки разных знаков.

Напомним, что $M_k = \max_{[a; b]} |f^{(k)}(x)|$, максимум ищется на отрезке, на котором вычисляются значения производных. В этом случае суммарная ошибка, состоящая из погрешности метода и погрешности округления, есть $\Delta = \frac{2M_0\epsilon_m}{h} + \frac{M_2h}{2}$.

Для вычисления оптимального шага численного дифференцирования найдем минимум суммарной ошибки как функции шага

сетки $\frac{M_2}{2} - \frac{2M_0\epsilon_m}{h^2} = 0$, откуда

$$h_{\text{opt}} = 2\sqrt{\frac{M_0\epsilon_m}{M_2}}.$$

Если требуется повысить точность вычисления производных, необходимо воспользоваться формулами, имеющими меньшие погрешности метода. Так, из курсов математического анализа известно, что

$$f'(x) = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x - \Delta x)}{2\Delta x}.$$

По аналогии напомним конечно-разностную формулу

$$f'(x_j) \approx \frac{f(x_j + h) - f(x_j - h)}{2h}. \quad (1.2)$$

Это формула с центральной разностью. Исследуем ее на аппроксимацию, т.е. оценим погрешность метода. Предположим, что функция, которую спроектировали на сетку, трижды непрерывно дифференцируема, тогда справедливы разложения в ряд Тейлора в окрестности x_j :

$$f(x_j + h) = f(x_j) + f'(x_j)h + f''(x_j)\frac{h^2}{2} + f'''(x_j + \theta_1 h)\frac{h^3}{6},$$

$$f(x_j - h) = f(x_j) - f'(x_j)h + f''(x_j)\frac{h^2}{2} - f'''(x_j - \theta_2 h)\frac{h^3}{6}.$$

Погрешность метода определяется 3-й производной функции. Суммарная погрешность при вычислении по формуле с центральной разностью есть

$$\Delta = \frac{M_3 h^2}{3} + \frac{M_0 \epsilon_m}{h}.$$

Для вычисления оптимального шага находим минимум погрешности как функции шага сетки. Из условия равенства нулю первой производной по h

$$\frac{2M_3 h}{6} - \frac{M_0 \epsilon_m}{h^2} = 0,$$

тогда

$$h_{\text{opt}} = \sqrt[3]{\frac{3M_0\epsilon_m}{M_3}}.$$

Для более точного вычисления производной необходимо использовать разложение более высокого порядка, шаг h_{opt} будет увеличиваться.

Формула (1.1) — двухточечная, (1.2) — трехточечная: при вычислении производной используются точки (узлы) x_j (узел входит с нулевым коэффициентом), $x_j + h$, $x_j - h$. Совокупность узлов, участвующих в каждом вычислении производной, в дальнейшем будем иногда называть *сеточным шаблоном*.

Введем на рассматриваемом отрезке шаблон из нескольких точек.

Считаем, что сетка равномерная — шаг сетки постоянный, расстояния между любыми двумя соседними узлами равны. Используем для вычисления значения первой производной следующую приближенную (конечно-разностную) формулу:

$$f'(x_j) \approx \frac{1}{h} \sum_{k=-l}^m \alpha_k f(x_j + kh), \quad (1.3)$$

шаблон включает l точек слева от рассматриваемой точки x_j и m справа. Коэффициенты α_k — *неопределенные коэффициенты*. Формула дифференцирования может быть и *односторонней* — либо l , либо m могут равняться нулю. В первом случае иногда называют (на наш взгляд, не слишком удачно) такую приближенную формулу формулой дифференцирования вперед, во втором — формулой дифференцирования назад. Потребуем, чтобы (1.3) приближала первую производную с точностью $O(h^{l+m})$. Используем разложения в ряд Тейлора в окрестности точки x_j . Подставляя их в (1.3), получим

$$\begin{aligned} \frac{1}{h} \sum_{k=-l}^m \alpha_k f(x_j + kh) &= \\ &= \frac{1}{h} f(x_j) \sum \alpha_k + f'(x_j) \sum k \alpha_k + f''(x_j) \sum \frac{k^2}{2} \alpha_k h + \\ &+ f'''(x_j) \sum \frac{k^3}{6} \alpha_k h^2 + \dots + f^{(n)}(x_j) \sum \alpha_k \frac{k^n}{n!} h^{n-1} + \dots \end{aligned}$$

Потребуем выполнения условий

$$\sum \alpha_k = 0, \quad \sum k \alpha_k = 1, \quad \sum \alpha_k \frac{k^2}{2} = 0, \quad \dots, \quad \sum \alpha_k \frac{k^n}{n!} = 0, \quad \dots \quad (1.4)$$

Получаем систему линейных алгебраических уравнений для неопределенных коэффициентов α (1.4). Матрица этой системы есть

$$\begin{pmatrix} 1 & 1 & \dots & 1 \\ -l & -l+1 & \dots & m \\ l^2 & (l-1)^2 & \dots & m^2 \\ (-l)^3 & (-l+1)^3 & \dots & m^3 \\ \dots & \dots & \dots & \dots \end{pmatrix}.$$

Вектор правых частей $(0, 1, 0, \dots, 0)^T$.

Определитель данной матрицы — детерминант Вандермонда. Из курса линейной алгебры известно, что он не равен нулю. Тогда существует единственный набор коэффициентов α , который позволяет найти на шаблоне из $1+l+m$ точек значение первой производной с точностью $O(h^{l+m})$.

Для нахождения второй производной можно использовать ту же самую формулу (1.3) с небольшой модификацией:

$$f''(x_j) \approx \frac{1}{h^2} \sum_{k=-l}^m \alpha_k f(x_j + kh),$$

только теперь $\sum k\alpha_k = 0$, $\sum \alpha_k k^2 = 1/2$. Остальные уровни останутся без изменений.

Очевидно, что и данная система уравнений для нахождения неопределенных коэффициентов имеет единственное решение. Для получения с той же точностью приближенных значений производных до порядка $l+m$ включительно с точностью $O(h^{l+m+p-1})$, где p — порядок производной, модификации формулы (1.3) и условий (1.4) очевидны, набор неопределенных коэффициентов находится единственным образом.

Таким образом, доказано следующее утверждение. На сеточном шаблоне, включающем в себя $N+1$ точку, с помощью метода неопределенных коэффициентов всегда можно построить единственную формулу для вычисления производной от первого до N -го порядка включительно с точностью не хуже $O(h^{N-p})$, где p — порядок производной.

Утверждение доказано для равномерной сетки, но на случай произвольных расстояний между сеточными узлами обобщение проводится легко.

Так как на практике вычисления проводятся с конечной длиной мантииссы, то получить нулевую ошибку принципиально невозможно.

Читателям предлагается оценить значение оптимального шага при вычислениях по формулам типа (1.3) самостоятельно.

1.8. Примеры решения задач

1. Найти абсолютную предельную погрешность, погрешность по производной, линейную погрешность для функции $u = t^{10}$, если заданы точка приближения $t^* = 1$, значение функции u^* в этой точке и погрешность $\Delta t^* = 10^{-1}$.

Р е ш е н и е. Обозначим

$$b = \sup_{|t-1| \leq 0.1} |u'_t(t)| = \sup_{|t-1| \leq 0.1} 10t^9 = 10 \cdot (1.1)^9 \approx 23.57 \dots$$

Абсолютная предельная погрешность может быть определена как

$$D(u^*) = \sup_{|t-1| \leq 0.1} |t^{10} - 1| = (1.1)^{10} - 1 \approx 1.5 \dots$$

Оценка погрешности u при вычислении значения функции по максимуму производной и линейная оценка соответственно будут $D_1(u^*) = b \Delta(t^*) = 2, 3, \dots$; $D_2(u^*) = |\gamma(0)| \Delta(t^*) = 1$.

2. Дать линейную оценку погрешности при вычислении неявной функции $\varphi(u, t_1, t_2, \dots, t_n) = 0$, если известны точка приближения $\{t_1^*, \dots, t_n^*\}$, значение функции в точке приближения u^* и погрешность в определении аргументов $\Delta t_1^*, \dots, \Delta t_n^*$.

Р е ш е н и е. Дифференцируя по t_j , получим

$$\frac{\partial \varphi}{\partial u} \frac{\partial u}{\partial t_j} + \frac{\partial \varphi}{\partial t_j} = 0,$$

откуда

$$\frac{\partial u}{\partial t_j} = - \left(\frac{\partial \varphi}{\partial t_j} \right) \left(\frac{\partial \varphi}{\partial u} \right)^{-1}.$$

При заданных $\{t_1^*, \dots, t_n^*\}$, можно найти u^* как корень уравнения $\varphi(u, t_1, t_2, \dots, t_n) = 0$, а затем — значения

$$b_j(0) = - \left(\frac{\partial \varphi}{\partial t_j} \right) \left(\frac{\partial \varphi}{\partial u} \right)^{-1} \Big|_{(u^*, t_1^*, \dots, t_n^*)},$$

откуда можно получить линейную оценку погрешности функции $D_2(u^*)$.

3. Вычислить относительную погрешность в определении значения функции $u = xy^2z^3$, если $x^* = 37.1$, $y^* = 9.87$, $z^* = 6.052$, $\Delta x^* = 0.3$, $\Delta y^* = 0.11$, $\Delta z^* = 0.016$.

Р е ш е н и е. $\delta_x = \frac{0.3}{37.1} \approx 0.81 \cdot 10^{-2}$, $\delta_y = \frac{0.11}{9.87} \approx 1.12 \cdot 10^{-2}$, $\delta_z = \frac{0.016}{6.052} \approx 0.26 \cdot 10^{-2}$, $\delta(u) = \delta(x^*) + 2\delta(y^*) + 3\delta(z^*) = 3.8 \cdot 10^{-2}$.

4. Оценить погрешность в определении корней квадратного уравнения $\varphi(u, t_1, t_2) = u^2 + t_1u + t_2 = 0$, если заданы приближения t_1^* , t_2^* , $\Delta(t_1^*)$, $\Delta(t_2^*)$.

Пусть u^* — решение уравнения

$$u^{*2} + t_1^*u^* + t_2^* = 0.$$

Из формулы

$$b_j(0) = -\left(\frac{d\varphi}{dt_j}\right)\left(\frac{d\varphi}{du}\right)^{-1} \Big|_{(u^*, t_1^*, \dots, t_n^*)}$$

получим

$$b_1(0) = \frac{du}{dt_1} \Big|_{(t_1^*, t_2^*)} = -\frac{u^*}{2u^* + t_1^*},$$

$$b_2(0) = \frac{du}{dt_2} \Big|_{(t_1^*, t_2^*)} = -\frac{1}{2u^* + t_1^*}.$$

Следовательно, линейная оценка будет

$$D_2(u^*) = \frac{|u^*| \cdot \Delta(t_1^*) + \Delta(t_2^*)}{|2u^* + t_1^*|}.$$

Библиографический комментарий к Лекции 1

Необходимые сведения об элементарной теории погрешностей можно найти в учебниках [1–6]. Для практических занятий по данному разделу можно использовать задачи из [8]. Исследованию влияния погрешностей округления на результаты решения конкретных задач посвящена первая лабораторная работа [7].

ЛЕКЦИЯ 2

ЧИСЛЕННОЕ РЕШЕНИЕ СИСТЕМ ЛИНЕЙНЫХ АЛГЕБРАИЧЕСКИХ УРАВНЕНИЙ

Рассматриваются часто употребляемые приближенные методы решения систем линейных алгебраических уравнений. Вводятся согласованные нормы векторов и матриц. Вычисляется число обусловленности в различных нормах. Анализируется влияние ошибок округления на погрешность результата. Дается понятие о спектральных задачах. Для самосопряженной матрицы рассматривается метод вращений поиска собственных значений.

Ключевые слова: системы линейных алгебраических уравнений, согласованные нормы вектора и матрицы, обусловленность системы, число обусловленности матрицы, прямые методы, метод Гаусса, метод Гаусса с выбором главного элемента, LU -разложение, итерационные методы, метод простых итераций, методы Якоби, Зейделя, верхней релаксации, метод наискорейшего спуска, метод сопряженных градиентов, спектральные задачи, метод вращений.

К численному решению систем линейных алгебраических уравнений (СЛАУ) сводятся многие задачи математической физики. Математические модели, представляющие собой СЛАУ большой размерности, встречаются в математической экономике, биологии и т. п. Теория получения приближенных решений СЛАУ — часть вычислительной линейной алгебры. Сама вычислительная линейная алгебра, по-видимому, является наиболее обширной темой во всем курсе вычислительной математики. По прикладной линейной алгебре существует обширная литература (например, [9–17]), а программы, реализующие наиболее популярные алгоритмы вычислительной линейной алгебры, являются неотъемлемой частью прикладного программного обеспечения, в частности, современных математических пакетов.

2.1. Постановка задачи

Рассмотрим СЛАУ

$$Au = f, \tag{2.1}$$

где $\mathbf{A}$ — действительная невырожденная ($\det \mathbf{A} \neq 0$) квадратная матрица размером $n \times n$

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix},$$

$\mathbf{u} = \{u_1, \dots, u_n\}^T$ — действительный вектор-столбец решения, $\mathbf{f} = \{f_1, \dots, f_n\}^T$ — действительный вектор-столбец правой части. Ограничим рассмотрение случаем, когда все величины действительные, рассмотренные методы можно обобщить на комплексный случай.

Так как матрица системы — невырожденная ($\Delta = \det \mathbf{A} \neq 0$), то решение системы (2.1) существует и единственно.

Из курса линейной алгебры [14] известно правило Крамера нахождения решения. Так, каждый компонент вектора неизвестных может быть вычислен как $u_i = \Delta_i / \Delta$, где Δ_i — определитель матрицы, получаемой из $\mathbf{A}$ заменой i -го столбца столбцом правых частей. Однако несложные арифметические оценки позволяют понять, что использование этой формулы приводит к неоправданно большим затратам машинного времени [11]. Так, например, если одно слагаемое в Δ вычисляется за 10^{-6} с, то время расчета для $n = 100$ на существующих в момент написания книги компьютерах будет измеряться годами.

На самом деле в настоящее время с помощью компьютеров численно решаются СЛАУ намного более высокого порядка (примерно до $n \approx 10^6 \div 10^8$). Такие решения осуществляются при помощи *прямых* или *итерационных* численных методов. *Прямые методы* позволяют в предположении отсутствия ошибок округления (при проведении расчетов на идеальном, т. е. бесконечноразрядном компьютере) получить точное решение задачи за конечное число арифметических действий. *Итерационные* методы, или методы последовательных приближений, позволяют вычислить последовательность $\{\mathbf{u}^k\}$, сходящуюся к решению задач при $k \rightarrow \infty$ (на практике, разумеется, ограничиваются конечным k , в зависимости от требуемой точности).

Однако неточность в задании правых частей и элементов матрицы $\mathbf{A}$ может приводить к значительным погрешностям при вычислении решения (2.1). В первой лекции на примере было показано, что такое явление наблюдается в случае плохо обусловлен-

ной системы. Остановимся подробнее на важном вопросе оценки погрешности решения СЛАУ.

Для этого напомним некоторые сведения из функционального анализа, которые понадобятся в дальнейшем.

2.2. Согласованные нормы векторов и матриц

Перед прочтением данного параграфа рекомендуется вспомнить понятие «норма» и основные факты о нормах и нормированных пространствах. Краткая сводка содержится в Приложении 1.

В векторном n -мерном вещественном нормированном пространстве введем следующие нормы вектора:

кубическая:

$$\|\mathbf{u}\|_1 = \max_{1 \leq i \leq n} |u_i|, \quad (2.2)$$

октаэдрическая:

$$\|\mathbf{u}\|_2 = \sum_{i=1}^n |u_i|, \quad (2.3)$$

евклидова (в комплексном случае — эрмитова):

$$\|\mathbf{u}\|_3 = \left(\sum_{i=1}^n |u_i|^2 \right)^{1/2} = (\mathbf{u}, \mathbf{u})^{1/2}. \quad (2.4)$$

Рассмотрим квадратную матрицу $\mathbf{A}$ и связанное с ней линейное преобразование $\mathbf{v} = \mathbf{A}\mathbf{u}$, где $\mathbf{v}, \mathbf{u} \in R^n$ (R^n — n -мерное вещественное нормированное пространство). Норма матрицы определяется как действительное неотрицательное число, характеризующее это преобразование и определяющееся как

$$\|\mathbf{A}\| = \sup_{\|\mathbf{u}\| \neq 0} \frac{\|\mathbf{A}\mathbf{u}\|}{\|\mathbf{u}\|}. \quad (2.5)$$

Укажем некоторые свойства нормы матрицы:

$$\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|,$$

$$\|\lambda \mathbf{A}\| = |\lambda| \|\mathbf{A}\|,$$

$$\|\mathbf{AB}\| \leq \|\mathbf{A}\| \|\mathbf{B}\|,$$

$$\|\mathbf{A}\| = 0 \text{ тогда и только тогда, когда } \mathbf{A} = 0.$$

Заметим, что норму матрицы (2.5) называют подчиненной нормой вектора. Говорят, что норма матрицы $\mathbf{A}$ согласована с нормой

вектора $\mathbf{u}$, если выполнено условие

$$\|\mathbf{A}\mathbf{u}\| \leq \|\mathbf{A}\| \|\mathbf{u}\|.$$

Нетрудно видеть, что подчиненная норма согласована с соответствующей метрикой векторного пространства. В самом деле,

$$\|\mathbf{A}\| = \sup_{\|\mathbf{u}\| \neq 0} \frac{\|\mathbf{A}\mathbf{u}\|}{\|\mathbf{u}\|} \geq \frac{\|\mathbf{A}\mathbf{u}\|}{\|\mathbf{u}\|}, \quad \text{откуда } \|\mathbf{A}\mathbf{u}\| \leq \|\mathbf{A}\| \|\mathbf{u}\|.$$

Согласованные с введенными выше нормами векторов нормы матриц будут вычисляться по компонентам матрицы следующим образом:

$$\|\mathbf{A}\|_1 = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|,$$

$$\|\mathbf{A}\|_2 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|,$$

$$\|\mathbf{A}\|_3 = \sqrt{\max_{1 \leq i \leq n} \lambda^i(\mathbf{A}^* \cdot \mathbf{A})}.$$

Покажем, как получается выражение для подчиненной нормы матрицы $\|\mathbf{A}\|_1$, соответствующей норме вектора $\|\mathbf{u}\|_1$.

Оценим норму вектора $\|\mathbf{A}\mathbf{u}\|_1$:

$$\begin{aligned} \|\mathbf{A}\mathbf{u}\|_1 &= \max_i \left| \sum_j a_{ij} u_j \right| \leq \max_i \left(\sum_j |a_{ij}| |u_j| \right) \leq \\ &\leq \left(\max_i \sum_j |a_{ij}| \right) \max_j |u_j| = \left(\max_i \sum_j |a_{ij}| \right) \|\mathbf{u}\|_1, \end{aligned}$$

откуда $\|\mathbf{A}\mathbf{u}\|_1 / \|\mathbf{u}\|_1 \leq \max_i \sum_j |a_{ij}|$. По определению нормы матрицы как точной верхней грани отношения $\|\mathbf{A}\mathbf{u}\| / \|\mathbf{u}\|$, $\max_j \sum_i |a_{ij}| = \|\mathbf{A}\|_1$, если существует вектор, на котором точная верхняя грань достигается.

Таким вектором является, например, $\mathbf{v}_k = \{\text{sign } a_{k1}, \dots, \text{sign } a_{kn}\}^T$, при этом допустим, что максимум в последнем неравенстве достигается при $i = k$.

Поскольку $\|\mathbf{v}_k\| = k$, то $\sum_j a_{kj} v_j = \sum_j |a_{kj}| = \max_i \sum_j |a_{ij}|$.

Тогда в соответствии с выражением для первой нормы вектора получаем

$$\|\mathbf{A}\mathbf{v}\|_1 = \max_i \sum_j |a_{ij}|.$$

Таким образом, точная верхняя грань в рассмотренном неравенстве достижима и действительно $\|\mathbf{A}\|_1 = \max_i \sum_j |a_{ij}|$.

Для третьей нормы (2.4)

$$\|\mathbf{A}\|_3 = \sup_{\|\mathbf{u}\| \neq 0} \frac{\|\mathbf{A}\mathbf{u}\|_3}{\|\mathbf{u}\|_3} = \sup_{\|\mathbf{u}\| \neq 0} \sqrt{\frac{(\mathbf{A}\mathbf{u}, \mathbf{A}\mathbf{u})}{(\mathbf{u}, \mathbf{u})}} = \sup_{\|\mathbf{u}\| \neq 0} \sqrt{\frac{(\mathbf{A}^T \mathbf{A} \mathbf{u}, \mathbf{u})}{(\mathbf{u}, \mathbf{u})}}.$$

Заметим, что матрица $\mathbf{B} = \mathbf{A}^T \mathbf{A}$ — симметричная и положительно определенная. Без ограничения общности предположим, что все собственные числа матрицы различны. Матрица обладает всеми действительными собственными значениями, и каждому собственному числу соответствует собственный вектор. Все собственные векторы взаимно ортогональны. Можно рассмотреть ортонормированную систему собственных векторов $\mathbf{w}_1, \dots, \mathbf{w}_n$; $\lambda_1, \dots, \lambda_n$ — соответствующие им собственные значения. Любой вектор $\mathbf{u}$ можно представить в виде своего разложения по базису из собственных векторов: $\sum_i \xi_i \mathbf{w}_i$. Кроме того, $(\mathbf{A}^T \mathbf{A}) \mathbf{w}_i = \lambda_i \mathbf{w}_i$.

Поэтому

$$\begin{aligned} \sup_{\|\mathbf{u}\| \neq 0} \sqrt{\frac{(\mathbf{A}^T \mathbf{A} \mathbf{u}, \mathbf{u})}{(\mathbf{u}, \mathbf{u})}} &= \sup_{\|\mathbf{u}\| \neq 0} \sqrt{\sum_i \frac{(\lambda_i \xi_i \mathbf{w}_i, \xi_i \mathbf{w}_i)}{(\xi_i \mathbf{w}_i, \xi_i \mathbf{w}_i)}} = \\ &= \sup_{\|\mathbf{u}\| \neq 0} \sqrt{\frac{\sum \lambda_i \xi_i^2}{\sum \xi_i^2}} = \sqrt{\max_i \lambda_i (\mathbf{A}^T \mathbf{A})}, \end{aligned}$$

причем точная верхняя грань достигается при $\mathbf{u} = \mathbf{w}_i$. Действительно,

$$\sup_{\|\mathbf{u}\| \neq 0} \sqrt{\frac{(\mathbf{A}^T \mathbf{A} \mathbf{w}_i, \mathbf{w}_i)}{(\mathbf{w}_i, \mathbf{w}_i)}} = \sup_{\|\mathbf{u}\| \neq 0} \sqrt{\lambda_i (\mathbf{A}^T \mathbf{A})} = \sqrt{\max_i \lambda_i (\mathbf{A}^T \mathbf{A})},$$

так как $\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \lambda_i \mathbf{w}_i$, откуда $(\mathbf{A}^T \mathbf{A} \mathbf{w}_i, \mathbf{w}_i) = \lambda_i (\mathbf{w}_i, \mathbf{w}_i)$,

$$\frac{(\mathbf{A}^T \mathbf{A} \mathbf{w}_i, \mathbf{w}_i)}{(\mathbf{w}_i, \mathbf{w}_i)} = \lambda_i.$$

В важном частном случае симметричной (самосопряженной) матрицы $\mathbf{A}$ имеем $\lambda_{i\mathbf{A}^T \mathbf{A}} = \lambda_{i\mathbf{A}^2} = |\lambda_{i\mathbf{A}}|^2$, поэтому $\|\mathbf{A}\|_3 = \max_i |\lambda_{i\mathbf{A}}|$.

2.3. Обусловленность СЛАУ. Число обусловленности матрицы

Понятия согласованных норм матриц и векторов позволяют оценить погрешности, возникающие при численном решении СЛАУ. Пусть $\mathbf{A}$ — матрица, и правая часть системы заданы с некоторой погрешностью, тогда наряду с системой

$$\mathbf{A}\mathbf{u} = \mathbf{f} \quad (2.6)$$

рассматривается система

$$(\mathbf{A} + \Delta\mathbf{A})(\mathbf{u} + \Delta\mathbf{u}) = \mathbf{f} + \Delta\mathbf{f}. \quad (2.7)$$

Теорема 2.1. Пусть правая часть и невырожденная матрица СЛАУ (2.6) $\mathbf{A}\mathbf{u} = \mathbf{f}$, $\mathbf{u} \in R^n$, $\mathbf{f} \in R^n$, получили приращения $\Delta\mathbf{f}$ и $\Delta\mathbf{A}$ соответственно. Пусть существует обратная матрица $\mathbf{A}^{-1}$ и выполнены условия $\|\mathbf{A}\| \neq 0$, $\mu \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} < 1$, где $\mu = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|$. В этом случае оценка относительной погрешности решения $\frac{\|\Delta\mathbf{u}\|}{\|\mathbf{u}\|}$ удовлетворяет неравенству

$$\frac{\|\Delta\mathbf{u}\|}{\|\mathbf{u}\|} \leq \frac{\mu}{1 - \mu \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|}} \left(\frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|} + \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \right).$$

Доказательство. Из (2.7) следует, что

$$\Delta\mathbf{u} = \mathbf{A}^{-1}(\Delta\mathbf{f} - \Delta\mathbf{A}\mathbf{u} - \Delta\mathbf{A}\Delta\mathbf{u}).$$

Оценим норму приращения. Используя неравенство треугольника, получаем

$$\|\Delta\mathbf{u}\| \leq \|\mathbf{A}^{-1}\| \|\Delta\mathbf{f}\| + \|\mathbf{A}^{-1}\| \|\Delta\mathbf{A}\| \|\mathbf{u}\| + \|\mathbf{A}^{-1}\| \|\Delta\mathbf{A}\| \|\Delta\mathbf{u}\|,$$

или

$$\|\Delta\mathbf{u}\| \leq \|\mathbf{A}^{-1}\| \frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|} \|\mathbf{f}\| + \|\mathbf{A}^{-1}\| \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \|\mathbf{A}\| \|\mathbf{u}\| + \|\mathbf{A}^{-1}\| \|\mathbf{A}\| \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \|\Delta\mathbf{u}\|.$$

Введем обозначение $\mu(\mathbf{A}) = \|\mathbf{A}^{-1}\| \|\mathbf{A}\|$, перепишем последнее равенство в виде

$$\begin{aligned} \|\Delta\mathbf{u}\| \left(1 - \mu \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \right) &\leq \mu \frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|} \frac{\|\mathbf{f}\|}{\|\mathbf{A}\|} + \mu \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \|\mathbf{u}\| \leq \\ &\leq \mu \frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|} \|\mathbf{u}\| + \mu \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \|\mathbf{u}\| = \mu \left(\frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|} + \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \right) \|\mathbf{u}\|. \end{aligned}$$

Заметим, что $\frac{\|\mathbf{f}\|}{\|\mathbf{A}\|} \leq \|\mathbf{u}\|$, так как $\|\mathbf{f}\| = \|\mathbf{A}\mathbf{u}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{u}\|$.

Тогда для оценки относительной погрешности решения окончательно получим

$$\frac{\|\Delta\mathbf{u}\|}{\|\mathbf{u}\|} \leq \frac{\mu}{1 - \mu \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|}} \left(\frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|} + \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \right). \quad (2.8)$$

При $\Delta\mathbf{A} \approx 0$ получаем оценку при наличии погрешности только правых частей

$$\frac{\|\Delta\mathbf{u}\|}{\|\mathbf{u}\|} \leq \mu \frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|}; \quad (2.9)$$

если в (2.7) положить $\Delta\mathbf{A}\Delta\mathbf{u} \approx 0$, то

$$\frac{\|\Delta\mathbf{u}\|}{\|\mathbf{u}\|} \leq \mu \left(\frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|} + \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \right). \quad (2.10)$$

В результате получено важное неравенство, показывающее, на сколько возрастают относительные ошибки решения СЛАУ в случае наличия относительных ошибок при задании правых частей и элементов матриц.

Величина

$$\mu(\mathbf{A}) = \|\mathbf{A}^{-1}\| \|\mathbf{A}\| \quad (2.11)$$

называется *числом обусловленности* матрицы $\mathbf{A}$. Число обусловленности определяет, насколько погрешность входных данных может повлиять на решение системы (2.1). Очевидно, что всегда $\mu \geq 1$. Действительно,

$$1 = \|\mathbf{E}\| = \|\mathbf{A}^{-1}\mathbf{A}\| \leq \|\mathbf{A}^{-1}\| \|\mathbf{A}\| = \mu.$$

При $\mu \approx 1 \div 10$ ошибки входных данных слабо сказываются на решении, и система (2.1) считается хорошо обусловленной. При $\mu \gg 10^2 \div 10^3$ система является плохо обусловленной.

Пример. Решением системы

$$\begin{cases} 100u + 99v = 199, \\ 99u + 98v = 197 \end{cases}$$

будет пара чисел $u = v = 1$.

Внесем возмущение в правые части системы:

$$\begin{cases} 100u + 99v = 198.99, \\ 99u + 98v = 197.01. \end{cases}$$

При этом решение заметно изменится: $u = 2.97$; $v = -0.99$. Воспользовавшись выбранными согласованными нормами, получим

$$\begin{aligned} \|\mathbf{f}\|_1 &= 199, \quad \|\Delta\mathbf{f}\|_1 = 10^{-2}, \\ \delta f &= \frac{\|\Delta\mathbf{f}\|_1}{\|\mathbf{f}\|_1} \approx 0.5 \cdot 10^{-4} \text{ (это очень малая величина)}, \\ \|\mathbf{A}\|_1 &= \|\mathbf{A}^{-1}\|_1 = 199, \quad \mu = 199 \cdot 199 \approx 4 \cdot 10^4. \end{aligned}$$

Значит,

$$\delta u = \frac{\|\Delta\mathbf{u}\|}{\|\mathbf{u}\|} \leq \mu \frac{\|\Delta\mathbf{f}\|}{\|\mathbf{f}\|} \approx 4 \cdot 10^4 \cdot \frac{10^{-4}}{2} = 2,$$

что согласуется с результатами решения возмущенной и невозмущенной задач. Для невозмущенной задачи $\|\Delta\mathbf{u}\| \approx 2$, $\|\mathbf{u}\| = 1$.

Рассмотрим еще одно важное свойство. Число обусловленности матрицы, как было показано ранее, можно определить, как $\delta u / \delta f \leq \mu(\mathbf{A})$, если $\Delta\mathbf{A} \approx \mathbf{0}$ при $\delta u = \|\Delta\mathbf{u}\| / \|\mathbf{u}\|$. Можно ли найти более тонкую оценку отношения $\delta u / \delta f$, учитывающую зависимость обусловленности СЛАУ от выбора правых частей? В этом случае параметр обусловленности системы, вообще говоря, зависит и от $\mathbf{f}$, и от $\Delta\mathbf{f}$, и удовлетворяет неравенству

$$v(\mathbf{f}, \Delta\mathbf{f}) \geq \frac{\delta\mathbf{u}}{\delta\mathbf{f}} = \frac{\|\Delta\mathbf{u}\|}{\|\mathbf{u}\|} \cdot \frac{\|\mathbf{f}\|}{\|\Delta\mathbf{f}\|}.$$

Его можно определить как точную верхнюю грань отношения $\delta\mathbf{u} / \delta\mathbf{f}$ по $\Delta\mathbf{f}$, что соответствует наихудшей ситуации. Тогда

$$v(\mathbf{f}) = \sup_{\Delta\mathbf{f}} \frac{\|\Delta\mathbf{u}\|}{\|\mathbf{u}\|} \cdot \frac{\|\mathbf{f}\|}{\|\Delta\mathbf{f}\|} = \sup_{\Delta\mathbf{f}} \frac{\|\mathbf{f}\|}{\|\mathbf{u}\|} \cdot \frac{\|\Delta\mathbf{u}\|}{\|\Delta\mathbf{f}\|} = \frac{\|\mathbf{f}\|}{\|\mathbf{u}\|} \sup_{\Delta\mathbf{f}} \frac{\|\mathbf{A}^{-1}\Delta\mathbf{f}\|}{\|\Delta\mathbf{f}\|} = \frac{\|\mathbf{f}\|}{\|\mathbf{u}\|} \|\mathbf{A}^{-1}\|.$$

Далее,

$$\sup_{\mathbf{f}} \|\mathbf{A}^{-1}\| \cdot \frac{\|\mathbf{f}\|}{\|\mathbf{u}\|} = \|\mathbf{A}^{-1}\| \cdot \sup_{\mathbf{f}} \frac{\|\mathbf{A}\mathbf{u}\|}{\|\mathbf{u}\|} = \|\mathbf{A}^{-1}\| \|\mathbf{A}\| = \mu(\mathbf{A});$$

с другой стороны,

$$\begin{aligned} \inf_{\mathbf{f}} v(\mathbf{f}) &= \inf_{\mathbf{f}} \|\mathbf{A}^{-1}\| \cdot \frac{\|\mathbf{f}\|}{\|\mathbf{u}\|} = \|\mathbf{A}^{-1}\| \cdot \left(\sup_{\mathbf{f}} \frac{\|\mathbf{u}\|}{\|\mathbf{f}\|} \right)^{-1} = \\ &= \|\mathbf{A}^{-1}\| \left(\sup_{\mathbf{f}} \frac{\|\mathbf{A}^{-1}\mathbf{f}\|}{\|\mathbf{f}\|} \right)^{-1} = 1. \end{aligned}$$

Параметр $v(\mathbf{f})$, характеризующий обусловленность системы, зависит от правых частей. Более тонкая его оценка есть $v(\mathbf{f}) = \|\mathbf{A}^{-1}\| (\|\mathbf{f}\|/\|\mathbf{u}\|)$, причем $1 \leq v(\mathbf{f}) \leq \mu$. Так как такую оценку провести не всегда возможно, то чаще используется точная верхняя грань $\|\mathbf{A}^{-1}\| \|\mathbf{A}\|$. Такая оценка, конечно, может быть существенно завышенной.

Можно также показать, что для симметричной матрицы $\mathbf{A}$ имеет место $\mu = \max_k |\lambda_k(\mathbf{A})| / \min_k |\lambda_k(\mathbf{A})|$, т. е. обусловленность СЛАУ зависит от ее спектральных свойств. Это следует из определения третьей нормы матрицы $\|\mathbf{A}\|_3 = \max_k |\lambda_k^k|$ и равенства $\|\mathbf{A}^{-1}\|_3 = \min_k |\lambda_k^k|^{-1}$, которое предлагается доказать самостоятельно.

2.4. Прямые методы решения СЛАУ

Трудность численного решения рассматриваемых СЛАУ определяется видом матрицы $\mathbf{A}$. Легко получается решение системы с диагональной матрицей, в этом случае система распадается на n линейных уравнений, каждое из которых содержит лишь одну неизвестную величину. Для диагональной системы очевидны явные формулы

$$u_k = \frac{f_k}{a_{kk}}, \quad k = 1, \dots, n.$$

В случае треугольной матрицы (например, верхней треугольной)

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ 0 & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & a_{nn} \end{pmatrix}$$

$$\mathbf{N}_1 = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ -\eta_{21} & 1 & 0 & \dots & 0 \\ -\eta_{31} & 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ -\eta_{n1} & 0 & 0 & \dots & 1 \end{pmatrix}.$$

Очевидно, $\mathbf{A}_1 = \mathbf{N}_1 \mathbf{A}$, $\mathbf{f}_1 = \mathbf{N}_1 \mathbf{f}$. Аналогично, после второго шага система приводится к виду $\mathbf{A}_2 \mathbf{u} = \mathbf{f}_2$, где $\mathbf{A}_2 = \mathbf{N}_2 \mathbf{A}_1$, $\mathbf{f}_2 = \mathbf{N}_2 \mathbf{f}_1$,

$$\mathbf{A}_2 = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ 0 & a_{22}^1 & a_{23}^1 & \dots & a_{2n}^1 \\ 0 & 0 & a_{33}^2 & \dots & a_{3n}^2 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & a_{n3}^2 & \dots & a_{nn}^2 \end{pmatrix}, \quad \mathbf{N}_2 = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & -\eta_{32} & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & -\eta_{n2} & 0 & \dots & 1 \end{pmatrix},$$

$$\mathbf{f}_2 = \{f_1, f_2^1, f_3^2, \dots, f_n^2\}^T.$$

После $n-1$ шага получим $\mathbf{A}_{n-1} \mathbf{u} = \mathbf{f}_{n-1}$, $\mathbf{A}_{n-1} = \mathbf{N}_{n-1} \mathbf{A}_{n-2}$, $\mathbf{f}_{n-1} = \mathbf{N}_{n-1} \mathbf{f}_{n-2}$,

$$\mathbf{A}_{n-1} = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ 0 & a_{22}^1 & a_{23}^1 & \dots & a_{2n}^1 \\ 0 & 0 & a_{33}^2 & \dots & a_{3n}^2 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & a_{nn}^{(n-1)} \end{pmatrix},$$

$$\mathbf{N}_{n-1} = \begin{pmatrix} 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & \dots & 0 & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 & 0 \\ 0 & 0 & \dots & -\eta_{n,n-1} & 1 \end{pmatrix}, \quad \mathbf{f}_{n-1} = \{f_1, f_2^1, f_3^2, \dots, f_n^{n-1}\}^T.$$

В итоге получаются матрица и вектор $\mathbf{A}_{n-1} = \mathbf{N}_{n-1} \dots \mathbf{N}_2 \mathbf{N}_1 \mathbf{A}$, $\mathbf{f}_{(n-1)} = \mathbf{N}_{n-1} \dots \mathbf{N}_2 \mathbf{N}_1 \mathbf{f}$, откуда $\mathbf{A} = \mathbf{N}_1^{-1} \mathbf{N}_2^{-1} \dots \mathbf{N}_{n-1}^{-1} \cdot \mathbf{A}_{n-1}$. При этом

$$\mathbf{N}_1^{-1} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ \eta_{21} & 1 & 0 & \dots & 0 \\ \eta_{31} & 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ \eta_{n1} & 0 & 0 & \dots & 1 \end{pmatrix}, \quad \mathbf{N}_2^{-1} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & \eta_{32} & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & \eta_{n2} & 0 & \dots & 1 \end{pmatrix}, \dots,$$

$$\mathbf{N}_{n-1}^{-1} = \begin{pmatrix} 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & \dots & 0 & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 & 0 \\ 0 & 0 & \dots & \eta_{n,n-1} & 1 \end{pmatrix}.$$

После введения обозначений $\mathbf{U} = \mathbf{A}_{n-1}$, $\mathbf{L} = \mathbf{N}_1^{-1} \mathbf{N}_2^{-1} \dots \mathbf{N}_{n-1}^{-1}$, где

$$\mathbf{L} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ \eta_{21} & 1 & 0 & \dots & 0 \\ \eta_{31} & \eta_{32} & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ \eta_{n1} & \eta_{n2} & \eta_{n3} & \dots & 1 \end{pmatrix},$$

получим $\mathbf{A} = \mathbf{LU}$.

Это представление матрицы $\mathbf{A}$ называется LU -разложением (на произведение нижней и верхней треугольных матриц $\mathbf{L}$ и $\mathbf{U}$). Прямой ход метода Гаусса можно рассматривать как один из вариантов представления матрицы в виде произведения двух треугольных матриц, или LU -разложения. Его можно провести и другими способами.

Вспомним «отрицательный» пример из Лекции 1. Пусть необходимо решить систему

$$\begin{aligned} -10^{-7}u_1 + u_2 &= 1, \\ u_1 + 2u_2 &= 4. \end{aligned}$$

Исключая u_1 из первого уравнения и подставляя во второе, получим $u_2 = (10^7 + 4)/(10^7 + 2)$. После вычислений с шестью значащими цифрами получаем $u_1 = 0.000000$, $u_2 = 1.000000$, что неверно (см. второе уравнение). Теперь исключим u_1 из второго уравнения и подставим в первое. При этом получим $u_2 = (1 + 4 \cdot 10^{-7})/(1 + 2 \cdot 10^{-7})$. После вычислений с той же точностью имеем: $u_2 = 1.000000$, $u_1 = 2.000000$, что является правильным решением (с заданным количеством значащих цифр).

В реальных вычислениях используются методы с *выбором главного (или ведущего) элемента*. Выбор главного элемента *по столбцам* реализуется следующим образом. Перед исключением u_1 отыскивается $\max_i |a_{i1}|$. Пусть максимум достигается при $i = k$.

В этом случае меняются местами первое и k -е уравнения (или

в матрице меняются местами две строки) и реализуется процедура исключения.

Затем отыскивается $\max_i |a_{i2}^1|$, и процедура поиска главного элемента в столбцах повторяется. Так же реализуется выбор главного элемента по строкам: перед исключением u_1 отыскивается $\max_j |a_{kj}|$. Если максимум достигается при $i = k$, то у u_1 и u_k меняются номера, т. е. максимальный элемент из коэффициентов первого уравнения окажется на месте a_{11} , и т. д. Наиболее эффективным является метод Гаусса с выбором главного элемента по всей матрице. Во многих методах важным является условие *диагонального преобладания* $|a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$ для $i = 1, \dots, n$, при

выполнении которого проблемы, появляющиеся в методе Гаусса, не возникают. Если для всех строк матрицы выполняются строгие неравенства, то говорят о *строгом диагональном преобладании*.

Полученное решение можно улучшить следующим образом. Пусть $\mathbf{r}^1 = \mathbf{f} - \mathbf{A}\mathbf{u}^1$ есть невязка, допущенная при решении рассматриваемой системы ($\mathbf{u}^1$ — полученное численное решение) за счет ошибки округлений. Очевидно, что погрешность $\boldsymbol{\varepsilon}^1 = \mathbf{u} - \mathbf{u}^1$ удовлетворяет СЛАУ $\mathbf{A}\boldsymbol{\varepsilon}^1 = \mathbf{r}^1$, так как $\mathbf{A}\boldsymbol{\varepsilon}^1 = \mathbf{A}\mathbf{u} - \mathbf{A}\mathbf{u}^1 = \mathbf{f} - \mathbf{A}\mathbf{u}^1$.

Решив последнюю систему, получаем $\boldsymbol{\varepsilon}^1$, после чего уточняем решение:

$$\mathbf{u}^2 = \mathbf{u}^1 + \boldsymbol{\varepsilon}^1.$$

Эту процедуру можно продолжить.

2.4.2. Модификация метода Гаусса для случая линейных систем с трехдиагональными матрицами — метод прогонки. В приложениях часто возникают системы линейных уравнений с матрицами специального вида. В дальнейшем, например, при интерполяции функции сплайнами, при решении задачи Штурма–Лиувилля, при численном решении уравнений теплопроводности, уравнений Лапласа и Пуассона придется иметь дело с системами, матрицы которых имеют ненулевые элементы лишь на главной диагонали и еще на двух диагоналях — одной под главной, одной над главной. Такие матрицы называются трехдиагональными. Для решения систем с трехдиагональными матрицами существует экономичный (требующий малого количества памяти и арифметических действий) вариант метода Гаусса — *прогонка*. В англоязыч-

ной литературе метод прогонки называется алгоритмом Томаса. Вариант метода прогонки описан в Приложении 3.

2.4.3. LU-разложение. Среди прямых методов численного решения СЛАУ широко используется также LU -разложение матрицы $\mathbf{A}$.

Если матрица $\mathbf{A}$ представима в виде произведений матриц $\mathbf{L}\mathbf{U}$, то СЛАУ может быть представлена как

$$(\mathbf{L}\mathbf{U})\mathbf{u} = \mathbf{f}. \quad (2.15)$$

Перепишем (2.15), вводя вспомогательный вектор $\mathbf{v}$, в следующем виде:

$$\mathbf{L}\mathbf{v} = \mathbf{f}, \quad \mathbf{U}\mathbf{u} = \mathbf{v}. \quad (2.16)$$

Решение СЛАУ свелось к последовательному решению двух систем с треугольными матрицами. Первый этап решения системы $\mathbf{L}\mathbf{v} = \mathbf{f}$:

$$\begin{cases} v_1 = f_1, \\ l_{21}v_1 + v_2 = f_2, \\ \dots\dots\dots \\ l_{n1}v_1 + l_{n2}v_2 + \dots + l_{n,n-1}v_{n-1} + v_n = f_n, \end{cases}$$

откуда можно вычислить все v_k последовательно по формулам

$$v_k = f_k - \sum_{j=1}^{k-1} l_{kj} v_j; \quad k = 2, \dots, n.$$

Далее рассмотрим систему $\mathbf{U}\mathbf{u} = \mathbf{v}$, или

$$\begin{cases} d_{11}u_1 + d_{12}u_2 + \dots + d_{1n}u_n = v_1, \\ d_{22}u_2 + \dots + d_{2n}u_n = v_2, \\ \dots\dots\dots \\ d_{nn}u_n = v_n, \end{cases}$$

решение которой находится в обратном порядке, т.е. при $k = n-1, \dots, 1$ по очевидным формулам $u_k = d_{kk}^{-1}(v_k - \sum_{j=k+1}^n d_{kj}u_j)$.

Условия существования такого разложения даются следующей теоремой [13] (без доказательства).

Теорема 2.2. Если все главные миноры квадратной матрицы $\mathbf{A}$ отличны от нуля, то существуют единственные нижняя и верхняя треугольные матрицы $\mathbf{L} = \{l_{ij}\}$ и $\mathbf{U} = \{d_{ij}\}$ такие,

$$\begin{aligned} d_{ij} &= a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_{kj}, \quad i \leq j, \\ l_{ij} &= d_{ij}^{-1} \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_{kj} \right), \quad i > j. \end{aligned}$$

Приведение матриц к треугольному виду аналогично приведению матрицы в методе Гаусса и также требует количества арифметических действий порядка $O(n^3)$, точнее, примерно $2n^3$.

2.4.4. Метод Холецкого (метод квадратного корня). Пусть матрица рассматриваемой линейной системы $\mathbf{A}$ — симметричная (т.е. $a_{ij} = a_{ji}$) положительная матрица. Напомним, что матрица $\mathbf{A}$ называется положительной ($\mathbf{A} > 0$), если $\exists \alpha > 0$: $\forall \mathbf{u} (\mathbf{A}\mathbf{u}, \mathbf{u}) \geq \alpha (\mathbf{u}, \mathbf{u})$. Тогда она представима в виде $\mathbf{A} = \mathbf{L}\mathbf{L}^T$, где

$$\mathbf{L}^T = \begin{pmatrix} l_{11} & l_{12} & \dots & l_{1n} \\ 0 & l_{22} & \dots & l_{2n} \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & l_{nn} \end{pmatrix}, \quad \mathbf{L} = \begin{pmatrix} l_{11} & 0 & \dots & 0 \\ l_{12} & l_{22} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ l_{1n} & l_{2n} & \dots & l_{nn} \end{pmatrix}.$$

Далее, как и в случае LU -разложения, решение СЛАУ $\mathbf{A}\mathbf{u} = \mathbf{f}$ сводится к последовательному решению двух линейных систем с треугольными матрицами $\mathbf{L}\mathbf{v} = \mathbf{f}$, $\mathbf{L}^T\mathbf{u} = \mathbf{v}$, для решения которых требуется примерно $2n^2$ арифметических действий.

Первая из этих линейных систем

$$\begin{aligned} l_{11}v_1 &= f_1, \\ l_{12}v_1 + l_{22}v_2 &= f_2, \\ &\dots\dots\dots \\ l_{1n}v_1 + l_{2n}v_2 + \dots + l_{nn}v_n &= f_n \end{aligned}$$

легко решается. Для решения получаем очевидные формулы

$$v_i = l_{ii}^{-1} \left(f_i - \sum_{k=1}^i l_{ki}v_k \right), \quad i = 1, \dots, n.$$

Вторая система уравнений есть

$$\begin{aligned} l_{11}u_1 + l_{12}u_2 + \dots + l_{1n}u_n &= v_1, \\ l_{22}u_2 + \dots + l_{2n}u_n &= v_2, \\ &\dots\dots\dots \\ l_{nn}u_n &= v_n. \end{aligned}$$

Из нее находим значения переменных u_i в обратном порядке по формуле

$$u_k = l_{kk}^{-1} \left(v_k - \sum_{j=k+1}^n l_{kj}u_j \right).$$

Определенной опасностью при реализации этого метода являются возможная близость к нулю l_{ii} и отрицательность подкоренных выражений при вычислении l_{ii} (последнего не должно быть при симметричной положительной матрице $\mathbf{A}$).

Элементы матрицы $\mathbf{L}$ находим из уравнения $\mathbf{LL}^T = \mathbf{A}$, приравнявая соответствующие элементы матриц $\mathbf{LL}^T$ и $\mathbf{A}$. В результате получим систему уравнений

$$\begin{aligned} l_{11}^2 &= a_{11}, \quad l_{i1}l_{11} = a_{i1}, \quad i = 2, \dots, n, \\ l_{21}^2 + l_{22}^2 &= a_{22}, \quad l_{i1}l_{21} + l_{i2}l_{22} = a_{i2}, \quad i = 3, \dots, n, \\ &\dots\dots\dots \\ l_{k1}^2 + l_{k2}^2 + \dots + l_{kk}^2 &= a_{kk}, \\ l_{i1}l_{k1} + l_{i2}l_{k2} + \dots + l_{ik}l_{kk} &= a_{ik}, \quad i = k+1, \dots, n. \end{aligned}$$

Решение этой системы легко находится:

$$\begin{aligned} l_{11} &= \sqrt{a_{11}}, \quad l_{i1} = \frac{a_{i1}}{l_{11}}, \quad i = 2, \dots, n, \\ l_{22} &= \sqrt{a_{22} - l_{21}^2}, \quad l_{i2} = \frac{a_{i2} - l_{i1}l_{21}}{l_{22}}, \quad i = 3, \dots, n, \\ &\dots\dots\dots \\ l_{kk} &= \sqrt{a_{kk} - l_{k1}^2 - l_{k2}^2 - \dots - l_{k,k-1}^2}, \\ l_{ik} &= \frac{a_{ik} - l_{i1}l_{k1} - l_{i2}l_{k2} - \dots - l_{i,k-1}l_{k,k-1}}{l_{kk}}, \quad i = k+1, \dots, n, \end{aligned}$$

Метод также называется методом квадратного корня.

В н и м а н и е! Не следует путать матрицу (оператор) $\mathbf{L}$ с оператором $\mathbf{A}^{1/2}$ — квадратным корнем из самосопряженного положительного оператора.

2.4.5. QR-разложение. QR -разложением квадратной действительной матрицы $\mathbf{A}$ называется представление

$$\mathbf{A} = \mathbf{QR}$$

в виде произведения ортогональной матрицы $\mathbf{Q}$ ($\mathbf{Q}^T = \mathbf{Q}^{-1}$) и правой треугольной (верхнетреугольной) матрицы $\mathbf{R}$.

QR -разложение существует для любой квадратной матрицы $\mathbf{A}$. Если при этом матрица невырождена, то QR -разложение единственно при дополнительном условии, что элементы на диагонали

матрицы $\mathbf{R}$ — положительные числа. Сформулируем данное утверждение в виде теоремы.

Теорема 2.3. Пусть столбцы матрицы $\mathbf{A}$ линейно независимы, т.е. ранг матрицы $\mathbf{A}$ равен s . Тогда существует одно и только одно представление матрицы системы в виде $\mathbf{A} = \mathbf{QR}$, где прямоугольная матрица $\mathbf{Q}$ — ортогональная матрица $n \times s$, столбцы которой — ортонормированные векторы, квадратная матрица $\mathbf{R}$ размера $n \times n$ — верхнетреугольная с положительными элементами на главной диагонали.

Приведем доказательство этой теоремы, так как доказательство ее конструктивное. Оно совпадает с одним из алгоритмов реализации такого разложения.

Применим к столбцам матрицы $\mathbf{A}$ алгоритм ортогонализации Грама–Шмидта. Фиксируем первый столбец. Для нормировки делим все элементы столбца на длину вектора

$$\|\mathbf{a}_{n1}\| = \left(\sum_{i=1}^n a_{i1}a_{i1} \right)^{1/2},$$

$$\mathbf{a}_{n1} := \frac{\mathbf{a}_{n1}}{\|\mathbf{a}_{n1}\|}.$$

Знаки равенства с двоеточиями здесь понимаются как операции присваивания. Норма вектора здесь и в следующем параграфе — евклидова.

Затем вычтем из второго столбца матрицы его проекцию на первый столбец: $\mathbf{a}_{n2} := \mathbf{a}_{n2} - (\mathbf{a}_{n2}, \mathbf{a}_{n1})\mathbf{a}_{n1}$ и осуществим нормировку на новое значение длины вектора

$$\|\mathbf{a}_{n2}\| = \left(\sum_{i=1}^n a_{i2}a_{i2} \right)^{1/2},$$

$$\mathbf{a}_{n2} := \frac{\mathbf{a}_{n2}}{\|\mathbf{a}_{n2}\|}.$$

На каждом следующем шаге алгоритма от соответствующего столбца матрицы отнимается сумма проекций на все предыдущие направления

$$\mathbf{a}_{nl} := \mathbf{a}_{nl} - \sum_{j=1}^{l-1} (\mathbf{a}_{nl}, \mathbf{a}_{nj}) \mathbf{a}_{nj}$$

и осуществляется нормировка $\mathbf{a}_{nl} := \mathbf{a}_{nl} / \|\mathbf{a}_{nl}\|$.

По завершении m шагов алгоритма получаем ортонормированную систему векторов. Это — столбцы матрицы $\mathbf{Q}$. В этом случае столбцами матрицы $\mathbf{R}$ должны быть наборы коэффициентов разложения столбцов исходной матрицы $\mathbf{A}$ по получившемуся ортонормированному базису, причем на диагонали стоит тот коэффициент, на который нормировался соответствующий вектор в процессе Грама–Шмидта. Этот коэффициент всегда положительный. $\square$

QR -разложение возможно определить и для прямоугольных матриц размера $m \times n$. В случае $m < n$ произведение $\mathbf{A} = \mathbf{QR}$ — это произведение ортогональной $m \times m$ матрицы $\mathbf{Q}$ на трапецидальную $m \times n$ матрицу $\mathbf{R}$, в которой $r_{ij} = 0$ для $i = 2, \dots, m$ и $j = 1, \dots, i - 1$. В случае $m > n$ — это произведение $m \times n$ матрицы $\mathbf{Q}$ с ортонормированными столбцами на треугольную $n \times n$ матрицу $\mathbf{R}$.

Если известно QR -разложение квадратной матрицы $\mathbf{A}$, то решение линейной системы $\mathbf{Ax} = \mathbf{b}$ эквивалентно решению системы $\mathbf{Rx} = \mathbf{Q}^T \mathbf{b}$.

Опишем кратко основные алгоритмы построения QR -разложения.

2.4.5.1. Процесс ортогонализации Грама–Шмидта. Процесс ортогонализации Грама–Шмидта заключается в построении ортонормированного базиса $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_p\}$, $p \leq q$, в линейном пространстве, натянутом на столбцы $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}$ матрицы $\mathbf{A}$.

Процесс ортогонализации описан в доказательстве Теоремы.

Из-за ошибок округления построенные базисные векторы могут терять ортогональность. Чтобы сделать процесс Грама–Шмидта более вычислительно устойчивым, применяется следующая простая модификация. Этап нахождения составляющей вектора $\mathbf{a}_j$, ортогональной вектору $\mathbf{q}_i$, заменяется на формально тождественную операцию построения составляющей вектора $\mathbf{q}_j$, ортогональной вектору $\mathbf{q}_i$, которая по построению уже ортогональна векторам $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_{i-1}\}$.

Процесс ортогонализации Грама–Шмидта соответствует умножению справа матрицы $\mathbf{A}$ на верхнетреугольную матрицу. Результатом является ортогональная матрица $\mathbf{Q} = \{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n\}$. $\mathbf{R}$ — это матрица перехода от базиса $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n\}$ к базису $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}$.

Алгоритм использует $2n^3 + O(n^2)$ операций с плавающей точкой.

2.4.5.2. *Использование матриц отражения Хаусхолдера.* Для вектора $\mathbf{v} \in R^n$, $\|\mathbf{v}\| \neq 0$, матрица

$$\mathbf{H}(\mathbf{v}) = \mathbf{E} - 2 \frac{\mathbf{v}\mathbf{v}^T}{\|\mathbf{v}\|^2}$$

называется матрицей отражения, или матрицей Хаусхолдера.

Вектор $\mathbf{v}$ — порождающий вектор матрицы отражения $\mathbf{H}(\mathbf{v})$, $\mathbf{E}$ — единичная матрица. Напомним, что здесь используется евклидова норма вектора.

Матрицы Хаусхолдера являются симметричными ортогональными матрицами.

В методе отражений матрица $\mathbf{Q}$ представляется в виде произведения

$$\mathbf{Q} = \mathbf{H}_1 \mathbf{H}_1 \dots \mathbf{H}_{n-1} \mathbf{H}_n.$$

Построим последовательность таких матриц.

$\mathbf{H}_1 = \mathbf{H}(\mathbf{v}_1)$ — матрица Хаусхолдера с порождающим вектором

$$\mathbf{v}_1 = \mathbf{a}_1 + \text{sign}(a_{11}) \|\mathbf{a}_1\| \mathbf{e}_1,$$

где $\mathbf{a}_1$ — первый столбец матрицы $\mathbf{A}$, $\mathbf{e}_1 = (1, 0, \dots, 0)^T$ — первый столбец единичной матрицы $n \times n$. Тогда $\tilde{\mathbf{A}} = \mathbf{H}_1 \mathbf{A}$ — преобразованная матрица с нулями ниже главной диагонали в первом столбце.

Пусть $\tilde{\mathbf{A}} = \mathbf{H}_{j-1} \mathbf{H}_{j-2} \dots \mathbf{H}_2 \mathbf{H}_1 \mathbf{A}$ — матрица с нулями ниже главной диагонали в столбцах $1, \dots, j-1$. Обозначим через $\mathbf{p} = (\tilde{a}_{jj}, \tilde{a}_{j-1j}, \dots, \tilde{a}_{nj})^T$ — столбец, состоящий из $n-j+1$ элементов j -го столбца матрицы $\tilde{\mathbf{A}}$ (диагональный элемент и элементы ниже главной диагонали). Тогда матрица $\mathbf{H}_j$ имеет вид

$$\mathbf{H}_j = \begin{pmatrix} \mathbf{E}_{(j-1) \times (j-1)} & 0 \\ 0 & \mathbf{H}(\mathbf{v}_j) \end{pmatrix},$$

где $\mathbf{E}_{(j-1) \times (j-1)}$ — единичная матрица размера $(j-1) \times (j-1)$, а $\mathbf{H}(\mathbf{v}_j)$ — матрица отражений Хаусхолдера с порождающим вектором

$$\mathbf{v}_j = \mathbf{p} + \text{sign}(p_1) \|\mathbf{p}\| \mathbf{e}_1.$$

Здесь $\mathbf{e}_1 = (1, 0, \dots, 0)^T$ — первый столбец единичной матрицы $(n-j+1) \times (n-j+1)$.

После n шагов преобразования матрица $\tilde{\mathbf{A}}$ будет верхней треугольной, т. е.

$$\mathbf{R} = \mathbf{H}_n \mathbf{H}_{n-1} \dots \mathbf{H}_2 \mathbf{H}_1 \mathbf{A}.$$

Заметим, что для хранения матриц $\mathbf{H}_j$, достаточно хранить порождающий вектор матриц Хаусхолдера $\mathbf{H}(\mathbf{v}_j)$.

Трудоемкость алгоритма построения QR -разложения с использованием отражений составляет $\frac{4}{3}n^3 + O(n^2)$ арифметических операций с плавающей точкой.

2.4.5.3. Метод вращений Гивенса. Рассмотрим матрицу (для краткости записи все нулевые элементы матрицы опущены):

$$\mathbf{G}_{ij} = \begin{pmatrix} 1 & & & & & & \\ & \ddots & & & & & \\ & & 1 & & & & \\ & & & \cos \varphi & \cdots & -\sin \varphi & \\ & & & & \ddots & & \\ & & & \sin \varphi & \cdots & \cos \varphi & \\ & & & & & & 1 & \\ & & & & & & & \ddots & \\ & & & & & & & & 1 \end{pmatrix} \begin{matrix} \\ \\ \\ \mathbf{i} \\ \\ \mathbf{j} \\ \\ \\ \mathbf{i} \\ \mathbf{j} \end{matrix}$$

Диагональные элементы матрицы $\mathbf{G}_{ij}$ отличны от единицы только на ii и jj -позиции: $g_{ii} = g_{jj} = \cos \varphi$. Внедиагональные элементы матрицы $\mathbf{G}_{ij}$ отличны от нуля только на ij и ji -позиции: $g_{ij} = -\sin \varphi$ и $g_{ji} = \sin \varphi$. Эта матрица описывает поворот в плоскости (i, j) .

Выбором угла поворота φ можно добиться того, что в матрице

$$\tilde{\mathbf{A}} = \mathbf{G}_{ij}\mathbf{A}$$

внедиагональный элемент ниже главной диагонали станет равным нулю $\tilde{a}_{ji} = 0$. Для этого выберем угол φ такой, что

$$\sin \varphi = -\frac{a_{ji}}{\sqrt{a_{ii}^2 + a_{ji}^2}}; \quad \cos \varphi = \frac{a_{ii}}{\sqrt{a_{ii}^2 + a_{ji}^2}}.$$

Квадратная матрица $\mathbf{A}$ может быть приведена к верхнему треугольному виду с помощью последовательного умножения справа на соответствующие матрицы вращения $\mathbf{G}_{ij}$, где $i = 1, \dots, n-1$ и $j = i+1, \dots, n$:

$$\mathbf{R} = \mathbf{G}_{n-1n}\mathbf{G}_{n-2n}\mathbf{G}_{n-2n-1}\dots\mathbf{G}_{1n}\dots\mathbf{G}_{13}\mathbf{G}_{12}\mathbf{A}.$$

Заметим, что для реализации умножения матрицы $\mathbf{A}$ на матрицу $\mathbf{G}_{ij}$ достаточно пересчитывать только элементы матрицы a_{ik} и a_{jk} , где $k = i, \dots, n$.

Матрица $\mathbf{Q}$ в методе вращений Гивенса имеет вид

$$\mathbf{Q} = \mathbf{G}_{12}^T \mathbf{G}_{13}^T \dots \mathbf{G}_{1n}^T \dots \mathbf{G}_{n-2n-1}^T \mathbf{G}_{n-2n}^T \mathbf{G}_{n-1n}^T.$$

Для плотных матриц метод вращений Гивенса требует в полтора раза больше арифметических операций, чем получение QR -разложения с помощью матриц отражения Хаусхолдера. Однако в случае разреженных матриц метод вращений может оказаться существенно эффективнее метода отражений.

2.5. Итерационные методы решения СЛАУ

2.5.1. Метод простой итерации. Рассмотрим систему линейных алгебраических уравнений

$$\mathbf{A}\mathbf{u} = \mathbf{f}.$$

Проведем несколько равносильных преобразований. Умножим обе части системы на один и тот же скалярный множитель τ , затем прибавим к правой и левой частям системы вектор $\mathbf{u}$. Систему уравнений можно теперь записать в виде, удобном для итераций:

$$\mathbf{u} = \mathbf{B}\mathbf{u} + \mathbf{F}, \quad (2.17)$$

где $\mathbf{B} = \mathbf{E} - \tau\mathbf{A}$, $\mathbf{F} = \tau\mathbf{f}$.

Теперь построим последовательность приближений к решению системы. Выберем произвольный вектор $\mathbf{u}^0$ — начальное приближение к решению. Чаще всего его просто полагают нулевым вектором. Скорее всего, начальное приближение не удовлетворяет (2.17) и, следовательно, исходной системе. При подстановке его в исходное уравнение возникает невязка $\mathbf{r}^0 = \mathbf{f} - \mathbf{A}\mathbf{u}^0$. Вычислив невязку, с помощью (2.17) можно уточнить приближение к решению, считая, что

$$\mathbf{u}^1 = \mathbf{u}^0 + \tau\mathbf{r}^0.$$

По первому приближению снова вычисляется невязка, процесс продолжается. В ходе итерации получаем $\mathbf{u}^{k+1} = \mathbf{u}^k + \tau\mathbf{r}^k$, $\mathbf{r}^k = \mathbf{f} - \mathbf{A}\mathbf{u}^k$.

Эквивалентная формулировка метода, называемого методом простых итераций, заключается в следующем. Решение (2.17) находится как предел последовательности $\{\mathbf{u}^0, \mathbf{u}^1, \mathbf{u}^2, \dots\}$ приближений, члены которой связаны рекуррентным соотношением (оно

эквивалентно приведенному выше, из записи исключен вектор невязки):

$$\mathbf{u}^{k+1} = \mathbf{B}\mathbf{u}^k + \mathbf{F}, \quad (2.18)$$

$\mathbf{u}^0 = 0$ (или любому произвольному вектору). Если предел такой последовательности существует, то говорят о *сходимости* итерационного процесса к решению СЛАУ.

Существуют другие формы записи метода итераций, например

$$\mathbf{u}^{k+1} = (\mathbf{E} - \tau\mathbf{A})\mathbf{u}^k + \tau\mathbf{f}. \quad (2.19)$$

Канонической формой записи двухслойного итерационного процесса называется следующая:

$$\mathbf{D}_{k+1} \frac{\mathbf{u}^{k+1} - \mathbf{u}^k}{\tau_{k+1}} + \mathbf{A}\mathbf{u}^k = \mathbf{f}. \quad (2.20)$$

При $\mathbf{D}_k = \mathbf{E}$, $\tau_k = \tau$, формула (2.20) соответствует однопараметрическому итерационному процессу — рассмотренному выше *методу простых итераций*. При $\mathbf{D}_k = \mathbf{E}$, $\tau_k = \{\tau_k, k = 1, \dots, n\}$ — n -шаговому явному итерационному процессу, при $\mathbf{D}_k = \mathbf{D}'$, $\tau_k = 1$ — методу простой итерации без итерационного параметра. В случае, когда $\mathbf{D} \neq \mathbf{E}$, итерационный метод называется *явным* — для вычисления следующего приближения к решению придется решать (как правило, более простую, чем исходную) систему линейных уравнений.

Теорема 2.4 (достаточное условие сходимости метода простой итерации). *Итерационный процесс (2.18) сходится к решению $\mathbf{u}$ СЛАУ $\mathbf{u} = \mathbf{B}\mathbf{u} + \mathbf{F}$ со скоростью геометрической прогрессии при выполнении условия $\|\mathbf{B}\| \leq q < 1$.*

Доказательство. Пусть $\mathbf{u}$ — точное решение системы (2.17). Вычитая из (2.18) равенство (2.17), получим $\mathbf{u}^k - \mathbf{u} = \mathbf{B}(\mathbf{u}^{k-1} - \mathbf{u})$, или, обозначив погрешность $\boldsymbol{\epsilon}^k = \mathbf{u}^k - \mathbf{u}$, имеем для эволюции погрешности уравнение $\boldsymbol{\epsilon}^k = \mathbf{B}\boldsymbol{\epsilon}^{k-1}$. Справедлива цепочка неравенств

$$\|\mathbf{u}^k - \mathbf{u}\| = \|\boldsymbol{\epsilon}^k\| \leq \|\mathbf{B}\| \|\boldsymbol{\epsilon}^{k-1}\| \leq q \|\boldsymbol{\epsilon}^{k-1}\| \leq \dots \leq q^k \|\boldsymbol{\epsilon}^0\| = q^k \|\mathbf{u}^0 - \mathbf{u}\|,$$

где $0 < q \leq \|\mathbf{B}\|$. Отсюда следует, что при $q < 1$ $\lim_{k \rightarrow \infty} \mathbf{u}^k = \mathbf{u}$.

Из неравенства $\|\boldsymbol{\epsilon}^k\| \leq q^k \|\boldsymbol{\epsilon}^0\|$ можно получить оценку количества итераций, необходимых для достижения точности ϵ , т. е. для

выполнения условия $\|\mathbf{u}^k - \mathbf{u}\| = \|\epsilon^k\| \leq \epsilon$. Эта оценка имеет вид $k \geq (\ln \frac{\epsilon}{\|\epsilon_0\|}) / \ln q$. $\square$

Теорема 2.5 (критерий сходимости метода простой итерации (без доказательства)). Пусть СЛАУ (2.17) имеет единственное решение. Тогда для сходимости итерационного процесса (2.18) необходимо и достаточно, чтобы все собственные значения матрицы $\mathbf{B}$ по абсолютной величине были меньше единицы.

Сравним по количеству арифметических действий прямые и итерационные методы. Метод Гаусса без выбора главного элемента при $n \gg 1$ требует примерно $\frac{2}{3}n^3$ арифметических действий; метод простой итерации (2.18) — примерно $2n^2I$, где I — число приближений, необходимое для достижения заданной точности. Значит, при $I < n/3$ метод итераций становится предпочтительнее. В реальных задачах в основном $I \ll n$. Кроме того, итерационные методы можно делать более эффективными, изменяя итерационные параметры. В ряде случаев итерационные методы оказываются более устойчивыми по отношению к накоплению ошибок округления, чем прямые.

2.5.2. Влияние ошибок округления на результат численного решения. Будем трактовать суммарный эффект ошибок округления при выполнении одного итерационного шага как возмущение правой части в итерационном процессе

$$\mathbf{u}^k = \mathbf{B}\mathbf{u}^{k-1} + \mathbf{F}. \quad (2.21)$$

Результат вычислений на каждой итерации при наличии ошибок округления представим в виде

$$\widetilde{\mathbf{u}}^k = \mathbf{B}\widetilde{\mathbf{u}}^{k-1} + \mathbf{F} + \boldsymbol{\delta}_k, \quad (2.22)$$

где $\boldsymbol{\delta}_k$ — суммарная погрешность округления. Норму разности между реальным и идеальным (т.е. в отсутствие ошибки округления) результатами расчетов получим, вычитая (2.21) из (2.22). Учтем, что $\|\mathbf{B}\| \leq q < 1$,

$$\begin{aligned} \|\widetilde{\mathbf{u}}^k - \mathbf{u}^k\| &\leq q \|\widetilde{\mathbf{u}}^{k-1} - \mathbf{u}^{k-1}\| + \|\boldsymbol{\delta}_k\| \leq \\ &\leq q^2 \|\widetilde{\mathbf{u}}^{k-2} - \mathbf{u}^{k-2}\| + q \|\boldsymbol{\delta}_{k-1}\| + \|\boldsymbol{\delta}_k\| \leq \dots \leq q^k \|\widetilde{\mathbf{u}}^0 - \mathbf{u}^0\| + \\ &+ \left(\max_i \|\boldsymbol{\delta}_i\| \right) (1 + q + \dots + q^{k-1}), \quad i = 1, \dots, k. \end{aligned}$$

Так как начальное приближение задано точно, то $\|\epsilon^0\| = \|\widetilde{\mathbf{u}}^0 - \mathbf{u}^0\| = 0$. Обозначим $\delta = \max_i \|\delta_i\|$ и вычислим сумму членов геометрической прогрессии. Получим

$$\|\widetilde{\mathbf{u}}^k - \mathbf{u}^k\| \leq \delta \frac{q^k - 1}{q - 1} \leq \frac{\delta}{1 - q},$$

т. е. погрешность, вносимая в решение из-за конечной разрядности мантиссы, в пределе не зависит от количества итераций. Этот результат является характеристикой устойчивости рассматриваемого вычислительного процесса.

2.5.3. Методы Якоби, Зейделя, верхней релаксации. Рассмотрим СЛАУ

$$a_{11}u_1 + a_{12}u_2 + \dots + a_{1n}u_n = f_1,$$

$$a_{21}u_1 + a_{22}u_2 + \dots + a_{2n}u_n = f_2,$$

$$\dots\dots\dots$$

$$a_{n1}u_1 + a_{n2}u_2 + \dots + a_{nn}u_n = f_n.$$

В *методе Якоби* из i -го уравнения выражается i -й компонент решения, при этом все остальные компоненты берутся с предыдущей итерации:

$$u_1^{k+1} = -\frac{a_{12}u_2^k + a_{13}u_3^k + \dots + a_{1n}u_n^k - f_1}{a_{11}},$$

$$u_2^{k+1} = -\frac{a_{21}u_1^k + a_{23}u_3^k + \dots + a_{2n}u_n^k - f_2}{a_{22}},$$

$$\dots\dots\dots$$

$$u_n^{k+1} = -\frac{a_{n1}u_1^k + a_{n2}u_2^k + \dots + a_{n,n-1}u_{n-1}^k - f_n}{a_{nn}}.$$

В реальных вычислениях все уже вновь вычисленные компоненты решения на новой итерации можно использовать при вычислении новой итерации. Это не приводит к дополнительному

расходу ресурсов. Такой метод называется *методом Зейделя*:

$$\begin{aligned} u_1^{k+1} &= -\frac{a_{12}u_2^k + a_{13}u_3^k + \dots + a_{1n}u_n^k - f_1}{a_{11}}, \\ u_2^{k+1} &= -\frac{a_{21}u_1^{k+1} + a_{23}u_3^k + \dots + a_{2n}u_n^k - f_2}{a_{22}}, \\ &\dots\dots\dots \\ u_n^{k+1} &= -\frac{a_{n1}u_1^{k+1} + a_{n2}u_2^{k+1} + \dots + a_{n,n-1}u_{n-1}^{k+1} - f_n}{a_{nn}}. \end{aligned}$$

Приведем эти методы к каноническому виду записи двуслойного итерационного метода (2.20). Для этого представим матрицу **A** в виде

$$\mathbf{A} = \mathbf{L} + \mathbf{D} + \mathbf{U}, \quad (2.23)$$

где **L** и **U** — нижняя и верхняя треугольные матрицы с нулевыми элементами на главной диагонали, **D** — диагональная матрица. Рассматриваемая СЛАУ может быть переписана в следующем эквивалентном виде:

$$\mathbf{L}\mathbf{u} + \mathbf{D}\mathbf{u} + \mathbf{U}\mathbf{u} = \mathbf{f}.$$

Построим два итерационных метода: метод Якоби

$$\mathbf{L}\mathbf{u}^k + \mathbf{D}\mathbf{u}^{k+1} + \mathbf{U}\mathbf{u}^k = \mathbf{f}$$

и метод Зейделя

$$\mathbf{L}\mathbf{u}^{k+1} + \mathbf{D}\mathbf{u}^{k+1} + \mathbf{U}\mathbf{u}^k = \mathbf{f}.$$

Каноническая форма записи метода Якоби тогда будет $\mathbf{D}(\mathbf{u}^{k+1} - \mathbf{u}^k) + \mathbf{A}\mathbf{u}^k = \mathbf{f}$. Для метода Зейделя канонический вид $(\mathbf{L} + \mathbf{D})(\mathbf{u}^{k+1} - \mathbf{u}^k) + \mathbf{A}\mathbf{u}^k = \mathbf{f}$. Из приведенных канонических форм записи следует, что оба метода — неявные. Кроме того, в методах значение итерационного параметра равно 1.

Для исследования сходимости методов методы Якоби и Зейделя запишем в форме, разрешенной относительно данных на следующей итерации:

$$\mathbf{u}^{k+1} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{u}^k + \mathbf{D}^{-1}\mathbf{f} \quad (2.24)$$

и

$$\mathbf{u}^{k+1} = -(\mathbf{L} + \mathbf{D})^{-1}\mathbf{U}\mathbf{u}^k + (\mathbf{L} + \mathbf{D})^{-1}\mathbf{f}. \quad (2.25)$$

Очевидно, что эти формулы описывают итерационные процессы вида (2.18), если положить в (2.24)

$$\mathbf{B} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}), \quad \mathbf{F} = \mathbf{D}^{-1}\mathbf{f}$$

или

$$\mathbf{B} = -(\mathbf{L} + \mathbf{D})^{-1}\mathbf{U}, \quad \mathbf{F} = (\mathbf{L} + \mathbf{D})^{-1}\mathbf{f}.$$

Теорема 2.6 (достаточное условие сходимости метода Якоби). *Итерационный метод Якоби сходится к решению соответствующей СЛАУ, если выполнено условие диагонального преобладания*

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, \quad i = 1, \dots, n. \quad (2.26)$$

Доказательство. Выполнение условия (2.26) означает, что в любой строке матрицы перехода

$$\mathbf{B} = \begin{pmatrix} 0 & -\frac{a_{12}}{a_{11}} & -\frac{a_{13}}{a_{11}} & \dots & -\frac{a_{1,n-1}}{a_{11}} & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & -\frac{a_{23}}{a_{22}} & \dots & -\frac{a_{2,n-1}}{a_{22}} & -\frac{a_{2n}}{a_{22}} \\ \dots & \dots & \dots & \dots & \dots & \dots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & -\frac{a_{n3}}{a_{nn}} & \dots & -\frac{a_{n,n-1}}{a_{nn}} & 0 \end{pmatrix}$$

сумма модулей элементов меньше единицы. В этом случае по крайней мере одна из норм матрицы $\mathbf{B}$ меньше единицы. Тогда выполняется достаточное условие сходимости метода простых итераций. $\square$

Теорема 2.7 (критерий сходимости итерационного метода Якоби). *Для сходимости итерационного метода Якоби необходимо и достаточно, чтобы все корни уравнения*

$$\begin{vmatrix} \lambda a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & \lambda a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & \lambda a_{nn} \end{vmatrix} = 0$$

по модулю не превосходили единицы.

Доказательство. Легко проверить, что в силу диагональности $\mathbf{D}$ имеет место

$$\begin{aligned}\det(\mathbf{B} - \lambda \mathbf{E}) &= \det[-\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}) - \lambda \mathbf{E}] = \\ &= \det(-\mathbf{D}^{-1}) \cdot \det[(\mathbf{L} + \mathbf{U}) + \mathbf{D}\lambda].\end{aligned}$$

Собственными значениями матрицы $\mathbf{B} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})$ являются корни уравнения

$$\det[(\mathbf{L} + \mathbf{U}) + \mathbf{D}\lambda] = 0,$$

которые в соответствии с критерием сходимости метода простой итерации должны быть по модулю меньше единицы.

Аналогичную теорему можно доказать и для метода Зейделя, однако матрица в этой теореме будет иметь другой вид:

$$\begin{pmatrix} \lambda a_{11} & a_{12} & \dots & a_{1n} \\ \lambda a_{12} & \lambda a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ \lambda a_{n1} & \lambda a_{n2} & \dots & \lambda a_{nn} \end{pmatrix}.$$

Теорема 2.8 (достаточное условие сходимости метода Зейделя (без доказательства)). Пусть $\mathbf{A}$ — вещественная, симметричная, положительно определенная матрица. В этом случае итерационный метод Зейделя сходится.

Доказательство этой теоремы сводится к проверке того, что выполнение условий теоремы для матрицы $\mathbf{A} = \mathbf{L} + \mathbf{D} + \mathbf{L}^T$ влечет выполнение условия сходимости итерационного метода с матрицей перехода: $(\mathbf{L} + \mathbf{D})^{-1}\mathbf{L}^T$. СЛАУ с вещественной матрицей $\mathbf{A}$ такой, что $\det \mathbf{A} \neq 0$, может быть симметризована умножением на матрицу $\mathbf{A}^T$:

$$(\mathbf{A}^T \mathbf{A})\mathbf{u} = \mathbf{A}^T \mathbf{f}$$

(симметризация Гаусса).

Развитием метода Зейделя является метод релаксации. В этом методе вводится параметр ω , называемый параметром релаксации. Представим метод релаксации в матричной форме:

$$(\omega \mathbf{L} \mathbf{u}^{k+1} + \mathbf{D} \mathbf{u}^{k+1}) + (\omega - 1) \mathbf{D} \mathbf{u}^k + \omega \mathbf{U} \mathbf{u}^k = \omega \mathbf{f}.$$

Выбирая ω , можно существенно изменять скорость сходимости итерационного метода. Выразим $\mathbf{u}^{k+1}$:

$$\mathbf{u}^{k+1} = -(\mathbf{D} + \omega\mathbf{L})^{-1}[(\omega - 1)\mathbf{D} + \omega\mathbf{L}]\mathbf{u}^k + \omega(\mathbf{D} + \omega\mathbf{L})^{-1}\mathbf{f}.$$

В общем случае задача вычисления $\omega_{\text{опт}}$ (оптимального итерационного параметра) не решена, однако известно, что $1 < \omega_{\text{опт}} < 2$. В этом случае итерационный метод называется методом последовательной верхней релаксации, или SOR — Successive Over Relaxation. Иногда встречается термин «сверхрелаксация» при $1 < \omega_{\text{опт}} < 2$. При $0 < \omega < 1$ имеем метод нижней релаксации. Конечно, матричная запись метода релаксаций является вспомогательной. Основные итерационные формулы в компонентах предоставляем читателям выписать самостоятельно.

2.6. Вариационные итерационные методы

2.6.1. Связь между вариационной задачей и задачей решения СЛАУ. Пусть $\mathbf{u} \in R^n$. Рассмотрим квадратичный функционал от $\mathbf{u}$, называемый *функционалом энергии*:

$$\Phi(\mathbf{u}) = (\mathbf{A}\mathbf{u}, \mathbf{u}) - 2(\mathbf{f}, \mathbf{u}) + c,$$

где $\mathbf{A}$ — линейный оператор, $\mathbf{f} \in R^n$, c — константа. Этот функционал совпадает с квадратичным функционалом $\Phi(\mathbf{u}) = (\mathbf{A}^*\mathbf{u}, \mathbf{u}) - 2(\mathbf{f}, \mathbf{u}) + c$, где $\mathbf{A}^*$ — сопряженный к $\mathbf{A}$ оператор. Действительно, $(\mathbf{A}\mathbf{u}, \mathbf{u}) \equiv (\mathbf{u}, \mathbf{A}^*\mathbf{u})$ по определению сопряженного оператора и $(\mathbf{u}, \mathbf{A}^*\mathbf{u}) = (\mathbf{A}^*\mathbf{u}, \mathbf{u})$ в силу коммутативности скалярного произведения. Тогда

$$\Phi(\mathbf{u}) = \left(\frac{\mathbf{A} + \mathbf{A}^*}{2} \mathbf{u}, \mathbf{u} \right) - 2(\mathbf{f}, \mathbf{u}) + c,$$

так как

$$\frac{1}{2}(\mathbf{A}\mathbf{u}, \mathbf{u}) + \frac{1}{2}(\mathbf{A}^*\mathbf{u}, \mathbf{u}) = \left(\frac{\mathbf{A} + \mathbf{A}^*}{2} \mathbf{u}, \mathbf{u} \right).$$

Без ограничения общности предположим, что оператор $\mathbf{A}$ — самосопряженный, $\mathbf{A} = \mathbf{A}^*$. В противном случае будем рассматривать задачу с оператором $\frac{1}{2}(\mathbf{A} + \mathbf{A}^*)$ при решении вариационной задачи.

Будем также считать, что $\mathbf{A}$ — положительный оператор, т. е. $\mathbf{A} > 0$. Это условие означает, что для любого ненулевого вектора $\mathbf{u}$

выполнено $(\mathbf{A}\mathbf{u}, \mathbf{u}) > 0$. Поставим задачу об отыскании элемента $\mathbf{v}$, придающего наименьшее значение функционалу $\Phi(\mathbf{u})$:

$$\Phi(\mathbf{v}) = \min_{\mathbf{u} \in R^n} \Phi(\mathbf{u}).$$

Теорема 2.9. Пусть $\mathbf{A} = \mathbf{A}^* > 0$. В этом случае существует единственный элемент $\mathbf{v} \in R^n$, придающий наименьшее значение квадратичному функционалу $\Phi(\mathbf{u}) = (\mathbf{A}\mathbf{u}, \mathbf{u}) - 2(\mathbf{f}, \mathbf{u}) + c$, являющийся решением СЛАУ $\mathbf{A}\mathbf{u} = \mathbf{f}$.

Доказательство. СЛАУ $\mathbf{A}\mathbf{u} = \mathbf{f}$ имеет единственное решение $\mathbf{v}$, поскольку $\mathbf{A}$ является невырожденным оператором в силу его положительной определенности. Покажем, что в этом случае при $\mathbf{A}\mathbf{v} - \mathbf{f} = 0$ для любого вектора δ имеет место $\Phi(\mathbf{v} + \delta) > \Phi(\mathbf{v})$, т. е. при $\mathbf{u} = \mathbf{v}$ достигается минимум квадратичного функционала $\Phi(\mathbf{u})$.

Действительно,

$$\begin{aligned} \Phi(\mathbf{v} + \delta) &= (\mathbf{A}(\mathbf{v} + \delta), \mathbf{v} + \delta) - 2(\mathbf{f}, \mathbf{v} + \delta) + c = \\ &= (\mathbf{A}\mathbf{v} + \mathbf{A}\delta, \mathbf{v} + \delta) - 2(\mathbf{f}, \mathbf{v} + \delta) + c = \\ &= (\mathbf{A}\mathbf{v}, \mathbf{v}) + (\mathbf{A}\mathbf{v}, \delta) + (\mathbf{A}\delta, \mathbf{v}) + (\mathbf{A}\delta, \delta) - 2(\mathbf{f}, \mathbf{v}) - 2(\mathbf{f}, \delta) + c = \\ &= (\mathbf{A}\mathbf{v}, \mathbf{v}) + 2(\mathbf{A}\mathbf{v}, \delta) + (\mathbf{A}\delta, \delta) - 2(\mathbf{f}, \mathbf{v}) - 2(\mathbf{f}, \delta) + c = \\ &= [(\mathbf{A}\mathbf{v}, \mathbf{v}) - 2(\mathbf{f}, \mathbf{v}) + c] + 2(\mathbf{A}\mathbf{v}, \delta) - 2(\mathbf{f}, \delta) + (\mathbf{A}\delta, \delta) = \\ &= \Phi(\mathbf{v}) + 2(\mathbf{A}\mathbf{v} - \mathbf{f}, \delta) + (\mathbf{A}\delta, \delta) = \Phi(\mathbf{v}) + (\mathbf{A}\delta, \delta) > \Phi(\mathbf{v}), \end{aligned}$$

т. е. при $\mathbf{A}\mathbf{v} = \mathbf{f}$ и любом δ имеет место $\min_{\mathbf{u}} \Phi(\mathbf{u})$. Докажем, что верно и обратное утверждение. Если элемент доставляет минимальное значение функционалу энергии, то он является решением системы линейных уравнений $\mathbf{A}\mathbf{v} = \mathbf{f}$. Из курса математического анализа известно, что в точке минимума должно выполняться условие $\nabla \Phi(\mathbf{v}) = 0$, $\mathbf{A} > 0$. Вычисляя градиент, приходим к условию минимума функционала $\nabla \Phi(\mathbf{v}) = 2\mathbf{A}\mathbf{v} - 2\mathbf{f} = 0$. Таким образом, установлена эквивалентность вариационной задачи (отыскание элемента, придающего минимум $\Phi(\mathbf{u})$) и задачи о нахождении решения СЛАУ. $\square$

Заметим, что СЛАУ с самосопряженным и положительно определенным оператором $\mathbf{A}$ представляют собой важный класс задач

в математической физике. В частности, они возникают при решении краевых задач для эллиптических уравнений. При необходимости можно произвести симметризацию по Гауссу исходной системы.

2.6.2. Методы градиентного и наискорейшего спуска. Метод градиентного спуска состоит в нахождении следующего приближения в итерационном процессе из предыдущего путем смещения в направлении градиента функционала

$$\Phi(\mathbf{u}) = (\mathbf{A}\mathbf{u}, \mathbf{u}) - 2(\mathbf{f}, \mathbf{u}); \quad (2.27)$$

$$\Phi(\mathbf{u}^{k+1}) = \mathbf{u}_{k+1} = \mathbf{u}_k - \alpha_k \nabla \Phi(\mathbf{u}_k), \quad (2.28)$$

где $\mathbf{A}$ — положительно определенная симметричная матрица; α_k — параметр, определяемый из заданных условий — например, из условия минимума величины $\Phi[\mathbf{u}_k - \alpha_k \nabla \Phi(\mathbf{u}_k)]$.

В этом случае итерационный метод называется методом наискорейшего спуска. Так как $\nabla \Phi(\mathbf{u}) = 2(\mathbf{A}\mathbf{u} - \mathbf{f})$, то (2.28) приобретает вид

$$\mathbf{u}_{k+1} = \mathbf{u}_k - \tau_k(\mathbf{A}\mathbf{u}_k - \mathbf{f}), \quad \text{где } \tau_k = 2\alpha_k, \quad (2.29)$$

что соответствует записи итерационного метода в форме (2.19). Здесь τ_k является итерационным параметром, который в методе наискорейшего спуска определяется из условия минимума функции $\Phi(\tau_k, \mathbf{u}_{k+1})$ по τ_k . Найдем условие этого минимума:

$$\begin{aligned} 0 &= \frac{d}{d\tau_k} \Phi(\tau_k, \mathbf{u}_{k+1}) = (\mathbf{A}(\mathbf{u}_{k+1})'_{\tau_k}, \mathbf{u}_{k+1}) + (\mathbf{A}\mathbf{u}_{k+1}, (\mathbf{u}_{k+1})'_{\tau_k}) - \\ &- 2(\mathbf{f}, (\mathbf{u}_{k+1})'_{\tau_k}) = 2(\mathbf{A}\mathbf{u}_{k+1} - \mathbf{f}, (\mathbf{u}_{k+1})'_{\tau_k}) = -2(\mathbf{A}\mathbf{u}_{k+1} - \mathbf{f}, \mathbf{A}\mathbf{u}_k - \mathbf{f}). \end{aligned}$$

Здесь учтено равенство $(\mathbf{A}\mathbf{u}', \mathbf{u}) = (\mathbf{u}', \mathbf{A}^*\mathbf{u}) = (\mathbf{A}\mathbf{u}, \mathbf{u}')$, поскольку $\mathbf{A} = \mathbf{A}^*$ и $(\mathbf{v}, \mathbf{A}\mathbf{w}) = (\mathbf{A}\mathbf{w}, \mathbf{v})$ в силу самосопряженности оператора $\mathbf{A}$. Подставим в последние равенства $\mathbf{u}^{k+1}$ из (2.29), получим $(\mathbf{A}\mathbf{u}^k - \mathbf{f} - \tau_k \mathbf{A}(\mathbf{A}\mathbf{u}^k - \mathbf{f}), \mathbf{A}\mathbf{u}^k - \mathbf{f}) = 0$, откуда следует

$$\begin{aligned} (\mathbf{A}\mathbf{u}^k - \mathbf{f}, \mathbf{A}\mathbf{u}^k - \mathbf{f}) - \tau_k (\mathbf{A}(\mathbf{A}\mathbf{u}^k - \mathbf{f}), \mathbf{A}\mathbf{u}^k - \mathbf{f}) &= 0, \\ \tau_k &= \frac{(\mathbf{A}\mathbf{u}^k - \mathbf{f}, \mathbf{A}\mathbf{u}^k - \mathbf{f})}{(\mathbf{A}(\mathbf{A}\mathbf{u}^k - \mathbf{f}), \mathbf{A}\mathbf{u}^k - \mathbf{f})}, \quad \text{или } \tau_k = \frac{(\mathbf{r}^k, \mathbf{r}^k)}{(\mathbf{A}\mathbf{r}^k, \mathbf{r}^k)}. \end{aligned}$$

где $\mathbf{r}^k = \mathbf{A}\mathbf{u}^k - \mathbf{f}$.

2.6.3. Метод минимальных невязок. Этот итерационный метод определяется следующим образом. Пусть $\mathbf{u}^{k+1} = \mathbf{u}^k - \tau_k \mathbf{r}^k$, как и ранее, $\mathbf{r}^k = \mathbf{A}\mathbf{u}^k - \mathbf{f}$. Итерационный параметр τ_k на каждой итерации выбирается так, чтобы минимизировать евклидову норму невязки $\mathbf{r}^{k+1}$. Заметим, что итерационный процесс $\mathbf{u}^{k+1} = \mathbf{u}^k - \tau_k \mathbf{r}^k$ может быть представлен в равносильном виде в терминах невязки $\mathbf{r}^{k+1} = \mathbf{r}^k - \tau_k \mathbf{A}\mathbf{r}^k$ вычитанием из $\mathbf{r}^{k+1} - \mathbf{r}^k$. Тогда для квадрата евклидовой (третьей) нормы невязки получаем условие

$$(\mathbf{r}^{k+1}, \mathbf{r}^{k+1}) = (\mathbf{r}^k, \mathbf{r}^k) - 2\tau_k(\mathbf{A}\mathbf{r}^k, \mathbf{r}^k) + \tau_k^2(\mathbf{A}\mathbf{r}^k, \mathbf{A}\mathbf{r}^k).$$

Для отыскания минимума невязки на следующей итерации приравняем нулю производную последнего выражения по итерационному параметру τ_k . Получим равенство

$$-2(\mathbf{A}\mathbf{r}^k, \mathbf{r}^k) + 2\tau_k(\mathbf{A}\mathbf{r}^k, \mathbf{A}\mathbf{r}^k) = 0.$$

Из последнего уравнения находим значение итерационного параметра

$$\tau_k = \frac{(\mathbf{A}\mathbf{r}^k, \mathbf{r}^k)}{(\mathbf{A}\mathbf{r}^k, \mathbf{A}\mathbf{r}^k)}.$$

2.6.4. Метод сопряженных градиентов.

Подпространства Крылова. Выберем произвольный вектор $\mathbf{u}^0 = \mathbf{v} \in R^N$. Пусть задана самосопряженная положительная матрица $\mathbf{A} = \mathbf{A}^* > 0$. Рассмотрим последовательность векторов $\mathbf{u}^1 = \mathbf{A}\mathbf{v}$, $\mathbf{u}^2 = \mathbf{A}\mathbf{u}^1 = \mathbf{A}^2\mathbf{v}$, ..., $\mathbf{u}^{m-1} = \mathbf{A}\mathbf{u}^{m-2} = \mathbf{A}^{m-1}\mathbf{v}$.

Тогда линейная оболочка, натянутая на эти векторы, называется подпространством Крылова

$$K_m(\mathbf{v}, \mathbf{A}) = \text{span}(\mathbf{u}^0, \mathbf{u}^1, K, \mathbf{u}^{m-1}) = \text{span}(\mathbf{v}, \mathbf{A}\mathbf{v}, K, \mathbf{A}^{m-1}\mathbf{v}).$$

Подпространство Крылова можно построить, даже если сама матрица системы неизвестна, а доступна только операция умножения данной матрицы на произвольный вектор.

Выше был описан метод наискорейшего спуска. Пусть каждая итерация имеет вид (2.29), а начальное приближение — нулевой вектор. В результате последовательности j итераций получаем

$$\begin{aligned} \mathbf{u}^j &= \mathbf{u}^{j-1} - \tau_{j-1}(\mathbf{A}\mathbf{u}^{j-1} - \mathbf{f}) = \mathbf{u}^{j-1} - \tau_{j-1}\mathbf{r}^{j-1} = \dots = \\ &= -\tau_0\mathbf{r}^0 - \tau_1\mathbf{r}^1 - \dots - \tau_{j-1}\mathbf{r}^{j-1}. \end{aligned}$$

Тогда вектор следующего приближения принадлежит линейной оболочке

$$K_{j-1}(\mathbf{f}, \mathbf{A}) = \text{span}(\mathbf{f}, \mathbf{A}\mathbf{f}, \dots, \mathbf{A}^{m-1}\mathbf{f}),$$

т. е. соответствующему крыловскому подпространству.

Простейшая формулировка метода сопряженных градиентов. Этот метод применяется для решения систем уравнений с самосопряженной положительной матрицей $\mathbf{A} = \mathbf{A}^* > 0$. Такая матрица порождает скалярное произведение и энергетическую норму.

Поставим в соответствие каждому вектору $\mathbf{u} \in R^N$ скалярную величину $\xi(\mathbf{u}) = (\mathbf{A}\mathbf{u}, \mathbf{u})^{1/2}$. Непосредственно проверяется, что для нее выполнены все аксиомы нормы. Тогда можно считать, что каждая самосопряженная положительно определенная матрица порождает норму в конечномерном пространстве. Такая норма называется *энергетической* и обозначается

$$\|\mathbf{u}\|_{\mathbf{A}} = (\mathbf{A}\mathbf{u}, \mathbf{u})^{1/2}.$$

Величину $\langle \mathbf{u}, \mathbf{v} \rangle_{\mathbf{A}} = (\mathbf{A}\mathbf{v}, \mathbf{u}) = (\mathbf{A}\mathbf{u}, \mathbf{v})$ будем называть скалярным произведением, порождаемым матрицей $\mathbf{A}$.

С использованием энергетической нормы функционал энергии можно переписать как

$$\Phi(\mathbf{y}) = \frac{1}{2}(\mathbf{A}\mathbf{y}, \mathbf{y}) - (\mathbf{f}, \mathbf{y}) + C = \frac{\langle \mathbf{y}, \mathbf{y} \rangle_{\mathbf{A}}}{2} - (\mathbf{f}, \mathbf{y}) + C.$$

Будем рассматривать $\mathbf{y}$ как приближение к решению системы $\mathbf{A}\mathbf{u} = \mathbf{f}$ и введем итерационную погрешность $\boldsymbol{\varepsilon} = \mathbf{y} - \mathbf{u}$.

Выделив в функционале энергии полный квадрат, получим

$$\begin{aligned} \Phi(\mathbf{y}) &= \frac{\langle \mathbf{y}, \mathbf{y} \rangle_{\mathbf{A}}}{2} - (\mathbf{f}, \mathbf{y}) + C = \frac{\langle \boldsymbol{\varepsilon} + \mathbf{u}, \boldsymbol{\varepsilon} + \mathbf{u} \rangle_{\mathbf{A}}}{2} - (\mathbf{f}, \boldsymbol{\varepsilon} + \mathbf{u}) + C = \\ &= \frac{\langle \boldsymbol{\varepsilon}, \boldsymbol{\varepsilon} \rangle_{\mathbf{A}}}{2} + \frac{\langle \mathbf{u}, \mathbf{u} \rangle_{\mathbf{A}}}{2} + (\mathbf{A}\mathbf{u}, \boldsymbol{\varepsilon}) - (\mathbf{f}, \boldsymbol{\varepsilon} + \mathbf{u}) + C = \frac{\langle \boldsymbol{\varepsilon}, \boldsymbol{\varepsilon} \rangle_{\mathbf{A}}}{2} - \frac{\langle \mathbf{u}, \mathbf{u} \rangle_{\mathbf{A}}}{2} + C. \end{aligned}$$

Так как энергетическая норма точного решения задачи $\mathbf{u}$ суть вполне определенная константа, то минимум функционала энергии совпадает с минимумом энергетической нормы погрешности.

Пусть мы минимизируем функционал, выбирая направление движения по антиградиенту как $\mathbf{u}^j = \mathbf{u}^{j-1} - \tau_{j-1}\mathbf{r}^{j-1}$. Тогда для итерационных погрешностей справедливо рекуррентное равенство $\boldsymbol{\varepsilon}^j = \boldsymbol{\varepsilon}^{j-1} - \tau_{j-1}\mathbf{r}^{j-1}$. После j итераций имеем

$$\boldsymbol{\varepsilon}^j = \boldsymbol{\varepsilon}^0 - (\tau_0\mathbf{r}^0 + \tau_1\mathbf{r}^1 + \dots + \tau_{j-1}\mathbf{r}^{j-1}).$$

Тогда набор коэффициентов (шагов, итерационных параметров) есть не что иное, как решение оптимизационной задачи

$$\operatorname{Argmin} \|\boldsymbol{\epsilon}^0 - (\tau_0 \mathbf{r}^0 + \tau_1 \mathbf{r}^1 + \dots + \tau_{j-1} \mathbf{r}^{j-1})\|_{\mathbf{A}}.$$

Известно, что наилучшим приближением вектора на подпространстве является такое, когда погрешность ортогональна каждому вектору из этого подпространства. Здесь ортогональность понимается в смысле скалярного произведения с весовой матрицей $\mathbf{A}$. Если два вектора таковы, что $(\mathbf{A}\boldsymbol{\epsilon}, \mathbf{u}) = 0$, то они называются *A-сопряженными*.

Идея метода состоит в следующем. Выбираем произвольное начальное приближение и вычисляем по нему вектор невязки $\mathbf{r}^0 = \mathbf{A}\mathbf{u}^0 - \mathbf{f}$, тогда первое приближение $\mathbf{u}^1 = \mathbf{u}^0 - \tau_0 \mathbf{r}^0$.

Из условия ортогональности невязок на двух первых шагах находим значение итерационного параметра

$$\tau_0 = \frac{(\mathbf{r}^0, \mathbf{r}^0)}{(\mathbf{A}\mathbf{r}^0, \mathbf{r}^0)} = \frac{(\mathbf{r}^0, \mathbf{r}^0)}{\langle \mathbf{r}^0, \mathbf{r}^0 \rangle_{\mathbf{A}}}.$$

Теперь модифицируем метод: вместо минимизации функционала путем передвижения в направлении антиградиента учтем и предыдущее направление спуска с каким-то весом. Очевидно, что сделать это можно для всех итераций с номером больше единицы. Покажем, что в этом случае

$$\mathbf{u}^{k+1} = \mathbf{u}^k - \tau_k \mathbf{p}^k,$$

а вектор

$$\mathbf{p}^k = \mathbf{r}^k + \beta_k \mathbf{p}^{k-1}. \quad (2.30)$$

Если теперь выбрать $\tau_k = \frac{(\mathbf{r}^k, \mathbf{p}^k)}{\langle \mathbf{p}^k, \mathbf{p}^k \rangle_{\mathbf{A}}}$, то, как легко проверить, вектор невязки на следующей итерации будет ортогонален направлению минимизации, а итерационная погрешность будет *A-сопряжена* направлению минимизации. Для быстреего достижения минимума энергетического функционала направления поиска следует выбирать *A-сопряженными*.

Пусть после k шагов выбирается направление

$$\mathbf{p}^{k+1} = \mathbf{r}^{k+1} - \sum_{i=0}^k c_{ik} \mathbf{p}^i. \quad (2.31)$$

Тогда с помощью процедуры Грама–Шмидта для коэффициентов разложения получим

$$c_{ik} = \frac{\langle \mathbf{r}^{k+1}, \mathbf{p}^i \rangle_{\mathbf{A}}}{\langle \mathbf{p}^i, \mathbf{p}^i \rangle_{\mathbf{A}}}.$$

Далее для завершения построения метода нам необходимо утверждение следующей Теоремы.

Теорема 2.10. *После j шагов метода сопряженных градиентов линейная оболочка всех векторов направлений поиска минимума функционала энергии совпадает с крыловским подпространством $K_j(\mathbf{r}^0, \mathbf{A})$.*

С л е д с т в и е. В разложении (2.31) все коэффициенты, кроме последнего, равны 0. При реализации метода сопряженных градиентов (2.31) приобретает вид (2.30) с условием

$$\beta_k = \frac{(\mathbf{r}^{k+1}, \mathbf{r}^{k+1})}{(\mathbf{r}^k, \mathbf{r}^k)}.$$

Метод сопряженных градиентов можно рассматривать как прямой метод решения СЛАУ — в арифметике с бесконечной длиной мантиссы за число итераций, равной размерности пространства, невязка будет $\mathbf{A}$ -сопряженной ко всем векторам крыловского пространства; следовательно, нулевая. Конечно, в реальных вычислениях из-за влияния погрешностей округления добиться того, чтобы невязка в точности обратилась в ноль, чаще всего не удастся, а метод сопряженных градиентов применяется как итерационный метод. В этом случае число итераций метода может быть и больше размерности пространства.

В настоящее время существует ряд модификаций метода сопряженных градиентов, они отличаются темпами накопления погрешности, связанной с ошибками округления.

2.7. О спектральных задачах

Спектральные задачи — вычислительно наиболее трудоемкие задачи в прикладной линейной алгебре. Различают полную и частичную проблемы собственных значений. В первом случае необходимо отыскать *все* собственные числа матрицы, во втором — лишь максимальное по абсолютной величине собственное число.

Различают также самосопряженную спектральную задачу и задачу для произвольной матрицы. Очевидно, самосопряженная проблема решается проще — спектр самосопряженной матрицы всегда действительный.

Рассмотрим два алгоритма для самосопряженных матриц. Первый — *степенной* алгоритм, для вычисления наибольшего по абсолютной величине собственного числа. Выбираем произвольный ненулевой вектор $\mathbf{u}_0$ и строим последовательность векторов

$$\mathbf{u}^{k+1} = \mathbf{A}\mathbf{u}^k.$$

Легко показать, что выражение

$$\lambda \approx \frac{(\mathbf{A}\mathbf{u}^k, \mathbf{u}^k)}{(\mathbf{u}^k, \mathbf{u}^k)} = \frac{(\mathbf{u}^{k+1}, \mathbf{u}^k)}{(\mathbf{u}^k, \mathbf{u}^k)}$$

приближает максимальное по абсолютной величине собственное значение с точностью $O(\lambda_N/\lambda_{N-1})^k$. Здесь λ_N/λ_{N-1} — отношение самого большого по модулю собственного числа матрицы к следующему по абсолютной величине.

Для решения полной самосопряженной проблемы собственных значений применяется *метод вращений*.

Определение собственных значений самосопряженной матрицы $\mathbf{A}$ эквивалентно отысканию такой ортогональной матрицы $\mathbf{T}$, что $\mathbf{\Lambda} = \mathbf{T}\mathbf{A}\mathbf{T}$, матрица $\mathbf{\Lambda}$ — диагональная. Среди всех ортогональных преобразований данное минимизирует сумму квадратов внедиагональных элементов исходной матрицы. Построим итерационный метод, минимизирующий эту сумму на каждой итерации. Пусть каждое преобразование подобия на каждой итерации содержит лишь одну матрицу вращения $\widehat{\mathbf{A}} = \mathbf{T}'_{ij}\mathbf{A}\mathbf{T}_{ij}$, где матрица $\mathbf{T}_{ij}$ есть матрица поворота в плоскости $\mathbf{u}_i\mathbf{u}_j$ на угол α . Эта матрица отличается от матрицы $\mathbf{A}$ только двумя строками и двумя столбцами (с номерами i и j). Так как норма Фробениуса матрицы не изменяется при ортогональных преобразованиях, то легко получить соотношение между суммами квадратов внедиагональных элементов старой и новой матриц:

$$\sum_{i \neq j} \widehat{a}_{ij}^2 = \sum_{i \neq j} a_{ij}^2 - 2a_{ij}^2 + \frac{1}{2}((a_{jj} - a_{ii})\sin 2\alpha + 2a_{ij}\cos 2\alpha)^2.$$

Очевидны условия минимизации суммы в левой части последнего равенства. Следует на текущей итерации выбирать индексы

так, чтобы выполнялось условие $|a_{ij}| = \max_{k \neq l} |a_{kl}|$, а угол поворота выбирается из условия

$$0 = ((a_{jj} - a_{ii}) \sin 2\alpha + 2a_{ij} \cos 2\alpha)^2.$$

Тогда он удовлетворяет условию

$$\operatorname{tg} 2\alpha = \frac{2a_{ij}}{a_{ii} - a_{jj}}, \quad |\alpha| \leq \frac{\pi}{4}.$$

Независимо от наличия кратных собственных значений метод вращений обладает квадратичной сходимостью.

Выбор максимального по модулю внедиагонального элемента — затратная операция, поэтому часто реализуется метод вращений с барьерами. Его идея состоит в следующем. При переборе внедиагональных значений вращение производится тогда, когда значение элемента по абсолютной величине превосходит некоторую величину (барьер). Если все элементы меньше барьера, его значение уменьшается, например, на порядок, и снова начинается циклический перебор внедиагональных элементов. (Подробнее о методе вращений см. в [15].)

Другие алгоритмы решения спектральных задач описаны в специальной литературе [9, 11, 15].

2.8. Примеры решения задач

1. Методом Гаусса решить систему линейных уравнений $\mathbf{A}\mathbf{u} = \mathbf{f}$, где

$$\mathbf{A} = \begin{pmatrix} 5 & 0 & 1 \\ 2 & 6 & -2 \\ -3 & 2 & 10 \end{pmatrix}, \quad \mathbf{f} = (11, 8, 6)^T.$$

Решение. Расширенная матрица $\widetilde{\mathbf{A}}$ имеет вид

$$\widetilde{\mathbf{A}} = \begin{pmatrix} a_{11} & a_{12} & a_{13} & f_1 \\ a_{21} & a_{22} & a_{23} & f_2 \\ a_{31} & a_{32} & a_{33} & f_3 \end{pmatrix} = \begin{pmatrix} 5 & 0 & 1 & 11 \\ 2 & 6 & -2 & 8 \\ -3 & 2 & 10 & 6 \end{pmatrix}.$$

Разделив элементы первой строки на ведущий элемент $a_{11} = 5$, получаем первую опорную строку $(1, 0, 0.2, 2.2)$.

Далее умножим ее на $a_{21} = 2$ и вычтем из второй строки, после чего умножим опорную строку на $a_{31} = 3$ и вычтем из третьей. Получаем матрицу $\tilde{\mathbf{A}}_1$:

$$\tilde{\mathbf{A}}_1 = \begin{pmatrix} a_{11} & a_{12} & a_{13} & f_1 \\ 0 & \tilde{a}_{22}^1 & \tilde{a}_{23}^1 & \tilde{f}_2^1 \\ 0 & \tilde{a}_{32}^1 & \tilde{a}_{33}^1 & \tilde{f}_3^1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0.2 & 2.2 \\ 0 & 6 & -2.4 & 3.6 \\ 0 & 2 & 10.6 & 12.6 \end{pmatrix}.$$

Вторая опорная строка — результат деления второй строки матрицы $\tilde{\mathbf{A}}_1$ на $\tilde{a}_{22}^1 = 6$: $(0, 1, -0.4, 0.6)$.

Матрица $\tilde{\mathbf{A}}_2$ после умножения опорной строки на 2 и вычитания ее из третьей:

$$\tilde{\mathbf{A}}_2 = \begin{pmatrix} a_{11} & a_{12} & a_{13} & f_1 \\ 0 & \tilde{a}_{22}^1 & \tilde{a}_{23}^1 & \tilde{f}_2^1 \\ 0 & 0 & \tilde{\tilde{a}}_{33}^2 & \tilde{\tilde{f}}_3^2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0.2 & 2.2 \\ 0 & 1 & -0.4 & 0.6 \\ 0 & 0 & 11.4 & 11.4 \end{pmatrix}.$$

Третья опорная строка (результат деления третьей строки на 11.4) есть $(0, 0, 1, 1)$.

Матрица $\tilde{\mathbf{A}}_3$ будет

$$\tilde{\mathbf{A}}_3 = \begin{pmatrix} 1 & 0 & 0.2 & 2.2 \\ 0 & 1 & -0.4 & 0.6 \\ 0 & 0 & 1 & 1 \end{pmatrix}.$$

Расширенная матрица приведена к верхнетреугольному виду; на этом завершается прямой ход алгоритма. Для определения решения служит обратный ход метода Гаусса.

В результате прямого хода получена система уравнений с матрицей $\tilde{\mathbf{A}}_3$:

$$\begin{aligned} u_1 + 0 \cdot u_2 + 0.2u_3 &= 2.2, \\ u_2 - 0.4u_3 &= 0.6, \\ u_3 &= 1. \end{aligned}$$

Разрешая эту систему, начиная с последнего уравнения, получим

$$u_3 = 1, \quad u_2 = 1, \quad u_1 = 2.$$

2. Показать, что решение системы линейных уравнений

$$\begin{aligned}u_1 + 2u_2 + 3u_3 + 4u_4 &= 2, \\u_1 + 3u_2 + u_3 + 2u_4 &= -1, \\2u_1 + 3u_2 + 8u_3 + 7u_4 &= 10, \\2u_1 + 5u_2 + 3u_3 + 7u_4 &= 3\end{aligned}$$

методом Гаусса невозможно.

Решение. Преобразование матрицы рассматриваемой системы будет

$$\begin{pmatrix} 1 & 2 & 3 & 4 & 2 \\ 1 & 3 & 1 & 2 & -1 \\ 2 & 3 & 8 & 7 & 10 \\ 2 & 5 & 3 & 7 & 3 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 2 & 3 & 4 & 2 \\ 0 & 1 & -2 & -2 & -3 \\ 0 & -1 & 2 & -1 & 6 \\ 0 & 1 & -3 & -1 & 1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 2 & 3 & 4 & 2 \\ 0 & 1 & -2 & -2 & -3 \\ 0 & 0 & 0 & -3 & -3 \\ 0 & 0 & -1 & 1 & 2 \end{pmatrix}.$$

Поскольку $a_{33}^2 = 0$, то вычисление третьей опорной строки невозможно.

3. Найти число обусловленности матрицы $\mathbf{A}$, выразив его через число обусловленности матрицы $\mathbf{B}$, если $\mathbf{A} = \mathbf{B}^* \mathbf{B} > 0$.

Решение. Для самосопряженной положительной матрицы $\mathbf{A}$ имеем

$$\|\mathbf{A}\| = \sup_{\|\mathbf{u}\| \neq 0} \frac{(\mathbf{u}, \mathbf{A}\mathbf{u})}{(\mathbf{u}, \mathbf{u})}.$$

Тогда

$$\begin{aligned}\mu(\mathbf{A}) &= \|\mathbf{A}\|_3 \|\mathbf{A}^{-1}\|_3 = \sup_{\|\mathbf{u}\| \neq 0} \frac{(\mathbf{u}, \mathbf{A}\mathbf{u})}{(\mathbf{u}, \mathbf{u})} \sup_{\|\mathbf{u}\| \neq 0} \frac{(\mathbf{u}, \mathbf{A}^{-1}\mathbf{u})}{(\mathbf{u}, \mathbf{u})} = \\ &= \sup_{\|\mathbf{u}\| \neq 0} \frac{(\mathbf{B}\mathbf{u}, \mathbf{B}\mathbf{u})}{(\mathbf{u}, \mathbf{u})} \sup_{\|\mathbf{u}\| \neq 0} \frac{(\mathbf{B}^{-1}\mathbf{u}, \mathbf{B}^{-1}\mathbf{u})}{(\mathbf{u}, \mathbf{u})} = \|\mathbf{B}\|_3^2 \|\mathbf{B}^{-1}\|_3^2,\end{aligned}$$

откуда

$$\mu(\mathbf{A}) = \mu^2(\mathbf{B}).$$

4. Показать, что норма матрицы

$$\|\mathbf{A}\|_2 = \max_{1 \leq j \leq n} \sum_{j=1}^n |a_{ij}|$$

согласована с нормой вектора

$$\|\mathbf{u}\|_2 = \sum_{i=1}^n |u_i|.$$

Решение.

$$\begin{aligned} \|\mathbf{A}\mathbf{u}\|_2 &= \sum_{i=1}^n \left| \sum_{j=1}^n a_{ij} u_j \right| \leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| |u_j| \leq \sum_{j=1}^n |u_j| \cdot \sum_{i=1}^n |a_{ij}| \leq \\ &\leq \left(\max_{1 \leq i \leq n} \sum_j |a_{ij}| \right) \|\mathbf{u}\|_2 = \|\mathbf{A}\|_2 \|\mathbf{u}\|_2. \end{aligned}$$

Положим

$$\max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| = \sum_{j=1}^n |a_{kj}|, \quad \max_{i=1}^n \sum_{j=1}^n |a_{ij}| = \sum_{i=1}^n |a_{ik}|.$$

Покажем, что существует вектор $\mathbf{v}$, для которого достигается равенство. В качестве такового можно взять вектор $\mathbf{v}$ с компонентами $v_i = 0$, $i \neq k$, $v_k = 1$.

Таким образом, норма матрицы $\|\mathbf{A}\|_2 = \max_{1 \leq j \leq n} \sum |a_{ij}|$ согласована с нормой вектора $\|\mathbf{u}\|_2 = \sum_{i=1}^n |u_i|$.

5. Дана жорданова клетка порядка n :

$$\mathbf{A} = \begin{pmatrix} 1 & d & 0 & \dots & \dots & 0 & 0 \\ 0 & 1 & d & \dots & \dots & 0 & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 & d & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \dots & \dots & 1 & d \\ 0 & 0 & \dots & \dots & \dots & \dots & 1 \end{pmatrix}.$$

Найти $\mu(\mathbf{A})$ и оценить возмущение в компоненте u_1 решения системы $\mathbf{A}\mathbf{u} = \mathbf{f}$, если компонента f_n вектора $\mathbf{f}$ возмущена на величину ε .

Решение. Из $\mathbf{A}\mathbf{u} = \mathbf{f}$ следует, что $\mathbf{u} = \mathbf{A}^{-1}\mathbf{f}$. С помощью обратной подстановки $u_n = 1$, $u_{n-1} = \dots$ находим компоненты матрицы

$$\mathbf{A}^{-1} = \begin{pmatrix} 1 & -d & d^2 & \dots & \dots & (-d)^{n-2} & (-d)^{n-1} \\ 0 & 1 & -d & \dots & \dots & (-d)^{n-3} & (-d)^{n-2} \\ 0 & 0 & 1 & \dots & \dots & (-d)^{n-4} & (-d)^{n-3} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & \dots & 1 & -d \\ 0 & 0 & 0 & \dots & \dots & 0 & 1 \end{pmatrix}.$$

В этом случае

$$\|\mathbf{A}\|_1 = 1 + |d|, \quad \|\mathbf{A}^{-1}\|_1 = 1 + |d| + d^2 + \dots + |d|^{n-1} = \frac{|d|^n - 1}{|d| - 1}.$$

Видно, что при $|d| > 1$ матрица $\mathbf{A}$ плохо обусловлена, при $|d| < 1$ — хорошо. При $n = 20$ и $d = 5$ имеем $\mu(\mathbf{A}) \approx 10^{14}$.

Компонент $\tilde{u}_1$ решения возмущенной системы $\tilde{\mathbf{u}} = \mathbf{A}^{-1}\tilde{\mathbf{f}}$ будет

$$\begin{aligned} \tilde{u}_1 &= f_1 - df_2 + d^2f_3 + \dots + (-d)^{n-2}f_{n-1} + (-d)^{n-1}(f_n + \varepsilon) = \\ &= u_1 + (-d)^{n-1}\varepsilon, \end{aligned}$$

где u_1 — компонент решения невозмущенной системы $\mathbf{A}\mathbf{u} = \mathbf{f}$.

Отсюда видно, что при $|d| > 1$ возмущение в n -компоненте вектора $\mathbf{f}$ увеличивается в компоненте u_1 вектора $\mathbf{u}$ в $|d|^{n-1}$ раз, а при $|d| < 1$ в $|d|^{n-1}$ раз убывает.

6. *Выписать формулы итерационных методов Якоби, Зейделя, верхней релаксации для СЛАУ*

$$\mathbf{A}\mathbf{u} = \mathbf{f}, \quad \mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \quad \mathbf{u} = (1, -1)^T, \quad \mathbf{f} = (1, -1)^T,$$

или

$$\begin{aligned} 2u + v &= 1, \\ u + 2v &= -1. \end{aligned}$$

Оценить количество итераций для метода Якоби.

Р е ш е н и е. Итерационные методы Якоби, Зейделя, релаксации записываются соответственно

$$\begin{cases} u_{k+1} = -\frac{1}{2}v_k + \frac{1}{2}, \\ v_{k+1} = -\frac{1}{2}u_k - \frac{1}{2}, \end{cases}$$

$$(u_0, v_0) = (u_0^0, v_0^0),$$

или $\mathbf{x}_{k+1} = \mathbf{B}\mathbf{x}_k + \mathbf{f}$,

$$\mathbf{B} = \begin{pmatrix} 0 & -0.5 \\ -0.5 & 0 \end{pmatrix},$$

$$u_{k+1} = -\frac{1}{2}v_k + \frac{1}{2},$$

$$v_{k+1} = -\frac{1}{2}u_{k+1} - \frac{1}{2};$$

$$u_{k+1} = (1 - \tau)u_k + \frac{\tau}{2}(1 - v_k),$$

$$v_{k+1} = (1 - \tau)v_k - \frac{\tau}{2}(1 + u_k).$$

Оценка количества итераций проводится по формуле

$$k \approx \frac{\ln(\epsilon/\epsilon_0)}{\ln\|\mathbf{B}\|} = \frac{\ln 10^{-3}}{\ln(1/2)}.$$

7. Представить графическую интерпретацию итерационного метода Зейделя для СЛАУ

$$a_{11}u + a_{12}v = f_1,$$

$$a_{21}u + a_{22}v = f_2,$$

$$a_{11} \neq 0, \quad a_{22} \neq 0.$$

Р е ш е н и е. Итерационный метод Зейделя записывается как

$$u_{k+1} = -\frac{a_{12}}{a_{11}}v_k + \frac{f_1}{a_{11}},$$

$$v_{k+1} = -\frac{a_{21}}{a_{22}}u_{k+1} + \frac{f_2}{a_{22}}.$$

Первое уравнение соответствует прямой 1, второе — прямой 2 (в координатных осях $\{u, v\}$, рис. 2.1). Вычисление u_1 соответствует проведению отрезка, параллельного оси $0u$ и (при $v = v_0$), до




Рис. 2.1

пересечения с прямой 1; точка пересечения даст первое приближение u_1 . Вычислению v_1 соответствует проведение из точки A_1 прямой, параллельной оси $0v$ до пересечения с прямой 2 и т. д. до сходимости итераций к точке пересечения прямых 1 и 2 (A_k) с заданной точностью.

Библиографический комментарий к Лекции 2

При чтении данной главы необходимо знание основ линейной алгебры в пределах [14]. Описание основных численных методов решения СЛАУ можно найти в [1–5]. О нормах векторов и матриц подробно написано в приложении к [6]. Многие вопросы прикладной линейной алгебры более широко изложены в книгах [9–13, 15, 16, 26]. Теоретическое изучение современных методов матричного анализа можно начать с [17]. Многие современные алгоритмы матричных вычислений с примерами реализации в среде matlab описаны в [18].

Для практических занятий по данному разделу можно использовать задачи из [8].

ЧИСЛЕННОЕ РЕШЕНИЕ ПЕРЕОПРЕДЕЛЕННЫХ СЛАУ. МЕТОД НАИМЕНЬШИХ КВАДРАТОВ

В лекции рассматриваются методы решения переопределенных систем уравнений. Рассматривается также приближение функций обобщенными полиномами. Обсуждается вопрос о выборе функционального базиса на погрешность результата.

Ключевые слова: переопределенная система, метод наименьших квадратов, обобщенный многочлен, конечный ряд Фурье.

3.1. Пример использования метода наименьших квадратов (МНК)

Приведем простой пример получения переопределенной системы линейных уравнений. Такого рода задачи часто встречаются, например, при обработке результатов экспериментов.

Пусть f — линейная (или близкая к линейной) функция аргумента x : $f(x) = u_1x + u_0$. В точках x_k известны значения функции $f(x_k)$. Тогда u_0, u_1 — коэффициенты, которые необходимо подобрать так, чтобы выполнялись условия $u_1x_k + u_0 = f_k$, $k = 0, 1, 2, 3, 4$, $f_k = f(x_k)$.

Получим систему пяти уравнений относительно двух неизвестных. Это — переопределенная система. Она не имеет классического решения, так как в общем случае не существует прямой, проходящей через все 5 точек (это возможно только тогда, когда какие-либо три уравнения полученной системы линейными преобразованиями сводятся к двум другим — система линейно зависима).

Рассмотрим общий случай. Пусть коэффициенты $\{u_0, u_1\}$ необходимо определить по результатам $n + 1$ измерения. Введем функцию, равную сумме квадратов невязок, $r_k = u_1x_k + u_0 - f_k$

$$\Phi(u_1, u_0) = \sum_{k=0}^n r_k^2 = \sum_{k=0}^n (u_1x_k + u_0 - f_k)^2. \quad (3.1)$$

Примем за обобщенное решение переопределенной СЛАУ такие $\{u_0, u_1\}$, для которых $\Phi(u_0, u_1)$ принимает наименьшие значения. Для определения обобщенного решения из условия минимума суммы квадратов невязки получаем систему двух уравнений, имеющую классическое решение:

$$\frac{\partial \Phi}{\partial u_0} = 0, \quad \frac{\partial \Phi}{\partial u_1} = 0.$$

Выбор $\Phi(u_0, u_1)$ имеет некоторый произвол. Например, возможно каждому измерению придать некоторый вес b_k . От набора таких весовых множителей зависело бы решение системы. В этом случае функционал Φ будет

$$\Phi(u_0, u_1) = \sum_{k=0}^n b_k (u_1 x_k - u_0 - f_k)^2.$$

Если минимизировать сумму абсолютных значений невязок $r_k = |u_1 x_k + u_0 - f_k|$, то получим задачу линейного программирования на отыскании минимума функционала

$$\Phi(u_1, u_2) = \sum_{k=0}^3 |u_1 x_k + u_0 - f_k|.$$

Получившийся таким образом функционал, вообще говоря, недифференцируем. Для решения этой задачи нельзя использовать метод наименьших квадратов.

Произвол имеется и в выборе базисных функций. Вообще говоря, можно было бы записать невязку r_k в виде

$$r_k = \sum_{j=0}^p u_j \varphi_j(x_k) - f(x_k), \quad k = 1, \dots, n,$$

где $\varphi_j(x)$ — некоторые функции, образующие базис, например тригонометрические: $\varphi_j(x) = \sin(jx)$. Выражение $\sum_{j=0}^p u_j \varphi_j(x)$ называется *обобщенным полиномом*. Это — линейная оболочка базисных функций. В приведенном выше примере в качестве базисных функций были выбраны степенные функции $\varphi_j(x) = x^j$, $j = 1, 0$. Обобщенный полином превратился в алгебраический.

пространства $\mathbf{v}$, придающий наименьшее значение квадратичной форме:

$$\Phi(\mathbf{u}) = [\mathbf{A}\mathbf{u} - \mathbf{f}, \mathbf{A}\mathbf{u} - \mathbf{f}].$$

Теорема 3.1. Пусть столбцы матрицы $\mathbf{A}$ линейно независимы, т.е. ранг $\mathbf{A}$ равен p . Тогда существует единственный элемент p -мерного евклидова пространства $\mathbf{v} \in R^p$, являющийся обобщенным решением системы (3.2), и решением СЛАУ

$$\mathbf{A}^T \mathbf{B} \mathbf{A} \mathbf{u} = \mathbf{A}^T \mathbf{B} \mathbf{f}, \quad (3.5)$$

состоящей из p скалярных уравнений относительно неизвестных $\{\mathbf{u}_k\}_{k=1}^{k=p}$, доставляющий минимум квадратичной форме

$$\Phi(\mathbf{u}) = [\mathbf{A}\mathbf{u} - \mathbf{f}, \mathbf{A}\mathbf{u} - \mathbf{f}].$$

Доказательство. Покажем, что решение СЛАУ $\mathbf{A}^T \mathbf{B} \mathbf{A} \mathbf{u} = \mathbf{A}^T \mathbf{B} \mathbf{f}$ существует и единственно. Введем обозначение $\mathbf{q}_k \in R^n$ для вектора — k -столбца матрицы $\mathbf{A}$ системы уравнений

$$\mathbf{q}_k = \{a_{1k}, \dots, a_{nk}\}^T; \quad k = 1, \dots, p.$$

Несложно показать, что матрица $\mathbf{D} = \mathbf{A}^T \mathbf{B} \mathbf{A}$ системы (3.5) есть квадратная матрица $p \times p$. Элемент d_{ij} этой матрицы, стоящий на пересечении i -й строки и j -го столбца, есть $d_{ij} = (\mathbf{q}_i, \mathbf{B} \mathbf{q}_j) = (\mathbf{B} \mathbf{q}_i, \mathbf{q}_j) = [\mathbf{q}_i, \mathbf{q}_j]$ в силу коммутативности скалярного произведения. Следовательно, $d_{ij} = d_{ji}$, что означает самосопряженность матрицы $\mathbf{D}$: $\mathbf{D} = \mathbf{D}^T$.

Покажем, что матрица $\mathbf{D}$ невырождена и положительно определена. Напомним, что $(\mathbf{f}, \mathbf{A} \boldsymbol{\xi}) = (\mathbf{A}^T \mathbf{f}, \boldsymbol{\xi})^p$, верхний индекс p здесь обозначает, что скалярное произведение определено в пространстве размерности p ; $\mathbf{f} \in R^n$, $\boldsymbol{\xi} \in R^p$. Это равенство проверяется непосредственно, если записать обе его части в развернутом виде. Невырожденность матрицы $\mathbf{D}$ следует из того, что ранг матрицы $\mathbf{A}$ равен p .

В таком случае $0 < [\mathbf{A} \mathbf{x}, \mathbf{A} \mathbf{x}] = (\mathbf{B} \mathbf{A} \mathbf{x}, \mathbf{A} \mathbf{x}) = (\mathbf{A}^T \mathbf{B} \mathbf{A} \mathbf{x}, \mathbf{x})^p = (\mathbf{D} \mathbf{x}, \mathbf{x})^p$. Поскольку $\mathbf{D}$ невырождена и положительно определена, то (3.5) имеет единственное решение $\mathbf{v} \in R^n$. Теперь покажем, что $\mathbf{v}$ — единственное обобщенное решение системы. Для любого

вектора $\delta \neq 0$ выполнено $\Phi(\mathbf{v} + \delta) > \Phi(\mathbf{v})$:

$$\begin{aligned}\Phi(\mathbf{v} + \delta) &= [\mathbf{A}(\mathbf{v} + \delta) - \mathbf{f}, \mathbf{A}(\mathbf{v} + \delta) - \mathbf{f}]^n = \\ &= [\mathbf{A}\mathbf{v} - \mathbf{f}, \mathbf{A}\mathbf{v} - \mathbf{f}]^n - 2[\mathbf{A}\mathbf{v} - \mathbf{f}, \mathbf{A}\delta]^n + [\mathbf{A}\delta, \mathbf{A}\delta]^n = \\ &= \Phi(\mathbf{v}) + 2[\mathbf{A}\mathbf{v} - \mathbf{f}, \mathbf{A}\delta]^n + (\mathbf{D}\delta, \delta)^p = \Phi(\mathbf{v}) + (\mathbf{D}\delta, \delta)^p > \Phi(\mathbf{v}),\end{aligned}$$

что и требовалось доказать.

При доказательстве использовалось

$$[\mathbf{A}\mathbf{v} - \mathbf{f}, \mathbf{A}\delta]^n = (\mathbf{B}(\mathbf{A}\mathbf{v} - \mathbf{f}), \mathbf{A}\delta)^n = (\mathbf{A}^T \mathbf{B} \mathbf{A} \mathbf{v} - \mathbf{A}^T \mathbf{B} \mathbf{f}, \delta)^p = 0,$$

поскольку $\mathbf{A}^T \mathbf{B} \mathbf{A} \mathbf{v} = \mathbf{A}^T \mathbf{B} \mathbf{f}$.

Так как матрица $\mathbf{D} = \mathbf{A}^T \mathbf{B} \mathbf{A}$ — симметричная и положительно определенная, то для численного решения полученной СЛАУ можно воспользоваться итерационными методами (см. Лекцию 2).

Если система векторов $\{\mathbf{q}_k\}_{k=1}^p$ оказывается ортонормированной, т. е. $[\mathbf{q}_i, \mathbf{q}_j] = \delta_{ij}$; $i, j = 1, \dots, p$, то матрица $\mathbf{D}$ оказывается единичной. Ее элементы и есть скалярные произведения $[\mathbf{q}_i, \mathbf{q}_j]$. В этом случае решением системы будет

$$\mathbf{u} = \mathbf{A}^T \mathbf{B} \mathbf{f}.$$

Следует отметить, что если базисные функции $\varphi_i(x)$, $i = 0, \dots, p$ не выбираются специальным образом, то при достаточно больших p ($p \geq 5$) полученная СЛАУ оказывается плохо обусловленной. Строки матрицы $\mathbf{D} = \mathbf{A}^T \mathbf{B} \mathbf{A}$ могут оказаться почти линейно зависимыми. Простейшим примером такого почти линейно зависимого базиса является система функций x^i , $i = 1, \dots, p$ при больших p . В этом случае желательно использовать ортогональные функциональные базисы, однако такой выбор не всегда возможен и удобен.

Для примера возьмем в качестве базисных функций степенные, обобщенный полином в этом случае будет

$$f(x) = \sum_{j=0}^p u_j x^j.$$

Скалярные произведения на отрезке $[0, 1]$, записанные в интегральной форме (т. е. при $n \rightarrow \infty$), будут иметь вид

$$(\varphi_i, \varphi_j) = \int_0^1 x^i x^j dx = \int_0^1 x^{i+j} dx = \frac{1}{i+j+1}.$$

3.2. Примеры решения задач

1. Для функции $f(x) = \sqrt{x}$ на отрезке $[0, 1]$ построить многочлен $F(x) = u_0 + u_1x$ среднеквадратичного приближения со скалярными произведениями:

$$(\varphi_i, \varphi_j) = \int_0^1 x^i x^j dx, \quad (f, \varphi_i) = \int_0^1 f(x) x^i dx.$$

Решение. Введем базисные функции $\varphi_0(x) = 1$, $\varphi_1(x) = x$ и вычислим скалярные произведения

$$(\varphi_0, \varphi_0) = \int_0^1 1^2 dx = 1, \quad (\varphi_1, \varphi_1) = \int_0^1 x^2 dx = \frac{1}{3},$$

$$(\varphi_0, \varphi_1) = \int_0^1 x dx = \frac{1}{2}, \quad (f, \varphi_0) = \int_0^1 \sqrt{x} dx = \frac{2}{3},$$

$$(f, \varphi_1) = \int_0^1 \sqrt{x} x dx = \frac{2}{5}.$$

Для вычисления коэффициентов получим СЛАУ

$$\begin{aligned} u_0 + \frac{1}{2}u_1 &= \frac{2}{3}, \\ \frac{1}{2}u_0 + \frac{1}{3}u_1 &= \frac{2}{5}, \end{aligned}$$

откуда $u_0 = \frac{4}{15}$, $u_1 = \frac{4}{5}$, $F(x) = \frac{4}{15} + \frac{4}{5}x$.

2. Получить СЛАУ

$$u_{11}x_1 + u_{12}x_2 = f_1,$$

$$u_{21}x_1 + u_{22}x_2 = f_2,$$

если она задана в форме метода наименьших квадратов $\mathbf{A}^* \mathbf{B} \mathbf{A} \mathbf{u} = \mathbf{A}^* \mathbf{B} \mathbf{f}$, где

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad \mathbf{u} = (u_1, u_2)^T, \quad \mathbf{f} = (f_1, f_2, f_3)^T.$$

Решить эту систему для случая $a_{11} = a_{32} = 1$, $a_{21} = a_{12} = 2$, $a_{31} = 0$, $a_{22} = 1$, $f_1 = 1$, $f_2 = 2$, $f_3 = 1$.

Р е ш е н и е. Проведем необходимые вычисления:

$$\begin{pmatrix} a_{11} & a_{21} & a_{31} \\ a_{12} & a_{22} & a_{32} \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} = \begin{pmatrix} a_{11} & a_{21} & a_{31} \\ a_{12} & a_{22} & a_{32} \end{pmatrix} \begin{pmatrix} f_1 \\ f_2 \\ f_3 \end{pmatrix},$$

$$\begin{pmatrix} a_{11}^2 + a_{21}^2 + a_{31}^2 & a_{11}a_{12} + a_{21}a_{22} + a_{31}a_{32} \\ a_{11}a_{12} + a_{21}a_{22} + a_{31}a_{32} & a_{12}^2 + a_{22}^2 + a_{32}^2 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} = \begin{pmatrix} a_{11}f_1 + a_{21}f_2 + a_{31}f_3 \\ a_{12}f_1 + a_{22}f_2 + a_{32}f_3 \end{pmatrix},$$

$$\begin{aligned} (a_{11}^2 + a_{21}^2 + a_{31}^2)u_1 + (a_{11}a_{12} + a_{21}a_{22} + a_{31}a_{32})u_2 &= \\ &= a_{11}f_1 + a_{21}f_2 + a_{31}f_3, \end{aligned}$$

$$\begin{aligned} (a_{11}a_{12} + a_{21}a_{22} + a_{31}a_{32})u_1 + (a_{12}^2 + a_{22}^2 + a_{32}^2)u_2 &= \\ &= a_{12}f_1 + a_{22}f_2 + a_{32}f_3. \end{aligned}$$

3. С помощью метода наименьших квадратов найти коэффициенты полинома второй степени $f(x) = u_0 + u_1x + u_2x^2$, если таблица измерений задана: $\{x_i, f_i\}_{i=0}^n$.

Р е ш е н и е. Переопределенная система уравнений

$$u_0 + u_1x_k + u_2x_k^2 = f_k, \quad k = 0, 1, \dots, n,$$

определяет функционал

$$\Phi(u_0, \dots, u_n) = \sum_{k=0}^n r_k^2 = \sum_{k=0}^n (u_0 + u_1x_k + u_2x_k^2 - f_k)^2.$$

Условия минимума последнего

$$\frac{\partial \Phi}{\partial u_k} = 0.$$

После проведения алгебраических преобразований получим для коэффициентов систему линейных уравнений

$$u_0 + \left(\sum_{k=0}^n x_k \right) u_1 + \left(\sum_{k=0}^n x_k^2 \right) u_2 = \sum_{k=0}^n f_k,$$

$$\left(\sum_{k=0}^n x_k \right) u_0 + \left(\sum_{k=0}^n x_k^2 \right) u_1 + \left(\sum_{k=0}^n x_k^3 \right) u_2 = \sum_{k=0}^n f_k x_k,$$

$$\left(\sum_{k=0}^n x_k^2 \right) u_0 + \left(\sum_{k=0}^n x_k^3 \right) u_1 + \left(\sum_{k=0}^n x_k^4 \right) u_2 = \sum_{k=0}^n f_k x_k^2.$$

Библиографический комментарий к Лекции 3

Развитие метода наименьших квадратов связано с именами К. Ф. Гаусса и А. М. Лежандра. Гаусс предложил метод решения насущной практической задачи о введении минимальных изменений в геодезические данные. Лежандр плодотворно занимался задачами интерполяции и наилучшего приближения функций. Изложение в данной лекции близко к [1]. Некоторые алгоритмы, связанные с реализацией метода наименьших квадратов на matlab, описаны в [18]. Для понимания свойств построения наилучшего приближения в смысле метода наименьших квадратов в зависимости от выбора базиса рекомендуется ознакомиться с соответствующей лабораторной работой из [7]. Для практических занятий по теме следует воспользоваться задачами из сборника [8]. Отметим, что и метод наименьших квадратов (МНК), и среднеквадратичное приближение функций лежат в основе многих методов машинного обучения (см. книгу [19] и цикл лекций [20]).

ЧИСЛЕННОЕ РЕШЕНИЕ НЕЛИНЕЙНЫХ АЛГЕБРАИЧЕСКИХ УРАВНЕНИЙ И СИСТЕМ

Рассматриваются численные методы решения нелинейных уравнений и систем. На основе принципа сжимающих отображений рассматриваются условия сходимости итерационных методов. Доказывается квадратичная сходимость метода Ньютона. Рассматривается задача о динамике простейшего нелинейного дискретного отображения — логистического. Дается понятие о бифуркациях дискретного отображения.

Ключевые слова: итерации, метод простой итерации. Терма о неподвижной точке. Метод Ньютона, метод хорд, дискретные отображения, бифуркации.

4.1. Сжимающие отображения. Итерации. Метод простых итераций (МПИ)

Рассмотрим системы нелинейных алгебраических уравнений, записанные в векторном виде.

Система нелинейных алгебраических уравнений

$$\mathbf{f}(\mathbf{u}) = 0 \quad (4.1)$$

может быть также представлена в равносильном виде

$$\mathbf{u} = \mathbf{F}(\mathbf{u}), \quad (4.2)$$

где $\mathbf{u} \in R^n$. Как правило, для нелинейной системы переход от формы записи (4.1) к равносильному виду (4.2) осуществляется не единственным образом.

Поставим в соответствие системе (4.2) итерационный процесс, определяющий последовательность итераций (последовательных приближений к решению). Он записывается в форме

$$\mathbf{u}^{k+1} = \mathbf{F}(\mathbf{u}^k), \quad \mathbf{u}^0 = \mathbf{a}, \quad k = 0, 1, \dots \quad (4.3)$$

Для дальнейшего изложения потребуется понятие отображения.

Отображением называется закон, по которому каждому элементу $\mathbf{x}$ некоторого множества X однозначно сопоставляется определенный элемент $\mathbf{y}$ множества Y (X может совпадать с Y). Это соответствие между элементами $\mathbf{x} \in X$ и $\mathbf{y} \in Y$ записывается как $\mathbf{y} = \mathbf{f}(\mathbf{x})$ или $\mathbf{f}: \mathbf{x} \rightarrow \mathbf{y}$. Говорят, что отображение $\mathbf{f}$ действует из X в Y ($\mathbf{f}: X \rightarrow Y$). Отображение $\mathbf{f}: X \rightarrow X$ называют преобразованием множества X , это отображение $\mathbf{f}$ переводит множество X в себя. В функциональном анализе и линейной алгебре вместо термина «отображение» часто употребляется термин «оператор»; в случае, если X и Y — числовые множества, употребляется термин «функция».

Определение 4.1. Область $\Omega \in R^n$ называется выпуклой, если наряду с любыми двумя точками $\mathbf{a} \in \Omega$ и $\mathbf{b} \in \Omega$ она включает все точки отрезка $[\mathbf{a}, \mathbf{b}]$, т. е. точки с координатами $\mathbf{u} = \mathbf{a} + t(\mathbf{b} - \mathbf{a})$, где $0 \leq t \leq 1$.

Определение 4.2. Отображение $\mathbf{v} = \mathbf{F}(\mathbf{u})$ называется сжимающим в замкнутой выпуклой области Ω , если существует такое число $0 < q < 1$, что

$$\rho[\mathbf{F}(\mathbf{u}^1), \mathbf{F}(\mathbf{u}^2)] \leq q\rho(\mathbf{u}^1, \mathbf{u}^2)$$

при любых $\mathbf{u}^1, \mathbf{u}^2$, принадлежащих области Ω . Здесь $\rho(\mathbf{u}^1, \mathbf{u}^2)$ — расстояние между элементами. В линейном нормированном пространстве $\rho(\mathbf{u}^1, \mathbf{u}^2) = \|\mathbf{u}^1 - \mathbf{u}^2\|$.

Приведем без доказательства одну из основных теорем функционального анализа.

Теорема 4.1 (принцип сжимающих отображений). Всякое сжимающее отображение имеет в Ω одну и только одну неподвижную точку $\mathbf{u}^* \in \Omega$:

$$\mathbf{u}^* = \mathbf{F}(\mathbf{u}^*).$$

Более подробно о сжимающих отображениях и другие теоремы о неподвижных точках можно найти, например, в [3].

Теорема 4.2 (о сжимающем отображении). Последовательность $\{\mathbf{u}^k\}$, $k = 0, 1, \dots$, элементов n -мерного евклидова пространства, порожденная итерационным процессом

$$\mathbf{u}^{k+1} = \mathbf{F}(\mathbf{u}^k), \quad \mathbf{u}^0 = \mathbf{a},$$

сходится к решению $\mathbf{U}$ системы нелинейных алгебраических уравнений $\mathbf{U} = \mathbf{F}(\mathbf{U})$ или к неподвижной точке отображения, если отображение

$$\mathbf{v} = \mathbf{F}(\mathbf{u})$$

является сжимающим; при этом выполнено

$$\rho(\mathbf{U}, \mathbf{u}^k) \leq \frac{q^k}{1-q} \rho(\mathbf{u}^0, \mathbf{u}^1).$$

Доказательство. По определению сжимающего отображения

$$\begin{aligned} \rho(\mathbf{u}^{k+1}, \mathbf{u}^k) &= \rho[\mathbf{F}(\mathbf{u}^k), \mathbf{F}(\mathbf{u}^{k-1})] \leq \\ &\leq q \rho(\mathbf{u}^k, \mathbf{u}^{k-1}) \leq \dots \leq q^k \rho(\mathbf{u}^0, \mathbf{u}^1) = q^k \rho_0. \end{aligned}$$

В таком случае получим цепочку неравенств при $p > k$:

$$\begin{aligned} \rho(\mathbf{u}^p, \mathbf{u}^k) &\leq \rho(\mathbf{u}^p, \mathbf{u}^{p-1}) + \dots + \rho(\mathbf{u}^{k+1}, \mathbf{u}^k) \leq \\ &\leq q^{p-1} \rho_0 + \dots + q^k \rho_0 \leq q^k \rho_0 \sum_{i=0}^{\infty} q^i = \rho_0 \frac{q^k}{1-q}. \end{aligned}$$

В соответствии с критерием Коши существования предела последовательности, последовательность $\mathbf{u}^k$ стремится к пределу $\mathbf{U}$, поскольку правая часть неравенства стремится к нулю при $k \rightarrow \infty$.

Критерий Коши сходимости числовой последовательности: последовательность $\{\mathbf{u}^k\}$, $k = 0, 1, \dots$, является сходящейся, если для любого положительного числа ε существует номер N такой, что при всех $k > N$ и любых натуральных p расстояние между членами последовательности $\mathbf{u}^k$ и $\mathbf{u}^{k+p}$ меньше ε , т.е. $|\mathbf{u}^k - \mathbf{u}^{k+p}| < \varepsilon$.

Напомним критерий Коши для последовательности элементов метрического пространства: последовательность $\{\mathbf{u}^k\}$, $k = 0, 1, \dots$, является сходящейся, если для любого $\varepsilon > 0$ существует номер N такой, что при всех $k > N$ и любом натуральном p расстояние $\rho(\mathbf{u}^k, \mathbf{u}^{k+p}) < \varepsilon$.

Продолжим доказательство. Переходя в последнем неравенстве к пределу при $p \rightarrow \infty$, получим

$$\rho(\mathbf{U}, \mathbf{u}^k) \leq \rho_0 \frac{q^k}{1-q}.$$

Покажем, что $\mathbf{U}$ есть корень уравнения (4.2):

$$\begin{aligned} \rho[\mathbf{U}, \mathbf{F}(\mathbf{U})] &\leq \rho(\mathbf{U}, \mathbf{u}^{k+1}) + \rho[\mathbf{u}^{k+1}, \mathbf{F}(\mathbf{U})] = \\ &= \rho(\mathbf{U}, \mathbf{u}^{k+1}) + \rho[\mathbf{F}(\mathbf{u}^k), \mathbf{F}(\mathbf{U})] \leq \\ &\leq \rho_0 \frac{q^{k+1}}{1-q} + q\rho(\mathbf{u}^k, \mathbf{U}) \leq \rho_0 \frac{q^{k+1}}{1-q} + q\rho_0 \frac{q^k}{1-q} = 2\rho_0 \frac{q^{k+1}}{1-q}. \end{aligned}$$

Поскольку k выбрано произвольно, а левая часть от k не зависит, то $\rho[\mathbf{U}, \mathbf{F}(\mathbf{U})] = 0$, или $\mathbf{U} = \mathbf{F}(\mathbf{U})$.

Для дифференцируемой функции $\mathbf{F}(\mathbf{u})$ в случае скалярного уравнения имеем $\theta = u^k + t(u^{k+1} - u^k)$,

$$\begin{aligned} |u^{k+1} - u^k| &= |F(u^k) - F(u^{k-1})| \leq \\ &\leq \max_{\Delta} |F'(\theta)| |u^k - u^{k-1}| \leq \dots \leq \left(\max_{\Delta} |F'(\theta)| \right)^k |u^1 - u^0|, \end{aligned}$$

откуда следует условие сходимости итерационного процесса

$$\max |F'(u)| \leq q < 1.$$

Отрезок Δ включает в себя всю последовательность u^k , $u^k \in \Delta$, $k = 0, 1, 2, \dots$

В случае решения системы нелинейных уравнений достаточным условием сходимости итерационного процесса будет $\|\mathbf{F}'(\mathbf{u})\| < 1$, где $\mathbf{F}'(\mathbf{u})$ — матрица Якоби.

Теорема 4.3 (без доказательства). Пусть область $\Omega \in \mathbb{R}^n$ выпуклая, $\mathbf{u} \in \Omega$, а компоненты $F_i(\mathbf{u})$ вектор-функции $\mathbf{F}(\mathbf{u}) = (F_1, \dots, F_N)^T$ имеют равномерно-непрерывные производные первого порядка. Положим, что норма матрицы Якоби

$$\mathbf{I} = \frac{d\mathbf{F}(\mathbf{u})}{d\mathbf{u}} = \begin{pmatrix} \frac{\partial F_1}{\partial u_1} & \dots & \frac{\partial F_1}{\partial u_n} \\ \dots & \dots & \dots \\ \frac{\partial F_n}{\partial u_1} & \dots & \frac{\partial F_n}{\partial u_n} \end{pmatrix}$$

не превосходит некоторого числа $0 \leq q < 1$, т. е. $\|\mathbf{I}\| \leq q < 1$ для всех $\mathbf{u} \in \Omega$.

В этом случае отображение $\mathbf{v} = \mathbf{F}(\mathbf{u})$ является сжимающим в области Ω , т.е. $\rho(\mathbf{F}(\mathbf{u}^1), \mathbf{F}(\mathbf{u}^2)) \leq q\rho(\mathbf{u}^1, \mathbf{u}^2)$, или $\|\mathbf{F}(\mathbf{u}^1) - \mathbf{F}(\mathbf{u}^2)\| \leq q\|\mathbf{u}^1 - \mathbf{u}^2\|$.

Геометрическая интерпретация метода простой итерации для скалярного случая $u^{k+1} = F(u^k)$ приведена на рис. 5.1. Алгоритм метода простых итераций таков.

1. Локализуем корень, приближенно определяем, на каком отрезке он находится. Вопрос локализации корня не всегда решается




Рис. 4.1. Геометрическая интерпретация метода простых итераций

алгоритмически; это, скорее, вопрос искусства вычислителя, хотя во многих случаях локализовать корень достаточно легко.

2. Выбираем точку u^0 на оси Ou .

3. Вычисляем $F(u^0)$.

4. Определяем точку u^1 по значению $F(u^0)$:

4.1. Пересечение горизонтальной прямой AA' с прямой $v = u$ есть точка C ($OA = v^1$, $AC = u^1$).

4.2. Очевидно, что горизонтальная координата точки C и есть u^1 (так как $F(u^0) = u^1$).

4.3. Опустим перпендикуляр из C на u . Поскольку $OA = u^1$, то u^1 — значение на первой итерации.

5. Аналогично строим точки u^2, u^3 . Получившаяся диаграмма носит название *лестница* (или *лесенка*) *Ламерея*.

Метод релаксации. Без ограничения общности рассмотрим скалярный случай. Положим $F(u) = u + \tau f(u)$ и построим итерационный процесс $u^{k+1} = u^k + \tau f(u^k)$, $u^0 = a$.

Тогда $F'(u) = 1 + \tau f'(u)$ и τ выбирается из условия $|F'(u)| < 1$, причем чем меньше значение $|F'(u)|$, тем быстрее будет сходиться итерационный процесс. В частности, если положить $F'(u) = 0$, то

$\tau = -[f'(u)]^{-1}$, а формулы итерационного процесса будут $u^{k+1} = u^k - [f'(u^k)]^{-1} f(u^k)$, $u^0 = a$.

4.2. Метод Ньютона

Как и выше, необходимо найти решение уравнения $f(u) = 0$. Пусть u^k есть k -е приближение решения (k -я итерация). Следующее приближение ищем в виде $u^{k+1} = u^k + \Delta u^k$, разложив функцию $f(u)$ в ряд Тейлора с точностью до членов первого порядка:

$$f(u^k + \Delta u^k) = f(u^k) + f'_u(u^k) \Delta u^k + O(\Delta^2 u^k).$$

Пренебрегая членами $O(\Delta^2 u^k)$, получим линеаризованное уравнение для определения Δu^k :

$$\begin{aligned} f(u^k) + f'_u(u^k) \Delta u^k &= 0, \\ u^{k+1} - u^k &= \Delta u^k = -f_u^{-1}(u^k) f(u^k), \\ u^{k+1} &= u^k - f_u^{-1}(u^k) f(u^k), \quad u^0 = a. \end{aligned}$$

Это уже знакомая формула, полученная в результате оптимизации релаксационного варианта метода простой итерации.

Для системы уравнений матрица Якоби $\mathbf{f}'_u(\mathbf{u}_k)$ будет

$$\mathbf{I} = \left\{ \frac{\partial f_i}{\partial u_j} \right\} = \begin{pmatrix} \frac{\partial f_1}{\partial u_1} & \cdots & \frac{\partial f_1}{\partial u_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial u_1} & \cdots & \frac{\partial f_n}{\partial u_n} \end{pmatrix},$$

а метод Ньютона выглядит следующим образом:

$$\begin{aligned} f_1^{k+1} &= f_1^k + \left(\frac{\partial f_1}{\partial u_1} \right)^k \Delta u_1^k + \dots + \left(\frac{\partial f_1}{\partial u_n} \right)^k \Delta u_n^k, \\ &\dots\dots\dots \\ f_n^{k+1} &= f_n^k + \left(\frac{\partial f_n}{\partial u_1} \right)^k \Delta u_1^k + \dots + \left(\frac{\partial f_n}{\partial u_n} \right)^k \Delta u_n^k, \end{aligned}$$

где $f_i = f_i(u_1, \dots, u_n)$. Приравнявая к нулю правые части полученных уравнений, приходим к СЛАУ вида $\mathbf{I}(\Delta \mathbf{u}) = -\mathbf{f}$, где

$\Delta \mathbf{u} = (\Delta u_1, \Delta u_2, \dots, \Delta u_n)^T$, $\mathbf{f} = (f_1, f_2, \dots, f_n)^T$, $\Delta \mathbf{u} \in R^n$, $\mathbf{f} \in R^n$,
 $\Delta u_i = u_i^{k+1} - u_i^k$, $i = 1, \dots, n$, $k = 0, 1, \dots$

Геометрический смысл метода Ньютона в одномерном случае проиллюстрирован на рис. 4.2. Заменим $f(u)$ в точках u^k — каж-




Рис. 4.2. Геометрическая интерпретация метода Ньютона в одномерном случае

дом приближении к корню — касательными. За следующее приближение по методу Ньютона примем значение u точки пересечения касательной с осью абсцисс. Метод Ньютона называют также методом линеаризации или методом касательных.

Теорема о квадратичной сходимости метода Ньютона [2]. Сформулируем и докажем теорему для одномерного (скалярного) случая. Аналогичная теорема будет справедлива и для систем нелинейных уравнений.

Если невязка следующего приближения пропорциональна квадрату невязки предыдущего, то говорят о квадратичной сходимости метода.

Теорема 4.4. Пусть на конечном отрезке $[a; b]$ выполнено $f(a)f(b) < 0$, существуют первые две ограниченные производные $f(u)$ и, кроме того, существует $[f'_u(u)]^{-1}$; причем имеют место оценки $|f''_{uu}| \leq C_2$, $|[f'_u(u)]^{-1}| \leq C_1$ (отображение $f(u)$ равномерно невырождено), а начальное приближение выбирается из условия

$$C_1^2 C_2 |f(u^0)| \leq q < 1.$$

Тогда метод Ньютона сходится к корню уравнения на $[a; b]$ с квадратичной скоростью сходимости.

До к а з а т е л ь с т в о. В силу условий теоремы у $f(x)$ на $[a; b]$ имеется единственный корень (функция непрерывна, на концах отрезка приобретает значения разных знаков и не имеет экстремумов на $[a; b]$). Разложим $f(u^{k+1})$ в ряд Тейлора в окрестности $f(u^k)$, ограничившись квадратичными членами разложения:

$$f(u^{k+1}) = f(u^k) + f'_u(u^k) \Delta u^k + O(\Delta^2 u^k).$$

Здесь введено обозначение $\Delta u^k = u^{k+1} - u^k$. Переходя к абсолютной величине и учитывая, что для метода Ньютона $f(u^k) + f'_u(u^k) \Delta u^k = 0$, или $\Delta u^k = -[f'_u(u)]^{-1} f(u^k)$, получим

$$\begin{aligned} |f(u^{k+1})| &= O(\Delta^2 u^k) \leq C_2 \Delta^2 u^k = \\ &= C_2 [f'_u(u^k)]^{-1} f(u^k)]^2 \leq C_2 C_1^2 |f(u^k)|^2, \end{aligned}$$

так как $|[f'_u(u)]^{-1}| < C_1$.

Введем в рассмотрение *невязку* $r^k = f(u^k)$, получим $|r^{k+1}| \leq C(r^k)^2$, где $C = C_2 C_1^2$.

Можно выписать цепочку неравенств

$$|\mathbf{r}^1| \leq C(r^0)^2, \quad |\mathbf{r}^2| \leq C(r^1)^2 \leq C^3(r^0)^4, \quad |\mathbf{r}^3| \leq C(r^2)^2 \leq C^7(r^0)^8$$

и т. д., в результате для невязки на k -й итерации получается выражение $|\mathbf{r}^k| \leq C^{-1}(Cr_0)^{2^k}$.

Для сходимости итерационного процесса метода Ньютона достаточно, чтобы было выполнено условие, следующее из последнего неравенства: $C|r^0| = C|f(u^0)| \leq q < 1$. Отсюда следуют ограничения на начальное приближение, в частности $|f(u^0)| \leq 1/C$. $\square$

З а м е ч а н и е. Несложно показать, что погрешность, определяемая как $\varepsilon^k = \rho(\mathbf{u}^k - \mathbf{U})$, или, в скалярном случае, $\varepsilon^k = |u^k - U|$, убывает квадратично. Для этого разложим $f(u^{k+1})$ в окрестности u^k в ряд Тейлора до второго члена, ограничиваясь квадратичным членом:

$$f(u^{k+1}) \approx f(u^k) + f'(u^k)(u^{k+1} - u^k) + \frac{f''}{2}(u^{k+1} - u^k)^2.$$

Так как в методе Ньютона приближения находятся достаточно близко к корню уравнения и $u^{k+1} \approx U$, положим

$$0 = f(U) \approx f(u_k) + f'(u^k)(U - u^k) + \frac{f''}{2}(U - u^k)^2.$$

Разделив полученное равенство на $f'_u(u^k)$, приходим к оценке

$$U - \left[u^k - \frac{f(u^k)}{f'_u(u^k)} \right] + \frac{f''_u(\theta)}{2f'_u(u^k)}(U - u^k)^2 = 0,$$

откуда следует

$$\left| U - \left(u^k - \frac{f(u^k)}{f'_u(u^k)} \right) \right| \leq \left| \frac{\max |f''_u(\theta)|}{2f'_u(u^k)} \right| |U - u^k|^2, \quad u^k \in \Delta, \quad k = 0, 1, \dots$$

Левая часть последнего неравенства по формуле Ньютона равна $\epsilon^{k+1} = |U - u^{k+1}|$. В таком случае $\epsilon^{k+1} \leq \tilde{C}(\epsilon^k)^2$, где

$$\tilde{C} = \frac{\max_{\Delta} |f''(\theta)|}{2|f'(u^k)|}.$$

Итерационные процессы, имеющие третий и четвертый порядок сходимости, представляются формулами

$$u^{k+1} = u^k - \frac{f_k}{f'_k} - \frac{f''_k \cdot f_k^2}{2(f'_k)^3},$$

$$u^{k+1} = u^k - \frac{f_k}{f'_k} - \frac{f''_k f_k^2}{2(f'_k)^3} - \frac{(f''_k)^2 f_k^3}{2(f'_k)^5} + \frac{f_k^{(3)} f_k^3}{6(f'_k)^7},$$

где $f_k = f(u^k)$.

Отметим, что итерационные методы высших порядков используются достаточно редко вследствие повышенных требований к выбору начального приближения, гладкости функций и необходимости вычисления ее производных и обратных к ним величин.

Иногда для численного решения нелинейных алгебраических систем уравнений, чтобы не вычислять на каждой итерации обратную матрицу, используют упрощенный метод Ньютона

$$\mathbf{u}^{k+1} = \mathbf{u}^k - [\mathbf{f}'_{\mathbf{u}}(\mathbf{u}^0)]^{-1} \mathbf{f}(\mathbf{u}^k), \quad \mathbf{u}^0 = \mathbf{a}.$$

Этот метод оказывается приемлемым, поскольку начальное приближение в методе Ньютона обычно выбирается достаточно близким к корню уравнения.

Методом секущих (или разностным методом Ньютона) называется итерационный метод, в котором вместо производной вычисляется разностное выражение

$$f'(u^k) \approx \frac{f(u^k) - f(u^{k-1})}{\tau_k},$$

откуда

$$u^{k+1} = u^k - \frac{f(u^k)\tau_k}{f(u^k) - f(u^{k-1})}, \quad \tau_k = u^k - u^{k-1}.$$

4.3. О вариационных подходах к решению нелинейных систем уравнений

Рассмотрим систему нелинейных уравнений $f(u, v) = 0, g(u, v) = 0, \{u, v\} \in \Omega$.

Рассмотрим функционал $\Phi(u, v) = f^2(u, v) + g^2(u, v)$.

Так как Φ неотрицателен, то найдется точка $\{\bar{u}, \bar{v}\}$ такая, что $\{\bar{u}, \bar{v}\} = \arg \min_{\{u, v\} \in \Omega} \Phi(u, v)$, но $\min \Phi(u, v)$, очевидно, достигается

при $f(u, v) = 0, g(u, v) = 0$, т.е. на решении исходной системы уравнений.

Построим итерационный процесс, соответствующий методу *градиентного спуска*,

$$\begin{pmatrix} u^{k+1} \\ v^{k+1} \end{pmatrix} = \begin{pmatrix} u^k \\ v^k \end{pmatrix} - \tau_k \begin{pmatrix} \Phi'_u(u^k, v^k) \\ \Phi'_v(u^k, v^k) \end{pmatrix},$$

где τ_k — параметр, который выбирается, например, из условия минимальности $\Phi(u^{k+1}, v^{k+1})$ в данном направлении (метод наискорейшего спуска), $-\text{grad } \Phi(u^k, v^k) = -\begin{pmatrix} \Phi'_u(u^k, v^k) \\ \Phi'_v(u^k, v^k) \end{pmatrix}$ — вектор, определяющий направление минимизации. На каждом шаге итераций решается задача минимизации Φ по одному аргументу.

4.4. Метод Чебышёва построения итерационных процессов высшего порядка

Предположим, что существует функция $g(u)$, обратная к $f(u)$. При этом $u = g[f(u)]$, $U = g(0)$. Пусть, кроме того, $f(u)$ непре-

рывна и имеет необходимое число непрерывных производных на отрезке, внутри которого лежат все члены последовательности $\{u^k\}$, $k = 0, 1, \dots$. Обратная функция имеет такое же количество непрерывных производных, как и $f(u)$. Разложим функцию $g(f[v]) = g(h)$ в ряд Тейлора в окрестности корня — точки $w = f(u)$:

$$g(h) \approx g(w) + \sum_{i=1}^n \frac{g^{(i)}(w)}{i!} (h - w)^i.$$

Тогда, учитывая, что $u = g[f(u)]$, $w = f(u)$, $h = f(v)$, получим

$$g(0) = U \approx u + \sum_{i=1}^n \frac{g^{(i)}[f(u)]}{i!} [-f(u)]^i + \dots$$

Можно показать, что итерационный метод

$$u^{k+1} = u^k + \sum_{i=1}^n (-1)^i \frac{g^{(i)}[f(u^k)]}{i!} [f(u^k)]^i, \quad u^0 = a$$

имеет порядок сходимости $n + 1$. Для вычисления производных обратной функции $u = g[f(u)]$ воспользуемся правилом дифференцирования сложной функции:

$$\begin{aligned} 1 &= g^{(1)}[f(u)] \cdot f^{(1)}(u), \\ 0 &= g^{(2)}[f(u)] \cdot [f^{(1)}(u)]^2 + g^{(1)}[f(u)] \cdot f_{(u)}^{(2)}, \\ 0 &= g^{(3)}[f(u)] \cdot [f_{(u)}^{(1)}]^3 + 3g^{(2)}[f(u)] \cdot f_{(u)}^{(2)} \cdot f_{(u)}^{(1)} + g^{(1)}[f(u)] \cdot f_{(u)}^{(3)}, \\ &\dots \end{aligned}$$

4.5*. Разностные отображения в нелинейной динамике

Рассмотрим последовательность чисел $u^{k+1} \in R$ (R — множество вещественных чисел), каждый член которой связан с предыдущим рекуррентным соотношением

$$u^{k+1} = f(u^k, u^{k-1}, \dots, u^1, k), \quad (4.4)$$

где $k \in N$ (N — множество натуральных чисел). Соотношения (4.4) называются разностными отображениями (уравнениями) с дискретным аргументом.

Такие уравнения появляются при моделировании процессов, в которых величина u рассматривается через определенные промежутки времени. Например, еще в середине XIX века Ферхюльст для описания динамики популяционной системы предложил измерять ежегодно численность особей u^k , где k — номер года. Относительная численность u^{k+1} полагалась пропорциональной численности в k -й год, однако она начинает убывать, когда животных становится много (u^k сравнимо с 1):

$$u^{k+1} = f(u^k), \quad (4.5)$$

где

$$f(u^k) = \lambda u^k (1 - u^k), \quad u^0 = a. \quad (4.6)$$

Другой пример из экономической области — задача о банковских сбережениях. Пусть u^0 — денежный вклад, растущий в соответствии с постоянным процентом δ по закону:

$$u^{k+1} = (1 + \delta)u^k = \dots = (1 + \delta)^k u^0.$$

Пусть далее законодательный орган, желая воспрепятствовать такому обогащению вкладчика, издает закон о том, чтобы процент убывал пропорционально u^k , т. е.

$$\delta^k = \delta^0 \left(1 - \frac{u^k}{u_{\max}}\right).$$

Тогда счет в банке изменился бы по закону

$$u^{k+1} = \left[1 + \delta_0 \left(1 - \frac{u^k}{u_{\max}}\right)\right] u^k, \quad (4.7)$$

т. е. в соответствии с моделью (4.6).

Так как $u^k \in [0; 1]$, то $\lambda \in [0; 4]$. Отображение (4.6) называется логистическим. К нему можно также прийти, применив простейший из численных методов решения обыкновенных дифференциальных уравнений — явный метод Эйлера (см. Лекцию 8) для решения дифференциального уравнения динамики популяции (уравнения Ферхюльста)

$$\dot{u} = \lambda u(1 - u), \quad u(0) = a, \quad (4.8)$$

где u — численность популяции. Вводя шаг по времени, получим разностный аналог уравнения (4.8):

$$\frac{u^{k+1} - u^k}{\tau} = \lambda u^k (1 - u^k), \quad u^0 = a, \quad (4.9)$$

откуда получаем

$$\begin{aligned} u^{k+1} &= \alpha u^k - \beta (u^k)^2, \\ \alpha &= \lambda \tau + 1, \quad \beta = \lambda \tau. \end{aligned} \quad (4.10)$$

И отображение (4.7), и отображение (4.10) легко приводятся к виду (4.6). Достаточно произвести очевидную замену переменных. Для (4.10) эта замена будет $\mu = \alpha$, $z^k = \frac{\alpha}{\beta} u^k$. Как двумерное обобщение логистического отображения можно рассматривать отображение Хенона

$$u^{k+1} = 1 - \alpha (u^k)^2 + y^k, \quad y^{k+1} = \beta u^k, \quad |\beta| \leq 1, \quad (4.11)$$

или

$$u^{k+1} = 1 - \alpha (u^k)^2 + \beta u^{k-1}. \quad (4.12)$$

К известным двумерным дискретным моделям относится также отображение Чирикова, предложенное для моделирования поведения незатухающего ротатора, возбуждаемого внешними толчками:

$$u^{k+1} = u^k - \alpha \sin y^k, \quad y^{k+1} = y^k + u^{k+1}. \quad (4.13)$$

Рассмотрим подробнее свойства отображения:

$$u^{k+1} = \lambda u^k (1 - u^k), \quad u^0 = a.$$

Заметим, что $f(0) = f(1) = 0$ и $\max f(u) = f(0.5) = \lambda/4$, то при $0 < \lambda < 4$ интервал $X = [0; 1]$ отображается в себя, $u \in X$.

Введем обозначения

$$f^2 = f(f(u)), \quad f^3 = f(f(f(u))), \quad f^k = \underbrace{f(f \dots f(u) \dots)}_k.$$

Последовательность $f, f^2, \dots, f^k, \dots$ называется траекторией отображения и обозначается $\{f^k(u_0)\}_{k=0}^{\infty}$.

Определение. Точка $a \in X$ (X — множество, включающее в себя все значения отображения (4.4)) называется предельной точкой траектории $\{f^k(u_0)\}_{k=0}^{\infty}$, если существует последовательность $k_1 < k_2 < \dots < k_n \xrightarrow{n \rightarrow \infty} \infty$ такая, что $f^{k_n} \rightarrow a$, $n = 1, 2, \dots$

Рассмотрим вначале случай $0 < \lambda < 1$. Случай $\lambda = 0$ тривиальный, поэтому не рассматривается. На $X = [0; 1]$ существует толь-

ко одна предельная (или неподвижная) точка $u^0 = 0$. Любая последовательность $\{f^k(u_0)\}_{k=0}^{\infty}$ сходится к предельной точке рассматриваемого отображения $\bar{u}^0 = 0$. Если рассматривается популяционная модель, то это означает, что рассматриваемая популяция не может выжить.

Из теоремы о сжимающем отображении следует, что последовательность $\{u^k\}_{n=0}^{\infty}$ сходится к своей предельной точке, если $|f'_u| \leq 1$.

В этом случае точка называется притягивающей. При выполнении условия $|f'_u| > 1$ неподвижная точка называется отталкивающей.

Графическое изображение траектории (лесенка Ламерея) представлено на рис. 4.3.

Теперь рассмотрим случай $1 < \lambda < 3$.

В случае, когда $\lambda > 1$ — неподвижная точка, $\bar{u}^0 = 0$ становится отталкивающей, поскольку $|f'(0)| > 1$, а на отрезке $[0, 1]$ появляется другая неподвижная точка $\bar{u}^1 = 1 - \lambda^{-1}$.

Производная для рассматриваемого отображения $|f'(\bar{u}^1)| = |2 - \lambda| < 1$. Точка $\bar{u}^1$ при $1 < \lambda \leq 3$ является притягивающей.




Рис. 4.3. Притягивающая точка 0




Рис. 4.4. Притягивающая неподвижная точка

Отметим, что при $1 < \lambda \leq 2$ производная $f'(\bar{u}^1) > 0$, и траектория $\{f^k(u_0)\}_{k=1}^{\infty}$ стремится монотонно к $\bar{u}^1$ (рис. 4.4); при $2 < \lambda \leq 3$

производная $f'(\bar{u}^1) < 0$, и траектория приближается к $\bar{u}^1$ немонотонно, поочередно принимая значения то меньше, то больше $\bar{u}^1$.

При $\lambda = 3$ точка $\bar{u}^1$ остается притягивающей, но значение производной в этой точке является предельным: $|f'(\bar{u}_1)| = 1$.

При значениях параметра логистического отображения $\lambda = 1$ и $\lambda = 3$ неподвижная точка этого отображения теряет устойчивость и появляется либо другая устойчивая неподвижная точка, как это произошло в первом случае, либо притягивающий цикл; определение цикла будет дано ниже. Качественное изменение поведения решения (траектории отображения) при изменении параметра называется *бифуркацией*.

Пусть теперь $3 < \lambda \leq 1 + \sqrt{6}$. Как уже отмечалось, при значении параметра $\lambda = 3$ происходит *бифуркация*: неподвижная точка $\bar{u}^2 = 1 - \lambda^{-1}$ из притягивающей превращается в отталкивающую: $|f'(u)| > 1$ при $\lambda > 3$. После того как точка стала отталкивающей, рассмотрим корни u^3, u^4 уравнения $f^2(u) = u$, или $\lambda^2 u^2 - \lambda(\lambda + 1)u + (\lambda + 1) = 0$.

Заметим, что если $\bar{u}^1$ — предельная точка отображения $f(u) = u$, то она является также и предельной точкой отображения $f^2(u) = u$. Действительно, $f^2(\bar{u}^1) = f(f(\bar{u}^1)) = f(\bar{u}^1) = \bar{u}^1$, где $\bar{u}^1$ — любая предельная точка рассматриваемого отображения, отличная от корней уравнения $f^2(u) = u$. Тогда, зная корни уравнения $f^2(u) = u$, точки $\bar{u}^3, \bar{u}^4$ можно легко найти как корни квадратного уравнения; они есть

$$\bar{u}^{3,4} = \frac{(\lambda + 1) \pm \sqrt{2\lambda - 3\lambda^2 - 3}}{2\lambda}.$$

Эти корни связаны равенствами

$$f(\bar{u}^3) = \bar{u}^4, \quad f(\bar{u}^4) = \bar{u}^3.$$

В данном случае говорят, что отображение имеет *цикл периода 2*, который будем обозначать P_2 . Его наличие, например, в популяционной модели говорит об изменении численности особей с периодом в 2 единицы времени. Траектория для случая такого цикла изображена на рис. 4.5. Можно считать, что неподвижная (предельная) точка отображения есть цикл периода 1.




Рис. 4.5. Цикл периода 2 в логистическом отображении

Переход от цикла P_1 (предельная точка логистического отображения) к циклу P_2 называют *бифуркацией рождения цикла (удвоения периода)*.

Определение. Точка $a \in X$ называется *периодической периода m* , если $f^m(a) = a$ и $f^i(a) \neq a$ при $0 < i < m$.

Отметим, что каковы бы ни были попарно различные точки $\bar{u}^1, \bar{u}^2, \dots, \bar{u}^m$, если положить $f(\bar{u}^i) = \bar{u}^{i+1}$, $i = 1, 2, \dots, m-1$, и $f(\bar{u}^m) = \bar{u}^1$, то рассматриваемое отображение будет иметь периодическую траекторию периода m : $\bar{u}^1, \bar{u}^2, \dots, \bar{u}^m, \bar{u}^1, \bar{u}^2, \dots, \bar{u}^m, \dots$

Если к тому же $f(u)$ имеет первую производную, то в окрестности каждой из точек u_i выполнено

$$|f(u) - f(\bar{u}^i)| \approx |f'(\bar{u}^i)| \cdot |u - \bar{u}^i|,$$

или

$$|f(u) - \bar{u}^{i+1}| \approx |f'(\bar{u}^i)| \cdot |u - \bar{u}^i|.$$

Будем рассматривать $f^m(u)$ как сложную функцию. Пользуясь правилом дифференцирования сложной функции, получим

$$|f^m(u) - \bar{u}^{i+1}| \approx \left| \prod_{k=1}^m f'(\bar{u}^k) \right| \cdot |u - \bar{u}^i|.$$

Если $\left| \prod_{k=1}^m f'(\bar{u}^k) \right| < 1$, то траектория $\{f_k(u^0)\}_{k=0}^\infty$ приближается к циклу $\{\bar{u}^1, \dots, \bar{u}^m\}$, или $\{u^k\}_{k=1}^m$. Такой цикл называется *притяги-*

вающим циклом, а величина $\left| \prod_{k=1}^m f'(\bar{u}^k) \right|$ — мультипликатором цикла. Цикл может быть как притягивающим, так и отталкивающим.

Определение 4.3. Цикл $P_m = \{\bar{u}^1, \dots, \bar{u}^m\}$ отображения $f: X \rightarrow X$, переводящего множество X в себя, называется притягивающим, если существует число k_0 такое, что для любого $k > k_0$ траектория $\{f^k(u^0)\}_{k=0}^\infty$ распадается на m последовательностей, каждая из которых сходится к точкам $\bar{u}^1, \dots, \bar{u}^m$ соответственно.

Достаточным условием существования притягивающего (отталкивающего) цикла является выполнение неравенства $\mu(P_m) < 1$, где $\mu(P_m) = \left| \prod_{k=1}^m f'(u^k) \right|$, $u \in P_m$ — мультипликатор цикла.

Отметим интересные свойства функции $f^2(u)$, в частности, ее график пересекается с прямой $y = u$ не только в неподвижных точках рассматриваемого отображения, u_1, u_2 , но и в точках цикла P_2 . Таким образом, можно сказать, что бифуркация рождения




Рис. 4.6. Вторая степень отображения и появление цикла периода 2

цикла обусловлена потерей устойчивости одной предельной точки и появлением двух устойчивых предельных точек отображения $f^2(u)$. На рис. 4.6а, б показано поведение функции $f^2(u)$ при разных значениях параметра λ ($\lambda = 2.8$; $\lambda = 1 + \sqrt{5}$).

При увеличении λ у отображения появляются новые неподвижные точки. Мультипликатор цикла P_2 вычисляется следующим

образом:

$$\mu(\bar{u}^3, \bar{u}^4) = f'(\bar{u}^3)f'(\bar{u}^4) = \lambda^2(1 - 2\bar{u}^3)(1 - 2\bar{u}^4) = 4 + 2\lambda + \lambda^2.$$

Очевидно, что $|\mu(\bar{u}^3, \bar{u}^4)| < 1$, если $3 < \lambda < 1 + \sqrt{6}$, тогда цикл P_2 — притягивающий. Траектория $\{f_k(u^0)\}_{k=0}^\infty$ притягивается циклом $\{\bar{u}^3, \bar{u}^4\}$, и подпоследовательность $\{f^{2k}(u^0)\}_{k=0}^\infty$ сходится к одной точке цикла, а $\{f^{2k+1}(u^0)\}_{k=0}^\infty$ — к другой.

Знак мультипликатора дает информацию о характере приближения траектории к циклу. В частности, если $3 < \lambda < 1 + \sqrt{5}$, то подпоследовательности $\{f^{2k}(u^0)\}_{k=0}^\infty$ и $\{f^{2k+1}(u^0)\}_{k=0}^\infty$, начиная с некоторого u , являются монотонными, одна из них возрастающая, а другая — убывающая, что зависит от знаков $f'(\bar{u}^3)$ и $f'(\bar{u}^4)$.

При $1 + \sqrt{5} < \lambda \leq 1 + \sqrt{6}$ значение мультипликатора $\mu < 0$, и подпоследовательности $\{f^{2k}(\bar{u}^0)\}_{k=0}^\infty$ и $\{f^{2k+1}(\bar{u}^0)\}_{k=0}^\infty$ приближаются к точкам $\{\bar{u}^3, \bar{u}^4\}$ немонотонно.

Рассмотрим теперь случай $1 + \sqrt{6} \leq \lambda < 3.54\dots$ При $\lambda = 1 + \sqrt{6}$ происходит вторая бифуркация удвоения периода.

Цикл $\{\bar{u}^3, \bar{u}^4\}$ из притягивающего превращается в отталкивающий, $|\mu(\bar{u}^3, \bar{u}^4)| > 1$ при $\lambda > 1 + \sqrt{6}$. Появляется новый притягивающий цикл P_4 :

$$\bar{u}^6 = f(\bar{u}^5), \quad \bar{u}^7 = f(\bar{u}^6), \quad \bar{u}^8 = f(\bar{u}^7), \quad \bar{u}^5 = f(\bar{u}^8).$$

Для популяционной динамики это означает, что численность особей колеблется с периодом 4 единицы времени. Соответствующий график приведен на рис. 4.7.

При $\lambda \approx 3.54$ цикл P_4 периода 4 становится отталкивающим, $|\mu(\bar{u}^5, \dots, \bar{u}^8)| > 1$; при этом появляются притягивающий цикл P_8 периода 8. Дальнейшее увеличение параметра λ будет приводить к появлению циклов P_{16} , P_{32} и т. д. Происходит *каскад бифуркаций удвоения периода*.

Заметим, что рассмотренный простой процесс имеет сложное поведение. Наблюдается каскад бифуркаций при увеличении величины λ ; кроме того, все циклы, которые при этом встречаются, имеют период 2^p . Эта важнейшая закономерность, которая прослеживается не только в расчетах, но и в природе! Рассмотренные бифуркации при увеличении λ можно наглядно представить

на бифуркационной диаграмме (рис. 4.8). Диаграмма получается, если обозначить через Λ_1, Λ_2 те значения λ , в которых происходят бифуркации на горизонтальные оси, а через $\lambda_1, \lambda_2, \dots$ — при кото-




Рис. 4.7. Цикл периода 4 в логистическом отображении




Рис. 4.8. К построению бифуркационной диаграммы

рых $u = 0.5$ является элементом циклов $P_2, P_4, \dots$; по вертикальной оси откладываются значения предельных точек отображения. Обозначим за $d_1, d_2, \dots$ величины, равные расстоянию между $u = 0.5$ и ближайшим к нему элементом цикла P_2 при $\lambda = \lambda_k$. Численный эксперимент показал, что Λ_k и λ_k при достаточно боль-

ших k ведут себя, как члены геометрической прогрессии со знаменателем $\delta = 4.66920\dots$, т. е.

$$\lim_{k \rightarrow \infty} \frac{\Lambda_{k+1} - \Lambda_k}{\Lambda_{k+2} - \Lambda_{k+1}} = \delta.$$

Отношение d_k/d_{k+1} имеет предел, равный $\alpha = 2.50290\dots$

Эти закономерности были замечены американским математиком Фейгенбаумом.

При дальнейшем увеличении λ последовательность $\{u_k\}_{k=0}^{\infty}$ приобретает хаотический характер ($\lambda = \lambda_{\infty} \approx 3.569$), что видно на рис. 4.9.

Примечательно, что каскады Фейгенбаума имеют фрактальный характер (т. е. сохраняют подобие при изменении масштабов, рис. 4.10а, б).

Изучение графиков функций $f^2(u)$ и $f^1(u)$ показывает, что их фрагменты вблизи максимумов близки друг к другу, более того,




Рис. 4.9. Бифуркационная диаграмма логистического отображения — каскад Фейгенбаума

они отличаются лишь масштабами. Оказывается, что такое же подобие имеет место для функции f^{2^k} , $n > 1$ при $\lambda = \lambda_k$ и выполняется тем точнее, чем больше n . Если положить $u' = u - 1/12$ (в дальнейшем штрих будем опускать) и считать α коэффициентом растяжения вдоль осей, то для некой симметричной функции $g(u)$, определенной на отрезке $[-1; 1]$, можно получить следующее функциональное уравнение:

$$g(u) = -\alpha g\left[g\left(-\frac{u}{\alpha}\right)\right],$$

которое универсально определяет α :

$$g(0) = -\alpha g(g(0)).$$

Вблизи максимума $g(x)$ должна быть близка к квадратичной параболе, причем $g(0) = 1$. В *теории универсальности* показывается, что эта функция вычисляется с помощью ряда

$$g(u) = 1 - 1.52763u^2 + 0.104815u^4 - 0.0267057u^6 + \dots$$




Рис. 4.10 Два увеличенных фрагмента каскада Фейгенбаума




Рис. 4.11 Первые три итерации при установлении цикла периода 3 (а); при последовательных итерациях при $k = 100, 101, 102$ (б)

Пусть теперь $\lambda = 3.83$. В этом случае из хаотической области появляется устойчивый цикл P_3 (на рис. 4.11а, б представлены циклы в разные моменты времени).

Циклу на рис. 4.11 соответствует самое большое окно устойчивых циклов $P_{3.2^k}$. Чередование хаотических и регулярных зон называется перемежаемостью. Возможно, нечто подобное наблюдается в гидродинамических потоках, где ламинарные зоны чередуются с турбулентными.

4.6. Примеры решения задач

1. Методами простых итераций и Ньютона решить уравнение

$$x^2 - e^{-x} = 0, \quad x_0 \in [0.5; 1].$$

Решение. Метод простых итераций будет $x^{k+1} = e^{x^k/2}$, $x^0 = 0.75$, $F(x) = e^{-x^k/2}$, $|F'_x(x)| < 1$ при $x \in [0.5; 1]$.

Приведем таблицу приближений до точности $|x_5 - x_4| < 10^{-4}$:

k	0	1	2	3	4	5
x^k	0.75	0.6873	0.7091	0.7015	0.7042	0.7032

Метод Ньютона запишется как

$$x^{k+1} = x^k - \frac{(x^k)^2 - e^{-x^k}}{2x^k - e^{-x^k}}, \quad x^0 = 1.$$

Результаты расчетов:

k	0	1	2	3
x^k	1	0.7330	0.7038	0.7035

2. Методом простых итераций найти все корни уравнения

$$x^3 + 3x^2 - 1 = 0.$$

Решение. Все корни данного уравнения лежат на отрезках $[-3; -2]$, $[-1; 0]$, $[0; 1]$.

Построим итерационный процесс для вычисления первого корня, лежащего на отрезке $[-3; -2]$:

$$x^{k+1} = (x^k)^{-2} - 3, \quad F(x) = x^{-2} - 3, \quad |F'_x(x)| = |-2x^{-3}| \leq \frac{1}{4} < 1,$$

т. е. для начального приближения $x^0 \in [-3; -2]$ метод простых итераций сходится.

Для вычисления двух оставшихся корней, лежащих на отрезках $[-1; 0]$ и $[0; 1]$, построим итерационный метод

$$x^{k+1} = \pm(x^k + 3)^{-1/2}, \quad F(x) = \pm(x^k + 3)^{-1/2}.$$

Поскольку для рассматриваемых отрезков

$$|F'_x(x)| = \left| 2(x+3)^{-1/2} \right|^3 < 1,$$

то этот итерационный процесс сходится к корням рассматриваемого уравнения.

3. Построить формулы метода простых итераций и итерационного метода Ньютона для системы уравнений

$$f(x, y) = x + 3 \lg x - y^2 = 0,$$

$$g(x, y) = 2x^2 - xy - 5x + 1 = 0.$$

Решение. Определим графически, где лежат корни данной системы. Графики функций $f(x, y)$ и $g(x, y)$ приведены на рис. 4.12.




Рис. 4.12 К определению положения корней в задаче 3

Метод простых итераций имеет вид

$$\begin{aligned}x^{k+1} &= (y^k)^2 - 3\lg x^k, \\y^{k+1} &= 2x^k + \frac{1}{x^k} - 5,\end{aligned}$$

где $x^0 = 3.4$, $y^0 = 2.2$, $F(x, y) = y^2 - 3\lg x$; $G(x, y) = 2x + \frac{1}{x} - 5$.

Матрица Якоби для такого процесса

$$\mathbf{J} = \begin{pmatrix} \frac{\partial F}{\partial x} & \frac{\partial F}{\partial y} \\ \frac{\partial G}{\partial x} & \frac{\partial G}{\partial y} \end{pmatrix} = \begin{pmatrix} -\frac{3\lg e}{x} & 2y \\ 2 - x^{-2} & 0 \end{pmatrix}.$$

Несложно проверить, вычислив норму матрицы Якоби, что для приведенного начального приближения достаточное условие сходимости не выполняется.

Рассмотрим теперь другой итерационный процесс:

$$\begin{aligned}x^{k+1} &= \left(\frac{x^k(y^k + 5) - 1}{2} \right)^{1/2}, & y^{k+1} &= (x^k + 3\lg x^k)^{1/2}, \\F(x, y) &= \left(\frac{x^k(y^k + 5) - 1}{2} \right)^{1/2}, & G(x, y) &= (x + 3\lg x)^{1/2}.\end{aligned}$$

Матрица Якоби для этого итерационного метода будет

$$\mathbf{J} = \begin{pmatrix} \frac{5+y}{2\sqrt{2}\sqrt{x(y+5)-1}} & \frac{x}{2\sqrt{2}\sqrt{x(y+5)-1}} \\ 1 + \frac{3\lg e}{x} & 0 \\ \frac{1}{2\sqrt{x+3\lg x}} & 0 \end{pmatrix}.$$

В окрестности начального приближения условие сходимости выполнено. Таблица первых пяти приближений приведена ниже:

k	0	1	2	3	4	5
x	3.4	3.426	3.451	3.466	3.475	3.480
y	2.2	2.243	2.2505	2.255	2.258	2.259

4. С помощью метода Ньютона вычислить $\sqrt[n]{a}$, $a > 0$, $n \in \mathbb{R}$.

Решение. Будем вычислять действительный положительный корень уравнения

$$f(x) = x^n - a = 0.$$

Метод Ньютона в этом случае

$$\begin{aligned} x^{k+1} &= x^k - \frac{f(x^k)}{f'(x^k)} = x^k - \frac{(x^k)^n - a}{n(x^k)^{n-1}} = \\ &= \frac{n-1}{n}x^k + \frac{a}{n(x^k)^{n-1}} = \frac{1}{n} \left[(n-1)x^k + \frac{a}{(x^k)^{n-1}} \right]. \end{aligned}$$

В частности, при $n = 2$ имеем

$$x^{k+1} = \frac{1}{2} \left(x^k + \frac{a}{x^k} \right).$$

5. Получить расчетные формулы метода Ньютона для численного решения системы двух нелинейных уравнений $f(x, y) = 0$, $g(x, y) = 0$.

Решение. Положим $x^{k+1} = x^k + \Delta x^k$, $y^{k+1} = y^k + \Delta y^k$, $f(x^k, y^k) = f_k$, $g(x^k, y^k) = g_k$, получим

$$f(x^k, y^k) + \left(\frac{\partial f}{\partial x} \right)_k \Delta x^k + \left(\frac{\partial f}{\partial y} \right)_k \Delta y^k = 0,$$

$$g(x^k, y^k) + \left(\frac{\partial g}{\partial x} \right)_k \Delta x^k + \left(\frac{\partial g}{\partial y} \right)_k \Delta y^k = 0,$$

откуда

$$\begin{aligned} \Delta x^k = \frac{|\mathbf{X}_k|}{|\mathbf{J}_k|} &= \left| \begin{pmatrix} \left(\frac{\partial f}{\partial x} \right)_k & \left(\frac{\partial f}{\partial y} \right)_k \\ \left(\frac{\partial g}{\partial x} \right)_k & \left(\frac{\partial g}{\partial y} \right)_k \end{pmatrix} \right|^{-1} \cdot \begin{vmatrix} -f_k & \left(\frac{\partial f}{\partial y} \right)_k \\ -g_k & \left(\frac{\partial g}{\partial y} \right)_k \end{vmatrix} = \\ &= \frac{-f_k \left(\frac{\partial g}{\partial y} \right)_k + g_k \left(\frac{\partial f}{\partial y} \right)_k}{\left(\frac{\partial f}{\partial x} \right)_k \left(\frac{\partial g}{\partial y} \right)_k - \left(\frac{\partial g}{\partial x} \right)_k \left(\frac{\partial f}{\partial y} \right)_k}, \end{aligned}$$

$$\Delta y^k = \frac{|\mathbf{Y}_k|}{|\mathbf{J}_k|} = \frac{\begin{vmatrix} \left(\frac{\partial f}{\partial x}\right)_k & \left(\frac{\partial f}{\partial y}\right)_k \\ \left(\frac{\partial g}{\partial x}\right)_k & \left(\frac{\partial g}{\partial y}\right)_k \end{vmatrix}^{-1} \begin{vmatrix} \left(\frac{\partial f}{\partial x}\right)_k & -f_k \\ \left(\frac{\partial g}{\partial x}\right)_k & -g_k \end{vmatrix}}{\begin{vmatrix} \left(\frac{\partial f}{\partial x}\right)_k & \left(\frac{\partial f}{\partial y}\right)_k \\ \left(\frac{\partial g}{\partial x}\right)_k & \left(\frac{\partial g}{\partial y}\right)_k \end{vmatrix}} = \frac{-g_k \left(\frac{\partial g}{\partial x}\right)_k + f_k \left(\frac{\partial f}{\partial x}\right)_k}{\left(\frac{\partial f}{\partial x}\right)_k \left(\frac{\partial g}{\partial y}\right)_k - \left(\frac{\partial g}{\partial x}\right)_k \left(\frac{\partial f}{\partial y}\right)_k},$$

где $\mathbf{J}_k = \begin{pmatrix} \left(\frac{\partial f}{\partial x}\right)_k & \left(\frac{\partial f}{\partial y}\right)_k \\ \left(\frac{\partial g}{\partial x}\right)_k & \left(\frac{\partial g}{\partial y}\right)_k \end{pmatrix}$ — матрица Якоби, $\mathbf{X}_k, \mathbf{Y}_k$ — матрицы

$$\mathbf{X}_k = \begin{pmatrix} -f_k & \left(\frac{\partial f}{\partial x}\right)_k \\ -g_k & \left(\frac{\partial f}{\partial y}\right)_k \end{pmatrix}, \quad \mathbf{Y}_k = \begin{pmatrix} \left(\frac{\partial f}{\partial x}\right)_k & -f_k \\ \left(\frac{\partial f}{\partial y}\right)_k & -g_k \end{pmatrix}.$$

6. Найти приближенное решение системы двух нелинейных алгебраических уравнений $x^3 - y^3 - 1 = 0$, $xy^3 - y - 4 = 0$, используя метод Ньютона.

Решение. Пусть $f(x, y) = x^3 - y^3 - 1$, $g(x, y) = xy^3 - y - 4$. Начальное приближение можно найти графически. Выбираем $x_0 = y_0 = 1.5$. Матрицы $\mathbf{J}_k, \mathbf{X}_k, \mathbf{Y}_k$:

$$\mathbf{J}_k = - \begin{pmatrix} 3(x^k)^2 & -2y^k \\ (y^k)^3 & 3x^k(y^k)^2 - 1 \end{pmatrix},$$

$$\mathbf{X}_k = - \begin{pmatrix} (x^k)^3 - (y^k)^3 - 1 & -2y^k \\ x^k(y^k)^3 - y^k - 4 & 3x^k(y^k)^2 - 1 \end{pmatrix},$$

$$\mathbf{Y}_k = - \begin{pmatrix} 3(x^k)^2 & (x^k)^3 - (y^k)^3 - 1 \\ (y^k)^3 & x^k(y^k)^3 - y^k - 4 \end{pmatrix}.$$

Следующее приближение вычисляется по формуле Ньютона:

$$x^{k+1} = x^k + \frac{|\mathbf{X}_k|}{|\mathbf{J}_k|}, \quad y^{k+1} = y^k + \frac{|\mathbf{Y}_k|}{|\mathbf{J}_k|}.$$

Результаты вычислений первых двух итераций приведены в таблице (точность $\varepsilon \approx 10^{-3}$):

k	$x^k; y^k$	$f_k; g_k$	$ \mathbf{J}_k $	$ \mathbf{X}_k $	$ \mathbf{Y}_k $
0	1.5; 1.5	0.12500 -4.33750	71.71875	-0.171875	-3.3750
1	1.502397 1.547059	-0.002170 0.015844	77.73277	0.0277988	0.1153255
2	1.5020396 1.545570	0.0000017 0.000019			

Библиографический комментарий к Лекции 4

Итерационным методам решения нелинейных уравнений и систем посвящена обширная литература. В качестве первоначального чтения можно рекомендовать учебники [1–6, 21], см. также [26] и библиографию в ней.

С итерационными методами решения нелинейных систем тесно связаны различные дискретные отображения. О них лучше прочитать в [27] на «студенческом» уровне, а на более глубоком математическом уровне — в [28].

Для практических занятий рекомендуется использовать задачи из [8].

ВВЕДЕНИЕ В ЧИСЛЕННЫЕ МЕТОДЫ БЕЗУСЛОВНОЙ ОПТИМИЗАЦИИ

Рассматриваются наиболее употребительные численные методы поиска минимума функций нескольких переменных.

Ключевые слова: функционал, целевая функция, стационарная точка, метод перебора, метод золотого сечения, метод парабол, метод по координатного спуска, градиентного спуска, метод наискорейшего спуска, математическое программирование.

5.1. Поиск безусловного минимума функции

О п р е д е л е н и е. Пусть на множестве U , состоящем из элементов линейного метрического пространства, определена скалярная функция $\Phi(\mathbf{u})$.

1. Говорят, что $\Phi(\mathbf{u})$ имеет локальный минимум на элементе $\mathbf{u}^*$, если существует его конечная ε -окрестность, в которой выполнено

$$\Phi(\mathbf{u}^*) \leq \Phi(\mathbf{u}), \quad \|\mathbf{u} - \mathbf{u}^*\| \leq \varepsilon. \quad (5.1)$$

2. $\Phi(\mathbf{u})$ достигает глобального минимума в U на элементе $\mathbf{u}^*$ (строгий, абсолютный минимум), если имеет место равенство

$$\Phi(\mathbf{u}^*) = \inf_U \Phi(\mathbf{u}). \quad (5.2)$$

Замечание. Если U — числовая ось, решается задача на нахождение минимума функции одного переменного, если U — n -мерное векторное пространство, имеется задача на нахождение минимума функции n переменных, если U — функциональное пространство, то решается задача на отыскание функции, доставляющей минимум функционалу (задача оптимального управления или динамического программирования).

Если к (5.1) или (5.2) добавляются условия

$$\begin{aligned} u_k^0 &\leq u_k \leq u_k^1, \quad k = 1, \dots, K, \\ F_i^0 &\leq \Phi_i(\mathbf{u}) \leq F_i^1, \quad i = 1, \dots, I, \end{aligned}$$

(u_k^p , F_i^p — числа, а Φ_i — заданные функции), то это задача поиска условного минимума; если подобные ограничения отсутствуют, то это задача поиска безусловного минимума. Причем, если функции $\Phi_i(u)$ линейны, задача поиска условного минимума называется задачей линейного программирования, если хотя бы одна из этих функций нелинейна, то имеется задача нелинейного программирования. Обе эти задачи вместе с задачей динамического программирования в теории оптимального управления называются задачами математического программирования.

Говорят о поиске минимума функции, не ограничивая общности, так как максимум функции $\Phi(\mathbf{u})$ является минимумом функции $-\Phi(\mathbf{u})$. $\Phi(\mathbf{u})$ называют целевой функцией.

Отметим связь между задачами вычисления корней системы нелинейных алгебраических уравнений (СНАУ) и задачи минимизации.

Пусть на множестве $U \in R^n$ решается система нелинейных уравнений

$$f_1(u_1, \dots, u_n) = 0,$$

$$\dots\dots\dots$$

$$f_n(u_1, \dots, u_n) = 0.$$

Определим целевую функцию следующим образом:

$$\Phi(u_1, \dots, u_n) = \sum_{k=1}^n f_k^2(u_1, \dots, u_n).$$

В области U справедливо $\Phi(\mathbf{u}) \geq 0$, причем минимальное значение $\Phi(\mathbf{u})$ имеет при $\mathbf{u} = \mathbf{u}^*$, где $\mathbf{u}^*$ — корень рассмотренной системы. Поэтому ее решение эквивалентно поиску минимума $\Phi(\mathbf{u})$ в U . Если $\Phi(\mathbf{u})$ строго больше нуля, то система решений не имеет.

Теперь положим, что необходимо найти минимум целевой функции $\Phi(\mathbf{u})$, у которой существуют первые производные. В этом случае задача сводится к решению СНАУ

$$\frac{\partial \Phi(u_1, \dots, u_n)}{\partial u_1} = 0,$$

$$\dots\dots\dots$$

$$\frac{\partial \Phi(u_1, \dots, u_n)}{\partial u_n} = 0.$$

Точка, являющаяся решением указанной СНАУ, называется стационарной. Однако не всякая стационарная точка может быть точкой локального минимума целевой функции.

Следующую теорему приведем без доказательства.

Теорема 5.1. Пусть функция $\Phi(\mathbf{u})$ дважды непрерывно дифференцируема. Тогда достаточным условием того, чтобы стационарная точка $\mathbf{u}^*$ была точкой локального минимума, является положительная определенность матрицы Гессе

$$\mathbf{G}(\mathbf{u}^*) = \begin{pmatrix} \frac{\partial^2 \Phi}{\partial u_1^2} & \cdots & \frac{\partial^2 \Phi}{\partial u_1 \partial u_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 \Phi}{\partial u_n \partial u_1} & \cdots & \frac{\partial^2 \Phi}{\partial u_n^2} \end{pmatrix}.$$

Отметим, что методы отыскания минимума $\Phi(\mathbf{u})$ нередко оказываются более эффективными, чем методы численного решения СНАУ.

Рассмотрим некоторые методы одномерной оптимизации.

Метод перебора. Пусть $U = [a, b]$, т. е. отрезок числовой оси. Разобьем его на n равных частей с узлами в точках $u_i = a + i(b - a)/n$; $i = 0, \dots, n$.

Вычислив значение $\Phi(u)$ в этих точках, найдем путем сравнения точку u^* , в которой

$$\Phi(u^*) = \min_{0 \leq i \leq n} \Phi(u_i).$$

Далее полагаем $u^* \approx u_{\min}$, $\Phi^* \approx \Phi(u^*)$. Погрешность в определении u^* этого простейшего метода не превосходит числа

$$\epsilon_n = \frac{b - a}{n}.$$

Этот метод прост, но неэкономичен, особенно когда ищется минимум функции многих переменных. Например, в гиперкубе $U = \{0 \leq u_i \leq 1, 1 \leq i \leq 10\}$ с разбиением каждого из отрезков (по каждой из координат) на 10 частей, с быстродействием 10^6 операций в секунду потребуется около 10^7 с (примерно 4 месяца) для нахождения $\min_U \Phi(\mathbf{u})$, если предположить, что количество арифметических действий, необходимое для вычисления значений $\Phi(\mathbf{u})$ в каждой точке, требует тысячи арифметических операций. Этот метод можно сделать более эффективным, если сначала определить минимум с грубым шагом, затем уже искать минимум

с меньшим шагом на том из отрезков $[x_i, x_{i+1}]$, на котором предполагается наличие минимума; можно и далее уточнять решение задачи таким же образом.

Усовершенствованием этого метода в одномерном случае являются методы исключения отрезков, дихотомии (деления отрезка пополам) и золотого сечения. В них отрезок $[a; b]$ делится на 4 части выбором внутри отрезка точек u_1, u_2 , в которых вычисляются значения целевой функции. Сравнив ее значения в этих точках, можно сократить отрезок поиска точки минимума, перейдя к отрезку $[a; u_2]$, если $\Phi(u_1) \leq \Phi(u_2)$, или $[u_1; b]$, если $\Phi(u_1) \geq \Phi(u_2)$. Эту процедуру можно продолжить.

Метод дихотомии. В методе дихотомии точки u_1, u_2 выбираются близко к середине отрезка $\left[u_1 = \frac{b+a-\Delta}{2}, u_2 = \frac{b+a+\Delta}{2}\right]$, где Δ достаточно мало. Поскольку отношения $\frac{b-u_1}{b-a}, \frac{u_2-a}{b-a}$ близки к $1/2$, такой выбор объясняется стремлением обеспечить максимальное относительное уменьшение отрезков.

В конце вычисления в качестве приближенного значения u^* берется середина последнего отрезка. В результате n итераций длина отрезка будет

$$\Delta_n = \frac{b-a}{2^n} + \left(\frac{1}{2^n} + \frac{1}{2^{n-1}} + \dots + \frac{1}{2}\right)\Delta = \frac{b-a}{2^n} + \left(1 - \frac{1}{2^n}\right)\Delta,$$

т. е. точность определения u^* составляет $\epsilon_n = \Delta_n/2$.

Находя n из условия $\epsilon_n \leq \epsilon$, получим количество итераций, необходимое для достижения данной точности:

$$n \geq \left\lceil \log_2 \frac{b-a-\Delta}{2\epsilon-\Delta} \right\rceil + 1,$$

$$\epsilon_n \approx \frac{b-a}{2^{n+1}}.$$

Метод золотого сечения. Расположим точки u_1, u_2 на $[a, b]$ так, чтобы одна из них стала бы также пробной, но уже на новом отрезке, после исключения части исходного отрезка. Это позволит уменьшить количество вычислений, поскольку необходимо будет вычислить значение $\Phi(u)$ лишь в одной из пробных точек, так как во второй оно уже известно.

Найдем расположение таких точек, для чего рассмотрим отрезок $[0, 1]$ и для определенности положим, что при его уменьшении исключается его правая часть.

Пусть $u_2 = \tau$, тогда симметрично расположенная относительно центра отрезка точка имеет координату $u_1 = 1 - \tau$ (рис. 5.1).




Рис. 5.1

Пробная точка u_1 отрезка $[0; 1]$ перейдет в пробную точку $u'_2 = 1 - \tau$ нового отрезка $[0; \tau]$. Условием деления отрезков $[0; 1]$ и $[0; \tau]$ в одном и том же отношении точками $u_2 = \tau$ и $u'_2 = 1 - \tau$ является равенство

$$\frac{1}{\tau} = \frac{\tau}{1-\tau}, \quad \text{или} \quad \tau^2 + \tau - 1 = 0,$$

откуда находим положительный корень

$$\tau = \frac{\sqrt{5}-1}{2} \approx 0.61803\dots,$$

т. е. $u_1 = 1 - \tau = \frac{3-\sqrt{5}}{2}$, $u_2 = \tau = \frac{\sqrt{5}-1}{2}$.

Для отрезка $[a; b]$

$$u_1 = a + \frac{3-\sqrt{5}}{2}(b-a), \quad u_2 = a + \frac{\sqrt{5}-1}{2}(b-a).$$

Замечания.

1. Точки u_1, u_2 обладают следующим свойством: каждая из них делит отрезок $[a; b]$ на две неравные части так, что отношение длины всего отрезка к длине его большей части равно отношению длин большей и меньшей части. Точки, обладающие таким свойством, называются точками золотого сечения, введенного Леонардо да Винчи.

2. На каждой итерации отрезок поиска минимума уменьшается в одном и том же отношении

$$\tau = \frac{\sqrt{5}-1}{2},$$

поэтому в результате n итераций длина становится равной

$$\Delta_n = \tau^n(b - a).$$

Следовательно, точность ε_n определения точки u^* после n итераций равна

$$\varepsilon_n = \frac{\Delta_n}{2} = \frac{1}{2} \left(\frac{\sqrt{5} - 1}{2} \right)^n (b - a);$$

а условием окончания вычислительного процесса будет $\varepsilon_n \leq \varepsilon$.

Метод парабол. Методы, использующие исключение отрезков, основаны на сравнении функций в двух точках пробного отрезка, причем учитываются лишь значения функции в этих точках.

Учесть информацию о значениях функции между точками позволяют методы полиномиальной аппроксимации. Их основная идея заключена в том, что функция $\Phi(u)$ аппроксимируется полиномом, а точка его минимума служит приближением к u^* . Разумеется, в этом случае кроме свойства унимодальности (т. е. наличия единственного минимума на рассматриваемом отрезке), необходимо на $\Phi(u)$ наложить и требования достаточной гладкости для ее полиномиальной аппроксимации.

Для повышения точности поиска u^* можно как увеличивать степень полинома, так и уменьшать пробный отрезок. Поскольку первый прием приводит к заметному увеличению вычислительной работы и появлению дополнительных экстремумов, обычно пользуются полиномами второй (метод парабол) или третьей (метод кубической интерполяции) степени.

Алгоритм поиска минимума состоит в следующем.

Выбираем на пробном отрезке три точки u_1, u_2, u_3 такие, что $u_1 < u_2 < u_3$ и $u_1 \leq u^* \leq u_3$.

Построим параболу (квадратичный полином)

$$Q(u) = a_0 + a_1(u - u_1) + a_2(u - u_1)(u - u_2),$$

график которой проходит через точки $(u_1, f(u_1))$, $(u_2, f(u_2))$, $(u_3, f(u_3))$.

Коэффициенты a_k , $k = 1, 2, 3$ находим из системы уравнений

$$Q(u_1) = f(u_1),$$

$$Q(u_2) = f(u_2),$$

$$Q(u_3) = f(u_3),$$

откуда

$$a_0 = f(u_1), \quad a_1 = \frac{f(u_2) - f(u_1)}{u_2 - u_1},$$

$$a_2 = \frac{1}{u_3 - u_2} \left[\frac{f(u_3) - f(u_1)}{u_3 - u_1} - \frac{f(u_2) - f(u_1)}{u_2 - u_1} \right].$$

Точку $\bar{u}$ минимума $Q(u)$ находим, приравнивая производную нулю:

$$\bar{u} = \frac{1}{2} \left(u_1 + u_2 - \frac{a_1}{a_2} \right) = \frac{1}{2} \left[(u_1 + u_2) - \frac{\frac{(f_2 - f_1)(u_3 - u_2)}{u_2 - u_1}}{\frac{f_3 - f_1}{u_3 - u_1} - \frac{f_2 - f_1}{u_2 - u_1}} \right].$$

Далее полагаем $u^* \approx \bar{u}$ (очередное приближение точки минимума). Эту процедуру можно продолжить до достижения необходимой точности, выбирая новые точки u_k , $k = 1, 2, 3$. Для этого можно использовать методы исключения отрезков, используя в качестве двух пробных точек u_2 и $\bar{u}$ такие, что $u_2, \bar{u} \in [u_1, u_3]$.

5.2. Методы спуска

Знакомство с методами многомерной оптимизации начнем с широко распространенных методов спуска.

Основная идея таких методов состоит в том, чтобы построить алгоритм, позволяющий перейти из точки начального приближения $\mathbf{u}^0 = \{u_0^1, \dots, u_0^n\}$ в следующую точку $\mathbf{u}^1 = \{u_1^1, \dots, u_1^n\}$ таким образом, чтобы значение целевой функции приблизилось к минимальному.

5.2.1. Метод покоординатного спуска. Этот метод является сведением поиска функции многих переменных к последовательности задач минимизации функции одной переменной. Пусть $\mathbf{u}^0 \in U$ — начальное приближение к минимуму $\Phi(\mathbf{u})$.

Рассмотрим $\Phi(\mathbf{u}^0) = \Phi(u_1^0, u_2^0, \dots, u_n^0)$ как функцию одной переменной u_1 при фиксированных $u_2^0, \dots, u_n^0$ и найдем одним из приведенных методов поиска минимума функции одной переменной $\min_{u_1 \in U} \Phi(u_1, u_2^0, \dots, u_n^0)$.

Полученное значение u_1 , доставляющее минимум $\Phi(u_1)$, обозначим u_1^1 ; при этом

$$\Phi(u_1^1, u_2^0, \dots, u_n^0) \leq \Phi(u_1^0, \dots, u_n^0).$$

Далее, при фиксированных значениях $u_1^1, u_0^3, \dots, u_0^n$ ищем $\min_{u_2 \in U} \Phi(u_1^1, u_2^2, u_0^3, \dots, u_0^n)$ как функции от u_2 ; соответствующее значение u_2 обозначим u_2^1 ; при этом

$$\Phi(u_1^1, u_2^1, \dots, u_n^0) \leq \Phi(u_1^1, u_2^0, \dots, u_n^0).$$

Этот процесс продолжаем аналогичным образом и для оставшихся координат; в результате получим

$$\Phi(u_1^1, \dots, u_n^1) \leq \Phi(u_1^1, \dots, u_n^0).$$

Таким образом, переходим из точки $\mathbf{u}^0$ в точку $\mathbf{u}^1$. Этот процесс повторяется до тех пор, пока не будет выполнено условие выхода из итераций, например,

$$|\Phi(\mathbf{u}^{k+1}) - \Phi(\mathbf{u}^k)| \leq \varepsilon,$$

где $\varepsilon > 0$ — заданная точность.

Пример. Найти минимум функции двух переменных

$$\Phi(u) = (u_1)^2 + (u_2)^2.$$

Выбрав некоторую точку начального приближения (например, $u_0 = (2, 2)$), получим минимум целевой функции за два шага, так как ее линии уровня — окружности с центром в начале координат (рис. 5.2).

Если же целевой функцией является, например,

$$\Phi(u) = 5u_1^2 + 5u_2^2 + 8u_1u_2,$$

которая поворотом системы координат на угол -45° и преобразованием $u_1 = (v_1 + v_2)/\sqrt{2}$; $u_2 = (-v_1 + v_2)/\sqrt{2}$ приводится к виду $\Phi'(v) = v_1^2 + 9v_2^2$, то ее линиями уровня являются эллипсы $v_1^2/9 + v_2^2 = c^2$, поэтому спуск будет иметь иной характер (рис. 5.3).

Можно показать, что покоординатный спуск реализуется (сходится к точке минимума) при условии существования вторых производных Φ''_{u_1} , Φ''_{u_2} , $\Phi''_{u_1u_2}$, причем $\Phi''_{u_1} \geq a_1 > 0$, $\Phi''_{u_2} \geq a_2 > 0$, $|\Phi''_{u_1u_2}| \leq a_3$, $a_1a_2 > a_3^2$. Этот метод сходится достаточно медленно, а при наличии так называемых «оврагов» — очень медленно. Разделим «рельефы», образуемые линиями уровня, на два типа: «котловинный» и «овражный». В первом случае линии уровня похожи

на эллипсы, а функция вблизи своего минимума практически не изменяется при изменении переменных. Этот случай можно назвать простым (рис. 5.3).

Рельеф овражного типа имеет либо точки излома (рис. 5.4), либо участки с большей кривизной («разрешимый овраг»). Если же линии уровня — кусочно-гладкие, то выделим на них точки излома. Геометрическое место этих точек излома назовем истинным «оврагом», если угол направлен в сторону возрастания функции, или «гребнем» — если в сторону убывания (рис. 5.5).




Рис. 5.2. Покоординатный спуск, линии уровня целевого функционала — окружности

Рис. 5.3. Покоординатный спуск, линии уровня целевого функционала — эллипсы




Рис. 5.4. Рельеф овражного типа с точкой излома

Рис. 5.5. «Гребень». Стрелка — направление убывания функции

Примером невыпуклой функции, используемой в качестве тестовой для отладки программ решения задач оптимизации (вычисления минимума), может быть функция двух переменных

$$f(u_1, u_2) = (1 - u_1)^2 + 100(u_2 - u_1^2)^2.$$

Эта функция была предложена английским математиком Х. Розенброком и носит название функции Розенброка (или, несколько жаргонно, «банан Розенброка») из-за того, что линии уровня функции по форме напоминают тропический фрукт). Глобальный минимум функции находится в точке $(1; 1)$, легко видеть, что $f(1; 1) = 0$.

Рельеф, определяемый функцией Розенброка, носит характер «разрешимого оврага». Обобщение на случай произвольной размерности пространства получается достаточно легко:

$$f(u_1, \dots, u_N) = \sum_{i=1}^{N-1} (1 - u_i)^2 + 100(u_{i+1} - u_i^2)^2,$$

здесь N — размерность пространства.

Существуют и другие обобщения функции Розенброка. Многие примеры разрешимых оврагов с более сложным рельефом основаны на рассмотренном примере. Еще одним примером разрешимого оврага является изображенная на рис. 5.6 функция $\Phi(u_1, u_2) = 10(u_2 - \sin u_1)^2 + 0.1u_1^2$.

Неупорядоченный тип рельефа характеризуется наличием многих экстремумов; примером может служить функция $\Phi(u_1, u_2) = (1 + \sin 2u_1)(1 + \sin 2u_2)$ (рис. 5.7).




Рис. 5.6. Разрешенный овраг — одно из обобщений функции Розенброка
Рис. 5.7. Неупорядоченный рельеф

Метод оврагов используется в случае, если «дно» оврага узкое, а «склоны» крутые. В этом случае спустимся из двух точек P_0 и P_1 , например, с помощью метода координатного или градиентного спуска на «дно» оврага (или в его окрестность) в точки с координатами r_0 или r_1 , не требуя высокой точности сходимости. Проведем через эти две точки прямую и выберем на ней новую точку

$$P_2 = r_1 \pm h(r_1 - r_0),$$

где $h = \text{const} > 0$ — «овражный шаг», который выбирается для каждой функции путем расчета (рис. 5.8). Точка P_2 лежит на




Рис. 5.8 Спуск в овраг

«склоне» оврага. Из нее спускаемся на «дно» и попадаем в некую точку r_2 , через точки r_1 и r_2 проводим прямую и находим точку P_3 , из которой возможно опуститься в точку r_3 .

Процесс продолжается до тех пор, пока значения целевой функции на «дне» оврага убывают, т. е. пока

$$\Phi(r_{n+1}) > \Phi(r_n).$$

5.2.2. Метод градиентного спуска. Напомним, что градиент функции $\nabla\Phi(\mathbf{u}) = \left(\frac{d\Phi}{du_1}, \dots, \frac{d\Phi}{du_n}\right)^T$ есть вектор, ортогональный линиям уровня целевой функции, а его направление совпадает с направлением наибольшего роста $\Phi(\mathbf{u})$ в данной точке. В точке минимума $\nabla\Phi(\mathbf{u}) = 0$.

Построим итерационный процесс следующим образом:

$$\mathbf{u}^{k+1} = \mathbf{u}^k - \tau \nabla\Phi(\mathbf{u}^k), \quad \mathbf{u}^0 = \mathbf{a},$$

где τ — шаг спуска (итерационный параметр). Итерации продолжим до выполнения заданного условия окончания процесса поиска.

ка минимума, например

$$\|\Phi(\mathbf{u}^{k+1})\| \leq \varepsilon.$$

Пример. Рассмотрим функцию двух переменных $\Phi(u_1, u_2) = \frac{(u_1)^2}{4} + (u_2)^2$.

Пользуясь методом градиентного спуска, получим

$$\begin{aligned} u_1^{k+1} &= u_1^k - \tau \frac{u_1^k}{2}, \\ u_2^{k+1} &= u_2^k - \tau \cdot 2u_2^k. \end{aligned}$$

Пусть начальное приближение $u^0 = \{1; 1\}$; $\tau = 0.1$. Тогда

$$\begin{aligned} u^1 &= \{0.95; 0.80\}; \quad u^2 = \{0.9025; 0.6400\}; \quad u^3 = \{0.8574; 0.5120\}; \\ \Phi(u^1) &= 1.25; \quad \Phi(u^3) = 0.446. \end{aligned}$$

Если взять $\tau = 2$, то $u^1 = \{0; -3\}$ и $\Phi(u^1) = 9$, в то время как $\min_U \Phi(u) = 0$. Выбор шага для этого метода оказывается существенным, поэтому чаще используются методы с переменным шагом.

5.2.3. Метод наискорейшего спуска. В методе градиентного спуска выберем шаг τ так, чтобы функция $\Phi(u)$ максимально уменьшала свое значение:

$$\Phi(\mathbf{u}^{k+1}) = \min \Phi(\mathbf{u}^k - \tau \nabla \Phi(\mathbf{u}^k)).$$

В предыдущем примере выбор шага в точке u^0 сводится к задаче о поиске минимума функции

$$\frac{1}{4} \left(1 - \frac{\tau}{2}\right)^2 + (1 - 2\tau)^2,$$

откуда $\tau = 34/65$, поскольку

$$\begin{aligned} \Phi(\mathbf{u}^1) &= \frac{1}{4} \left(u_1^0 - \tau \frac{u_1^0}{2}\right)^2 + (u_2^0 - 2\tau u_2^0)^2 = \\ &= \frac{1}{4} \left(1 - \frac{\tau}{2}\right)^2 + (1 - 2\tau)^2, \quad u_1^0 = u_2^0 = 1. \end{aligned}$$

На следующих шагах τ будет зависеть от u_i^k , $k > 0$, $i = 1, 2$.

Отметим следующее важное обстоятельство. Решение экстремальных задач в R^n зачастую сопряжено со значительными трудностями, особенно для многоэкстремальных задач. Некоторые из этих трудностей исчезают, если ограничиться рассмотрением только выпуклых функций на выпуклых множествах.

Определение. Функция $\Phi(\mathbf{u})$, заданная на выпуклом множестве $U \in R^n$, называется выпуклой, если для любых точек $\mathbf{u}, \mathbf{v} \in U$ и любого $\alpha \in [0; 1]$ выполнено

$$\Phi(\alpha \mathbf{u} + (1 - \alpha)\mathbf{v}) \leq \alpha \Phi(\mathbf{u}) + (1 - \alpha)\Phi(\mathbf{v}).$$

Определение. Функция $\Phi(\mathbf{u})$ называется строго выпуклой, если для всех $\alpha \in (0; 1)$ выполнено строгое неравенство

$$\Phi(\alpha \mathbf{u} + (1 - \alpha)\mathbf{v}) < \alpha \Phi(\mathbf{u}) + (1 - \alpha)\Phi(\mathbf{v}).$$

Это определение имеет наглядный геометрический смысл: график функции $\Phi(\mathbf{u})$ на интервале, соединяющем точки $\mathbf{u}, \mathbf{v}$, лежит ниже хорды, проходящей через точки $\{\mathbf{u}, \Phi(\mathbf{u})\}$ и $\{\mathbf{v}, \Phi(\mathbf{v})\}$.

Для дважды непрерывно дифференцируемой функции $\Phi(\mathbf{u})$ положительная определенность матрицы Гессе $\Phi''_{\mathbf{u}}(\mathbf{u})$ есть достаточное условие строгой выпуклости.

Теорема 5.2. Пусть $\Phi(\mathbf{u})$ — выпуклая функция на выпуклом множестве U , $\mathbf{u} \in U$. Тогда любой ее локальный минимум на U является одновременно и глобальным.

Глобальный минимум строго выпуклой функции $\Phi(\mathbf{u})$ на выпуклом множестве U достигается в единственной точке.

Доказательство. Предположим противное, т.е. $\mathbf{u}^0$ — точка локального, а $\mathbf{u}^*$ — глобального минимума $\Phi(\mathbf{u})$ на U , $\mathbf{u}^* \neq \mathbf{u}^0$ и $\Phi(\mathbf{u}^0) > \Phi(\mathbf{u}^*)$. Отсюда с учетом выпуклости $\Phi(\mathbf{u})$ имеем

$$\Phi(\alpha \mathbf{u}^* + (1 - \alpha)\mathbf{u}^0) \leq \alpha \Phi(\mathbf{u}^*) + (1 - \alpha)\Phi(\mathbf{u}^0) < \Phi(\mathbf{u}^0).$$

При $\alpha \rightarrow +0$ точка $\mathbf{u} = \alpha \mathbf{u}^* + (1 - \alpha)\mathbf{u}^0$ попадает в сколь угодно малую окрестность $\mathbf{u}^0$. Поэтому полученное неравенство $\Phi(\mathbf{u}) < \Phi(\mathbf{u}^0)$ противоречит предположению о том, что $\mathbf{u}^0$ — точка локального минимума (первая часть теоремы доказана).

Пусть $\mathbf{u}^{(1)}, \mathbf{u}^{(2)}$ — две различные точки глобального минимума. Из строгой выпуклости $\Phi(\mathbf{u})$ следует, что для всех $\alpha \in [0; 1]$ выполняется строгое неравенство

$$\Phi(\alpha \mathbf{u}^{(1)} + (1 - \alpha) \mathbf{u}^{(2)}) < \alpha \Phi(\mathbf{u}^{(1)}) + (1 - \alpha) \Phi(\mathbf{u}^{(2)}) = \Phi^* = \min_U \Phi(\mathbf{u}),$$

что противоречит предположению о том, что $\mathbf{u}^{(1)}, \mathbf{u}^{(2)}$ — точки глобального минимума.

5.3. Понятие о задачах линейного программирования

Под линейным программированием понимают часть экстремальных задач, рассматривающую минимизацию линейных функций при наличии дополнительных линейных условий трех типов:

$$\begin{aligned} \min \Phi(\mathbf{u}); \quad \Phi(\mathbf{u}) &= \sum_{i=1}^n c_i u_i; \\ u_i &\geq 0; \quad 1 \leq i \leq n; \\ \sum_{i=1}^n a_{ij} u_i &= b_j, \quad 1 \leq j \leq J_1; \\ \sum_{i=1}^n u_i &\leq b_j, \quad J_1 < j \leq J_2. \end{aligned} \tag{5.3}$$

Каждое из этих условий определяет полупространство, ограниченное гиперплоскостью; вместе эти условия определяют выпуклый n -мерный многогранник J' , являющейся пересечением полупространств. Условия типа равенств выделяют из n -мерного пространства $(n-m)$ -мерную плоскость. Ее пересечение с M дает выпуклый $(n-m)$ -мерный многогранник G . Таким образом, задача состоит в том, чтобы найти минимум линейной функции $\Phi(\mathbf{u})$ в многограннике G .

G — выпуклый многогранник (возможно и неограниченный), поэтому внутри него линейная функция $\Phi(\mathbf{u})$ не может достигать минимума. Показывается, что ее минимум, если он существует, достигается в какой-то из его вершин. Теоретически задача линейного программирования достаточно проста: необходимо вычислить значение функций в конечном числе точек — вершинах многогранника, сравнить их между собой и найти среди них наи-

меньшее. Однако трудность заключается в том, что в экономических задачах количество переменных порядка $10^2 \div 10^4$, поэтому решение оказывается достаточно сложным.

Пример. Рассмотрим вычислительно следующую простую задачу линейной оптимизации на плоскости: найти $\min \Phi(\mathbf{u}) = c_1 u_1 + c_2 u_2$ при ограничениях

$$\begin{cases} a_{11}u_1 + a_{12}u_2 = b_1, \\ a_{21}u_1 + a_{22}u_2 = b_2, \\ u_1 \geq 0, u_2 \geq 0. \end{cases}$$

Неравенства $u_1 \geq 0$ и $u_2 \geq 0$ выделяют I квадрант плоскости (u_1, u_2) , а линейная функция $\Phi(u) = c_1 u_1 + c_2 u_2$ при определенных c_1, c_2 задает в этом квадранте семейство прямых уравнением $c_1 u_1 + c_2 u_2 = d$ (d неизвестно) (рис. 5.9).




Рис. 5.9. Разные значения целевой функции




Рис. 5.10. К решению задачи линейного программирования

Вообще говоря, ограничения в форме равенств могут быть следующего типа: отсутствует, одно ограничение, два ограничения (последний случай соответствует рассматриваемому). Пусть СЛАУ в данном примере имеет единственное решение $u^* = (u_1^*, u_2^*)$.

Если выполнены неравенства $u_1 \geq 0$, $u_2 \geq 0$, то u^* и есть решение задачи линейной оптимизации, а $\min \Phi(\mathbf{u}) = c_1 u_1^* + c_2 u_2^*$ (рис. 5.10).

Если же, например, $u_1^* < 0$ и $u_2^* < 0$, то задача линейного программирования неразрешима, так как по условию решения находится внутри первого квадранта. В данном случае ограничения определяют единственное решение рассматриваемой задачи, а це-

левая функция принимает «навязанное» значение $\Phi(u^*)$. Процесс решения оказался весьма простым. Если бы имелось больше условий типа неравенств и меньше равенств, рассмотрение оказалось бы более сложным.

Пример. Графическое решение задачи

$$\begin{aligned}\min \Phi(\mathbf{u}) &= -3u_1 - 3u_2, \\ u_1 + 2u_2 &\leq 7, \\ 2u_1 + u_2 &\leq 8, \\ u_1 &\leq 3, \\ u_2 &\leq 3, \\ u_1 &\geq 0, \\ u_2 &\geq 0.\end{aligned}$$

приводит к решению $u^* = (3; 2)$ и $\Phi(u^*) = -15$. Для решения задачи рассматриваются линии уровня функции $\Phi(u)$, т. е. семейство параллельных прямых $-3u_1 - 3u_2 = d = \text{const}$.

Нормальный к этим прямым вектор $-\Phi'_u(u)$ указывает направление убывания целевой функции. Решением задачи u^* является одна из вершин многогранника, образованного прямыми системы неравенств.

5.4. Задачи с решениями

1. Свести задачу о нахождении решения системы нелинейных уравнений

$$\begin{cases} u - 5 \cdot 10^{-2} e^{uv} = 0, \\ v - 5 \cdot 10^{-2} e^{-(u+v)} = 0, \end{cases}$$

к вариационной задаче в области

$$\Omega = \{|u - 0.1| \leq 0.1; |v - 0.1| \leq 0.1\}.$$

Решение. Решение системы сводится к нахождению условий минимума функционала

$$\Phi(u, v) = (u - 5 \cdot 10^{-2} e^{uv})^2 + (v - 5 \cdot 10^{-2} e^{-(u+v)})^2.$$

2. Свести задачу о нахождении минимума функции

$$\Phi(u, v) = u^4 + v^4 - u^2 - v^2 \text{ в области } \Omega = \{|u| \leq 1; |v| \leq 1\}.$$

к решению системы алгебраических уравнений.

Решение. Задача о нахождении минимума функции $\Phi(u, v)$ сводится к решению системы уравнений $\frac{\partial \Phi}{\partial u} = 0, \frac{\partial \Phi}{\partial v} = 0$.

Отсюда

$$\frac{\partial \Phi}{\partial u} = 4u^3 - 2u = 0,$$

$$\frac{\partial \Phi}{\partial v} = 4v^3 - 2v = 0.$$

3. Найти значения $\{x, y\}$, при которых достигается минимум функции $f(x, y) = x^3 + y^3 - 3xy$.

Решение. Вычислим частные производные $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}$ и приравняем их к нулю. Получим систему двух нелинейных уравнений $3x^2 - 3y = 0, -3x + 3y^2 = 0$. Решениями этой системы являются пары $\{0; 0\}, \{1; 1\}$. Подстановкой убеждаемся, что вторая точка является точкой глобального минимума.

4. Методом деления отрезка пополам найти точку локального минимума для функции $f(x) = x^3 + e^{-x} - x$ на отрезке $[0; 1]$ с точностью $\varepsilon = 10^{-2}$.

Решение. Обозначим границы отрезка $a_0 = 0, b_0 = 1$ и зададим $\Delta/2 = \delta = 10^{-3}$.

Вычислим $f\left(\frac{a_0 + b_0 - \Delta}{2}\right) \approx 0.2324$ и $f\left(\frac{a_0 + b_0 + \Delta}{2}\right) \approx 0.2307$. Так как второе значение меньше первого, то положим $\{a_1, b_1\} = \{0.4990; 1\}$. Продолжая далее, получим

$$\{a_2, b_2\} = \{0.4990; 0.7505\},$$

$$\{a_3, b_3\} = \{0.6238; 0.7505\},$$

$$\{a_4, b_4\} = \{0.6861; 0.7505\},$$

$$\{a_5, b_5\} = \{0.6861; 0.7191\},$$

$$\{a_6, b_6\} = \{0.7016; 0.7191\},$$

$$\{a_7, b_7\} = \{0.7101; 0.7198\}.$$

5. С помощью метода Ньютона найти минимум функции $F(t) = \sin t - \cos t, t^0 = -0.5$.

Решение. Найдём точку минимума функции $F(t)$ как корень уравнения $F'(t) = 0$. Для этого построим итерационный про-

цесс Ньютона:

$$t^{n+1} = t^n - \frac{F'(t^n)}{F''(t^n)}, \quad t^0 = -0.5.$$

При $t^0 = -0.5$ имеем $F'(t^0) = \cos t + \sin t \approx 0.3982$, $F''(t^0) = -\sin t^0 + \cos t^0 \approx 1.3570$, $t^1 = t^0 - \frac{0.3982}{1.357} \approx -0.7934$. Дальнейшие вычисления дают $t^2 = -0.7854$, $t^3 = -0.7854$.

Библиографический комментарий к Лекции 5

Численным методам оптимизации (как безусловной, так и условной) посвящена обширная литература. Для первоначального ознакомления с некоторыми простыми методами поиска экстремумов можно ознакомиться в учебниках [2, 5, 21]. Теория методов оптимизации нашла сжатое отражение в учебниках [22, 23]. Численные методы оптимизации (в том числе и более сложные быстро сходящиеся методы) описаны в [23, 24]. Первоначальные сведения о задачах и методах линейного программирования и их приложениях к экономическим задачам можно найти в небольшом, но крайне интересном пособии [25]. Отметим, что численные методы оптимизации, наряду с методами наименьших квадратов и методами приближения функций, являются одними из основных методов машинного обучения (подробнее см. в [19, 20]).

Для практических занятий рекомендуется использовать задачи из [7].

ИНТЕРПОЛЯЦИЯ ФУНКЦИЙ

Рассматривается задача алгебраической интерполяции. Обусловленность задачи исследуется на основе рассмотрения константы Лебега. Доказывается теорема об остаточном члене интерполяции. Выводятся формулы алгебраической интерполяции с кратными узлами. Рассматривается задача гладкого восполнения функции (локальными и нелокальными сплайнами), а также естественный базис в пространстве сплайн-функций — В-сплайны.

Ключевые слова: интерполяция, обобщенный полином, метод неопределенных коэффициентов, интерполяционный полином в формах Лагранжа и Ньютона, постоянная Лебега, кусочно-линейная интерполяция, сплайны, В-сплайны.

6.1. Постановка задачи интерполяции

Пусть задана совокупность *узлов интерполяции*, или *сетка*, на некотором отрезке $[a, b]$. В простейшем случае сетка — равномерная, т. е. расстояние между соседними узлами одинаково. В дальнейшем также будем рассматривать неравномерные сетки.

1. Совокупность узлов $\{t_n\}_{n=0}^N$, $t_n = a + n\tau$, $\tau = (b - a)/N$, $t \in [a, b]$.
2. Сеточная проекция функции $f(t)$ на $[a, b]$, т. е. таблица $f_n = \{f(t_n)\}_{n=0}^N$; эту таблицу задает оператор ограничения на сетку **R**.

Задача состоит в том, чтобы по таблице f_n восстановить непрерывную функцию. Обозначим ее через $F(t)$. Разумеется, она отличается от исходной функции $f(t)$, причем такое восстановление неоднозначно. Оно осуществляется оператором интерполяции **I**. Сама функция $F(t)$ называется интерполирующей, или интерполянтom. Необходимо оценить потерю информации при действии этого оператора, т. е. величину $|f(t) - F(t)|$, зависящую от типа оператора интерполяции и свойств $f(t)$, в частности ее гладкости. Таким образом, имеем схему

$$f(t) \xrightarrow{\mathbf{R}} \{f(t_n)\}_{n=0}^N \xrightarrow{\mathbf{I}} F(t).$$

Если функция $F(t)$ восстанавливается на $[a, b]$, то говорят о задаче *интерполяции*, если на отрезке $[c, d]$: $c \leq a$, $d \geq b$ и хотя бы одно из этих неравенств выполняется строго, то говорят о задаче *экстраполяции*.

6.2. Кусочно-линейная интерполяция

Простейший способ интерполяции — кусочно-линейная, требующая минимальных требований на гладкость функции $f(t)$. При таком способе интерполяции соседние точки (t_n, f_n) и (t_{n+1}, f_{n+1}) соединяют отрезками прямых

$$F(t) = \frac{f_{n+1}(t - t_n) + f_n(t_{n+1} - t)}{t_{n+1} - t_n}, \quad t \in [t_n, t_{n+1}].$$

Теорема 6.1. Пусть $f(t)$ — липшиц-непрерывная функция, т. е. $|f(t_1) - f(t_2)| \leq C |t_1 - t_2|$; тогда $|f(t) - F(t)| \leq C \frac{\tau}{2}$.

Примечание. Если сетка неравномерная и $\tau = \max_n (t_{n+1} - t_n)$, то теорема верна и для этого случая.

Доказательство. Пусть $t \in [t_n, t_{n+1}]$. Обозначим $\tau = t_{n+1} - t_n$. Тогда $t = t_n + \alpha\tau$; $0 \leq \alpha \leq 1$. В силу линейности $F(t)$ имеем равенство $F(t) = \alpha f_{n+1} + (1 - \alpha)f_n$.

Оценим разность

$$\begin{aligned} |F(t) - f(t)| &= |\alpha f_{n+1} + (1 - \alpha)f_n - \alpha f(t) - (1 - \alpha)f(t)| \leq \\ &\leq \alpha |f_{n+1} - f(t)| + (1 - \alpha) |f_n - f(t)|. \end{aligned}$$

Поскольку $f_{n+1} = f(t_n + \tau)$, имеем

$$\begin{aligned} |f_{n+1} - f(t)| &= |f(t_n + \tau) - f(t_n + \alpha\tau)| \leq |C(1 - \alpha)\tau| = \\ &= C(1 - \alpha)\tau, \quad \text{так как} \quad 0 \leq \alpha \leq 1. \end{aligned}$$

Аналогично $|f_n - f(t)| \leq C\alpha\tau$. В таком случае

$$|f(t) - F(t)| \leq 2\alpha(1 - \alpha)c\tau \leq C \frac{\tau}{2}.$$

Замечание. Простой аппарат кусочно-линейной интерполяции позволяет ввести объекты, на которых базируется вариант одного

где

$$\mathbf{A} = \begin{pmatrix} \varphi_0(t_0) & \varphi_1(t_0) & \cdots & \varphi_N(t_0) \\ \varphi_0(t_1) & \varphi_1(t_1) & \cdots & \varphi_N(t_1) \\ \cdots & \cdots & \cdots & \cdots \\ \varphi_0(t_N) & \varphi_1(t_N) & \cdots & \varphi_N(t_N) \end{pmatrix},$$

$$\mathbf{u} = (u_0, u_1, \dots, u_N)^T, \quad \mathbf{f} = (f_0, f_1, \dots, f_N)^T.$$

Теорема 6.2 (доказывается в курсе линейной алгебры).

Для того чтобы решение задачи интерполяции существовало и было единственным, необходимо и достаточно, чтобы система базисных функций $\varphi_n(t_k)$ была линейно независима.

Теорема 6.3 (доказывается в курсе линейной алгебры).

Для того чтобы система функций $\varphi_n(t_k)$ была линейной независимой в точках $t_0, \dots, t_n$, необходимо и достаточно, чтобы определитель матрицы Грама

$$\mathbf{C} = \mathbf{A}^* \mathbf{A} = \begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_N) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_N) \\ \cdots & \cdots & \cdots & \cdots \\ (\varphi_N, \varphi_0) & (\varphi_N, \varphi_1) & \cdots & (\varphi_N, \varphi_N) \end{pmatrix},$$

был отличен от нуля. Здесь каждый элемент матрицы Грама имеет вид

$$\gamma_{jk} = (\varphi_k, \varphi_j) = \sum_{i=0}^N \varphi_k(t_i) \varphi_j(t_i).$$

В случае если система функций $\{\varphi_j\}_0^N$ ортогональна на множестве точек $\{t_j\}_0^N$, решение задачи интерполяции значительно упрощается (напомним, что система функций $\{\varphi_j\}_0^N$ является ортогональной на множестве точек $\{t_j\}_0^N$, если $(\varphi_k, \varphi_j) = 0$ при $k \neq j$ и $(\varphi_k, \varphi_j) \neq 0$ при $k = j$ для всех $k = 0, 1, \dots, N$; $j = 0, 1, \dots, n$).

Дело в том, что матрица Грама для ортогональной системы функций диагональна и ее определитель отличен от нуля (всякая ортогональная система функций заведомо линейно незави-

ему узлу сетки так, что $\varphi_n^N(t_k) = \delta_k^n$. Заметим, что правильнее было бы писать $L_N(t, \{t_n\}, \{f_n\})$, т. е. интерполянт зависит от t , сетки и сеточной функции. Такой вид записи алгебраического интерполяционного полинома не единственен. Выписанный полином называется интерполяционным полиномом *в форме Лагранжа*. Он удобен для теоретического рассмотрения, но на практике часто оказывается более удобной другая форма представления — полином *в форме Ньютона*, о котором речь пойдет ниже.

6.5. Теорема об остаточном члене интерполяции

Остаточный член интерполяции для оценки погрешности определяется следующим образом:

$$R_N(t) = f(t) - L_N(t). \quad (6.1)$$

Теорема 6.4. Пусть функция $f(t)$ на отрезке $[a, b]$ имеет $N + 1$ ограниченную производную. Тогда

$$R_N(t) = \frac{f^{(N+1)}(\xi)}{(N+1)!} \prod_{j=0}^N (t - t_j),$$

где $\xi \in [a, b]$.

Доказательство. Рассмотрим функцию

$$\psi(x) = f(x) - L_N(x) - R_N(t) \frac{(x - t_0)(x - t_1) \dots (x - t_N)}{(t - t_0)(t - t_1) \dots (t - t_N)},$$

имеющую по крайней мере $N + 1$ производную. По условию эту производную имеет $f(x)$, а два остальных слагаемых — полиномы.

Кроме того, $\psi(x)$ на $[a, b]$ имеет по крайней мере $N + 2$ нуля. Их можно указать. Точки $x = t_n$ ($n = 0, \dots, N$) — нули, поскольку $f(t_n) = L(t_n)$, а последнее слагаемое обращается в них в нуль. $(N + 2)$ -м нулем является точка $x = t$ в силу определения остаточного члена. Далее, поскольку между каждыми двумя нулями непрерывно дифференцируемой функции имеется хотя бы один нуль ее производной, на $[a, b]$ имеется хотя бы $N + 1$ нуль ψ' . Применяя это рассуждение к $\psi'', \psi''', \dots$, можно показать, что существует точка $\xi \in [a, b]$ такая, что $\psi^{(N+1)}(\xi) = 0$.

Вычислим $(N+1)$ -ю производную правой части выражения для $F(x)$ с учетом того, что $L^{(N+1)} = 0$. Кроме того, в точке ξ

$$\begin{aligned} \Psi^{(N+1)}(\xi) &= f^{(N+1)}(\xi) - L^{(N+1)}(\xi) - \\ &\quad - \frac{d^{N+1}}{dx^{N+1}} \left[R_N(t) \cdot \frac{(x-t_0)\dots(x-t_N)}{(t-t_0)\dots(t-t_N)} \right]_{\xi}, \end{aligned}$$

$$L^{(N+1)}(\xi) = 0; \quad \Psi^{(N+1)}(\xi) = 0;$$

$$\frac{d^{N+1}}{dx^{N+1}} \left[\frac{(x-t_0)\dots(x-t_N)}{(t-t_0)\dots(t-t_N)} \right]_{x=\xi} = \frac{(N+1)!}{\prod_{j=0}^N (t-t_j)}.$$

Тогда

$$f^{(N+1)}(\xi) - R_N(t) \cdot \frac{(N+1)!}{\prod_{j=0}^N (t-t_j)} = 0,$$

откуда получим выражение для $R_N(t)$:

$$R_N(t) = \frac{f^{(N+1)}(\xi)}{(N+1)!} \prod_{j=0}^N (t-t_j).$$

Рассмотрим некоторые важные следствия этой теоремы.

Следствие 1 (точность интерполяции на равномерной сетке). Положим, что $t_n = n\tau$, $\tau = (b-a)/N$, $t \in [a, b]$ — сетка равномерная. В этом случае имеет место оценка

$$|R_N(t)| \leq \frac{\tau^{N+1}}{N+1} C, \quad C = \max_{t \in [a, b]} |f^{(N+1)}(t)|.$$

Доказательство. Пусть $t = t_k + \alpha\tau$, $\alpha \in [0, 1]$, $k=0, 1, \dots, N-1$.

Тогда $t - t_n = k\tau + \alpha\tau - n\tau = (k + \alpha - n)\tau$; откуда $\prod_{n=0}^N (t - t_n) = \tau^{N+1} \prod_{n=0}^N (k + \alpha - n)$. Можно показать, что $\prod_{n=0}^N |k + \alpha - n| \sim N!$.

Остаточный член оценивается следующим образом: $R_N(t) = \frac{f^{(N+1)}(\xi)}{(N+1)!} \prod_{n=0}^N (t - t_n)$, поэтому с учетом приведенных оценок получим

$$|R_N(t)| \leq \frac{\tau^{N+1}}{N+1} \max_{\xi \in [a, b]} |f^{(N+1)}(\xi)|.$$

Следствие 2 (точность задачи экстраполяции). Рассмотрим, как ведет себя оценка погрешности остаточного члена в задаче экстраполяции при удалении точки t от интервала $[t_0, t_N]$.

При $t \in [t_N, t_N + \tau]$ имеем

$$|R_N(t)| \leq \tau^{N+1} \max_{\xi \in [t_0, t_N + \tau]} |f^{(N+1)}(\xi)|,$$

поскольку $\prod_{n=0}^{N+1} |k + \alpha - n| \leq (N+1)!$.

При $t \in [t_N + \tau, t_N + 2\tau]$

$$|R_N(t)| \leq (N+2)\tau^{N+1} \max_{\xi \in [t_0, t_N + 2\tau]} |f^{(N+1)}(\xi)|,$$

так как для рассматриваемого интервала $\prod_{n=0}^{N+2} |k + \alpha - n| \sim (N+2)!$

При $t \in [t_N + 2\tau, t_N + 3\tau]$

$$|R_N(t)| \leq \frac{(N+2)(N+3)}{2!} \tau^{N+1} \max_{\xi \in [t_0, t_N + 3\tau]} |f^{(N+1)}(\xi)|$$

и так далее.

Видно, что ошибка экстраполяции растет быстро, но не сразу, экстраполяция допустима на интервалах $\sim O(\tau)$.

6.6. Интерполяционный полином в форме Ньютона

6.6.1. Разделенные и конечные разности.

Определение 6.1. Пусть задана система узлов $\{t_n\}_{n=0}^N$, $t_n \in [a, b]$, $t_0 = a$, $t_N = b$.

Разделенные разности нулевого порядка в точке t_i совпадают со значениями функции $f(t_i)$.

Разности первого порядка определяются для двух точек t_i, t_{i+1} равенством

$$f(t_i, t_{i+1}) = \frac{f(t_{i+1}) - f(t_i)}{t_{i+1} - t_i},$$

разности второго порядка для трех точек t_i, t_{i+1}, t_{i+2} — равенством

$$f(t_i, t_{i+1}, t_{i+2}) = \frac{f(t_{i+1}, t_{i+2}) - f(t_i, t_{i+1})}{t_{i+2} - t_i},$$

разности порядка k для $(k+1)$ -й точки — по рекуррентной формуле

$$f(t_i, t_{i+1}, \dots, t_{i+k}) = \frac{f(t_{i+1}, \dots, t_{i+k}) - f(t_i, \dots, t_{i+k-1})}{t_{i+k} - t_i}.$$

Методом математической индукции можно показать, что

$$f(t_i, t_{i+1}, \dots, t_{i+k}) = \sum_{j=0}^k \frac{f(t_{i+j})}{\prod_{\substack{r=0 \\ r \neq i+j}}^k (t_{i+j} - t_{i+r})}.$$

Кроме того, существует точка $\xi \in [a, b]$ такая, что

$$k! f(t_i, t_{i+1}, \dots, t_{i+k}) = f^{(k)}(\xi).$$

Отсюда следует, что разделенная разность есть симметричная функция своих аргументов $t_i, \dots, t_{i+k}$, и она не изменяется при их перестановке.

Для удобства вычислений введем таблицу разделенных разностей:

t_0	$f(t_0)$				
		$f(t_0, t_1)$			
t_1	$f(t_1)$		$f(t_0, t_1, t_2)$		
		$f(t_1, t_2)$			
t_2	$f(t_2)$		$\vdots$	$\vdots$	$f(t_0, \dots, t_n)$
$\vdots$	$\vdots$		$f(t_{n-2}, t_{n-1}, t_n)$		
		$f(t_{n-1}, t_n)$			
t_n	$f(t_n)$				

Пусть сетка — равномерная. Тогда конечной разностью первого порядка функции $f(t)$ в точке t_k с шагом τ называют величину $\Delta f_k = f_{k+1} - f_k$, где $f_k = f(t_k)$, второго порядка — величину

$$\Delta^2 f_k = \Delta f_{k+1} - \Delta f_k = f_{k+2} - 2f_{k+1} + f_k,$$

третьего —

$$\Delta^3 f_k = \Delta^2 f_{k+1} - \Delta^2 f_k = f_{k+3} - 3f_{k+2} + 3f_{k+1} - f_k,$$

четвертого —

$$\Delta^4 f_k = f_{k+4} - 4f_{k+3} + 6f_{k+2} - 4f_{k+1} + f_k.$$

При этом справедлива рекуррентная формула

$$\Delta^n f_k = \Delta^{n-1} f_{k+1} - \Delta^{n-1} f_k, \quad k \geq 1, \quad \Delta^0 f_k = f_k.$$

Методом математической индукции доказывается формула

$$\Delta^n f_k = \sum_{s=0}^n (-1)^{n-1} C_n^s f_{k+s},$$

где $C_i^s = \frac{i!}{s!(i-s)!}$ — биномиальные коэффициенты.

Нетрудно показать, например, используя формулу Лагранжа, что существует точка $\xi \in [a, b]$ такая, что $\tau^n f^{(n)}(\xi) = \Delta^n f_k$, $t_k \in [a, b]$, поэтому в вычислительных методах используется приближенная формула

$$f^{(n)}(t) \approx \frac{\Delta^n f_k}{\tau^n},$$

аналогичная тем формулам численного дифференцирования, что были получены в первой лекции методом неопределенных коэффициентов.

Заметим, что введенные конечные разности называют «разностями вперед». Аналогично можно ввести «разности назад»

$$\Delta f_k = f_k - f_{k-1},$$

$$\Delta^2 f_k = \Delta f_k - \Delta f_{k-1} = f_k - 2f_{k-1} + f_{k-2},$$

.....

$$\Delta^n f_k = \Delta^{n-1} f_k - \Delta^{n-1} f_{k-1}$$

и центральные разности

$$\begin{aligned}\Delta f_k &= f_{k+1/2} - f_{k-1/2}, \\ \Delta^2 f_k &= \Delta f_{k+1/2} - \Delta f_{k-1/2} = f_{k+1} - 2f_k + f_{k-1}, \\ &\dots\dots\dots \\ \Delta^n f_k &= \Delta^{n-1} f_{k+1/2} - \Delta^{n-1} f_{k-1/2}.\end{aligned}$$

Иногда для обозначения первых конечных разностей вперед и назад используют обозначения $\Delta^+ f_k$, $\Delta^- f_k$.

6.6.2. Интерполяционный полином в форме Ньютона. Интерполяционный полином может быть записан с использованием введенных выше разделенных разностей. Такая форма его записи называется интерполяционным полиномом в форме Ньютона. Полином имеет вид

$$\begin{aligned}N_n(t) &= f(t_1) + f(t_1, t_2)(t - t_1) + \dots + \\ &\quad + f(t_1, \dots, t_{n+1})(t - t_1) \dots (t - t_n).\end{aligned}$$

То, что это интерполяционный полином, может быть доказано, например, методом математической индукции. Отметим, что полином в форме Ньютона напоминает ряд Тейлора, а остаточный член интерполяционного полинома — остаточный член этого ряда. Достоинством записи интерполянта в форме Ньютона является то, что для повышения порядка полинома нет необходимости в его полной перестройке; достаточно лишь добавить к уже полученному выражению еще одно или несколько слагаемых. С помощью разделенных разностей можно оценивать погрешность интерполяции. Читатели могут предложить способ контроля точности вычислений, основанный на использовании разделенных разностей.

6.7. Минимизация остаточного члена интерполяции

Нас интересует решение следующей задачи на минимакс: найти

$$\min_{\{t_n\}_{n=0}^N} \left\{ \max_{t \in [-1, 1]} \left| \prod_{n=0}^N (t - t_n) \right| \right\},$$

чтобы путем выбора узлов сетки минимизировать остаточный член интерполяции. Эта задача была решена П. Л. Чебышёвым.

Теорема 6.5 (Чебышёва, без доказательства). Среди всех многочленов степени $n \geq 1$ со старшим коэффициентом a_n , равным единице, наименьшее уклонение от нуля, равное 2^{1-n} , имеет нормированный полином Чебышёва первого рода $\bar{T}_n(t) = 2^{1-n}T_n(t)$, $t \in [-1, 1]$.

Определение полиномов Чебышёва дано в Приложении 2. Там же приведена справка об основных свойствах этих функций.

Это свойство полиномов Чебышёва — наименьшее уклонение от нуля, — можно сформулировать по-другому: для любого полинома $P_n(t) = t^n + a_{n-1}t^{n-1} + \dots + a_0$, отличного от $\bar{T}_n(t)$, справедливо неравенство

$$2^{1-n} = \max_{[-1,1]} |\bar{T}_n(t)| < \max_{[-1,1]} |P_n(t)|, \quad t \in [-1, 1].$$

Если в качестве интерполяционных узлов выбрать нули полинома Чебышёва, то произведение $\prod_{j=0}^{N+1} (t - t_j)$, а также $R_n(t)$ будут наименее уклоняющимися от нуля.

6.8. Обусловленность задачи интерполяции. Постоянная Лебега

В процессе вычислений значения интерполируемой функции известны с некоторой погрешностью. При работе на вычислительной машине ошибки округления неизбежны. Возникает вопрос о чувствительности интерполяционного полинома к ошибкам начальных данных (обусловленности задачи интерполяции) и к ошибкам округления (вопрос вычислительной устойчивости). Интерполяционный полином — оператор, линейный по отношению к значениям интерполируемой функции. С учетом погрешности начальных данных полином в форме Лагранжа может быть записан следующим образом:

$$L_N(t) = \sum_{n=0}^N f_n \varphi_n^N(t) + \sum_{n=0}^N \delta f_n \varphi_n^N(t),$$

причем слагаемое

$$\Delta_N(t, \delta f) = \sum_{n=0}^N \delta f_n \varphi_n^N(t)$$

характеризует чувствительность к ошибкам начальных данных и ошибкам вычислений. Нас интересует оценка

$$\max_{t \in [a, b]} |\Delta_N(t, \delta f)| \leq l_N \delta; \quad \delta = \max_{t \in [a, b]} |\delta f_n|.$$

Введем в рассмотрение еще один объект. Пусть $\sum |\varphi_i^N(x)|$ — сумма модулей всех базисных функций. Обозначим ее $L(x) = \sum |\varphi_i^N(x)|$ — функция Лебега (сетки). Тогда константа Лебега $l_N = \sup_{x \in [a, b]} L(x)$.

Так как функция Лебега зависит лишь от расположения узлов сетки, то и константа Лебега зависит лишь от введенной сетки. Обусловленность и устойчивость задачи интерполяции зависят от константы Лебега.

Если рассматривать оператор интерполяции как оператор проекции (проектор), переводящий элемент одного пространства (пространства сеточных функций) в другое (пространство непрерывно дифференцируемых функций), то постоянная Лебега есть норма такого оператора проекции. Подробнее об этом в [29, 32].

Конечно, реальная погрешность при интерполяции будет заведомо меньше, чем приведенная выше оценка. Тем не менее, оценка является достижимой (это свойство нормы оператора). Наихудшим распределением погрешности будет такое распределение, когда погрешности максимальны и меняют знак от точки к точке. То, что при этом будет достижима приведенная выше оценка, следует из вида функции Лебега и каждой из базисных функций. Предлагаем читателям соответствующие построения провести самостоятельно.

Приведем (без доказательства) примерные оценки роста постоянной Лебега в зависимости от числа узлов сетки. Константа Лебега растет примерно как $l_N \sim 2^N$ для равномерной сетки и $l_N \sim \ln N$ для сетки с чебышёвским набором узлов. Доказано, что рост константы Лебега для последней сетки асимптотически стремится к минимально возможному, и сетка с чебышёвскими узлами близка к оптимальной для задач интерполяции.

6.9. Интерполяция с кратными узлами

Определение 6.2. Пусть в узлах сетки $\{t_n\}_{n=0}^M$ заданы не только значения функции $f(t_n)$, но и значения ее производных $f'(t_n)$, $f''(t_n)$, ..., $f^{(k_n-1)}(t_n)$. В этом случае узел t_n называется

кратным, а число k_n , равное количеству заданных значений производных в n -м узле, — кратностью узла.

Доказывается теорема о существовании единственного полинома $P_N(t)$, удовлетворяющего условиям

$$P_N(t_n) = f_n, \quad P'_N(t_n) = f'_n, \dots, P_N^{(k_n-1)}(t_n) = f_n^{k_n-1}, \\ N = k_0 + k_1 + \dots + k_M - 1.$$

Такой полином называется полиномом с кратными узлами. Отметим два частных случая.

а) в точке $t = t_0$ заданы $f_0, f'_0, \dots, f_0^{(N)}$ ($M = 0, k_0 = N + 1$).

Тогда многочлен $P_N(t)$, удовлетворяющий этим условиям, может быть записан как

$$P_N(t) = \sum_{i=0}^N f^{(i)}(t_0) \frac{(t - t_0)^i}{i!}.$$

Это — частичная сумма ряда Тейлора. Она является интерполантом с кратным узлом в точке $t = t_0$ кратности $N + 1$.

б) Пусть на концах отрезка $[t_0, t_1]$ заданы значения f_0, f_1, f'_0, f'_1 ($M = 1, k_0 = 2, k_1 = 2, N = 3$).

Тогда $P_3(t_0) = f_0, P'_3(t_0) = f'_0, P_3(t_1) = f_1, P'_3(t_1) = f'_1$, а интерполант имеет вид

$$P_3(t) = f_0 \frac{(t_1 - t)^2 (2(t - t_0) + \tau)}{\tau^3} + f'_0 \frac{(t_1 - t)^2 (t - t_0)}{\tau^2} + \\ + f_1 \frac{(t - t_0)^2 (2(t_1 - t) + \tau)}{\tau^3} + f'_1 \frac{(t - t_0)^2 (t - t_1)}{\tau^2},$$

здесь $\tau = t_1 - t_0$.

Такой многочлен называется кубическим интерполяционным многочленом Эрмита.

Теорема 6.6 (без доказательства). Пусть $f(t)$ имеет $N + 1$ ограниченную производную на отрезке $[a, b]$. Тогда погрешность интерполяционного многочлена Эрмита степени N выражается формулой

$$R_N(t) = \frac{f^{(N+1)}(\xi)}{(N+1)!} (t - t_0)^{k_0} (t - t_1)^{k_1} \dots (t - t_M)^{k_M},$$

где t_n — интерполяционные узлы, $n = 0, \dots, M$, k_i — кратность i -го узла, $\xi \in [a, b]$, $N = k_0 + k_1 + \dots + k_M - 1$.

Поставим теперь следующую задачу: построить кусочно-кубическую интерполирующую функцию, непрерывную на отрезке $[a, b]$ со своими двумя первыми производными.

Обозначим такую функцию $S(t)$; значения производных в узлах t_n обозначим $m_n = S'(t_n)$. Если задать в узлах t_n, t_{n+1} значение функции и ее первой производной, то получим эрмитов кусочно-кубический полином

$$S(t) = \frac{(t_{n+1} - t)^2 (2(t - t_n) + \tau)}{\tau^3} f_n + \frac{(t - t_n)^2 (2(t_{n+1} - t) + \tau)}{\tau^3} f_{n+1} + \\ + \frac{(t_{n+1} - t)^2 (t - t_n)}{\tau^2} m_n + \frac{(t - t_n)^2 (t - t_{n+1})}{\tau^2} m_{n+1},$$

или

$$S(z) = f_n(1 - z)^2(1 + 2z) + f_{n+1}z^2(3 - 2z) + \\ + m_n\tau_n z(1 - \tau)^2 - m_{n+1}\tau_n z^2(1 - z),$$

где $\tau_n = t_{n+1} - t_n$, $z = (t - t_n)/\tau_n$, $m_n = S'(t_n)$.

6.9.1. Замечание о тригонометрической интерполяции. Для периодической функции $f(t)$ с периодом T естественно строить приближение с использованием функций

$$\varphi_n(t) = a_n \cos \frac{\pi n t}{T} + b_n \sin \frac{\pi n t}{T}.$$

Тригонометрическая интерполяция состоит в замене $f(t)$ тригонометрическим многочленом

$$F_N(t) = \sum_{n=0}^N \varphi_n(t) = a_0 + \sum_{n=1}^N \left(a_n \cos \frac{\pi n t}{T} + b_n \sin \frac{\pi n t}{T} \right),$$

коэффициенты которого находятся при решении СЛАУ

$$F_N(t_k) = f(t_k), \quad k = 1, \dots, 2N + 1, \quad t_{2N+1} - t_0 = T.$$

Здесь $\{t_k\}_{k=0}^{2N+1}$ — последовательность узлов интерполяции.

6.10. Кусочно-многочленная глобальная интерполяция (сплайны)

Определение 6.3. Пусть на отрезке $[a, b]$ задана система узловых точек (сетка) $\{t_n\}_{n=0}^{N-1}$. Сплайном $S_m(t)$ называется определенная на $[a, b]$ функция, имеющая l непрерывных производных и являющаяся на каждом интервале (t_{n-1}, t_n) многочленом степени m .

Определение 6.4. Дефектом сплайна называется разность $d = m - l$ между степенью сплайна и показателем его гладкости l .

Для сплайнов также используется обозначение $S_{m,d}(t)$.

Определение 6.5. Если сплайн строится так, чтобы выполнялись условия $S_m(t_n) = f(t_n)$, где $f(t)$ — интерполируемая функция, то он называется интерполяционным сплайном.

В соответствии с определением кусочно-линейная функция является интерполяционным сплайном первой степени дефекта 1, кусочно-квадратичная функция с первой непрерывной производной — интерполяционным сплайном второй степени дефекта 1. Самым известным в приложениях является интерполяционный кубический сплайн дефекта 1 (естественный сплайн), который будем обозначать $S(t)$.

Определение 6.6. Кубическим сплайном дефекта 1, интерполирующим на отрезке $[a, b]$ заданную функцию $f(t)$, называется функция $S(t)$, удовлетворяющая следующим условиям:

1. $S(t_n) = f(t_n)$ — условие интерполяции в узлах сетки $\{t_n\}_{n=0}^{N-1}$.

2. $S(t) \in C^2[a, b]$, т. е. является непрерывной вместе с двумя первыми производными.

3. На каждом отрезке $[t_n, t_{n+1}]$, $S(t)$ является кубическим многочленом; $n = 0, \dots, N-1$.

4. На краях отрезка $[a, b]$ заданы краевые условия и часто употребляются следующие:

4.1. $S'(a) = f'(a)$, $S'(b) = f'(b)$;

4.2. $S''(a) = f''(a)$, $S''(b) = f''(b)$; часто полагают $S''(a) = S''(b) = 0$;

4.3. $S(a) = S(b)$, $S'(a) = S'(b)$; эти условия называются *периодическими*, т. е. интерполируемая функция является периодической с периодом $b - a$.

Покажем, что эта задача имеет единственное решение.

Теорема 6.7. *Интерполяционный кубический сплайн $S(t)$, удовлетворяющий условиям 1–3 и одному из краевых условий 4, существует и единственен.*

Доказательство. Пусть $S(z)$ — эрмитов кубический многочлен, который на каждом отрезке $[t_n, t_{n+1}]$, $n = 0, \dots, N-1$, представлен как

$$S(z) = f_n(1-z)^2(1+2z) + f_{n+1}z^2(3-2z) + m_n\tau_n z(1-z)^2 - m_{n+1}\tau_n z^2(1-z),$$

где $\tau_n = t_{n+1} - t_n$, $z = (t - t_n)/\tau_n$, $m_n = S'(t_n)$. Тогда

$$S''(t) = \frac{(f_{n+1} - f_n)(6 - 12z)}{\tau_n^2} + m_n \frac{6z - 4}{\tau_n} + m_{n+1} \frac{6z - 2}{\tau_n},$$

$$S''(t_n + 0) = 6 \frac{f_{n+1} - f_n}{\tau_n^2} - \frac{4m_n}{\tau_n} - \frac{2m_{n+1}}{\tau_n},$$

$$S''(t_n - 0) = -6 \frac{f_n - f_{n-1}}{\tau_{n-1}^2} + \frac{2m_{n-1}}{\tau_{n-1}} + m_{n+1} \frac{4m_n}{\tau_{n-1}}.$$

Условие непрерывности второй производной $S''(t_n + 0) = S''(t_n - 0)$ будет

$$r_n m_{n-1} + 2m_n + s_n m_{n+1} = c_n,$$

$$c_n = 3 \left(s_n \frac{f_{n+1} - f_n}{\tau_n} + r_n \frac{f_n - f_{n-1}}{\tau_{n-1}} \right), \quad s_n = \frac{\tau_{n-1}}{\tau_{n-1} + \tau_n}, \quad r_n = 1 - s_n,$$

$$n = 1, \dots, N-1.$$

После добавления краевых условий получаем систему из $N+1$ уравнения с $N+1$ неизвестным m_n . Для краевых условий первого типа (заданы первые производные) система выглядит как

$$m_0 = f'_0,$$

$$r_n m_{n-1} + 2m_n + s_n m_{n+1} = c_n,$$

$$m_N = f'_N.$$

Для условий второго типа (заданы вторые производные)

$$\begin{aligned} 2m_0 + m_1 &= 3 \frac{f_1 - f_0}{\tau_0} - \frac{\tau_0}{2} f_0'', \\ r_n m_{n-1} + 2m_n + s_n m_{n+1} &= c_n, \\ m_{N-1} + 2m_N &= 3 \frac{f_N - f_{N-1}}{\tau_{N-1}} + \frac{\tau_{N-1}}{2} f_N''. \end{aligned}$$

Аналогично получается СЛАУ для третьего типа краевых условий.

Во всех случаях матрицы СЛАУ оказываются трехдиагональными симметричными, со строгим диагональным преобладанием и, как показывается, положительно определенными, а следовательно, и неособенными. Следовательно, решение СЛАУ существует и единственно. Отсюда следует существование и единственность решения задачи о построении кубического сплайна.

Приведем еще одно доказательство этой же теоремы.

Доказательство. Рассмотрим неравномерную сетку: $t_n - t_{n-1} = \tau_{n-1}$, $t_{n+1} - t_n = \tau_n$. В узлах сетки определены значения функции: f_{n-1} , f_n , f_{n+1} . Пусть m_n — значение второй производной в точке t_n (пока неизвестное!). На отрезке $[t_n, t_{n+1}]$ для второй производной кусочно-кубического сплайна имеем

$$S''_{tt} = \frac{1}{\tau_n} (m_n(t_{n+1} - t) + m_{n+1}(t - t_n)). \quad (6.2)$$

Так как сплайн — полином третьей степени, то его вторая производная — линейная функция. Интегрируем (6.2) по t , получаем (на отрезке $[t_n, t_{n+1}]$)

$$S'_t = \frac{1}{2\tau_n} (m_n(t_{n+1} - t)^2 - m_{n+1}(t - t_n)^2) + A_n,$$

где A_n — константа интегрирования.

Интегрируя последнее соотношение еще раз, получаем

$$\begin{aligned} S(t) &= \frac{1}{6\tau_n} (m_n(t_{n+1} - t)^3 + m_{n+1}(t - t_n)^3) + A_n t + B_n = \\ &= \frac{1}{6\tau_n} (m_n(t_{n+1} - t)^3 + m_{n+1}(t - t_n)^3) + \alpha_n(t_{n+1} - t) + \beta_n(t - t_n). \end{aligned}$$

После второго интегрирования мы положили

$$A_n t + B_n = (\beta_n + \alpha_n)t + \alpha_n t_{n+1} - \beta_n t_n,$$

т. е. вместо двух констант A_n, B_n введем две новые константы, более удобные для дальнейших выкладок.

Из условий $S(t_n) = f_n$, $S(t_{n+1}) = f_{n+1}$, получаем

$$\begin{aligned} f_n &= \frac{m_n \tau_n^2}{6} + \alpha_n \tau_n \Rightarrow \alpha_n = \frac{f_n}{\tau_n} - \frac{m_n \tau_n}{6}, \\ f_{n+1} &= \frac{m_{n+1} \tau_n^2}{6} + \beta_n \tau_n \Rightarrow \beta_n = \frac{f_{n+1}}{\tau_n} - \frac{m_{n+1} \tau_n}{6}. \end{aligned}$$

Приравнявая первые производные в t_n справа и слева: $S'_t(t_n + 0) = S'_t(t_n - 0)$, получим систему уравнений для определения коэффициентов сплайна:

$$\begin{aligned} \frac{m_n \tau_{n-1}}{2} - \frac{m_{n-1} \tau_{n-1}}{2} + \frac{f_n - f_{n-1}}{\tau_{n-1}} - \frac{(m_n - m_{n-1}) \tau_{n-1}}{6} = \\ = \frac{m_{n+1} \tau_n}{2} - \frac{m_n \tau_n}{2} + \frac{f_{n+1} - f_n}{\tau_n} - \frac{(m_{n+1} - m_n) \tau_n}{6}, \end{aligned} \quad (6.3)$$

которая дополняется соответствующими граничными условиями. В случае свободного сплайна $m_0 = m_N = 0$.

Систему для определения коэффициентов, называемых *моментами кубического сплайна*, можно записать в матричной форме

$$\mathbf{A}\mathbf{M} = \mathbf{F},$$

где $\mathbf{A}$ — квадратная матрица:

$$\mathbf{A} = \begin{pmatrix} \frac{\tau_1 + \tau_2}{3} & \frac{\tau_2}{6} & 0 & \dots & 0 & 0 \\ \frac{\tau_2}{6} & \frac{\tau_2 + \tau_3}{3} & \frac{\tau_3}{6} & \dots & 0 & 0 \\ 0 & \frac{\tau_3}{6} & \frac{\tau_3 + \tau_4}{3} & \dots & 0 & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & \frac{\tau_{N-1}}{6} & \frac{\tau_N + \tau_{N-1}}{3} \end{pmatrix}$$

$\mathbf{M}$ и $\mathbf{F}$ — векторы-столбцы:

$$\mathbf{M} = (m_1, m_2, \dots, m_{N-1})^T,$$

$$\mathbf{F} = \left(\frac{f_2 - f_1}{\tau_1} - \frac{f_1 - f_0}{\tau_0}, \frac{f_3 - f_2}{\tau_2} - \frac{f_2 - f_1}{\tau_1}, \dots, \frac{f_N - f_{N-1}}{\tau_N} - \frac{f_{N-1} - f_{N-2}}{\tau_{N-1}} \right)^T.$$

Матрица **A** симметрична, имеет свойство диагонального преобладания и, как можно показать, положительно определена, а следовательно, неособенная. Значит, решение рассматриваемой СЛАУ существует и единственно. Следовательно, и задача о построении кубического сплайна имеет единственное решение. Для других типов краевых условий доказательство проводится аналогично. Метод решения такой СЛАУ описан в Приложении 3 — прогонка.

Теорема 6.8 (без доказательства). Для функции $f(t) \in C^4[a, b]$ и интерполирующего ее сплайна $S(t)$, построенного на сетке $\{t_n\}_{n=0}^N$, имеют место следующие неравенства:

$$\|f(t) - S(t)\|_{[a,b]} \leq M_4 \tau^4,$$

$$\|f'(t) - S'(t)\|_{[a,b]} \leq M_4 \tau^3,$$

$$\|f''(t) - S''(t)\|_{[a,b]} \leq M_4 \tau^2,$$

где $M_4 = \|f^{(4)}(t)\|_{[a,b]}$, $\tau = \max_n (t_{n+1} - t_n)$.

Отсюда следует, что при $\tau \rightarrow 0$ последовательность функций $S^{(k)}(t)$, $i = 0, 1, 2$ (кубический сплайн и первые две его производные) сходится, соответственно, к $f^{(k)}(t)$.

Теорема 6.9 (экстремальное свойство кубических сплайнов, без доказательства). Пусть сплайн $S(t)$ интерполирует функцию $f(t)$ на системе узлов

$$\{t_n\}_{n=0}^N; \quad t_0 = a, \quad t_N = b.$$

Тогда $S(t)$ с краевыми условиями $S''(a) = S''(b) = 0$ доставляет минимум функционалу

$$\int_a^b [F'''(t)]^2 dt$$

среди всех функций $F(t) \in C_2^2[a, b]$, т. е. функций, имеющих интегрируемые с квадратом вторые производные $\left(\int_a^b [F''(t)]^2 dt\right)$ и интерполирующих $f(t)$ на отрезке $[a, b]$.

Локальный сплайн. Локальная форма сплайн-интерполяции предложена В. С. Рябенкиным [?, 33]. Рассмотрим неравномерную сетку: $t_n - t_{n-1} = h_{n-1}$, $t_{n+1} - t_n = h_n$. В узлах сетки определены значения функции: f_{n-1} , f_n , f_{n+1} . Не вдаваясь в детали, приведем важные для практического использования формулы в случае постоянного шага сетки $h = \text{const}$.

Построим интерполяционный полином второго порядка $P_2(x)$ в форме Ньютона $(d - f_n)/h$:

t_{n-1}	f_{n-1}	$\frac{f_n - f_{n-1}}{h}$	$\frac{f_{n-1} - 2f_n + f_{n+1}}{h^2}$
t_n	f_n		
t_{n+1}	f_{n+1}	$\frac{f_{n+1} - f_n}{h}$	

$$P_2(t, f_n) = f_{n-1} + \frac{f_n - f_{n-1}}{h}(t - t_{n-1}) + \frac{f_{n-1} - 2f_n + f_{n+1}}{h^2}(t - t_{n-1})(t - t_n). \quad (6.4)$$

Этот полином приближает f на отрезке $[t_{n-1}, t_{n+1}]$ с точностью до $o(h^2)$. Рассмотрим теперь полином

$$Q_5(t, f_n) = P_2(t, f_n) + \frac{h^3}{2} \left\{ \frac{f_{n+2} - 3f_{n+1} + 3f_n - f_{n-1}}{h^3} \times \right. \\ \left. \times \left(\frac{t - t_n}{h} \right)^3 \left(\frac{t - t_{n+1}}{h} \right) \left(3 - \frac{2(t - t_n)}{h} \right) \right\},$$

представляющий собой аппроксимацию функции f на отрезке $[t_{n-1}, t_{n+1}]$ с непрерывными первой и второй производными. В [2] доказано, что выражение (6.4) аппроксимирует $f_x^{(m)}$ с порядком $o(h^{3-m})$ во всех точках отрезка. Так как коэффициенты сплайна зависят от значений функции лишь в четырех соседних точках и для определения коэффициентов (6.4) не требуется решать систему линейных уравнений, такая кусочно-гладкая интерполяция называется *локальным сплайном*.

З а м е ч а н и е. $Q_5(t, f_n)$ уже не обладает экстремальным свойством.

6.11. В-сплайны

Сплайны с локальным носителем (*В-сплайны*). В последнее время в вычислительной практике широкое распространение получили *В-сплайны* (от английского слова bell — колокол), сосредоточенные на конечном носителе. Они используются как для интерполяции функций, так и в качестве базисных функций при построении методов типа конечных элементов.

Для подробного ознакомления с приложениями *В-сплайнов* и *В-сплайнами* произвольной степени рекомендуется обратиться к [30, 31] и современным публикациям. В данной лекции ограничимся наиболее распространенными случаями *В-сплайнов* порядка 2 и 3.

Определение 6.7. *В-сплайном, или базисным сплайном степени $N-1$ дефекта 1 относительно узлов $\{t_i\}_{i=n}^{n+N}$ называется функция*

$$B_{N-1,n}(t) = B_{N-1}(t_n, t_{n+1}, \dots, t_{n+N}, t) = N \sum_{i=n}^{n+N} \frac{(t_i - t)_{\max}^{N-1}}{\prod_{\substack{j=n \\ j \neq i}}^{n+N} (t_i - t_j)},$$

$$(t_i - t)_{\max}^{N-1} = \begin{cases} (t_i - t)^{N-1}, & t \leq t_i, \\ 0, & t > t_i. \end{cases}$$

Пусть $t_{n+i} = t_n + i\tau$, т. е. рассматривается случай равномерной сетки.

Рассмотрим несколько частных случаев *В-сплайнов*.

1. $N = 2$. В этом случае сплайн строится наиболее просто.

$$\begin{aligned} B_{1,n}(t) &= B_1(t_n, t_{n+1}, t_{n+2}, t) = 2 \left[\frac{(t_n - t)_{\max}}{(t_n - t_{n+1})(t_n - t_{n+2})} + \right. \\ &\quad \left. + \frac{(t_{n+1} - t)_{\max}}{(t_{n+1} - t_n)(t_{n+1} - t_{n+2})} + \frac{(t_{n+2} - t)_{\max}}{(t_{n+2} - t_n)(t_{n+2} - t_{n+1})} \right] = \\ &= \frac{1}{\tau^2} \left[(t_n - t)_{\max} - 2(t_{n+1} - t)_{\max} + (t_{n+2} - t)_{\max} \right], \end{aligned}$$

или

$$B(t) = \begin{cases} \frac{1}{\tau^2} (t_n - t - 2t_{n+1} + 2t + t_{n+2} - t) = 0, & t \leq t_n, \\ \frac{1}{\tau^2} (0 - 2t_{n+1} + 2t + t_{n+2} - t) = \frac{1}{\tau} + \frac{t - t_{n+1}}{\tau^2}, & t_n \leq t \leq t_{n+1}, \\ \frac{1}{\tau^2} (0 - 0 + t_{n+2} - t) = \frac{1}{\tau} - \frac{t - t_{n+1}}{\tau^2}, & t_{n+1} \leq t \leq t_{n+2}, \\ 0, & t \geq t_{n+2}. \end{cases}$$

Это функция «крышка», или «крышечка». Она часто используется в качестве базисной функции в методах конечных элементов.

Рассмотрим случай B -сплайна 2-го порядка, задаваемого формулой

$$B_{2,n}(t) = \begin{cases} x^2; & x = \frac{t - t_{n-2}}{t_{n-1} - t_{n-2}}, \quad t \in [t_{n-2}, t_{n-1}]; \\ 1 + 2x - x^2; & x = \frac{t - t_{n-1}}{t_n - t_{n-1}}, \quad t \in [t_{n-1}, t_n]; \\ 2 - x^2; & x = \frac{t - t_n}{t_{n+1} - t_n}, \quad t \in [t_n, t_{n+1}]; \\ (1 - x)^2; & x = \frac{t - t_{n+1}}{t_{n+2} - t_{n+1}}, \quad t \in [t_{n+1}, t_{n+2}]. \end{cases}$$

При $t < t_{n-2}$, $t > t_{n+2}$, $B_{2,n}(t) \equiv 0$. Построенный сплайн обладает следующими свойствами:

- а) $(B_2)'_t(t_{n-2}) = (B_2)'_t(t_{n+2}) = 0$;
- б) $B_2(t_{n-1}) = B_2(t_{n+1}) = 1$;
- в) $B_2(t_{n-2}) = B_2(t_{n+2}) = 0$.

При интерполяции функций можно поступить таким способом. Заметим, что для интерполяции с помощью сплайна необходимо потребовать выполнения условия

$$b_{i-1}B_{2,i-1} + b_iB_{2,i} + b_{i+1}B_{2,i+1} = f_i,$$

где b — коэффициенты интерполяции, B_2 — B -сплайн, индекс указывает на точку носителя, в которой сплайн достигает своего максимума. Система таких соотношений, естественно, дополняется граничными условиями. Получившаяся система для определения коэффициентов разложения будет иметь трехдиагональную матрицу с диагональным преобладанием при выполнении ограничения на длины соседних шагов: они должны различаться не более чем в $(1 + \sqrt{13})/2$ раза [30].

2. $N = 4$ (кубический B -сплайн) имеет вид

$$B_{3,n}(t) = \frac{1}{6\tau^4} \left[(t_n - t)_{\max}^3 - 4(t_{n+1} - t)_{\max}^3 + 6(t_{n+2} - t)_{\max}^3 - \right. \\ \left. - 4(t_{n+3} - t)_{\max}^3 + (t_{n+4} - t)_{\max}^3 \right],$$

или, после несложных упрощений,

$$B_{3,n}(t) = \begin{cases} 0, & t \geq t_n, \\ \frac{1}{6\tau^4}(t - t_n)^3, & t_n \leq t \leq t_{n+1}, \\ \frac{1}{6\tau} + \frac{1}{2\tau^2}(t - t_{n+1}) + \\ \quad + \frac{1}{2\tau^3}(t - t_{n+1})^2 - \frac{1}{2\tau^4}(t - t_{n+1})^3, & t_{n+1} \leq t \leq t_{n+2}, \\ \frac{1}{6\tau} + \frac{1}{2\tau^2}(t_{n+3} - t) + \\ \quad + \frac{1}{2\tau^3}(t_{n+3} - t)^2 - \frac{1}{2\tau^4}(t_{n+3} - t)^3, & t_{n+2} \leq t \leq t_{n+3}, \\ \frac{1}{6\tau^4}(t_{n+4} - t)^3, & t_{n+3} \leq t \leq t_{n+4}, \\ 0, & t \geq t_{n+4}. \end{cases}$$

Базисные сплайны заданной степени являются линейно независимыми функциями и образуют базис в функциональных пространствах, что можно использовать для представления с их помощью других функций этих же пространств. Например, любая кусочно-постоянная функция на отрезке, составленном из равных интервалов, может быть единственным образом представлена как линейная комбинация B -сплайнов нулевой степени, любая кусочно-линейная функция — B -сплайнов первой степени и т. д. Базисные сплайны играют существенную роль при построении численных методов решения задач математической физики, например метода конечных элементов в теории приближения функций, при решении задач компьютерной графики.

Для последнего класса задач также используются функции Бернштейна:

$$B_n^N(t) = \frac{N!}{n!(N-n)!} \frac{(b-t)^{N-n}(t-a)^n}{(b-a)^N}, \quad n = 0, \dots, N, \quad t \in [a, b].$$

Функции Бернштейна иногда определяют в форме рекуррентного соотношения:

$$B_{-1}^N(t) = 0, \quad B_0^0(t) = 1, \quad B_i^N(t) = \frac{(b-t)B_i^{N-1}(t) + (t-a)B_{i-1}^{N-1}(t)}{b-a},$$

$$i = 0, \dots, n, \quad B_{N+1}^N(t) = 0.$$

Такие рекуррентные последовательности применяются при вычислениях с целью уменьшения ошибок округления.

Функции Бернштейна являются базисными для построения кривых Безье, активно используемых в компьютерной графике и техническом дизайне, появившихся в результате работ Безье и де Кастильо над формами автомобилей фирм Рено и Ситроен. Подробнее о функциях Бернштейна см. в [26].

6.12. Интерполяция функций двух переменных

Пусть сетка образована пересечением прямых $x = x_n$, $n = 0, \dots, N$, и $y = y_m$, $m = 0, \dots, M$; $f_{nm} = f(x_n, y_m)$ — значение функции в узле x_n, y_m . Воспользуемся, например, аппаратом кусочно-многочленной интерполяции. Для этого сначала реализуется кусочно-многочленная интерполяция заданной степени по x на каждой прямой $y = y_m$. Затем при каждом значении $x = x_n$ реализуется кусочно-многочленная интерполяция по y с учетом значений функции, полученных на первом шаге. Так, в случае кусочно-линейной интерполяции по обоим переменным этот метод приводит (для случая прямоугольника $x \in [x_n, x_{n+1}]$, $y \in [y_n, y_{n+1}]$) к интерполяционному многочлену

$$F(x, y) = f_{nm} \frac{(x - x_{n+1})(y - y_{m+1})}{(x_n - x_{n+1})(y_m - y_{m+1})} + f_{n+1, m} \frac{(x - x_n)(y - y_{m+1})}{(x_{n+1} - x_n)(y_m - y_{m+1})} +$$

$$+ f_{n+1, m+1} \frac{(x - x_n)(y - y_m)}{(x_{n+1} - x_n)(y_{m+1} - y_m)} + f_{n, m+1} \frac{(x - x_{n+1})(y - y_m)}{(x_n - x_{n+1})(y_{m+1} - y_m)}.$$

Сходным образом можно провести последовательную лагранжеву интерполяцию, но при каждом фиксированном значении m , затем — при каждом фиксированном значении n с учетом первого шага интерполяции. Общая формула такого интерполянта аналогична одномерной формуле для интерполяционного полинома

в форме Лагранжа:

$$L_{NM}(x, y) = \sum_{n=0}^N \sum_{m=0}^M f_{nm} \prod_{\substack{i=0 \\ i \neq n}}^N \prod_{\substack{j=0 \\ j \neq m}}^M \frac{(x - x_i)(y - y_j)}{(x_n - x_i)(y_m - y_j)}.$$

Если f_A, f_B, f_D — значение функции $f(x, y)$ в вершинах A, B, D некоторого треугольника на треугольной расчетной сетке, то вычислить приближенное значение функции внутри этого треугольника можно с помощью билинейной функции $f(x, y) \approx F(x, y) = ax + by + c$, находя коэффициенты a, b, c из условий

$$ax_A + by_A + c = f_A,$$

$$ax_B + by_B + c = f_B,$$

$$ax_D + by_D + c = f_D,$$

где $\{x_A, y_A\}, \{x_B, y_B\}, \{x_D, y_D\}$ — координаты вершин A, B, D . Погрешность такой интерполяции для функции $f(x, y)$ с непрерывными вторыми производными будет $O(h^2)$, где h — длина наибольшей стороны треугольника D .

6.13. Примеры решения задач

1. Выписать интерполяционные полиномы первой и второй степени в форме Лагранжа и Ньютона.

Решение. Интерполяционные полиномы первой и второй степени в форме Лагранжа:

$$L_1(t) = f(t_0) \frac{t - t_1}{t_0 - t_1} + f(t_1) \frac{t - t_0}{t_1 - t_0},$$

$$L_2(t) = f(t_0) \frac{(t - t_1)(t - t_2)}{(t_0 - t_1)(t_0 - t_2)} + f(t_1) \frac{(t - t_0)(t - t_2)}{(t_1 - t_0)(t_1 - t_2)} + f(t_2) \frac{(t - t_0)(t - t_1)}{(t_2 - t_0)(t_2 - t_1)},$$

где t_0, t_1, t_2 — узлы интерполяции, $f(t_1), f(t_2), f(t_3)$ — значения интерполируемой функции.

Интерполяционные полиномы первой и второй степени в форме Ньютона:

$$N_1(t) = f(t_1) + \frac{f(t_2) - f(t_1)}{t_2 - t_1}(t - t_1),$$

$$N_2(t) = f(t_1) + \frac{f(t_2) - f(t_1)}{t_2 - t_1}(t - t_1) +$$

$$+ \frac{1}{t_3 - t_1} \left[\frac{f(t_3) - f(t_2)}{t_3 - t_2} - \frac{f(t_2) - f(t_1)}{t_2 - t_1} \right] (t - t_1)(t - t_2).$$

2. Сравните количество арифметических действий, требуемое для вычисления интерполяционного полинома, записанного в двух формах:

$$L_N(x) = a_0 + a_1t + \dots + a_nt^n,$$

$$L_N(x) = a_0 + t(a_1 + t(a_2 + t(\dots(a_{n-1} + c_nt)\dots))) \text{ (схема Горнера).}$$

Решение. В первом случае для вычисления значения в одной точке требуется $\frac{n}{2}(n+1)$ умножений и n сложений. Во втором — n умножений и n сложений.

3. Задана система узлов интерполяции:

$$t_i = t_0 + \frac{t_n - t_0}{n-1}(i-1), \quad i = 1, \dots, n.$$

Какова погрешность интерполяции, если $n = 3$?

Решение. Сделаем замену переменных в выражении для остаточного члена:

$$R_3(t) = (t - t_0) \left(t - \frac{t_0 + t_n}{2} \right) (t - t_n), \quad t = \frac{t_0 + t_n}{2} + \frac{t_n - t_0}{2}z, \quad z \in [-1; 1].$$

Получим

$$R_3(t) = \frac{(t_n - t_0)^3}{2}(z^3 - z).$$

Полученный кубический полином имеет на $[-1; 1]$ экстремумы в точках

$$z_{1,2} = \pm \frac{1}{\sqrt{3}}.$$

$$\text{В таком случае } \max |R_3(t)| = \|R_3(t)\| = \frac{(t_n - t_0)^3}{12\sqrt{3}}.$$

4. Предложите простой рекуррентный алгоритм вычисления коэффициентов a_i ($i = 0, \dots, N-1$) интерполяционного полинома

$$P_N(t) = a_0 + a_1(t - t_0) + \dots + a_N(t - t_0) \dots (t - t_{N-1}).$$

Решение. Для коэффициентов полинома получаем систему линейных уравнений с треугольной матрицей:

$$a_0 = f_0,$$

$$a_0 + a_1(t_1 - t_0) = f_1,$$

$$a_0 + a_1(t_2 - t_0) + a_2(t_2 - t_0)(t_2 - t_1) = f_2,$$

$$\dots\dots\dots$$

$$a_0 + a_1(t_N - t_0) + \dots + a_N(t_N - t_0) \dots (t_N - t_{N-1}) = f_N,$$

которая легко решается от первого уравнения к последнему:

$$a_0 = f_0, \quad a_1 = \frac{f_1 - f_0}{t_1 - t_0}, \quad a_2 = \frac{1}{t_2 - t_1} \left(\frac{f_2 - f_1}{t_2 - t_1} + \frac{f_1 - f_0}{t_1 - t_0} \right), \dots$$

5. Оценить погрешность приближения функции $\ln t'$ ($t' = 1.23$) при помощи интерполяционного полинома второй степени по точкам 1.1; 1.2; 1.3.

Решение. Остаточный член интерполяции будет

$$R_N(t) = \frac{f^{(N+1)}(\xi)}{(N+1)!} (t - t_0) \dots (t - t_N);$$

при $N = 2$ имеем

$$\varepsilon = |f(x) - L_2(t)| \leq \frac{\max_{[1.1; 1.3]} |f^{(3)}(t)|}{6} |(t - t_0)(t - t_1)(t - t_2)|,$$

$$\max_{[1.1; 1.3]} |f^{(3)}(t)| = \frac{2}{(1.1)^3} \approx 1.5.$$

В таком случае

$$\begin{aligned} \varepsilon &= |\ln(t') - L_2(t)| \leq \frac{1.5}{6} |(1.23 - 1.1)(1.23 - 1.2)(1.23 - 1.3)| \approx \\ &\approx 6.9 \cdot 10^{-5}. \end{aligned}$$

6. Показать, что погрешность интерполяции может быть выражена следующим образом:

$$f(t) - L_N(t) = (t - t_0) \dots (t - t_N) f(t, t_0, \dots, t_N),$$

где $f(t, t_0, \dots, t_N)$ — разделенная разность порядка N .

Решение. Из выражения для разделенной разности порядка $N + 1$

$$\begin{aligned} f(t, t_0, \dots, t_N) &= \frac{f(t)}{(t - t_0) \dots (t - t_N)} + \\ &+ \frac{f(t_0)}{(t_0 - t)(t_0 - t_1) \dots (t_0 - t_N)} + \dots + \frac{f(t_N)}{(t_N - t)(t_N - t_0) \dots (t_N - t_{N-1})}, \end{aligned}$$

получим выражение для $f(t)$:

$$\begin{aligned} f(t) &= f(t_0) \frac{(t - t_1) \dots (t - t_N)}{(t_0 - t_1) \dots (t_0 - t_N)} + \dots + f(t_N) \frac{(t - t_0) \dots (t - t_{N-1})}{(t_N - t_0) \dots (t_N - t_{N-1})} + \\ &+ (t - t_0) \dots (t - t_N) \cdot f(t, t_0, \dots, t_N) = \\ &= L_N(t) + (t - t_0) \dots (t - t_N) \cdot f(t, t_0, \dots, t_N). \end{aligned}$$

Тогда

$$f(t) - L_N(t) = (t - t_0) \dots (t - t_N) \cdot f(t, t_0, \dots, t_N).$$

Сравнивая полученное выражение с выражением для остаточного члена интерполяции

$$R_N(t) = f(t) - L(t) = \frac{f^{(N+1)}(\xi)}{(N+1)!} (t - t_0) \dots (t - t_N),$$

приходим к выводу, что для некоторой точки $\xi \in [t_0, t_N]$ имеет место соотношение между разделенной разностью и производной порядка $N + 1$:

$$f(t, t_0, \dots, t_N) = \frac{f^{(N+1)}(\xi)}{(N+1)!}.$$

7. Пусть значения функции $f(t)$ заданы в узлах интерполяции t_1, t_2, t_3 . Построить функцию $g(t) = \frac{a_0 + a_1 t}{d_0 + t}$, для которой выполнялось бы условие интерполяции $g(t_i) = f(t_i)$, $i = 1, 2, 3$ (задача дробно-линейной интерполяции).

Решение. Из условий интерполяции $g(t_i) = \frac{a_0 + a_1 t_i}{d_0 + t_i} = f(t_i)$, $i = 1, 2, 3$ получаем систему трех линейных уравнений:

$$\begin{aligned} a_0 + a_1 t_1 - d_0 f_1 &= t_1 f_1, \\ a_0 + a_1 t_2 - d_0 f_2 &= t_2 f_2, \\ a_0 + a_1 t_3 - d_0 f_3 &= t_3 f_3. \end{aligned}$$

Вводя обозначения

$$\tau_n = t_n - t_{i-1}, \quad \bar{\tau} = \frac{\tau_n + \tau_{n+1}}{2}, \quad \Delta_n f = \frac{f_n - f_{n-1}}{\tau_n},$$

$$\Delta_{n+1} f = \frac{f_{n+1} - f_n}{\tau_{n+1}}, \quad \delta_n f = \frac{\Delta_{n+1} f - \Delta_n f}{\bar{\tau}}$$

и применив метод последовательного исключения неизвестных, получим

$$a_0 = \frac{2t_n \Delta_n f \Delta_{n+1} f - f_n t_n \delta_n f}{\delta_n(tf)},$$

$$a_1 = f_n - 2\Delta_n f \Delta_{n+1} f, \quad d_0 = -\frac{t \delta_n(tf)}{\delta_n f}.$$

Здесь учтено, что $\delta_n(tf) = t_n \delta_n f + \frac{f_{n+1} + f_{n-1}}{\bar{\tau}_n}$.

Разумеется, знаменатель дробно-рационального выражения не должен обращаться в нуль на рассматриваемом отрезке.

Библиографический комментарий к Лекции 6

Об алгоритмах интерполяции можно прочесть в учебниках [1–5]. Свойства тригонометрической интерполяции подробно обсуждаются в [1]. Наглядное представление о свойствах основных алгоритмов алгебраической и тригонометрической интерполяции можно получить при выполнении лабораторной работы [7]. При проведении практических занятий рекомендуется использовать задачи из пособия [8]. О сплайн-интерполяции и применении алгоритмов сплайн-функций (в частности, в инженерной графике) см. [30]. О свойствах B -сплайнов подробнее в [31], о применении кривых Безье в инженерной геометрии — в [26]. Некоторые вопросы теории приближения функций (в частности, свойства функции Лебега различных сеток) описаны в [29, 32].

ЧИСЛЕННОЕ ИНТЕГРИРОВАНИЕ

Исследуются простейшие квадратурные формулы интерполяционного типа — прямоугольников, трапеций, Симпсона. Для оценки реальной погрешности формул используется правило Рунге. Дается понятие о квадратурных формулах Гаусса. Рассматриваются методы вычисления многомерных интегралов.

Ключевые слова: квадратурные формулы интерполяционного типа. Правильные квадратурные формулы. Кубатурные формулы. Квадратуры Гаусса.

В данной лекции будет рассматриваться задача численного интегрирования. Формулы численного интегрирования функций одного переменного называют *квадратурными формулами*, нескольких переменных — *кубатурными формулами*. Задача приближенного вычисления определенного интеграла (на отрезке или по многомерной области) фактически разбивается на две самостоятельные подзадачи. Первая — это интегрирование таблично заданной функции, полученной, например, при проведении лабораторного эксперимента. В таком случае априорная информация о гладкости подынтегральной функции отсутствует, весьма ограничены возможности в выборе узлов интегрирования. Для этой задачи наиболее эффективными будут квадратурные формулы интерполяционного типа и правило Рунге оценки погрешности.

Вторая задача — подсчет значения определенного интеграла от известной функции. При этом самая ресурсоемкая операция с точки зрения вычислений — подсчет значения функции. Желательно построить численный метод, позволяющий получать как можно более высокую точность при наименьшем количестве вычислений, при этом выбор узлов квадратурных формул — целиком в руках вычислителя. В этом случае наиболее эффективными окажутся квадратурные формулы типа Гаусса.

7.1. Квадратурные формулы интерполяционного типа (формулы Ньютона–Котеса)

Пусть необходимо вычислить интеграл

$$I = \int_a^b f(x) dx.$$

Если подынтегральная функция непрерывна, то верно равенство

$$I = \int_a^b f(x) dx = (b-a) \bar{f}.$$

Черта над буквой здесь обозначает интегральное среднее.

Заметим, что интеграл $I = \int_a^b f(x) dx$ линейной заменой переменного интегрирования может быть сведен к $I = \int_{-1}^1 \tilde{f}(y) dy$. Поэтому без ограничения общности будем рассматривать формулы численного интегрирования на отрезке $[-1; 1]$.

Для вычисления интегрального среднего в правой части выражения используем следующий прием. Вычислим значение подынтегральной функции в некоторых точках, принадлежащих отрезку интегрирования $f(x_k) = f_k$, а затем приблизим среднее значение, вычисляя сумму с весами

$$\tilde{f} = \sum b_k f_k.$$

Формулы для вычисления определенных интегралов от функции одного переменного называют *квадратурными формулами* (квадратурами). Точки, в которых вычисляются значения функций, называются *узлами квадратуры*. Коэффициенты, с помощью которых вычисляется среднее значение, называются *весами квадратуры*. Для весов квадратуры, очевидно, должно выполняться $\sum b_k = 1$.

Ниже мы увидим, что для формул интерполяционного типа веса квадратуры однозначно определяются выбором узлов.

Рассмотрим задачу вычисления интеграла

$$I = \int_{-1}^1 f(x) dx.$$

Квадратурную формулу для него запишем в виде

$$I = \int_{-1}^1 f(x) dx \approx 2 \sum b_k f(x_k).$$

Здесь в явном виде учтена длина отрезка интегрирования.

Выберем узлы квадратуры на отрезке, а саму функцию заменим ее интерполяционным полиномом. В этом случае будем иметь на рассматриваемом отрезке приводимые ниже квадратурные формулы.

Формула трапеций. Узлы квадратуры — концы отрезка. Построим интерполяционный полином в форме Лагранжа

$$L_1(x) = f(-1) \cdot \frac{1}{2}(1-x) + f(1) \cdot \frac{1}{2}(x+1).$$

Вычисляя интеграл от этой линейной интерполяции функции, получим

$$\begin{aligned} I &\approx \int_{-1}^1 L_1(x) dx = \\ &= f(-1) \cdot \frac{1}{2} \int_{-1}^1 (1-x) dx + f(1) \cdot \frac{1}{2} \int_{-1}^1 (x+1) dx = f(-1) + f(1). \end{aligned}$$

Сравнивая с приведенной выше формой записи квадратурной формулы, получаем формулу трапеций на отрезке

$$I = \int_{-1}^1 f(x) dx \approx 2 \left(\frac{1}{2} f(-1) + \frac{1}{2} f(1) \right).$$

Формула Симпсона. Теперь заменим подынтегральную функцию полиномом второй степени

$$\begin{aligned} f(x) &\approx L_2(x) = \\ &= f(-1) \cdot \frac{1}{2} x(1-x) + f(0)(1-x)(x+1) + f(1) \cdot \frac{1}{2} x(x+1). \end{aligned}$$

После интегрирования получим

$$I = \int_{-1}^1 f(x) dx \approx 2 \left(\frac{1}{6} f(-1) + \frac{2}{3} f(0) + \frac{1}{6} f(1) \right).$$

Правило 3/8. Аналогично, заменив подынтегральную функцию интерполяционным полиномом третьей степени, построенным

по четырем равноотстоящим точкам, получим выражение интеграла «правило 3/8»:

$$I \approx 2\left(\frac{1}{8}f(-1) + \frac{3}{8}f\left(-\frac{1}{3}\right) + \frac{3}{8}f\left(\frac{1}{3}\right) + \frac{1}{8}f(1)\right).$$

Квадратурные формулы интерполяционного типа более высокого порядка рассматриваются редко по двум важным взаимосвязанным причинам. Заметим, что все полученные формулы являются *правильными*, так как все веса квадратурных формул были положительными. При использовании интерполяционных полиномов более высоких степеней получающиеся квадратурные формулы перестают быть правильными: для полиномов степени выше седьмой среди весов квадратурных формул появляются отрицательные величины. Более того, Д. Пойа показал, что

$$\lim_{n \rightarrow \infty} \sum_{k=0}^n |b_{nk}| = \infty,$$

в то время как для самой суммы

$$\sum_{k=0}^n b_{nk} = 1.$$

Здесь b_{nk} — веса квадратурных формул, получающихся при замене $f(x)$ интерполяционным полиномом степени n . Такое увеличение суммы абсолютных значений весов квадратурных формул связано с быстрым ростом постоянной Лебега при алгебраической интерполяции на равномерной сетке.

Квадратурные формулы с разбиением отрезка интегрирования на элементарные отрезки. Пусть имеется некоторое разбиение отрезка $[a, b]$:

$$a = x_0 < x_1 < \dots < x_n = b.$$

Тогда в качестве приближения значения интеграла можно использовать интегральную сумму

$$I = \sum_{k=0}^{n-1} (x_{k+1} - x_k) f(\xi_k), \quad x_k \leq \xi_k \leq x_{k+1}.$$

Последняя формула точна в том случае, если $f(x)$ постоянна на каждом отрезке разбиения (т. е. для многочленов степени ноль).

Оказывается, если в качестве узлов квадратурной формулы взять центральную точку элементарного интервала

$$\xi_k = 0.5(x_k + x_{k+1}),$$

то квадратурная формула будет точна и для линейной функции на каждом отрезке разбиения. При любом выборе узлов эта формула носит название (составной) *формулы прямоугольников*.

К вычислению интеграла можно подойти как к вычислению площади под кривой, и тогда в предположении кусочно-линейной интерполяции подынтегральной функции на каждом отрезке разбиения получается *формула трапеций* (или *составная формула трапеций*) для приближенного вычисления интеграла:

$$I \approx \sum_{k=0}^{n-1} \frac{h_k}{2} (f(x_k) + f(x_{k+1})), \quad h_k = x_{k+1} - x_k.$$

Составная формула Симпсона получается с помощью построения квадратичной интерполяции подынтегральной функции по трем равноотстоящим узлам x_i , $x_{i+1/2}$, x_{i+1} на каждом отрезке разбиения

$$f(x) \approx P_2(x) = f(x_k) + f(x_k, x_{k+1})(x - x_k) + \\ + f(x_k, x_{k+1}, x_{k+1/2})(x - x_k)(x - x_{k+1}),$$

что приводит к интегральной формуле вида

$$I \approx \sum_{k=0}^{n-1} \frac{h_k}{6} (f(x_k) + 4f(x_{k+1/2}) + f(x_{k+1})), \quad h_k = x_{k+1} - x_k.$$

Для разбиения полного отрезка интегрирования на вдвоенные интервалы равной длины можно получить формулу Симпсона несколько другого вида:

$$I \approx \sum_{k=0}^{[n/2]} \frac{h_{2k}}{3} (f(x_{2k}) + 4f(x_{2k+1}) + f(x_{2k+2})).$$

Аналогично, интерполируя подынтегральную функцию полиномом третьей степени по четырем равноотстоящим точкам, получим выражение интеграла в соответствии с «*правилом 3/8*»:

$$I \approx \sum_{k=0}^{n-1} \frac{h_k}{8} (f(x_k) + 3f(x_{k+1/3}) + 3f(x_{k+2/3}) + f(x_{k+1})).$$

7.2. Оценка погрешности квадратурных формул

Оценка погрешности квадратурных формул Ньютона–Котеса производится через оценку остаточного члена погрешности интерполяции подынтегральной функции.

1. Формула прямоугольников при произвольном выборе узла интерполяции на отрезке разбиения дает погрешность для отдельного интервала разбиения $\xi_k \in [x_k, x_{k+1}]$

$$\begin{aligned} \epsilon_k &\leq \max_{x_k \leq x \leq x_{k+1}} |f'(x)| \int_{x_k}^{x_{k+1}} |x - \xi_k| dx \leq \\ &\leq \frac{1}{2} \max_{x_k \leq x \leq x_{k+1}} |f'(x)| (x_{k+1} - x_k)^2 = \frac{1}{2} \max_{x_k \leq x \leq x_{k+1}} |f'(x)| h_k^2, \end{aligned}$$

а при суммировании по всем отрезкам равной длины с учетом равенства $\sum_k h_k = b - a$ будем иметь формулу первого порядка аппроксимации

$$\epsilon \leq \frac{1}{2} \max_{a \leq x \leq b} |f'(x)| (b - a) h.$$

Для формулы прямоугольников с центральной точкой для получения более точной оценки погрешности интегрирования интерполяцию по значению в средней точке нужно рассматривать как интерполяцию с кратным узлом, в котором известно не только значение функции, но и производная. В этом случае интерполяционный многочлен совпадает с отрезком ряда Тейлора из двух членов, а погрешность интегрирования на отдельном интервале выражается остаточным членом

$$\epsilon_k \leq \max_{x_k \leq x \leq x_{k+1}} |f''(x)| \int_{x_k}^{x_{k+1}} |(x - x_{k+1/2})^2| dx = \frac{1}{24} \max_{x_k \leq x \leq x_{k+1}} |f''(x)| h_k^3.$$

Тогда суммарная погрешность на отрезке

$$\epsilon \leq \frac{1}{24} \max_{a \leq x \leq b} |f''(x)| (b - a) h^2.$$

2. Оценка погрешности формулы трапеций получается интегрированием остаточного члена погрешности линейной интерпо-

ляции для отдельного интервала:

$$\epsilon_k \leq \max_{x_k \leq x \leq x_{k+1}} |f''(x)| \int_{x_k}^{x_{k+1}} |(x - x_k)(x - x_{k+1})| dx = \frac{1}{12} \max_{x_k \leq x \leq x_{k+1}} |f''(x)| h_k^3.$$

Суммарная погрешность

$$\epsilon \leq \frac{1}{12} \max_{a \leq x \leq b} |f''(x)| (b - a) h^2.$$

Как видим, формула прямоугольников со средней точкой и формула трапеций являются формулами второго порядка аппроксимации, однако константа погрешности у формулы прямоугольников в два раза меньше.

3. Оценка погрешности формулы Симпсона, как и в случае формулы прямоугольников со средней точкой, может быть повышена на единицу, если рассматривать среднюю точку интервала как кратный узел интерполяции с известной производной. Тогда интерполяционный многочлен Эрмита представляется в виде суммы обычного интерполяционного многочлена второго порядка, построенного по трем точкам, и добавочного слагаемого, возникшего из-за кратного узла интерполяции:

$$P_3(x) = P_2(x) + f(x_k, x_{k+1}, x_{k+1/2}, x_{k+1/2})(x - x_k)(x - x_{k+1})(x - x_{k+1/2}). \quad (7.1)$$

В (7.1) под разделенной разностью с кратными узлом понимается предел

$$f(x_k, x_{k+1}, x_{k+1/2}, x_{k+1/2}) = \lim_{\epsilon \rightarrow 0} f(x_k, x_{k+1}, x_{k+1/2} - \epsilon, x_{k+1/2} + \epsilon).$$

Для дифференцируемой функции этот предел существует и конечен.

Добавочный член к $P_2(x)$ является нечетной функцией относительно середины интервала интерполяции, поэтому интеграл от него по отрезку $[x_k, x_{k+1}]$ обращается в ноль.

Остаточный член интерполяции позволяет оценить погрешность интегрирования по формуле Симпсона на элементарном

отрезке

$$\begin{aligned} \varepsilon_k &\leq \frac{1}{24} \max_{x_k \leq x \leq x_{k+1}} |f^{IV}(x)| \int_{x_k}^{x_{k+1}} |(x-x_k)(x-x_{k+1/2})^2(x-x_{k+1})| dx = \\ &= \frac{1}{2880} \max_{x_k \leq x \leq x_{k+1}} |f^{IV}(x)| h_k^5 \end{aligned}$$

и на всем интервале интегрирования

$$\varepsilon \leq \frac{b-a}{2880} \max_{a \leq x \leq b} |f^{IV}(x)| h^4.$$

Аналогично, для формулы со сдвоенными интервалами интерполяции будем иметь оценку погрешности:

$$\varepsilon \leq \frac{b-a}{180} \max_{a \leq x \leq b} |f^{IV}(x)| h^4.$$

4. Хотя формула «правило 3/8» строится по большему числу узлов интерполяции, чем формула Симпсона, но для нее невозможно улучшить оценку, как и для формулы трапеций. Правило 3/8 также четвертого порядка аппроксимации:

$$\varepsilon \leq \frac{b-a}{6480} \max_{a \leq x \leq b} |f^{IV}(x)| h^4.$$

Правило Рунге, экстраполяция Ричардсона. Опишем один простой практический способ оценки реальной погрешности квадратурной формулы. Вначале изложим обычную теорию, как она описывается в большинстве источников. Пусть к приближенному вычислению значения I данного интеграла применяется некая квадратурная формула p -го порядка аппроксимации I^p из семейства составных формул Ньютона–Котеса. Вычисляется интеграл от табличной функции, заданной на равномерной сетке. При условии, что подынтегральная функция является p раз непрерывно дифференцируемой, существует константа c такая, что выполняется условие

$$I = I^p(h) + c h^p. \quad (7.2)$$

Как было показано выше при рассмотрении погрешности составных квадратурных формул, эта константа зависит лишь от коэффициентов выбранного метода интегрирования и от значения производной подынтегральной функции в некоторой точке сетки.

В действительности эта константа нам неизвестна — при переходе от «обычной» интегрируемой функции к ее сеточной проекции большинство информации о функции утрачено. При уменьшении шага интегрирования вдвое будем иметь

$$I = I^p\left(\frac{h}{2}\right) + c_1 \cdot \left(\frac{h}{2}\right)^p. \quad (7.3)$$

При малых h постоянные c и c_1 близки (их отличие есть величина $O(h)$), тогда из (7.2) и (7.3) следует

$$I^p(h) + ch^p = I^p\left(\frac{h}{2}\right) + c_1 \cdot \left(\frac{h}{2}\right)^p \approx I^p\left(\frac{h}{2}\right) + c \cdot \left(\frac{h}{2}\right)^p.$$

Отсюда можем найти константу в оценке погрешности квадратурной формулы

$$c \approx c_1 \approx \frac{I^p(h/2) - I^p(h)}{h^p - (h/2)^p}. \quad (7.4)$$

Тогда можно получить уточненное значение интеграла:

$$I \approx I^p\left(\frac{h}{2}\right) + \frac{I^p(h/2) - I^p(h)}{(2^p - 1)}. \quad (7.5)$$

К полученному равенству (7.5) можно относиться двояко:

1) для контроля точности (*правило Рунге* практического оценивания погрешности):

$$I - I^p(h/2) \approx \frac{I^p(h/2) - I^p(h)}{(2^p - 1)}; \quad (7.6)$$

его применение считается правомочным, если выполнено неравенство

$$\left| \frac{2^p (I^p(h/2) - I^p(h))}{I^p(h) - I^p(2h)} - 1 \right| < 0.1;$$

2) для повышения порядка точности вычисления интеграла (*экстраполяция Ричардсона*)

$$I^{p+1} = I^p\left(\frac{h}{2}\right) + \frac{I^p(h/2) - I^p(h)}{(2^p - 1)} + O(h^{p+1}). \quad (7.7)$$

Практически вместо приведенной выше последовательности формул используют несколько другой алгоритм. С половинным шагом интеграл подсчитать невозможно — просто не хватает точек в таблице. Тогда вместо (7.3) используем

$$I = I^p(2h) + c_2 \cdot (2h)^p.$$

Далее, как и ранее,

$$I^p(h) + ch^p = I^p(2h) + c_2 \cdot (2h)^p \approx I^p(2h) + c \cdot (2h)^p$$

Вместо (7.4) имеем оценку

$$c \approx c_1 \approx \frac{I^p(2h) - I^p(h)}{h^p - (2h)^p}.$$

и вместо (7.6), (7.7) легко получается

$$I - I^p(h) \approx \frac{I^p(h) - I^p(2h)}{(2^p - 1)}, \quad (7.8)$$

$$I^{p+1} \approx I^p(h) + \frac{I^p(h) - I^p(2h)}{(2^p - 1)}. \quad (7.9)$$

7.3. Квадратурные формулы Гаусса

Поскольку формулы Ньютона–Котеса являются интерполяционными, очевидно, что они не могут успешно использоваться для получения формул высокой точности по причине неустойчивости интерполяционного процесса для многочленов высокого порядка. Как отмечалось выше, постоянные Лебега растут с увеличением количества узлов интерполяции для равномерной сетки как 2^N . По этой причине обычно используются полиномы степени от нуля до трех (соответственно, формулы прямоугольников со средней точкой, трапеций, Симпсона, 3/8). Вычисление с их помощью интегралов от функций, обладающих высокой степенью гладкости (например, близким к полиномам высокой степени), представляется нерациональным. В выражения для погрешности этих формул входят первая, вторая или четвертая производные. Погрешность определяется низким порядком производной при высокой степени гладкости интегрируемой функции. Этих недостатков лишены квадратуры Гаусса.

Формулировка задачи построения квадратурных формул, поставленная Гауссом, такова. Для заданного количества точек, а именно, для $N + 1$ точки, найти такое расположение узлов и такие веса c_i , чтобы квадратурная формула

$$\int_a^b f(x) dx = \sum_{i=0}^N c_i f(x_i) + r_N$$

была точной для полиномов как можно более высокой степени, т. е. чтобы $r_N = 0$.

Пояснение. Для некоторых классов функций существуют квадратурные формулы с $r_N(x) = 0$, которые называются точными. Примером такого класса функций являются полиномы

$$P_N(x) = \sum_{k=0}^N a_k x^k$$

на отрезке $[a, b]$. Определим на этом отрезке узлы x_i , $i = 1, \dots, N$ и веса c_i так, что

$$\int_a^b P_N(x) dx = \sum_{i=0}^N c_i P_N(x_i).$$

Представим $P_N(x)$ в виде интерполяционного полинома

$$P_N(x) = \sum_{i=0}^N P_N(x_i) \prod_{\substack{k=0 \\ k \neq i}}^N \frac{(x - x_k)}{(x_i - x_k)},$$

при этом остаточный член интерполяции полинома равен нулю: $P_N^{(N+1)}(x) = 0$. Тогда из предыдущего условия следует

$$c_i = \int_a^b \prod_{\substack{k=0 \\ k \neq i}}^N \frac{(x - x_k)}{(x_i - x_k)} dx,$$

где веса c_i являются интегралами от базисных функций полиномов Лагранжа. Квадратурная формула

$$\int_a^b P_N(x) dx = \sum_{i=0}^N c_i P_N(x_i)$$

является точной для любого полинома степени N . Оказывается, эта формула может быть точной и для полиномов более высокой степени, а именно $2N + 1$, что используется при построении квадратурных формул Гаусса.

Пусть формула численного интегрирования имеет вид

$$I = \int_a^b f(x) dx = c_0 f(x_0) + c_1 f(x_1) + \dots + c_N f(x_N) + r_N,$$

где c_i — веса, r_N — остаточный член квадратуры.

Положим, что существует многочлен $P_M(x)$ степени $M > N$, для которого квадратурная формула точна, т.е. $r_N = 0$ при $f(x) = P_M(x)$:

$$f(x) = P_M(x) = a_0 + a_1 x + a_2 x^2 + \dots + a_M x^M,$$

где a_i — коэффициенты. В этом случае получим

$$\begin{aligned} a_0 \int dx + a_1 \int x dx + a_2 \int x^2 dx + \dots + a_M \int x^M dx = \\ = c_0 (a_0 + a_1 x_0 + a_2 x_0^2 + \dots + a_M x_0^M) + \\ + c_1 (a_0 + a_1 x_1 + a_2 x_1^2 + \dots + a_M x_1^M) + \dots + \\ + c_N (a_0 + a_1 x_N + a_2 x_N^2 + \dots + a_M x_N^M). \end{aligned}$$

Приравняем выражения в обеих частях равенства при a_j :

$$\begin{aligned} c_0 + c_1 + \dots + c_N &= \int_a^b dx = I_0, \\ c_0 x_0 + c_1 x_1 + \dots + c_N x_N &= \int_a^b x dx = I_1, \\ &\dots\dots\dots \\ c_0 x_0^M + c_1 x_1^M + \dots + c_N x_N^M &= \int_a^b x^M dx = I_M. \end{aligned}$$

Получается нелинейная система из $N+1$ уравнения с $2(N+1)$ неизвестными c_i, x_i . Отсюда следует, что максимальное значение M есть $2N+1$. Решение этой системы или исследование на

его существование и единственность в общем случае затруднительны. Ниже будет рассмотрен пример получения квадратурной формулы Гаусса таким путем для двух узлов.

Гаусс решил эту задачу более простым (в смысле реализации, но не решения!) способом, доказав следующую теорему. Приведем ее без доказательства.

Теорема 7.1. *Если в качестве узлов $x_i, i = 0, \dots, N$ в квадратурной формуле используются нули полиномов Лежандра $q_{N+1}(x)$, а веса c_i вычисляются по формулам*

$$c_i = \int_{-1}^1 \prod_{\substack{k \neq i \\ k=0}}^N \frac{(x - x_k)}{(x_i - x_k)} dx,$$

то квадратурная формула

$$\int_{-1}^1 f(x) dx = \sum_{i=0}^N c_i f(x_i) + r_N$$

точна для полиномов степени $2N + 1$.

Полиномы Лежандра описаны в Приложении 2.

Погрешность квадратурной формулы Гаусса на отрезке будет $r_N(x) = 2^{2(N+1)+1} \alpha_N f^{(2(N+1))}(\xi)$, при этом $\xi \in [-1; 1]$. Для $\xi \in [a, b]$ формула остаточного члена будет $r_N(x) = (b - a)^{2(N+1)+1} \alpha_N f^{(2(N+1))}(\xi)$, причем коэффициент α_N быстро убывает с ростом N . Здесь $\alpha_N = \frac{[(N+1)!]^4}{\{[2(N+1)]!\}^3 [2(N+1)+1]}$.

Формулы Гаусса обеспечивают высокую точность уже при небольшом количестве узлов (от 4 до 10). В этом случае $\alpha_2 \approx 5 \cdot 10^{-7}$, $\alpha_3 \approx 6 \cdot 10^{-10}$, $\alpha_4 \approx 4 \cdot 10^{-13}$. В практических же вычислениях число узлов составляет от нескольких сотен до нескольких тысяч. Отметим также, что веса квадратур Гаусса всегда положительны, что обеспечивает устойчивость алгоритма

вычисления сумм $\sum_{i=0}^N c_i f(x_i)$.

7.4. Вычисление интегралов от функций с особенностями

Пусть требуется вычислить несобственный интеграл

$$\int_a^b f(x) dx$$

от функции, обращающейся в бесконечность в некоторой точке $c \in [a, b]$. В этом случае интеграл обычно разбивают на два:

$$\int_a^b f(x) dx = \lim_{\substack{\delta_1 \rightarrow 0 \\ \delta_2 \rightarrow 0}} \left(\int_a^{c-\delta_1} f(x) dx + \int_{c+\delta_2}^b f(x) dx \right).$$

Числа δ_1 и δ_2 выбирают малыми величинами так, чтобы выполнялась оценка

$$\left| \int_{c-\delta_1}^{c+\delta_2} f(x) dx \right| < \frac{1}{2}\epsilon,$$

где ϵ — заданное малое положительное число (точность вычисления интеграла). После этого по квадратурным формулам вычисляют определенные интегралы $I_1 = \int_a^{c-\delta_1} f(x) dx$ и $I_2 =$

$\int_{c+\delta_2}^b f(x) dx$ с точностью $\epsilon/4$ каждый. После таких вычислений за приближенное значение интеграла с особенностью принимают

$\int_a^b f(x) dx$ с точностью $\epsilon/4$ каждый. После таких вычислений за приближенное значение интеграла с особенностью принимают

$\int_a^b f(x) dx \approx I_1 + I_2$ (с точностью ϵ).

Другой способ вычисления интеграла от функции с особенностью, называемый методом Канторовича выделения особенностей, состоит в следующем. Представим подынтегральную функцию в виде суммы:

$$\int_a^b f(x) dx = \int_a^b g(x) dx + \int_a^b [f(x) - g(x)] dx.$$

При этом $g(x)$ подбирают так, чтобы она была интегрируемой, а разность $[f(x) - g(x)]$ — ограниченной.

Пр и м е р. Вычислить $I = \int_0^1 \frac{dx}{\sqrt{x(1+x^2)}}$.

Представим I как сумму двух интегралов $I = I_1 + I_2$, где

$$I_1 = \int_0^1 \frac{dx}{\sqrt{x}}, \quad I_2 = \int_0^1 \left[\frac{1}{\sqrt{x(1+x^2)}} - \frac{1}{\sqrt{x}} \right] dx.$$

Интеграл I_1 вычисляется аналитически, а I_2 , поскольку подынтегральная функция ограничена, можно вычислить по квадратным формулам.

Аналогично можно поступить и в следующей задаче:

$$\int_0^1 \frac{e^{-x^2}}{\sqrt{x}} dx = \int_0^1 \frac{1-x^2}{\sqrt{x}} dx + \int_0^1 \frac{e^{-x^2} - 1 + x^2}{\sqrt{x}} dx.$$

Интегрирование быстро осциллирующих функций типа $I = \int_a^b f(x)e^{i\omega x} dx$ можно проводить, заменив $f(x)$ на интерполяционный полином, $I \approx \int_a^b P_N(x)e^{i\omega x} dx$. Этот интеграл вычисляется явно.

7.5. Кратные интегралы

Рассмотрим, для примера двукратный интеграл по прямоугольной области $\Omega (a \leq x \leq b, c \leq y \leq d)$. Аналогично одномерному случаю, в соответствии с формулой прямоугольников (со средней точкой) заменим функцию ее значением в точке пересечения диагоналей прямоугольника. В таком случае получим

$$I = \int_a^b \int_c^d f(x, y) dx dy \approx S f\left(\frac{a+b}{2}, \frac{c+d}{2}\right),$$

где $S = \tau_x \tau_y$, $\tau_x = b - a$, $\tau_y = d - c$. Если разбить прямоугольник на прямоугольные ячейки S_i , то получим аналог формулы прямоугольников со средней точкой в виде суммы по i : $I \approx \sum_i S_i f(x_i, y_i)$,

где S_i — площадь i -й прямоугольной ячейки, x_i, y_i — координаты точки пересечения ее диагоналей.

Применим теперь формулу Симпсона для вычисления двукратного интеграла путем редукции к методу вычисления одномерного интеграла, для чего представим двойной интеграл как

$$I = \int_a^b \int_c^d f(x, y) dx dy = \int_a^b dx \int_c^d f(x, y) dy.$$

Сначала применим формулу Симпсона для вычисления внешнего интеграла:

$$I \approx \frac{\tau_x}{6} \left[\int_c^d f(a, y) dy + 4 \int_c^d f\left(\frac{a+b}{2}, y\right) dy + \int_c^d f(b, y) dy \right].$$

Теперь применим формулу Симпсона для каждого из трех полученных интервалов:

$$I_1 = \int_c^d f(a, y) dy \approx \frac{\tau_y}{6} \left[f(a, c) + 4f\left(a, \frac{c+d}{2}\right) + f(a, d) \right],$$

$$I_2 = \int_c^d f\left(\frac{a+b}{2}, y\right) dy \approx \frac{\tau_y}{6} \left[f\left(\frac{a+b}{2}, c\right) + 4f\left(\frac{a+b}{2}, \frac{c+d}{2}\right) + f\left(\frac{a+b}{2}, d\right) \right],$$

$$I_3 = \int_c^d f(b, y) dy \approx \frac{\tau_y}{6} \left[f(b, c) + 4f\left(b, \frac{c+d}{2}\right) + f(b, d) \right].$$

Подставляя приближенные формулы для вычисления интегралов I_1, I_2, I_3 в формулу для вычисления I , получим

$$\begin{aligned} I \approx \frac{\tau_x \tau_y}{36} & \left\{ f(a, c) + f(a, d) + f(b, c) + f(b, d) + \right. \\ & + 4 \left[f\left(a, \frac{c+d}{2}\right) + f\left(b, \frac{c+d}{2}\right) + f\left(\frac{a+b}{2}, c\right) + f\left(\frac{a+b}{2}, d\right) \right] + \\ & \left. + 16f\left(\frac{a+b}{2}, \frac{c+d}{2}\right) \right\}. \end{aligned}$$

Если область интегрирования не является прямоугольной, то ее можно сделать подобластью большей по площади прямоугольной области, которую в свою очередь разбить на прямоугольные ячейки. Ячейки в этом случае разделяются на внутренние, к ним применяются приведенные формулы численного интегрирования, и граничные, не прямоугольные, площади которых вычисляются по более сложным алгоритмам. При этом приближенное значение интеграла, например при использовании формулы средних, можно записать как $I \approx \sum I_{\text{вн}}^i + \sum I_{\text{гр}}^j$, где $I_{\text{вн}}^i$ — приближенное значение интегралов по внутренним ячейкам, $I_{\text{гр}}^j$ — по граничным, i, j — номера ячеек с площадями S_i и S_j .

7.6. Идея метода Монте-Карло

Метод Монте-Карло используется, как правило, для вычисления кратных интегралов. Рассмотрим задачу вычисления интеграла по многомерному кубу:

$$I = \int_0^1 \int_0^1 \dots \int_0^1 f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n.$$

Для его вычисления можно построить кубатурные формулы, используя процедуру последовательного интегрирования, заменяя кратный интеграл I на

$$I = \int_0^1 dx_1 \int_0^1 dx_2 \dots \int_0^1 dx_n f(x_1, x_2, \dots, x_n).$$

Проблема вычисления подобных интегралов заключается в том, что при росте размерности задачи объем вычисления значительно увеличивается, а задача численного интегрирования превращается из довольно простой в одну из самых сложных и трудоемких. По этой причине приведенные выше квадратурные формулы используются обычно для решения одно-, дву- и трехмерных задач.

Для вычисления интегралов по гиперкубу высокой размерности обычно используется метод Монте-Карло. Суть его состоит в том, что генерируется последовательность случайных точек

единичного n -мерного куба $x_1, x_2, \dots, x_n \in R^n$; очевидно, что чем больше точек участвует в вычислительном процессе, тем больше точность расчета.

Пусть теперь необходимо взять интеграл по области Ω , принадлежащей n -мерному кубу, причем Ω выделяется неравенствами

$$g_j(x_k) \leq 0, \quad j = 1, \dots, J, \quad k = 1, \dots, K.$$

Далее генерируется последовательность случайных чисел, равномерно распределенная в единичном гиперкубе, и для всех точек проверяются неравенства $g_j(x_k) \leq 0$. Если они выполнены, т. е. $x_k \in \Omega$, то вычисляются значения $f(x_k)$, прибавляющиеся к сумме.

Пусть вычислено M точек, из которых K попали в Ω , и накоплена сумма $\sum_{k=1}^K f(x_k)$.

Среднее по объему Ω значение функции f вычисляется по формуле $\bar{f} = I_\Omega / S_\Omega$, где $S_\Omega = K/M$, I_Ω — кратный интеграл по Ω .

С другой стороны, это же значение можно приближенно вычислить как сумму $[\sum f(x_k)] / K$.

Приравнявая эти выражения, получим

$$\frac{M}{K} I_\Omega \approx \frac{1}{K} \sum_{k=1}^K f(x_k),$$

откуда

$$I_\Omega \approx \frac{1}{M} \sum_{k=1}^K f(x_k).$$

7.7. Примеры решения задач

1. Вычислить $\int_{-1}^1 \ln(1 + x^2/3) dx$ по формулам Гаусса с точностью $\varepsilon = 10^{-3}$.

Решение. Воспользуемся четностью подынтегральной функции:

$$\int_{-1}^1 \ln\left(1 + \frac{x^2}{3}\right) dx = 2 \int_0^1 \ln\left(1 + \frac{x^2}{3}\right) dx$$

Оценим количество узлов интегрирования по квадратурным формулам Гаусса, необходимое для достижения заданной точности. Для этого нам нужны оценки сверху величин производных подынтегральной функции $f(x) = \ln(1 + x^2/3)$.

$$f'(x) = \frac{2x}{3 + x^2} = \frac{x + \sqrt{3}i + x - \sqrt{3}i}{(x + \sqrt{3}i)(x - \sqrt{3}i)} = \frac{1}{x + \sqrt{3}i} + \frac{1}{x - \sqrt{3}i},$$

$$f''(x) = -(x + \sqrt{3}i)^{-2} - (x - \sqrt{3}i)^{-2},$$

$$f'''(x) = 2(x + \sqrt{3}i)^{-3} + 2(x - \sqrt{3}i)^{-3},$$

$$f''''(x) = -6(x + \sqrt{3}i)^{-4} - 6(x - \sqrt{3}i)^{-4},$$

$$\max_{[0,1]} |f''''(x)| \leq 6(\sqrt{3})^{-4} + 6(\sqrt{3})^{-4} = \frac{4}{3},$$

тогда ошибка интегрирования на двух узлах на интервале единичной длины будет оценена как

$$r_2^\Gamma = \frac{1}{2^5} \frac{1}{135} f^{(4)}(\xi) \leq \frac{1}{4320} \cdot \frac{4}{3} \approx 3 \cdot 10^{-4} < \varepsilon.$$

Таким образом, для достижения заданной точности нам достаточно двух узлов для вычисления интеграла по отрезку $[0; 1]$:

$$\int_{-1}^1 \ln\left(1 + \frac{x^2}{3}\right) dx = 2\left(c_1 \ln\left(1 + \frac{x_1^2}{3}\right) + c_2 \ln\left(1 + \frac{x_2^2}{3}\right)\right)$$

Здесь c_1 и c_2 — веса квадратурной формулы на отрезке $[0; 1]$, а x_1 и x_2 — узлы квадратуры на этом интервале.

На $[-1; 1]$ узлы и веса $\widetilde{c}_1 = \widetilde{c}_2 = 1$, $t_1 = -t_2 = \sqrt{3}/3$. Выполняя линейную замену $y = \frac{1}{2}(x+1)$ для интегрирования на $[0, 1]$, для весов и узлов квадратурной формулы получим $c_1 = c_2 = 1/2$, $x_{1,2} = 1/2 \pm \sqrt{3}/6$. Подставляя это в (7.2), получим

$$\begin{aligned} \int_{-1}^1 \ln\left(1 + \frac{x^2}{3}\right) dx &= 2 \left[\frac{1}{2} \ln\left(1 + \frac{1}{3} \left(\frac{1}{2} - \frac{\sqrt{3}}{6}\right)^2\right) + \right. \\ &\quad \left. + \frac{1}{2} \ln\left(1 + \frac{1}{3} \left(\frac{1}{2} + \frac{\sqrt{3}}{6}\right)^2\right) \right] = \ln\left(1 + \frac{73}{9 \cdot 36}\right) = 0.2031928. \end{aligned}$$

Сравнивая вычисленный результат с точным значением интеграла $2\ln\frac{4}{3} - 4 + \frac{2\sqrt{3}\pi}{3} \approx 0.2029629$, видим, что точность получилась высокой.

2. Предложить метод вычисления несобственного интеграла $\int_0^{\infty} \frac{1}{1+x^5} dx$ с точностью $\varepsilon = 10^{-4}$.

Решение. Разобьем интеграл на два:

$$\int_0^{\infty} \frac{1}{1+x^5} dx = \int_0^M \frac{1}{1+x^5} dx + \int_M^{\infty} \frac{1}{1+x^5} dx.$$

Параметр M можно выбирать из условия, что значение второго интеграла в правой части (7.3) окажется меньше половины требуемой точности, а вторую половину допустимой погрешности можно было бы использовать для приближенного вычисления первого интеграла (например, методом трапеций или прямоугольников).

Поступим иначе. При больших M значение второго интеграла мало отличается от интеграла, вычисляемого точно:

$$\int_M^{\infty} \frac{1}{x^5} dx = \frac{1}{4M^4}.$$

Выберем M из условия, что разность этих двух интегралов по модулю не превосходит половины заданной точности:

$$\begin{aligned} \left| \int_M^{\infty} \frac{1}{1+x^5} dx - \int_M^{\infty} \frac{1}{x^5} dx \right| &= \left| \int_M^{\infty} \frac{1}{x^5(1+x^5)} dx \right| \leq \\ &\leq \int_M^{\infty} \frac{1}{x^{10}} dx = \frac{1}{9M^9} \leq \frac{1}{2} \varepsilon = \frac{1}{2} \cdot 10^{-4}. \end{aligned}$$

Это неравенство позволяет определить $M \geq 2.3534$. Возьмем $M = 2.5$, тогда второй с нужной точностью будет равен 0.0064. Для вычисления первого интеграла (например, методом прямоугольников со средней точкой) нужно оценить шаг численного

интегрирования, обеспечивающий нужную точность. Оценим вторую производную подынтегральной функции на отрезке $[0; 2.5]$.

$$f'(x) = -\frac{5x^4}{(1+x^5)^2}, \quad f''(x) = \frac{30x^8 - 20x^3}{(1+x^5)^3},$$

$$f'''(x) = \frac{30x^2(-7x^{10} + 16x^5 - 2)}{(1+x^5)^3}.$$

Точки экстремума второй производной $x_{1,2} = \sqrt[5]{\frac{8 \pm \sqrt{50}}{7}}$, максимальное значение второй производной $|f''(x)| \leq 3.5$. Тогда для обеспечения заданной точности формулы прямоугольников со средней точкой нужно выбрать шаг интегрирования, удовлетворяющий неравенству:

$$\frac{1}{24} h^2 \cdot (2.5 - 0) \cdot 3.5 \leq \frac{1}{2} \varepsilon = \frac{1}{2} 10^{-4},$$

откуда $h < 0.012$. Возьмем, например, $h = 0.01$. Тогда $x_k = kh$, $k = 0, \dots, 250$,

$$\int_0^{2.5} \frac{1}{1+x^5} dx \approx \sum_{k=0}^{249} h f\left(x_k + \frac{h}{2}\right) = 0.01 \cdot \sum_{k=0}^{249} \frac{1}{1+(x_k + h/2)^5}.$$

Библиографический комментарий к Лекции 7

При проведении практических занятий можно воспользоваться задачами [7].

Об основных квадратурных формулах можно прочитать в [1–5]. Некоторые более тонкие свойства методов численного интегрирования обсуждаются в [29, 32].

ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ ЗАДАЧИ КОШИ ДЛЯ СИСТЕМ ОБЫКНОВЕННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ

Подробно рассматриваются методы типа Рунге–Кутты, менее подробно — Адамса. Формулируются и доказываются утверждения об устойчивости методов Рунге–Кутты на устойчивых и нейтральных по устойчивости траекториях.

Ключевые слова: методы Рунге–Кутты, Адамса, таблицы Бутчера, аппроксимация, устойчивость, сходимость, устойчивые траектории, нейтральные траектории.

8.1. Основные понятия

Рассмотрим численные методы решения задачи Коши для обыкновенных дифференциальных уравнений (ОДУ) вида

$$\begin{aligned}\frac{du(t)}{dt} &= f(t, u), \quad t > 0, \\ u(0) &= u_0,\end{aligned}\tag{8.1}$$

а также систем ОДУ

$$\begin{aligned}\frac{d\mathbf{u}(t)}{dt} &= \mathbf{f}(t, \mathbf{u}), \\ \mathbf{u}(0) &= \mathbf{u}_0,\end{aligned}$$

где

$$\mathbf{u} = (u_1, u_2, \dots, u_m)^T, \quad \mathbf{f} = (f_1, f_2, \dots, f_m)^T$$

— векторы-столбцы искомых функций и правых частей соответственно $\mathbf{u}, \mathbf{f} \in R^m$.

К аналогичной форме приводится задача Коши для обыкновенного дифференциального уравнения порядка выше первого (или системы уравнений) вида

$$\begin{aligned}\frac{d^m u}{dt^m} &= g\left(t, u, \frac{du}{dt}, \dots, \frac{d^{m-1}u}{dt^{m-1}}\right), \quad t > 0, \\ u(0) &= a_0, \\ \frac{du}{dt}(0) &= a_1, \dots, \frac{d^{m-1}u}{dt^{m-1}}(0) = a_{m-1},\end{aligned}$$

если положить

$$\begin{aligned} u_1 = u, \quad u_2 = \frac{du_1}{dt}, \quad u_3 = \frac{du_2}{dt}, \quad \dots, \quad u_m = \frac{du_{m-1}}{dt}, \\ \frac{du_m}{dt} = g(t, u_1, u_2, \dots, u_m), \\ u_i(0) = a_{i-1}, \quad i = 1, 2, \dots, m. \end{aligned}$$

Введем в расчетной области $t \in [0, T]$ точки (узлы расчетной сетки) $\{t_n = n\tau, n = 0, 1, \dots, N\}$, в которых вычисляется искомое решение. Совокупность узлов называется *расчетной сеткой* (сеточной областью), τ — *шагом интегрирования*. Здесь для простоты введена равномерная сетка. В реальных расчетах применяются и неравномерные сетки.

Введем сеточную функцию u^τ , определенную в узлах сетки и представляющую собой совокупность приближенных значений искомой функции, U^τ — проекцию точного решения искомой задачи на сетку и f^τ — значения правой части в узлах сетки.

Введем вслед за [1] также операторное обозначение дифференциальной задачи

$$L(u) = F, \quad (8.2)$$

где

$$L(u) = \begin{cases} \frac{du}{dt} - f(t, u), & t > 0; \\ u(0), & t = 0; \end{cases} \quad F = \begin{cases} 0, & t > 0; \\ u_0, & t = 0; \end{cases}$$

и аппроксимирующей разностной задачи

$$L_\tau(u^\tau) = F_\tau, \quad (8.3)$$

где L_τ — обозначения разностного оператора, F_τ — проекция F на расчетную сетку. Заметим, что u и u^τ являются элементами соответственно функционального и конечномерного пространств. Определим основные понятия теории разностных схем [1].

О п р е д е л е н и е 8.1. *Решение задачи (8.3) u^τ сходится при $\tau \rightarrow 0$ к решению исходной задачи (8.2), если*

$$\|u^\tau - U^\tau\| \rightarrow 0$$

при $\tau \rightarrow 0$.

При этом, если имеет место оценка

$$\|u^\tau - U^\tau\| \leq C\tau^p, \quad C \neq C(\tau),$$

то имеет место сходимость порядка p .

Определение 8.2. *Говорят, что задача (8.3) аппроксимирует задачу (8.2) на ее решении, если невязка $\|r_\tau\| \rightarrow 0$ при $\tau \rightarrow 0$, где $r_\tau \equiv L_\tau(U^\tau) - F_\tau$; при этом, если имеет место оценка*

$$\|r_\tau\| \leq C_1 \tau^p, \quad C_1 \neq C_1(\tau),$$

то говорят, что имеет место аппроксимация порядка p .

Определение 8.3. *Задача (8.3) устойчива, если из соотношений*

$$L_\tau(u^\tau) - F_\tau = \xi_\tau,$$

$$L_\tau(v^\tau) - F_\tau = \eta_\tau$$

следует

$$\|u^\tau - v^\tau\| \leq C_2 (\|\xi_\tau\| + \|\eta_\tau\|), \quad C_2 \neq C_2(\tau).$$

Как правило, исследование на сходимость затруднено — для этого необходимо знать точное решение исходной дифференциальной задачи. Как будет видно из дальнейшего, исследование разностных схем на аппроксимацию и устойчивость (для систем ОДУ) — задачи более легкие. Теорема, связывающая понятия аппроксимации, устойчивости и сходимости, дает возможность обосновать достоверность полученных численных результатов. В силу этого ее называют *основной теоремой вычислительной математики*.

Теорема 8.1 (В. С. Рябенького–П. Лакса). *Решение задачи (8.3) сходится к решению исходной задачи (8.2), если задача (8.3) устойчива и аппроксимирует задачу (8.2); если аппроксимация имеет порядок p , то сходимость также имеет порядок p .*

Доказательство. В силу аппроксимации имеем оценку $\|r_\tau\| \leq C_1 \tau^p$. Тогда из определения устойчивости, положив $v^\tau = U^\tau$, получим

$$\|u_\tau - U_\tau\| \leq C_2 \|r_\tau\| \leq C_2 C_1 \tau^p = C \tau^p,$$

поскольку в данном случае

$$\|\xi_\tau\| = 0$$

и, кроме того,

$$\|r_\tau\| = \|\eta_\tau\|. \quad \square$$

Приведем примеры простейших разностных уравнений, аппроксимирующих (8.1):

$$\begin{aligned} \frac{u^{n+1} - u^n}{\tau} &= f(t_n, u^n), \quad 0 \leq n \leq N-1, \\ \frac{u^{n+1} - u^n}{\tau} &= f(t_n, u^{n+1}), \quad 0 \leq n \leq N-1, \\ \frac{u^{n+1} - u^{n-1}}{2\tau} &= f(t_n, u^n), \quad 1 \leq n \leq N-1. \end{aligned}$$

Первая из схем называется *явной* (явная схема Эйлера), вторая — *неявной* (неявная схема Эйлера). Алгоритмическая реализация первой схемы — бегущий счет (рекуррентная формула), второй — решение нелинейного алгебраического уравнения на каждом временном шаге.

Для реализации третьей схемы необходимо задание функции u^n в двух точках: t_0 и t_1 . Один из возможных вариантов — решение на первом шаге нелинейного уравнения вида

$$\frac{u^{n+1} - u^{n-1}}{2\tau} = \frac{1}{2} [f(t_{n-1}, u^{n-1}) + f(t_{n+1}, u^{n+1})]$$

при $n = 1$. В данном случае проявляется несовпадение формальных порядков дифференциального и разностного уравнений (дифференциальное уравнение первого порядка, разностное — второго).

Один из первых методов приближенного решения обыкновенных дифференциальных уравнений — разложение в ряд Тейлора.

Дифференцируя по t исходное уравнение (8.1), получим

$$u'' = f'_t(t, u) + f'_u(t, u) u',$$

$$u''' = f''_{tt}(t, u) + 2f''_{tu}(t, u) u' + f''_{uu}(t, u) (u')^2 + f'_u(t, u) u'', \dots$$

Таким образом, можно написать приближенное равенство

$$u(t) \approx \widetilde{V}^n(t) \equiv \sum_{i=0}^I \frac{u^{(i)}(t_n)}{i!} (t - t_n)^i.$$

Полагая

$$u^{n+1} = \widetilde{V}^n(t_{n+1}),$$

получаем приближенное значение $u(t)$ в точке $t = t_{n+1}$. При $I = 1$ и $t_{n+1} - t_n = \tau = \text{const}$ получаем метод Эйлера:

$$u^{n+1} = u^n + \tau f_n.$$

Этот способ не получил распространения в практике решения дифференциальных уравнений из-за необходимости вычисления производных $u^{(i)}$, где $i = 1, \dots, I$. По затратам машинного времени он заметно уступает другим методам, о которых будет идти речь далее.

В настоящее время в практике решения *жестких систем* ОДУ применяют так называемые *многозначные методы*, основанные на разложении в ряд Тейлора и вычислении производных. О жестких системах ОДУ будет рассказано ниже.

Рассмотрим еще один способ получения простейших одношаговых расчетных схем для численного решения уравнения (8.1), для чего напомним равенство

$$u(t + \tau) = u(t) + \int_t^{t+\tau} u'(z) dz. \quad (8.4)$$

После аппроксимации интеграла в правой части по формуле прямоугольников и замене его на величину $\tau u'(t)$, получим

$$u(t + \tau) = u(t) + \tau u'(t) + O(\tau^2),$$

или

$$u(t + \tau) = u(t) + \tau f(t, u) + O(\tau^2),$$

поскольку $u'(t) = f(t, u)$. Опуская член $O(\tau^2)$ и обозначая $t = t_n$, $t + \tau = t_{n+1}$, $u(t) = u^n$, $u(t + \tau) = u^{n+1}$, получим метод Эйлера.

Если рассматриваемый интеграл заменить формулой трапеций, получим

$$u(t + \tau) = u(t) + \frac{\tau}{2} [u'(t) + u'(t + \tau)] + O(\tau^3),$$

откуда имеем

$$u^{n+1} = u^n + \frac{\tau}{2} [f(t_n, u^n) + f(t_{n+1}, u^{n+1})].$$

Этот метод называется *неявным методом трапеций*. Для того чтобы метод был явным, его делают двухэтапным:

$$\begin{aligned} \widetilde{u}^{n+1} &= u^n + \tau f(t_n, u^n), \\ u^{n+1} &= u^n + \frac{\tau}{2} [f(t_n, u^n) + f(t_{n+1}, \widetilde{u}^{n+1})], \end{aligned}$$

где $\widetilde{u}^{n+1}$ — вспомогательная величина, вычисляемая на промежуточном этапе. Если этот же интеграл приблизить формулой прямоугольников со средней точкой, то получим

$$u(t+\tau) = u(t) + \tau u' \left(t + \frac{\tau}{2} \right) + O(\tau^3).$$

Снова воспользовавшись дифференциальным уравнением (8.1), преобразуем последнее выражение к виду

$$u(t+\tau) = u(t) + \tau f \left[t + \frac{\tau}{2}, u \left(t + \frac{\tau}{2} \right) \right] + O(\tau^3).$$

Соответствующий неявный метод имеет вид

$$u^{n+1} = u^n + \tau f \left[t_n + \frac{\tau}{2}, u \left(t_n + \frac{\tau}{2} \right) \right];$$

для его явной реализации можно воспользоваться следующей двухэтапной формулой:

$$u^{n+1/2} = u^n + \frac{\tau}{2} f(t_n, u^n),$$

$$u^{n+1} = u^n + \tau f \left(t_n + \frac{\tau}{2}, u^{n+1/2} \right).$$

Двухэтапные явные реализации, как мы увидим ниже, представляют собой частные случаи методов Рунге–Кутты.

8.2. Методы Рунге–Кутты

Рассмотрим общий метод построения двухточечных (одношаговых) явных методов. Будем использовать точное равенство (8.4). Для вычисления интеграла в правой части воспользуемся какой-либо квадратурной формулой. Для этого выбираем узлы квадратуры $t + c_i \tau$, $\tau = 1, 2, \dots, s$. Выбираем $c_0 = 0$, а все остальные $c_i > 0$. Выбор узлов однозначно определяет выбор весов квадратурной функции. Значения u в узлах квадратуры будем определять с помощью экстраполяции. Тогда (8.4) перейдет в

$$u(t+\tau) \approx u(t) + \tau \sum_{i=0}^s b_i f \left(t + c_i \tau, u(t) + \Delta \tau \right).$$

Наиболее распространенными при численном решении обыкновенных дифференциальных уравнений являются методы Рунге–Кутты.

Определение 8.4. *Явный s -стадийный метод Рунге–Кутты для численного решения задачи Коши для обыкновенного дифференциального уравнения (8.1) определяется формулами*

$$\begin{aligned} k_1 &= f(t_n, u^n), \\ k_2 &= f(t_n + c_2\tau, u^n + \tau a_{21}k_1), \\ k_3 &= f(t_n + c_3\tau, u^n + \tau(a_{31}k_1 + a_{32}k_2)), \dots, \\ k_r &= f(t_n + c_r\tau, u^n + \tau(a_{s1}k_1 + \dots + a_{s,s-1}k_{r-1})), \\ u^{n+1} &= u^n + \tau(b_1k_1 + \dots + b_s k_s), \end{aligned} \quad (8.5)$$

где k_i — промежуточные вспомогательные величины.

Коэффициенты, определяющие конкретный метод, могут быть представлены в виде *таблицы Бутчера* (табл. 8.1). Нулевые коэффициенты a_{ij} , как правило, в таблице Бутчера не указывают.

Т а б л и ц а 8.1.

0					
c_2	a_{21}				
c_3	a_{31}	a_{32}			
$\dots$	$\dots$	$\dots$	$\dots$		
c_r	a_{r1}	a_{r2}	$\dots$	a_{rr-1}	
	b_1	b_2	$\dots$	b_{r-1}	b_r

Обычно также используют условия, предложенный Куттой без объяснений и не являющиеся обязательными:

$$c_n = \sum_j b_{nj}.$$

Условия Кутты означают, что все k есть приближения к решению первого порядка в точках $t_n + c_r\tau$.

Получим простейшие методы Рунге–Кутты. Для этого введем погрешность

$$\xi(\tau) = u(t + \tau) - \left[u(t) + \sum_{j=1}^r b_j k_j \right]$$

и представим ее в виде разложения в ряд Маклорена:

$$\xi(\tau) = \sum_{i=0}^p \frac{\xi^{(i)}(0)}{i!} \tau^i + \frac{\xi^{(p+1)}(\theta\tau)}{(p+1)!} \tau^{p+1},$$

где $\frac{\xi^{(p+1)}(\theta\tau)}{(p+1)!} \tau^{p+1}$ — остаточный член ряда; $0 < \theta < 1$. Будем полагать (что можно сделать соответствующим выбором коэффициентов)

$$\xi(0) = \xi'(0) = \dots = \xi^{(p)}(0) = 0.$$

В таком случае разложение для $\xi(\tau)$ имеет более простой вид:

$$\xi(\tau) = \frac{\xi^{(p+1)}(\theta\tau)}{(p+1)!} \tau^{p+1},$$

где p — порядок точности метода.

1. Пусть $p = 1$, $r = 1$. Тогда

$$\xi(\tau) = u(t + \tau) - u(t) - \tau b_1 f(t, u),$$

отсюда

$$\xi(0) = 0,$$

$$\xi'(0) \equiv [u'(t + \tau) - b_1 f(t, u)]|_{t=0} = f(t, u)(1 - b_1),$$

$$\xi''(0) = u''(t + \tau).$$

Видно, что условие $\xi(0) = 0$ выполняется лишь при $b_1 = 0$, что соответствует методу Эйлера, при этом

$$\frac{u(t + \tau) - u(t)}{\tau} - f(t, u) = \frac{\xi''(t + \theta\tau)}{2} \tau = r_\tau,$$

где r_τ — невязка, имеющая первый порядок малости по τ .

2. Рассмотрим более сложный случай: $p = 2$, $r = 2$. Тогда

$$\xi(\tau) = u(t + \tau) - u(t) - \tau b_1 f(t, u) - \tau b_2 f[t + c_2 \tau, u + a_{21} \tau f(t, u)].$$

Вводя обозначения

$$\tilde{t} = t + c_2 \tau, \quad \tilde{u} = u + a_{21} \tau f(t, u),$$

получим следующие выражения для производных погрешности ξ по аргументу τ :

$$\begin{aligned} \xi'(\tau) &= u'(t + \tau) - b_1 f(t, u) - b_2 f(\tilde{t}, \tilde{u}) - \\ &\quad - \tau b_2 [c_2 f'_t(\tilde{t}, \tilde{u}) + a_{21} f'_u(\tilde{t}, \tilde{u}) f(t, u)], \\ \xi''(\tau) &= u''(t + \tau) - 2b_2 [c_2 f'_t(\tilde{t}, \tilde{u}) + a_{21} f'_u(\tilde{t}, \tilde{u}) f(t, u)] - \\ &\quad - \tau b_2 [c_2^2 f''_{tt}(\tilde{t}, \tilde{u}) + 2c_2 a_{21} f''_{tu}(\tilde{t}, \tilde{u}) f(t, u) + a_{21}^2 f''_{uu}(\tilde{t}, \tilde{u}) f^2(t, u)], \\ \xi'''(\tau) &= u'''(t + \tau) - 3b_2 [c_2^2 f''_{tt}(\tilde{t}, \tilde{u}) + 2c_2 a_{21} f''_{tu}(\tilde{t}, \tilde{u}) f(t, u) + \\ &\quad + a_{21}^2 f''_{uu}(\tilde{t}, \tilde{u}) f^2(t, u)] + o(\tau). \end{aligned}$$

Поставив в эти выражения следующие равенства:

$$u' = f, \quad u'' = f'_t + f'_u f, \quad u''' = f''_{tt} + 2f''_{tu} f + f''_{uu} f^2 + f'_u u'',$$

получим

$$\begin{aligned} \xi(0) &= 0, \quad \xi'(0) = (1 - b_1 - b_2) f(t, u), \\ \xi''(0) &= (1 - 2b_2 c_2) f'_t(t, u) + (1 - 2b_2 a_{21}) f'_u(t, u) f(t, u), \\ \xi'''(0) &= (1 - 3b_2 c_2^2) f''_{tt}(t, u) + (2 - 6b_2 c_2 a_{21}) f''_{tu}(t, u) f(t, u) + \\ &\quad + (1 - 3b_2 a_{21}^2) f''_{uu}(t, u) f^2(t, u) + f'_u(t, u) u''(t). \end{aligned}$$

Второе из полученных соотношений выполняется при $b_1 + b_2 = 1$, третье — при $1 - 2b_2 c_2 = 0$, $1 - 2b_2 a_{21} = 0$. Таким образом, имеются три алгебраических уравнения и четыре параметра. Эти уравнения определяют однопараметрическое семейство схем. Задавая один из параметров, можно получать различные методы Рунге–Кутты с аппроксимацией второго порядка. При формально одинаковом порядке аппроксимации они будут обладать различными свойствами (устойчивостью, реальной погрешностью).

Так, при $b_1 = 1/2$ имеем $b_2 = 1/2$, $c_2 = 1$, $a_{21} = 1$; метод будет выглядеть следующим образом:

$$\begin{aligned}\widetilde{u}^{n+1} &= u^n + \tau f(t_n, u_n), \\ u^{n+1} &= u^n + \frac{\tau}{2} [f(t_n, u^n) + f(t_{n+1}, \widetilde{u}^{n+1})].\end{aligned}$$

Положив $b_1 = 0$, имеем $b_2 = 1$, $c_2 = 1/2$, $a_{21} = 1/2$; соответствующий метод будет

$$\begin{aligned}u^{n+1/2} &= u^n + \frac{\tau}{2} f(t_n, u^n), \\ u^{n+1} &= u^n + f\left(t_n + \frac{\tau}{2}, u^{n+1/2}\right).\end{aligned}$$

3. При $p = 2$, $r = 3$ получаем систему уравнений для коэффициентов:

$$\begin{aligned}c_2 &= a_{21}, \quad c_3 = a_{31} + a_{32}, \\ c_3(c_3 - c_2) - a_{32}c_2(2 - 3c_2) &= 0, \\ b_3a_{32}c_2 = \frac{1}{6}, \quad b_2c_2 + b_3c_3 = \frac{1}{2}, \quad b_1 + b_2 + b_3 &= 1,\end{aligned}$$

имеющую бесконечное множество решений. Расчетные формулы одного из возможных методов имеют вид

$$\begin{aligned}k_1 &= \tau f(t_n, u^n), \quad k_2 = \tau f\left(t_n + \frac{\tau}{2}, u^n + \frac{k_1}{2}\right), \\ k_3 &= \tau f(t_n + \tau, u^n - k_1 + 2k_2), \\ u^{n+1} &= u^n + \frac{k_1 + 4k_2 + k_3}{6}.\end{aligned}$$

В случае $p = 4$, $r = 4$ имеем двухпараметрическое семейство методов Рунге–Кутты, из которого наиболее известен следующий «классический» метод:

$$\begin{aligned}k_1 &= \tau f(t_n, u^n), \\ k_2 &= \tau f\left(t_n + \frac{\tau}{2}, u^n + \frac{k_1}{2}\right), \\ k_3 &= \tau f\left(t_n + \frac{\tau}{2}, u^n + \frac{k_2}{2}\right), \\ k_4 &= \tau f(t_n + \tau, u^n + k_3), \\ u^{n+1} &= u^n + \frac{k_1 + 2k_2 + 2k_3 + k_4}{6}.\end{aligned}$$

Таблица 8.2.

0	0
	1

Таблица 8.3.

0		
1/2	1/2	
	0	1

Таблица 8.4.

0			
1/3	1/3		
2/3	0	2/3	
	1/4	0	3/4

Таблица 8.5.

0			
1/2	1/2		
1	0	1	
	1/6	2/3	1/6

В представлении Бутчера хорошо известные методы численного решения ОДУ выглядят так, как показано в следующих таблицах. Метод Эйлера (первый порядок аппроксимации) табл. 8.2, метод Эйлера с пересчетом (второй порядок аппроксимации) — табл. 8.3. Метод Хойна третьего порядка аппроксимации — табл. 8.4. Метод Рунге–Кутты третьего порядка аппроксимации — табл. 8.5.

Значения коэффициентов классического метода Рунге–Кутты (четвертого порядка аппроксимации) указаны в табл. 8.6. Правило $3/8$ (четвертый порядок аппроксимации) представлено в табл. 8.7. Этот метод имеет, по-видимому, наименьшую погрешность среди явных схем Рунге–Кутты четвертого порядка аппроксимации. Метод Бутчера (шестой порядок аппроксимации) указан в табл. 8.8. Очевидна связь между методами, приведенными в табл. 8.5 и 8.6, с формулой Симпсона численного интегрирования.

Таблица 8.6.

0				
1/2	1/2			
1/2	0	1/2		
1	0	0	1	
	1/6	2/6	2/6	1/6

Таблица 8.7.

0				
1/3	1/3			
2/3	-1/3	1		
1	1	-1	1	
	1/8	3/8	3/8	1/8

По-видимому, наивысший порядок аппроксимаций (десятый) был получен в работах Кёртиса, позже — Хайрера. Соответствующие коэффициенты не приведены ввиду их громоздкости.

Т а б л и ц а 8.8.

0							
1/2	1/2						
2/3	2/9	4/9					
1/3	7/36	2/9	-1/12				
5/6	-35/144	-55/36	35/48	15/8			
1/6	-1/360	-11/36	-1/8	1/2	1/10		
1	-41/260	22/13	43/156	-118/39	32/195	80/39	
	13/200	0	11/40	11/40	4/25	4/25	13/200

В численной практике используются также так называемые вложенные формулы Рунге–Кутты [34], в которых наряду с соотношением

$$u^{n+1} = u^n + \tau(b_1 k_1 + \dots + b_r k_r) \quad (8.6)$$

используется соотношение того же вида, но с другим набором весовых множителей:

$$\bar{u}^{n+1} = u^n + \tau(\bar{b}_1 k_1 + \dots + \bar{b}_r k_r), \quad (8.7)$$

причем порядки аппроксимации в них различаются: q — порядок аппроксимации (8.7), а p — (8.6). В этом случае порядок метода

Т а б л и ц а 8.9.

0					
c_2	a_{21}				
c_3	a_{31}	a_{32}			
...	...	...	...		
c_r	a_{r1}	a_{r2}	...	a_{rr-1}	
u_1	$\bar{b}_1$	$\bar{b}_2$	...	$\bar{b}_{r-1}$	$\bar{b}_r$
u_2	$\bar{b}_1$	$\bar{b}_2$	...	$\bar{b}_{r-1}$	$\bar{b}_r$

указывается как $p(q)$, а таблица Бутчера имеет вид табл. 8.9. Последнюю строчку в этой таблице иногда называют оценщиком погрешности.

Приближения точного решения с разными остаточными членами (8.6) и (8.7) позволяют оценить погрешность численного метода, полученную в конкретном расчете, и служат для повышения точности еще на один порядок в каждой точке или (что бывает чаще) для автоматического выбора длины следующего шага интегрирования (см. § 8.5).

Приведем несколько наиболее известных вложенных методов Рунге–Кутты. Метод Фельберга 2(3) представлен в табл. 8.10, метод Ческино 2(4) — в табл. 8.11.

Метод Кутты–Мерсона 4(5) приведен в табл. 8.12. Этот метод — наиболее простой среди вложенных методов Рунге–Кутты порядка 4(5), поскольку требует небольшого числа обращений к функциям вычисления правых частей системы уравнений (8.1) и имеет простые коэффициенты.

Для 5-этапного метода Кутты–Мерсона 4(5) приведем подробные расчетные формулы:

$$\begin{aligned}
 k_1 &= \tau f(t_n, u^n), \\
 k_2 &= \tau f\left(t_n + \frac{\tau}{3}, u^n + \frac{k_1}{3}\right), \\
 k_3 &= \tau f\left(t_n + \frac{\tau}{3}, u^n + \frac{k_1}{6} + \frac{k_2}{6}\right), \\
 k_4 &= \tau f\left(t_n + \frac{\tau}{2}, u^n + \frac{k_1}{8} + \frac{3k_3}{8}\right), \\
 k_5 &= \tau f\left(t_n + \tau, u^n + \frac{k_1}{8} - \frac{3k_3}{8} + 2k_4\right), \\
 u^{n+1} &= u_1(t + \tau) = u^n + \frac{k_1}{2} - \frac{3k_3}{2} + 2k_4, \\
 u^{n+1} &= u_2(t + \tau) = u^n + \frac{k_1}{6} + \frac{2k_4}{3} + \frac{k_5}{6}.
 \end{aligned}$$

Т а б л и ц а 8.10.

0			
1	1		
1/2	1/4	1/4	
	1/2	1/2	0
	1/6	1/6	4/6

Т а б л и ц а 8.11.

0				
1/4	1/4			
1/2	0	1/2		
1	1	-2	2	
	1	-2	2	0
	1/6	0	4/6	1/6

Т а б л и ц а 8.12.

0					
1/3	1/3				
1/3	1/6	1/6			
1/2	1/8	0	3/8		
1	1/2	0	-3/2	2	
	1/2	0	-3/2	2	0
	1/6	0	0	2/3	1/6

Рассмотрим вкратце другие вложенные методы и соответствующие им таблицы. Метод Фельберга 4(5) представлен в табл. 8.13, метод Дормана–Принса 5(4) — в табл. 8.14.

Т а б л и ц а 8.13.

0						
$\frac{1}{4}$	$\frac{1}{4}$					
$\frac{3}{8}$	$\frac{3}{32}$	$\frac{9}{32}$				
$\frac{12}{13}$	$\frac{1932}{2197}$	$\frac{7296}{2197}$				
1	$\frac{439}{216}$	-8	$\frac{3680}{513}$	$-\frac{845}{4104}$		
$\frac{1}{2}$	$-\frac{8}{27}$	2	$-\frac{3544}{2565}$	$\frac{1859}{4104}$	$-\frac{14}{40}$	
	$\frac{25}{216}$	0	$\frac{1408}{2565}$	$\frac{2197}{4104}$	$-\frac{1}{5}$	0
	$\frac{16}{135}$	0	$\frac{6656}{12825}$	$\frac{28561}{56430}$	$-\frac{9}{50}$	$\frac{2}{55}$

Этот метод замечателен тем, что он не только минимизирует остаточный член в оценщике погрешностей, но и требует меньшей памяти для хранения таблицы коэффициентов метода. Действительно, последняя строка a совпадает с одной из строк b .

Т а б л и ц а 8.14.

0							
$\frac{1}{5}$	$\frac{1}{5}$						
$\frac{3}{10}$	$\frac{3}{40}$	$\frac{9}{40}$					
$\frac{4}{5}$	$\frac{44}{45}$	$-\frac{56}{15}$	$\frac{32}{9}$				
$\frac{8}{9}$	$\frac{19372}{6561}$	$-\frac{25360}{2187}$	$\frac{64448}{6561}$	$-\frac{212}{729}$			
1	$\frac{9017}{3168}$	$-\frac{355}{33}$	$\frac{46732}{5247}$	$\frac{49}{176}$	$-\frac{5163}{18656}$		
1	$\frac{35}{384}$	0	$\frac{500}{1113}$	$\frac{125}{192}$	$-\frac{2187}{6784}$	$\frac{11}{84}$	
	$\frac{35}{384}$	0	$\frac{500}{1113}$	$\frac{125}{192}$	$-\frac{2187}{6784}$	$\frac{11}{84}$	0
	$\frac{5179}{57600}$	0	$\frac{7571}{16695}$	$\frac{393}{640}$	$-\frac{92097}{339200}$	$\frac{187}{2100}$	$\frac{1}{40}$

С методом Фельберга более высокого порядка 7(8) можно ознакомиться в [34], значения его коэффициентов приведены в табл. 8.15.

Среди современных методов решения нежестких систем ОДУ наилучшие результаты дает метод Дормана–Принса 8(7). Он обладает наименьшей погрешностью среди всех схем порядка 8, коэффициенты указаны в табл. 8.16, 8.17. С вложенными формулами Рунге–Кутты, разработанными в 1990-х годах, можно ознакомиться в монографии [35].

Методы Рунге–Кутты — это одношаговые методы, так как позволяют найти значение искомой функции в точке t_{n+1} , используя только значение функции в точке t_n . При этом не учитывается информация о функции, накопленная на предыдущих этапах расчета. Такая информация может быть полезна при решении жестких задач или при автоматическом выборе следующего шага интегрирования.

Один из способов учета предыстории заключается в использовании общих многошаговых методов. Частный случай — методы Адамса — рассмотрен в следующем параграфе. Другой способ учета описан в § 8.5.

Т а б л и ц а 8.15.

0													
$\frac{2}{27}$	$\frac{2}{27}$												
$\frac{1}{9}$	$\frac{1}{36}$	$\frac{1}{12}$											
$\frac{1}{6}$	$\frac{1}{24}$	0	$\frac{1}{8}$										
$\frac{5}{12}$	$\frac{5}{12}$	0	$-\frac{25}{16}$	$\frac{25}{16}$									
$\frac{1}{2}$	$\frac{1}{20}$	0	0	$\frac{1}{4}$	$\frac{1}{5}$								
$\frac{5}{6}$	$-\frac{25}{108}$	0	0	$\frac{125}{108}$	$-\frac{65}{27}$	$\frac{125}{54}$							
$\frac{1}{6}$	$\frac{31}{300}$	0	0	0	$\frac{61}{225}$	$-\frac{2}{9}$	$\frac{13}{900}$						
$\frac{2}{3}$	2	0	0	$-\frac{53}{6}$	$\frac{704}{45}$	$-\frac{107}{9}$	$\frac{67}{90}$	3					
$\frac{1}{3}$	$-\frac{91}{108}$	0	0	$\frac{23}{108}$	$-\frac{976}{135}$	$\frac{311}{54}$	$-\frac{19}{60}$	$\frac{17}{6}$	$-\frac{1}{12}$				
1	$\frac{2383}{4100}$	0	0	$-\frac{341}{164}$	$\frac{4496}{1025}$	$-\frac{301}{82}$	$\frac{2133}{4100}$	$\frac{45}{82}$	$\frac{45}{164}$	$\frac{18}{41}$			
0	$\frac{3}{205}$	0	0	0	0	$-\frac{6}{41}$	$-\frac{3}{205}$	$-\frac{3}{41}$	$\frac{3}{41}$	$\frac{6}{41}$	0		
1	$-\frac{1777}{4100}$	0	0	$-\frac{341}{164}$	$\frac{4496}{1025}$	$-\frac{289}{82}$	$\frac{2193}{4100}$	$\frac{51}{82}$	$\frac{33}{164}$	$\frac{12}{41}$	0	1	
	$\frac{41}{840}$	0	0	0	0	$\frac{34}{105}$	$\frac{9}{35}$	$\frac{9}{35}$	$\frac{9}{280}$	$\frac{9}{280}$	$\frac{41}{840}$	0	0
	0	0	0	0	0	$\frac{34}{105}$	$\frac{9}{35}$	$\frac{9}{35}$	$\frac{9}{280}$	$\frac{9}{280}$	0	$\frac{41}{840}$	$\frac{41}{840}$

Т а б л и ц а 8.16.

a_{ij}		i					
		2	3	4	5	6	7
j	1	1/18	1/48	1/32	5/16	3/80	$\frac{29443841}{614563906}$
	2		1/16	0	0	0	0
	3			3/32	-75/64	0	0
	4				75/64	3/16	$\frac{77736538}{692538347}$
	5					3/20	$-\frac{28693883}{1112000000}$
	6						$\frac{23124283393}{1800000000}$

a_{ij}		i					
		8	9	10	11	12	13
j	1	$\frac{16016141}{946692911}$	$\frac{39632708}{573591083}$	$\frac{246121993}{1340847787}$	$-\frac{1028468189}{846180014}$	$\frac{185892177}{718116043}$	$\frac{403863854}{491063109}$
	2, 3	0	0	0	0	0	0
	4	$\frac{61564180}{158732637}$	$-\frac{433636366}{683701615}$	$-\frac{37695042795}{15268766246}$	$\frac{8478235783}{506512852}$	$-\frac{3185094517}{667107341}$	$-\frac{5068492393}{434740067}$
	5	$\frac{22789713}{633445777}$	$-\frac{421739975}{2616292301}$	$-\frac{309121744}{1061227803}$	$\frac{1311729495}{1432422823}$	$-\frac{477755414}{1098053517}$	$-\frac{411421997}{543043805}$
	6	$\frac{545815736}{2771057229}$	$\frac{100302831}{723423059}$	$-\frac{12992083}{490766935}$	$-\frac{10304129995}{1701304382}$	$-\frac{703635378}{230739211}$	$\frac{652783627}{914296604}$
	7	$-\frac{180193667}{1043307555}$	$\frac{790204164}{839813087}$	$\frac{6005943433}{2108947869}$	$-\frac{48777925059}{3047939560}$	$\frac{5731566787}{1027545527}$	$\frac{11173962825}{925320556}$
	8		$\frac{800635310}{3783071287}$	$\frac{393006217}{1396673457}$	$\frac{15336726248}{1032824649}$	$\frac{5232866602}{850066563}$	$-\frac{13158990841}{6184727034}$
	9			$\frac{123872331}{1001029789}$	$-\frac{45442868181}{3398467696}$	$\frac{4093664535}{808688257}$	$\frac{3936647629}{1978049680}$
	10				$\frac{3065993473}{597172653}$	$\frac{3962137247}{1805957418}$	$-\frac{160528059}{685178525}$
	11					$\frac{65686385}{487910083}$	$\frac{248638103}{1413531060}$

Т а б л и ц а 8.17.

i	1	2	3	4	5	6	7	8
c_i	1	$\frac{1}{18}$	$\frac{1}{12}$	$\frac{1}{8}$	$\frac{5}{16}$	$\frac{3}{8}$	$\frac{59}{400}$	$\frac{93}{200}$
b_i	$\frac{14005451}{335480064}$	0	0	0	0	$-\frac{59238493}{1068277825}$	$\frac{181606676}{758867731}$	$\frac{561292985}{797845732}$
$\bar{b}_i$	$\frac{13451932}{455176623}$	0	0	0	0	$-\frac{808719846}{976000145}$	$\frac{1757004468}{5645159321}$	$\frac{656045339}{265891186}$

i	9	10	11	12	13
c_i	$\frac{5490023248}{9719169821}$	$\frac{1201146811}{1299019798}$	$\frac{3}{20}$	1	1
b_i	$-\frac{1041891430}{1371343529}$	$\frac{760417239}{1151165299}$	$\frac{118820643}{751138087}$	$-\frac{528747749}{2220607170}$	$\frac{1}{4}$
$\bar{b}_i$	$-\frac{3867574721}{1518517206}$	$\frac{465885868}{322736535}$	$\frac{5301238}{667516719}$	$\frac{2}{45}$	0

Общие условия аппроксимации методов Рунге–Кутты и барьеры Бутчера. Вернемся к общей записи метода Рунге–Кутты (8.5) и соответствующей таблице Бутчера. Рассматривается задача

$$\frac{d\mathbf{u}(t)}{dt} = \mathbf{f}(t, \mathbf{u}), \quad \mathbf{u}(0) = \mathbf{u}^0,$$

а численный метод имеет вид

$$\begin{aligned} \mathbf{k}_1 &= \mathbf{f}(t_n, \mathbf{u}^n), \\ \mathbf{k}_2 &= \mathbf{f}(t_n + c_2\tau, \mathbf{u}^n + \tau a_{21}\mathbf{k}_1), \\ \mathbf{k}_3 &= \mathbf{f}(t_n + c_3\tau, \mathbf{u}^n + \tau(a_{31}\mathbf{k}_1 + a_{32}\mathbf{k}_2)), \\ &\dots\dots\dots \\ \mathbf{k}_r &= \mathbf{f}(t_n + c_r\tau, \mathbf{u}^n + \tau(a_{r1}\mathbf{k}_1 + \dots + a_{r, r-1}\mathbf{k}_{r-1})), \\ \mathbf{u}^{n+1} &= \mathbf{u}^n + \tau(b_1\mathbf{k}_1 + \dots + b_r\mathbf{k}_r), \end{aligned}$$

где k_i — вспомогательные векторы.

Наряду с явными, рассмотрим также неявные методы Рунге–Кутты, определенные как

$$\begin{aligned} \mathbf{k}_1 &= \mathbf{f}\left(t_n + c_1\tau, \mathbf{u}^n + \tau \sum_{j=1}^r a_{1j}\mathbf{k}_j\right), \\ \mathbf{k}_2 &= \mathbf{f}\left(t_n + c_2\tau, \mathbf{u}^n + \tau \sum_{j=1}^r a_{2j}\mathbf{k}_j\right), \\ &\dots\dots\dots \\ \mathbf{k}_r &= \mathbf{f}\left(t_n + c_r\tau, \mathbf{u}^n + \tau \sum_{j=1}^r a_{rj}\mathbf{k}_j\right), \\ \mathbf{u}^{n+1} &= \mathbf{u}^n + \tau(b_1\mathbf{k}_1 + \dots + b_r\mathbf{k}_r). \end{aligned}$$

Таблица Бутчера для неявных методов примет вид

c_1	a_{11}	a_{12}	$\dots$	$a_{1, r-1}$	a_{1r}
c_2	a_{21}	a_{22}	$\dots$	$a_{2, r-1}$	a_{2r}
c_3	a_{31}	a_{32}	$\dots$	$a_{3, r-1}$	a_{3r}
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
c_r	a_{r1}	a_{r2}	$\dots$	a_{rr-1}	a_{rr}
	b_1	b_2	$\dots$	b_{r-1}	b_r

Для вывода условий аппроксимации общего метода Рунге–Кутты необходимо действовать так же, как описано выше. Для

этого введем погрешность

$$\xi(\tau) = u(t + \tau) - \left[u(t) + \sum_{j=0}^r b_j k_j \right]$$

и представим ее в виде разложения в ряд Маклорена. Приравнявая члены при одинаковых степенях шага τ , получим условия аппроксимации метода. Для того чтобы метод имел порядок 3, необходимо выполнение следующих условий:

$$\begin{aligned} \sum_{i=1}^r b_i &= 1; & 2 \sum_{i=1}^r \sum_{k=1}^r b_i a_{ik} &= 1; \\ 3 \sum_{i=1}^r \sum_{k=1}^r \sum_{l=1}^r b_i a_{ik} a_{il} &= 1; & 6 \sum_{i=1}^r \sum_{k=1}^r \sum_{l=1}^r b_i a_{ik} a_{kl} &= 1, \end{aligned}$$

причем эти выражения упрощаются, если воспользоваться необязательными условиями Кутты. При повышении порядка аппроксимации метода возникают дополнительные условия на коэффициенты, система значительно усложняется.

Для того чтобы построить аппроксимирующую схему (метод Рунге–Кутты) необходимо найти набор коэффициентов метода. Как было показано выше, в случае двух стадий метода такой набор коэффициентов — не единственный, существует континуум методов второго порядка аппроксимации. Континуум решений системы уравнений порядка для явных методов Рунге–Кутты имеет и в случае явных методов с тремя или четырьмя стадиями. Но для пятистадийного метода система уравнений порядка является несовместной. Это утверждение было доказано Бутчером и носит название «первый барьер Бутчера». Его обычно формулируют в виде теоремы [34].

Теорема 8.2 (первый барьер Бутчера). *Среди явных методов Рунге–Кутты с числом стадий пять не существует методов пятого порядка аппроксимации.*

Для повышения порядка до пятого приходится использовать шестистадийные методы. При увеличении числа стадий возникает второй барьер Бутчера — порядок аппроксимации метода, начиная с семи стадий, оказывается уже на 2 ниже, чем число стадий. При увеличении порядка аппроксимации метода приходится значительно увеличивать число стадий — барьеры Бутчера встречаются чаще.

Наличие такого барьера — одно из следствий быстрого роста констант Лебега при интерполяции на равномерной сетке. Дело в том, что явные методы Рунге–Кутты тесно связаны с квадратурными формулами интерполяционного типа. Достаточно очевидно, что классический метод Рунге–Кутты порядка 4 основан на применении формулы Симпсона, а правило 3/8 — на одноименной квадратурной формуле. Как было показано в лекции 7, с повышением порядка аппроксимации квадратурные формулы перестают быть правильными, а это — следствие роста константы Лебега. Тогда и появляются барьеры Бутчера при построении методов решения систем ОДУ.

От этого недостатка свободны некоторые неявные методы, основанные на квадратурных формулах Гаусса.

8.3. Методы Адамса

Для решения ОДУ или систем ОДУ существуют *одностадийные методы Адамса* (линейные многошаговые методы), суть которых заключается в следующем.

Пусть известно приближенное решение в некоторых узлах расчетной сетки: $t_n, t_{n-1}, \dots, t_{n-m}$. В окрестности этих узлов заменим $f(t, x(t))$ интерполяционным полиномом, записанным в форме Ньютона (см. лекцию 6):

$$f(t) = f(t_n) + f(t_n, t_{n-1})(t - t_n) + f(t_n, t_{n-1}, t_{n-2})(t - t_n)(t - t_{n-1}) + \\ + f(t_n, t_{n-1}, t_{n-2}, t_{n-3})(t - t_n)(t - t_{n-1})(t - t_{n-2}) + \dots$$

Для того чтобы вычислить решение в точке $n+1$, запишем его в интегральном виде

$$u^{n+1} = u^n + \int_{t_n}^{t_{n+1}} f(t, u(t)) dt = \int_{t_n}^{t_{n+1}} f(t) dt$$

и подставим в него интерполяционный полином с переменным шагом:

$$u^{n+1} = u^n + \tau_n f(t_n) + \frac{\tau_n^2}{2} f(u^n, u^{n-1}) + \\ + \frac{\tau_n^2}{6} (2\tau_n + 3\tau_{n-1}) f(u^n, u^{n-1}, u^{n-2}) + \frac{\tau_n^2}{12} (2\tau_n^2 + 8\tau_n\tau_{n-1} + \\ + 4\tau_n\tau_{n-2} + 6\tau_{n-1}^2 + 6\tau_n\tau_{n-2}) f(u^n, u^{n-1}, u^{n-2}, u^{n-3}).$$

Здесь $\tau_n = t_{n+1} - t_n$, $f(u^n, u^{n-1})$, $f(u^n, u^{n-1}, u^{n-2})$ и т. д. — разделенные разности.

Эта формула — четвертого порядка аппроксимации. Если опустить последнее слагаемое, то получим формулу третьего порядка, если опустить еще и предпоследнее, то — второго, и т. д. Если же положить $\tau_n = \text{const.}$ то формула значительно упростится:

$$u^{n+1} = u^n + \tau f^n + \frac{\tau^2}{2} \Delta_1 f^n + \frac{5}{12} \tau^3 \Delta_2 f^n + \frac{3}{8} \tau^4 \Delta_3 f^n,$$

где $\Delta_k f^n$ — k -я конечная разность.

Для того чтобы начать вычисления по данному варианту метода Адамса, необходимо знать решение в четырех точках. Это можно сделать, например, с помощью методов Рунге–Кутты. Кроме того, коэффициент при погрешности, например, для метода четвертого порядка аппроксимации Рунге–Кутты существенно меньше соответствующего коэффициента для метода Адамса.

Первые четыре метода Адамса (от первого до четвертого порядка аппроксимации с постоянным шагом интегрирования) представляются в виде

$$\begin{aligned} u^{n+1} &= u^n + \tau f^n, \\ u^{n+1} &= u^n + \tau \left(\frac{3}{2} f^n - \frac{1}{2} f^{n-1} \right), \\ u^{n+1} &= u^n + \tau \left(\frac{23}{12} f^n - \frac{16}{12} f^{n-1} + \frac{5}{12} f^{n-2} \right), \\ u^{n+1} &= u^n + \tau \left(\frac{55}{24} f^n - \frac{59}{24} f^{n-1} + \frac{37}{24} f^{n-2} - \frac{9}{24} f^{n-3} \right). \end{aligned} \quad (8.8)$$

В общем виде методы Адамса могут быть записаны следующим образом:

$$u^{n+1} = u^n + \tau \sum_{j=0}^{k-1} \eta_j \Delta^j f^j.$$

Значительно большее значение в вычислительной практике имеют неявные методы Адамса, которые можно записать как

$$u^{n+1} = u^n - \tau \sum_{j=0}^k \tilde{\gamma}_j \Delta^j f^{n+1}.$$

Первые четыре неявных метода имеют вид

$$k = 0: u^{n+1} = u^n + \tau f^{n+1},$$

$$k = 1: u^{n+1} = u^n + \tau \left(\frac{1}{2} f^{n+1} + \frac{1}{2} f^n \right),$$

$$k = 2: u^{n+1} = u^n + \tau \left(\frac{5}{12} f^{n+1} + \frac{8}{12} f^n - \frac{1}{12} f^{n-1} \right),$$

$$k = 3: u^{n+1} = u^n + \tau \left(\frac{9}{24} f^{n+1} + \frac{19}{24} f^n - \frac{5}{24} f^{n-1} + \frac{1}{24} f^{n-2} \right).$$

Первая и вторая формулы — неявный метод Эйлера и неявный метод трапеций соответственно. Порядок аппроксимации приведенных методов — с первого по четвертый соответственно.

Т а б л и ц а 8.18.

J	0	1	2	3	4	5	6	7	8
$\widetilde{\gamma}_j$	1	$-\frac{1}{2}$	$-\frac{1}{12}$	$-\frac{1}{24}$	$-\frac{19}{720}$	$-\frac{3}{160}$	$-\frac{863}{60480}$	$-\frac{275}{24192}$	$-\frac{33953}{3628800}$

Т а б л и ц а 8.19.

j	0	1	2	3	4	5	6	7	8
η_j	1	$\frac{1}{2}$	$\frac{5}{12}$	$\frac{3}{8}$	$\frac{251}{720}$	$\frac{95}{288}$	$\frac{19087}{60480}$	$\frac{5257}{17280}$	$\frac{1070017}{3628800}$

Для $k = 8$ коэффициент $\widetilde{\gamma}_j$ можно представить в виде таблицы (см. табл. 8.18) и ввести следующие обозначения: $\Delta^{j+1} f^n = \Delta^j f^n - \Delta^j f^{n-1}$ — «разности назад», η_j — коэффициенты, которые можно представить в виде таблицы (для $k = 8$ табл. 8.19). Для $k = 1$ получается уже знакомый явный метод Эйлера.

8.4. Метод неопределенных коэффициентов для построения многошаговых методов численного решения задачи Коши

Рассматриваются численные решения задачи Коши для системы ОДУ

$$\frac{d\mathbf{u}}{dt} = \mathbf{f}(t, \mathbf{u}), \quad t > 0, \quad \mathbf{u}(0) = \mathbf{u}_0$$

на расчетной сетке с эквидистантными узлами $\omega_\tau = \{t_n = n\tau; n = 0, 1, \dots\}$.

Определение 8.5. *Разностным m -шаговым методом называется разностное уравнение вида*

$$\tau^{-1} \sum_{j=0}^m \alpha_j \mathbf{u}^{n-j} = \sum_{j=0}^m \beta_j \mathbf{f}^{n-j}, \quad (8.9)$$

или

$$\frac{\alpha_0 \mathbf{u}^n + \alpha_1 \mathbf{u}^{n-1} + \dots + \alpha_m \mathbf{u}^{n-m}}{\tau} = \beta_0 \mathbf{f}^n + \beta_1 \mathbf{f}^{n-1} + \dots + \beta_m \mathbf{f}^{n-m}.$$

Здесь $n = m, m+1, \dots, N$; α_n, β_n — действительные числа.

Уравнение (8.9) позволяет определить значение $\mathbf{u}^n$ через уже известные значения в предыдущих точках сетки, причем на первом этапе решается уравнение для $n = m$:

$$\frac{\alpha_0 \mathbf{u}^m + \alpha_1 \mathbf{u}^{m-1} + \dots + \alpha_m \mathbf{u}^0}{\tau} = \beta_0 \mathbf{f}^m + \beta_1 \mathbf{f}^{m-1} + \dots + \beta_m \mathbf{f}^0.$$

Для того чтобы начать расчет, необходимо задать m значений $\mathbf{u}^j$, $j = 0, \dots, m-1$. При этом, если $\mathbf{u}^0$ задается в качестве начальных данных задачи Коши, то значения в остальных точках необходимо вычислять, например, по одному из методов Рунге–Кутты.

Метод является явным, т. е. $\mathbf{u}^n$ вычисляется по известным значениям в предыдущих узлах сетки, если $\beta_0 = 0$, и неявным, если $\beta_0 \neq 0$. В последнем случае на каждом шаге интегрирования численно решается нелинейное уравнение

$$\tau^{-1} \alpha_0 \mathbf{u}^n = \beta_0 \mathbf{f}^n + \sum_{j=1}^m (\beta_j \mathbf{f}^{n-j} - \tau^{-1} \alpha_j \mathbf{u}^{n-j}).$$

При $\beta_0 = 1$, $\beta_j = 0$, $j > 1$ метод называется чисто неявным.

Поскольку коэффициенты разностного уравнения (8.9) определены с точностью до множителя, то для устранения произвола добавим условие нормировки

$$\sum_{j=0}^m \beta_j = 1. \quad (8.10)$$

В случае если производная решения ОДУ аппроксимируется по двум точкам, т. е. $\alpha_0 = 1$, $\alpha_1 = -1$, $\alpha_j = 0$, $j = 2, 3, \dots, m$, рассматриваемые многошаговые методы называются методами Адамса. Они были рассмотрены в предыдущем параграфе.

Отметим, что в [38] использовалось другое условие нормировки, а именно, $\alpha_0 = 1$. Оно не только является естественным при выводе методов Адамса, но и позволяет получить систему линейных уравнений, однозначно определяющих свойства методов.

8.4.1. Погрешности многошаговых методов.

Определение 8.6. *Невязкой (погрешностью) многошагового метода называется функция*

$$r_n = - \sum_{i=0}^m \tau^{-1} \alpha_i U_{n-i} + \sum_{i=0}^m \beta_i f(t_{n-i}, U_{n-i}),$$

где U_i — проекция на сетку точного решения исходной дифференциальной задачи.

Полагая, что рассматриваемые функции имеют все необходимые производные, определим порядок аппроксимации разностного метода. Воспользуемся формулой Тейлора для разложения функций $U(t_n - k\tau) = U_{n-k}$ и $f(t_{n-k}, U_{n-k})$:

$$U_{n-k} = \sum_{i=0}^p \frac{(-k\tau)^i U^{(i)}(t_n)}{i!} + O(\tau^{p+1});$$

$$f(t_{n-k}, U_{n-k}) = \frac{dU}{dt}(t_n - k\tau) = \sum_{i=0}^{p-1} \frac{(-k\tau)^i U^{(i+1)}(t_n)}{i!} + O(\tau^p).$$

После подстановки разложений в выражение для невязки получим

$$\begin{aligned} r_n = & - \sum_{k=0}^m \tau^{-1} \alpha_k \left[\sum_{i=0}^p \frac{(-k\tau)^i U^{(i)}(t_n)}{i!} \right] + \sum_{k=0}^m \beta_k \left[\sum_{i=0}^{p-1} \frac{(-k\tau)^i U^{(i+1)}(t_n)}{i!} \right] + \\ & + O(\tau^p) = - \sum_{i=0}^p \left[\sum_{k=0}^m \tau^{-1} \alpha_k \frac{(-k\tau)^i U^{(i)}(t_n)}{i!} \right] + \\ & + \sum_{i=1}^p \left[\sum_{k=0}^{p-1} \beta_k \frac{(-k\tau)^{i-1} U^{(i)}(t_n)}{(i-1)!} \right] + O(\tau^p) = - \left(\sum_{k=0}^m \tau^{-1} \alpha_k \right) U(t_n) + \\ & + \sum_{i=1}^m \left[\sum_{k=0}^p (-k\tau)^{i-1} (k^{-1} i^{-1} \alpha_k + \beta_k) \right] \frac{U^{(i)}(t_n)}{(i-1)!} + O(\tau^p). \end{aligned}$$

Отсюда разностный метод имеет p -й порядок аппроксимации при выполнении следующих условий, представляющих систему из $p+2$ линейных алгебраических уравнений относительно $2(m+1)$ неизвестных:

$$\begin{aligned}\sum_{k=0}^m \alpha_k &= 0; \\ \sum_{k=0}^m k^{i-1} (k\alpha_k + i\beta_k) &= 0; \quad i = 1, \dots, p; \\ \sum_{k=0}^m \beta_k &= 1.\end{aligned}$$

Обычно эту систему упрощают, рассматривая отдельно уравнение для $i = 1$, т. е.

$$\sum_{k=0}^m k\alpha_k + \sum_{k=0}^m \beta_k = 0, \quad \text{или} \quad \sum_{k=0}^m k\alpha_k = -1.$$

После этих упрощений рассматриваемая система линейных алгебраических уравнений приобретает вид

$$\begin{aligned}\sum_{k=0}^m k\alpha_k &= -1; \\ \alpha_0 &= -\sum_{k=1}^m \alpha_k; \\ \sum_{k=0}^m k^{i-1} (k\alpha_k + i\beta_k) &= 0; \quad i = 2, \dots, p; \\ \sum_{k=0}^m \beta_k &= 1.\end{aligned}$$

Очевидно, что эта система не будет переопределенной при выполнении условия $p \leq 2m$, т. е. число уравнений не должно превышать числа неизвестных. В этом случае порядок аппроксимации неявного разностного многошагового метода не превышает $2m$, явного — $2m-1$.

Для методов Адамса получим

$$\alpha_0 = 1, \quad \alpha_1 = -1, \quad \beta_0 = 1 - \sum_{k=1}^m \beta_k, \quad \sum_{k=0}^m k^{i-1} \beta_k = 1, \quad i = 2, \dots, p.$$

Отсюда видно, что порядок аппроксимации m -шагового неявного метода Адамса не превышает $m + 1$, явного — m .

Линейный многошаговый разностный метод удовлетворяет *условию корней*, если все корни характеристического уравнения

$$\alpha_0 \lambda^m + \alpha_1 \lambda^{m-1} + \dots + \alpha_{m-1} \lambda + \alpha_m = 0,$$

полученного из разностного однородного уравнения

$$\alpha_0 u^n + \alpha_1 u^{n-1} + \dots + \alpha_m u^{n-m} = 0,$$

путем подстановки решения вида $u^n = \lambda^n$, лежат внутри или на границе единичного круга в комплексной плоскости и на границе этого круга нет кратных корней. Такой разностный метод является устойчивым.

Методы Адамса являются устойчивыми, так как удовлетворяют условию корней, поскольку если $\alpha_0 = 1$, $\alpha_1 = -1$, то $\lambda = 1$.

Теорема 8.3. *Условие корней является необходимым и достаточным для устойчивости линейного однородного разностного уравнения по начальным данным.*

Оказывается, что условие корней накладывает ограничение на порядок аппроксимации многошагового метода: для неявных методов $p \leq m + 1$ при нечетном m и $p \leq m + 2$ при m четном; для явных методов $p \leq m$.

К линейным многошаговым методам вернемся в следующей лекции при рассмотрении методов решения жестких систем ОДУ.

8.5. Оценка погрешности

8.5.1. Автоматический выбор шага интегрирования. Рунге предложил простое правило оценки точности метода, основанное на проведении вычислений с разными шагами интегрирования. Оценка погрешности по правилу Рунге идейно такая же, как и при вычислении интегралов.

Погрешность численного метода порядка $p - 1$ в точке $t_i = i\tau$ представляется в виде

$$u^n(t_i) - \widetilde{V}^n(t_i) = C\tau^p + O(\tau^{p+1}).$$

Если выполнить аналогичные вычисления с шагом вдвое меньшим ($\tau/2$), то получим

$$u^{2n} - \widetilde{V}^n(t_i) = C\frac{\tau^p}{2^p} + O(\tau^{p+1}).$$

После вычитания из первого соотношения второго

$$u^n - u^{2n} = C(\tau^p - \frac{\tau^p}{2^p}) + O(\tau^{p+1}),$$

откуда

$$C = \frac{2^p}{\tau^p} \frac{u^n - u^{2n}}{2^p - 1} + O(\tau).$$

Подставив выражение для C во второе соотношение, получим

$$u^{2n} - \tilde{V}^n(t_i) = \frac{u^n - u^{2n}}{2^p - 1} + O(\tau^{p+1}),$$

т. е. погрешность метода с точностью $O(\tau^{p+1})$ оценивается по простой формуле

$$\varepsilon = \frac{u^n - u^{2n}}{2^p - 1}.$$

Это правило используется не только для оценки погрешности вычисления, но и для автоматического выбора шага интегрирования. Для этого на каждом шаге вычисления производятся трижды: с шагом τ и с двумя шагами $\tau/2$. Полученные значения u_n и u_{2n} используются для вычисления реальной погрешности ε (точнее, оценки ее главного члена). Если величина ε превышает некую заданную (или заранее выбранную) константу ε_0 , то шаг интегрирования уменьшается; если, напротив, ε существенно меньше ε_0 , то τ увеличивается.

Разумеется, алгоритмы выбора шага интегрирования могут основываться и на иных принципах. Например, можно выбрать τ адаптирующимся к решению: уменьшать при увеличении абсолютной величины производной и увеличивать при ее уменьшении, т. е. вычислять τ как функцию от $\|\mathbf{u}'_t\|$.

Управление длиной шага в методах Рунге–Кутты осуществляется на основе сравнения с некоторой задаваемой величиной T , характеризующей требования к погрешности на каждом шаге численного интегрирования системы.

Пусть используется метод с порядком аппроксимации p . Тогда главный член погрешности метода ε , определяемый по правилу Рунге, или, в случае использования вложенных методов Рунге–Кутты, представляющий собой модуль разности между приближениями к решению, вычисленными по формулам (8.6) и (8.7), имеет вид

$$\varepsilon = C_2 \tau^{p+1} \leq T.$$

Положим теперь $T = C_2 \tau_{\text{new}}^{p+1}$. Тогда для величины максимального значения нового шага интегрирования τ_{new} получаем

$$\tau_{\text{new}} = \beta \tau \left(\frac{T}{\varepsilon} \right)^{1/(p+1)},$$

где β — так называемый гарантированный множитель. Он служит для того, чтобы в случае резкого уменьшения шага (например, при выходе на жесткий участок при решении умеренно *жестких систем*) численный метод оставался устойчивым.

Кроме того, гарантированный множитель помогает избежать слишком быстрого увеличения величины шага интегрирования в случае, когда реально полученная погрешность мала. Обычно величина гарантийного множителя принимается за 0.5; 0.8; 0.9 или $(0.25, \dots, 0.38)^{1/(p+1)}$. Если при выполнении очередного шага погрешность ε не превосходит величины T , то шаг считается *принятым*, а дальнейший расчет продолжается с шагом τ_{new} , в противном случае шаг считается *отклоненным* и проводится пересчет с новым значением шага для перехода от t_n к t_{n+1} .

На практике применяют модернизации алгоритма выбора шага. Так, если реальная ошибка ε мала, то предлагаемый алгоритм позволяет выбрать очень большой шаг по τ . В таком случае применяют алгоритм

$$\tau_{\text{new}} = \tau \cdot \min \left\{ \beta_{\max}, \max \left(\beta_{\min}, \beta \left(\frac{T}{\varepsilon} \right)^{1/(p+1)} \right) \right\}.$$

Здесь $\beta_{\max}$, $\beta_{\min}$ — максимальное и минимальное разрешенное изменение шага интегрирования.

Другая возможность регуляции шага численного интегрирования для методов Рунге–Кутты заключается в объединении достоинств методов Рунге–Кутты и Адамса. Первые из них допускают легко регулировать шаг интегрирования, а вторые «помнят» часть предыстории изменения функции.

Более тонкий алгоритм управления величиной шага получается с учетом величины ошибки на предыдущем шаге:

$$\tau_{\text{new}} = \tau \left(\frac{T}{\varepsilon_n} \right)^a \left(\frac{T}{\varepsilon_{n-1}} \right)^{-\beta},$$

т.е. фактически гарантийный множитель зависит от ошибки на предыдущем шаге. Обычно при таком выборе управления длиной

шага полагается $\alpha = 1/(p+1)$, $\beta \approx 0.08$. Такой выбор регулирования шага повышает устойчивость численных методов Рунге–Кутты не очень высокого порядка. Для метода Дормана–Принса порядка 8(7) лучшие результаты дает $\beta \approx 0.04$. В [35] показано, что такой метод выбора шага является решением задачи оптимального управления с учетом пропорциональной обратной связи и интегральной обратной связи. Там же показано, что оптимальный выбор показателей степени есть $\alpha \approx 0.7/(p+1)$, $\beta \approx 0.4/(p+1)$.

8.6. Устойчивость методов Рунге–Кутты

Для исследования устойчивости методов Рунге–Кутты для численного решения задачи

$$\frac{d\mathbf{u}}{dt} = \mathbf{f}(t, \mathbf{u}), \quad \mathbf{u}(0) = \mathbf{u}_0, \quad t \in [0, T]$$

представим ее дискретный аналог в виде

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = \mathbf{F}(t_n, \mathbf{u}^n). \quad (8.11)$$

Здесь $\mathbf{F}(t, \mathbf{x})$ — функция приращения метода Рунге–Кутты, которая, конечно, связана с функцией правой части системы ОДУ.

Теорема 8.4 (устойчивость методов Рунге–Кутты). Пусть $\mathbf{f}(t, \mathbf{x})$ липшиц-непрерывна по второму аргументу, т. е.

$$\|\mathbf{f}(t, \mathbf{x}) - \mathbf{f}(t, \mathbf{y})\| \leq C\|\mathbf{x} - \mathbf{y}\|,$$

причем это условие выполняется для каждого t , $C \neq C(\tau)$ и $C\tau \ll 1$. Тогда разностное уравнение (8.11) устойчиво и имеет место оценка

$$\|\mathbf{u}^n - \mathbf{v}^n\| \leq e^{C_2 t} \|\mathbf{u}^0 - \mathbf{v}^0\| + \frac{2\epsilon e^{C_2 T}}{C_2}. \quad (8.12)$$

Здесь $\mathbf{u}^n, \mathbf{v}^n$ — решения близких систем разностных уравнений

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = \mathbf{F}(t_n, \mathbf{u}^n) + \boldsymbol{\epsilon}_n^1, \quad \mathbf{u}_0 = \mathbf{u}^0,$$

$$\frac{\mathbf{v}^{n+1} - \mathbf{v}^n}{\tau} = \mathbf{F}(t_n, \mathbf{v}^n) + \boldsymbol{\epsilon}_n^2, \quad \mathbf{v}_0 = \mathbf{v}^0$$

ϵ — максимальная погрешность при вычислении правой части системы, т. е. для всех n (включая ноль)

$$\|\epsilon_n^1\| \leq \epsilon, \quad \|\epsilon_n^2\| \leq \epsilon,$$

а постоянная C_2 незначительно отличается от C .

Сформулируем вначале следующую лемму.

Лемма 8.1. Пусть C — постоянная Липшица для функции правых частей системы (8.1), тогда функция приращения $\mathbf{F}(t, \mathbf{u})$ для метода (8.11) удовлетворяет следующему неравенству:

$$\|\mathbf{F}(t, \mathbf{u}^n) - \mathbf{F}(t, \mathbf{v}^n)\| \leq C_2 \|\mathbf{u}^n - \mathbf{v}^n\|,$$

где

$$C_2 = C \left(\sum_i |b_i| + \tau C \sum_{i,j} |b_i a_{ij}| + \tau^2 C^2 \sum_{i,j,k} |b_i a_{ij} a_{jk}| + \dots \right).$$

Суммирование в правой части последнего равенства ведется по каждому индексу от 1 до r — числа стадий метода. Число сумм в скобках, конечно, тоже равно r . Отметим также, что если в таблице Бутчера все коэффициенты неотрицательны (такой метод Рунге–Кутты по аналогии с методом численного интегрирования назовем правильным), то из условий порядка (аппроксимации) будет следовать, что в скобках стоят первые r членов разложения $e^{C\tau}$ в ряд Тейлора. Отсюда необходимое требование (в формулировке теоремы) к малости $C\tau$. В случае наличия отрицательных коэффициентов в таблице Бутчера константа Липшица C_2 увеличится незначительно — число стадий метода конечно и невелико (в настоящее время известны методы максимум с 17 стадиями, см. [34]).

Доказательство данной леммы довольно простое, но громоздкое. Читатель может проделать это самостоятельно.

Доказательство теоремы. Рассмотрим эти близкие уравнения. Вычитая из первого уравнения второе, получим

$$\|\mathbf{u}^{n+1} - \mathbf{v}^{n+1}\| \leq \|\mathbf{u}^n - \mathbf{v}^n\| + \tau \|\mathbf{F}(t, \mathbf{u}^n) - \mathbf{F}(t, \mathbf{v}^n)\| + 2\tau\epsilon, \quad (8.13)$$

или, учитывая условие Липшица,

$$\|\mathbf{u}^{n+1} - \mathbf{v}^{n+1}\| \leq (1 + C_2\tau) \|\mathbf{u}^n - \mathbf{v}^n\| + 2\tau\epsilon.$$

Здесь константа C_2 — постоянная Липшица функции приращения метода Рунге–Кутты, выражение для нее приведено выше в формулировке леммы 8.1.

Далее, применяя последовательно это неравенство, получим оценки:

$$\begin{aligned}\|\mathbf{u}^1 - \mathbf{v}^1\| &\leq (1 + C_2\tau)\|\mathbf{u}^0 - \mathbf{v}^0\| + 2\tau\epsilon, \\ \|\mathbf{u}^2 - \mathbf{v}^2\| &\leq (1 + C_2\tau)\|\mathbf{u}^1 - \mathbf{v}^1\| + 2\tau\epsilon \leq \\ &\leq (1 + C_2\tau)^2\|\mathbf{u}^0 - \mathbf{v}^0\| + 2\tau\epsilon[1 + (1 + C_2\tau)], \\ \|\mathbf{u}^3 - \mathbf{v}^3\| &\leq (1 + C_2\tau)\|\mathbf{u}^2 - \mathbf{v}^2\| + 2\tau\epsilon \leq \\ &\leq (1 + C_2\tau)^3\|\mathbf{u}^0 - \mathbf{v}^0\| + 2\tau\epsilon[1 + (1 + C_2\tau) + (1 + C_2\tau)^2], \\ \|\mathbf{u}^n - \mathbf{v}^n\| &\leq \\ &\leq (1 + C_2\tau)^n\|\mathbf{u}^0 - \mathbf{v}^0\| + 2\tau\epsilon[1 + (1 + C_2\tau) + \dots + (1 + C_2\tau)^{n-1}],\end{aligned}$$

откуда, после суммирования прогрессии, имеем

$$\begin{aligned}\|\mathbf{u}^n - \mathbf{v}^n\| &\leq (1 + C_2\tau)^n\|\mathbf{u}^0 - \mathbf{v}^0\| + 2\tau\epsilon \frac{(1 + C_2\tau)^n - 1}{(1 + C_2\tau) - 1} \leq \\ &\leq (1 + C_2\tau)^n \left(\|\mathbf{u}^0 - \mathbf{v}^0\| + \frac{2\epsilon}{C_2} \right).\end{aligned}$$

Далее полагаем $(1 + C_2\tau)^n = (1 + C_2\tau)^{t/\tau} \approx e^{C_2 t}$ при $C_2\tau \ll 1$. После подстановки экспоненты в последнюю оценку получим неравенство (8.12). $\square$

Заметим, что экспоненциальный множитель в неравенстве (8.12) при больших t велик, а оценка, в наиболее общем случае, в предположении липшиц-непрерывности функции $\mathbf{F}(\mathbf{u})$, неулучшаема. Однако в некоторых важных частных случаях эту оценку можно улучшить, рассматривая более тонкие свойства рассматриваемой функции. Докажем следующее утверждение [2], рассматривая задачу Коши для системы ОДУ.

Утверждение. Пусть матрица

$$\mathbf{A}(\mathbf{u}) = \frac{1}{2}(\mathbf{f}_u(\mathbf{u}) + \mathbf{f}_u^*(\mathbf{u}))$$

строго отрицательна, т. е.

$$(\mathbf{A}(\mathbf{u})\xi, \xi) \leq -a(\xi, \xi)$$

для любых ξ , $\mathbf{u}$ и $a > 0$ (траектория, в окрестности которой выполняется это условие, называется устойчивой).

Тогда при интегрировании правильным методом Рунге-Кутты k -го порядка аппроксимации погрешность приближенного решения есть $O(\tau^k)$ при любом $t > 0$ при выполнении условий $a\tau \ll 1$. Утверждение будет доказано, если в оценке устойчивости метода не будет содержаться множитель e^{Ct} .

Доказательство. Оценим норму разности в правой части неравенства (8.13) используя более точные свойства функции $\mathbf{F}(\mathbf{u})$, чем липшиц-непрерывность:

$$\begin{aligned} \mathbf{F}(\mathbf{u}) - \mathbf{F}(\mathbf{v}) &= \mathbf{F}(\mathbf{v} + s(\mathbf{u} - \mathbf{v})) \Big|_{s=0}^{s=1} = \int_0^1 \frac{d}{ds} \mathbf{F}(\mathbf{v} + s(\mathbf{u} - \mathbf{v})) ds = \\ &= \int_0^1 \mathbf{F}'(\mathbf{v} + s(\mathbf{u} - \mathbf{v})) (\mathbf{u} - \mathbf{v}) ds. \end{aligned}$$

Здесь произведена замена переменных $\mathbf{u}(s) = \mathbf{v} + s(\mathbf{u} - \mathbf{v})$. Поскольку

$$\mathbf{u} - \mathbf{v} = \int_0^1 (\mathbf{u} - \mathbf{v}) ds,$$

то получаем, что

$$\begin{aligned} \|(\mathbf{u} - \mathbf{v}) + \tau(\mathbf{F}(\mathbf{u}) - \mathbf{F}(\mathbf{v}))\| &= \\ &= \left\| \int_0^1 (\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}}(\mathbf{v} + s(\mathbf{u} - \mathbf{v}))) (\mathbf{u} - \mathbf{v}) ds \right\| \leq \\ &\leq \int_0^1 \|\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}}\| \|\mathbf{u} - \mathbf{v}\| ds. \quad (8.14) \end{aligned}$$

Оценим норму $\|\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}}\|$. Для этого сначала оценим квадрат нормы

$$\begin{aligned} \|\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}}\|^2 &= \sup_{\|\xi\| \neq 0} \frac{((\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}})\xi, (\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}})\xi)}{(\xi, \xi)} = \\ &= \sup_{\|\xi\| \neq 0} \frac{(\xi, \xi) + 2\tau(\mathbf{A}\xi, \xi) + \tau^2(\mathbf{F}'_{\mathbf{u}}\xi, \mathbf{F}'_{\mathbf{u}}\xi)}{(\xi, \xi)} \leq 1 - 2\tau a + O(\tau^2). \end{aligned}$$

Здесь использовано определение нормы матрицы (см. лекцию 2)

$$\|\mathbf{B}\|^2 = \sup_{\|\xi\| \neq 0} \frac{(\mathbf{B}\xi, \mathbf{B}\xi)}{(\xi, \xi)},$$

где $\mathbf{B}$ — матрица, ξ — вектор из рассматриваемого пространства.

При малых τ , пренебрегая членами порядка $O(\tau^2)$, из последнего неравенства получаем требуемую оценку:

$$\|\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}}\| \leq 1 - a\tau.$$

Тогда из (8.14) имеем

$$\int_0^1 \|\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}}\| \|\mathbf{u} - \mathbf{v}\| ds \leq (1 - a\tau) \|\mathbf{u} - \mathbf{v}\|,$$

откуда

$$\|\mathbf{u}^{n+1} - \mathbf{v}^{n+1}\| \leq (1 - a\tau) \|\mathbf{u}^n - \mathbf{v}^n\| + 2\tau\varepsilon.$$

Рассмотрев, как и ранее, цепочку неравенств

$$\begin{aligned} \|\mathbf{u}^1 - \mathbf{v}^1\| &\leq (1 - a\tau) \|\mathbf{u}^0 - \mathbf{v}^0\| + 2\tau\varepsilon, \\ \|\mathbf{u}^2 - \mathbf{v}^2\| &\leq (1 - a\tau) \|\mathbf{u}^1 - \mathbf{v}^1\| + 2\tau\varepsilon, \\ &\dots\dots\dots \end{aligned}$$

получим

$$\|\mathbf{u}^n - \mathbf{v}^n\| \leq (1 - a\tau)^n \|\mathbf{u}^0 - \mathbf{v}^0\| + 2\tau\varepsilon \frac{1 - (1 - a\tau)^n}{1 - (1 - a\tau)},$$

или

$$\|\mathbf{u}^n - \mathbf{v}^n\| \leq (1 - a\tau)^n \|\mathbf{u}^0 - \mathbf{v}^0\| + \frac{2\varepsilon}{a}. \quad (8.15)$$

Утверждение доказано. $\square$

Пусть теперь $(\mathbf{A}(\mathbf{u})\xi, \xi) \leq 0$ т. е. рассматриваются нейтральные, или «не неустойчивые» траектории исследуемой системы обыкновенных дифференциальных уравнений. В этом случае аналогичным образом показывается, что

$$\|\mathbf{E} + \tau \mathbf{F}'_{\mathbf{u}}\| \leq 1 + C_2 \tau^2.$$

Тогда, проведя аналогичные выкладки, получим

$$\|\mathbf{u}^{n+1} - \mathbf{v}^{n+1}\| \leq (1 + C_2 \tau^2) \|\mathbf{u}^n - \mathbf{v}^n\| + 2\tau\epsilon,$$

откуда

$$\|\mathbf{u}^n - \mathbf{v}^n\| \leq (1 + C_2 \tau^2)^n \|\mathbf{u}^0 - \mathbf{v}^0\| + 2\tau\epsilon \frac{(1 + C_2 \tau^2)^n - 1}{C_2 \tau^2}.$$

Для метода k -го порядка аппроксимации $\epsilon = O(\tau^k)$, $k \geq 0$. В этом случае решения близких систем на n -м шаге по времени отличаются на величину

$$\|\mathbf{u}^n - \mathbf{v}^n\| \leq e^{C_2 \tau^2 n} \|\mathbf{u}^0 - \mathbf{v}^0\| + O(\tau^{k-1}). \quad (8.16)$$

Отсюда видно, что при $n \sim \tau^{-2}$ (или $t_n = n\tau \sim \tau^{-1}$) численное решение имеет точность $O(\tau^{k-1})$. Другими словами, на конечных интервалах времени $t \sim O(1)$ точность метода $O(\tau^k)$, на больших же временах $t \sim O(\tau^{-1})$ точность понижается до $t \sim O(\tau^{k-1})$. Такие случаи возникают, когда имеется необходимость проводить численные расчеты при исследовании процессов с большим количеством колебаний, вращений и т. д. Важно отметить то, что наши оценки погрешности численного решения получены с использованием более сильных, чем условие Липшица, свойств правых частей рассматриваемых дифференциальных уравнений.

8.7. Примеры решения задач

1. Управление длиной шага.

а) Система ОДУ решается с помощью метода Рунге–Кутты порядка аппроксимации $p > 1$. Описать алгоритм выбора шагов интегрирования таких, чтобы достигнутая погрешность на каждом из них не превосходила заданную величину ϵ .

Решение. Пусть переход от значения y_n к y_{n+1} осуществляется с шагом h . Тогда в результате работы метода получим

$$y^{n+1} = \tilde{y}^{n+1} + Ch^{p+1} + O(h^{p+2}), \quad (8.17)$$

где $\tilde{y}^{n+1}$ — точное решение задачи, взятое в точке $n + 1$, Ch^{p+1} — главный член погрешности, постоянная C зависит как от коэффициентов конкретного метода, так и от решения задачи. (Из решения задачи 8.1 следует, что разложения y_{n+1} и $\tilde{y}^{n+1}$ в ряд Тейлора совпадают до членов с номерами $p + 1$ включительно).

Осуществим теперь переход от y_n к y_{n+1} за два этапа, используя тот же метод Рунге–Кутты с шагом $h/2$. Тогда имеем

$$\tilde{\tilde{y}}^{n+1} = \tilde{y}^{n+1} + 2C\left(\frac{h}{2}\right)^{p+1} + O(h^{p+2}). \quad (8.18)$$

Так как C оценивается через максимальное по абсолютной величине значение $(p + 1)$ -й производной на отрезке $[t_n, t_{n+1}]$, можно считать, что в последнем выражении константа совпадает с константой в предыдущем равенстве. Используя два равенства, возможно либо явно вычислить Ch^p и исключить его из (8.18), повысив точность аппроксимации на порядок, либо поступить следующим образом. Вычитая из (8.18) равенство (8.17), имеем

$$y^{n+1} - \tilde{\tilde{y}}^{n+1} = Ch^{p+1}(1 - 2^{-p}) + O(h^{p+2}),$$

отсюда главный член погрешности (8.18) будет равен

$$Ch^{p+1} = \frac{y^{n+1} - \tilde{\tilde{y}}^{n+1}}{1 - 2^{-p}}. \quad (8.19)$$

Необходимо выбрать шаг интегрирования h_{new} таким образом, чтобы главный член погрешности не превосходил заданное значение ($Ch_{\text{new}}^{p+1} < \varepsilon$):

$$\left(\frac{h_{\text{new}}}{h}\right)^{p+1} \frac{y^{n+1} - \tilde{\tilde{y}}^{n+1}}{1 - 2^{-p}} < \varepsilon,$$

откуда имеем

$$h_{\text{new}} = q \left(\frac{y^{n+1} - \tilde{\tilde{y}}^{n+1}}{1 - 2^{-p}} \frac{1}{\varepsilon} \right)^{-1/(p+1)} h. \quad (8.20)$$

где $0 < q < 1$.

Если же на текущем шаге погрешность (8.19) превышает ε , то шаг считается *отклоненным* и расчет выполняется снова со значением, найденным по формуле (8.20).

б) Система ОДУ решается с помощью *явных* методов p -го и $(p+1)$ -го порядка аппроксимации. На каждом шаге погрешность расчетов не должна превышать ε . Как выбрать длину шага интегрирования?

Рассуждаем аналогично тому, как это сделано в п. 1. При расчете методом p -го порядка аппроксимации имеем

$$y_p^{n+1} = \tilde{y}^{n+1} + Ch^{p+1} + K_1 h^{p+2} + O(h^{p+3}), \quad (8.21)$$

а $(p+1)$ -й порядок дает

$$y_{p+1}^{n+1} = \tilde{y}^{n+1} + K_2 h^{p+2} + O(h^{p+3}). \quad (8.22)$$

Отсюда сразу получаем $Ch^{p+1} \sim y_p^{n+1} - y_{p+1}^{n+1}$. Эти величины сравниваются с заданной точностью.

Существует семейство методов Рунге–Кутты, таких, что члены погрешности для результата старшего $(p+1)$ -го порядка минимизируются, а вычисление погрешности p -го порядка используется лишь для управления длиной шага. При этом для порядков p и $p+1$ коэффициенты b , c в таблице Бутчера (табл. 8.9) совпадают, а различаются лишь коэффициенты a . Кроме того, $b_{si} = a_i(y_p)$. Такие методы построены Дорманом и Принсом и носят их имя.

2. Рассмотрим *уравнение Ферхюльста (логистическое уравнение)*, описывающее динамику численности популяции:

$$\begin{aligned} y' &= ay(1-y), \\ y(0) &= y_0; \quad 0 < y_0 < 1, \quad a > 0. \end{aligned} \quad (8.23)$$

а) Решить уравнение (8.23) точно, учитывая, что это уравнение в разделяющихся переменных. Получившаяся кривая — график точного решения — носит название логистической кривой.

б) Рассмотреть для (8.23) *явный метод Эйлера*:

$$y^{n+1} = y^n + \tau ay^n(1 - y^n). \quad (8.24)$$

При каких шагах τ метод является устойчивым?

Решение. Точное решение получится, если записать, что исходное нелинейное уравнение есть уравнение с разделяющимися переменными. Точное решение $y(t) = \frac{Ce^{at}}{1 + Ce^{at}}$, $C = \frac{y_0}{1 - y_0}$. При

$t \rightarrow \infty$ точное решение (8.23) асимптотически стремится к единице. Очевидно, что последовательность $y_n \equiv 1$ является и решением (8.23). Непосредственно проверяется, что (8.24) аппроксимирует (8.23) с точностью $O(\tau)$. В случае, если метод (8.24) *устойчив*, то решение (8.24) *сходится* к решению (8.23) и должно выполняться неравенство

$$|y^{n+1} - 1| < |y^n - 1|.$$

Если рассмотреть (8.24) как запись метода простых итераций для (8.23), то он должен сходиться к корню $y = 1$ при любом начальном приближении y_0 , лежащем между 0 и 1.

Перепишем (8.24) в виде

$$z^{n+1} = bz^n(1 - z_n); \quad z^n = \frac{\tau a}{\tau a + 1} y^n; \quad b = 1 + \tau a, \quad (8.25)$$

и для (8.25) воспользуемся результатами, полученными в лекции 5. Таким образом, условия устойчивости для (8.24) будут следующими: $b = 1 + \tau a < 3$, откуда $\tau < 2/a$.

3. Описать сценарий развития вычислительной неустойчивости для задачи (8.24), можно воспользоваться материалом лекции 5. Следует обратить внимание на то, что когда метод неустойчив, в отличие от линейных задач, модуль разности численного и точного решений остается ограниченным при любом сколь угодно большом t при $2/a \leq \tau < 3/a$.

Решение сводится к исследованию бифуркаций в логистическом отображении, см. §4.5.

4. Задача Коши для системы ОДУ

$$\dot{x} = -2y, \quad \dot{y} = 2x, \quad x(0) = 0, \quad y(0) = 1$$

решается с помощью метода трапеций

$$\frac{y^{n+1} - y^n}{\tau} = \frac{f^{n+1} + f^n}{2}.$$

Доказать, что решение разностной задачи сходится к решению дифференциальной.

Решение. Решение дифференциальной задачи легко ищется.

Рассмотрим решение разностной задачи. Имеем

$$\frac{x^{n+1} - x^n}{\tau} = -y^{n+1} - y^n, \quad \frac{y^{n+1} - y^n}{\tau} = x^{n+1} + x^n,$$

откуда

$$\begin{pmatrix} x \\ y \end{pmatrix}^{n+1} = \frac{1}{1+\tau^2} \begin{pmatrix} 1-\tau^2 & -2\tau \\ 2\tau & 1-\tau^2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}^n = \begin{pmatrix} \cos \xi & -\sin \xi \\ \sin \xi & \cos \xi \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}^n,$$

где $\cos \xi = \frac{1-\tau^2}{1+\tau^2}$.

Тогда

$$\begin{pmatrix} x \\ y \end{pmatrix}^n = \begin{pmatrix} \cos \xi & -\sin \xi \\ \sin \xi & \cos \xi \end{pmatrix}^{T/\tau} \begin{pmatrix} x \\ y \end{pmatrix}^0 = \begin{pmatrix} \cos \frac{T}{\tau} \xi & -\sin \frac{T}{\tau} \xi \\ \sin \frac{T}{\tau} \xi & \cos \frac{T}{\tau} \xi \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}^0.$$

Теперь необходимо вычислить предел

$$\begin{aligned} \lim_{\tau \rightarrow 0} \begin{pmatrix} \cos \frac{T}{\tau} \xi & -\sin \frac{T}{\tau} \xi \\ \sin \frac{T}{\tau} \xi & \cos \frac{T}{\tau} \xi \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}^0 &= \\ &= \lim_{\tau \rightarrow 0} \begin{pmatrix} \cos \frac{T}{\tau} \arcsin \frac{2\tau}{1+\tau^2} & -\sin \frac{T}{\tau} \arcsin \frac{2\tau}{1+\tau^2} \\ \sin \frac{T}{\tau} \arcsin \frac{2\tau}{1+\tau^2} & \cos \frac{T}{\tau} \arcsin \frac{2\tau}{1+\tau^2} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}^0 = \\ &= \begin{pmatrix} \cos 2T & -\sin 2T \\ \sin 2T & \cos 2T \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}^0. \end{aligned}$$

Отсюда следует сходимость к решению дифференциальной задачи.

Библиографический комментарий к Лекции 8

Теорема о связи аппроксимации, устойчивости и сходимости была установлена, доказана и опубликована в 1956 г. независимо В. С. Рябенкиным и А. Ф. Филипповым в СССР [33], П. Лаксом и Р. Рихтмайером в США [36]. Отметим, что ранее близкие теоремы были установлены Л. В. Канторовичем, некоторые из них нашли отражение в [37].

Простейшие численные методы решения задачи Коши для систем ОДУ подробно рассмотрены в большом количестве учебников и специальных изданий. Самое подробное изложение различных численных методов можно найти в [34]. Теоремы об устойчивости явных методов Рунге–Кутты впервые были опубликованы в первом издании книги [2] в 1984 г. (Федоренко Р. П. Введение в вычислительную физику. — М.: Изд-во МФТИ, 1994. — 528 с.).

Описание численных методов для решения ОДУ в пространствах неопределенных коэффициентов содержится в [38, 39]. В данной лекции изложение следует [39].

Для более полного понимания материала лекции рекомендуется использовать задачник [8] при проведении практических занятий. Для понимания свойств наиболее распространенных численных методов можно выполнить соответствующую лабораторную работу [7]. Варианты выполнения практических работ по теме можно найти также в книге авторов [27].

ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ ЖЕСТКИХ СИСТЕМ ОБЫКНОВЕННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ

Дается понятие жесткой системы обыкновенных дифференциальных уравнений (ЖС ОДУ). Рассматриваются неявные методы Рунге–Кутты и Гира для решения ЖС ОДУ. Исследуется устойчивость методов.

Ключевые слова: жесткие системы ОДУ, спектр матрицы Якоби, А-устойчивость, асимптотическая устойчивость, жесткая устойчивость, неявные и диагонально-неявные методы Рунге–Кутты, методы Розенброка, методы Гира, представление Нордсика.

9.1. Явление жесткости. Предварительные сведения

Рассмотрим в качестве примера две задачи Коши для систем обыкновенных дифференциальных уравнений (ОДУ):

$$\begin{aligned}\dot{u} &= au + \frac{1}{\varepsilon} v, \\ \dot{v} &= -\frac{1}{\varepsilon} v,\end{aligned}$$

с начальными данными $u(0) = u_0$, $v(0) = v_0$; здесь $a \sim O(1)$, $\varepsilon \ll 1$; и линейную систему с постоянными коэффициентами

$$\begin{aligned}\dot{u} &= 998u + 1998v, \\ \dot{v} &= -999u - 1999v, \\ u(0) &= v(0) = 1.\end{aligned}$$

Решением первой задачи Коши являются функции

$$\begin{aligned}u(t) &= u_0 e^{at} + \frac{v_0}{1 + a\varepsilon} (e^{at} - e^{-t/\varepsilon}), \\ v(t) &= v_0 e^{-t/\varepsilon},\end{aligned}$$

а второй —

$$\begin{aligned}u(t) &= 4e^{-t} - 3e^{-1000t}, \\ v(t) &= -2e^{-t} + 3e^{-1000t}.\end{aligned}$$

В обоих случаях решение состоит из двух экспонент: быстро убывающей и относительно медленно изменяющейся. Отметим,

что абсолютные величины собственных значений матриц рассматриваемых линейных систем ОДУ при их представлении в виде

$$\dot{\mathbf{u}} = \mathbf{A}\mathbf{u}$$

($\mathbf{u}$ — вектор-столбец, $\mathbf{A}$ — матрица с постоянными коэффициентами) существенно различаются. Так, в первом случае $\lambda_1 \approx \epsilon^{-1}$, $\lambda_2 \sim O(1)$; во втором: $\lambda_1 \approx -1$, $\lambda_2 = 10^{-3}$. В обоих случаях имеем

$$\frac{|\lambda_1|}{|\lambda_2|} \gg 1.$$

При моделировании физических процессов причина такой разницы в собственных числах заключена в существенно различных характерных временах процессов, описываемых системами ОДУ. Часто подобные системы встречаются при моделировании процессов в ядерных реакторах, при решении задач радиофизики, астрофизики, физики плазмы, биофизики, химической кинетики. Последние задачи часто могут быть записаны в виде

$$\frac{du_k}{dt} = \sum_{i=1}^N \sum_{j=1}^N a_{ij}^k u_i u_j, \quad k = 1, \dots, N;$$

где u_k — концентрации веществ, участвующих в химических реакциях, скорости протекания которых характеризуются коэффициентами a_{ij}^k . В качестве примера приведем одну из систем химической кинетики, описывающую изменение концентрации трех веществ, участвующих в реакции, для случая полного перемешивания.

Пример 1. Обозначим концентрации трех веществ, участвующих в реакции, через u_1 , u_2 и u_3 , тогда

$$\begin{aligned} \dot{u}_1 &= -4 \cdot 10^{-2} u_1 + 10^4 u_2 u_3, \\ \dot{u}_2 &= 10^{-2} u_1 - 10^4 u_2 u_3 - 6 \cdot 10^7 u_2^2, \\ \dot{u}_3 &= 3 \cdot 10^7 u_2^2, \\ u_1(0) &= 1, \quad u_2(0) = u_3(0) = 0. \end{aligned}$$

Участки решения, характеризующиеся быстрым и медленным его изменением, называются соответственно *пограничным слоем* и *квазистационарным режимом*.

Трудности численного решения подобных систем ОДУ, получивших название *жестких* (определение жесткой системы будет

приведено ниже), связаны с выбором шага интегрирования. Дело в том, что характерные времена исследуемых процессов могут различаться более чем в 10^{12} раз. Следовательно, если при численном решении системы

$$\dot{\mathbf{u}} = \mathbf{f}(\mathbf{u})$$

выбирать шаг из условия

$$\tau \|\mathbf{f}'_{\mathbf{u}}(\mathbf{u})\| \ll 1,$$

то он будет соответствовать самому быстрому процессу. В данном случае затраты машинного времени для исследования самых медленных процессов будут неоправданно велики. По этой причине имеется альтернатива в выборе подхода к численному решению рассматриваемых задач:

1) численно решать систему ОДУ с шагом

$$\tau \ll \|\mathbf{f}'_{\mathbf{u}}(\mathbf{u})\|^{-1},$$

т.е. с учетом характерных времен всех процессов, описываемых данной системой

2) «пренебречь» быстропротекающими процессами и численно рассматривать лишь медленные, проводя интегрирование с шагом, превышающим характерные времена быстрых процессов. В этом случае придется конструировать численные методы, позволяющие проводить расчеты с шагом

$$\tau \gg \|\mathbf{f}'_{\mathbf{u}}(\mathbf{u})\|^{-1}.$$

О п р е д е л е н и е 9.1. Система ОДУ для задачи Коши

$$\dot{\mathbf{u}} = \mathbf{f}(\mathbf{u}), \quad \mathbf{u}(0) = \mathbf{u}_0, \quad t_0 \leq t \leq t_k, \quad \mathbf{u}, \mathbf{f} \in R^N$$

называется жесткой, если спектр матрицы Якоби

$$\mathbf{J} = \{\mathbf{f}'_{\mathbf{u}}(\mathbf{u})\}$$

разделяется на две части.

1) Жесткий спектр:

$$\operatorname{Re} \Lambda_k(u) \leq -\Lambda_0, \quad |\operatorname{Im} \Lambda_k| < |\operatorname{Re} \Lambda_k|, \quad k = 1, \dots, N_1$$

(Λ_i — собственные значения матрицы Якоби); $\Lambda_0 > 0$.

2) *Мягкий спектр*:

$$|\lambda_k| \leq \lambda_0, \quad k = N_1 + 1, \dots, N, \quad \lambda_0 > 0.$$

При этом $\lambda_0 \ll \Lambda_0$ и $\lambda_0 T > 1$.

Для удобства восприятия элементы жесткого спектра будем обозначать Λ_k , а мягкого — λ_k .

Отношение Λ_0/λ_0 называется *показателем жесткости системы*.

В дальнейшем будем полагать $\lambda_0 \sim O(1)$. Проблему численного решения жестких систем ОДУ рассмотрим на примере модельной линейной системы

$$\dot{\mathbf{u}} = \mathbf{B}\mathbf{u}, \quad \mathbf{u}(0) = \mathbf{u}_0. \quad (9.1)$$

Ее точное решение задается формулой

$$\mathbf{u}(t) = \sum_{j=1}^{N_1} b_j e^{\Lambda_j t} \boldsymbol{\Omega}_j + \sum_{k=1}^{N_2} \bar{b}_k e^{\lambda_k t} \boldsymbol{\omega}_k, \quad (9.2)$$

где константы интегрирования b_j , $\bar{b}_k$ соответствуют жесткой и мягкой частям спектра; $\boldsymbol{\Omega}_j$, $\boldsymbol{\omega}_k$ — собственные векторы матрицы Якоби, соответствующие собственным значениям Λ_j , λ_k .

В этом решении видны две части: первая (жесткая) убывает как $e^{-\Lambda_0 t}$ на временном интервале $[t_0, O(\Lambda_0^{-1})]$ (пограничный слой), вторая заметно изменяется на интервале $[t_0, O(\Lambda_0^{-1})]$ (квазистационарный режим).

Если провести аппроксимацию линейной системы ОДУ с помощью явного метода Эйлера

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = \mathbf{B}\mathbf{u}^n,$$

или

$$\mathbf{u}^{n+1} = (\mathbf{E} + \tau \mathbf{B})\mathbf{u}^n,$$

то общее решение системы разностных уравнений будет иметь вид

$$\mathbf{u}_n(t) = \sum_{j=1}^{N_1} c_j (1 + \tau \Lambda_j)^n \boldsymbol{\Omega}_j + \sum_{k=1}^{N_2} c_k (1 + \tau \lambda_k)^n \boldsymbol{\omega}_k. \quad (9.3)$$

Второе слагаемое в этом решении аппроксимирует второе слагаемое в точном решении (9.2), а первое быстро растет по абсолютной величине и приводит к абсурдному результату.

Теперь проведем аппроксимацию линейной системы ОДУ (9.1) с помощью неявного метода Эйлера:

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = \mathbf{B}\mathbf{u}^{n+1},$$

или

$$\mathbf{u}^{n+1} = (\mathbf{E} + \tau\mathbf{B})^{-1}\mathbf{u}^n.$$

Общее решение такого разностного уравнения имеет следующий вид:

$$\mathbf{u}_n(t) = \sum_{j=1}^{N_1} c_j (1 - \tau\Lambda_j)^{-n} \boldsymbol{\Omega}_j + \sum_{k=1}^{N_2} \bar{c}_k (1 - \tau\lambda_k)^{-n} \boldsymbol{\omega}_k.$$

В этом случае второе слагаемое ведет себя так же, как и точное решение, а первое стремится к нулю как $(\tau\Lambda_0)^{-n}$, т.е. его поведение качественно совпадает с точным в области пограничного слоя.

В практике численных исследований жестких задач часто не нужно изучать поведение решения в пограничном слое и можно воспользоваться неявными методами. Но в случае необходимости исследовать этот слой можно с шагом $\tau \ll \Lambda_0^{-1}$. Устойчивость методов численного интегрирования жестких систем ОДУ обычно исследуется на примере скалярного уравнения (модельные уравнения Далквиста)

$$\dot{u} = \lambda u, \quad u(0) = u_0. \quad (9.4)$$

Положим, что численный метод, применяемый к решению этого уравнения, может быть записан в виде

$$u^{n+1} = R(z)u^n, \quad z = \tau\lambda,$$

где $R(z)$ называется функцией устойчивости. О построении функции устойчивости речь пойдет ниже.

О п р е д е л е н и е 9.2. Численный метод для решения уравнения (9.4) является абсолютно устойчивым, если выполнено условие

$$|R(z)| \leq 1.$$

Из определения следует, что $|u^{n+1}| \leq |u^n|$.

Это требование является естественным при $\operatorname{Re} z \leq 0$, поскольку в таком случае модуль точного решения есть невозрастающая функция.

Множество всех точек z , для которых $|R(z)| \leq 1$, называется *областью абсолютной устойчивости*.

Определение 9.3. Если область абсолютной устойчивости ($|R(z)| \leq 1$) занимает левую полуплоскость комплексной плоскости ($\operatorname{Re} z \leq 0$), то метод является *A-устойчивым* (заштрихованная область на рис. 9.1).




Рис. 9.1

Определение 9.4. Если область абсолютной устойчивости включает в себя угол (в левой полуплоскости комплексной плоскости) с вершиной в нуле и углом полураствора α , то метод называется *A(α)-устойчивым*.

Области $A(\alpha)$ - и $A(0)$ -устойчивости изображены на рис. 9.2а и рис. 9.2б соответственно.




Рис. 9.2

В случае, когда вся область абсолютной устойчивости включает в себя часть левой полуплоскости (граница ее лежит вне




Рис. 9.3

заштрихованной части на рис. 9.3), то метод называется жестко-устойчивым. Область жесткой устойчивости имеет вид, представленный, например, на рис. 9.3.

Определение 9.5. Численный метод называется *L-устойчивым*, если он *A-устойчив* и если

$$|R(z)| \rightarrow 0, \quad \text{при } Z \rightarrow \infty.$$

В частности, рассмотренный выше неявный метод Эйлера является *L-устойчивым*. Решения, полученные такими методами, будут затухающими.

9.2. Сингулярно-возмущенные задачи

Рассмотрим нелинейную жесткую систему А. Н. Тихонова (сингулярно-возмущенная задача Коши с малым параметром при производной):

$$\begin{aligned} \varepsilon \dot{u} &= f(u, v), \\ \dot{v} &= g(u, v), \\ 0 < \varepsilon &\ll 1, \end{aligned}$$

или

$$\begin{aligned} \dot{u} &= \frac{1}{\varepsilon} f(u, v), \\ \dot{v} &= g(u, v), \end{aligned}$$

с начальными условиями

$$u(0) = u_0, \quad v(0) = v_0.$$

Из характеристического уравнения находим:

$$\det \begin{vmatrix} \frac{1}{\varepsilon} f'_u - \lambda & \frac{1}{\varepsilon} f'_v \\ g'_u & g'_v - \lambda \end{vmatrix} = \lambda^2 - \lambda \left(\frac{1}{\varepsilon} f'_u + g'_v \right) + \frac{1}{\varepsilon} (f'_u g'_v - g'_u f'_v),$$

$$\lambda_1 = \frac{1}{\varepsilon} f'_u + O(1), \quad \lambda_2 = O(1),$$

т. е. λ_1 — жесткая, а λ_2 — мягкая часть спектра.

Первое, что хотелось бы сделать, — упростить задачу, положив $\varepsilon \approx 0$. В этом случае система приобретает вид

$$\begin{aligned} f(u, v) &= 0, \\ \dot{v} &= g(u, v), \\ u(0) &= u_0, \quad v(0) = v_0 \end{aligned}$$

и описывает траекторию, проходящую по кривой $f(u, v) = 0$. Эта кривая играет существенную роль в решении исходной системы ОДУ. Однако полностью поведение решения упрощенная (невозмущенная) система описывать не будет, поскольку начальные данные не обязательно должны лежать на этой кривой.

Для того чтобы понять эту ситуацию, рассмотрим фазовый портрет конкретной системы ОДУ вида

$$\begin{aligned} \varepsilon \dot{u} &= v - \frac{1}{3} u^3 + u, \\ \dot{v} &= -u, \\ u(0) &= u_0, \quad v(0) = v_0. \end{aligned}$$

Эта система эквивалентна нелинейному уравнению второго порядка — уравнению Ван-дер-Поля. Приведенный выше вид иногда называется представлением Льенара.

Кривая $f(u, v) = 0$ для этого случая изображена на рис. 9.4. Она делит плоскость u, v на две части: $f > 0$ и $f < 0$; вдали от кривой поле скоростей du, dv направлено почти горизонтально влево (вправо) в зависимости от знака f . В малой окрестности кривой выделяются две устойчивые ветви AB и CD , где $f'_u < 0$, и неустойчивая ветвь BD , на которой $f'_u > 0$. Опишем теперь качественно поведение траектории рассматриваемой системы ОДУ, состоящей из следующих участков.

1. Пограничный слой $A'A$. На этом участке за малое время $O(\varepsilon)$ траектория из точки $\{u_0, v_0\}$ переходит в ε -окрестность кривой $f = 0$. Здесь траектория почти горизонтальна и приближенно

определяется дифференциальным уравнением

$$\begin{aligned}\dot{u} &= \frac{1}{\varepsilon} f(u, v), \\ v(t) &\approx v_0, \\ u(0) &= u_0.\end{aligned}$$

($f/\varepsilon \gg g$, так как $f, g \sim O(1)$, $0 < \varepsilon \ll 1$).

В окрестности кривой $f(u, v) = 0$ имеем $f'_u < 0$, поэтому допустима оценка

$$\frac{df}{dt} = f'_u \cdot \dot{u} = \frac{1}{\varepsilon} f \cdot f'_u,$$

откуда видно, что $f(u, v_0)$ стремится к нулю как экспонента с показателем $\frac{1}{\varepsilon} f'_u$, т. е. f становится малой величиной (≈ 0) за время $t_{A'A} = O(\varepsilon)$.

2. Квазистационарный режим. Движение точки $\{u(t), v(t)\}$ продолжается уже вдоль кривой AB , $f(u, v) = 0$ и описывается системой

$$\begin{aligned}f(u, v) &= 0, \\ \dot{v} &= g(u, v).\end{aligned}$$

На этом участке за время $t_{AB} \sim O(1)$, что видно из второго уравнения, точка подвигается от A к B , пока система ОДУ устойчива. В случае невозмущенной системы точка могла бы и далее




Рис. 9.4

продвигаться вдоль BD , но для полной системы эта ветвь оказывается неустойчивой ($f'_u > 0$) и траектория «срывается» на устойчивую ветвь CD в точке B , в которой $f'_u = 0$.

3. Пограничный слой. На участке BC точка $\{u(t), v(t)\}$ «перескакивает» из B в C за малое время $O(\varepsilon)$; движение здесь, как и

на ветви AB , приближенно описывается уравнениями

$$\begin{aligned}\dot{u} &= \frac{1}{\varepsilon} f(u, v), \\ v(t) &\approx \text{const.}\end{aligned}$$

4. Квазистационарный режим. Движение вдоль ветви CD , как и вдоль ветви AB , описывается уравнениями

$$\begin{aligned}f(u, v) &= 0, \\ \dot{v} &= g(u, v),\end{aligned}$$

и длится $t_{CD} \sim O(1)$.

5. Пограничный слой. На неустойчивой ветви DA так же, как и на ветви BC , происходит скачок из точки D за время $t_{DA} \sim O(\varepsilon)$ в точку A и т. д.

Такое поведение траектории (замкнутая кривая) называется предельным циклом. Для жестких систем периодические решения называют иногда релаксационными колебаниями.

Таким образом, это характерно для жестких систем, траектория состоит из чередующихся участков быстрого (за время $t \sim O(\varepsilon)$) и медленного (за время $t \sim O(1)$) изменения решения.

Рассмотрим проблемы, которые могут возникнуть при численном интегрировании подобных жестких систем ОДУ. Численное интегрирование в зоне пограничного слоя, если оно необходимо исследователю, проблемы не составляет. Требуется лишь выполнение условия

$$\tau \cdot \frac{1}{\varepsilon} |f'_u| \ll 1.$$

В зоне квазистационарного режима часто оказывается, что интегрирование с таким шагом слишком дорого. Можно, правда, разрешить уравнение $f(u, v) = 0$ ($u = \varphi(v)$) относительно u и далее интегрировать его, предварительно реализовав алгоритм перехода на другой шаг:

$$\dot{v} = g(v, \varphi(v)),$$

однако в случаях более сложных построение подобных численных методов может оказаться отдельной сложной задачей.

Чаще всего в практике численных расчетов целесообразно использовать неявные схемы. В случае ЖС ОДУ неявные схемы предпочтительнее из соображений устойчивости. Так, рассматриваемую задачу можно аппроксимировать системой дискретных

уравнений

$$\begin{aligned}\frac{u^{k+1} - u^k}{\tau} &= \frac{1}{\varepsilon} f(u^{k+1}, v^{k+1}), \\ \frac{v^{k+1} - v^k}{\tau} &= g(u^{k+1}, v^{k+1}).\end{aligned}$$

Эта система нелинейных уравнений может быть решена численно, например методом Ньютона. Иногда полагают, что неявные схемы позволяют проводить численное интегрирование сквозным методом с большим шагом τ . Рассмотрим, к чему это может привести.

Первый пограничный слой будет пройден за один шаг:

$$\begin{aligned}u^1 &= u^0 + \frac{\tau}{\varepsilon} f(u^1, v^1), \\ v^1 &= v^0 + \tau g(u^1, v^1),\end{aligned}$$

так как $\varepsilon \ll \tau$, τg мало.

Далее следует процесс численного интегрирования на устойчивой ветви AB . В окрестности точки B поведение численного решения по неявной схеме осложняется. Это связано с тем, что рассматриваемая система в данной окрестности может иметь более одного решения. При этом по крайней мере одно из решений нелинейной алгебраической системы может лежать на неустойчивой ветви CD кривой $f(u, v) = 0$. Возможно, что при выборе большего шага интегрирования получится именно это нефизическое решение, к которому сойдутся итерации.

Такую опасность необходимо всегда учитывать при проведении численного интегрирования по неявным схемам с большим шагом.

9.3. Решение линейных ЖС ОДУ и вычисление матричной экспоненты

Рассмотрим один из наиболее простых численных методов решения жестких линейных систем ОДУ, основанный на представлении решения в явном виде

$$\mathbf{u}^{n+1} = e^{\mathbf{B}\tau} \mathbf{u}^n$$

для линейных систем жестких ОДУ вида

$$\dot{\mathbf{u}} = \mathbf{B}\mathbf{u}, \quad \mathbf{u}(0) = \mathbf{u}_0.$$

Его численная реализация связана с вычислением матричной экспоненты. Использование для этого разложения в ряд Тейлора

$$e^{\mathbf{B}\tau} = \mathbf{E} + \sum_{k=1}^N \frac{\tau^k}{k!} \mathbf{B}^k$$

представляется непригодным, так как простые оценки показывают, что по вычислительным затратам такой алгоритм сопоставим с методом Эйлера с шагом $\tau \|\mathbf{B}\| < 1$:

$$\frac{\tau^k}{k!} \|\mathbf{B}^k\| \approx \left(\frac{e\tau \|\mathbf{B}\|}{k} \right)^k, \text{ так как } k! \sim \left(\frac{k}{e} \right)^k.$$

Следовательно, для того чтобы k -й член разложения ряда Тейлора был по крайней мере порядка $O(1)$, необходимо выполнение условия

$$\frac{e\tau \|\mathbf{B}\|}{k} \sim O(1), \text{ или } \tau \|\mathbf{B}\| \sim O(1),$$

что соответствует условию численного интегрирования с шагом $\tau \|\mathbf{B}\| < 1$. Количество членов ряда при этом $N \sim \tau \|\mathbf{B}\| \gg 1$, что неприемлемо для решения.

Представим экспоненту в следующем эквивалентном виде:

$$e^{\mathbf{B}\tau} = (e^{\tau \mathbf{B}/2^p})^{2^p} \approx \left[\mathbf{E} + \frac{\tau}{2^p} \mathbf{B} + \dots + \frac{1}{k!} \left(\frac{\tau}{2^p} \right)^k \mathbf{B}^k \right]^{2^p}.$$

При этом значение параметра p выбирают таким, чтобы $\tau \|\mathbf{B}\|/2^p \ll 1$, и для построения алгоритма экономичного вычисления матричной экспоненты можно было использовать ряд Тейлора с небольшим количеством членов. Действительно, в этом случае

$$\frac{\tau \|\mathbf{B}\|}{k \cdot 2^p} \sim O(1) \text{ и } N \sim 2^{-p} \tau \|\mathbf{B}\|,$$

что вполне приемлемо при соответствующем выборе параметра p .

В этом алгоритме сначала вычисляют матрицу

$$\mathbf{D} = \mathbf{E} + \sum_{k=1}^N \left(\frac{\tau}{2^p} \right)^k \mathbf{B}^k,$$

затем $\mathbf{D}^{2^p}$ путем последовательных перемножений. При таком способе вычисления матрицы также имеется опасность, что при неко-

торых p , λ_0 , Λ_0 слагаемые, соответствующие мягкой части спектра, окажутся много меньше единицы (и слагаемых, соответствующих жесткой части). В этом случае предпочтение отдается представлению

$$\exp(\mathbf{B}\tau) = \left[\exp\left(-\frac{\tau}{2^p} \mathbf{B}\right)^{-1} \right]^{2^p},$$

а последовательность вычислений имеет вид

$$\mathbf{D} = \mathbf{E} + \frac{\tau}{2^p} \mathbf{B}; \quad \mathbf{C} = \mathbf{D}^{-1}; \quad \mathbf{C}' = (\mathbf{C}^2)^p.$$

При этом на мягкой части спектра, поскольку $\tau|\lambda_j| \ll 1$, имеем

$$\left(1 - \frac{\tau}{2^p} |\lambda_j|\right)^{-2^p} \approx e^{\lambda_j \tau};$$

на жесткой части, поскольку теперь p небольшие и $\tau|\Lambda_j|/2^p \gg 1$, получим оценку

$$\left| \left(\frac{1}{1 - \tau|\Lambda_j| \cdot 2^p} \right)^{2^p} \right| \ll 1,$$

что уже приемлемо для вычислений.

9.4. Численные методы решения ЖС ОДУ.

Семейства неявных методов Рунге–Кутты и Розенброка

Рассмотрим другие методы для численного решения как линейных жестких систем ОДУ вида (9.1), так и нелинейных систем общего вида

$$\dot{\mathbf{u}} = \mathbf{f}(t; \mathbf{u}), \quad \mathbf{u}(0) = \mathbf{u}_0$$

и автономных ЖС ОДУ

$$\dot{\mathbf{u}} = \mathbf{f}(\mathbf{u}), \quad \mathbf{u}(0) = \mathbf{u}_0.$$

Из соображений устойчивости метода предпочтение естественно отдать неявным методам. Простейшими из них являются:

1) *неявный метод Эйлера* (приведем его вид для случая автономной ЖС ОДУ, для неавтономной системы формулы очевидны):

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = \mathbf{f}(\mathbf{u}^{n+1}), \quad \mathbf{u}^0 = \mathbf{a};$$

2) метод трапеций

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = \frac{\mathbf{f}(\mathbf{u}^{n+1}, t_{n+1}) + \mathbf{f}(\mathbf{u}^n, t_n)}{2}, \quad \mathbf{u}^0 = \mathbf{a};$$

3) метод прямоугольников (правило средней точки)

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = \mathbf{f}(\mathbf{u}^{n+1/2}, t_{n+1/2}), \quad \mathbf{u}^0 = \mathbf{a},$$

где

$$t_{n+1/2} = \frac{t_{n+1} + t_n}{2}, \quad \mathbf{u}^{n+1/2} = \frac{\mathbf{u}^{n+1} + \mathbf{u}^n}{2}.$$

Среди одношаговых методов для решения жестких систем наиболее известны методы Рунге–Кутты. Все приведенные в данном параграфе формулы можно рассматривать как частные случаи неявных одно- и двухстадийных методов из этого семейства. Не останавливаясь на получении приводимых коэффициентов, выпишем наиболее известные из формул Рунге–Кутты, используя таблицу Бутчера. О представлении методов Рунге–Кутты в виде таблиц Бутчера см. лекцию 8.

Отметим, что в отличие от рассматриваемых выше *явных* методов при использовании *неявных* схем Рунге–Кутты матрица коэффициентов метода в таблице Бутчера — заполненная, и для определения вспомогательных векторов, входящих в функцию приращения, приходится решать систему нелинейных алгебраических уравнений.

Условия порядка для неявных методов Рунге–Кутты в общем аналогичны условиям порядка явных методов. Способ их получения совпадает со способом вывода для явных методов, хотя, конечно, он технически более сложен. Приведем несколько первых условий порядка:

1) условие порядка аппроксимации не ниже первого:

$$\sum_{i=1}^s b_i = 1;$$

это условие означает, что набор коэффициентов b суть веса некой квадратурной формулы;

2) условие по крайней мере второго порядка аппроксимации:

$$\sum_{i=1}^s b_i c_i = \frac{1}{2};$$

3) условий порядка аппроксимации не ниже третьего уже два:

$$\sum_{i=1}^s b_i c_i^2 = \frac{1}{3}; \quad \sum_{i=1}^s b_i \sum_{j=1}^s a_{ij} c_j = \frac{1}{6}.$$

Условия более высоких порядков приведены в [36].

Методы Гаусса соответственно 2-го, 4-го, и 6-го порядков представлены в табл. 9.1, табл. 9.2 и табл. 9.3. Основаны эти

Таблица 9.1.

$1/2$	$1/2$
	1

Таблица 9.2.

$\frac{1}{2} - \frac{\sqrt{3}}{6}$	$\frac{1}{4}$	$\frac{1}{4} - \frac{\sqrt{3}}{6}$
$\frac{1}{2} + \frac{\sqrt{3}}{6}$	$\frac{1}{4} + \frac{\sqrt{3}}{6}$	$\frac{1}{4}$
	$1/2$	$1/2$

Таблица 9.3.

$\frac{1}{2} - \frac{\sqrt{15}}{10}$	$\frac{5}{36}$	$\frac{2}{9} - \frac{\sqrt{15}}{15}$	$\frac{5}{36} - \frac{\sqrt{15}}{30}$
$\frac{1}{2}$	$\frac{5}{36} + \frac{\sqrt{15}}{24}$	$\frac{2}{9}$	$\frac{5}{36} - \frac{\sqrt{15}}{24}$
$\frac{1}{2} + \frac{\sqrt{15}}{10}$	$\frac{5}{36} + \frac{\sqrt{15}}{30}$	$\frac{2}{9} + \frac{\sqrt{15}}{15}$	$\frac{5}{36}$
	$\frac{5}{18}$	$\frac{4}{9}$	$\frac{5}{18}$

Таблица 9.4.

1	1
	1

Таблица 9.5.

$1/3$	$5/12$	$-1/12$
1	$3/4$	$1/4$
	$3/4$	$1/4$

Таблица 9.6.

$\frac{4 - \sqrt{6}}{10}$	$88 - 7\sqrt{6}$	$\frac{296 - 169\sqrt{6}}{1800}$	$\frac{-2 + 3\sqrt{6}}{225}$
$\frac{4 + \sqrt{6}}{10}$	$\frac{296 + 169\sqrt{6}}{1800}$	$\frac{88 + 7\sqrt{6}}{360}$	$\frac{-2 - 3\sqrt{6}}{225}$
1	$\frac{16 - \sqrt{6}}{36}$	$\frac{16 + \sqrt{6}}{36}$	$\frac{1}{9}$
	$\frac{16 - \sqrt{6}}{36}$	$\frac{16 + \sqrt{6}}{36}$	$\frac{1}{9}$

методы на соответствующих квадратурных формулах Гаусса, рассмотренных в лекции 7. Первый метод совпадает с правилом средней точки. Второй метод (4-го порядка) носит название метода Хаммера–Холлинсворта.

Методы Радо IIA порядков 1, 3, 5 представлены соответственно в табл. 9.4, табл. 9.5 и табл. 9.6. Основаны на квадратурных формулах Радо, принадлежащих к семейству формул Гаусса. Метод первого порядка является неявным методом Эйлера.

Методы Лобатто IIIA 2-го, 4-го и 6-го порядков точности см. в табл. 9.7, табл. 9.8 и табл. 9.9 соответственно. Видно, что метод второго порядка точности является неявным методом трапеций.

Т а б л и ц а 9.7.

0	0	0
1	1/2	1/2
	1/2	1/2

Т а б л и ц а 9.8.

0	0	0	0
1/2	5/24	1/3	-1/24
1	1/6	2/3	1/6
	1/6	2/3	1/6

Т а б л и ц а 9.9.

0	0	0	0	0
$5 - \sqrt{5}$	$\frac{11 + \sqrt{5}}{120}$	$\frac{25 - \sqrt{5}}{120}$	$\frac{25 - 13\sqrt{5}}{120}$	$\frac{-1 + \sqrt{5}}{120}$
$5 + \sqrt{5}$	$\frac{11 - \sqrt{5}}{120}$	$\frac{25 + 13\sqrt{5}}{120}$	$\frac{25 + \sqrt{5}}{120}$	$\frac{-1 - \sqrt{5}}{120}$
1	1/12	5/12	5/12	1/12
	1/12	5/12	5/12	1/12

Рассмотрим теперь, как строится функция устойчивости для методов Рунге–Кутты [35]. Выше уже отмечалось, что при построении функции устойчивости рассматривается модельное уравнение вида

$$\dot{v} = \lambda v, \quad v(0) = v_0.$$

Запишем теперь метод Рунге–Кутты для решения приведенного выше уравнения в общей форме с использованием новых переменных Y :

$$v^{n+1} = v^n + \tau \sum b_p f(t_n + c_p \tau, Y_p) \equiv v^n + \tau \lambda \sum b_p Y_p,$$

$$Y_p = v^n + \tau \sum_{k=1}^s a_{kp} f(t_n + c_k \tau, Y_k) \equiv v^n + \tau \lambda \sum b_{kp} Y_k.$$

Приведенные выше формулы можно рассматривать как систему линейных уравнений относительно новых переменных $Y_1, \dots, Y_k, v_{n+1}$ следующего вида:

$$\begin{pmatrix} 1 - za_{11} & -za_{12} & \dots & -za_{1s} & 0 \\ -za_{21} & 1 - za_{22} & \dots & -za_{2s} & 0 \\ \dots & \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots & \dots \\ -za_{s1} & -za_{s2} & \dots & 1 - za_{ss} & 0 \\ -zb_1 & -zb_2 & \dots & -zb_s & 1 \end{pmatrix} \begin{pmatrix} Y_1 \\ Y_2 \\ \dots \\ Y_s \\ v^{n+1} \end{pmatrix} = \begin{pmatrix} v^n \\ v^n \\ \dots \\ v^n \\ v^n \end{pmatrix}.$$

Необходимо выразить v^{n+1} через v^n . Для этого воспользуемся правилом Крамера. Ответ можно записать в следующей форме:

$$v^{n+1} = \frac{\det(\mathbf{E} - z\mathbf{A} + z\mathbf{e}\mathbf{b}^T)}{\det(\mathbf{E} - z\mathbf{A})} v^n,$$

где $\mathbf{E}$ — единичная матрица размера $S \times S$, $\mathbf{A}$ — матрица коэффициентов a_{ij} , входящая в таблицу Бутчера, $\mathbf{e}$ — единичный вектор размерности S (столбец), $\mathbf{b}^T$ — строка коэффициентов b_l , входящая в таблицу Бутчера, S — число стадий метода Рунге–Кутты.

Условием устойчивости метода будет

$$\left| \frac{\det(\mathbf{E} - z\mathbf{A} + z\mathbf{e}\mathbf{b}^T)}{\det(\mathbf{E} - z\mathbf{A})} \right| < 1.$$

Одноитерационные методы Розенброка. Розенброком был предложен класс неявных методов, в котором не решается система нелинейных уравнений.

Рассмотрим связь между методами Розенброка и Рунге–Кутты.

О п р е д е л е н и е 9.6. *S-стадийный метод Розенброка для решения автономной системы ЖС ОДУ имеет вид*

$$\mathbf{k}_i = \tau \mathbf{f} \left(\mathbf{u}_n + \sum_{j=1}^{i-1} \beta_{i,j} \mathbf{k}_j \right) + \tau \mathbf{B} \sum_{j=1}^i \mu_{i,j} \mathbf{k}_j, \quad i = 1, \dots, S,$$

$$\mathbf{u}^{n+1} = \mathbf{u}^n + \sum_{k=1}^S \gamma_k \mathbf{k}_k,$$

где β, γ, μ — управляющие коэффициенты метода. Как и выше, матрица Якоби правой части системы $\mathbf{B}$ вычисляется по данным в точке t_n .

Связь последних формул с выражениями для явных методов Рунге–Кутты очевидна.

Несколько сложнее представляются методы Розенброка в случае неавтономной ЖС ОДУ [35]:

$$\mathbf{k}_i = \tau \mathbf{f} \left(t_n + \alpha_i \tau, \mathbf{u}^n + \sum_{j=1}^{i-1} \beta_{i,j} \mathbf{k}_j \right) + \tau \mathbf{B} \sum_{j=1}^i \mu_{i,j} \mathbf{k}_j + \mu_i \tau^2 \mathbf{B},$$

$$i = 1, \dots, S,$$

$$\mathbf{u}^{n+1} = \mathbf{u}^n + \sum_{k=1}^S \gamma_k \mathbf{k}_k, \quad \alpha_i = \sum_j \beta_{i,j}, \quad \mu_i = \sum_j \mu_{i,j}.$$

Вывод *условий порядка* методов Розенброка — достаточно громоздкий, и всем заинтересованным читателям можно рекомендовать разобраться в выкладках в книге [35]. Отметим, что широкое распространение получают в последнее время вложенные методы Розенброка высокого порядка аппроксимации, имеющие очень хорошие вычислительные качества. Возможно, что новые методы типа Розенброка способны будут вытеснить из вычислительной практики наиболее распространенные до этого в вычислительной практике методы Гира.

9.5. Формулы «дифференцирования назад» и методы Гира. Представление Нордсика

В предыдущей лекции вкратце был изложен альтернативный методам Рунге–Кутты подход к построению численных методов для решения ОДУ, основанный на расширении шаблона разностной схемы. При переходе от точки t_n к t_{n+1} использовались значения решения (или функций от него) в предыдущих точках. Полученные численные методы (первые схемы такого рода были получены Адамсом) носят название линейных многошаговых. Однако применение методов Адамса для решения ЖС ОДУ приводит к неутешительному результату. Отчасти он обоснован результатом, полученным Далквистом.

Теорема 9.1 (Далквиста, или второй барьер Далквиста [34, 35]). *Не существует А-устойчивых линейных многошаговых схем с порядком аппроксимации выше второго.*

Попробуем ввести другой класс линейных многошаговых методов — это так называемые «формулы дифференцирования назад» (или ФДН-методы) [35].

Общий вид ФДН-метода в записи неопределенных коэффициентов таков:

$$\mathbf{u}^{n+1} + \sum_{j=1}^k \alpha_j \mathbf{u}^{n+1-j} = \tau \mathbf{f}^{n+1}, \quad (9.5)$$

где коэффициенты α_j, β выбираются из условий аппроксимации метода. В отличие от методов типа Рунге–Кутты, при использовании ФДН-методов нелинейная система алгебраических уравнений для определения u_{n+1} имеет меньшую размерность, следовательно, требуется меньшее число операций для нахождения решения.

Семейство $A(\alpha)$ -устойчивых ФДН-методов с достаточно большим значением угла полураствора α носит общее название методов Гира. Коэффициенты методов Гира, представленных в виде (9.5), приведены в табл. 9.10.

Величина k характеризует количество точек в шаблоне и порядок аппроксимации ФДН-метода. В первом столбце таблицы также приведен угол полураствора α для $A(\alpha)$ -устойчивых методов. ФДН-методы с порядком аппроксимации 7 и выше безусловно неустойчивы.

К очевидным недостаткам методов ФДН (как, впрочем, и других многошаговых) является необходимость разгонного участка и трудности при автоматическом выборе шага. Существует эквивалентная форма ФДН-методов — методы Нордсика, — в которой эти недостатки преодолеваются сравнительно легко. В некоторых источниках они не выделяются в самостоятельный класс методов, а называются ФДН-методами в представлении Нордсика.

Т а б л и ц а 9.10. Коэффициенты методов Гира

k	β	α_0	α_1	α_2	α_3	α_4	α_5
1	1	-1					
2	$\frac{2}{3}$	$\frac{1}{3}$	$-\frac{4}{3}$				
3(86)	$\frac{6}{11}$	$-\frac{2}{11}$	$\frac{9}{11}$	$-\frac{18}{11}$			
4(73,35)	$\frac{12}{25}$	$-\frac{3}{25}$	$\frac{16}{25}$	$\frac{36}{25}$	$-\frac{48}{25}$		
5(51,84)	$\frac{60}{137}$	$-\frac{12}{137}$	$\frac{75}{137}$	$-\frac{200}{137}$	$\frac{300}{137}$	$-\frac{300}{137}$	
6(17,84)	$\frac{600}{147}$	$\frac{10}{147}$	$-\frac{72}{147}$	$\frac{225}{147}$	$-\frac{400}{147}$	$\frac{450}{147}$	$-\frac{360}{147}$

Рассмотрим в качестве примера построение метода Нордсика [26, 34] для модельной задачи

$$\dot{u} = f(t, u), \quad u(0) = u_0 \quad (9.6)$$

и введем также в рассмотрение вектор Нордсика

$$\mathbf{z}^n = \left(u^n, u'(t_n), \frac{\tau^2}{2} u''(t_n), \dots, \frac{\tau^k}{k!} u^{(k)}(t_n) \right)^T,$$

в который, кроме искомого значения функции, включены приближенные значения первых k производных в узлах сетки. Для того чтобы осуществить переход к следующему значению z_{n+1} , необходимо задать правила вычисления компонентов вектора z по данным в текущий момент времени. Ограничимся рассмотрением случая $k = 3$. Для этого разложим (9.6) в ряд Тейлора в окрестности t_n :

$$u(t_{n+1}) = u(t_n) + \tau u'(t_n) + \frac{\tau^2}{2} u''(t_n) + \frac{\tau^3}{3!} u^{(3)}(t_n) + \frac{\tau^4}{4!} u^{(4)}(\xi); \quad (9.7)$$

для записи ряда использован остаточный член в форме Лагранжа.

Кроме того, используем следующие следствия приведенного выше разложения:

$$\tau u'(t_{n+1}) = \tau u'(t_n) + 2 \frac{\tau^2}{2} u''(t_n) + 3 \frac{\tau^3}{3!} u^{(3)}(t_n) + 4 \frac{\tau^4}{4!} u^{(4)}(\xi), \quad (9.8)$$

$$\frac{\tau^2}{2} u''(t_{n+1}) = 2 \frac{\tau^2}{2} u''(t_n) + 3 \frac{\tau^3}{3!} u^{(3)}(t_n) + 6 \frac{\tau^4}{4!} u^{(4)}(\xi), \quad (9.9)$$

$$\frac{\tau^3}{3!} u^{(3)}(t_{n+1}) = 3 \frac{\tau^3}{3!} u^{(3)}(t_n) + 4 \frac{\tau^4}{4!} u^{(4)}(\xi), \quad (9.10)$$

а конкретное значение ξ выберем из условий аппроксимации уравнения (9.6), т. е. $u'(t_{n+1}) = f(t_{n+1}, u_{n+1})$.

Подставляя это равенство в (9.8), получим

$$4 \frac{\tau^4}{4!} e = \tau (f(t_{n+1}, u^{n+1}) - f_n^p), \quad (9.11)$$

где

$$\tau f_n^p = \tau u'(t_n) + 2 \frac{\tau^2}{2!} u''(t_n) + 3 \frac{\tau^3}{3!} u^{(3)}(t_n).$$

Велик соблазн подставить выражение для e (9.11) в формулы (9.7)–(9.10), что приводит к неустойчивым методам. Чтобы показать это, подставим во все формулы выше $f(t, u) = 0$. В этом

случае метод превращается в линейное преобразование

$$\mathbf{z}^{n+1} = \mathbf{M}\mathbf{z}^n$$

с матрицей

$$\mathbf{M} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 \\ 0 & 0 & 1 & 3 \\ 0 & 0 & 0 & 1 \end{pmatrix} - \begin{pmatrix} 1/4 \\ 1 \\ 3/2 \\ 1 \end{pmatrix} \begin{pmatrix} 0 & 1 & 2 & 3 \end{pmatrix}.$$

Собственные значения $\mathbf{M}$ равны $1, 0, -2 \pm \sqrt{3}$, откуда следует неустойчивость метода, а потому и его практическая непригодность.

Чтобы преодолеть трудность, Нордсик предложил заменить постоянные $1/4, 1, 3/2, 1$, стоящие в (9.7)–(9.10) перед скобками после подстановки в них (9.11), на произвольные значения (l_0, l_1, l_2, l_3) и использовать эту дополнительную степень свободы для достижения устойчивости. Такую модификацию можно записать в компактной форме

$$\mathbf{z}^{n+1} = (\mathbf{P} \otimes \mathbf{E})\mathbf{z}^n + (\mathbf{1} \otimes \mathbf{E})(\tau \mathbf{f}(t_{n+1}, \mathbf{u}^{n+1}) - (\mathbf{e}_1^T \mathbf{P} \otimes \mathbf{E})\mathbf{z}^n). \quad (9.12)$$

Здесь $\mathbf{P}$ — треугольная матрица Паскаля, определяемая формулой

$$\mathbf{P}_{ij} = \begin{cases} C_i^j, & 0 \leq i \leq j \leq k, \\ 0, & \text{в противном случае,} \end{cases}$$

$\mathbf{1} = (l_0, l_1, \dots, l_k)$, $\mathbf{e}_1 = (0, 1, 0, \dots, 0)^T$ (индексы векторов и матриц начинаются с нуля). Через $\mathbf{P} \otimes \mathbf{E}$ обозначено тензорное произведение Кронекера, т. е. блочная матрица размерности mk (m — размерность системы ОДУ) с $m \times m$ блоками $\mathbf{P}_{ij}\mathbf{E}$.

Условие аппроксимации построенного метода фиксирует значение $l_1 = 1$. Анализируя устойчивость метода общего вида (9.12), как описано выше, мы придем к разностному уравнению с матрицей

$$\mathbf{M} = \mathbf{P} - \mathbf{l}\mathbf{e}_1^T \mathbf{P}.$$

Например, для $k = 3$ эта матрица имеет вид

$$\mathbf{M} = \begin{pmatrix} 1 & 1 - l_0 & 1 - 2l_0 & 1 - 3l_0 \\ 0 & 0 & 0 & 0 \\ 0 & -l_2 & 1 - 2l_2 & 3 - 3l_2 \\ 0 & -l_3 & -2l_3 & 1 - 3l_3 \end{pmatrix}.$$

Заметим, что 1 и 0 являются собственными значениями матрицы $\mathbf{M}$, а ее характеристический многочлен не зависит от l_0 . Нордсик определил $l_2, \dots, l_k$ таким образом, чтобы остальные собственные значения $\mathbf{M}$ были равны нулю. В случае $k = 3$ это выполняется при $l_2 = 3/4$, $l_3 = 1/6$. Коэффициент l_0 можно выбрать из условия обращения в ноль константы погрешности метода. В нашем случае получается $l_0 = 3/8$, а весь метод задается вектором $\mathbf{l} = (3/8, 1, 3/4, 1/6)$.

Отметим, что метод Гира в представлении Нордсика оказывается самостоятельно стартовым. При старте можно положить вектор Нордсика для данной задачи равным, например, $\mathbf{z}_0 = (u_0, 0, 0, \dots, 0)$, что позволит начать вычисления, но приведет к уменьшению порядка аппроксимации. Таким образом, многозначный (по введенной в [26] терминологии) вариант метода Гира обладает переменным порядком аппроксимации: стартуя как метод первого порядка, по завершении разгонного участка метод стремится к максимально возможному для данной формулы порядку.

Отметим также, что для системы с релаксационными колебаниями лучшие результаты могут давать многозначные методы Гира не очень высокого порядка аппроксимации.

9.6. Примеры решения задач

1. Исследовать на порядок аппроксимации, A -устойчивость и L -устойчивость трехстадийные ДНМРК с таблицами Бутчера:

$$\text{а) } \left[\begin{array}{c|cccc} & 1/3 & & & \\ \mathbf{c} & 1 & & & \\ \mathbf{A} & & 1/3 & & \\ \hline & 1 & 0 & 0 & 1 \\ \mathbf{b}^T & & 3/4 & 3/4 & -1/2 \end{array} \right] ;$$

$$\text{б) } \left[\begin{array}{c|cccc} & 1 & & & \\ \mathbf{c} & 1/3 & & & \\ \mathbf{A} & & 1 & & \\ & & 0 & 1/3 & \\ \hline & 1 & -1/12 & 3/4 & 1/3 \\ \mathbf{b}^T & & -1/12 & 3/4 & 1/3 \end{array} \right] ;$$

$$\text{в) } \left[\begin{array}{c|cccc} c_1 & a & & & \\ c_2 & a_{21} & a & & \\ c_3 & a_{31} & a_{32} & a & \\ \hline & b_1 & b_2 & b_3 & \end{array} \right]$$

— однократно диагонально-неявный метод Рунге–Кутты (SDIRK); коэффициенты a_{ij} , b_i ($i = 1, 2$) имеют значения

$$\begin{aligned} a_{21} &= -\frac{a - 1/3}{2\left(a^2 - 2a + \frac{1}{2}\right)}, \\ b_1 &= a_{31} = 1 - a - b_2, \\ b_2 &= a_{32} = -\frac{2\left(a^2 - 2a + \frac{1}{2}\right)^2}{a - \frac{1}{3}}, \\ b_3 &= a, \end{aligned}$$

где $a = 1 + \sqrt{2}\cos((\varphi + 4\pi)/3)$, $\varphi = \arccos(2\sqrt{2}/3)$.

Коэффициенты c_1 , c_2 , c_3 получаются из условий Кутты: $c_i = \sum_j a_{ij}$.

Р е ш е н и е. Проверяя условия порядка методов Рунге–Кутты, получим, что все три метода имеют третий порядок аппроксимации.

Найдем функции устойчивости методов. Для случая а) функция устойчивости

$$\begin{aligned} R(z) &= \frac{\det(\mathbf{E} - z\mathbf{A} + z\mathbf{e}\mathbf{b}^T)}{\det(\mathbf{E} - z\mathbf{A})} = \\ &= \frac{\det\begin{pmatrix} 1 - \frac{z}{3} + \frac{3z}{4} & \frac{3z}{4} & -\frac{z}{2} \\ -\frac{z}{3} + \frac{3z}{4} & 1 - 2\frac{z}{3} + \frac{3z}{4} & -\frac{z}{2} \\ \frac{3z}{4} & \frac{3z}{4} & 1 - z - \frac{z}{2} \end{pmatrix}}{\det\begin{pmatrix} 1 - \frac{z}{3} & 0 & 0 \\ -\frac{z}{3} & 1 - 2\frac{z}{3} & 0 \\ 0 & 0 & 1 - z \end{pmatrix}} = \\ &= \frac{1 - z - \frac{5z^2}{18} + \frac{z^3}{6}}{\left(1 - \frac{z}{3}\right)\left(1 - \frac{2z}{3}\right)(1 - z)}. \end{aligned}$$

Если степени числителя и знаменателя совпадают, $R(-\infty) = 3/4$, то метод а) может быть A -устойчивым. Можно аккуратно

построить границу области устойчивости на комплексной плоскости (например, с помощью пакета Mathematica) и убедиться, что метод действительно является A -устойчивым — граница целиком лежит в правой полуплоскости комплексной плоскости.

Для случая б) функция устойчивости

$$R(z) = \frac{\det \begin{pmatrix} 1 - z - z/12 & \frac{3z}{4} & \frac{z}{3} \\ -z/12 & 1 - \frac{z}{3} + \frac{3z}{4} & \frac{z}{3} \\ 0 & 0 & 1 \end{pmatrix}}{\det \begin{pmatrix} 1 - z & 0 & 0 \\ 0 & 1 - \frac{z}{3} & 0 \\ z/12 & -\frac{3z}{4} & 1 - \frac{z}{3} \end{pmatrix}} = \frac{18 - 12z - 7z^2}{2(3 - z)^2(1 - z)}.$$

Поскольку степень многочлена в числителе на единицу меньше, чем в знаменателе, диагонально-неявный метод Рунге–Кутты из пункта б) может быть L -устойчивым (если он A -устойчив). Также графически можно убедиться, что это истина — граница области устойчивости также целиком лежит в правой полуплоскости.

Наконец, для случая в)

$$\begin{aligned} R(z) &= \frac{\det \begin{pmatrix} 1 - az + \left(a - 1 - \frac{2(a^2 - 2a + \frac{1}{2})^2}{a - \frac{1}{3}} \right) z & -\frac{2(a^2 - 2a + \frac{1}{2})^2}{a - \frac{1}{3}} z & az \\ \frac{-(a - \frac{1}{3})z}{2(a^2 - 2a + \frac{1}{2})} + \left(a - 1 - \frac{2(a^2 - 2a + \frac{1}{2})^2}{a - \frac{1}{3}} \right) z & 1 - az - \frac{2(a^2 - 2a + \frac{1}{2})^2}{a - \frac{1}{3}} z & az \\ 0 & 0 & 1 \end{pmatrix}}{\det \begin{pmatrix} 1 - az & 0 & 0 \\ \frac{-(a - \frac{1}{3})z}{2(a^2 - 2a + \frac{1}{2})} & 1 - az & 0 \\ \left(a - 1 - \frac{2(a^2 - 2a + \frac{1}{2})^2}{a - \frac{1}{3}} \right) z & \frac{2(a^2 - 2a + \frac{1}{2})^2}{a - \frac{1}{3}} z & 1 - az \end{pmatrix}} = \\ &= \frac{(1 - az)^2 + (1 - az)(1 - a)z + z^2(a^2 - 2a + \frac{1}{2})}{(1 - az)^3}. \end{aligned}$$

Коэффициент при z^3 в числителе равен нулю, метод является L -устойчивым. По своим вычислительным свойствам методы б) и в) очень близки.

2. На отрезке $[-1; 1]$ заданы узлы квадратурной формулы Гаусса $-(1/3)^{1/2}$, $(1/3)^{1/2}$; веса соответствующей квадратурной формулы равны $1/2$. Построить однопараметрическое семейство двухстадийных диагонально неявных методов Рунге–Кутты, удовлетворяющих необязательным условиям Кутты.

1) Исследовать построенное семейство на устойчивость для решения жестких систем ОДУ.

2) Найти асимптотически устойчивые методы для решения жестких систем ОДУ

3) Найти среди методов для решения жестких систем ОДУ метод с наивысшим порядком аппроксимации.

Решение. Отообразим отрезок $[-1; 1]$ на $[0; 1]$. Тогда сразу получим узлы и веса квадратуры, которые будут являться соответствующими коэффициентами метода

$\frac{1}{2} - \frac{\sqrt{3}}{6}$	?
$\frac{1}{2} + \frac{\sqrt{3}}{6}$	? ?
$\frac{1}{2}$	$\frac{1}{2}$

Условия Кутты позволяют ввести единственный параметр в таблицу:

$\frac{1}{2} - \frac{\sqrt{3}}{6}$	$\frac{1}{2} - \frac{\sqrt{3}}{6}$
$\frac{1}{2} + \frac{\sqrt{3}}{6}$	$\frac{1}{2} + \frac{\sqrt{3}}{6} - \gamma$ γ
$\frac{1}{2}$	$\frac{1}{2}$

Проверим условия порядка метода. Условия порядка 1 выполнены: $1/2 + 1/2 = 1$. Условия порядка 2 также выполнены:

$$\frac{1}{2} \left(\frac{1}{2} - \frac{\sqrt{3}}{6} \right) + \frac{1}{2} \left(\frac{1}{2} + \frac{\sqrt{3}}{6} \right) = \frac{1}{2}.$$

Однопараметрическое семейство двухстадийных схем по крайней мере второго порядка аппроксимации построено. Найдем величину γ , обеспечивающую третий порядок аппроксимации.

Условиями третьего порядка аппроксимации являются два:

$$1) \sum_i^2 b_i c_i^2 = \frac{1}{3}, \text{ или тождество}$$

$$\frac{1}{2} \left(\frac{1}{2} - \frac{\sqrt{3}}{6} \right)^2 + \frac{1}{2} \left(\frac{1}{2} + \frac{\sqrt{3}}{6} \right)^2 = \frac{1}{3},$$

что не влечет дополнительных условий на величину γ .

$$2) \sum_{i,j=1}^2 b_i a_{ij} c_j = \frac{1}{6}, \text{ или}$$

$$\frac{1}{2} \left(\frac{1}{2} - \frac{\sqrt{3}}{6} \right)^2 + \frac{1}{2} \left[\left(\frac{1}{2} + \frac{\sqrt{3}}{6} - \gamma \right) \left(\frac{1}{2} - \frac{\sqrt{3}}{6} \right) + \gamma \left(\frac{1}{2} + \frac{\sqrt{3}}{6} \right) \right] = \frac{1}{6}.$$

Второе условие выполняется при $\gamma = \frac{1}{2} - \frac{\sqrt{3}}{6}$.

Строим функцию устойчивости метода. Она есть

$$\begin{aligned} R(z) &= \frac{\det(\mathbf{E} - z\mathbf{A} + z\mathbf{e}\mathbf{b}^T)}{\det(\mathbf{E} - z\mathbf{A})} = \\ &= \frac{\det \begin{pmatrix} 1 + z\frac{\sqrt{3}}{6} & \frac{z}{2} \\ -\left(\frac{\sqrt{3}}{6} - \gamma\right)z & 1 - \gamma z + \frac{z}{2} \end{pmatrix}}{\det \begin{pmatrix} 1 - \left(\frac{1}{2} - \frac{\sqrt{3}}{6}\right)z & 0 \\ -\left(\frac{1}{2} + \frac{\sqrt{3}}{6} - \gamma\right)z & 1 - \gamma z \end{pmatrix}} = \frac{\frac{1}{2}z^2\left(\frac{\sqrt{3}}{6} - \gamma\right) + \left(1 + z\frac{\sqrt{3}}{6}\right)\left(1 - z\left(\gamma - \frac{1}{2}\right)\right)}{\left(1 + z\left(\frac{\sqrt{3}}{6} - \frac{1}{2}\right)\right)(1 - z\gamma)}. \end{aligned}$$

Для асимптотической устойчивости (L -устойчивости) необходимо, чтобы в числителе стоял полином первой степени по z , откуда имеем $\gamma = (\sqrt{3} - 1)/2$.

Библиографический комментарий к Лекции 9

Основной рекомендуемой книгой при углубленном изучении данного раздела, безусловно, является [35]. Математические модели, описываемые жесткими системами ОДУ, встречаются довольно часто. Необходимые ссылки на источники приведены при формулировке соответствующих задач. О многоступенчатых методах в представлении Нордсика см. также [26]. О методах для решения ЖС ОДУ и их построении при помощи метода неопределенных коэффициентов см. [38].

Для практических занятий по данной теме рекомендуется использовать также задачник [40].

ЧИСЛЕННОЕ РЕШЕНИЕ КРАЕВЫХ ЗАДАЧ ДЛЯ СИСТЕМ ОБЫКНОВЕННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ

Рассматриваются численные методы решения краевых задач. Для нелинейных краевых задач рассмотрены методы стрельбы и квазилинеаризации. Дается представление о методах решения спектральных задач (задач на собственные значения). Обсуждается вопрос о применении метода Фурье при решении краевых задач для разностных уравнений, аппроксимирующих исходную дифференциальную задачу.

Ключевые слова: Метод стрельбы. Метод прогонки. Дифференциальная прогонка. Жесткие краевые задачи. Метод квазилинеаризации. Задача Штурма–Лиувилля. Метод Фурье.

10.1. Краевая задача для линейной системы ОДУ первого порядка

Рассмотрим линейную систему ОДУ первого порядка

$$\frac{d\mathbf{u}}{dt} = \mathbf{A}\mathbf{u} + \mathbf{f}, \quad \mathbf{u} \in R^n, \quad t \in [0; L]$$

с краевыми условиями

$$\mathbf{R}\mathbf{u}(0) + \mathbf{S}\mathbf{u}(L) = \mathbf{q},$$

где $\mathbf{u}$, $\mathbf{f}$, $\mathbf{q}$ — n -мерные векторы, $\mathbf{A}(t)$, $\mathbf{R}(t)$, $\mathbf{S}(t)$ — матрицы размера $n \times n$.

Для приближенного решения задачи введем расчетную сетку $\{t_n\}_{n=0}^N$ и за приближенное решение примем сеточную функцию $\{u_n\}_{n=0}^N$. Рассмотрим методы построения приближенного решения.

Метод построения фундаментальных решений аналогичен известному по курсу дифференциальных уравнений способу построения общего решения системы линейных уравнений первого порядка. Решение представляется в виде

$$\mathbf{u}(t) = \overline{\mathbf{u}}(t) + \sum_{k=1}^n \alpha_k \mathbf{u}^k.$$

Здесь $u_k(t)$ есть полная фундаментальная система решений однородной задачи

$$\frac{d\mathbf{u}^k}{dt} = \mathbf{A}\mathbf{u}^k, \quad k = 1, 2, \dots, n$$

с начальными данными, например,

$$\mathbf{u}^k(0) = \{0, \dots, 0, 1, 0, \dots, 0\}^T,$$

где единица стоит на k -м месте, т.е. в качестве начальных данных используются векторы $\mathbf{u}^k(0) = \mathbf{e}_k$. Важно, чтобы решения однородной задачи составляли систему линейно независимых функций. Каждая такая функция ищется численно как решение соответствующей задачи Коши с использованием методов, описанных в лекциях 8 и 9.

Пусть $\bar{\mathbf{u}}(t)$ — частное решение неоднородной системы

$$\frac{d\bar{\mathbf{u}}}{dt} = \mathbf{A}\bar{\mathbf{u}} + \mathbf{f}$$

с нулевыми начальными условиями $\bar{\mathbf{u}}(0) = 0$. Тогда неопределенные коэффициенты α_k находятся из краевых условий

$$\mathbf{R}\mathbf{u}(0) + \mathbf{S}\mathbf{u}(L) = \mathbf{q},$$

или

$$\mathbf{R}\left[\bar{\mathbf{u}}(0) + \sum_{k=1}^n \alpha_k \mathbf{u}^k(0)\right] + \mathbf{S}\left[\bar{\mathbf{u}}(L) + \sum_{k=1}^n \alpha_k \mathbf{u}^k(L)\right] = \mathbf{q}.$$

Последнее равенство представляет собой СЛАУ относительно коэффициентов α_k размерности n .

Полную фундаментальную систему решений однородной задачи можно получить, используя, например, схему второго порядка аппроксимации (метод трапеций)

$$\frac{\mathbf{u}_{n+1} - \mathbf{u}_n}{\tau} = \mathbf{A}_{n+1/2} \frac{\mathbf{u}_n + \mathbf{u}_{n+1}}{2}, \quad \mathbf{A}_{n+1/2} = \mathbf{A}\left(t_n + \frac{\tau}{2}\right),$$

$$\mathbf{u}_{n+1} = \left(\mathbf{E} - \frac{\tau}{2}\mathbf{A}_{n+1/2}\right)^{-1} \left(\mathbf{E} + \frac{\tau}{2}\mathbf{A}_{n+1/2}\right) \mathbf{u}_n,$$

$$\mathbf{u}_0 = \mathbf{e}_k.$$

Частное решение получаем аналогично:

$$\begin{aligned}\frac{\bar{\mathbf{u}}_{n+1} - \bar{\mathbf{u}}_n}{\tau} &= \mathbf{A}_{n+1/2} \frac{\bar{\mathbf{u}}_{n+1} + \bar{\mathbf{u}}_n}{2} + \mathbf{f}_{n+1/2}, \\ \mathbf{f}_{n+1/2} &= \mathbf{f}\left(t_n + \frac{\tau}{2}\right), \\ \bar{\mathbf{u}}_0(0) &= 0,\end{aligned}$$

или

$$\begin{aligned}\bar{\mathbf{u}}_{n+1} &= \left(\mathbf{E} - \frac{\tau}{2}\mathbf{A}\right)^{-1} \left[\left(\mathbf{E} + \frac{\tau}{2}\mathbf{A}\right)\mathbf{u}_n + \tau\mathbf{f}_{n+1/2} \right], \\ \bar{\mathbf{u}}_0 &= 0.\end{aligned}$$

Приведем пример, когда решение задачи методом построения фундаментальных решений не проходит. Рассмотрим систему уравнений

$$\begin{aligned}\frac{du}{dt} &= av + f, \quad \frac{dv}{dt} = bu + g, \\ u(0) &= U_0, \quad v(1) = 0,\end{aligned}$$

Подобные системы ОДУ моделируют, например, процессы прохождения излучения или потоков элементарных частиц (гамма-излучение, потоки нейтронов) через разные среды (атмосфера, защита ядерных реакторов) в приближении оптически толстого слоя. Коэффициенты $a, b \sim 50$ характерны для защиты реакторов. Найдем общее решение этой задачи с помощью метода фундаментальных систем в виде линейной комбинации двух решений однородных ОДУ:

$$\begin{pmatrix} u \\ v \end{pmatrix} = \begin{pmatrix} \bar{u} \\ \bar{v} \end{pmatrix} + \alpha_1 \begin{pmatrix} u^1 \\ v^1 \end{pmatrix} + \alpha_2 \begin{pmatrix} u^2 \\ v^2 \end{pmatrix},$$

где (u_1, v_1) и (u_2, v_2) — решения двух однородных систем (в дальнейшем для простоты будем полагать, что $\bar{u} = \bar{v} = 0$). Тогда

$$\begin{aligned}\dot{u}^1 &= av^1, \quad \dot{v}^1 = bu^1, \quad u^1(0) = 1, \quad v^1(0) = 0; \\ \dot{u}^2 &= av^2, \quad \dot{v}^2 = bu^2, \quad u^2(0) = 0, \quad v^2(0) = 1,\end{aligned}$$

а коэффициенты α_1 и α_2 находятся из краевых условий.

Общее решение такой системы, как известно, представляет собой сумму двух экспонент:

$$\begin{pmatrix} u^1 \\ v^1 \end{pmatrix} = C_1 \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} e^{\lambda_1 t} + C_2 \begin{pmatrix} a_2 \\ b_2 \end{pmatrix} e^{\lambda_2 t}$$

(аналогичным образом решение представляется и для u_2, v_2), где $a_i, b_i, i = 1, 2$ находятся из решения задачи; $C_i, i = 1, 2$ — произвольные постоянные; λ_1 и λ_2 — корни характеристического уравнения $\begin{vmatrix} -\lambda & a \\ b & -\lambda \end{vmatrix} = 0$. Решая характеристическое уравнение, получаем $\lambda_{1,2} = \pm \sqrt{ab} \approx \pm 50$. Полученное решение есть сумма двух экспонент: одной — быстро растущей ($\sim e^{50t}$) и второй — быстро убывающей ($\sim e^{-50t}$). Искомое же решение есть функция, близкая к $U_0 e^{-50t}$ (в случае задачи с защитой реактора U_0 — падающий поток нейтронов; задача защиты — значительное его ослабление, приблизительно в e^{50} раз).

Слагаемые с быстро растущими экспонентами должны взаимно уничтожиться. Получение же численного решения — весьма трудная задача, поскольку численное решение имеет большую и быстро возрастающую погрешность.

Пусть $u^M = u(1 + \varepsilon) \sim e^{50t}(1 + 10^{-12})$, т.е. начальная погрешность имеет порядок 10^{-12} . Она возрастает при вычислениях примерно в e^{50t} раз — даже при умеренных t это очень большое число.

10.2. Метод дифференциальной прогонки

Рассмотрим метод дифференциальной прогонки, не приводя доказательства его устойчивости. Покажем, что с помощью этого метода можно решить рассмотренную выше задачу. Будем искать решение в виде прогоночного соотношения

$$u(t) = \alpha(t)v(t) + \beta(t),$$

где α и β — пока неизвестные функции (прогоночные коэффициенты), для которых необходимо получить дифференциальные уравнения.

Продифференцируем прогоночное соотношение:

$$\dot{u} = \dot{\alpha}v + \alpha\dot{v} + \dot{\beta}$$

и подставим в него уравнения системы $\dot{u} = av + f$, $\dot{v} = bu + g$. В результате получим, что $av + f = \dot{\alpha}v + \alpha(bu + g) + \dot{\beta}$. Подставим в полученное равенство уравнение $u = \alpha v + \beta$. Тогда

$$av + f = \dot{\alpha}v + b\alpha^2v + b\beta\alpha + \alpha g + \dot{\beta}v + \beta.$$

После приведения подобных членов имеем равенство

$$v(\dot{\alpha} + b\alpha^2 - a) + (\dot{\beta} + b\beta\alpha + \alpha g - f) = 0.$$

Приравнявая нулю коэффициенты при v и единице, получим два дифференциальных уравнения для прогоночных коэффициентов:

$$\dot{\alpha} + b\alpha^2 - a = 0,$$

$$\dot{\beta} + \alpha\beta b + \alpha g - f = 0.$$

Дополним их начальными условиями. Левое краевое условие вида $u(0) = U_0$ запишем в виде прогоночного соотношения $u(0) = \alpha(0)v(0) + \beta(0)$, полагая $\alpha(0) = 0$, $\beta(0) = U_0$. Таким образом, получаем начальные данные для двух задач Коши для $\alpha(t)$ и $\beta(t)$, которые могут быть решены численно.

Теперь разрешим правое краевое условие. На правой границе отрезка интегрирования имеем условие $v(1) = 0$ и прогоночное соотношение при $t = 1$: $u(1) = \alpha(1)v(1) + \beta(1)$, откуда получаем $u(1) = \beta(1)$. Далее воспользуемся уравнением $\dot{v} = bu + g$; подставив в него прогоночное соотношение $u = \alpha v + \beta$, получим дифференциальное уравнение для v :

$$\dot{v} = \alpha bv + b\beta + g, \quad v(1) = 0.$$

Интегрируя эту задачу справа налево, попутно определяем $u(t)$:

$$u(t) = \alpha(t)v(t) + \beta(t).$$

Метод дифференциальной прогонки оказывается весьма эффективным при решении линейных систем дифференциальных уравнений с переменными коэффициентами. Очевидно, что все приведенные выше выкладки верны без изменения и для таких систем.

10.3. Понятие о жестких краевых задачах

Рассмотрим теперь общую постановку жесткой краевой задачи, неявно содержащую большой параметр. О жестких системах и задаче Коши для них речь шла в предыдущей лекции. Рассматривается линейная система

$$\begin{aligned} \frac{du}{dt} &= \mathbf{A}u + \mathbf{f}, \quad t \in [a, b], \\ (\mathbf{d}_i, u(a)) &= \sum_{s=1}^N d_{is} u_s(a) = q_i, \quad i = 1, \dots, k, \quad k < N, \\ (\mathbf{d}_i, u(b)) &= \sum_{s=1}^N d_{is} u_s(b) = q_i, \quad i = k+1, \dots, N, \end{aligned}$$

где $u, q_i, \mathbf{d}_i, \mathbf{f} \in R^n$, $\|\mathbf{d}_i\| \approx O(1)$, $i = 1, \dots, N$. Здесь $\mathbf{A}$ — постоянная матрица размером $N \times N$ (дальнейшие рассуждения будут справедливы и для систем уравнений с переменными коэффициентами). Определители систем линейных алгебраических уравнений, которыми являются краевые условия на обоих концах интервала интегрирования, полагаются отличными от нуля.

Определение 10.1. *Рассматриваемая краевая задача для ОДУ является жесткой, если спектр собственных значений матрицы $\mathbf{A}$ можно разделить на три части.*

1) *Левый жесткий спектр, для которого справедливо $\operatorname{Re} \Lambda_i^1 \leq -\Lambda_0$, $|\operatorname{Im} \Lambda_i^1| < \Lambda_0$, $\Lambda_0 \gg 1$, $i = 1, \dots, N_1$.*

2) *Правый жесткий спектр, для которого $\operatorname{Re} \Lambda_i^2 \geq \Lambda_0$, $|\operatorname{Im} \Lambda_i^2| < \Lambda_0$, $i = N_1 + 1, \dots, N_2$.*

3) *Мягкий спектр $|\lambda_i| \leq \lambda_0$, $i = N_2 + 1, \dots, N$.*

Отношение $\Lambda_0/\lambda_0 \gg 1$ является параметром, характеризующим жесткость системы. В дальнейшем будем полагать $\Lambda_0(b-a) \gg 1$, $\lambda_0(b-a) \approx O(1)$. Общее решение такой системы имеет вид

$$u(t) = \sum_{i=1}^{N_1} \gamma_i^1 e^{\Lambda_i^1 t} \Omega_i^1 + \sum_{i=N_1+1}^{N_2} \gamma_i^2 e^{\Lambda_i^2 t} \Omega_i^2 + \sum_{i=N_2+1}^N \gamma_i^3 e^{\lambda_i t} \omega_i,$$

где Ω_i^1 , Ω_i^2 , ω_i есть собственные векторы матрицы $\mathbf{A}$, соответствующие трем частям спектра. Понятна качественная структура

этого решения, содержащего как левый, так и правый пограничные слои. Будем полагать, что количество собственных значений в каждой из трех частей спектра не изменяется. Особенность жестких краевых задач состоит в том, что их решениями являются ограниченные функции. Для них верно $\|\mathbf{u}\| \leq C(\|\mathbf{f}\| + \|\mathbf{q}\|)$, $\|\mathbf{f}\|$ и $\|\mathbf{q}\|$ — соответственно нормы правых частей в системе ОДУ и краевых условиях. Для численного решения задачи можно использовать такую же схему второго порядка, как и ранее. Рассматриваем класс вычислительно корректных задач, для которых $C = O(1) \ll \exp[\Lambda_0(b-a)]$.

В дальнейшем будем полагать величину $\|\mathbf{A}\|(b-a) \approx \Lambda_0(b-a)$ большой, а величину $\exp[\|\mathbf{A}\|(b-a)] \approx \exp[\Lambda_0(b-a)]$ — очень большой. В приложениях такие задачи встречаются наиболее часто. Важно отметить и то, что не все возможные постановки задач для жесткой системы приводят к вычислительно корректным алгоритмам. Показывается, что необходимыми (и почти достаточными) условиями корректности являются следующие неравенства: $k \geq N_1$, $N - k \geq N_2 - N_1$, т. е. число краевых условий на левом конце отрезка интегрирования не должно быть меньше числа быстро убывающих вправо решений, на правом конце — не меньше числа быстро убывающих влево решений. В противном случае краевая задача оказывается вычислительно некорректной, так как $C = O(\exp[\Lambda_0(b-a)])$.

Проблемы, которые возникают при численном решении жесткой краевой задачи, были уже рассмотрены: суммирование функций порядка $e^{\Lambda_0 t}$, как известно, приводит к потере точности и накоплению вычислительных ошибок. Вторая проблема состоит в следующем. Для вычисления коэффициентов α_i , входящих в общее решение неоднородной системы (а оно состоит из суммы частного решения неоднородной системы и общего решения однородной $\mathbf{u}(t) = \bar{\mathbf{u}}_0 + \sum_{i=1}^N \alpha_i \mathbf{u}_i$), приходится решать плохо обусловленную СЛАУ $(\mathbf{d}_i, \bar{\mathbf{u}}(b) + \sum_i \alpha_i \mathbf{u}_i(b)) = \mathbf{q}_i$, $i = k+1, \dots, N$.

10.4. Краевая разностная задача для обыкновенного дифференциального уравнения второго порядка

Краевая задача для обыкновенного дифференциального уравнения второго порядка часто встречается в приложениях. Рассмотрим

линейную задачу

$$\begin{aligned} \frac{d}{dt}\left[g\frac{du}{dt}\right] + h\frac{du}{dt} + su &= f, \quad t \in [a, b], \\ A\frac{du}{dt} + Bu &= D, \quad t = a, \\ A'\frac{du}{dt} + B'u &= D', \quad t = b, \end{aligned} \quad (10.1)$$

где коэффициенты g , h , s , вообще говоря, являются функциями независимого переменного t .

Для разностной аппроксимации рассматриваемой краевой задачи введем равномерную разностную сетку $\{t_n\}_0^N$, $t_n = n\tau$, $\tau = (b-a)/N$ и определим на этой сетке сеточную функцию $\{u_n\}_0^N$.

Коэффициент g , вообще говоря, может не иметь первой производной. Такая задача может возникнуть, например, в случае расчета установившегося распределения температуры в задаче стационарной теплопроводности с контактным разрывом. Представим разностную задачу в виде

$$\begin{aligned} \frac{1}{\tau}\left(g_{n+1/2}\frac{u_{n+1}-u_n}{\tau} - g_{n-1/2}\frac{u_n-u_{n-1}}{\tau}\right) + \\ + h_n\frac{u_{n+1}-u_{n-1}}{2\tau} + s_n u_n &= f_n, \quad n = 1, \dots, N-1, \\ g_{n+1/2} &= g\left(t_n + \frac{\tau}{2}\right), \quad h_n = h(t_n), \\ A\frac{u_1-u_0}{\tau} + Bu_0 &= D, \quad t = a, \\ A'\frac{u_N-u_{N-1}}{\tau} + B'u_N &= D', \quad t = b. \end{aligned}$$

Контактный разрыв при этом помещается в узел с номером n . В этом случае фактически аппроксимируется тепловой поток через границы ячейки разностной сетки, для уравнения теплопроводности получается консервативная разностная схема (подробнее см. в лекциях, посвященных численному решению уравнений в частных производных).

Выписанные выше соотношения определяют простейшую *разностную схему*. Под разностной схемой здесь и ниже понимается совокупность разностных уравнений для определения значений

сеточной функции внутри расчетной области, дополненная соответствующими начальными и граничными условиями для этой сеточной функции.

Существуют экономичные (т. е. требующие $O(N)$ арифметических операций) методы решения систем линейных алгебраических уравнений такого вида. Они описаны в Приложении 3.

10.5. Численное решение нелинейных краевых задач

10.5.1. Метод стрельбы. Рассмотрим систему нелинейных ОДУ:

$$\begin{cases} \frac{d\mathbf{u}}{dt} = \mathbf{f}(\mathbf{u}); & t \in [0, L], \\ \mathbf{F}[\mathbf{u}(0), \mathbf{u}(L)] = 0, & \mathbf{u}, \mathbf{f}, \mathbf{F} \in R^n. \end{cases}$$

Введем пока неизвестный вектор α размерности n такой, что

$$\begin{cases} \frac{d\mathbf{u}}{dt} = \mathbf{f}(\mathbf{u}), \\ \mathbf{u}(0) = \alpha \end{cases}$$

и решим соответствующую задачу Коши, например, методом Рунге–Кутты; получим решение $\mathbf{u}(t, \alpha)$. Используя краевые условия, получаем нелинейную систему алгебраических уравнений

$$\mathbf{F}(\alpha, \mathbf{u}(L, \alpha)) = 0, \quad \text{или} \quad \mathbf{F}(\alpha) = 0,$$

которая решается численно методом Ньютона или простых итераций. Отметим, что левая часть данной системы при использовании метода стрельбы задается не в виде функции, а алгоритмически — процедурой вычисления значений функции на правом краю отрезка интегрирования как решения соответствующей нелинейной задачи Коши!

Рассмотрим метод стрельбы на примере одного нелинейного уравнения второго порядка

$$\begin{aligned} u'' &= f(x, u, u'), & 0 < x \leq 1, \\ u(0) &= U_0, & u(1) = U_1. \end{aligned}$$

Положим теперь $u'(0) = \alpha$ и сведем краевую задачу к задаче Коши, где U_0 — ордината точки, из которой выходит интегральная кривая; α — пристрелочный параметр (можно считать, что он

определяет угол наклона интегральной кривой к оси x при выходе из точки $(0, U_0)$. При фиксированном U_0 решение задачи будет зависеть от пристрелочного параметра, $u = u(x, \alpha)$. В дальнейшем будем считать такую зависимость непрерывной, хотя это не всегда так. При $x = 1$ решение зависит только от пристрелочного параметра α :

$$u(x, \alpha)|_{x=1} = u(1, \alpha).$$

Задачу тогда можно переформулировать следующим образом: найти такой параметр $\alpha = \alpha^*$, при котором интегральная кривая, выходящая из точки $(0, U_0)$ попадет в точку $(1, U_1)$.

Таким образом, дело сводится к решению уравнения

$$F(\alpha) = 0,$$

где $F(\alpha) = u(1, \alpha) - U_1$.

Оно отличается от привычных уравнений лишь тем, что функция $F(\alpha)$ задана не аналитическим выражением, а с помощью алгоритма численного решения задачи Коши.

Для решения уравнения можно использовать любой метод решения нелинейного уравнения, например, метод деления отрезка пополам, метод Ньютона (касательных) и др. Метод Ньютона здесь предпочтительнее (если имеется достаточно хорошее начальное приближение) из-за высокой стоимости вычисления одного значения функции $F(\alpha)$ (нужно решить задачу Коши).

В случае использования для решения уравнения $F(\alpha) = 0$ метода Ньютона очевидная реализация опирается на приемы, связанные с численным дифференцированием. Например, задаем α_0 , а затем последующие α_n вычисляем по рекуррентной формуле

$$\alpha_{n+1} = \alpha_n - \frac{F(\alpha_n)}{F'(\alpha_n)}, \quad n = 0, 1, \dots$$

Производная $F'(\alpha_n)$ может быть вычислена по одной из формул численного дифференцирования, например, первого порядка аппроксимации:

$$F'(\alpha_n) = \frac{F(\alpha_n + \delta) - F(\alpha_n)}{\delta}.$$

Заметим, что для численной оценки производной необходимо решать две задачи Коши. Такой способ является очевидным, но не самым лучшим из-за некорректности задачи численного дифференцирования.

Второй способ заключается в следующем. Заметим, что решаемая задача Коши на самом деле задает равенство

$$u''_{xx}(x, \alpha) = f(x, u(x, \alpha), u'_x(x, \alpha)),$$

тогда, после дифференцирования по параметру, получаем тождество

$$\begin{aligned} \frac{\partial}{\partial \alpha} u''_{xx}(x, \alpha) = \\ = \frac{\partial}{\partial u} f(x, u(x, \alpha), u'_x(x, \alpha)) \frac{\partial u}{\partial \alpha} + \frac{\partial}{\partial u'_x} f(x, u(x, \alpha), u'_x(x, \alpha)) \frac{\partial u'_x}{\partial \alpha}. \end{aligned}$$

Пусть решение нашей краевой задачи обладает достаточной гладкостью, и в последнем равенстве можно поменять порядок дифференцирования. Тогда мы получим

$$\left(\frac{\partial u}{\partial \alpha} \right)''_{xx} = \frac{\partial f}{\partial u} \frac{\partial u}{\partial \alpha} + \frac{\partial f}{\partial u'_x} \frac{d}{dx} \frac{\partial u}{\partial \alpha}.$$

Если рассмотреть новую функцию $w = \frac{\partial u}{\partial \alpha}$, то она определяется линейным уравнением в вариациях

$$w'' = \frac{\partial f}{\partial u} w + \frac{\partial f}{\partial u'_x} w',$$

которое определено вдоль траектории решения задачи Коши для исходного нелинейного дифференциального уравнения второго порядка. Для уравнения в вариациях также необходимо задать начальные условия, которые получаются дифференцированием по параметру начальных условий для нелинейной задачи. Очевидно, они будут иметь вид

$$w(0) = 0, \quad w'(0) = 1.$$

Заметим, что для определения производной нам и теперь необходимо решать две задачи Коши, но вторая задача легче — она линейная и может быть легко решена одновременно с нелинейной задачей Коши. Уравнение в вариациях довольно часто встречается при решении нелинейных задач.

10.5.2. Метод квазилинеаризации (метод Ньютона). Рассмотрим простейшую разностную аппроксимацию краевой задачи

для ОДУ второго порядка

$$\frac{d^2 u}{dt^2} = f(u), \quad u(0) = U_1, \quad u(L) = U_2$$

следующего вида:

$$\begin{aligned} \frac{u_{n-1} - 2u_n + u_{n+1}}{\tau^2} &= f(u_n), \quad n = 1, \dots, N-1, \\ u_0 &= U_1, \quad u_N = U_2, \quad \tau = \frac{L}{N}. \end{aligned}$$

Зададим некоторые начальные приближения $u_n^0 = \varphi(t_n)$ к искомой функции и построим итерационный процесс, воспользовавшись линейным приближением функции правой части:

$$\begin{aligned} f(u_n^{i+1}) &\approx f(u_n^i) + f'_u(u_n^i)(u_n^{i+1} - u_n^i), \\ \frac{u_{n-1}^{i+1} - 2u_n^{i+1} + u_{n+1}^{i+1}}{\tau^2} &= f(u_n^i) + f'_u(u_n^i)(u_n^{i+1} - u_n^i), \\ u_n^0 &= \varphi(t_n), \quad i = 0, 1, \dots, \end{aligned}$$

где i является итерационным индексом, а начальное приближение $\varphi(t_n)$ удовлетворяет граничным условиям $\varphi(0) = U_1$, $\varphi(L) = U_2$. На первой итерации, т. е. при $i = 0$, получаем первое приближение к искомому решению, решая методом трехточечной прогонки разностное уравнение

$$\frac{u_{n-1}^1 - 2u_n^1 + u_{n+1}^1}{\tau^2} = f(u_n^0) + f'_u(u_n^0)(u_n^1 - u_n^0), \quad u_n^0 = \varphi_n.$$

Полученное первое приближение вновь подставляем в линеаризованную разностную задачу и методом прогонки получаем второе приближение. Аналогично поступаем и далее, до достижения заданной точности в соответствии с условием $\|u^{i+1} - u^i\| \leq \varepsilon$.

10.5.3. Аппроксимация граничных условий. Для простоты выше рассматривались краевые задачи, для которых задавались граничные условия первого рода, т. е. на границе рассматриваемой области задавалось значение функции. Тогда трудностей с аппроксимацией граничных условий не возникало. Несколько сложнее обстоит дело при задании граничных условий второго и третьего рода (условий на производные и смешанные условия). Ограничимся описанием способов аппроксимации лишь для граничных условий второго рода.

Рассмотрим вначале линейную задачу с постоянными коэффициентами

$$\frac{d^2 u}{dt^2} + h \frac{du}{dt} + su = f,$$

$$u'(0) = a, \quad u'(1) = b,$$

и соответствующую ей разностную задачу

$$\frac{u_{n+1} - 2u_n + u_{n-1}}{\tau^2} + h \frac{u_{n+1} - u_{n-1}}{2\tau} + su_n = f_n,$$

заменяя при этом производные в граничных условиях по формулам одностороннего дифференцирования первого порядка

$$u_1 - u_0 = \tau a, \quad u_N - u_{N-1} = \tau b.$$

В результате получим разностную схему для аппроксимации дифференциальной задачи. Несмотря на то, что во внутренних узлах разностные формулы приближают дифференциальные уравнения со вторым порядком аппроксимации, решение по этой схеме получается только с первым порядком из-за понижения порядка аппроксимации в граничных точках. Естественно было бы повысить порядок схемы до второго во всех точках, включая граничные.

Наиболее распространены три способа.

1. Использование формул одностороннего дифференцирования более высокого порядка точности. Эти формулы разбирались в лекции 1. Подход очевиден, однако имеет недостаток — матрица системы уравнений для определения решения будет уже не трехдиагональной, следовательно, алгоритм прогонки неприменим. Можно избавиться от этого недостатка, проведя перед численным решением системы соответствующие алгебраические преобразования. Они в случае применения конкретной формулы численного дифференцирования для аппроксимации граничных условий свои, но достаточно очевидны.

2. Использование фиктивной ячейки (фиктивного узла). Рассмотрим расширение сеточной области. Введем в рассмотрение узлы с индексами 0 и $N+1$, находящиеся формально за пределами рассматриваемой области. Пусть в них тоже определено значение сеточной функции. Тогда узел с индексом 0 выступает как внутренний узел, и в нем может быть записано соотношение

$$\frac{u_1 - 2u_0 + u_{-1}}{\tau^2} + h \frac{u_1 - u_{-1}}{2\tau} + su_0 = f_0,$$

при этом можно для граничного условия использовать формулу для вычисления производной со вторым порядком аппроксимации по формуле центральных разностей $(u_1 - u_{-1})/\tau = a$. Из этих двух уравнений осталось только исключить значение в фиктивном узле (фиктивной ячейке).

Такой метод аппроксимации граничных условий очень хорошо зарекомендовал себя при решении нелинейных задач для уравнений в частных производных. В таком случае значения сеточной функции в фиктивных точках не исключаются из системы, а тоже входятся численно.

На правом конце отрезка формулы аналогичны. Не составляет труда обобщить этот подход и для граничных условий третьего рода.

3. Использование ряда Тейлора. Для формулы на левой границы области интегрирования $u_1 - u_0 = \tau a$ в явном виде выпишем главный член невязки:

$$\frac{u_1 - u_0}{\tau} = u'(0) + \frac{\tau}{2}u''(0) + o(\tau).$$

Используя само дифференциальное уравнение, можно выразить значение второй производной функции в окрестности границы:

$$\frac{d^2u(0)}{dt^2} = f(0) - h\frac{du(0)}{dt} - su(0),$$

откуда следует

$$\frac{u_1 - u_0}{\tau} = a + \frac{\tau}{2} \left(f(0) - h\frac{du(0)}{dt} - su(0) \right) + o(\tau).$$

Заменив в последнем соотношении производную на конечную разность, получим

$$\frac{u_1 - u_0}{\tau} = a + \frac{\tau}{2} \left(f_0 - h\frac{u_1 - u_0}{\tau} - su_0 \right).$$

Осталось только привести это соотношение к виду, удобному для использования в методе прогонки.

В случае линейных уравнений с постоянными коэффициентами два последних способа приводят к одному и тому же выражению для значения сеточной функции в граничном узле. Для нелинейных уравнений эти способы будут различаться, но каждый из них приводит к повышению порядка аппроксимации граничных условий и, следовательно, разностной схемы.

10.6. Краевые задачи на собственные значения для обыкновенных дифференциальных уравнений

Краевые задачи на собственные значения достаточно часто встречаются в физических приложениях. Например, это задача определения собственных колебаний струны, сводящаяся к ОДУ вида

$$\frac{d}{dt} \left(k(t) \frac{du}{dt} \right) + \lambda r(t) u = 0.$$

В приведенном уравнении краевые условия зависят от способа закрепления струны.

Это и задачи собственных колебаний упругого стержня (ОДУ четвертого порядка), нахождения энергетических уровней атома водорода, вычисление критических нагрузок в теории стержней и оболочек и др.

В задачах на собственные значения добавляется еще один стрелочный параметр — λ , поэтому эти задачи часто решаются методом стрельбы. Приведем простейший пример — одно дифференциальное уравнение первого порядка с двумя краевыми условиями (второе краевое условие появляется из-за присутствия неизвестного параметра λ):

$$\frac{du}{dt} + f(u, t, \lambda) = 0, \quad u(0) = u_1, \quad u(1) = u_2.$$

Если не учитывать правое краевое условие, то получим задачу Коши. Ее численное интегрирование приводит к некому значению на правом конце, зависящему от λ и, вообще говоря, не равному u_2 . Варируя параметр λ , можно добиться выполнения правого краевого условия с некоторой заданной точностью. При этом, разумеется, используются методы численного нахождения корней алгебраического уравнения, обычно метод касательных.

Второй пример — краевая задача на собственные значения для ОДУ второго порядка с нулевыми краевыми условиями:

$$\frac{d^2 u}{dt^2} + b'(t) \frac{du}{dt} + (c'(t) + \lambda) u = 0, \quad u(0) = u(L) = 0.$$

Поскольку это уравнение второго порядка с неизвестным параметром λ (собственное значение дифференциального оператора), то для его решения требуется третье условие. Однако в силу линейности и однородности задачи решение определяется с точностью до произвольного постоянного множителя, что и является

неявным заданием третьего условия. Его можно задать, например, следующим образом:

$$\frac{du(a)}{dt} = 1,$$

где a — произвольная точка на отрезке.

Трудности при использовании метода стрельбы возникают, если соответствующая задача Коши плохо обусловлена, а также в случае жестких краевых задач. В этих случаях появляется сильная зависимость численного решения от пристрелочного параметра λ .

В качестве тестового примера для сравнения с результатами численного расчета удобно использовать модельную краевую задачу на собственные значения:

$$\frac{d^2 u}{dt^2} + \lambda u = 0, \quad u(0) = u(L) = 0,$$

имеющую точное решение

$$\lambda_k = \left(\frac{\pi k}{L}\right)^2, \quad u_k(t) = \sin\left(\frac{\pi k t}{L}\right), \quad k = 1, 2, \dots$$

Непосредственной подстановкой показывается, что решениями соответствующей разностной задачи на собственные значения

$$\frac{u_{n-1} - 2u_n + u_{n+1}}{\tau^2} + \lambda^\tau u_n = 0, \quad n = 1, 2, \dots, N-1, \\ \tau N = L, \quad u_0 = u_N = 0,$$

являются собственные значения и собственные функции

$$\lambda_k^\tau = \frac{4}{\tau^2} \sin^2 \frac{\pi k \tau}{2N}, \quad \omega_n^\tau = \sin \frac{\pi k t_n}{L}, \quad k, n = 1, 2, \dots, N-1,$$

откуда видно, что

$$\lim_{\tau \rightarrow 0} \frac{4}{\tau^2} \sin^2 \frac{\pi k \tau}{2L} = \left(\frac{\pi k}{L}\right)^2 = \lambda_k,$$

т.е. имеет место сходимость решения разностной задачи к решению дифференциальной задачи $\lambda_k^\tau \xrightarrow{\tau \rightarrow 0} \lambda_k$.

10.7. Решение краевой задачи методом Фурье

Рассмотрим разностную задачу

$$\frac{u_{n-1} - 2u_n + u_{n+1}}{\tau^2} = -f_n, \quad n = 1, \dots, N-1,$$

$$u_0 = u_N = 0, \quad \tau N = L.$$

Построим ее решение в виде разложения по базису из собственных функций разностного оператора:

$$\mathbf{P}^\tau(u) = \frac{u_{n-1} - 2u_n + u_{n+1}}{\tau^2}.$$

Этот оператор имеет полную ортонормированную систему собственных функций $\omega_k(t_n) = \sqrt{\frac{2}{L}} \sin \frac{\pi k(\tau n)}{L}$, $k = 1, \dots, N-1$, $\tau n = t_n$, которые соответствуют собственным значениям оператора $\mathbf{P}^\tau(u)$: $\lambda_k^\tau = \frac{4}{\tau^2} \sin^2 \frac{\pi k \tau}{2L}$. Будем искать решение в виде

$$u_n = u(t_n) = \sum_{k=1}^{N-1} c_k \omega_k(t_n), \quad n = 1, \dots, N-1,$$

где c_k — пока неизвестные коэффициенты Фурье. Для нахождения этих коэффициентов представим правую часть разностного уравнения в виде суммы Фурье

$$f_n = \sum_{k=1}^{N-1} \widehat{f}_k \omega_k(t_n), \quad \text{где} \quad \widehat{f}_k = (f, \omega_k) = \sum_{i=1}^{N-1} f_i \omega_k(t_i).$$

Подставим выражения для u_n , f_n в виде сумм Фурье в исходное разностное уравнение

$$\mathbf{P}^\tau \left(\sum_{k=1}^{N-1} c_k \omega_k(t_n) \right) = - \sum_{k=1}^{N-1} \widehat{f}_k \omega_k(t_n),$$

или

$$\sum_{k=1}^{N-1} c_k \mathbf{P}^\tau(\omega_k(t_n)) = - \sum_{k=1}^{N-1} \widehat{f}_k \omega_k(t_n),$$

откуда, с учетом равенства

$$\mathbf{P}^\tau(\omega_k) = -\lambda_k^\tau \omega_k,$$

получим

$$-\sum_{k=1}^{N-1} c_k (\lambda_k^\tau \omega_k) = -\sum_{k=1}^{N-1} \widehat{f}_k \omega_k, \quad c_k \lambda_k^\tau = \widehat{f}_k, \quad c_k = \frac{\widehat{f}_k}{\lambda_k^\tau}.$$

Таким образом, получено решение разностного уравнения в виде суммы Фурье. Несложные арифметические подсчеты показывают, что метод прогонки, требующий $O(N)$ арифметических действий для численного решения этой же разностной задачи (из них $2(N-1)$ умножений и $N-1$ деление) оказывается более экономичным, чем метод Фурье, требующий $O(N^2)$ действий $2(N-1)^2$ умножений и $N-1$ деление). Преимущества метода Фурье сказываются при решении двумерных разностных уравнений с постоянными коэффициентами.

10.8. Примеры решения задач

1. Пусть краевая задача имеет вид

$$y'' = f(x, y), \quad y(0) = a, \quad y(1) = b, \quad (10.2)$$

где нелинейная функция f не зависит явно от первой производной y'_x . В 1924 г. Б. Нумеров предложил следующий метод аппроксимации задачи (10.2):

$$y_{n+1} - 2y_n + y_{n-1} = h^2 \left[f_n + \frac{1}{12} (f_{n+1} - 2f_n + f_{n-1}) \right], \quad (10.3)$$

где введено обозначение $f_n = f(x_n, y_n)$. В чем заключается отличие метода Нумерова от аппроксимации вида (10.4):

$$y_{n+1} - 2y_n + y_{n-1} = h^2 f_n? \quad (10.4)$$

Описать алгоритмы численного решения нелинейных алгебраических систем (10.3) и (10.4). В случае (10.3) и $f = f(x)$ это — алгоритм прогонки.

Решение. Выпишем главный член погрешности аппроксимации разностного уравнения (10.3). Для этого подставим в разностное уравнение проекцию на сетку точного решения задачи (10.2). Следует отметить, что конкретный вид решения не важен, достаточно только, чтобы решение существовало. Предположим также, что оно четырежды непрерывно дифференцируемо.

Раскладывая проекции точного решения в правой части (10.3) в ряд Тейлора до четвертого порядка включительно, убедимся, что все нечетные производные взаимно уничтожатся, а четные дадут следующее выражение для главного члена погрешности аппроксимации:

$$y_{n+1} - 2y_n + y_{n-1} = y''(x_n) + \frac{1}{12}h^2 \frac{d^4 u}{dx^4}(x_n) + O(h^4).$$

Из уравнения (10.2) следует, что во всех внутренних точках области выполняется равенство

$$y^{(4)} = \frac{d^2}{dx^2} f(x, y).$$

Переходя в последнем равенстве к разностной аппроксимации правой части, можно учесть явно главный член погрешности аппроксимации в (10.4). Приводя подобные слагаемые в (10.3), получаем аппроксимацию Нумерова

$$y_{n+1} - 2y_n + y_{n-1} = \frac{h^2}{12}(f_{n+1} + 10f_n + f_{n-1}),$$

которая приближает исходную задачу во внутренних точках сеточной области с четвертым порядком.

Такая идея разумного распоряжения правой частью для неоднородных и нелинейных задач приводит к компактным (возможно, название не слишком удачное — термины «компакт» и «компактный» уже давно заняты в математике под совсем другое!) разностным схемам — схемам повышенного порядка точности на нерасширенном шаблоне. Действительно, и в элементарном шаге вычислений для (10.3), и для (10.4) участвуют только три точки. ;уравнений в частных производных посвящена монография [?].

В случае, когда правая часть явно зависит от первой производной, либо не получается компактной схемы, либо схема перестает быть экономичной. Действительно, чтобы не ухудшить порядок аппроксимации, необходимо вычислять значение первой производной в соответствующих узлах со вторым порядком. Если во всех точках использовать формулу с центральной разностью, то расширится шаблон схемы — в каждом шаге элементарных вычислений должно теперь участвовать пять точек. Если для точки с индексом n использовать формулу с центральной разностью, а для точек с индексами $n+1$ и $n-1$ — соответствующие формулы для односторонней производной, то для каждой точки шаблона

придется вычислять заново значения функции f . При использовании классического вида аппроксимации Нумерова при каждом элементарном вычислении производится лишь однократное обращение к функции вычисления правой части — лишь для f_{n+1} , значения f_n и f_{n-1} уже получены при вычислениях для точки с индексом $n - 1$. Так как время вычислений, как правило, определяется в таких задачах именно количеством обращений к правой части, то вычисления замедляются в три раза.

2. Для численного отыскания периодического с периодом единица решения уравнения

$$y'' + p(x)y' + q(x)y = f(x),$$

где f , q , p — заданные функции, используется разностная схема второго порядка аппроксимации с центральной разностью

$$\frac{y_{n+1} - 2y_n + y_{n-1}}{h^2} + p_n \frac{y_{n+1} - y_{n-1}}{2h} + q_n y_n = f_n$$

Предложить модификацию метода прогонки (периодическая прогонка) для решения данной задачи.

Решение. Рассмотрим следующую краевую задачу для уравнения Штурма–Лиувилля:

$$y'' + p(x)y' + q(x)y = f(x)$$

с условиями периодичности

$$y^{(p)}(0) = y^{(p)}(1),$$

где p принимает значения 0 и 1.

Краевая задача с условиями периодичности решается методом циклической прогонки. Запишем дискретный аналог уравнения:

$$\frac{y_{n+1} - 2y_n + y_{n-1}}{h^2} + p_n \frac{y_{n+1} - y_{n-1}}{2h} + q_n y_n = f_n.$$

Очевидно, что оно аппроксимирует дифференциальную задачу со вторым порядком на равномерной сетке. На случай неравномерной сетки рассматриваемый метод легко обобщается.

В силу периодичности дискретное уравнение должно выполняться во всех точках сетки, включая граничные. Кроме того,

в силу граничного условия при $p = 0$ $y_0 = y_{N+1}$. Система сеточных соотношений примет вид

$$\begin{aligned} a_0 y_N - b_0 y_0 + c_0 y_1 &= \varphi_0, \\ &\dots\dots\dots \\ a_n y_{n-1} - b_n y_n + c_n y_{n+1} &= \varphi_n, \\ &\dots\dots\dots \\ a_N y_{N-1} - b_N y_N + c_N y_0 &= \varphi_N, \end{aligned}$$

где $a_k = 1 - 0.5p_k h$, $b_k = 2 - q_k h^2$, $c_k = 1 + 0.5p_k h$, $\varphi_k = f_k h^2$. Матрица системы линейных уравнений получается «почти трехдиагональной» — от трехдиагональной ее отличают всего два элемента в углах матрицы.

Обобщение стандартных прогоночных соотношений (для трехточечной прогонки) на периодический случай будет иметь вид

$$y_{n-1} = \alpha_n y_n + \beta_n + \gamma_n y_N.$$

Из приведенного выше соотношения для y_0 сразу получаем, что $\alpha_1 = c_0/b_0$, $\beta_1 = -f_0/b_0$, $\gamma_1 = a_0/b_0$.

Теперь несложно получить рекуррентную зависимость для прогоночных коэффициентов:

$$\alpha_{k+1} = \frac{c_k}{b_k - \alpha_k a_k}, \quad \beta_{k+1} = \frac{a_k \beta_k - f_k}{b_k - \alpha_k a_k}, \quad \gamma_{k+1} = \frac{a_k \gamma_k}{b_k - \alpha_k a_k}.$$

По приведенным выше формулам получаются значения коэффициентов для всех уравнений с номерами меньше, чем N . Это уже известный прямой ход прогонки слева направо.

Подставим теперь прогоночные соотношения в последнее уравнение линейной системы. В итоге с учетом введенных выше обозначений получаем

$$a_N(\alpha_N y_N + \beta_N + \gamma_N y_N) - b_N y_N + c_N y_0 = \varphi_N,$$

а это соотношение, сгруппировав члены, можно переписать как:

$$y_N = \mu_N y_0 + \nu_N,$$

где введены обозначения

$$\mu_N = \frac{-c_N}{a_N(\alpha_N + \gamma_N) - b_N}, \quad \nu_N = \frac{\varphi_N - a_N \beta_N}{a_N(\alpha_N + \gamma_N) - b_N}.$$

Теперь выражение для значения сеточной функции y_{n-1} подставляем в прогоночные соотношения. Получается выражение, связывающее y_{n-1} с y_0 :

$$y_{n-1} = \alpha_n(\mu_n y_0 + v_n) + \beta_n + \gamma_n(\mu_N y_0 + v_N).$$

Отсюда получаем следующие рекуррентные соотношения:

$$\mu_{n-1} = \alpha_n \mu_n + \gamma_n \mu_N, \quad v_{n-1} = \beta_n + \alpha_n v_n + \gamma_n v_N.$$

Отметим, что эти коэффициенты вычисляются в обратном порядке справа налево — аналог обратного хода прогонки. Последнее соотношение приводит к явному выражению для y_0 . В результате получаем

$$y_0 = \frac{v_0}{1 - \mu_0}.$$

Теперь информации для определения значений искомой функции во всех точках сетки (еще один ход прогонки) достаточно.

Библиографический комментарий к Лекции 10

Детальную теоретическую справку о методах решения краевых задач можно получить, используя книги [2, 34]. При проведении практических занятий рекомендуем воспользоваться задачником [40].

ИССЛЕДОВАНИЕ РАЗНОСТНЫХ СХЕМ ДЛЯ ЭВОЛЮЦИОННЫХ УРАВНЕНИЙ НА УСТОЙЧИВОСТЬ И СХОДИМОСТЬ

В лекции рассматриваются методы исследования устойчивости разностных схем для линейных эволюционных уравнений в частных производных (гиперболического и параболического типов). Обсуждается применение спектрального признака устойчивости, энергетического признака, условия Куранта, Фридрихса и Леви для гиперболических уравнений. Формулируется и доказывается теорема (В. С. Рябенко–П. Лакса) о связи аппроксимации, устойчивости и сходимости для линейных разностных схем.

Ключевые слова: аппроксимация, устойчивость, сходимость. Теорема П. Лакса–В. С. Рябенко. Спектральный признак устойчивости. Энергетическая устойчивость.

11.1. Постановка некоторых задач для уравнений математической физики

Напомним некоторые корректные постановки задач для уравнений в частных производных, которые будут встречаться в дальнейшем.

Задача Коши для уравнения теплопроводности. Найти функцию $u(t, x)$ в области $x \in (-\infty, \infty)$, $t \in [0, T]$, удовлетворяющую уравнению

$$\frac{\partial u}{\partial t} = a \frac{\partial^2 u}{\partial x^2} + f(t, x)$$

и начальным данным $u(0, x) = u_0(x)$, где $u_0(x)$ — заданная функция.

Смешанная задача для уравнения теплопроводности. Найти функцию $u(t, x)$ в области $x \in [0, X]$, $t \in [0, T]$, удовлетворяющую уравнению

$$\frac{\partial u}{\partial t} = a \frac{\partial^2 u}{\partial x^2} + f(t, x),$$

начальным данным $u(0, x) = u_0(x)$ и краевым условиям, записанным в общей форме

$$\begin{aligned} -A_1 \frac{\partial}{\partial x} u(t, 0) + B_1 u(t, 0) &= \varphi_1(t), \\ A_2 \frac{\partial}{\partial x} u(t, X) + B_2 u(t, X) &= \varphi_2(t). \end{aligned}$$

Смешанная задача для уравнения переноса. Найти функцию $u(t, x)$ в области $x \in [0, X]$, $t \in [0, T]$, удовлетворяющую уравнению (для определенности положим $a > 0$)

$$\frac{\partial u}{\partial t} + a \frac{\partial u}{\partial x} = f(t, x),$$

начальным данным Коши

$$u(0, x) = u_0(x), \quad t = 0$$

и левому краевому условию

$$u(t, 0) = \varphi(t).$$

Смешанная задача для волнового уравнения. Найти функцию $u(t, x)$ в области $x \in [0, X]$, $t \in [0, T]$, удовлетворяющую уравнению

$$\frac{\partial^2 u}{\partial t^2} = c^2 \frac{\partial^2 u}{\partial x^2} + f(t, x)$$

с начальными данными

$$u(0, x) = u_0(x), \quad \frac{\partial u(0, x)}{\partial t} = u_1(x)$$

и краевыми условиями $u(t, 0) = \varphi_1(t)$, $u(t, X) = \varphi_2(t)$.

Эллиптическая краевая задача (уравнение Пуассона). Найти функцию $u(x, y)$ в области $x \in [0, X]$, $y \in [0, Y]$, удовлетворяющую уравнению

$$\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = f(x, y)$$

и краевым условиям $u(0, x) = \varphi_1(x)$, $u(Y, x) = \varphi_2(x)$, $u(0, y) = \Psi_1(y)$, $u(X, y) = \Psi_2(y)$.

Простейший способ построения численных решений для уравнений в частных производных — *метод сеток*. В дальнейшем,

наряду с методом сеток, будем рассматривать и другие подходы к численному решению задач (например, вариационные, методы конечных элементов).

Рассмотрим постановку разностной задачи в методе сеток на примере одномерного уравнения теплопроводности.

Для решения одномерной смешанной задачи для уравнений в частных производных параболического типа область определения искомой функции покрывается расчетной сеткой с узлами в точках $\{t_n, x_m\}$, $n = 0, \dots, N$, $m = 0, \dots, M$, $t_n = n\tau$, $x_m = mh$, $\tau = T/N$, $h = X/M$, где τ, h — шаги сетки по времени и пространству соответственно. Приближенным решением задачи назовем сеточную функцию $\{u_m^n\}$. Верхний индекс в такой форме записи сеточной функции традиционно указывает на номер слоя по времени, нижний (нижние) — на номер узла сетки по пространственной координате (рис. 11.1).




Рис. 11.1

Рассмотрим подходы к построению численных алгоритмов для приближенного решения уравнений в частных производных.

Явная разностная схема для приближенного решения уравнения теплопроводности во внутренних узлах сетки (не принадлежащих границе сеточной области) имеет вид

$$\frac{u_m^{n+1} - u_m^n}{\tau} = a \frac{u_{m-1}^n - 2u_m^n + u_{m+1}^n}{h^2} + f_m^n.$$




Рис. 11.2

Под *разностной схемой* понимается совокупность разностных уравнений для определения значений сеточной функции внутри расчетной области, дополненная соответствующими начальными и граничными условиями для этой сеточной функции. *Шаблон схемы*, представляющий собой конфигурацию расчетных узлов в области интегрирования, используемых на каждом элементарном шаге вычислений, показан на рис. 11.2.

Эта схема аппроксимирует дифференциальное уравнение во внутренних точках (узлах) области интегрирования, т.е. при $n = 1, \dots, N-1$; $m = 1, \dots, M-1$. Проведем аппроксимацию на-

чальных данных и краевых условий:

$$\begin{aligned} u_m^0 &= u_0(x_m), \quad m = 0, \dots, M, \\ -A_1 \frac{u_1^n - u_0^n}{h} + B_1 u_0^n &= \varphi_1(t_n), \quad n = 1, \dots, N, \\ A_2 \frac{u_M^n - u_{M-1}^n}{h} + B_2 u_M^n &= \varphi_2(t_n), \quad n = 1, \dots, N. \end{aligned}$$

Для определенности положим $A_k, B_k \geq 0$, $k = 1, 2$. Расчет ведется по рекуррентной формуле на каждом временном слое от $n = 1$ до $n = N$ от $m = 1$ до $m = M - 1$ во внутренних узлах; слой $n = 0$ ($t = t_0$) соответствует начальным данным, лучи $m = 0$ ($x = x_0$) и $m = M$ ($x = x_M$) — левому и правому краевым условиям.

Запишем явную схему в виде

$$u_m^{n+1} = u_m^n + \frac{\tau a}{h^2} (u_{m-1}^n - 2u_m^n + u_{m+1}^n) + \tau f_m^n.$$

По этой формуле последовательно на каждом слое вычисляется сеточная функция во внутренних узлах области интегрирования.

Для завершения расчета слоя $t = t_{n+1}$ необходимо вычислить u_{n+1}^0 и u_M^{n+1} , для чего разрешаем левое и правое краевые условия относительно этих величин:

$$u_0^{n+1} = \frac{A_1 u_1^{n+1} + h \varphi_1^{n+1}}{A_1 + h B_1}, \quad u_M^{n+1} = \frac{A_2 u_{M-1}^{n+1} + h \varphi_2^{n+1}}{A_2 + h B_2},$$

где u_1^{n+1} и u_{M-1}^{n+1} уже вычислены ранее. Реализация одного шага по времени занимает $O(M)$ арифметических операций, всех слоев — $O(NM)$ операций.

Явными схемами называются такие разностные схемы для эволюционных уравнений, когда данные на следующем слое по времени находятся непосредственно из данных на предыдущем слое без решения алгебраических систем уравнений. Если же на верхнем временном слое для определения значений сеточной функции необходимо решать систему алгебраических уравнений, то схема называется *неявной*.

Простейшая неявная разностная схема имеет вид (для простоты положим $a = 1$)

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{u_{m-1}^{n+1} - 2u_m^{n+1} + u_{m+1}^{n+1}}{h^2} + f_m^{n+1},$$

ее шаблон показан на рис. 11.3.

На каждом временном слое имеем СЛАУ с трехдиагональной матрицей; алгоритм ее решения — прогонка (см. Приложение 3).




Рис. 11.3

Неявную схему представим в виде

$$(A_1 + hB_1)u_0^{n+1} - A_1u_1^{n+1} = h\varphi_1^{n+1}, \quad m = 0,$$

$$\frac{\tau}{h^2}u_{m-1}^{n+1} - \left(1 + 2\frac{\tau}{h^2}\right)u_m^{n+1} + \frac{\tau}{h^2}u_{m+1}^{n+1} = -u_m^n - \tau f_m^{n+1}, \quad m = 1, \dots, M-1,$$

$$(A_2 + hB_2)u_M^{n+1} - A_2u_{M-1}^{n+1} = h\varphi_2^{n+1}, \quad m = M,$$

откуда несложно получить прогоночное соотношение на каждом слое по времени.

11.2. Основные определения — сходимость, аппроксимация, устойчивость

11.2.1. Основные определения. Напомним основные определения из теории разностных схем.

Пусть $\mathbf{L}u = F$ и $\mathbf{L}_\tau u_\tau = F_\tau$ — операторные обозначения исходной дифференциальной и аппроксимирующей ее разностной задачи (точнее, параметрического семейства задач); $\mathbf{L}$ и $\mathbf{L}_\tau$ — соответственно дифференциальный и разностный операторы; $u \in \Omega$, $u_\tau \in \Omega_\tau$ — решения дифференциального и разностного уравнений, принадлежащие соответствующим функциональным пространствам; F, F_τ — правая часть исходного уравнения и ее проекция на расчетную сетку. Считается известным способ получения проекции непрерывной функции на сетку. В простейшем случае используются значения функции, вычисленные в узлах сетки. Индекс τ в этой операторной записи указывает на всю совокупность сеточных параметров. Можно сказать, что для дискретной задачи

имеется не один оператор, а совокупность различных операторов, зависящих от набора параметров.

Например, задачу Коши для линейного одномерного уравнения переноса

$$\begin{aligned}\frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} &= f(t, x), \quad t \in [0, T], \quad x \in [0, X], \\ u(0, x) &= \varphi(x),\end{aligned}$$

можно представить в виде

$$\mathbf{L}u = F.$$

Здесь

$$\mathbf{L}u = \begin{cases} \frac{\partial u}{\partial t} - \frac{\partial u}{\partial x}, & t > 0, \\ u(0, x), & t = 0, \end{cases}$$

$$F(t, x) = \begin{cases} f(t, x), & t > 0, \\ \varphi(x), & t = 0. \end{cases}$$

Одна из аппроксимирующих эту задачу разностных схем (правый уголок) имеет вид

$$\begin{aligned}\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - u_m^n}{h} &= f_m^n, \quad n = 0, \dots, N-1, \quad m = 0, \dots, M-1, \\ u_m^0 &= \varphi_m,\end{aligned}$$

или в операторной форме

$$\mathbf{L}_\tau u_\tau = F_\tau$$

где

$$\begin{aligned}\mathbf{L}_\tau u_\tau &= \begin{cases} \frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - u_m^n}{h}, \\ u_m^0, \end{cases} \\ F_\tau &= \begin{cases} f_m^n, \\ \varphi_m. \end{cases}\end{aligned}$$

Определение 11.1. Говорят, что решение u_τ сходится к решению при $\tau \rightarrow 0$, если $\|u_\tau - U_\tau\| \rightarrow 0$, где U_τ — проекция точного решения на разностную сетку; причем, если имеет место оценка $\|u_\tau - U_\tau\| \leq c\tau^p$, $c \neq c(\tau)$, то сходимость имеет порядок p .

В определении 11.1 индекс τ указывает на сеточную функцию. В общем случае, как, например, для схем, приближающих уравнение теплопроводности, сеточных параметров может быть несколько.

В качестве примера исследуем на сходимость разностную схему для задачи Коши для обыкновенного дифференциального уравнения (схема Эйлера)

$$\frac{u^{n+1} - u^n}{\tau} + \lambda u^n = 0, \quad u^0 = a,$$

аппроксимирующую простейшее ОДУ

$$\frac{du}{dt} + \lambda u = 0, \quad x \in [0; 1], \quad u(0) = a.$$

Из разностного уравнения

$$u^n = (1 - \lambda\tau)u^{n-1}$$

найдем его общее решение:

$$u^n = a(1 - \lambda\tau)^n, \quad \text{или} \quad u^n = a(1 - \lambda\tau)^{t_n/\tau}.$$

Решение дифференциальной задачи легко находится:

$$u(t) = ae^{-\lambda t}.$$

Величина погрешности решения, входящая в определение сходимости, тогда будет $\Delta_n = a \left| (1 - \lambda\tau)^{t_n/\tau} - e^{-\lambda t_n} \right|$.

Представим $(1 - \lambda\tau)^{t_n/\tau}$ в виде

$$\begin{aligned} (1 - \lambda\tau)^{t_n/\tau} &= \exp \left[\frac{t_n}{\tau} \ln(1 - \lambda\tau) \right] = \exp \frac{t_n}{\tau} \left[-\lambda\tau + \frac{\lambda^2\tau^2}{2} + O(\tau^3) \right] = \\ &= e^{-\lambda t_n} \left[1 + \frac{\lambda^2\tau t_n}{2} + O(\tau^2) \right] \left[1 + O(\tau^2) \right] = e^{-\lambda t_n} + \frac{\tau}{2} \lambda^2 t_n e^{-\lambda t_n} + O(\tau^2). \end{aligned}$$

Тогда

$$u^n = ae^{-\lambda t_n} + \tau a \frac{\lambda^2 t_n}{2} e^{-\lambda t_n} + O(\tau^2),$$

и, следовательно,

$$\Delta_n = \frac{a\tau}{2} \lambda^2 t_n e^{-\lambda t_n} + O(\tau^2) = O(\tau),$$

т.е. разностная схема имеет первый порядок сходимости. К сожалению, чтобы исследовать схему на сходимость, необходимо знать точное решение дифференциальной задачи. Обычно разностные схемы исследуются на аппроксимацию и устойчивость, откуда по теореме П. Лакса и В.С.Рябенского и следует сходимость, по крайней мере, для линейных задач.

О п р е д е л е н и е 11.2. *Говорят, что разностная задача аппроксимирует дифференциальную на ее решении, если норма невязки, возникающей при действии разностного оператора на сеточную функцию — проекцию на сетку точного решения*

$$r_\tau = \mathbf{L}_\tau U_\tau - F_\tau$$

стремится к нулю при $\tau \rightarrow 0$; если выполнена оценка $\|r_\tau\| \leq c_1 \tau^p$, $c_1 \neq c_1(\tau)$ (константа, входящая в правую часть неравенства, не зависит от сеточных параметров), то имеет место аппроксимация порядка p .

Как правило, исследование на аппроксимацию проводится в предположении достаточной гладкости решения дифференциальной задачи.

Рассмотрим задачу Коши для уравнения переноса

$$\begin{aligned} \frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} &= f(t, x), \quad -\infty < x < \infty, \quad 0 \leq t \leq T, \\ u(0, x) &= \varphi(x), \quad -\infty < x < \infty. \end{aligned}$$

Введем разностную сетку и положим

$$\frac{\partial u(t, x)}{\partial t} \approx \frac{u(t + \tau, x) - u(t, x)}{\tau}, \quad \frac{\partial u(t, x)}{\partial t} \approx \frac{u(t, x + h) - u(t, x)}{h}.$$

Получим схему «правый уголок».

Приведем пример исследования разностной схемы на аппроксимацию, для чего воспользуемся разложениями проекции точного

решения на сетку в ряд Тейлора в окрестности одного из сеточных узлов:

$$U(t + \tau) = U(t) + \tau U'_t(t) + \frac{\tau^2}{2!} U''_t(t) + \frac{\tau^3}{3!} U^{(3)}_t(t) + \frac{\tau^4}{4!} U^{(4)}_t(t) + O(\tau^5),$$

$$U'(t) \approx \frac{U(t + \tau) - U(t)}{\tau} = U'(t) + \frac{\tau}{2} U''_t(t) + O(\tau^2),$$

$$U'(t) \approx \frac{U(t) - U(t - \tau)}{\tau} = U'(t) - \frac{\tau}{2} U''_t(t) + O(\tau^2),$$

$$U'(t) \approx \frac{U(t + \tau) - U(t - \tau)}{2\tau} = U'(t) + \frac{\tau^2}{3} U^{(3)}_t(t) + O(\tau^3),$$

$$U(t - \tau) = U(t) - \tau U'_t(t) + \frac{\tau^2}{2!} U''_t(t) - \frac{\tau^3}{3!} U^{(3)}_t(t) + \frac{\tau^4}{4!} U^{(4)}_t(t) + O(\tau^5);$$

$$U''(t) \approx \frac{U(t + \tau) - 2U(t) + U(t - \tau)}{\tau^2} = U''(t) + \frac{\tau^2}{12} U^{(4)}_t(t) + O(\tau^4).$$

Положив, что функция $u(t, x)$ имеет ограниченные вторые производные, получим выражения для главных членов погрешности аппроксимации, т. е. тех членов, которые определяются минимальными степенями сеточных параметров,

$$\frac{U_{m+1}^n - U_m^n}{h} = \frac{\partial u(t_n, x_m)}{\partial x} + \frac{h}{2} \frac{\partial^2 u(t_n, x_m)}{\partial x^2} + O(h^2),$$

$$\frac{U_m^{n+1} - U_m^n}{\tau} = \frac{\partial u(t_n, x_m)}{\partial t} + \frac{\tau}{2} \frac{\partial^2 u(t_n, x_m)}{\partial t^2} + O(\tau^2).$$

Тогда для невязки верно равенство $\mathbf{L}_\tau U_\tau = F(t_m, x_m) + r_\tau$. Поскольку в силу самого дифференциального уравнения

$$F(t_m, x_m) = \left(\frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} \right) \Big|_{t_n, x_m},$$

то при подстановке в разностную схему проекции точного решения получим

$$\frac{U_m^{n+1} - U_m^n}{\tau} - \frac{U_{m+1}^n - U_m^n}{h} = \left(\frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} \right) \Big|_{t_n, x_m} + r_\tau.$$

Здесь невязка r_τ определяется выражением

$$r_\tau = \frac{\tau}{2} \frac{\partial^2 u(t_n, x_m)}{\partial t^2} - \frac{h}{2} \frac{\partial^2 u(t_n, x_m)}{\partial x^2} + O(\tau^2, h^2).$$

Так как в случае ограниченных вторых производных решения $\|r_\tau\| = O(\tau + h)$, то разностная схема имеет первый порядок аппроксимации по τ и h .

Аналогично можно получить выражение для невязки разностной схемы

$$\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - 2u_m^n + u_{m-1}^n}{h^2} = 0,$$

аппроксимирующей уравнение теплопроводности

$$\frac{\partial u}{\partial t} - \frac{\partial^2 u}{\partial x^2} = 0.$$

После соответствующих вычислений получим

$$r_\tau = \left. \frac{\tau}{2} \frac{\partial^2 u}{\partial t^2} - \frac{h^2}{12} \frac{\partial^4 u}{\partial x^4} \right|_{t_n, x_m} + O(\tau^2, h^4), \quad \|r_\tau\| = O(\tau + h^2).$$

Таким образом, схема обладает первым порядком аппроксимации по τ и вторым по h .

О п р е д е л е н и е 11.3. *Говорят, что разностная задача является устойчивой, если $\exists \tau_0: \forall \tau < \tau_0 \exists \delta_0$ и для двух близких задач $\mathbf{L}_\tau u_\tau - F_\tau = \xi_\tau$, $\mathbf{L}_\tau v_\tau - F_\tau = \eta_\tau$ таких, что $\|\xi_\tau\| \leq \delta_0$, $\|\eta_\tau\| \leq \delta_0$, решения одновременно существуют и единственны и, кроме того, выполняется оценка в смысле выбранной нормы $\|u_\tau - v_\tau\| \leq c_2(\|\xi_\tau\| + \|\eta_\tau\|)$. Эта оценка равномерная по сеточным параметрам, $c_2 \neq c_2(\tau)$.*

Теорема 11.1 (П. Лакса–В. С. Рябенского). *Решение линейной разностной задачи сходится к решению дифференциальной, если разностная задача устойчива и аппроксимирует дифференциальную задачу на ее решении. При этом порядок аппроксимации совпадает с порядком сходимости.*

Дадим еще одно эквивалентное определение устойчивости разностной задачи, применимое лишь для линейных разностных операторов. Как будет видно ниже, даже для линейных дифференциальных задач возможно построение нелинейных разностных схем.

О п р е д е л е н и е 11.4. *Линейная разностная задача устойчива, если при любой правой части F_τ она имеет единственное решение u_τ , причем $\|u_\tau\| \leq C\|F_\tau\|$, и данная оценка равномерна по сеточным параметрам т. е. $C \neq C(\tau)$.*

Покажем, что из устойчивости задачи в смысле второго определения следует ее устойчивость в смысле первого определения.

Вычтем из разностного уравнения $\mathbf{L}_\tau u_\tau = F_\tau$ «возмущенное» разностное уравнение (положим для простоты $\eta_\tau = 0$):

$$\mathbf{L}_\tau v_\tau = F_\tau + \xi_\tau.$$

Получим в силу линейности разностного оператора

$$\mathbf{L}_\tau(u_\tau - v_\tau) = \xi_\tau.$$

В силу определения 11.4 справедливо неравенство

$$\|u_\tau - v_\tau\| \leq C \|\xi_\tau\|,$$

откуда и следует справедливость в смысле определения 11.3, так как ξ_τ в этом неравенстве играет роль правой части, а $u_\tau - v_\tau$ — искомой функции. Можно также показать справедливость обратного утверждения. Заметим, что в силу произвольности ξ_τ из последнего неравенства следует единственность решения разностного уравнения.

В теории разностных схем также вводится определение корректности разностной задачи.

О п р е д е л е н и е 11.5. Семейство разностных уравнений

$$\mathbf{L}_\tau u_\tau = F_\tau$$

считается корректным, если:

его решение существует и единственно при любых правых частях $F_\tau \in \omega_F$;

существует константа C , не зависящая от τ , такая, что при любых F_τ выполняется оценка $\|u_\tau\| \leq C \|F_\tau\|$.

Первое условие эквивалентно существованию оператора $\mathbf{L}_\tau^{-1}$, второе — равномерной по τ ограниченности $\mathbf{L}_\tau^{-1}$, т. е. константа C является универсальной для всего семейства уравнений.

Заметим также, что условие $\|u_\tau\| \leq C \|F_\tau\|$ означает непрерывную равномерную по τ зависимость решения разностной задачи от правой части.

Это неравенство является введенным ранее определением устойчивости разностной задачи.

11.2.2. Необходимое условие сходимости разностной схемы Куранта, Фридрихса, Леви (условие КФЛ). Рассмотрим разностное уравнение

$$u_m^{n+1} = (1 - \sigma)u_m^n + \sigma u_{m+1}^n, \quad u_m^0 = \varphi_m, \quad \sigma = \frac{\tau}{h},$$

аппроксимирующее задачу Коши для уравнения переноса

$$\frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} = 0, \quad t \in [0; 1], \quad u(0, x) = \varphi(x).$$

Очевидно, что значение u_0^N сеточной функции в точке $(1, 0)$ выражается через значения u_0^{N-1} и u_1^{N-1} в точках $(1 - \tau, 0)$, $(1 - \tau, h)$. В свою очередь, значения u_0^{N-1} и u_1^{N-1} находятся по значениям сеточной функции u_0^{N-2} , u_1^{N-2} , u_2^{N-2} в точках $(1 - 2\tau, 0)$, $(1 - 2\tau, h)$, $(1 - 2\tau, 2h)$, значения сеточной функции u_0^{N-2} , u_1^{N-2} , u_2^{N-2} находятся по значениям u_0^{N-3} , u_1^{N-3} , u_2^{N-3} , u_3^{N-3} в точках $(1 - 3\tau, ih)$, $i = 0, \dots, 3$, и т.д. Значение сеточной функции u_0^N выражается через значение u_m^0 решения в точках расчетной сетки $(0, mh)$, $m = 0, \dots, N$, $N = \tau^{-1}$. Все эти точки лежат на отрезке $[0, h/\tau]$ или $[0, \sigma^{-1}]$ оси $t = 0$, на которой задано начальное условие $u(0, x) = \varphi(x)$ исходной дифференциальной задачи. Значение u_0^N не зависит от значения функции $\varphi(x)$ при x , лежащих вне отрезка $[0, \sigma^{-1}]$.

Из курса обыкновенных дифференциальных уравнений известно, что решением однородного уравнения переноса является функция $u(t, x) = \varphi(t + x)$, сохраняющая свое значение вдоль характеристики $t + x = \text{const}$, и в частности на прямой $t + x = 1$, проходящей через точки $(0, 1)$, $(0, 1)$, см. рис. 11.4.

Таким образом, при $\sigma > 1$ область зависимости решения дифференциальной задачи для u_0^N , являющаяся точкой $(0, 1)$, не входит в отрезок $0 \leq x \leq \sigma^{-1}$. В случае $\sigma^{-1} < 1$ сходимость решения разностной задачи к решению дифференциальной отсутствует. Разумеется, приведенные рассуждения не носят характера доказательства, а лишь косвенно объясняют, почему не следует ожидать сходимости при $\sigma = \tau/h > 1$.

Сформулируем теперь условие Куранта–Фридрихса–Леви (условие КФЛ), необходимое для сходимости разностной задачи.

Пусть некая точка A принадлежит области определения решения $u(t, x)$ и значение функции $u(A)$ зависит от значения некоторой функции $\varphi(x)$ в точках x , принадлежащих множеству $\Omega(A)$,

которое, в свою очередь, принадлежит области определения функции $\varphi(x)$.

Положим, что для приближенного вычисления решения уравнения $\mathbf{L}u = F$ используется разностная схема $\mathbf{L}_\tau u_\tau = F_\tau$, причем полностью определяются значениями функции φ на множестве $\Omega_x(A_x)$. Для того чтобы имела место сходимость $u_\tau \rightarrow u$ при $h \rightarrow 0$, разностная схема должна быть устроена так, чтобы при сколь угодно малых значениях пространственного шага h в произвольной окрестности любой точки области $\Omega(A)$ имелась точка множества $\Omega_x(A_x)$.

Другими словами, разностная схема должна быть устроена так, чтобы область зависимости разностного уравнения учитывала область зависимости решения исходного дифференциального уравнения. В противном случае сходимости ожидать, вообще говоря, нельзя. Если же разностная задача аппроксимирует дифференциальную, то необходимое условие сходимости КФЛ является также необходимым условием устойчивости схемы. Отметим, что условию КФЛ можно придать форму теоремы.




Рис. 11.4

11.3. Элементы теории устойчивости разностных схем

Канонической формой двухслойной линейной разностной схемы называется ее запись в виде

$$\mathbf{B} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \mathbf{A} \mathbf{u}^n = \mathbf{f}^n, \quad (11.1)$$

$\mathbf{B}$ и $\mathbf{A}$ — операторы, действующие в Ω_τ . Рассматриваем случай, когда для этих операторов выполнено условие $(\mathbf{A}\mathbf{u}, \mathbf{u}) > \mu(\mathbf{u}, \mathbf{u})$, где μ — положительное число, $\mathbf{u}$ — произвольный ненулевой элемент пространства сеточных функций. Тогда оператор $\mathbf{A}$ называется положительным, записывается $\mathbf{A} > 0$. Требуем и $\mathbf{B} > 0$. Пока не

оговорено иное, рассматриваем случаи самосопряженных операторов.

Если $\mathbf{B} = \mathbf{E}$, то разностная схема называется явной. Рассмотрим для примера разностную схему с весами для одномерного уравнения теплопроводности

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \xi \Lambda u_m^{n+1} + (1 - \xi) \Lambda u_m^n, \quad \xi \in [0; 1],$$

где

$$\Lambda u_m^{n+1} = \frac{u_{m-1}^{n+1} - 2u_m^{n+1} + u_{m+1}^{n+1}}{h^2}, \quad \Lambda u_m^n = \frac{u_{m-1}^n - 2u_m^n + u_{m+1}^n}{h^2},$$

$$n = 0, \dots, N-1; \quad m = 0, \dots, M-1,$$

ξ — весовой коэффициент, $\xi \in [0; 1]$. В случае $\xi = 0.5$ эта схема называется схемой Кранка–Николсон (именами английских математиков Джона Кранка и Филлис Николсон). Для записи схемы с весами в каноническом виде положим

$$\mathbf{A} \mathbf{u}^n = -\Lambda u_m^n, \quad \mathbf{A} \mathbf{u}^{n+1} = -\Lambda u_m^{n+1},$$

и, обозначив $\mathbf{u}^n = (u_1^n, u_2^n, \dots, u_{M-1}^n)^T$, получим форму записи

$$\mathbf{B} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \mathbf{A} \mathbf{u}^n = 0,$$

где $\mathbf{B} = \mathbf{E} + \tau \xi \mathbf{A}$. В случае неравномерной сетки каноническая форма записи схемы будет

$$\mathbf{B} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau_{n+1}} + \mathbf{A} \mathbf{u}^n = \mathbf{f}^n, \quad \mathbf{f}^n = (f_1^n, \dots, f_{M-1}^n)^T. \quad (11.2)$$

Иногда схему с весами записывают в виде

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \Lambda u^{(\xi)}.$$

Заметим, что канонический вид разностной схемы аналогичен итерационному методу решения СЛАУ $\mathbf{A} \mathbf{u} = \mathbf{f}$. Эта аналогия не является формальной — переход от СЛАУ к итерационному методу (11.1) может быть интерпретирован как замена стационарного уравнения $\mathbf{A} \mathbf{u} = \mathbf{f}$ нестационарным. Решение последнего при стационарных граничных условиях стремится к решению стационарного при стремлении времени к бесконечности.

Отличие состоит в том, что в последнем случае операторы $\mathbf{B}$, $\mathbf{A}$ и функция $\mathbf{f}$ не зависят от n , и итерационный параметр τ не обязательно должен стремиться к нулю.

Введем величину $(\mathbf{A}\mathbf{u}, \mathbf{u})$ — энергию оператора $\mathbf{A}$, а также энергетическую норму вектора:

$$\|\mathbf{u}\|_{\mathbf{A}} = (\mathbf{A}\mathbf{u}, \mathbf{u})^{1/2}.$$

Говорят, что эта норма порождается оператором $\mathbf{A}$.

Рассматривается задача Коши для оператора — однородного разностного уравнения (11.1); $\mathbf{u}^0 = \boldsymbol{\varphi}$. Дадим два определения.

Определение 11.6. *Разностная схема (11.1) устойчива по начальным данным, если для решения (11.1) выполняется оценка*

$$\|\mathbf{u}^{n+1}\| \leq C_1 \|\boldsymbol{\varphi}\| \quad (11.3)$$

на любом слое по времени, причем константа C_1 не зависит от сеточных параметров.

Будем рассматривать также неоднородное уравнение, соответствующее (11.1):

$$\mathbf{B} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = -\mathbf{A}\mathbf{u}^n + \mathbf{f}(x_m, t_n). \quad (11.4)$$

Определение 11.7. *Говорят, что разностная схема (11.4) устойчива по правой части, если для решения (11.4) в любой момент времени выполняется условие*

$$\|\mathbf{u}^{n+1}\| \leq C_2 \|\mathbf{f}\|, \quad (11.5)$$

причем константа C_2 не зависит от сеточных параметров.

Определение 11.8. *Разностная схема (11.1) равномерно устойчива по начальным данным в энергетической норме, порождаемой некоторым оператором $\mathbf{R} = \mathbf{R}^* > 0$, если $\exists \rho > 0$: $\forall t_n$ выполнено*

$$\|\mathbf{u}^{n+1}\|_{\mathbf{R}} \leq \rho \|\mathbf{u}^n\|_{\mathbf{R}}$$

и при этом $\rho^n \leq M_1$, ρ и M_1 не зависят от сеточных параметров.

Обычно рассматриваются случаи $\rho = C_1 = 1$ или $\rho = 1 + c\tau$, $C_1 = e^{cT}$.

Если разностную схему в канонической форме представить в виде

$$\mathbf{u}^{n+1} = \mathbf{R}_\tau \mathbf{u}^n + \tau \mathbf{B}^{-1} \mathbf{f}^n, \quad n = 0, \dots, N-1, \quad \mathbf{R}_\tau = \mathbf{R}_\tau(t_n),$$

то оператор $\mathbf{R}_\tau = \mathbf{E} - \tau \mathbf{B}^{-1} \mathbf{A}$ называется оператором послойного перехода разностной схемы (11.1). Нетрудно заметить, что условие равномерной устойчивости по начальным данным эквивалентно ограничению нормы оператора $\mathbf{R}_\tau$: $\|\mathbf{R}_\tau\| \leq \rho$, а в силу условия $\rho^n \leq C$ и ограниченности норм степеней оператора $\mathbf{R}$: $\|\mathbf{R}_\tau^n\| \leq C$. Для оценки нормы оператора $\mathbf{R}_\tau^n$ можно воспользоваться собственными значениями этого оператора — корнями уравнения $\det \|\mathbf{R}_\tau - \lambda \mathbf{E}\| = 0$. Если λ — собственное значение, а $\boldsymbol{\omega}$ — соответствующий ему собственный вектор, то $\mathbf{R}_\tau \boldsymbol{\omega} = \lambda \boldsymbol{\omega}$. Поэтому $\mathbf{R}_\tau^n \boldsymbol{\omega} = \lambda^n \boldsymbol{\omega}$, откуда $\|\mathbf{R}_\tau^n\| \geq |\lambda|^n$, так как $\|\mathbf{R}_\tau^n \boldsymbol{\omega}\| = |\lambda|^n \|\boldsymbol{\omega}\| \leq \|\mathbf{R}_\tau^n\| \|\boldsymbol{\omega}\|$. Последнее неравенство должно выполняться при любом n . Оно невыполнимо, если $|\lambda|^n$ с увеличением n будет неограниченно расти, так как $\|\mathbf{R}_\tau^n\| \leq C$. Этого не произойдет, если на λ будет наложено условие $|\lambda| \leq 1 + c\tau$, константа c не зависит от сеточных параметров, $c = O(1)$, $\tau \ll 1$. Последнее условие называется необходимым *спектральным признаком* устойчивости (признак фон Неймана).

Рассмотрим разностную задачу Коши для линейного уравнения переноса

$$\mathbf{L}_\tau u_\tau = F_\tau,$$

где

$$\mathbf{L}_\tau u_\tau = \begin{cases} \frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - u_m^n}{h}, & n = 0, \dots, N-1; \quad m = 0, \dots, M-1, \\ u_m^0, & m = 0, \dots, M-1, \end{cases}$$

$$F_\tau = \begin{cases} f_n^m, & n = 1, \dots, N; \quad m = 0, \dots, M, \\ \varphi_m, & n = 0; \quad m = 0, \dots, M, \end{cases}$$

Условие ее устойчивости записывается в виде неравенства

$$\|u_\tau\| \leq C \|F_\tau\|.$$

Для однородного уравнения переноса это условие принимает вид

$$\max_m |u_m^n| \leq C \max_m |u_m^0|.$$

Последнее неравенство означает устойчивость разностной схемы по начальным данным. Оно должно выполняться, в частности, в случае, если $u_m^0 = \varphi_n$ является произвольной гармоникой при представлении начальных условий в виде ряда Фурье (важно лишь знать, будет ли эта гармоника неограниченно расти по времени). Возьмем в качестве начального условия произвольную гармонику $u_m^0 = e^{iam}$, где α — вещественный параметр.

Решение однородной разностной задачи в этом случае ищется с помощью метода разделения переменных. На каждом временном слое решение разностной задачи ищется как произведение $u_m^n = \lambda^n e^{iam}$. Спектр оператора послойного перехода $\lambda(\alpha)$ легко находится подстановкой в разностное уравнение. Например, для однородного уравнения переноса с постоянными коэффициентами после преобразований $u_m^{n+1} = (1 - \sigma)u_m^n + \sigma u_{m+1}^n$, где $\sigma = \tau/h = \text{const}$ — безразмерный параметр — число Куранта (в числитель дроби входит скорость переноса, которая в рассматриваемой задаче равна единице). Для спектра оператора перехода имеем $\lambda(\alpha) = (1 - \sigma) + \sigma e^{i\alpha}$. Для решения вида $u_m^n = \lambda^n e^{iam}$ справедливо $\|u_m^n\| = \|\lambda^n e^{iam}\| = \|\lambda^n u_m^0\| \leq |\lambda^n| \|u_m^0\|$, или $\max_m |u_m^n| = |\lambda^n| \max_m |u_m^0|$, поэтому для выполнения условия устойчивости $\max_m |u_m^n| \leq C \max_m |u_m^0|$ необходимо выполнение неравенства $|\lambda(\alpha)| \leq 1 + C\tau$. Константа в правой части последнего неравенства не зависит от сеточных параметров.

Спектральным признаком это условие называется потому, что каждая гармоника e^{iam} является собственной функцией оператора послойного перехода $u_m^{n+1} = \mathbf{R}_\tau u_m^n$. В частности, для рассмотренного выше примера с уравнением переноса $\mathbf{R}_\tau u_m^n = (1 - \sigma)u_m^n + \sigma u_{m+1}^n$. Множество точек $\lambda(\alpha)$ на комплексной плоскости состоит из собственных значений оператора перехода и называется спектром оператора перехода. При этом считаем $\alpha \in [0; 2\pi]$. Сформулируем теперь спектральный признак устойчивости в этих терминах. Спектр оператора перехода с n -го на $(n+1)$ -й временной слой должен лежать в круге радиуса $1 + C\tau$ на комплексной плоскости.

В приведенном примере спектр оператора не зависит явно от τ , поэтому условие устойчивости может быть записано в виде $|\lambda(\alpha)| \leq 1$. Такое условие иногда называется условием *строгой устойчивости*. В [42] показано, что строго устойчивые схемы можно построить лишь для таких дифференциальных задач, для

которых справедлив принцип максимума, т. е. максимальное и минимальное значения решение дифференциальной задачи принимает на границе расчетной области.

Вернемся к модельному уравнению переноса. В данном случае спектр представляет собой окружность с центром в точке $1 - \sigma$ и радиусом σ на комплексной плоскости. При $\sigma < 1$ эта окружность лежит внутри единичного круга, касаясь его в точке $\lambda = 1$ ($\alpha = 0$), при $\sigma = 1$ совпадает с единичной окружностью, при $\sigma > 1$ находится вне единичного круга.

Приведем еще один пример исследования на устойчивость разностной задачи:

$$\frac{u_m^{n+1} - u_m^n}{\tau} - a^2 \frac{u_{m-1}^n - 2u_m^n + u_{m+1}^n}{h^2} = 0, \quad u_m^0 = \varphi_m, \\ n = 0, \dots, N - 1; \quad m = 0, \dots, M - 1; \quad a > 0.$$

Эта схема аппроксимирует задачу Коши для уравнения теплопроводности.

После подстановки решения в виде гармоники Фурье, умноженной на коэффициент перехода, $u_m^n = \lambda^n e^{iam}$ в разностное уравнение, получим уравнение для спектра оператора послойного перехода

$$\frac{\lambda - 1}{\tau} - a \frac{e^{-ia} - 2 + e^{ia}}{h^2} = 0.$$

После очевидных преобразований получим

$$\lambda(\alpha) = 1 - 4\sigma' \sin^2 \frac{\alpha}{2},$$

где $\sigma' = \tau a / h^2$ — аналог числа Куранта для параболических уравнений (иногда его называют параболическим числом Куранта).

При изменении α спектр $\lambda(\alpha)$ пробегает значения $1 - 4\sigma' \leq \lambda(\alpha) \leq 1$, а для выполнения условия устойчивости необходимо $1 - 4\sigma' \geq -1$, или $\sigma' \leq 1/2$, откуда $\tau \leq h^2 / (2a)$. Аппроксимация этого же дифференциального уравнения с помощью неявной схемы приводит к следующему выражению для спектра $\lambda(\alpha)$:

$$\lambda(\alpha) = \frac{1}{1 + 4\sigma' \sin^2 \frac{\alpha}{2}}.$$

Здесь, как и ранее, $\sigma' = \tau a / h^2$.

В этом случае условие устойчивости выполнено при любом соотношении сеточных параметров. В таких случаях говорят, что схема безусловно устойчивая.

Теорема 11.2. *Для задачи Коши*

$$\mathbf{B} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = -\mathbf{A}\mathbf{u}^n; \quad \mathbf{u}^0 = \varphi; \quad A = A^* > 0, \quad B = B^* > 0, \quad (11.6)$$

условие $\mathbf{B} \geq \frac{\tau}{2} \mathbf{A}$ необходимо и достаточно для устойчивости в энергетической норме, порождаемой $\mathbf{A}$, т. е.

$$\|\mathbf{u}^{n+1}\|_{\mathbf{A}} \leq \|\mathbf{u}^0\|_{\mathbf{A}}.$$

Неравенство в последней теореме имеет смысл операторного неравенства, т. е. для любого ненулевого вектора выполнено $(\mathbf{B}\mathbf{u}, \mathbf{u}) \geq \frac{\tau}{2}(\mathbf{A}\mathbf{u}, \mathbf{u})$.

Доказательство. Достаточность. Умножим (11.6) скалярно на $\mathbf{y}_\tau = \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau}$, тогда получим

$$(\mathbf{B}\mathbf{y}_\tau, \mathbf{y}_\tau) = -(\mathbf{A}\mathbf{u}^n, \mathbf{y}_\tau).$$

Ввиду того, что

$$\mathbf{u}^n \equiv \frac{1}{2}(\mathbf{u}^{n+1} + \mathbf{u}^n) - \frac{1}{2} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} \tau = \frac{1}{2}(\mathbf{u}^{n+1} + \mathbf{u}^n) - \frac{1}{2} \mathbf{y}_\tau,$$

последнее равенство можно представить как уравнение:

$$\left(\left(\mathbf{B} - \frac{\tau}{2} \mathbf{A} \right) \mathbf{y}_\tau, \mathbf{y}_\tau \right) + \frac{1}{2\tau} \left(\mathbf{A}(\mathbf{u}^{n+1} + \mathbf{u}^n), \mathbf{u}^{n+1} - \mathbf{u}^n \right) = 0. \quad (11.7)$$

В силу самосопряженности $\mathbf{A}$, $(\mathbf{A}\mathbf{u}^n, \mathbf{u}^{n+1}) = (\mathbf{A}\mathbf{u}^{n+1}, \mathbf{u}^n)$ и тогда

$$\left(\mathbf{A}(\mathbf{u}^{n+1} + \mathbf{u}^n), \mathbf{u}^{n+1} - \mathbf{u}^n \right) = (\mathbf{A}\mathbf{u}^{n+1}, \mathbf{u}^{n+1}) - (\mathbf{A}\mathbf{u}^n, \mathbf{u}^n).$$

Из (11.7) следует

$$\left(\left(\mathbf{B} - \frac{\tau}{2} \mathbf{A} \right) \mathbf{y}_\tau, \mathbf{y}_\tau \right) + \frac{1}{2\tau} \left(\|\mathbf{u}^{n+1}\|_{\mathbf{A}}^2 - \|\mathbf{u}^n\|_{\mathbf{A}}^2 \right) = 0. \quad (11.8)$$

В случае $\mathbf{B} \geq \frac{\tau}{2} \mathbf{A}$ получим, что $\|\mathbf{u}^{n+1}\|_{\mathbf{A}}^2 \leq \|\mathbf{u}^n\|_{\mathbf{A}}^2$. Отсюда следует устойчивость в норме $H_{\mathbf{A}}$ по начальным данным.

Необходимость. Пусть $\|\mathbf{u}^{n+1}\|_{\mathbf{A}} \leq \|\mathbf{u}^0\|_{\mathbf{A}}$. Используем равенство (11.7) (оно называется *энергетическим тождеством*). В случае $n = 0$ из (11.7) следует

$$2\tau \left(\left(\mathbf{B} - \frac{\tau}{2} \mathbf{A} \right) \mathbf{w}, \mathbf{w} \right) + (\mathbf{A} \mathbf{u}^1, \mathbf{u}^1) - (\mathbf{A} \mathbf{u}^0, \mathbf{u}^0) = (\mathbf{A} \boldsymbol{\varphi}, \boldsymbol{\varphi}).$$

Это равенство может быть выполнено для произвольного вектора $\mathbf{w}$ лишь в случае

$$\left(\left(\mathbf{B} - \frac{\tau}{2} \mathbf{A} \right) \mathbf{w}, \mathbf{w} \right) > 0.$$

В силу того, что $\mathbf{B} = \mathbf{B}^* > 0$, существует $\mathbf{B}^{-1}$. Так как $\boldsymbol{\varphi}$ — произвольный элемент нашего пространства сеточных функций, то $\mathbf{w} = -\mathbf{B}^{-1} \mathbf{A} \boldsymbol{\varphi}$ — произволен. Последнее равенство выполнено при любых $\boldsymbol{\varphi}$, значит, $\mathbf{B} - \frac{\tau}{2} \mathbf{A} \geq 0$. Теорема доказана. $\square$

Теорема 11.3. Пусть $\mathbf{A}, \mathbf{B}$ — постоянные самосопряженные положительные операторы. Тогда условие $\mathbf{B} \geq \frac{\tau}{2} \mathbf{A}$ необходимо и достаточно для устойчивости по начальным данным в энергетической норме, порождаемой оператором $\mathbf{B}$:

$$\|\mathbf{u}^{n+1}\|_{\mathbf{B}} \leq \|\boldsymbol{\varphi}\|_{\mathbf{B}}.$$

Таким образом, получим следующее правило исследования устойчивости двухслойных разностных схем.

1. Приводим схему к каноничному виду.
2. Исследуем свойства оператора $\mathbf{A}$. Если он является положительным, самосопряженным и не зависящим от n , проверяется условие $\mathbf{B} \geq 0.5\tau \mathbf{A}$.

Рассмотрим теперь устойчивость схемы Кранка–Николсон для уравнения теплопроводности. Эта схема введена в рассмотрение в начале данного параграфа. В операторном виде она записывается так:

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = -\frac{1}{2} \mathbf{A} \mathbf{u}^n - \frac{1}{2} \mathbf{A} \mathbf{u}^{n+1}.$$

Запишем ее в каноническом виде:

$$\left(\mathbf{E} + \frac{\tau}{2} \mathbf{A} \right) \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} = -\mathbf{A} \mathbf{u}^n.$$

По доказанной ранее теореме данная схема устойчива по начальным данным в $H_{\mathbf{A}}$ в случае, если

$$\mathbf{B} = \mathbf{E} + \frac{\tau}{2} \mathbf{A} \geq \frac{\tau}{2} \mathbf{A} \Rightarrow \mathbf{E} > 0 \quad (\text{что всегда верно}).$$

Тогда в энергетической норме, порождаемой оператором $\mathbf{A}$, схема Кранка–Николсон безусловно устойчива.

Схема с весами.* Можно действовать так же, как и для схемы Кранка–Николсон, а можно несколько иначе. Для общей записи схемы с весами

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \mathbf{A}(\xi \mathbf{u}^{n+1} + (1 - \xi) \mathbf{u}^n) = 0$$

иногда употребляется сокращенная форма

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \mathbf{A} \mathbf{u}^{(\xi)} = 0, \quad \text{здесь} \quad \mathbf{u}^{(\xi)} = \xi \mathbf{u}^{n+1} + (1 - \xi) \mathbf{u}^n.$$

Умножив это разностное уравнение на $\mathbf{A}^{-1}$ слева, получаем

$$\begin{aligned} \mathbf{A}^{-1} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \xi \mathbf{u}^{n+1} + (1 - \xi) \mathbf{u}^n &= 0, \\ (\mathbf{A}^{-1} + \xi \tau \mathbf{E}) \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \mathbf{u}^n &= 0. \end{aligned}$$

Тогда необходимое и достаточное условие устойчивости в норме, порождаемой оператором $\mathbf{E}$ (т. е. в евклидовой норме),

$$(\mathbf{A}^{-1} + \xi \tau \mathbf{E}) \geq \frac{\tau}{2} \mathbf{E}, \quad \mathbf{A}^{-1} + \left(\sigma - \frac{1}{2}\right) \tau \mathbf{E} \geq 0.$$

Так как $\mathbf{A} = \mathbf{A}^* > 0$, домножим обе части последнего неравенства на $\mathbf{A}$, тогда $\mathbf{E} + (\xi - 1/2) \tau \mathbf{A} \geq 0$ — условие устойчивости схемы с весами.

Неявная схема ($\xi = 1$) безусловно устойчива в норме $\|\cdot\| = (\dots)^{1/2}$ (аналог нормы L^2).

Докажем теперь, что из равномерной устойчивости однородной разностной схемы следует устойчивость по правой части.

Рассмотрим уравнение

$$\mathbf{B} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \mathbf{A} \mathbf{u}^n = \boldsymbol{\varphi}^n.$$

Умножив это равенство скалярно на $2\tau \mathbf{y}_\tau = 2\tau \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau}$, получим

$$2\tau \left(\left(\mathbf{B} - \frac{\tau}{2} \mathbf{A} \right) \mathbf{y}_\tau, \mathbf{y}_\tau \right) + (\mathbf{A} \mathbf{u}^{n+1}, \mathbf{u}^{n+1}) = (\mathbf{A} \mathbf{u}^n, \mathbf{u}^n) + 2\tau (\boldsymbol{\varphi}^n, \mathbf{y}_\tau)$$

(это — энергетическое множество для неоднородного уравнения). Кроме того,

$$\begin{aligned} ((\mathbf{u}, \mathbf{v}) = (\mathbf{A}^{-1} \mathbf{A} \mathbf{u}, \mathbf{v}) = (\mathbf{A} \mathbf{u}, \mathbf{A}^{-1} \mathbf{v}) \leq \|\mathbf{u}\|_{\mathbf{A}} \|\mathbf{v}\|_{\mathbf{A}^{-1}}, \\ (\boldsymbol{\varphi}^n, \mathbf{y}_\tau) \leq \|\mathbf{y}_\tau\|_{\mathbf{B}} \|\boldsymbol{\varphi}^n\|_{\mathbf{B}^{-1}} \end{aligned}$$

(аналог неравенства Коши–Буняковского).

Теперь используем ε -неравенство

$$0 \leq \left(\varepsilon a - \frac{b}{2\varepsilon} \right)^2 = \varepsilon^2 a^2 - ab + \frac{b^2}{4\varepsilon^2} \Rightarrow ab \leq \varepsilon^2 a^2 + \frac{b^2}{4\varepsilon^2},$$

тогда получаем

$$\begin{aligned} 2\tau \left(\left(\mathbf{B} - \frac{\tau}{2} \mathbf{A} \right) \mathbf{y}_\tau, \mathbf{y}_\tau \right) + (\mathbf{A} \mathbf{u}^{n+1}, \mathbf{u}^{n+1}) &\leq \\ &\leq (\mathbf{A} \mathbf{u}^n, \mathbf{u}^n) + \frac{\tau}{2\varepsilon_1} \|\boldsymbol{\varphi}^n\|_{\mathbf{B}^{-1}}^2 + 2\tau \varepsilon_1 \|\mathbf{y}_\tau\|_{\mathbf{B}}^2, \\ 2\tau \left(\left(\mathbf{B} (1 - \varepsilon_1) - \frac{\tau}{2} \mathbf{A} \right) \mathbf{y}_\tau, \mathbf{y}_\tau \right) + (\mathbf{A} \mathbf{u}^{n+1}, \mathbf{u}^{n+1}) &\leq \\ &\leq (\mathbf{A} \mathbf{u}^n, \mathbf{u}^n) + \frac{\tau}{2\varepsilon_1} \|\boldsymbol{\varphi}^n\|_{\mathbf{B}^{-1}}^2. \end{aligned}$$

Выбираем $\varepsilon: \frac{1}{1 - \varepsilon_1} = 1 + \varepsilon$, тогда можно написать

$$\begin{aligned} 2\tau (1 - \varepsilon_1) \left(\left(\mathbf{B} - \frac{1 + \varepsilon}{2} \tau \mathbf{A} \right) \mathbf{y}_\tau, \mathbf{y}_\tau \right) + (\mathbf{A} \mathbf{u}^{n+1}, \mathbf{u}^{n+1}) &\leq \\ &\leq (\mathbf{A} \mathbf{u}^n, \mathbf{u}^n) + \frac{\tau}{2\varepsilon_1} \|\boldsymbol{\varphi}^n\|_{\mathbf{B}^{-1}}^2. \end{aligned}$$

Пусть $\mathbf{B} - \frac{1 + \varepsilon}{2} \tau \mathbf{A} \geq 0$, $\varepsilon > 0$, ε не зависит от сеточных параметров

$$1 = (1 + \varepsilon)(1 - \varepsilon_1) \Rightarrow \varepsilon - \varepsilon_1 - \varepsilon_1 \varepsilon = 0, \quad \varepsilon_1 = \frac{\varepsilon}{1 + \varepsilon},$$

получаем

$$\|\mathbf{u}^{n+1}\|_{\mathbf{A}}^2 \leq \|\mathbf{u}^n\|_{\mathbf{A}}^2 + \frac{1 + \varepsilon}{2\varepsilon} \tau \|\boldsymbol{\varphi}^n\|_{\mathbf{B}^{-1}}^2.$$

Откуда сразу следует

$$\|\mathbf{u}^{n+1}\|_{\mathbf{A}}^2 \leq \|\mathbf{u}^0\|_{\mathbf{A}}^2 + \frac{1+\varepsilon}{2\varepsilon} \tau \sum_{k=0}^n \|\boldsymbol{\varphi}^k\|_{\mathbf{B}^{-1}}^2. \quad (11.9)$$

Таким образом, для неоднородной разностной схемы доказана следующая теорема.

Теорема 11.4. *Для разностной схемы вида*

$$\mathbf{B} \frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \mathbf{A} \mathbf{u}^n = \boldsymbol{\varphi}^n,$$

где $\mathbf{A}$ — постоянный (т.е. не зависящий явно от n) положительно определенный самосопряженный оператор, а $\mathbf{B}$ удовлетворяет условию

$$\mathbf{B} \geq \frac{1+\varepsilon}{2} \tau \mathbf{A},$$

где $\varepsilon > 0$ не зависит от сеточных параметров, выполнена априорная оценка (11.9).

Вообще, в силу того, что разностная схема устойчива по начальным данным при $\mathbf{B} = \mathbf{B}^* > 0$, из равномерной устойчивости по начальным данным следует устойчивость по правой части.

Так как $\mathbf{B} = \mathbf{B}^* > 0$, то $\exists \mathbf{B}^{-1}$, тогда

$$\mathbf{u}^{n+1} - \mathbf{u}^n + \tau \mathbf{B}^{-1} \mathbf{A} \mathbf{u}^n = \tau \mathbf{B}^{-1} \boldsymbol{\varphi}^n,$$

или

$$\mathbf{u}^{n+1} = \mathbf{T} \mathbf{u}^n + \tau \mathbf{B}^{-1} \boldsymbol{\varphi}^n,$$

где $\mathbf{T} = \mathbf{E} - \tau \mathbf{B}^{-1} \mathbf{A}$ — оператор послойного перехода.

Равномерная устойчивость по начальным данным означает, что $\|\mathbf{T} \mathbf{u}^n\|_{\mathbf{R}} \leq \rho \|\mathbf{u}^n\|_{\mathbf{R}}$. Тогда из предыдущего равенства с использованием неравенства треугольника получим

$$\|\mathbf{u}^{n+1}\|_{\mathbf{R}} \leq \rho \|\mathbf{u}^n\|_{\mathbf{R}} + \tau \|\mathbf{B}^{-1} \boldsymbol{\varphi}^n\|_{\mathbf{R}}.$$

Применяя оценку n раз, получим априорную оценку для устойчивости по правой части с использованием энергетической нормы, порождаемой оператором $\mathbf{R} = \mathbf{R}^* > 0$:

$$\|\mathbf{u}^{n+1}\|_{\mathbf{R}} \leq \rho^{n+1} \|\mathbf{u}^0\|_{\mathbf{R}} + \tau \sum_{k=0}^n \rho^{n-k} \|\mathbf{B}^{-1} \boldsymbol{\varphi}^k\|_{\mathbf{R}}.$$

Теперь попробуем обобщить полученные результаты на случай операторов, зависящих от времени.

Для начала рассмотрим аппроксимацию типа Кранка–Николсон

$$\frac{\mathbf{u}^{n+1} - \mathbf{u}^n}{\tau} + \mathbf{A}^n \frac{\mathbf{u}^{n+1} + \mathbf{u}^n}{2} = 0, \quad \mathbf{u}^0 = \varphi,$$

при этом $(\mathbf{A}^n \psi, \psi) \geq 0, \forall n$. Самый простой способ рассмотрения этого уравнения — разрешить его (в операторном виде) относительно $\mathbf{u}^{n+1}$:

$$\mathbf{u}^{n+1} = \left(\mathbf{E} + \frac{\tau}{2} \mathbf{A}^n \right)^{-1} \left(\mathbf{E} - \frac{\tau}{2} \mathbf{A}^n \right) \mathbf{u}^n = \mathbf{T}^n \mathbf{u}^n.$$

Оценим $\|\mathbf{T}^n\|$. Воспользуемся тем, что

$$\left(\mathbf{E} + \frac{\tau}{2} \mathbf{A}^n \right)^{-1} \left(\mathbf{E} - \frac{\tau}{2} \mathbf{A}^n \right) = \left(\mathbf{E} - \frac{\tau}{2} \mathbf{A}^n \right) \left(\mathbf{E} + \frac{\tau}{2} \mathbf{A}^n \right)^{-1} \text{ (перестановочность).}$$

$$\begin{aligned} \|\mathbf{T}^n\|^2 &= \sup_{\|\mathbf{v}\| \neq 0} \frac{\left(\left(\mathbf{E} + \frac{\tau}{2} \mathbf{A}^n \right)^{-1} \left(\mathbf{E} - \frac{\tau}{2} \mathbf{A}^n \right) \mathbf{v}, \left(\mathbf{E} + \frac{\tau}{2} \mathbf{A}^n \right)^{-1} \left(\mathbf{E} - \frac{\tau}{2} \mathbf{A}^n \right) \mathbf{v} \right)}{(\mathbf{v}, \mathbf{v})} = \\ &= \sup_{\|\psi\| \neq 0} \frac{\left(\left(\mathbf{E} - \frac{\tau}{2} \mathbf{A}^n \right) \psi, \left(\mathbf{E} - \frac{\tau}{2} \mathbf{A}^n \right) \psi \right)}{\left(\left(\mathbf{E} + \frac{\tau}{2} \mathbf{A}^n \right) \psi, \left(\mathbf{E} + \frac{\tau}{2} \mathbf{A}^n \right) \psi \right)} = \\ &= \frac{(\psi, \psi) - \tau(\mathbf{A}\psi, \psi) + \frac{\tau^2}{4}(\mathbf{A}\psi, \mathbf{A}\psi)}{(\psi, \psi) + \tau(\mathbf{A}\psi, \psi) + \frac{\tau^2}{4}(\mathbf{A}\psi, \mathbf{A}\psi)} \leq 1, \end{aligned}$$

$$\psi = \left(\mathbf{E} + \frac{\tau}{2} \mathbf{A}^n \right)^{-1} \mathbf{v}.$$

Факт, что $\|(\mathbf{E} - \xi \mathbf{A})(\mathbf{E} + \xi \mathbf{A})^{-1}\| \leq 1, \forall \xi > 0, \mathbf{A} = \mathbf{A}^* > 0$, носит название *леммы Келлога*.

Для сеточной функции используем норму $\|\mathbf{v}\| = (\mathbf{v}, \mathbf{v})^{1/2}$. Подобный результат уже был получен при постоянном (не зависящем от времени) $\mathbf{A}$.

Везде в доказательствах существенную роль играет то, что $\mathbf{A} = \mathbf{A}^* > 0$.

Операторный подход был расширен и для случая несамосопряженных линейных разностных операторов. Результаты описаны в литературе, см. [41].

11.4. Примеры решения задач

1. Исследовать на аппроксимацию и устойчивость трехслойную схему Ричардсона

$$\frac{y_m^{n+1} - y_m^{n-1}}{2\tau} = a^2 \frac{y_{m+1}^n - 2y_m^n + y_{m-1}^n}{h^2},$$

аппроксимирующую линейное уравнение теплопроводности

$$\frac{\partial u}{\partial t} = a \frac{\partial^2 u}{\partial x^2}.$$

На том же самом шаблоне получить безусловно устойчивую схему.

Решение. В силу симметрии шаблона схемы для исследования ее на аппроксимацию проводим разложение в ряд Тейлора проекции точного решения в окрестности центральной точки шаблона. Несложно заметить, что в левой части остаются только производные нечетных порядков при разложении в ряд Тейлора, а в правой — четных. Таким образом, порядок аппроксимации схемы — второй, как по времени, так и по пространственным переменным.

Исследуем на устойчивость трехслойную схему по спектральному признаку. Подстановка частного решения в виде $u_m^n = \lambda^n e^{i\varphi m}$ в схему приводит к квадратному уравнению для определения спектра оператора послойного перехода

$$\lambda^2 + \frac{8a\tau}{h^2} \lambda \sin^2\left(\frac{\varphi}{2}\right) - 1 = 0.$$

Дискриминант уравнения всегда положительный. По теореме Виета в случае действительных корней один из корней этого уравнения при любом значении параметра φ по модулю больше единицы. Для устойчивости трехслойной схемы нам необходимо потребовать, чтобы все корни, определяющие норму оператора послойного перехода, были бы по абсолютной величине меньше единицы. Таким образом, схема Ричардсона безусловно неустойчива.

«Исправлением» схемы оказывается замена в выражении $\frac{y_{m-1}^n - 2y_m^n + y_{m+1}^n}{h^2}$ для аппроксимации производной по пространству значения функции в центральной точке шаблона на среднее

арифметическое на двух слоях по времени $0.5(y_m^{n-1} + y_m^{n+1})$ (схема Франкела–Дюффорта)

$$\frac{y_m^{n+1} - y_m^n}{2\tau} = \frac{a}{h^2} [y_{m-1}^n - (y_m^{n+1} + y_m^{n-1}) + y_{m+1}^n].$$

Это явная схема (значение сеточной функции на верхнем слое вычисляется явно). Исследование на устойчивость по спектральному признаку приводит к уравнению

$$(1 + 2\sigma)\lambda^2 + 4\sigma\lambda\cos\varphi - (1 - 2\sigma) = 0, \quad \sigma = \frac{a\tau}{h^2}.$$

По теореме Виета корни этого уравнения всегда меньше 1 по модулю, схема безусловно устойчива по спектральному признаку. Однако она обладает лишь условной аппроксимацией порядка $O(\tau^2, h^2, \tau^2/h^2)$.

2. Методом неопределенных коэффициентов построить разностную схему, аппроксимирующую уравнение

$$\frac{\partial u}{\partial t} - \frac{\partial^4 u}{\partial x^4} = 0, \quad u(0, x) = \varphi(x); \quad 0 \leq t \leq x; \quad -\infty \leq x \leq \infty$$




Рис. 11.5

на сетке $D_h = \{(t^n, x_m): t^n = n\tau, \tau N = 1, n = 0, \dots, N; x_m = mh, h = \text{const}, m = 0, \pm 1; \pm 2; \dots\}$ в точке $\{m, n\}$, используя заданный шаблон. Указать порядок аппроксимации.

Решение. Припишем веса точкам шаблона, двигаясь сверху вниз и справа налево, равные a, b, c, d, e, f . Тогда разностная схема будет иметь вид

$$ay_m^{n+1} + by_m^n + cy_{m-1}^n + dy_{m-2}^n + ey_{m-3}^n + fy_{m-4}^n = 0. \quad (11.10)$$

Разложим сеточную проекцию решения дифференциальной задачи в ряд Тейлора относительно точки $\{m, n\}$. Будем иметь:

$$u_m^{n+1} = u_m^n + u'_t \tau + u''_{tt} \frac{\tau^2}{2} + \dots,$$

$$u_m^n = u_m^n,$$

$$u_{m-1}^n = u_m^n - u'_x h + u''_{xx} \frac{h^2}{2} - u'''_{xxx} \frac{h^3}{6} + u''''_{xxxx} \frac{h^4}{24} - u'''''_{xxxxx} \frac{h^5}{120} + \dots,$$

$$\begin{aligned} u_{m-2}^n = u_m^n - u'_x 2h + u''_{xx} \frac{(2h)^2}{2} - u'''_{xxx} \frac{(2h)^3}{6} + \\ + u''''_{xxxx} \frac{(2h)^4}{24} - u'''''_{xxxxx} \frac{(2h)^5}{120} + \dots, \end{aligned}$$

$$\begin{aligned} u_{m-3}^n = u_m^n - u'_x 3h + u''_{xx} \frac{(3h)^2}{2} - u'''_{xxx} \frac{(3h)^3}{6} + \\ + u''''_{xxxx} \frac{(3h)^4}{24} - u'''''_{xxxxx} \frac{(3h)^5}{120} + \dots, \end{aligned}$$

$$\begin{aligned} u_{m-4}^n = u_m^n - u'_x 4h + u''_{xx} \frac{(4h)^2}{2} - u'''_{xxx} \frac{(4h)^3}{6} + \\ + u''''_{xxxx} \frac{(4h)^4}{24} - u'''''_{xxxxx} \frac{(4h)^5}{120} + \dots, \end{aligned}$$

Подставляя эти разложения в (11.10), в качестве коэффициента перед u_m^n получаем сумму $a + b + c + d + e + f$. Этот коэффициент необходимо приравнять к нулю, так как в дифференциальном уравнении нет члена, пропорционального u ,

$$a + b + c + d + e + f = 0.$$

Коэффициент перед u'_t есть $a\tau = 1$; коэффициенты:
перед u'_x

$$(-c - 2d - 3e - 4f)h = 0,$$

перед u''_{xx}

$$(c + 4d + 9e + 16f) \frac{h^2}{2} = 0,$$

перед u'''_{xxx}

$$(-c - 8d - 27e - 64f) \frac{h^3}{6} = 0,$$

перед u''''_{xxxx}

$$(c + 16d + 81e + 256f) \frac{h^4}{24} = -1.$$

Решением полученной системы шести линейных уравнений с шестью неизвестными коэффициентами разностной схемы является следующий набор:

$$a = \frac{1}{\tau}, \quad b = -\frac{1}{\tau} - \frac{1}{h^4}, \quad c = \frac{4}{h^4},$$

$$d = -\frac{6}{h^4}, \quad e = \frac{4}{h^4}, \quad f = -\frac{1}{h^4}.$$

Окончательно схема примет вид

$$\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_m^n - 4u_{m-1}^n + 6u_{m-2}^n - 4u_{m-3}^n + u_{m-4}^n}{h^4} = 0,$$

ее порядок аппроксимации $O(\tau, h)$.

Библиографический комментарий к Лекции 11

О спектральном признаке устойчивости и о принципе замороженных коэффициентов см. [1–3, 5]. Об энергетической устойчивости и операторных неравенствах можно прочитать в [39, 41]. О спектральном признаке устойчивости и его связи с методом Фурье см. [42]. Теорема о связи аппроксимации, устойчивости и сходимости применительно к численным методам была установлена и доказана независимо в СССР В. С. Рябеньким и А. Ф. Филипповым [33], в США — Р. Рихтмайером и П. Лаксом [36]. Ранее теоремы такого рода (применительно к нескольким другим объектам) были установлены Л. В. Канторовичем.

При проведении практических занятий по теме можно воспользоваться задачами из [40].

ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ УРАВНЕНИЙ ПАРАБОЛИЧЕСКОГО ТИПА

Рассматриваются разностные схемы для решения уравнений в частных производных параболического типа. Описаны простейшие разностные схемы решения уравнения теплопроводности. Для уравнений с несколькими пространственными переменными строятся локально-одномерные схемы. Рассматриваются также консервативные схемы для численного решения квазилинейных уравнений.

Ключевые слова: уравнение теплопроводности, явная схема, неявная схема, схема с весами, спектральный признак устойчивости, метод переменных направлений, метод дробных шагов, метод расщепления, локально-одномерные схемы, консервативные схемы, интегро-интерполяционный метод, операторная аппроксимация.

Уравнения параболического типа часто встречаются при описании диссипативных процессов — теплопроводности, диффузии, течения вязкой жидкости. В данном разделе приведены основные сведения о численных методах решения задач для уравнений параболического типа. Вкратце рассмотрены численные методы решения таких задач для случая нескольких пространственных переменных для прямоугольной области.

12.1. Постановки задач для некоторых линейных уравнений параболического типа

Основным уравнением параболического типа, рассматриваемым в учебных курсах, является уравнение теплопроводности (или уравнение диффузии)

$$\frac{\partial u}{\partial t} - \operatorname{div} k(t, \mathbf{r}) \operatorname{grad} u = Q(t, \mathbf{r}). \quad (12.1)$$

Это уравнение описывает процесс распространения тепла при наличии источника или стока тепла, а также процесс распространения примесей за счет молекулярной (броуновской) диффузии. В большинстве учебных задач мы будем использовать одномерное

нестационарное уравнение теплопроводности

$$\frac{\partial u}{\partial t} - \frac{\partial}{\partial x} \left(k(t, x) \frac{\partial u}{\partial x} \right) = Q(t, x). \quad (12.2)$$

В (12.1) и (12.2) на функцию $k(x, t)$ накладывается ограничение $k(x, t) \geq k_0 > 0$. Такой случай называется невырожденным. Иногда возникает необходимость рассматривать задачи с более слабым ограничением $k(x, t) \geq 0$. Если при этом коэффициент теплопроводности обращается в ноль в каких-то точках, то говорят, что в этих точках задача вырождается. Далее, во всяком случае, в разделах, касающихся методов решения линейной задачи, мы рассматриваем невырожденный случай.

Задача распространения тепла может рассматриваться в неограниченной области, т. е. как задача Коши с начальными данными

$$u(0, x) = \varphi(x), \quad -\infty < x < \infty$$

или как начально-краевая в ограниченной пространственной области $0 \leq x \leq L$, тогда к начальным условиям

$$u(0, x) = \varphi(x), \quad 0 \leq x \leq L$$

добавляются краевые условия, выбираемые из трех основных типов в зависимости от физической постановки задачи:

1) краевые условия первого рода определяют температуру (искомую функцию) на концах рассматриваемого интервала:

$$u(t, 0) = \chi_1(t), \quad u(t, L) = \chi_2(t), \quad 0 \leq t \leq T; \quad (12.3)$$

2) краевые условия второго рода, определяющие поток тепла (первую производную решения) на концах интервала

$$-k(t, 0) \frac{\partial u}{\partial x}(t, 0) = \chi_1(t), \quad k(t, L) \frac{\partial u}{\partial x}(t, L) = \chi_2(t), \quad 0 \leq t \leq T; \quad (12.4)$$

3) краевые условия третьего рода, при которых задается некоторая комбинация температуры и потока тепла на концах интервала,

$$\left(\alpha_1 u + \beta_1 \frac{\partial u}{\partial x} \right) \Big|_{(t, 0)} = \chi_1(t), \quad \left(\alpha_2 u + \beta_2 \frac{\partial u}{\partial x} \right) \Big|_{(t, L)} = \chi_2(t), \quad 0 \leq t \leq T. \quad (12.5)$$

При постоянном коэффициенте теплопроводности (12.2) упрощается, превращаясь в уравнение

$$\frac{\partial u}{\partial t} = k \frac{\partial^2 u}{\partial x^2} + Q(t, x). \quad (12.6)$$

Если функция Q тождественно равна нулю, то уравнение теплопроводности называется однородным,

$$\frac{\partial u}{\partial t} = k \frac{\partial^2 u}{\partial x^2}. \quad (12.7)$$

Для учебных целей мы чаще всего будем использовать уравнение (12.6), в частности, большое число численных методов будет рассмотрено именно на примере этого уравнения или уравнения (12.7).

Во многих задачах коэффициент теплопроводности является гладкой (или непрерывной) функцией. В этом случае решение задачи Коши для (12.2) (следовательно, и для (12.6)), будет гладкой бесконечно дифференцируемой функцией. Даже если данные Коши представляют собой разрывную функцию или в начально-краевой задаче начальные и граничные условия не согласованны, то точное решение задачи быстро становится гладким. Такие свойства линейных задач для уравнения теплопроводности (диффузии) сильно облегчают построение и исследование численных методов для их решения.

Вернемся к уравнению теплопроводности с несколькими пространственными переменными (12.1).

Запись этого уравнения в дивергентной форме будет полезна при рассмотрении консервативных разностных схем для решения этого уравнения. О них речь пойдет ниже. Иногда мы будем использовать другие формы записи. Так, в декартовых координатах это уравнение перейдет в

$$\begin{aligned} \frac{\partial u}{\partial t} - \frac{\partial}{\partial x} \left(k(t, x, y, z) \frac{\partial u}{\partial x} \right) - \frac{\partial}{\partial y} \left(k(t, x, y, z) \frac{\partial u}{\partial y} \right) - \\ - \frac{\partial}{\partial z} \left(k(t, x, y, z) \frac{\partial u}{\partial z} \right) = Q(t, x, y, z). \end{aligned}$$

Для многомерного уравнения теплопроводности также можно ставить задачу Коши

$$u(0, x, y, z) = \varphi(x, y, z), \quad -\infty < x < \infty, \quad -\infty < y < \infty, \quad -\infty < z < \infty$$

или начально-краевую задачу с граничными условиями разных типов. Обычно для постановки начально-краевой задачи выбирается некоторая замкнутая область в R^3 . Сразу оговоримся, что свойства методов могут зависеть от того, какая форма области выбрана. Будем считать, что в пределах данной лекции выбрана выпуклая односвязная область Ω . Ее границу обозначим $\partial\Omega$.

Тогда можно задавать на границе условия первого рода

$$u(t, x, y, z)|_{\partial\Omega} = \chi(t, x, y, z), \quad 0 \leq t \leq T;$$

условия второго рода

$$\frac{\partial u(t, x, y, z)}{\partial n} \Big|_{\partial\Omega} = \chi(t, x, y, z), \quad 0 \leq t \leq T;$$

здесь производная вычисляется в направлении внешней нормали к границе области.

Условие третьего рода будет

$$\beta(t, x, y, z) \frac{\partial u(t, x, y, z)}{\partial n} \Big|_{\partial\Omega} + \alpha(t, x, y, z) u(t, x, y, z) \Big|_{\partial\Omega} = \chi(t, x, y, z), \\ 0 \leq t \leq T.$$

Конечно, возможны и более сложные постановки задач, когда на части границы задано, например, условие первого рода, а на части границы — второго.

О постановках задач для нелинейных уравнений параболического типа речь пойдет ниже.

12.2. Простейшие разностные схемы для одномерного уравнения теплопроводности

Как отмечалось выше, простейшим способом построения разностных схем является замена в уравнении соответствующих частных производных конечными разностями. Ограничимся в данном пункте только формальным рассмотрением задач Коши, чтобы не рассматривать вопросы реализации тех или иных граничных условий для начально-краевой задачи.

Для решения задачи в расчетной области вводится сетка. Для простоты при исследовании численных методов будем полагать, что сетка равномерная. В дальнейшей записи для сеточных функций будем нумеровать значения по номеру узла разностной сетки. Для эволюционных задач (т.е. таких, которые зависят от выделенной переменной — времени) обычно будем верхний индекс сеточной функции ставить в соответствие номеру слоя по времени, а нижний (или нижние индексы) — индексу узла сетки при разбиении по пространству. Для ограниченной области

$$u(n\tau, mh) = u_m^n, \quad n = 1, \dots, N, \quad m = 1, \dots, M.$$

При решении задачи Коши (в полосе) $u(n\tau, mh) \rightarrow u_m^n$; $n = 1, \dots, N$; $m = -\infty, \dots, -1, 0, 1, \dots, \infty$. Сеточная функция представляет собой вектор длины $M \cdot N$, и для нее может быть введена любая векторная норма. Введя сетку, мы ввели в рассмотрение сеточную область. Все точки сетки, расположенные на границе расчетной области, будем называть точками сеточной границы, все остальные точки сетки — внутренними точками.

Для простоты при иллюстрации конечно-разностного подхода ограничимся уравнением (12.6). Для разностного представления производной по времени используем две точки, будем вычислять разность вперед. Для вычисления второй производной естественно воспользоваться трехточечной центральной аппроксимацией. Действительно, уравнение (12.6) симметрично относительно изменения направления системы координат (x на $-x$), а симметричная замена «отражает» свойства симметрии самого уравнения. О том, что может получиться при нарушении симметрии, речь пойдет ниже.

При такой замене мы получим явную схему на четырехточечном шаблоне для аппроксимации уравнения теплопроводности (диффузии)

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \frac{y_{m-1}^n - 2y_m^n + y_{m+1}^n}{h^2} + Q(t_n, x_m).$$

Под шаблоном разностной схемы понимается множество точек сетки, данные в которых используются в одном элементарном акте вычислений (приближении производных конечными разностями в выбранной точке). Точки, данные в которых нам необходимы, будем на рисунке маркировать точками, а линии, вдоль которых считаются «разностные производные» (т. е. направления, по которым вычисляются конечные разности) будем показывать сплошными линиями. На рис. 11.2 и рис. 11.3 (см. лекцию 11) показаны шаблоны для построенной явной и неявной разностных схем для уравнения теплопроводности (12.6). Если мы рассматриваем задачу Коши, то необходимо выбрать аппроксимацию начальных условий. Самый простой способ учета этих условий — выбрать значение функции в узлах сетки: $y_m^0 = u(0, mh) = \varphi(mh)$.

Об исследовании схем на аппроксимацию на гладких решениях речь шла выше. Результатом исследования на аппроксимацию для случая явной разностной схемы будет то, что невязка на гладком решении имеет порядок $O(\tau, h^2)$. Для исследования устойчивости простейшей явной разностной схемы можно использовать спек-

тральный признак Дж. фон Неймана. При исследовании на устойчивость с помощью спектрального признака мы приходим к ограничению $\sigma = k\tau/h^2 \leq 1/2$. Безразмерный параметр σ носит название аналога числа Куранта для уравнений параболического типа. В дальнейшем несколько сокращенно мы будем называть этот параметр параболическим числом Куранта.

Напомним, что *явной* называется такая разностная схема, при решении с помощью которой на следующем слое по времени все значения выражаются через известные на предыдущем слое без решения какой-либо системы уравнений.

Построенная разностная схема имеет довольно жесткое ограничение на шаг по времени при фиксированном параболическом числе Куранта. Для того чтобы улучшить устойчивость схемы, можно использовать неявную разностную схему

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \frac{y_{m-1}^{n+1} - 2y_m^{n+1} + y_{m+1}^{n+1}}{h^2} + Q(t_{n+1}, x_m).$$

Результат исследования неявной схемы — тот же порядок аппроксимации, но теперь схема безусловно устойчивая (т. е. устойчива при любом значении параболического числа Куранта).

Можно строить другие явные или неявные аппроксимации уравнения теплопроводности. Ограничимся при описании простейшего семейства схем немного отличным подходом.

Для численного решения уравнения (12.1), по-видимому, наиболее известной является параметрическая двухслойная разностная схема на шеститочечном шаблоне. Если продолжить рассмотрение упрощенной формулировки задачи — (12.6), то для внутренних точек можно написать

$$\begin{aligned} \frac{y_m^{n+1} - y_m^n}{\tau} = k \left[\xi \frac{y_{m-1}^{n+1} - 2y_m^{n+1} + y_{m+1}^{n+1}}{h^2} + (1 - \xi) \frac{y_{m-1}^n - 2y_m^n + y_{m+1}^n}{h^2} \right] + \\ + \xi Q(t_{n+1}, x_m) + (1 - \xi) Q(t_n, x_m), \quad (12.8) \end{aligned}$$

где весовой множитель $\xi \in [0; 1]$. Иногда для (12.8) употребляют следующую сокращенную форму записи:

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \left[\frac{y_{m-1}^{n+1} - 2y_m^{n+1} + y_{m+1}^{n+1}}{h^2} \right]^{(\xi)} + Q_m^{(\xi)}.$$

В этой сокращенной форме записи вес верхнего слоя по времени ставится в качестве верхнего индекса, но заключенного в круглые скобки.

При $\xi = 0$ имеем рассмотренную выше явную схему.

При $\xi = 1$ имеем неявную схему, устойчивую при любых шагах сетки, схема также имеет порядок аппроксимации $O(\tau, h^2)$. Очевидно, что задачу Коши даже формально невозможно решить с помощью этой схемы. Если решается начально-краевая задача, то на верхнем временном слое в этом случае получается система уравнений с трехдиагональной матрицей. Она может быть решена с помощью того или иного варианта метода прогонки (см. Приложение 3).

При $\xi = 1/2$ разностный метод называется схемой Кранка–Николсон:

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{k}{2} \left(\frac{y_{m-1}^{n+1} - 2y_m^{n+1} + y_{m+1}^{n+1}}{h^2} + \frac{y_{m-1}^n - 2y_m^n + y_{m+1}^n}{h^2} \right).$$

Схема устойчива при любых шагах τ , h и имеет порядок аппроксимации $O(\tau^2, h^2)$. Эта схема, в отличие от двух предыдущих, не является *монотонной*, т. е. она может давать осцилляции разностного происхождения на решениях, имеющих большие градиенты.

Отметим здесь одну особенность исследования разностных схем на аппроксимацию. Результат не зависит от того, какую именно точку шаблона мы выбрали для проведения наших разложений. Так как схема Кранка–Николсон симметричная, то естественно использовать эту симметрию и вести разложения проекции точного решения на сетку относительно точки $((n + \frac{1}{2})\tau, mh)$.

Схема Алена–Чена. Рассмотрим теперь вопрос, однозначно ли определяется разностная схема выбором шаблона. Будем рассматривать четырехточечный шаблон, похожий на шаблон простой явной схемы, но теперь производную по времени аппроксимируем несколько иначе:

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \frac{y_{m-1}^n - 2y_m^{n+1} + y_{m+1}^n}{h^2} + Q(t_n, x_m).$$

Рассмотрим вопросы, связанные с аппроксимацией и устойчивостью разностной схемы. Для исследования на аппроксимацию подставим в схему проекцию точного решения задачи Коши на сетку и разложим ее в ряд Тейлора в окрестности точки $(n\tau, mh)$. Опустим вычисления и сразу сформулируем ответ. Главный член невязки в этом случае будет пропорционален $O(\tau + \tau/h^2 + h^2)$. Говорят, что данная схема является негибкой (или условно аппрок-

симирующей). Действительно, определение аппроксимации требует выполнения условия $\tau/h^2 \rightarrow 0$ при $h \rightarrow 0$. При исследовании на устойчивость с использованием спектрального признака фон Неймана получаем, что схема безусловно устойчива.

Так лучше или хуже данная схема, чем простая явная? Что предпочтительнее для сходимости — лучшая аппроксимация или безусловная устойчивость?

Покажем, что схема Алена–Чена эквивалентна простой явной схеме, построенной на четырехточечном шаблоне. Ограничимся рассмотрением только однородного уравнения. Выполним следующую цепочку эквивалентных преобразований. Схема для внутренних точек сетки записана в виде разностного уравнения

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \frac{y_{m-1}^n - 2y_m^{n+1} + y_{m+1}^n}{h^2}.$$

К правой части разностного уравнения добавим и вычтем одно и то же число:

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \frac{y_{m-1}^n - 2y_m^{n+1} + 2y_m^n - 2y_m^n + y_{m+1}^n}{h^2}.$$

Теперь заметим, что

$$(y_m^{n+1} - y_m^n) \left(\frac{1}{\tau} + \frac{2k}{h^2} \right) = k \frac{y_{m-1}^n - 2y_m^n + y_{m+1}^n}{h^2}.$$

То есть расчет ведется по обычной явной схеме, но с несколько другим, меньшим шагом по времени, определяемом равенством $1/\widehat{\tau} = 1/\tau + 2k/h^2$.

«Безусловная устойчивость» схемы при негибкой аппроксимации обернулась тем, что разностное решение соответствует точному, но при меньшем значении времени.

Схема hopscotch (схема «классики»). Хотя в схеме Алена–Чена есть скрытая ловушка (решение соответствует не тому времени, которое дает разностная задача, а более раннему), она может послужить основой для модернизации метода. Будем наши послойные переходы осуществлять в соответствии со следующими пра-

вилами для внутренних точек сетки:

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \frac{y_{m-1}^n - 2y_m^{n+1} + y_{m+1}^n}{h^2}, \quad \text{если } m + n - \text{четное,}$$

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \frac{y_{m-1}^{n+1} - 2y_m^{n+1} + y_{m+1}^{n+1}}{h^2}, \quad \text{если } m + n - \text{нечетное.}$$

В половине точек сетки используется схема Алена–Чена. В остальных точках шаблон «переворачивается» и становится похож на шаблон неявной схемы.

Такая схема называется неоднородной — в различных точках разностной сетки используются различные разностные уравнения.

Рассмотрим первый послойный переход ($n = 0$). Тогда для всех точек с четными индексами значение сеточной функции находится по известным начальным данным. Пусть значения сеточной функции во всех точках с четным индексом вычислены. Перейдем ко второму этапу. Но схема второго этапа тоже становится явной — если m нечетное, то $m + 1$ и $m - 1$ четные, и для них уже вычислены y_{m-1}^{n+1} и y_{m+1}^{n+1} . Так как счет ведется по явной схеме, но с «перепрыгиванием» узлов через один, то она получила название популярной дворовой игры.

Конечно, такая схема тоже будет негибкой. Тем не менее, условие того, что для фиксированной точки (фиксированного значения индекса по пространству) схема Алена–Чена и «неявная» схема чередуются со слоя на слой, несколько уменьшает негативный эффект негибкой аппроксимации.

Такую схему сложнее исследовать на аппроксимацию, чем однородную схему. Для исследования на устойчивость можно слегка модифицировать спектральный признак устойчивости.

12.3. Уравнение теплопроводности с переменным коэффициентом

12.3.1. Задачи с переменным коэффициентом теплопроводности. Будем теперь рассматривать задачи с переменным коэффициентом теплопроводности (12.1) и (12.2). Вид уравнений (12.1) и (12.2) называется дивергентным видом, или дивергентной формой записи. В случае переменного коэффициента теплопроводности или для нелинейного уравнения (когда коэффициент теплопроводности является функцией от решения) именно дивергент-

ная форма записи является предпочтительной. Такая форма соответствует закону сохранения (энергии, если решается задача теплопроводности, или количества вещества — при рассмотрении задач диффузии). Заметим, что в задаче теплопроводности коэффициент теплопроводности не обязан быть непрерывной функцией. Если, к примеру, рассматривается распространение тепла в бесконечном стержне, одна половина которого ($x < 0$) сделана из одного материала, а правая — из другого, то коэффициент теплопроводности имеет разрыв первого рода в точке 0. В этом случае физический смысл имеет только дивергентная форма записи.

Разностная схема называется консервативной, если выполняются следующие условия. Пусть для дифференциальной задачи выполняется некий закон сохранения. Тогда соответствующий разностный аналог этого закона сохранения выполняется и на сеточном уровне. Если же в дифференциальной задаче имеется несколько законов сохранения, а при переходе к сеточному описанию все они получаются как следствие разностной схемы в результате эквивалентных алгебраических преобразований, то схема называется *полностью консервативной*.

В рассматриваемом случае уравнение теплопроводности выражает закон сохранения энергии. Если уравнение однородное, то изменение энергии некоторого рассматриваемого объема обусловлено потоком тепла через границы этого объема. В системе не должно быть внутренних (разностных) источников или стоков энергии. Сумма потоков через границы ячеек должна сводиться только к потокам через границы расчетной области.

В случае если коэффициент теплопроводности k зависит от времени и координат, консервативную схему можно получить, используя *интегро-интерполяционный метод*. В современной литературе такой подход называют также методом конечных объемов.

Как правило, при записи уравнений в частных производных законам сохранения соответствует дивергентная форма записи. Для уравнения теплопроводности роль такого закона сохранения играет непрерывность теплового потока.

Для этого запишем уравнение в *дивергентной потоковой* форме:

$$\frac{\partial u}{\partial t} + \frac{\partial W}{\partial x} = 0, \quad (12.9)$$

где $W = -k(t, x) \frac{\partial u}{\partial x}$ — тепловой поток.

Выбираем на плоскости (x, t) замкнутый контур. Мы требуем следующее. Каждый контур ограничивает некий конечный объем на плоскости (x, t) . В двумерном случае, конечно, эта величина имеет смысл площади, но подход универсальный и может быть обобщен на случай большего числа пространственных измерений. Фигуры, ограниченные контуром, выпуклые. Они покрывают всю нашу расчетную область без лакун и перекрытий. Контур захватывает точки сетки хотя бы с двух слоев по времени.




Рис. 12.1

Для простоты также наложим требование, чтобы наша расчетная область была покрыта одинаковыми фигурами. Сделать это можно различными способами, при этом будут получаться разные разностные схемы. Независимо от того, какое покрытие выбрано, можно проинтегрировать (12.9) по каждой ячейке. Тогда верно

$$\int_S \left(\frac{\partial u}{\partial t} + \frac{\partial W}{\partial x} \right) dt dx = \oint_{\Gamma} (u dx - W dt) = 0.$$

Зафиксируем покрытие контурами, как изображено на рис. 12.1. Воспользуемся интегральной формой записи и произведем аппроксимацию интеграла по границе прямоугольного контура. Воспользуемся квадратурной формулой Гаусса с одним узлом для приближения интегралов, тогда нам потребуются значения в точках $(n, m - 1/2)$, $(n, m + 1/2)$, $(n + 1, m + 1/2)$, $(n + 1, m - 1/2)$:

Интеграл примет вид

$$y_m^n h - W_{m+1/2}^{n+1/2} \tau - y_m^{n+1} h + W_{m-1/2}^{n+1/2} \tau = 0,$$

или, после деления на площадь ячейки,

$$\frac{y_m^{n+1} - y_m^n}{\tau} + \frac{W_{m+1/2}^{n+1/2} - W_{m-1/2}^{n+1/2}}{h} = 0. \quad (12.10)$$

Потоки в полуцелых точках будем вычислять с помощью линейной интерполяции по верхнему и нижнему временным слоям.

С использованием линейной интерполяции для потоков получим

$$W_{m+1/2}^{n+1/2} = \frac{1}{2} \left(k_{m+1/2}^n \frac{y_{m+1}^n - y_m^n}{h} + k_{m+1/2}^{n+1} \frac{y_{m+1}^{n+1} - y_m^{n+1}}{h} \right),$$

$$W_{m-1/2}^{n+1/2} = \frac{1}{2} \left(k_{m-1/2}^n \frac{y_m^n - y_{m-1}^n}{h} + k_{m-1/2}^{n+1} \frac{y_m^{n+1} - y_{m-1}^{n+1}}{h} \right).$$

Тогда после подстановки выражений для потоков в (12.10) получим схему Кранка–Никольсон для сред с переменным коэффициентом теплопроводности:

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{1}{h} \left(k_{m+1/2} \frac{y_{m+1} - y_m}{h} - k_{m-1/2} \frac{y_m - y_{m-1}}{h} \right)^{(1/2)}.$$

Если интегралы по боковым граням рассматриваемой ячейки приближать методом прямоугольников с левой точкой (т.е. на нижнем слое по времени), то с помощью интегроинтерполяционного метода (метода конечных объемов) получим явную разностную схему

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{1}{h} \left(k_{m+1/2}^n \frac{y_{m+1}^n - 2y_m^n}{h} - k_{m-1/2}^n \frac{y_m^n - 2y_{m-1}^n}{h} \right).$$

При использовании для вычисления интеграла по боковым граням квадратурной формулы прямоугольников с правой точкой получим неявную разностную схему

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{1}{h} \left(k_{m+1/2}^{n+1} \frac{y_{m+1}^{n+1} - 2y_m^{n+1}}{h} - k_{m-1/2}^{n+1} \frac{y_m^{n+1} - 2y_{m-1}^{n+1}}{h} \right).$$

Для исследования устойчивости схем с переменными коэффициентами может использоваться принцип замороженных коэффициентов (см. лекцию 11).

12.3.2. Замечание о задаче с разрывами коэффициента теплопроводности. Важный класс задач составляют задачи с контактными разрывами, на которых коэффициент теплопроводности может терпеть разрыв. При наличии разрывов в коэффициенте теплопроводности решение краевой задачи на верхнем слое становится, вообще говоря, не единственным. Существует множество обобщенных решений, каждое из которых удовлетворяет своему условию согласования в точке разрыва. Для выделения единственного решения необходимо поставить в этой точке

внутреннее краевое условие, оно выбирается из физических соображений и должно входить в полную постановку задачи.

Из физических соображений нужно потребовать непрерывности температуры и теплового потока в точке разрыва коэффициента $x = \xi$, т. е. скачок этих величин слева и справа от разрыва должен быть равен нулю:

$$u|_{x=\xi-0} = u|_{x=\xi+0}, \quad (ku)'|_{x=\xi-0} = (ku)'|_{x=\xi+0}.$$

При этом контактный разрыв всегда должен попадать в узел сетки. Такие сетки называются *специальными*. При этом для аппроксимации коэффициента теплопроводности в ячейке левее точки разрыва пользуются левым коэффициентом, а правее — правым.

В случае невозможности использовать специальную сетку (например, при решении задачи Стефана с движущимся разрывом) используются специальные методы. Описание таких методов выводит нас за рамки вводного курса.

12.4. Разностные схемы в пространстве неопределенных коэффициентов

12.4.1. Построение разностных схем для решения линейного уравнения теплопроводности методом неопределенных коэффициентов. Метод неопределенных коэффициентов для построения разностных схем, аппроксимирующих линейное уравнение теплопроводности, опишем в соответствии с [43].

Рассматриваем начально-краевую задачу для (12.6). Введем в расчетной области равномерную сетку. Для ограниченной области

$$u(n\tau, mh) = y_m^n, \quad n = 1, \dots, N, \quad m = 1, \dots, M.$$

Зафиксируем шаблон разностной схемы. Пусть шаблон включает в себя все точки $(n\tau + \nu\tau, mh + \mu h)$, $\nu = -1, 0, 1$, $\mu = -1, 0, 1$. Уравнение (12.7) симметрично относительно замены $x \leftarrow -x$, при такой замене переменных уравнение переходит само в себя.

Множество всех разностных схем, которые могут быть построены на шаблоне, можно записать в виде

$$y_m^{n+1} = \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 \alpha_{\mu}^{\nu} y_{m+\mu}^{n+\nu}. \quad (12.11)$$

Так как исходное уравнение линейное, то ему в соответствие также ставится линейная комбинация значений сеточной функции. Теперь определим некоторые связи между коэффициентами линейной комбинации (12.11). Для этого рассмотрим проекцию на сетку точного решения исходной дифференциальной задачи $u(n\tau, mh) = u_m^n$. Поскольку точное решение задачи (12.7) при гладких начальных и граничных условиях является бесконечно дифференцируемой функцией, то для точек шаблона справедливо разложение проекции точного решения на сетку в ряд Тейлора в окрестности $(n\tau, mh)$. Имеем

$$\begin{aligned} u_{m+\mu}^{n+\nu} = & u_m^n + \nu\tau \frac{\partial u}{\partial t} + \mu h \frac{\partial u}{\partial x} + \frac{1}{2} \left((\nu\tau)^2 \frac{\partial^2 u}{\partial t^2} + 2\nu\tau \frac{\partial u}{\partial t} \mu h \frac{\partial u}{\partial x} + (\mu h)^2 \frac{\partial^2 u}{\partial x^2} \right) + \\ & + \frac{1}{6} \left((\nu\tau)^3 \frac{\partial^3 u}{\partial t^3} + 3(\nu\tau)^2 \frac{\partial^2 u}{\partial t^2} \mu h \frac{\partial u}{\partial x} + 3\nu\tau \frac{\partial u}{\partial t} (\mu h)^2 \frac{\partial^2 u}{\partial x^2} + (\mu h)^3 \frac{\partial^3 u}{\partial x^3} \right) + \\ & + \frac{1}{24} \left((\nu\tau)^4 \frac{\partial^4 u}{\partial t^4} + 4(\nu\tau)^3 \frac{\partial^3 u}{\partial t^3} \mu h \frac{\partial u}{\partial x} + 6(\nu\tau)^2 \frac{\partial^2 u}{\partial t^2} (\mu h)^2 \frac{\partial^2 u}{\partial x^2} + \right. \\ & \left. + 4\nu\tau \frac{\partial u}{\partial t} (\mu h)^3 \frac{\partial^3 u}{\partial x^3} + (\mu h)^4 \frac{\partial^4 u}{\partial x^4} \right) + \dots \quad (12.12) \end{aligned}$$

Теперь необходимые разложения (12.12) подставляем в разностную схему и собираем члены с одинаковыми степенями разложения по сеточным параметрам. Получим, что при членах разложения, включающих u_m^n , в правой и левой частях стоят соответственно 1 и сумма $\sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 \alpha_{\mu}^{\nu}$, поэтому

$$1 = \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 \alpha_{\mu}^{\nu}. \quad (12.13)$$

Прежде чем продолжить процедуру вывода условий аппроксимации, используем еще одно необязательное предположение, сильно облегчающее дальнейшую процедуру. Будем считать, что отмеченное выше свойство симметрии дифференциального уравнения сохраняется и в разностной задаче. Это означает, что $\alpha_{\mu}^{\nu} = \alpha_{-\mu}^{\nu}$. Конечно, при таком предположении из рассмотрения исключаются схемы с несимметричным шаблоном типа схем Саульева. Зато число неопределенных коэффициентов сокращается, а при пространственных производных нечетных порядков (первых,

третьих) коэффициенты в разложении автоматически становятся равными нулю.

Теперь первый порядок по шагу по времени и второй порядок в разложении шага по пространству должны приводить к уравнению теплопроводности. Имеем

$$\tau \frac{\partial u}{\partial t} = \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 \nu \alpha_{\mu}^{\nu} \frac{\partial u}{\partial t} + \frac{h^2}{2} \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 \mu^2 \alpha_{\mu}^{\nu} \frac{\partial^2 u}{\partial x^2}.$$

Это уравнение перейдет в (12.6) при выполнении условия

$$\sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 (\mu^2 + 2\sigma(\nu - 1)) \alpha_{\mu}^{\nu} = 1 \quad (12.14)$$

или, с учетом симметрии схемы,

$$\sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=0}^1 (\mu^2 + 2\sigma(\nu - 1)) \widetilde{\alpha}_{\mu}^{\nu} = 1. \quad (12.15)$$

Здесь введено обозначение $\widetilde{\alpha}_{\mu}^{\nu} = \alpha_{\mu}^{\nu}$, $\mu = 0$ и $\widetilde{\alpha}_{\mu}^{\nu} = 2\alpha_{\mu}^{\nu}$, $\mu \neq 0$. Как и выше, σ — параболическое число Куранта ($\sigma = k\tau/h^2$).

На рассматриваемом шаблоне изначально было 8 неопределенных коэффициентов. Три коэффициента исключены за счет условий симметрии. Еще два коэффициента могут быть выражены через остальные с использованием условий аппроксимации минимального порядка (12.13), (12.14). Тогда любая тройка действительных чисел, соответствующая трем свободным коэффициентам, будет определять аппроксимирующую разностную схему.

Будем говорить, что трехмерное действительное пространство, соответствующее свободным коэффициентам, является пространством неопределенных коэффициентов. Любая точка в данном пространстве соответствует аппроксимирующей разностной схеме для решения уравнения теплопроводности.

Такие пространства впервые были введены А. С. Холодовым [54].

Среди всех точек трехмерного пространства можно указать множества схем, обладающих некими дополнительными свойствами. Во-первых, это схемы повышенного порядка аппроксимации.

Во-вторых, это устойчивые схемы. В-третьих, это множество монотонных схем.

12.4.2. О монотонности разностных схем. Монотонные разностные схемы (по Фридрихсу) — это схемы, которые при записи в виде, разрешенном относительно u_m^{n+1} при значениях сеточной функции во всех остальных точках шаблона, имеют неотрицательные коэффициенты. Монотонные разностные схемы не приводят к появлению паразитных осцилляций в численном решении.

Исследуем, является ли явная четырехточечная схема $(u_m^{n+1} - u_m^n)/\tau = k\Lambda_{xx}u^n$ монотонной. Для этого представим рассматриваемую схему в виде (12.11):

$$u_m^{n+1} = \sum_{k=-1}^1 \alpha_k u_{m+k},$$

где $\alpha = 1 - 2\sigma$, $\alpha_1 = \alpha_{-1} = \sigma$.

Схема является монотонной при выполнении условия $\alpha_k \geq 0$, $k = -1, 0, 1$, т. е. при $\sigma \leq 0.5$. Явная разностная схема — условно монотонная. Условие монотонности для явной схемы совпало с условием устойчивости.

Исследование монотонности параметрической шеститочечной схемы [21] в виде $u_m^{n+1} = \sum_{k=0}^{\infty} \alpha_k u_{m+k}$ дает (выкладки опускаем ввиду их громоздкости)

$$\begin{aligned} u_m^{n+1} &= \alpha_0 u_m + \sum_{k=1}^{\infty} \alpha_k (u_{m-k} + u_{m+k}), \\ \alpha_0 &= 1 - \frac{4k\tau}{\sqrt{h^2 + 4\xi k\tau}} \left(h + \sqrt{h^2 + 4\xi k\tau} \right)^{-1}, \\ \alpha_1 &= \frac{4k\tau}{\sqrt{h^2 + 4\xi k\tau}} \left(h + \sqrt{h^2 + 4\xi k\tau} \right)^{-2}, \\ \alpha_k &= \alpha_{k-1} \cdot 4\xi k\tau \left(h + \sqrt{h^2 + 4\xi k\tau} \right)^{-2}, \quad k \geq 2. \end{aligned}$$

Коэффициенты α_k при $k \geq 1$ неотрицательны, коэффициент α_0 неотрицателен при выполнении условия $\sigma \leq \frac{2-\xi}{4(1-\xi)^2}$. Отсюда видно, что за исключением неявной четырехточечной схемы с $\xi = 1$ все неявные схемы являются монотонными лишь при условии $\tau \sim h^2$.

12.4.3. Монотонные разностные схемы в пространстве неопределенных коэффициентов. Устойчивость разностных схем. Продолжим рассмотрение метода неопределенных коэффициентов на примере схем на введенном в рассмотрение выше девятиточечном шаблоне.

Выделим в пространстве неопределенных коэффициентов схемы повышенного порядка аппроксимации. Для этого воспользуемся следующими следствиями исходного дифференциального уравнения:

$$\frac{\partial}{\partial t} \frac{\partial u}{\partial t} = \frac{\partial}{\partial t} k \frac{\partial^2 u}{\partial x^2} = k \frac{\partial^2}{\partial x^2} \frac{\partial u}{\partial t} = k \frac{\partial^2}{\partial x^2} k \frac{\partial^2 u}{\partial x^2} = k \frac{\partial^4 u}{\partial x^4}. \quad (12.16)$$

Отсюда следует, что теперь после подстановки разложений (12.12) в схему (12.11) для обеспечения следующего порядка аппроксимации нам надо собрать слагаемые с производными $\frac{\partial^2 u}{\partial t^2}$, $\frac{\partial^3 u}{\partial t \partial x^2}$ и $\frac{\partial^4 u}{\partial x^4}$. С учетом самого уравнения (12.6) и его следствий (12.16) условие, которое приводит к множеству разностных схем следующего порядка аппроксимации (второго по времени и четвертого по пространственной переменной) примет вид

$$\sum_{\nu=-1}^1 \sum_{\substack{\mu=0 \\ (\nu, \mu) \neq (1, 0)}}^1 \left(\frac{\nu^2 \sigma^2}{2} + \frac{\nu \sigma}{12} (6\mu^2 - 1) + \frac{\mu^2}{24} (1 - \mu^2) \right) \tilde{\alpha}_{\mu}^{\nu} = \frac{\sigma(6\sigma - 1)}{12}.$$

Если же требуется достичь только второго порядка по времени, ограничиваясь вторым порядком аппроксимации по пространственной переменной, то условие аппроксимации немного упрощается:

$$\sum_{\nu=-1}^1 \sum_{\substack{\mu=0 \\ (\nu, \mu) \neq (1, 0)}}^1 \left(\frac{\nu^2 \sigma^2}{2} + \frac{\nu \sigma}{12} (6\mu^2 - 1) + \frac{\mu^2}{24} \right) \tilde{\alpha}_{\mu}^{\nu} = \frac{\sigma(6\sigma - 1)}{12}.$$

Повышение порядка аппроксимации выделяет в трехмерном пространстве неопределенных коэффициентов плоскость схем повышенного порядка аппроксимации. Учитывая дифференциальные следствия исходного уравнения в частных производных и собирая соответствующие слагаемые в разложениях (12.12), можно получить условия следующих порядков аппроксимации.

Важным свойством разностной схемы является ее монотонность. Рассмотрим, как строится множество всех монотонных разностных схем на симметричном шаблоне. Рассмотрим подмножество таких разностных схем, что, кроме рассчитываемой точки, коэффициенты $\tilde{\alpha}_\mu^v$ отличаются от нуля еще в двух точках шаблона. Конечно, в силу симметрии шаблона каждый такой коэффициент с тильдой реально соответствует двум точкам шаблона (и двум коэффициентам в записи (12.14), если он не лежит на оси симметрии). Для таких «трехточечных» (с учетом симметрии шаблона) разностных схем доказана следующая теорема о монотонности линейной разностной схемы для решения уравнения теплопроводности.

Теорема 12.1 (А. С. Холодов). *Для того чтобы разностная схема (12.11), в которой от нуля отличны только два коэффициента, была монотонной, необходимо и достаточно, чтобы узлы шаблона, соответствующие ненулевым коэффициентам $\tilde{\alpha}_\mu^v$, располагались по разные стороны от параболы*

$$\left(\frac{x - x_m}{h}\right)^2 + 2\sigma\left(\frac{t - t_n}{\tau}\right) = 0.$$

Данная теорема позволяет среди всех «трехточечных» схем при фиксированном числе Куранта выбрать все монотонные. Эти монотонные разностные схемы (низкого порядка аппроксимации, так как точек шаблона хватает лишь на первый порядок аппроксимации по времени и второй по пространству) будут границами области монотонности в пространстве неопределенных коэффициентов. Множество всех разностных схем будет афинной оболочкой всех возможных на данном шаблоне разностных схем с минимальным шаблоном. Множество всех монотонных схем можно определить как выпуклую оболочку (см. Приложение 5) всех монотонных «трехточечных» схем.

На основе подхода в пространстве неопределенных коэффициентов с использованием приведенной выше теоремы легко получить качественные выводы о монотонности шеститочечной параметрической схемы. Множество всех шеститочечных разностных схем с весами есть афинная оболочка двух «минимальных» схем — явной и неявной. Множество монотонных схем есть выпуклая оболочка этих же схем при условии, что явная схема является монотонной. По сформулированной выше теореме явная схема может быть только условно монотонной (при числе Куран-

та $\sigma = k\tau/h^2 < 1/2$). Следовательно, все (неявные) шеститочечные схемы (кроме простой неявной) могут быть только условно монотонными.

Как показывает рассмотрение, например, семейства шеститочечных схем с весами, монотонная схема может иметь более высокий порядок аппроксимации, чем первый. Например, схема Кранка–Никольсона всегда имеет второй порядок аппроксимации по своим переменным и монотонна при $\sigma < 1$. Отметим, что существование монотонных разностных схем высокого порядка аппроксимации — факт нетривиальный. Это обстоятельство делает численное решение уравнений параболического типа относительно несложной задачей.

Исследование на устойчивость семейства разностных схем для уравнения с постоянным коэффициентом можно провести с использованием спектрального признака. В силу симметрии шаблона спектр оператора послойного перехода в этом случае будет действительным. Подставим решение в виде $y_m^n = \lambda^n e^{i\varphi m}$ в равенство (12.11). После подстановки получим

$$\lambda^{n+1} e^{i\varphi m} = \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 \alpha_\mu^\nu \lambda^{n+\nu} e^{i\varphi(m+\mu)},$$

так как для вычисления спектра оператора послойного перехода нас интересует нетривиальное решение. Заметим, что в силу симметрии шаблона мнимые части комплексных экспонент будут входить в итоговое уравнение с одинаковыми коэффициентами, но с обратными знаками. Тогда после упрощений мы получим квадратное уравнение для спектра оператора послойного перехода

$$\lambda^2 = \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 \alpha_\mu^\nu \lambda^{1+\nu} \cos(\varphi\mu),$$

или

$$\lambda^2 = \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=0}^1 \tilde{\alpha}_\mu^\nu \lambda^{1+\nu} \cos(\varphi\mu).$$

Кроме того, должны выполняться условия аппроксимации (12.13), (12.14), т. е.

$$1 = \lambda^2 = \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 \alpha_{\mu}^{\nu} = \sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=0}^1 \widetilde{\alpha}_{\mu}^{\nu}.$$

$$\sum_{\substack{\nu=-1 \\ (\nu, \mu) \neq (1, 0)}}^1 \sum_{\mu=-1}^1 (\mu^2 + 2\sigma(\nu - 1)) \widetilde{\alpha}_{\mu}^{\nu} = 0.$$

Тогда можно оставить свободными коэффициентами, например, $\widetilde{\alpha}_1^1, \widetilde{\alpha}_0^{-1}, \widetilde{\alpha}_1^{-1}$. С учетом условий аппроксимации минимального порядка квадратное уравнение для спектра оператора послыонного перехода будет

$$\begin{aligned} (1 - c\widetilde{\alpha}_1^1)\lambda^2 + [(1 - 2\sigma + 2\sigma\widetilde{\alpha}_1^1 - (1 + 2\sigma)\widetilde{\alpha}_0^{-1} - 2\sigma\widetilde{\alpha}_1^{-1}) + \\ + (2\sigma - (1 + 2\sigma)\widetilde{\alpha}_1^1 + 2\sigma\widetilde{\alpha}_1^{-1} - (1 - 2\sigma)\widetilde{\alpha}_1^{-1})c]\lambda - \\ - \widetilde{\alpha}_0^{-1} - \widetilde{\alpha}_1^{-1} c = 0. \end{aligned}$$

Здесь $c = \cos \varphi$.

Для исследования на устойчивость отметим, что в квадратное уравнение входит параметр $-1 \leq c \leq 1$. Потребуем, чтобы оба корня квадратного уравнения были по абсолютному значению меньше 1. По теореме Виета необходимо потребовать, чтобы в приведенном уравнении свободный член по абсолютному значению не превосходил единицы:

$$\left| \frac{\widetilde{\alpha}_0^{-1} + \widetilde{\alpha}_1^{-1}c}{1 - c\widetilde{\alpha}_1^1} \right| \leq 1.$$

Заметим, что производная

$$\frac{d}{dc} \frac{\widetilde{\alpha}_0^{-1} + \widetilde{\alpha}_1^{-1}}{1 - c\widetilde{\alpha}_1^1} = \frac{(\widetilde{\alpha}_1^{-1} + \widetilde{\alpha}_1^{-1}) \widetilde{\alpha}_1^1}{(1 - c\widetilde{\alpha}_1^1)^2}$$

при фиксированных коэффициентах схемы не обращается в нуль. Значит, наибольшее и наименьшее значения дробно-линейная функция параметра c принимает на концах отрезка, где функция

определена. Для того чтобы при всех значениях параметра свободный член в квадратном уравнении не превосходил единицы, необходимо выполнение двух неравенств

$$\left| \frac{\tilde{\alpha}_0^{-1} + \tilde{\alpha}_1^{-1}}{1 - \tilde{\alpha}_1^1} \right| \leq 1$$

и

$$\left| \frac{\tilde{\alpha}_0^{-1} + \tilde{\alpha}_1^{-1}}{1 + \tilde{\alpha}_1^1} \right| \leq 1$$

на верхней и на нижней границах области значений параметра c . Снимая знаки модуля, получим, что коэффициенты разностной схемы должны удовлетворять следующей системе неравенств:

$$1 - \tilde{\alpha}_1^1 + \tilde{\alpha}_0^{-1} + \tilde{\alpha}_1^{-1} \geq 0,$$

$$1 - \tilde{\alpha}_1^1 - \tilde{\alpha}_0^{-1} - \tilde{\alpha}_1^{-1} \geq 0,$$

$$1 + \tilde{\alpha}_1^1 + \tilde{\alpha}_0^{-1} - \tilde{\alpha}_1^{-1} \geq 0.$$

Теперь потребуем, чтобы в приведенном уравнении коэффициент при первой степени был по абсолютной величине не больше 2. Получим

$$|g(c)| = \left| \frac{(1 - 2\sigma + 2\sigma\tilde{\alpha}_1^1 - (1 + 2\sigma)\tilde{\alpha}_0^{-1} - 2\sigma\tilde{\alpha}_1^1) + (2\sigma - (1 + 2\sigma)\tilde{\alpha}_1^1 + 2\sigma\tilde{\alpha}_1^{-1} - (1 - 2\sigma)\tilde{\alpha}_1^{-1})c}{1 - c\tilde{\alpha}_1^1} \right| \leq 2.$$

Видно, что знак производной не зависит от параметра, при фиксированных значениях коэффициентов наибольшее и наименьшее значения функции достигаются на границах области значений параметров.

При $c = 1$ имеем

$$\left| \frac{1 - 4\sigma + (1 + 4\sigma)\tilde{\alpha}_1^1 - (1 + 4\sigma)\tilde{\alpha}_0^{-1} + (1 - 4\sigma)\tilde{\alpha}_1^{-1}}{1 - \tilde{\alpha}_1^1} \right| \leq 2.$$

При $c = -1$ имеем

$$\left| \frac{1 - \tilde{\alpha}_1^1 - \tilde{\alpha}_0^{-1} - \tilde{\alpha}_1^{-1}}{1 + \tilde{\alpha}_1^1} \right| \leq 2.$$

С учетом ограничений, полученных выше, из второго неравенства имеем

$$1 - \widetilde{\alpha}_1^1 - \widetilde{\alpha}_0^{-1} - \widetilde{\alpha}_1^{-1} \leq 2 - 2\widetilde{\alpha}_1^1,$$

откуда

$$1 - \widetilde{\alpha}_1^1 + \widetilde{\alpha}_0^{-1} + \widetilde{\alpha}_1^{-1} \geq 0.$$

Это условие также совпадает с одним из ранее полученных ограничений.

Другое неравенство приводит к условию

$$1 - 2\sigma + (1 - 2\sigma)\widetilde{\alpha}_1^1 - \left(\frac{1}{2} + 2\sigma\right)\widetilde{\alpha}_0^{-1} + \left(\frac{1}{2} - 2\sigma\right)\widetilde{\alpha}_1^{-1} \geq 0.$$

Используя условия аппроксимации более высоких порядков, можно строить множество соответствующих разностных схем. При определенных фиксированных значениях чисел Куранта множество схем высокого порядка аппроксимации будет иметь пересечения со множеством схем монотонных.

Это — характерная черта разностных схем для решения уравнений именно параболического типа. Для гиперболических задач, как мы увидим в дальнейшем, не существует монотонных схем высокого (выше первого) порядка аппроксимации.

12.5. Численные методы решения полулинейного уравнения теплопроводности

12.5.1. Полулинейное уравнение теплопроводности. Назовем полулинейным уравнением параболического типа следующее уравнение

$$\frac{\partial u}{\partial t} = \frac{\partial}{\partial x} \left[k(x, t) \frac{\partial u}{\partial x} \right] + f(u, t, x), \quad t \in [0, T], \quad x \in [0, X].$$

Здесь $k(x, t) > 0$.

Дифференциальный оператор, входящий в уравнение, линейный. Вся нелинейность сосредоточена только в функции правой части.

Ограничимся в данном параграфе рассмотрением важного частного случая полулинейного уравнения

$$\frac{\partial u}{\partial t} = \frac{\partial}{\partial x} \left[k(x, t) \frac{\partial u}{\partial x} \right] + f(u).$$

Это довольно часто встречающийся тип задач при моделировании химических и экологических процессов.

Постановки основных начально-краевых задач совпадают с соответствующими постановками для линейного уравнения (действительно, дифференциальный оператор для линейного и полулинейного уравнения один и тот же).

12.5.2. Простейшие разностные схемы для полулинейных уравнений. Разностные схемы, построенные выше для линейной задачи, обобщаются и на случай задачи полулинейной. Приведем только формулировки явной и неявной четырехточечных схем:

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{1}{h} \left[k_{m+1/2}^n \frac{u_{m+1}^n - u_m^n}{h} - k_{m-1/2}^n \frac{u_m^n - u_{m-1}^n}{h} \right] + f_m^n,$$

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{1}{h} \left[k_{m+1/2}^{n+1} \frac{u_{m+1}^{n+1} - u_m^{n+1}}{h} - k_{m-1/2}^{n+1} \frac{u_m^{n+1} - u_{m-1}^{n+1}}{h} \right] + f_m^{n+1}.$$

Здесь использованы обозначения $k_{m+1/2}^n = k(n\tau, mh + 0.5h)$, $f_m^n = f(u_m^n)$, остальные обозначения очевидны.

В чем отличие от линейного случая? Исследование на аппроксимацию дает для этих схем формально тот же результат, что и для линейного уравнения. Правда, здесь надо уже быть осторожнее, так как существование решения задач такого типа не гарантировано при произвольной функции $f(u)$. Не будем останавливаться на вопросах существования решения — это предмет курса нелинейных уравнений в частных производных. Отметим только, что аппроксимация определена лишь на решении дифференциальной задачи. Если у дифференциальной задачи решения не существует, то говорить об аппроксимации не приходится.

Исследование на устойчивость данных разностных схем ведется немного иначе. В качестве «практического» приема (не имеющего, впрочем, под собой достаточного обоснования), можно рекомендовать следующее. Вычисляем производную Фреше разностного оператора (о производной Фреше см. Приложение 1). Записываем уравнение в вариациях. Вычисляем его устойчивость по принципу замороженных коэффициентов.

Принцип замороженных коэффициентов — эвристический прием исследования на устойчивость. В уравнении с переменными коэффициентами на этапе послыйного перехода все коэффициенты считаются постоянными и проводится исследование на устойчивость, например, с использованием спектрального признака. Вывод об устойчивости или неустойчивости делается при наихудшем

допустимом значении параметра. Отметим, что принцип замороженных коэффициентов не только не имеет строгого обоснования, но и иногда приводит к неверным выводам.

12.5.3. Пример исследования одной экологической модели.

Рассмотрим следующую задачу из динамики популяций. Пусть в изолированной популяции с полным перемешиванием динамика численности описывается уравнением Ферхюльста. Пусть, кроме того, справедлива гипотеза о случайных перемещениях особей в пространстве. Тогда мы получаем следующее уравнение популяционной динамики, принадлежащее к классу уравнений «реакция–диффузия» (частный случай полулинейных уравнений параболического типа):

$$\frac{\partial n}{\partial t} = D \frac{\partial^2 n}{\partial x^2} + an(K - n). \quad (12.17)$$

Это уравнение исследовалось в работах Колмогорова, Петровского и Пискунова, Фишера. Само уравнение носит название уравнения Колмогорова–Петровского–Пискунова (КПП).

Мы записали это уравнение в размерном виде. Уравнения популяционной динамики имеет смысл писать в терминах плотности популяции. Тогда D — коэффициент подвижности особей, aK — мальтузианская скорость роста численности популяции, K — равновесная плотность особей на ареале. Из трех входящих в уравнение параметров только два имеют независимую размерность. Безразмерная запись уравнения будет зависеть от одного параметра. Можно составить характерные безразмерные комбинации. Для реакционно-диффузионной длины и характерной скорости имеем

$$L^* = \sqrt{\frac{D}{aK}}, \quad v^* = \sqrt{DaK}.$$

Выбираем характерный пространственный масштаб задачи L_0 . Введем безразмерные переменные в соответствии со следующим способом выбора масштабов функции и независимых переменных задачи: $x = L_0 \xi$, $n = L_0^{-2} u$, тогда $t = \tau(KD) = L_0^2 \tau / D$ и уравнение КПП переписывается в следующем безразмерном виде:

$$\frac{\partial u}{\partial \tau} = \frac{\partial^2 u}{\partial \xi^2} + \alpha u(1 - u), \quad (12.18)$$

где единственный безразмерный параметр α выражается через размерные: $\alpha = a/D$.

Можно выбрать масштабы величин для приведения уравнения КПП к безразмерному виду и другим образом. При этом, конечно, управляющий безразмерный параметр может стоять при других слагаемых в правой части. Для дальнейшего нам наиболее удобен именно такой вид.

Рассмотрим следующую задачу Коши. Уравнение решается в полосе $(-\infty, \infty) \times [0, T]$ с начальным условием

$$u(x, 0) = \begin{cases} 1, & x \leq 0, \\ 0, & x > 0. \end{cases}$$

Заметим, что функции $u(x, t) = 0$ и $u(x, t) = 1$ являются пространственно-однородными стационарными решениями уравнения КПП (12.18). Элементарное исследование на устойчивость этих решений приводит к выводу о том, что $u(x, t) = 0$ — неустойчивое решение, $u(x, t) = 1$ — устойчивое. Можно ожидать, что решением нашей задачи Коши будет волна переключения из неустойчивого состояния среды в устойчивое. Доказательство этого факта лежит за рамками нашего рассмотрения; отметим лишь, что свойствам уравнения КПП посвящена обширная литература.

Поставим в соответствие задаче КПП явную разностную схему

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{u_{m+1}^n - 2u_m^n + u_{m-1}^n}{h^2} + \alpha u_m^n (1 - u_m^n),$$

а в соответствие задаче Коши — краевую задачу

$$u(-A, t) = 1, \quad u(A, t) = 0.$$

Параметр A выбирается достаточно большим, чтобы перенос граничных условий из бесконечности на конечное расстояние от начала координат внес бы несущественную погрешность, не превышающую погрешности аппроксимации данной схемы. Аккуратная оценка такого значения для каждой задачи — дело трудоемкое. На практике значение выбирается после серии расчетов с постепенно увеличивающейся длиной отрезка интегрирования, но при постоянных значениях остальных сеточных параметров.

Отметим здесь еще одну пользу приведения задачи к безразмерным переменным. У нас не только снизилось число управляющих параметров, но и сама искомая сеточная функция, как

ождается, будет принадлежать отрезку $[0; 1]$. На этом отрезке плотность машинных чисел выше, чем на любом отрезке большей длины или единичном отрезке, сдвинутом относительно начала координат. Это следует из представления машинных чисел в памяти в формате с плавающей точкой. При таком представлении число машинных чисел одинаково внутри каждого двоичного порядка. Следовательно, мы отображаем непрерывную функцию на дискретное множество, но с большим числом элементов. Можно ожидать, что это приведет к уменьшению ошибок округления. Кроме того, исчезнет влияние одного из самых коварных видов погрешностей — ошибок выравнивания, появляющихся при вычитании больших по абсолютной величине очень близких чисел.

Теперь исследуем разностную схему на устойчивость. Для этого предположим, что дифференциальная задача обладает единственным решением (даже для рассматриваемой задачи Коши для уравнения КПП это неверно — решение задачи неединственно!) и на проекции на сетку точного решения вычислим производную Фреше нашей разностной задачи. По определению это

$$\begin{aligned} \lim_{\varepsilon \rightarrow 0} \frac{1}{\varepsilon} \left[\frac{(u + \varepsilon v)_m^{n+1} - (u + \varepsilon v)_m^n}{\tau} - \frac{(u + \varepsilon v)_{m+1}^n - 2(u + \varepsilon v)_m^n + (u + \varepsilon v)_{m-1}^n}{h^2} - \right. \\ \left. - \alpha(u + \varepsilon v)_m^n (1 - (u + \varepsilon v)_m^n) - \right. \\ \left. - \left(\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - 2u_m^n - u_{m-1}^n}{h^2} - \alpha u_m^n (1 - u_m^n) \right) \right] = \\ = \frac{v_m^{n+1} - v_m^n}{\tau} - \frac{v_{m+1}^n - 2v_m^n - v_{m-1}^n}{h^2} - \alpha v_m^n + 2\alpha u_m^n v_m^n. \end{aligned}$$

Мы имеем линейную задачу в вариациях

$$\frac{v_m^{n+1} - v_m^n}{\tau} = \frac{v_{m+1}^n - 2v_m^n - v_{m-1}^n}{h^2} + \alpha v_m^n - 2\alpha u_m^n v_m^n,$$

которая допускает использование принципа замороженных коэффициентов.

По принципу замороженных коэффициентов задача условно-устойчивая. Около «устойчивого состояния» ($u \approx 1$) схема в вари-

ациях превращается в простую явную разностную схему для уравнения теплопроводности. Вблизи «фона», по которому бежит волна переключения ($0 \leq u_m^n \ll 1$), условие тоже совпадает с условием устойчивости явной разностной схемы по спектральному признаку фон Неймана, так как

$$\lambda = 1 - 4 \frac{\tau}{h^2} \sin^2 \frac{\varphi}{2} + \tau \alpha.$$

Хотя формально условие устойчивости фон Неймана выполнено при соответствующем значении числа Куранта вне зависимости от α (α — параметр дифференциальной задачи и не зависит от шагов сетки), при конкретном численном расчете надо всегда стремиться, чтобы выполнялось требование $\tau \alpha \ll 1$.

Если теперь мы рассматриваем неявную разностную схему, то правила перехода для внутренних точек будут

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{u_{m+1}^{n+1} - 2u_m^{n+1} + u_{m-1}^{n+1}}{h^2} + \alpha u_m^{n+1} (1 - u_m^{n+1}),$$

и на верхнем слое по времени приходится решать нелинейную задачу.

Основные приемы здесь следующие.

1. Нелинейность на предыдущем слое по времени. Тогда мы получаем схему, не эквивалентную ни явной, ни неявной схеме:

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{u_{m+1}^{n+1} - 2u_m^{n+1} + u_{m-1}^{n+1}}{h^2} + \alpha u_m^n (1 - u_m^n).$$

Уравнение в вариациях

$$\frac{v_m^{n+1} - v_m^n}{\tau} = \frac{v_{m+1}^{n+1} - 2v_m^{n+1} + v_{m-1}^{n+1}}{h^2} + \alpha v_m^n - 2\alpha u_m^n v_m^n.$$

Характеристическое уравнение при исследовании на устойчивость

$$\frac{\lambda - 1}{\tau} = \frac{e^{i\varphi} - 2 + e^{-i\varphi}}{h^2} \lambda + \alpha - 2\alpha u_m^n.$$

Тогда спектр оператора послойного перехода будет

$$\lambda = \frac{1 + \tau \alpha (1 - 2u_m^n)}{1 + 4\sigma \sin^2 \varphi / 2}.$$

В этом случае, как и ранее, по признаку фон Неймана схема безусловно устойчива, но появляется практическое требование $\tau \ll 1$. Конечно, такой способ вычислений — на верхнем слое по времени рассматривается линейный разностный оператор, а нелинейность может быть отнесена в «правую часть» — самый простой с точки зрения численной реализации.

2. Метод Ньютона.

Итерации метода Ньютона для рассматриваемого уравнения приводят к необходимости на каждой итерации метода решать на верхнем слое линейную систему

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{u_{m+1}^{n+1} - 2u_m^{n+1} + u_{m-1}^{n+1}}{h^2} + \alpha u_m^{n+1} - 2\alpha \tilde{u}_m^{n+1} u_m^{n+1}.$$

Здесь величины $\tilde{u}_m^{n+1}$ относятся к верхнему временному слою, но к предыдущей ньютоновской итерации.

В этом случае формально схема безусловно устойчива. Вопрос о сходимости метода Ньютона оставим открытым (для уравнения КПП все относительно благополучно, но это не всегда так!). При практической реализации метода у нас должны быть устойчивы все части нашего алгоритма. На верхнем слое система линейных уравнений решается прогонкой.

При решении практических задач для полулинейных систем, как правило, метод Ньютона сходится за 3–10 итераций. Если в реализованной задаче сходимость метода Ньютона более медленная, надо провести более тщательное исследование поставленной дифференциальной задачи.

12.5.4. Повышение порядка аппроксимации схемы для полулинейного уравнения. Используем то, что уравнение является неоднородным, а функция $f(u)$ не зависит явно от первой производной по пространству. Предположим также, что $k(x, t)$ является бесконечно непрерывно дифференцируемой функцией.

В качестве примера рассмотрим повышение порядка аппроксимации простой явной схемы

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{1}{h} \left[k_{m+1/2}^n \frac{u_{m+1}^n - u_m^n}{h} - k_{m-1/2}^n \frac{u_m^n - u_{m-1}^n}{h} \right] + f_m^n.$$

Идеи повышения порядка аппроксимации для полулинейной задачи близки к идеям повышения порядка аппроксимации в методе неопределенных коэффициентов. Как ни парадоксально, наличие нелинейной функции не усложняет, а даже несколько упрощает задачу. Как и при исследовании схемы на аппроксимацию, разложим проекцию точного решения дифференциальной задачи на сетку в ряды Тейлора в окрестности точки u_m^n . Имеем:

$$\begin{aligned} u_m^{n+1} &= u_m(t + \tau) = \\ &= u_m(t) + \tau u'_t(t) + \frac{\tau^2}{2!} u''_t(t) + \frac{\tau^3}{3!} u^{(3)}_t(t) + \frac{\tau^4}{4!} u^{(4)}_t(t) + O(\tau^5), \end{aligned}$$

$$\begin{aligned} u_{m+1}^n &= u^n(x + h) = \\ &= u^n(x) + h u'_x(x) + \frac{h^2}{2!} u''_x(x) + \frac{h^3}{3!} u^{(3)}_x(x) + \frac{h^4}{4!} u^{(4)}_x(x) + O(h^5), \end{aligned}$$

$$\begin{aligned} u_{m-1}^n &= u^n(x - h) = \\ &= u^n(x) - h u'_x(x) + \frac{h^2}{2!} u''_x(x) - \frac{h^3}{3!} u^{(3)}_x(x) + \frac{h^4}{4!} u^{(4)}_x(x) + O(h^5). \end{aligned}$$

Кроме того, учтем, что

$$\begin{aligned} k_{m+1/2}^n &= k^n\left(x + \frac{h}{2}\right) = \\ &= k_m^n + \frac{h}{2} k'_x(x) + \frac{h^2}{4 \cdot 2!} k''_x(x) + \frac{h^3}{8 \cdot 3!} k^{(3)}_x(x) + \frac{h^4}{16 \cdot 4!} k^{(4)}_x(x) + O(h^5), \end{aligned}$$

$$\begin{aligned} k_{m-1/2}^n &= k^n\left(x - \frac{h}{2}\right) = \\ &= k_m^n - \frac{h}{2} k'_x(x) + \frac{h^2}{4 \cdot 2!} k''_x(x) - \frac{h^3}{8 \cdot 3!} k^{(3)}_x(x) + \frac{h^4}{16 \cdot 4!} k^{(4)}_x(x) + O(h^5) \end{aligned}$$

и подставим все эти разложения в исходную разностную схему. Удерживаем члены до второго порядка по времени (τ) и четвертого по пространству (h). Получаем в левой части равенства

$$\frac{u_m^{n+1} - u_m^n}{\tau} = u'_t + \frac{\tau}{2} u''_t + \frac{\tau^2}{6} u'''_t + O(\tau^3).$$

В правой части будем собирать слагаемые с одинаковыми степенями шага по пространству.

$$\begin{aligned}
 -2: & \quad k_m^n u_m^n (1 - 2 + 1) \equiv 0, \\
 -1: & \quad \frac{k'_x}{2} u_m^n (1 - 1) + \frac{k'_x}{2} u_m^n (1 - 1) + k_m^n \frac{\partial u}{\partial x} - k_m^n \frac{\partial u}{\partial x} \equiv 0, \\
 0: & \quad 2 \frac{k'_x}{2} \frac{\partial u}{\partial x} + k_m^n \frac{\partial^2 u}{\partial x^2} = \frac{\partial}{\partial x} k \frac{\partial u}{\partial x} \Big|_{m,n}, \\
 1: & \quad \frac{k'_x}{2} \left(\frac{1}{2} \frac{\partial^2 u}{\partial x^2} - \frac{1}{2} \frac{\partial^2 u}{\partial x^2} \right) + \frac{k''_x}{8} \left(\frac{\partial u}{\partial x} - \frac{\partial u}{\partial x} \right) + \frac{1}{6} \left(k_m^n \frac{\partial^3 u}{\partial x^3} - k_m^n \frac{\partial^3 u}{\partial x^3} \right) \equiv 0, \\
 2: & \quad 2 \frac{k'''_x}{24} \frac{\partial u}{\partial x} + 2 \frac{k''_x}{8} \frac{\partial^2 u}{\partial x^2} + 2 \frac{k'_x}{2} \frac{1}{6} \frac{\partial^3 u}{\partial x^3} + k_m^n \frac{1}{12} \frac{\partial^4 u}{\partial x^4} = \frac{1}{12} (ku')''' - \frac{1}{12} k'_x u'''.
 \end{aligned}$$

Если из правой части схемы вычесть $\frac{1}{12}(ku')'''$, то в случае постоянного коэффициента диффузии (теплопроводности) порядок схемы повышается до четвертого по пространству, в случае квазилинейного уравнения и неоднородного по пространству коэффициента теплопроводности порядок аппроксимации сохраняется, но уменьшается невязка. С другой стороны, при фиксированном времени (на данном временном слое) в силу самого уравнения

$$\frac{\partial^2}{\partial x^2} (ku')' + \frac{\partial^2}{\partial x^2} f = 0,$$

откуда имеем простую модернизацию разностной схемы

$$\begin{aligned}
 \frac{u_m^{n+1} - u_m^n}{\tau} = \frac{1}{h} \left[k_{m+1/2}^n \frac{u_{m+1}^n - u_m^n}{h} - k_{m-1/2}^n \frac{u_m^n - u_{m-1}^n}{h} \right] + \\
 + \frac{1}{12} (f_{m-1}^n - 2f_m^n + f_{m+1}^n).
 \end{aligned}$$

Построенная разностная схема относится к классу компактных разностных схем — схем повышенного порядка аппроксимации на нерасширенном шаблоне.

12.6. Квазилинейное уравнение теплопроводности

Одномерное квазилинейное уравнение теплопроводности (диффузии) будем рассматривать в виде

$$\frac{\partial u}{\partial t} = \frac{\partial}{\partial x} \left[k(u) \frac{\partial u}{\partial x} \right] + f(u), \quad t \in [0, T], \quad x \in [0, X]. \quad (12.19)$$

Уравнения такого вида встречаются в теории горения, астрофизике, физике плазмы, теории сверхпроводимости Гинзбурга–Ландау, динамике популяций и других приложениях. Здесь $k(u) \geq 0$ при любых значениях u ; кроме того, $\int_0^u k(z) dz < +\infty$. Для глобальной ограниченности решения также требуется выполнение условия $\int_1^\infty \frac{dz}{f(z)} = \infty$. Для корректной постановки задачи необходимо задать одно начальное и два граничных условия. Основные постановки смешанных задач аналогичны постановкам для линейного уравнения.

Рассмотрим важный частный случай задачи. Начнем с физического примера. Спитцеровская теплопроводность в плазме определяется коэффициентом, который зависит от температуры по степенному закону $k = au^{5/2}$. Поэтому во многих практических задачах большой интерес представляют решения квазилинейного уравнения теплопроводности вида

$$\frac{\partial u}{\partial t} = \frac{\partial}{\partial x} au^\alpha \frac{\partial u}{\partial x}, \quad \alpha > 0. \quad (12.20)$$

Рассмотрим задачу с граничными условиями $u(+\infty, t) = 0$, $u(0, t) = ct^{1/\alpha}$, $u(x, 0) = 0$.

Уравнение (12.20) допускает решение в виде бегущей волны. В переменных бегущей волны $\zeta = x - vt$, где v — скорость волны, решение представляется в виде

$$u = u(\zeta) = u(x - vt).$$

Пусть $u \equiv 0$ при $\zeta = x - vt > 0$.

Подставив функцию в исходное дифференциальное уравнение в частных производных, получим обыкновенное дифференциальное уравнение

$$-vu'_\zeta = a(u^\alpha u'_\zeta)'.$$

Оно легко интегрируется по ζ один раз:

$$c - vu = au^\alpha u'_\zeta, \quad (12.21)$$

c — константа интегрирования. Выражение, стоящее в правой части (12.21), есть поток величины u , а само это уравнение является некоторым законом сохранения. В точке фронта $u = 0$ в силу непрерывности потока справа и слева от фронта должно выполняться $c - v \cdot 0 = 0$, отсюда следует $c = 0$.

Так как нас интересуют только нетривиальные решения задачи, то u не равно нулю тождественно, и можно разделить правую и левую части на u . Тогда получим

$$-v = au^{\alpha-1}u'_\zeta = \frac{a}{\alpha}(u^\alpha)'_\zeta,$$

откуда решение

$$u = \begin{cases} \left(\frac{\alpha v}{a}(-\zeta)\right)^{1/\alpha}, & \zeta \leq 0, \\ 0, & \zeta > 0. \end{cases} \quad (12.22)$$

Из граничного условия при $x = 0$ сразу имеем $v = ac^\alpha/\alpha$. То есть скорость распространения тепловой волны в этой задаче определяется законом нагрева границы области.

Построенное решение уравнения (12.20) непрерывно, но производная его разрывна при $\zeta = 0$. Поэтому данное решение является не классическим, а обобщенным, которое удовлетворяет интегральному закону сохранения. Решение (12.22) называется волной Зельдовича–Самарского–Соболя.

Уравнение (12.20) записано в *дивергентном* виде. Построение разностной схемы, исходя из такого вида квазилинейного уравнения теплопроводности, дает возможность получить *консервативную* разностную схему. Разностная схема называется консервативной, если разностный аналог закона сохранения, которому соответствует дифференциальное уравнение, выполнен для любой конечной подобласти в области решения. Отметим также, что идея использовать для построения разностной схемы «следствие» исходного уравнения

$$\frac{\partial u}{\partial t} = au^\alpha \frac{\partial^2 u}{\partial x^2} + au^{\alpha-1} \left(\frac{\partial u}{\partial x} \right)^2,$$

приводит к неверному результату. Действительно, решение уравнения не является дважды непрерывно дифференцируемой функцией (следовательно, не является решением в классическом смысле). Тем не менее, произведение $au^\alpha \frac{\partial u}{\partial x}$ — функция теплового потока — непрерывно дифференцируемо. Решение задачи существует в смысле обобщенного решения. По одной из гипотез (пока не нашедшей своего доказательства, но прекрасно работающей в практических расчетах), использование консервативных разностных схем является необходимым условием сходимости численного решения к обобщенному решению дифференциальной задачи.

Разностные схемы для квазилинейной задачи. Разностные схемы, построенные для линейной задачи, могут быть обобщены и на квазилинейный случай.

Приведем только формулы для внутренних точек для явной и неявной четырехточечных схем:

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{1}{h} \left[k_{m+1/2}^n \frac{u_{m+1}^n - u_m^n}{h} - k_{m-1/2}^n \frac{u_m^n - u_{m-1}^n}{h} \right] + f_m^n,$$

$$\frac{u_m^{n+1} - u_m^n}{\tau} = \frac{1}{h} \left[k_{m+1/2}^{n+1} \frac{u_{m+1}^{n+1} - u_m^{n+1}}{h} - k_{m-1/2}^{n+1} \frac{u_m^{n+1} - u_{m-1}^{n+1}}{h} \right] + f_m^{n+1}.$$

Вернемся к волне Самарского–Соболя–Зельдовича.

Самым простым способом решения такой задачи является неявная разностная схема с нелинейностью на нижнем слое

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{1}{h} \left[k_{m+1/2}^n \frac{y_{m+1}^{n+1} - y_m^{n+1}}{h} - k_{m-1/2}^n \frac{y_m^{n+1} - y_{m-1}^{n+1}}{h} \right] + f_m^n.$$

Такой способ учета нелинейности приводит к схемам, не эквивалентным полностью неявным схемам. Обычно использование таких схем приводит к неправильной скорости распространения тепловых волн. Схема с нелинейностью на верхнем слое:

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{1}{h} \left[k_{m+1/2}^{n+1} \frac{y_{m+1}^{n+1} - y_m^{n+1}}{h} - k_{m-1/2}^{n+1} \frac{y_m^{n+1} - y_{m-1}^{n+1}}{h} \right] + f_m^{n+1}.$$

Для реализации алгоритма прогонки проведем линеаризацию функции в правой части, т.е. используем итерационный метод Ньютона. Способ линеаризации сильно зависит от того, как именно аппроксимирован коэффициент теплопроводности в полужелой точке. Нелинейные коэффициенты для явной схемы могут быть вычислены различными способами, например следующими:

$$1) k_{m+1/2} = \frac{1}{2} (k(u_m^n) + k(u_{m+1}^n));$$

$$2) k_{m+1/2} = k\left(\frac{u_m^n + u_{m+1}^n}{2}\right);$$

$$3) k_{m+1/2} = k\left(\frac{2u_m^n u_{m+1}^n}{u_m^n + u_{m+1}^n}\right);$$

$$4) k_{m+1/2} = \frac{2k(u_m^n)k(u_{m+1}^n)}{k(u_m^n) + k(u_{m+1}^n)}.$$

Разностные схемы, построенные с такими «аппроксимациями» коэффициента теплопроводности, будут обладать различными свойствами. Например, при моделировании распространения волны Самарского–Соболя–Зельдовича по холодному фону предпочтительнее воспользоваться первой аппроксимацией, в то время как для распространения тепловой волны по нагретому фону оптимальной окажется аппроксимация 4. Отметим, что возможны и другие способы построения разностной схемы. Например, если можно найти первообразную коэффициента теплопроводности $K(u) = \int k(u) du$, то для решения уравнения теплопроводности может применяться схема

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{K(y_{m+1}^{n+1}) - 2K(y_m^{n+1}) + K(y_{m-1}^{n+1})}{h^2} + f_m^{n+1}.$$

Конечно, для решения системы нелинейных уравнений на верхнем слое следует использовать метод Ньютона.

12.7. Многомерное линейное уравнение теплопроводности

Численное решение даже простейших уравнений параболического типа сильно усложняется, если в задаче имеется в наличии более одного пространственного измерения. Условие устойчивости для многомерных схем накладывает столь жесткие ограничения на шаги по времени, что расчет по ним практически невозможен. Необходимо применять неявные схемы. Кроме того, сложности в численном решении задачи могут возрастать многократно, если расчетная область имеет сложную форму. Если расчетная область еще и невыпуклая, то в решении могут появиться особенности. Конечно, решение таких задач требует довольно сложных численных методов, описание которых выходит далеко за пределы вводного курса. Поэтому ограничимся только рассмотрением задачи с граничными условиями Дирихле или Неймана в области прямоугольной формы.

Начнем рассмотрение основных численных методов с двумерного случая. Простейшая явная разностная схема для численного решения двумерного уравнения теплопроводности

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2}$$

может быть получена путем замены производных разностями (далее мы обозначаем сеточную функцию той же буквой, что и решение дифференциального уравнения, в надежде, что читатель уже привык к тому, что это объекты разных функциональных пространств, и не будет их путать, а вот вторая пространственная переменная после x по традиции обозначается y)

$$\frac{u_{ml}^{n+1} - u_{ml}^n}{\tau} = \frac{u_{m-1,l}^n - 2u_{m,l}^n + u_{m+1,l}^n}{h_x^2} + \frac{u_{m,l-1}^n - 2u_{m,l}^n + u_{m,l+1}^n}{h_y^2},$$

или, в операторной форме,

$$\frac{u_{ml}^{n+1} - u_{ml}^n}{\tau} = \Lambda_1 u_{ml}^n + \Lambda_2 u_{ml}^n.$$

Здесь

$$\Lambda_1 u_{ml}^n = \frac{u_{m-1,l}^n - 2u_{m,l}^n + u_{m+1,l}^n}{h_x^2}, \quad \Lambda_2 u_{ml}^n = \frac{u_{m,l-1}^n - 2u_{m,l}^n + u_{m,l+1}^n}{h_y^2}.$$

Конечно, рассматривается начально-краевая задача, постановка которой приведена в начале главы. Исследование спектральной устойчивости этой схемы ($u_{ml}^n = \lambda^n e^{iam + i\beta l}$, $\alpha, \beta \in [0, \pi]$) приводит к следующему результату для спектра оператора послойного перехода:

$$\lambda(\alpha, \beta, \tau, h_x, h_y) = 1 - 4 \frac{\tau}{h_x^2} \sin^2 \frac{\alpha}{2} - 4 \frac{\tau}{h_y^2} \sin^2 \frac{\beta}{2},$$

откуда получаем условие устойчивости

$$\tau \leq \frac{1}{2(h_x^{-2} + h_y^{-2})}.$$

Это требование настолько жесткое, что решение задач большой размерности по явным схемам практически невозможно.

Рассмотрим теперь чисто неявную схему для численного решения двумерного уравнения теплопроводности

$$\frac{u_{ml}^{n+1} - u_{ml}^n}{\tau} = \Lambda_1 u_{ml}^{n+1} + \Lambda_2 u_{ml}^{n+1}.$$

При решении системы линейных уравнений на верхнем слое по времени возникает система линейных алгебраических уравнений

с разреженной (блочной) матрицей. В каждой строке матрицы от нуля отличны только пять элементов, но вид этой матрицы таков, что алгоритм пятиточечной прогонки в данном случае неприемлем. Хотя матрица системы является разреженной, обратная матрица будет полной.

Для неявной схемы исследование на устойчивость по спектральному признаку дает

$$\lambda = \frac{1}{1 + 4 \frac{\tau}{h_x^2} \sin^2 \frac{\alpha}{2} + 4 \frac{\tau}{h_y^2} \sin^2 \frac{\beta}{2}},$$

т.е. схема устойчива при любых сеточных параметрах. Но при практической реализации алгоритма нам необходимо потребовать, чтобы устойчивыми были все части алгоритма. При реализации неявной схемы возникнет необходимость найти решение системы линейных алгебраических уравнений большой размерности. Можно вычислить собственные числа матрицы этой системы и непосредственно убедиться, что система плохо обусловлена. Мы должны применять итерационный метод решения СЛАУ, причем потребовать, чтобы он был устойчивым. При реализации метода простых итераций условие устойчивости приведет к тем же ограничениям, что и при реализации явной схемы. Аналогичная ситуация складывается и для схемы Кранка–Никольсон при числе пространственных измерений не меньше двух.

Одним из способов решения проблемы построения устойчивых разностных схем, где накладываемые ограничения не столь существенны, является метод расщепления по направлениям. При таком подходе вместо разностного оператора, аппроксимирующего задачу, строится несколько более простых. Каждый из них задачу не аппроксимирует, но их композиция (т.е. последовательное применение этих операторов к сеточной функции) свойством аппроксимации обладает. Если мы сумеем построить такие операторы расщепления, в которых необходимо проводить прогонки только вдоль одной из координатных прямых, то получим семейство методов, которые называются *локально-одномерными*. Рассмотрим конкретный пример такой схемы — *метод дробных шагов* Н. Н. Яненко:

$$\frac{\tilde{u}_{ml} - u_{ml}^n}{\tau} = \Lambda_1 \tilde{u}_{ml},$$

$$\frac{u_{ml}^{n+1} - \tilde{u}_{ml}}{\tau} = \Lambda_2 u_{ml}^{n+1}.$$

Соответствующий пространственный шаблон схемы изображен на рис. 12.2.

Вычисления по разностной схеме ведутся в два этапа. Каждый из них не аппроксимирует дифференциальную задачу. Покажем, что композиция разностных операторов (т. е. два этапа, выполненные непосредственно один за другим) аппроксимируют исходную задачу, а величины с тильдой действительно относятся к промежуточному слою (тот самый дробный шаг).

Отметим, что на дробном шаге получается система линейных уравнений, матрица которой имеет строгое диагональное преобладание. Она может быть решена методом прогонки. С точки зрения математики это означает, что оператор, стоящий в левой части равенства

$$(\mathbf{E} - \tau \mathbf{\Lambda}_1) \tilde{u}_{ml} = u_{ml}^n,$$

обратим. Можно записать

$$\tilde{u}_{ml} = (\mathbf{E} - \tau \mathbf{\Lambda}_1)^{-1} u_{ml}^n.$$

Аналогично получим $u_{ml}^{n+1} = (\mathbf{E} - \tau \mathbf{\Lambda}_2)^{-1} \tilde{u}_{ml}$. С использованием двух последних равенств исключаем из рассмотрения величины с тильдой. Имеем $u_{ml}^{n+1} = (\mathbf{E} - \tau \mathbf{\Lambda}_2)^{-1} (\mathbf{E} - \tau \mathbf{\Lambda}_1)^{-1} u_{ml}^n$. Теперь обе части последнего равенства умножим на оператор, обратный действующему на известные величины на нижнем слое по времени. Получаем $(\mathbf{E} - \tau \mathbf{\Lambda}_1)(\mathbf{E} - \tau \mathbf{\Lambda}_2) u_{ml}^{n+1} = u_{ml}^n$. Отсюда сразу получим

$$u_{ml}^{n+1} - u_{ml}^n - \tau(\mathbf{\Lambda}_1 + \mathbf{\Lambda}_2) u_{ml}^{n+1} + \tau^2 \mathbf{\Lambda}_1 \mathbf{\Lambda}_2 u_{ml}^{n+1} = 0.$$

Последнее равенство, очевидно, представляет собой запись неявной разностной схемы с некой добавкой порядка погрешности аппроксимации. Такая добавка необходима для того, чтобы оператор послойного перехода мог быть разложен на множители, соответствующие каждому этапу вычислений. В этом случае говорят о *факторизации* оператора послойного перехода. Операторная добавка порядка погрешности аппроксимации делает факторизацию оператора послойного перехода возможной.




Рис. 12.2

Приведем исследование спектральной устойчивости для схемы переменных направлений. Рассмотрим переход с нижнего на верхний временной слой. В таком случае можно положить $u_{ml}^n = e^{iam+i\beta l}$; сомножитель λ^n опускаем, так как рассматривается один переход с n -го на $(n+1)$ -й слой в предположении, что известно решение на n -м слое (можно было бы написать $u_{ml}^n = Ce^{iam+i\beta l}$, где $C = \lambda^n$, но в этом нет смысла, так как C в дальнейших выкладках сократится).

Тогда на первом этапе получим $\tilde{u}_{ml} = \lambda_1 u_{ml}^n$, а на втором — $u_{ml}^{n+1} = \lambda_2 \tilde{u}_{ml} = (\lambda_1 \lambda_2) u_{ml}^n$. Вычисление λ_1 и λ_2 дает

$$\lambda_1 = \frac{1 - 4 \frac{\tau}{h_x^2} \sin^2 \frac{\alpha}{2}}{1 + 4 \frac{\tau}{h_y^2} \sin^2 \frac{\alpha}{2}}, \quad \lambda_2 = \frac{1 - 4 \frac{\tau}{h_x^2} \sin^2 \frac{\beta}{2}}{1 + 4 \frac{\tau}{h_y^2} \sin^2 \frac{\beta}{2}}.$$

Окончательно спектр оператора послыйного перехода представим в виде произведения спектров на каждом промежуточном этапе.

$$\lambda(\alpha, \beta, \tau, h_x, h_y) = \lambda_1 \lambda_2 = \frac{\left(1 - 4 \frac{\tau}{h_x^2} \sin^2 \frac{\alpha}{2}\right) \left(1 - 4 \frac{\tau}{h_x^2} \sin^2 \frac{\beta}{2}\right)}{\left(1 + 4 \frac{\tau}{h_y^2} \sin^2 \frac{\alpha}{2}\right) \left(1 + 4 \frac{\tau}{h_y^2} \sin^2 \frac{\beta}{2}\right)}.$$

Схема безусловно устойчива.

Для уравнения теплопроводности с тремя пространственными переменными

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2}$$

можно записать локально-одномерную схему дробных шагов

$$\begin{aligned} \frac{u_{mlp}^{n+1/3} - u_{mlp}^n}{\tau} &= \Lambda_1 u_{mlp}^{n+1/3}, \\ \frac{u_{mlp}^{n+2/3} - u_{mlp}^{n+1/3}}{\tau} &= \Lambda_2 u_{mlp}^{n+2/3}, \\ \frac{u_{mlp}^{n+1} - u_{mlp}^{n+2/3}}{\tau} &= \Lambda_3 u_{mlp}^{n+1}. \end{aligned}$$

и безусловно устойчивых:

$$\begin{aligned} u^* - u^n &= \frac{1}{2}\Lambda_1(u^* + u^n) + \Lambda_2(u^n) + \Lambda_3(u^n), \\ u^{**} - u^n &= \frac{1}{2}\Lambda_1(u^* + u^n) + \frac{1}{2}\Lambda_2(u^{**} + u^n) + \Lambda_3(u^n), \\ u^{n+1} - u^n &= \frac{1}{2}\Lambda_1(u^* + u^n) + \frac{1}{2}\Lambda_2(u^{**} + u^n) + \frac{1}{2}\Lambda_3(u^{n+1} + u^n). \end{aligned}$$

Верхние индексы * и ** обозначают промежуточные значения, координатные индексы i, j, k опущены во всех членах уравнений, Λ_i — компоненты разностного оператора теплопроводности. На каждом шаге метода возникает система линейных уравнений с трехдиагональной матрицей, решаемая методом прогонки. Схема Дугласа–Ганна безусловно устойчивая. В настоящее время это наиболее удачная из схем расщепления в трехмерном случае.

Схема «Классики». Для двумерного уравнения теплопроводности используется схема «классики». Это обобщение одномерной схемы hopscotch. Как и в схеме hopscotch, расчет осуществляется в два этапа:

$$\frac{u_{ml}^{n+1} - u_{ml}^n}{\tau} = \frac{u_{m-1,l}^n - 2u_{m,l}^{n+1} + u_{m+1,l}^n}{h_x^2} + \frac{u_{m,l-1}^n - 2u_{ml}^{n+1} + u_{m,l+1}^n}{h_y^2}$$

в случае, если $l + m + n$ — четное,

$$\frac{u_{ml}^{n+1} - u_{ml}^n}{\tau} = \frac{u_{m-1,l}^{n+1} - 2u_{m,l}^{n+1} + u_{m+1,l}^{n+1}}{h_x^2} + \frac{u_{m,l-1}^{n+1} - 2u_{ml}^{n+1} + u_{m,l+1}^{n+1}}{h_y^2}$$

в случае, если $l + m + n$ — нечетное.

Разностная схема будет безусловно устойчива по спектральному признаку. Схема явная, условно-аппроксимирующая задачу. «Перепрыгивание» узлов позволяет чередовать на соседних слоях знаки тех слагаемых в невязке, которые ответственны за условный характер аппроксимации схемы. Это позволяет надеяться на то, что на соседних слоях эта часть погрешности аппроксимации будет частично скомпенсирована.

12.8. Примеры решения задач

1. С помощью интегро-интерполяционного метода получите схему, аппроксимирующую квазилинейное стационарное уравнение

теплопроводности в плазме

$$-\frac{\partial}{\partial x}\left(u^{5/2}\frac{\partial u}{\partial x}\right) - \frac{\partial}{\partial y}\left(u^{5/2}\frac{\partial u}{\partial y}\right) = f(x, y)$$

на равномерной пространственной сетке, состоящей из центров прямоугольников (рис. 12.4).




Рис. 12.4

Решение. Пусть a , b — стороны прямоугольника. Уравнение теплопроводности можно записать в виде двух уравнений для температуры и потока тепла

$$\operatorname{div} \mathbf{W} + ku = f(x, y), \quad \mathbf{W} = -u^{5/2} \operatorname{grad} u.$$

Интегрируем первое уравнение по ячейке. Использование теоремы Остроградского–Гаусса дает

$$a \sum_{k=1,3} W_n^k + b \sum_{k=2,4} W_n^k + ku_{nm}ab = Q_{mn}ab,$$

где W_n^k — нормальная проекция потока к k -му ребру ячейки (их четыре) с внешней нормалью $\mathbf{n}^k$.

Из второго уравнения имеем:

$$\mathbf{W} = -u^{5/2} \operatorname{grad} u, \quad W_n^k = -u^{5/2} (\operatorname{grad} u, \mathbf{n}^k) = -u^{5/2} \frac{\partial u}{\partial \mathbf{n}^k}.$$

Нормаль в примере всегда направлена между центрами ячеек, от центра рассматриваемой ячейки к центру ячейки соседней. В этом нелинейном примере аппроксимировать коэффициент теплопроводности на ребре со вторым порядком аппроксимации можно разными способами, и все они правильные: степень полусуммы (по мнению А. А. Самарского, предпочтительный вариант), полусумма степеней, полусумма обратных величин к коэффициенту теплопроводности в центрах ячейки, и даже можно степень убрать

под производную. Здесь приведем формулу только для первого варианта из перечисленных:

$$W_n^{mn \rightarrow mn+1} = - \left(\frac{u_{mn+1} + u_{mn}}{2} \right)^{\frac{5}{2}} \frac{u_{mn+1} - u_{mn}}{a}.$$

Выражения для аппроксимации потоков для всех остальных ячеек получаются аналогично. Окончательно имеем

$$\begin{aligned} & -a \left(\left(\frac{u_{mn+1} + u_{mn}}{2} \right)^{\frac{5}{2}} \frac{u_{mn+1} - u_{mn}}{b} + \left(\frac{u_{mn-1} + u_{mn}}{2} \right)^{\frac{5}{2}} \frac{u_{mn-1} - u_{mn}}{b} \right) - \\ & -b \left(\left(\frac{u_{m+1n} + u_{mn}}{2} \right)^{\frac{5}{2}} \frac{u_{m+1n} - u_{mn}}{a} + \left(\frac{u_{m-1n} + u_{mn}}{2} \right)^{\frac{5}{2}} \frac{u_{m-1n} - u_{mn}}{a} \right) + \\ & + k u_{nm} ab = Q_{mn} ab. \end{aligned}$$

Разделив полученное разностное уравнение на объем ячейки ab , можно с помощью непосредственной проверки убедиться, что разностное уравнение аппроксимирует производные потоков.

2. Исследовать на аппроксимацию и устойчивость *схему Саульева* бегущего счета:

$$\frac{y_m^n - y_m^{n-1}}{\tau} = a \frac{y_{m-1}^n - (y_m^n + y_m^{n-1}) - y_{m+1}^{n-1}}{h^2}$$

— четные слои, счет слева направо;

$$\frac{y_m^{n+1} - y_m^n}{\tau} = a \frac{y_{m-1}^n - (y_m^n + y_m^{n+1}) + y_{m+1}^{n+1}}{h^2}$$

— нечетные слои, счет справа налево;
с шаблоном, изображенным на рис. 12.5.




Рис. 12.5

Решение. Путем подстановки решения в виде $y_m^n = \lambda^n e^{iam}$ несложно проверить, что схема безусловно устойчива.

Схема Саульева (схема бегущего счета) строится следующим образом. На нечетных шагах по времени используется несимметричная схема

$$\frac{y_m^n - y_m^{n-1}}{\tau} = k \frac{y_{m-1}^n - (y_m^n + y_m^{n-1}) + y_{m+1}^{n-1}}{h^2}.$$

Расчет ведется слева направо. Конечно, решение задачи Коши с помощью такой схемы даже формально невозможно. Но при расчете начально-краевой задачи разностная схема становится явной. При следующем переходе используется схема

$$\frac{y_m^{n+1} - y_m^n}{\tau} = k \frac{y_{m-1}^n - (y_m^n + y_m^{n+1}) + y_{m+1}^{n+1}}{h^2}.$$

Расчет ведется справа налево.




Рис. 12.6

Шаблон разностной схемы и направление расчетов показаны на рис. 12.6. Исследуем некоторые свойства метода Саульева. Для исследования на устойчивость используем спектральный признак. Подставив решение в виде $y_m^n = \lambda^n e^{iam}$ в разностные уравнения каждого этапа, несложно проверить, что схема безусловно устойчива.

Для исследования аппроксимации схемы Саульева воспользуемся методом операторной аппроксимации. Введем в рассмотрение два разностных оператора

$$\mathbf{L}_1 y_m = \frac{y_{m-1} - y_m}{h^2}, \quad \mathbf{L}_2 y_m = \frac{y_{m+1} - y_m}{h^2}.$$

Очевидно, что оператор второй разности можно представить как сумму этих операторов:

$$\Lambda y_m = \mathbf{L}_1 y_m + \mathbf{L}_2 y_m = \frac{y_{m-1} - 2y_m + y_{m+1}}{h^2}.$$

Первый этап схемы Саульева запишем в операторной форме как

$$\frac{y_m^n - y_m^{n-1}}{\tau} = k(\mathbf{L}_1 y_m^n + \mathbf{L}_2 y_m^{n-1}).$$

Эквивалентная форма записи есть

$$(\mathbf{E} - \tau k \mathbf{L}_1) y_m^n = (\mathbf{E} + \tau k \mathbf{L}_2) y_m^{n-1}.$$

Оператор, стоящий в левой части последнего равенства, обратим, решение системы уравнений «бегущим счетом» эквивалентно обращению этого оператора. Тогда мы можем выразить отсюда значение

$$y_m^n = (\mathbf{E} - \tau k \mathbf{L}_1)^{-1} (\mathbf{E} + \tau k \mathbf{L}_2) y_m^{n-1}.$$

Для второго этапа метода Саульева имеем

$$(\mathbf{E} - \tau k \mathbf{L}_2) y_m^{n+1} = (\mathbf{E} + \tau k \mathbf{L}_1) y_m^n.$$

С учетом первого этапа

$$(\mathbf{E} - \tau k \mathbf{L}_2) y_m^{n+1} = (\mathbf{E} + \tau k \mathbf{L}_1) (\mathbf{E} - \tau k \mathbf{L}_1)^{-1} (\mathbf{E} + \tau k \mathbf{L}_2) y_m^{n-1}.$$

Отсюда сразу следует симметричная форма записи операторного уравнения

$$(\mathbf{E} + \tau k \mathbf{L}_1)^{-1} (\mathbf{E} - \tau k \mathbf{L}_2) y_m^{n+1} = (\mathbf{E} - \tau k \mathbf{L}_1)^{-1} (\mathbf{E} + \tau k \mathbf{L}_2) y_m^{n-1}.$$

Если параметр τ достаточно мал, то справедливо равенство $(\mathbf{E} + \tau a^2 \mathbf{L}_1)^{-1} = \mathbf{E} - \tau a^2 \mathbf{L}_1 + O(\tau^2)$. С точностью до членов второго порядка по шагу по времени имеем

$$\begin{aligned} (\mathbf{E} - \tau k \mathbf{L}_1 - \tau k \mathbf{L}_2 + \tau^2 k^2 \mathbf{L}_1 \mathbf{L}_2) y_m^{n+1} &= \\ &= (\mathbf{E} + \tau k \mathbf{L}_1 + \tau k \mathbf{L}_2 + \tau^2 k^2 \mathbf{L}_1 \mathbf{L}_2) y_m^{n-1}. \end{aligned}$$

Это равенство можно переписать в виде

$$y_m^{n+1} - y_m^{n-1} = \tau k (\mathbf{L}_1 + \mathbf{L}_2) (y_m^{n+1} + y_m^{n-1}) + \tau^2 k^2 \mathbf{L}_1 \mathbf{L}_2 (y_m^{n-1} - y_m^{n+1}).$$

Хотя последние операторные слагаемые в этом равенстве действуют на сеточную функцию на разных слоях и только частично компенсируют друг друга, нетрудно убедиться, что остальные операторные слагаемые аппроксимируют уравнение теплопроводности со вторым порядком по времени и пространству. Наличие некомпенсированных слагаемых, имеющих порядок $O(\tau^2/h^4)$, говорит об условной аппроксимации разностной схемы.

Схема Саульева допускает значительное улучшение. Достаточно только вычислить значения функции в рамках перехода с данного слоя на следующий два раза — бегущим счетом слева направо и бегущим счетом справа налево — и усреднить результаты. Модифицировав приведенное выше исследование, получим, что такая схема имеет второй порядок аппроксимации как по пространственной переменной, так и по времени.

Библиографический комментарий к Лекции 12

Численным методам решения уравнений параболического типа посвящена обширная литература. Отметим только две книги. В [2] дано блестящее обоснование применения неявных разностных схем для решения нелинейных задач. Результаты по построению высокоточных монотонных схем в пространствах неопределенных коэффициентов подробно описаны в [43].

При проведении практических занятий по теме рекомендуем использовать материалы пособия [40].

ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ УРАВНЕНИЙ В ЧАСТНЫХ ПРОИЗВОДНЫХ ГИПЕРБОЛИЧЕСКОГО ТИПА

В лекции дается понятие о простейших разностных схемах для решения линейного уравнения переноса. Приводится вид некоторых часто употребляемых схем. Обсуждаются способы конструирования гибридных разностных схем. Описаны вопросы обобщения на квазилинейный случай. Дается первоначальное представление о способах регуляризации решений с большими градиентами. Вводится понятие схем с уменьшением полной вариации (TVD). Рассматриваются основные идеи метода конструирования разностных схем в пространстве неопределенных коэффициентов.

К л ю ч е в ы е с л о в а: линейное уравнение переноса, характеристика, квазилинейное уравнение переноса, дивергентная форма, консервативная разностная схема, регуляризация, сглаживание, схемная вязкость, антидиффузия, гибридные схемы, TVD-схемы, пространство неопределенных коэффициентов, первое дифференциальное приближение.

13.1. Простейшее линейное уравнение переноса

Рассмотрим простейший пример уравнений в частных производных. Пусть в некотором объеме движущейся жидкости находится пассивная примесь, т. е. такая, наличие которой не меняет принципиально характер движения. Например, это может быть маркер — краска, чернила или мелкие частицы, которые специально добавлены в жидкость для визуализации течений. Тогда изменение концентрации примеси в любом сколь угодно малом объеме равно потоку примеси через границы объема в единицу времени (закон сохранения массы), и можно записать, устремляя рассматриваемый объем к нулю,

$$\frac{\partial u}{\partial t} = -\operatorname{div}(u\mathbf{v}),$$

где u — концентрация пассивной примеси, $\mathbf{v}$ — скорость течения жидкости. Пусть жидкость несжимаема и $\operatorname{div} \mathbf{v} = 0$. Тогда из двух

предыдущих равенств сразу следует уравнение

$$\frac{\partial u}{\partial t} + \mathbf{v} \text{grad } u = 0. \quad (13.1)$$

Равенство (13.1) будем в дальнейшем называть уравнением переноса пассивной примеси, или линейным уравнением переноса. Кроме (13.1), будем рассматривать и одномерное уравнение переноса

$$\frac{\partial u}{\partial t} + a \frac{\partial u}{\partial x} = 0, \quad (13.2)$$

а также неоднородное уравнение переноса

$$\frac{\partial u}{\partial t} + a \frac{\partial u}{\partial x} = f, \quad (13.3)$$

где f — заданная функция, играющая роль источника (стока).

Неоднородным уравнением переноса описываются системы, в которых пассивная примесь может вступать, например, в химические реакции. Если уравнения переноса описывают распространение планктона, то в правой части будет стоять функция, описывающая размножение планктона и его пассивную утечку (например, за счет его поедания рыбами).

Уравнения вида (13.1), (13.2), (13.3) традиционно рассматриваются в курсах обыкновенных дифференциальных уравнений.

Причина этого кроется в следующем обстоятельстве. Рассмотрим систему ОДУ

$$\dot{\mathbf{x}} = \mathbf{v}, \quad (13.4)$$

соответствующую (13.1). Это — уравнение характеристик для линейного уравнения переноса. Если функция u является *первым интегралом* (13.4), то она является решением (13.1). Иными словами, вдоль характеристики решение однородного уравнения переноса сохраняет постоянное значение.

Для корректной постановки задач для линейного уравнения переноса начальные и граничные условия необходимо ставить на некоторой гиперповерхности. Так как решение уравнений переноса распространяется вдоль характеристик, то начальная гиперповерхность должна быть трансверсальной ко всем характеристикам (не иметь точек касания с характеристиками). Кроме того, если для однородного уравнения переноса какая-либо характеристика имеет с начальной гиперповерхностью более одной общей точки, то значения начальной функции во всех этих точках должны быть равны между собой. Все эти условия очевидны, если вспомнить физический смысл уравнения переноса.

Отметим, что наличие характеристик можно считать условием того, что система имеет гиперболический тип. Так, если система уравнений произвольного порядка n имеет n действительных характеристик, будем называть ее гиперболической. Таким образом, *линейное уравнение переноса имеет гиперболический тип.*

13.2. Линейные системы гиперболического типа с постоянными коэффициентами

От простейшего линейного уравнения переноса с постоянными коэффициентами можно перейти к рассмотрению гиперболических систем уравнений в частных производных с постоянными коэффициентами вида

$$\frac{\partial \mathbf{u}}{\partial t} + \mathbf{A} \frac{\partial \mathbf{u}}{\partial x} = \mathbf{F}, \quad (13.5)$$

где $\mathbf{u}$ — искомый вектор решения, $\mathbf{A}$ — матрица с постоянными коэффициентами, $\mathbf{F}$ — вектор правой части.

Определение 13.1. Система (13.5) будет иметь гиперболический тип, если спектр матрицы $\mathbf{A}$ действительный. Если среди собственных чисел матрицы $\mathbf{A}$ не будет нулей, то система называется строго гиперболической.

Для построения решения этой системы в ограниченной пространственной области необходимо корректно поставить смешанную начально-краевую задачу. Начальные условия должны ставиться для всех компонент вектора $\mathbf{u}$. Проще всего оценить корректность постановки краевых условий задачи переходом к *инвариантам Римана*.

Без ограничения общности считаем, что начально-краевая задача рассматривается в области $\Omega = \{x \in [0; 1] \mid t \in [0; T]\}$.

Пусть $\{\lambda_i, \mathbf{w}_k^T\}$ — полный набор собственных значений и *левых* собственных векторов матрицы $\mathbf{A}$. Напомним, что матрица системы имеет действительные собственные числа, но при этом не обязательно является самосопряженной. В этом случае каждому собственному числу будет соответствовать собственный вектор-столбец (правый собственный вектор) и собственный вектор-строка (левый собственный вектор). Умножим систему уравнений

(13.5) слева на собственный вектор $\mathbf{w}_k^T$:

$$\mathbf{w}_k^T \frac{\partial \mathbf{u}}{\partial t} + \mathbf{w}_k^T \mathbf{A} \frac{\partial \mathbf{u}}{\partial x} = \mathbf{w}_k^T \mathbf{F},$$

воспользовавшись свойством левого собственного вектора, будем иметь

$$\frac{\partial(\mathbf{w}_k^T, \mathbf{u})}{\partial t} + \lambda_k \frac{\partial(\mathbf{w}_k^T, \mathbf{u})}{\partial x} = (\mathbf{w}_k^T, \mathbf{F}).$$

Таким образом, мы видим, что система уравнений распадается на отдельные уравнения переноса для комбинаций переменных, называемых *инвариантами Римана*

$$R_k = (\mathbf{w}_k^T, \mathbf{u}).$$

Каждый инвариант R_k переносится со своей скоростью переноса λ_k .

Переменные u , в которых формулируется система, иногда называются естественными переменными.

Вместо системы уравнений, в которой все переменные связаны между собой, мы получили уравнения для отдельных инвариантов вида

$$\frac{\partial R_k}{\partial t} + \lambda_k \frac{\partial R_k}{\partial x} = f_k.$$

Если скорость переноса $\lambda_k > 0$, то соответствующее граничное условие должно быть поставлено на левой границе расчетной области, а если $\lambda_k < 0$, то на правой. Краевое условие не обязательно должно ставиться непосредственно для комбинации переменных, входящих в инвариант R_k .

Часто именно инварианты Римана служат основными расчетными величинами при решении систем гиперболического типа. По ним всегда однозначно восстанавливаются естественные переменные.

Для корректной постановки задачи необходимо потребовать, чтобы система уравнений, составленная из собственно граничных условий на данной границе, и инвариантов Римана, являющихся выходящими (из расчетной области), была бы невырожденной.

Поясним это. Пусть система (13.5) строго гиперболическая и у нее l собственных значений положительны, тогда $N - l$ значений отрицательны. Зададим на левой границе l условий вида

$$a_{k,1}u_1(0, t) + a_{k,2}u_2(0, t) + \dots + a_{k,N}u_N(0, t) = g_k(t),$$

или

$$(\mathbf{a}_k, \mathbf{u}) = g_k.$$

Эти условия на левой границе заданы. Кроме того, при решении системы вдоль направления характеристик на левую границу будут принесены значения тех инвариантов Римана, которые соответствуют отрицательным собственным числам. Для корректности постановки необходимо однозначно восстановить все естественные переменные в точке левой границы. Тогда система линейных уравнений

$$(\mathbf{a}_k, \mathbf{u}) = g_k, \quad k = 1, 2, \dots, l;$$

$$(\mathbf{w}_k^T, \mathbf{u}) = R_k, \quad k = l + 1, \dots, N$$

должна быть однозначно разрешимой при любой правой части. Для этого необходимо потребовать

$$\det \begin{pmatrix} \mathbf{a}_1 \\ \dots \\ \mathbf{a}_l \\ \mathbf{w}_{l+1}^T \\ \dots \\ \mathbf{w}_N^T \end{pmatrix} \neq 0.$$

Полученное условие называется условием совместности на левой границе.

Аналогично, рассматривая на левой границе систему граничных условий $(\mathbf{b}_k, \mathbf{u}) = g_k$, $k = l + 1, \dots, N$ и значения приносимых на правую границу значений инвариантов Римана $(\mathbf{w}_k^T, \mathbf{u}) = R_k$, $k = 1, \dots, l$, приходим к условиям совместности

$$\det \begin{pmatrix} \mathbf{w}_1^T \\ \dots \\ \mathbf{w}_l^T \\ \mathbf{b}_{l+1} \\ \dots \\ \mathbf{b}_N \end{pmatrix} \neq 0.$$

От знакомого по курсу уравнений математической физики волнового уравнения можно перейти к системе гиперболического типа — акустической системе. Как осуществляется такой переход, см. решение Задачи 7 в конце данной лекции.

Понятие гиперболической системы уравнений в частных производных можно обобщить и для линейных систем с переменными коэффициентами. Так, если в задаче

$$\frac{\partial \mathbf{u}}{\partial t} + \mathbf{A}(x, t) \frac{\partial \mathbf{u}}{\partial x} = \mathbf{F}$$

корни уравнения $\det(\mathbf{A}(x, t) - \lambda \mathbf{E}) = 0$ действительны при любых значениях независимых переменных, то система также расщепляется на отдельные уравнения; качественно случай ничем не отличается от рассмотренного выше случая с постоянными коэффициентами.

Рассмотренные свойства — наличие действительных характеристик — существенны и для некоторых нелинейных задач, например для системы Эйлера уравнений газовой динамики. Для таких систем также обобщается понятие гиперболичности. Рассмотрение таких систем уравнений и численных методов их решения находится за рамками нашего первоначального курса.

13.3. Численные методы решения уравнений в частных производных гиперболического типа на примере уравнения переноса

Двухслойные разностные схемы. Линейное одномерное уравнение переноса, как отмечалось выше, имеет вид (13.2):

$$\frac{\partial u}{\partial t} + a \frac{\partial u}{\partial x} = 0.$$

Наряду с линейным уравнением переноса, в следующем параграфе будем рассматривать также *квазилинейные* уравнения. Простейшее квазилинейное уравнение гиперболического типа — уравнение Хопфа

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} = 0. \quad (13.6)$$

Оно интересно тем, что моделирует уравнения газовой динамики. Запишем его в двух формах:

$$\frac{\partial u}{\partial t} + \frac{\partial f}{\partial x} = 0, \quad f = \frac{u^2}{2}. \quad (13.7)$$

Это *дивергентная* форма записи. Отметим, что дивергентная форма отражает наличие некоторого закона сохранения. В случае уравнения Хопфа это закон сохранения импульса.

Другая форма

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} = 0, \quad 0 \leq t \leq T, \quad 0 \leq x < \infty.$$

Эту форму записи иногда в дальнейшем будем называть *характеристической*.

Отметим, что для линейных уравнений с постоянными коэффициентами нет принципиальной разницы между характеристической и дивергентной формами. Для уравнений с переменными коэффициентами эта разница появляется даже в линейном случае. При использовании различных форм записи для построения разностных схем возникают численные методы с разными свойствами.

Для корректной постановки начальной и краевой задач необходимо корректно задать начальные и граничные условия. Для рассматриваемых ниже задач они имеют вид

$$\begin{aligned} u(0, x) &= \varphi_1(x), \quad 0 \leq x < \infty; \\ u(t, 0) &= \varphi_2(t), \quad 0 \leq t \leq T. \end{aligned}$$

Положим (для определенности) в уравнении переноса $a > 0$. Решением задачи Коши для уравнения (13.3) является «бегущая волна»:

$$u(t, x) = \Psi(x - at), \quad a = \text{const} > 0,$$

где a — скорость переноса, а функция $\Psi(x - at)$ определяется из начальных или граничных условий. Характеристики уравнения имеют вид $x - at = \text{const}$ и при постоянной скорости переноса являются прямыми линиями. Решение однородного уравнения (13.2), как отмечено выше, остается постоянным вдоль характеристики, поэтому начальные и граничные условия переносятся вдоль этих линий. В случае неоднородного уравнения вдоль характеристики оно превращается в обыкновенное дифференциальное уравнение.

Приведем вид двухпараметрического семейства двухслойных разностных схем первого и второго порядков аппроксимации:

$$\frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{\Delta^+ + \Delta^-}{2h} u_m^{(\gamma)} = \frac{h^2 q}{2\tau} \frac{\Delta^+ \Delta^-}{h^2} u_m^{(\gamma)}, \quad (13.8)$$

где применены обозначения

$$u_m^{(\gamma)} = \gamma u_m^{n+1} + (1 - \gamma) u_m^n,$$

$$\Delta^+ u_m = u_{m+1} - u_m, \quad \Delta^- u_m = u_m - u_{m-1},$$

$$\Delta = (\Delta^+ + \Delta^-) u_m = \Delta^+ u_m + \Delta^- u_m = u_{m+1} - u_{m-1},$$

$$\begin{aligned} (\Delta^+ \Delta^-) u_m &= \Delta^+ (\Delta^- u_m) = \Delta^+ (u_m - u_{m-1}) = \\ &= \Delta^+ u_m - \Delta^+ u_{m-1} = u_{m+1} - 2u_m + u_{m-1}. \end{aligned}$$

Рассмотрим теперь конкретные разностные схемы решения модельного линейного уравнения переноса.

Схема П. Лакса (трехточечная схема) получается при $\gamma = 0$, $q = 1$. Ее порядок аппроксимации $O(\tau + h^2 + h^2/\tau)$. Здесь и далее порядок аппроксимации приводится для модельного уравнения переноса с постоянными коэффициентами. В случае переменных коэффициентов в схему надо внести необходимые изменения.

Схема является *условно устойчивой*,

т.е. при выполнении условия Куранта $\sigma = a\tau/h \leq 1$ она устойчива. Отметим здесь, что величина σ играет определяющую роль при исследовании разностных схем на аппроксимацию и устойчивость. Она называется *числом Куранта*. Исследование разностной схемы на устойчивость для линейного эволюционного уравнения с постоянными коэффициентами можно провести с использованием *спектрального признака* (фон Неймана).

Приведем разностные уравнения для схемы Лакса во внутренних точках расчетной области:

$$\frac{u_m^{n+1} - 0.5(u_{m+1}^n + u_{m-1}^n)}{\tau} + a \frac{u_{m+1}^n - u_{m-1}^n}{2h} = 0.$$

На рис. 13.1 приведен шаблон для схемы Лакса. Напомним, что шаблоном разностной схемы называется конфигурация узлов, значения сеточной функции в которых определяют вид разностных уравнений во внутренних (не приграничных) точках сетки. Как правило, на рисунках с изображениями шаблонов точки, участвующие в вычислении производных, соединяются линиями.




Рис. 13.1

Схема Куранта–Изаксона–Риса (КИР), которую иногда также связывают с именем С. К. Годунова, получается при $\gamma = 0$, $q = \sigma \operatorname{sign} a$. Напомним, что число Куранта $\sigma = a\tau/h$. Ее порядок аппроксимации $O(\tau + h)$. Схема КИР условно устойчива, т. е. при выполнении условия Куранта $\sigma = |a|\tau/h \leq 1$ она устойчива.

Приведем разностные уравнения для схемы Куранта–Изаксона–Риса во внутренних точках расчетной области:

$$\begin{aligned} \frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_m^n - u_{m-1}^n}{h} &= 0, \quad a > 0, \\ \frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_{m+1}^n - u_m^n}{h} &= 0, \quad a < 0. \end{aligned}$$

Шаблоны схемы КИР показаны на рис. 13.2.




Рис. 13.2. Шаблоны схемы с разностью против потока

Эти схемы, имеющие также название «схемы с разностями против потока» (в англоязычной литературе — *upwind*), могут быть записаны в виде

$$u_m^{n+1} = u_m^n - \sigma \begin{cases} u_{m+1}^n - u_m^n, & a < 0, \\ u_m^n - u_{m-1}^n, & a \geq 0. \end{cases}$$

где $\sigma = |a|\tau/h$ — число Куранта.

Их преимущество состоит в более точном учете области зависимости решения. Если ввести обозначения

$$\begin{aligned} a^+ &= \frac{1}{2}(a + |a|) = \begin{cases} a, & a \geq 0, \\ 0, & a < 0, \end{cases} \\ a^- &= \frac{1}{2}(a - |a|) = \begin{cases} 0, & a \geq 0, \\ a, & a < 0, \end{cases} \end{aligned}$$

то обе схемы можно записать в следующих формах:

$$u_m^{n+1} = u_m^n - \frac{\tau}{h} \left[a^+(u_m^n - u_{m-1}^n) + a^-(u_{m+1}^n - u_m^n) \right];$$

$$u_m^{n+1} = u_m^n - \frac{\tau}{h} (f_{m+1/2}^n - f_{m-1/2}^n),$$

$$f_{m+1/2}^n = \frac{1}{2} \left[a(u_{m+1}^n + u_m^n) - |a|(u_{m+1}^n - u_m^n) \right],$$

$$f_{m-1/2}^n = \frac{1}{2} \left[a(u_m^n + u_{m-1}^n) - |a|(u_m^n - u_{m-1}^n) \right]$$

— потоковая форма разностного уравнения;

$$u_m^{n+1} = u_m^n - \frac{1}{2} \sigma (u_{m+1}^n - u_{m-1}^n) + \frac{|\sigma|}{2} (u_{m+1}^n - 2u_m^n + u_{m-1}^n)$$

— здесь явно выделен член со второй разностью, придающий устойчивость схеме;

$$\Delta_\tau u_m^n = \frac{|\sigma| - \sigma}{2} \Delta^+ u_m^n - \frac{|\sigma| + \sigma}{2} \Delta^- u_m^n, \quad \sigma = \frac{a\tau}{h},$$

— уравнение в конечных приращениях. Здесь

$$\Delta_\tau u_m^n = \frac{u_m^{n+1} - u_m^n}{\tau}.$$

Рассмотрим метод неопределенных коэффициентов для построения разностной схемы «правый уголок» первого порядка аппроксимации для уравнения переноса

$$\frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} = \varphi(t, x), \quad \text{т. е. при } a = -1.$$

Схему можно представить в виде

$$L_\tau u^\tau = b_1 u_m^{n+1} + b_2 u_m^n + b_3 u_{m+1}^n = \varphi_m^n,$$

$$b_1 = \tau^{-1}, \quad b_2 = h^{-1} - \tau^{-1}, \quad b_3 = -h^{-1}.$$

Схема Куранта–Изаксона–Риса тесно связана с численными методами характеристик. Дадим краткое описание идеи таких методов.

Построим характеристику, проходящую через узел (t_{n+1}, x_m) , значение в котором необходимо определить, и пересекающую

слой t_n в точке $x' = x_m - a\tau$. Для определенности считаем, что скорость переноса σ положительна.

Проведя линейную интерполяцию между узлами x_{m-1} и x_m на нижнем слое по времени, получим

$$\begin{aligned} u_m(x') &= u_{m-1} \frac{x_m - x'}{h} + u_m \frac{x' - x_{m-1}}{h} = \\ &= \frac{a\tau}{h} u_{m-1} + \left(1 - \frac{a\tau}{h}\right) u_m = \sigma u_{m-1} - (1 - \sigma) u_m. \end{aligned}$$

Далее перенесем вдоль характеристики значение $u_n(x')$ без изменения на верхний слой t_{n+1} , т.е. положим $u_m^{n+1} = u_n(x')$. Последнее значение естественно считать приближенным решением однородного уравнения переноса. В таком случае

$$u_m^{n+1} = (1 - \sigma) u_m + \sigma u_{m-1},$$

или, переходя от числа Куранта снова к сеточным параметрам,

$$\frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_m^n - u_{m-1}^n}{h} = 0,$$

т.е. другим способом мы пришли к уже известной схеме «левый уголок», устойчивой при $\sigma = a\tau/h \leq 1$, $a > 0$. При $\sigma > 1$ точка пересечения характеристики, выходящей из узла (t_{n+1}, x_m) , с n -м слоем по времени расположена левее узла (t_n, x_{m-1}) . Таким образом, для отыскания решения u_m^{n+1} используется уже не интерполяция, а экстраполяция, которая оказывается неустойчивой.




Рис. 13.3

Неустойчивость схемы «правый уголок» при $a > 0$ также очевидна. Для доказательства этого можно использовать либо спектральный признак, либо условие Куранта, Фридрихса и Леви. Аналогичные рассуждения можно провести и для случая $a < 0$ и схемы «правый уголок».

Неустойчивая *четырёхточечная схема* получается при $\gamma = 0$, $q = 1$, ее порядок аппроксимации $O(\tau + h^2)$. Сеточные уравнения для разностной схемы будут иметь следующий вид:

$$\frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_{m+1}^n - u_{m-1}^n}{2h} = 0.$$

Шаблон схемы показан на 13.3.

Схема Лакса–Вендроффа возникает при $\gamma = 0$, $q = \sigma$. Порядок аппроксимации схемы Лакса–Вендроффа есть $O(\tau^2 + h^2)$. Схема устойчива при выполнении условия Куранта $\sigma = a\tau/h \leq 1$. Эту схему можно получить либо методом неопределенных коэффициентов, либо путем более точного учета главного члена погрешности аппроксимации.

Рассмотрим процесс вывода схемы Лакса–Вендроффа подробнее. Проводя исследование предыдущей четырехточечной схемы на аппроксимацию (а исследование это довольно элементарно и сводится к разложению функции проекции на сетку точного решения дифференциальной задачи в ряд Тейлора), получим для главного члена погрешности

$$\frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_{m+1}^n - u_{m-1}^n}{2h} = \frac{\partial u}{\partial t} + a \frac{\partial u}{\partial x} \Big|_{t_n, x_m} + a^2 \frac{\tau}{2} \frac{\partial^2 u}{\partial x^2} + O(\tau^2 + h^2).$$

При выводе выражения для главного члена погрешности аппроксимации использовано следствие исходного дифференциального уравнения переноса

$$\frac{\partial^2 u}{\partial t^2} = a^2 \frac{\partial^2 u}{\partial x^2},$$

которое получается путем дифференцирования исходного уравнения (13.3) сначала по времени t , затем по координате x и вычитанием одно из другого получившихся дифференциальных следствий начального уравнения.

Далее, заменяя вторую производную во втором слагаемом в правой части с точностью до $O(h^2)$, получим новую разностную схему, аппроксимирующую исходное дифференциальное уравнение с точностью $O(\tau^2 + h^2)$. Сеточные уравнения для схемы Лакса–Вендроффа во внутренних узлах расчетных сеток есть

$$\frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_{m+1}^n - u_{m-1}^n}{2h} - a^2 \frac{\tau}{2} \frac{u_{m-1}^n - 2u_m^n + u_{m+1}^n}{h^2} = 0.$$

Неявная шеститочечная схема возникает при $q = 0$; при $\gamma = 0.5$ ее порядок аппроксимации $O(\tau^2 + h^2)$, при $\gamma = 1$ порядок аппроксимации $O(\tau + h^2)$.

Неявная нецентральная схема $q = \sigma \operatorname{sign} a$. При $\gamma = 0.5$ порядок аппроксимации $O(\tau^2 + h)$. При $\gamma = 1$ порядок аппроксимации $O(\tau + h)$.

Последние две разностные схемы носят названия схем Карлсона и Ландау–Меймана–Халатникова соответственно.

Монотонность. Начальный монотонный профиль точного решения однородного линейного уравнения переноса с постоянными коэффициентами в каждый момент времени переходит в монотонный (с некоторым сдвигом). Говорят, что сохраняется монотонность пространственного профиля. Желательно определить аналогичное свойство для численного решения. Существует несколько определений монотонности разностной схемы. Самыми известными являются три.

1. *Монотонность по Фридрихсу.* Двухслойная разностная схема для однородного уравнения (13.2)

$$y_m^{n+1} = \sum_k \alpha_k(\tau, h) y_{m+k}^{n+1}$$

называется монотонной, если все коэффициенты разностной схемы $\alpha_k \geq 0$.

2. *Монотонность по С. К. Годунову.* Монотонными называются разностные схемы, для которых следует $y_{m+1}^{n+1} - y_m^{n+1} \geq 0$, если $y_{m+1}^n - y_m^n \geq 0$, и $y_{m+1}^{n+1} - y_m^{n+1} \leq 0$, если $y_{m+1}^n - y_m^n \leq 0$.

3. *Монотонность по Хартену.* Для этого определяется полная вариация решения $\operatorname{TV}(y^n) = \sum_{m=-\infty}^{\infty} |y_{m+1}^n - y_m^n|$. Условие монотонности является невозрастание полной вариации:

$$\operatorname{TV}(y^{n+1}) \leq \operatorname{TV}(y^n).$$

Схемы, удовлетворяющие условию Хартена, называются TVD-схемами (Total Variation Diminishing). О них речь пойдет ниже.

При исследовании разностных схем для уравнений и систем гиперболического типа важную роль играет следующая теорема.

Теорема 13.1 (С. К. Годунов). *Не существует монотонных линейных разностных схем для решения уравнения переноса (13.2) с порядком аппроксимации выше первого.*

Следствием теоремы С. К. Годунова является то, что при использовании схем с порядком аппроксимации выше 1 в численном решении могут появляться осцилляции нефизической природы.

13.4. Численные методы решения квазилинейного уравнения переноса

Рассмотрим теперь простейшие разностные схемы для уравнения Хопфа.

Обобщение на случай уравнения Хопфа схемы П. Лакса имеет вид

$$\frac{u_m^{n+1} - 0.5(u_{m+1}^n - u_{m-1}^n)}{\tau} + \frac{f_{m+1}^n - f_{m-1}^n}{h} = 0.$$

Здесь, очевидно, используется дивергентный вид уравнения (13.7).

Схема условно устойчива при выполнении условия Куранта (точнее, обобщения условия Куранта) $\frac{\tau}{h} \max_m |u_m^n| \leq 1$. Здесь и ниже, как и ранее в (13.6), $f = 0.5u^2$. При этом предполагается, что течение достаточно гладкое, момент градиентной катастрофы еще не наступил, в решении нет ударных волн и других разрывов.

Схема Куранта–Изаксона–Риса. Обобщение схем КИР на квазилинейный случай (при использовании дивергентной формы записи уравнений) очевидно:

$$\begin{aligned} \frac{u_m^{n+1} - u_m^n}{\tau} + \frac{f_{m+1}^n - f_m^n}{h} &= 0, \quad u_m^n < 0; \\ \frac{u_m^{n+1} - u_m^n}{\tau} + \frac{f_m^n - f_{m-1}^n}{h} &= 0, \quad u_m^n > 0. \end{aligned}$$

Схема устойчива при выполнении условия Куранта $\frac{\tau}{h} \max_m |u_m^n| \leq 1$.

Обобщение схемы Лакса–Вендроффа (схема предиктор–корректор). Для квазилинейных уравнений (а также линейных уравнений с переменными коэффициентами, неоднородных уравнений и т. п.) схема Лакса–Вендроффа становится более сложной. Для ее построения необходимо ввести так называемые полуцелые точки (точки с дробными индексами). На первом этапе (предиктора) значения в полуцелых точках вычисляются по приведенной выше схеме — обобщению на квазилинейный случай схемы Лакса:

$$\begin{aligned} \frac{u_{m+1/2}^{n+1/2} - 0.5(u_{m+1}^n + u_m^n)}{\tau/2} + \frac{f_{m+1}^n - f_m^n}{h} &= 0, \\ \frac{u_{m-1/2}^{n+1/2} - 0.5(u_m^n + u_{m-1}^n)}{\tau/2} + \frac{f_m^n - f_{m-1}^n}{h} &= 0, \end{aligned}$$

на втором этапе (корректор) используется схема «чехарда» (трех-слойная схема на крестообразном шаблоне, которая не входит в семейство (13.8)):

$$\frac{u_m^{n+1} - u_m^n}{\tau} + \frac{f_{m+1/2}^{n+1/2} - f_{m-1/2}^{n+1/2}}{h} = 0.$$

Схема Лакса–Вендроффа принадлежит к так называемым *центральной* схемам. Ее шаблон симметричен. На первом этапе рассчитываются значения сеточной функции в полуцелых точках шаблона на промежуточном слое $(t_{m-1/2}, x_{m-1/2})$, $(t_{n+1/2}, x_{m+1/2})$, на втором этапе вычисляется решение на верхнем слое в точке (t_{n+1}, x_m) . Схема устойчива при выполнении условия Куранта.

Аналогично строятся схемы Лакса–Вендроффа для линейных неоднородных уравнений.

Нецентральная схема Мак-Кормака (предиктор–корректор). Как и приведенная выше схема Лакса–Вендроффа, схема Мак-Кормака состоит из двух этапов. Рассмотрим построение схемы Мак-Кормака для однородного уравнения (13.6). Первый этап (предиктор) имеет вид

$$\begin{aligned} \frac{\tilde{u}_m - u_m^n}{\tau} + \frac{f_{m+1}^n - f_m^n}{h} &= 0, \\ \frac{\tilde{u}_{m-1} - u_{m-1}^n}{\tau} + \frac{f_m^n - f_{m-1}^n}{h} &= 0, \end{aligned}$$

т.е. используется схема «явный правый уголок». Второй этап — корректор:

$$\frac{u_m^{n+1} - 0.5(u_m^n + \tilde{u}_m)}{\tau} + \frac{\tilde{f}_m - \tilde{f}_{m-1}}{2h} = 0.$$

Таким образом, расчет на первом этапе проводится по схеме «правый уголок», на втором — «левый уголок».

Другая схема Мак-Кормака имеет вид

$$\begin{aligned} \frac{\tilde{u}_m - u_m^n}{\tau} + \frac{f_m^n - f_{m-1}^n}{h} &= 0, \\ \frac{\tilde{u}_{m+1} - u_{m+1}^n}{\tau} + \frac{f_{m+1}^n - f_m^n}{h} &= 0, \\ \frac{u_m^{n+1} - 0.5(u_m^n + \tilde{u}_m)}{\tau} + \frac{\tilde{f}_{m+1} - \tilde{f}_m}{2h} &= 0. \end{aligned}$$

Такие разностные схемы называют *нецентральными*. К их преимуществам относят отсутствие полуцелых индексов, более простую постановку граничных условий. В линейном случае схемы Мак-Кормака совпадают со схемой Лакса–Вендроффа. Схемы имеют второй порядок аппроксимации по обоим переменным, схемы устойчивы при выполнении условия Куранта.

13.5. Аппроксимационная вязкость

Рассмотрим схему первого порядка аппроксимации для численного решения модельного однородного уравнения переноса (13.2)

$$\mathbf{L}_\tau u^\tau = \frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_m^n - u_{m-1}^n}{h} = 0,$$

исследование которой на аппроксимацию дает следующее выражение для главных членов ошибки аппроксимации (главных членов невязки):

$$\begin{aligned} \mathbf{L}_\tau u^\tau &= \mathbf{L}u + \frac{\tau}{2} \frac{\partial^2 u}{\partial t^2} - \frac{ah}{2} \frac{\partial^2 u}{\partial x^2} + O(\tau^2 + h^2) = \\ &= \mathbf{L}u - \frac{ah}{h} \left(1 - \frac{a\tau}{2}\right) \frac{\partial^2 u}{\partial x^2} + O(\tau^2 + h^2). \end{aligned}$$

Таким образом, с точностью до членов второго порядка аппроксимируется уравнение

$$\frac{\partial u}{\partial t} + a \frac{\partial u}{\partial x} = \gamma \frac{\partial^2 u}{\partial x^2},$$

где аналог коэффициента теплопроводности

$$\gamma = \frac{ah}{2} \left(1 - \frac{a\tau}{h}\right)$$

есть так называемый коэффициент аппроксимационной вязкости, а член

$$\eta = \frac{ah}{2} \left(1 - \frac{a\tau}{h}\right) \frac{\partial^2 u}{\partial x^2}$$

именуется аппроксимационной вязкостью. Его действие — сглаживание численного решения. Слагаемые в правой части уравнения переноса, пропорциональные второй производной, моделируют диссипативный эффект. Однако эта вязкость является свойством выбранной разностной схемы первого порядка аппроксимации. Здесь в уравнение не вводятся никакие дополнительные

члены и не используются сглаживающие операторы. Рассматриваемое уравнение носит название *первого дифференциального приближения* разностной схемы. Все схемы первого порядка аппроксимации будут обладать схемной вязкостью.

Искусственная вязкость. Для регуляризации решения, полученного с помощью немонотонных разностных схем с порядком аппроксимации выше первого, можно вводить так называемую *искусственную вязкость*. Этот способ регуляризации решения был предложен фон Нейманом и Рихтмайером для численного решения системы уравнений газовой динамики. В рамках данной лекции ограничимся рассмотрением модельного линейного уравнения переноса.

Идею искусственной вязкости можно проиллюстрировать на примере, вообще говоря, неустойчивой схемы

$$\mathbf{L}_\tau u^\tau = \frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_{m+1}^n - u_{m-1}^n}{2h} = 0$$

для решения линейного одномерного уравнения переноса (13.2).

Для того чтобы сделать эту схему устойчивой, введем в правую часть член порядка погрешности аппроксимации, моделирующий диссипативный эффект, так называемую искусственную вязкость. Получим следующую задачу:

$$\mathbf{L}_\tau u^\tau = \xi \tau \frac{u_{m+1}^n - 2u_m^n + u_{m-1}^n}{h^2},$$

где $\frac{\xi \tau}{h^2}(u_{m+1}^n - 2u_m^n + u_{m-1}^n)$ — искусственная вязкость, величина порядка главного члена погрешности аппроксимации (невязки), ξ — коэффициент искусственной вязкости. Исследование этой схемы на устойчивость с помощью *спектрального признака* дает $r \leq 0.5$, $\sigma^2/(2r) \leq 1$, где $r = \xi \tau / h^2$, $\sigma = a \tau / h$. При $\xi = 0.5$ для рассматриваемого линейного уравнения получим схему Лакса–Вендроффа.

13.6. Гибридные схемы (метод Р. П. Федоренко)

Идею построения гибридных схем, изложенную в [51], рассмотрим на традиционном примере схемы «уголок»

$$L_\tau u^\tau = \frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_m^n - u_{m-1}^n}{h} = 0$$

для численного решения модельного уравнения переноса

$$Lu = \frac{\partial u}{\partial t} + a \frac{\partial u}{\partial x} = 0.$$

Разложения сеточных функций проекции на сетку точного решения дифференциальной задачи в ряд Тейлора дает

$$L_{\tau} u^{\tau} = Lu + \frac{\tau}{2} \frac{\partial^2 u}{\partial t^2} - \frac{ah}{2} \frac{\partial^2 u}{\partial x^2} + O(\tau^2 + h^2).$$

Поскольку $\frac{\partial^2 u}{\partial t^2} = a^2 \frac{\partial^2 u}{\partial x^2}$, что показывается дифференцированием рассматриваемого уравнения переноса по t и по x , полученное выражение может быть представлено в виде

$$\frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_m^n - u_{m-1}^n}{h} + \frac{1}{2\tau} \left(\frac{a\tau}{h} - \frac{a^2\tau^2}{h^2} \right) (u_{m-1}^n - 2u_m^n + u_{m+1}^n) = 0.$$

Аналогичным образом можно получить и схему третьего порядка аппроксимации:

$$\begin{aligned} \frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_m^n - u_{m-1}^n}{h} + \frac{1}{2\tau} \left(\frac{a\tau}{h} - \frac{a^2\tau^2}{h^2} \right) (u_{m-1}^n - 2u_m^n + u_{m+1}^n) + \\ + \frac{1}{6} \left(\frac{a\tau}{h} - \frac{a^3\tau^3}{h^3} \right) (u_{m+1}^n - 3u_{m-1}^n + 3u_{m-1}^n - u_{m-2}^n) = 0. \end{aligned}$$

Введем разностный анализатор гладкости численного решения, сравнивая конечные разности первого и второго порядков:

$$\gamma = \begin{cases} 1, & |u_{m-1}^n - 2u_m^n + u_{m+1}^n| < \lambda |u_m^n - u_{m-1}^n|, \\ 0, & |u_{m-1}^n - 2u_m^n + u_{m+1}^n| > \lambda |u_m^n - u_{m-1}^n| \end{cases}$$

и представим полученную схему в виде

$$\frac{u_m^{n+1} - u_m^n}{\tau} + a \frac{u_m^n - u_{m-1}^n}{h} + \frac{\gamma}{2\tau} \left(\frac{a\tau}{h} - \frac{a^2\tau^2}{h^2} \right) (u_{m+1}^n - 2u_m^n + u_{m-1}^n) = 0.$$

Таким образом, в областях с большим градиентом численного решения $\gamma = 0$, и расчет ведется по схеме первого порядка аппроксимации, в области же гладкого решения $\gamma = 1$, и расчет ведется по схеме второго порядка (при $\lambda = 0$ имеем схему первого, при

$\lambda = \infty$ — второго порядка аппроксимации). Аналогичный анализатор можно ввести и для схемы третьего порядка аппроксимации.

Заметим, что гибридные схемы, построенные выше для аппроксимации линейного уравнения переноса, уже нелинейные — коэффициенты переключения зависят от локальных свойств решения. Таким образом, в соответствие линейному дифференциальному оператору ставится нелинейный. Для таких схем не обязана выполняться теорема С. К. Годунова, и можно ожидать, что на пути введения нелинейности для гиперболических систем и уравнений можно построить монотонные или близкие к монотонным схемы высокого порядка аппроксимации.

13.7. Схемы с уменьшением полной вариации (Total Variation Diminishing, схемы Хартена)

Рассмотрим схемы с уменьшением полной вариации (сокращенно их называют TVD-схемами). Для построения схемы введем полную вариацию численного решения. Она определяется следующим образом:

$$\text{Var}(u^n) = \sum_{j=-\infty}^{\infty} |u_{j+1}^n - u_j^n|. \quad (13.9)$$

Определение 13.2. Разностная схема, аппроксимирующая уравнение (13.2), будет TVD, если

$$\text{Var}(u^{n+1}) \leq \text{Var}(u^n). \quad (13.10)$$

Суть построения TVD-схем можно понять, представив схему Лакса–Вендроффа для численного решения модельного уравнения переноса в виде

$$u_m^{n+1} = u_m^n - \sigma(u_m^n - u_{m-1}^n) - (f_{m+1/2}^n - f_{m-1/2}^n), \quad (13.11)$$

где $\sigma = a\tau/h$, $f_{m+1/2} = 0.5\sigma(1-\sigma)(u_{m+1} - u_m)$ — антидиффузионные потоки. Эта схема не монотонна. Сделаем ее монотонной, ограничив антидиффузионные потоки введением функций $\varphi(r_m)$:

$$f'_{m+1/2} = 0.5\varphi(r_m)\sigma(1-\sigma)(u_{m+1} - u_m),$$

аналогично для $f'_{m-1/2}$. Здесь φ — ограничитель,

$$r_m = \frac{u_m - u_{m-1}}{u_{m+1} - u_m},$$

отношение прилежащих градиентов $\varphi(r_m)$ выбирается так, чтобы (13.11) была TVD-схемой. В расчетах обычно полагают

$$r_m = \frac{u_m - u_{m-1} + \varepsilon}{u_{m+1} - u_m + \varepsilon},$$

где ε — малое число.

Можно показать, что условием устойчивости схемы является неравенство

$$0 < \varphi(r_m) \leq \min(2r_m, 2) \text{ при } r_m > 0 \quad \text{и} \quad \varphi(r_m) = 0 \text{ при } r_m \leq 0.$$

Простейшим ограничителем является выбор конечных разностей в соответствии с принципом минимальных производных Колгана:

$$\varphi(r_m) = 1, \quad f'_{m+1/2} = \frac{\sigma}{2}(1 - \sigma) \cdot \begin{cases} \Delta u_m^n, & |\Delta u_m^n| \leq \Delta^- u_m^n, \\ \Delta^- u_m^n, & |\Delta u_m^n| > \Delta^- u_m^n. \end{cases}$$

Приведем пример другого ограничителя:

$$\varphi(r) = \begin{cases} \min(2, r_m), & r_m > 1, \\ \min(2r_m, 1), & 0 < r_m \leq 1, \\ 0, & r_m \leq 0 \end{cases}$$

или

$$\varphi(r_m) = \begin{cases} \min \text{mod}(2, r_m), & r_m > 1, \\ \min \text{mod}(1, 2r_m), & 0 < r_m < 1, \end{cases}$$


где

$$\min \text{mod}(x, y) = \frac{\text{sign } x + \text{sign } y}{2} \min(|x|, |y|).$$


Для того чтобы понять такую конструкцию переключателя, рассмотрим подробнее, как r_m зависит от профиля решения.

1) $r_m > 1$: $u_m - u_{m-1} > u_{m+1} - u_m$ (если и числитель, и знаменатель в выражении для r_m положительны), или $u_{m-1} - u_m >$


$> u_m - u_{m+1}$ (если и числитель, и знаменатель отрицательны); численное решение сглаживается, так как его градиент убывает.



2) $0 < r_m \leq 1$; $u_m - u_{m-1} \leq u_{m+1} - u_m$ (если и числитель, и знаменатель в выражении для r_m положительны) или $u_{m-1} - u_m < u_m - u_{m+1}$ (если и числитель, и знаменатель отрицательны); градиент численного решения растет (или не убывает).



3) $r_m \leq 0$: $u_m - u_{m-1} > 0$ и $u_{m+1} - u_m < 0$, или $u_m - u_{m-1} < 0$ и $u_{m+1} - u_m > 0$; численное решение осциллирует.



Для обеспечения второго порядка аппроксимации необходимо потребовать $\varphi(1) = 1$. Различные TVD-алгоритмы соответствуют различному выбору $\varphi(r_m)$. Дивергентный вариант TVD-схемы:

$$u_m^{n+1} = u_m^n - \frac{\tau}{h}(f_{m+1/2}^n - f_{m-1/2}^n),$$

где

$$f_{m+1/2}^n = \frac{f_m^n + f_{m+1}^n}{2} - \frac{q}{2}(f_{m+1}^n - f_m^n) + \frac{\varphi(r_m)}{2}(q - \sigma)(f_{m+1}^n - f_m^n),$$

$q = \text{sign } \sigma_{m+1/2}$, число Куранта $\sigma = \frac{\tau}{h} \frac{\partial f}{\partial u}$.

13.8. Идеи построения сеточно-характеристических методов и анализ разностных схем в пространстве неопределенных коэффициентов

Идея построения метода. Продemonстрируем основные идеи построения сеточно-характеристических методов на примере решения простейшего линейного уравнения переноса

$$\frac{\partial u}{\partial t} + a \frac{\partial u}{\partial x} = f(x, t), \quad a = \text{const} > 0 \quad (13.12)$$

с соответствующими начальными и граничными условиями.

Известно, что (13.12) имеет характеристику, определяемую уравнением *характеристики*

$$\frac{dx}{dt} = a$$

и вдоль нее превращается в обыкновенное дифференциальное уравнение (ОДУ)

$$\frac{du}{d\xi} = f(\xi).$$




Рис. 13.4

В частности, для однородного уравнения (13.12) значение функции u вдоль характеристики не меняется. На сведениях уравнения в частных производных к обыкновенному дифференциальному уравнению построены так называемые *методы характеристик*.

Методы сеток основаны на введении в области интегрирования уравнения разностной сетки, сеточного шаблона, т. е. совокупности узлов сетки, используемых для замены дифференциального уравнения (в малой области) разностным аналогом (аппроксимацией). При анализе аппроксимации обычно используются разложения проекции на сетку точного решения дифференциальной задачи в ряд Тейлора.

Рассмотрим класс методов, в которых одновременно использован и сеточный, и характеристический подход.

В области интегрирования введем *разностную сетку*:

$$t^n = n\tau, \quad x_m = m\hbar; \quad n = 0, 1, 2, 3, \dots; \quad m = 0, \pm 1, \pm 2, \pm 3, \dots$$

Значение решения (13.12) в узлах сетки обозначим через u_m^n . Для перехода на следующий временной шаг сетки будем использовать явный пятиточечный шаблон (рис. 13.4). Необходимо вычислить значение u_m^{n+1} , используя значения u на n -м слое по времени. Проведем из точки $(n+1, m)$ характеристику с наклоном λ до пересечения со слоем t^n в точке V . Тогда вдоль характеристики значение u_m^{n+1} выражается через u_v^n , например, как

$$u_m^{n+1} = u_v^n + \frac{\tau}{2}(f_m^{n+1} + f_v^n) + O(\tau^2). \quad (13.13)$$

Выражение (13.13) получено как аппроксимация обыкновенного дифференциального уравнения вдоль характеристики методом трапеций. Проводя ту или иную интерполяцию для нахождения значения u_v^n по точкам слоя t^n , получим различные разностные схемы для определения u_m^{n+1} на данном шаблоне.

О физическом смысле условия Куранта. Пусть $\sigma = \tau a / \hbar$ — число Куранта. В случае $a = \text{const}$ очевидно, что выбором τ и $\hbar$ можно добиться $\sigma = 1$ или $\sigma = 2$. В этом случае характеристика, проведенная через точку u_m^{n+1} , попадет в узел разностной сетки, где значение u_{m-1}^n (или u_{m-2}^n соответственно) известно точно. Для однородного уравнения происходит перенос значения в точку u_m^{n+1} вдоль характеристики. Если $2 \geq \sigma > 0$, то для определения значения u_v^n приходится решать задачу интерполяции, а для $\sigma > 2$ — задачу экстраполяции по узлам сетки. Известно, что вторая задача, как правило, неустойчива.

Точку V назовем *областью влияния* дифференциального уравнения (13.12), а точки шаблона, по которым проводится интерполяция — *областью влияния разностного уравнения*. Для устойчивости разностной схемы необходимо, чтобы область влияния

дифференциальной задачи лежала внутри области влияния разностной — это проявление условия КФЛ.

Пространство неопределенных коэффициентов.* Запишем разностную схему в виде

$$u_m^{n+1} = \sum_{k=-2}^1 \alpha_k u_{m+k}^n, \quad (13.14)$$

где коэффициенты α_k будем искать из условий аппроксимации, раскладывая проекцию точного решения дифференциальной задачи u_m^{n+1} , u_{m+k}^n в ряды Тейлора в окрестности точки (t^n, x_m) . Оставляя свободными два коэффициента (например, α_{-2} , α_0), получаем условия аппроксимации порядка $O(\tau + h)$:

$$\begin{aligned} \alpha_{-1} &= \frac{1}{2}(1 + \sigma - 3\alpha_{-2} - \alpha_0), \\ \alpha_1 &= \frac{1}{2}(1 - \sigma + \alpha_{-2} - \alpha_0). \end{aligned}$$

Примем свободные коэффициенты за координатные оси линейного пространства с евклидовой метрикой. Каждая точка этого пространства будет соответствовать разностной схеме первого порядка аппроксимации. Кроме того, можно выделить множество схем порядка $O(\tau + h^2)$

$$\alpha_0 = 1 - \sigma + 3\alpha_{-2} \quad (13.15)$$

и единственную на данном шаблоне схему третьего порядка аппроксимации с порядком $O(\tau + h^3)$:

$$\alpha_{-2} = \frac{\sigma(\sigma - 1)}{6}. \quad (13.16)$$

Остальные коэффициенты находятся с использованием (13.15) и (13.16).

Введем пространство коэффициентов (α_{-2}, α_0) . Тогда любая точка в этом пространстве есть разностная схема с порядком аппроксимации $O(\tau + h)$. Прямая (13.15) отделяет в пространстве множество схем с порядком $O(\tau + h^2)$ (рис. 13.5), на ней лежит единственная точка — аппроксимация $O(\tau + h^3)$. Должна быть также и точка с порядком аппроксимации $O(\tau^2 + h^2)$. Зафиксируем какое-либо число Куранта, например $\sigma = 0.5$. Применим к раз-

ностной схеме (13.14) с неопределенными коэффициентами спектральный признак устойчивости (фон Неймана). Получится кривая, которая определяет границу устойчивости разностных схем в пространстве неопределенных коэффициентов.

Для схем первого порядка выпишем первое дифференциальное приближение:

$$u'_t + au'_x = \frac{h^2}{\tau} (1 - \sigma^2 - \alpha_0 + 3\alpha_{-1}) u''_{xx}.$$

Можно также выделить множество таких схем, что $\alpha_\mu \geq 0$. Это — монотонные схемы (заштрихованный многоугольник на рис. 13.5). Среди монотонных схем можно найти схему с наимень-




Рис. 13.5

шей ошибкой аппроксимации. Это точка многоугольника, которая при данном σ лежит ближе всего к прямой со схемами второго порядка аппроксимации.

Закончим рассмотрение примера с модельным линейным уравнением переноса

$$u'_t + au'_x = 0.$$

На выбранном шаблоне любая разностная схема, как указывалось ранее, представляется в виде

$$u_m^{n+1} = \sum_{\mu \in \Pi} \alpha_\mu u_{m+\mu}^n.$$

В случае монотонной схемы можно оценить норму погрешности. Заметим, что погрешность v определяется тем же разностным

уравнением (13.14), тогда с использованием первой нормы (максимум абсолютной величины)

$$\|v^{n+1}\| = \|v^n\| \sum_{\mu \in \text{III}} \alpha_\mu$$

в силу аппроксимации

$$\sum_{\mu \in \text{III}} \alpha_\mu \leq 1.$$

Отсюда следует, что монотонные разностные схемы всегда устойчивы. В общем случае можно рассматривать многослойные шаблоны для уравнения переноса

$$u_m^{n+1} = \sum_{\mu, \nu \in \text{III}} \alpha_\mu^\nu u_{m+\mu}^{n+\nu}$$

и записывать условия порядка для аппроксимации соответствующего порядка:

$$\delta_0 = -1 \sum_{\mu, \nu \in \text{III}} \alpha_\mu^\nu = 0,$$

$$\delta_1 = \sigma + \sum_{\mu, \nu \in \text{III}} (\mu - \nu\sigma) \alpha_\mu^\nu.$$

Исключая два коэффициента из условий порядка, можно от пространства неопределенных коэффициентов $\{\alpha_\mu^\nu\}$ перейти к пространству $\{\tilde{\alpha}_\mu^\nu\}$, размерность которого на 2 меньше, например:

$$\begin{aligned} \alpha_{-1}^0 &= \frac{1}{2} \left(1 + \sigma - \sum (\mu - \nu\sigma) \alpha_\mu^\nu \right), \\ \alpha_1^0 &= \frac{1}{2} \left(1 - \sigma - \sum (\mu - \nu\sigma) \alpha_\mu^\nu \right), \end{aligned}$$

где, конечно, точки $(0; -1)$ и $(0; 1)$ не включаются в суммирование. Условие устойчивости в пространстве неопределенных коэффициентов имеет вид

$$|\lambda(\alpha_\mu^\nu, \varphi)| \leq 1,$$

где λ есть спектр оператора послыйного перехода. Эта величина определяется из условия

$$\lambda = \sum_{\mu, \nu} \alpha_\mu^\nu q^\nu e^{i\mu\varphi}$$

и дополнительного требования

$$\frac{\partial}{\partial \varphi} (|\lambda| - 1) = 0.$$

Основная гипотеза: *разностным схемам, которым в пространстве $\{\bar{\alpha}_\mu^v\}$ соответствуют близкие друг к другу точки (в смысле $\rho = \sqrt{(\bar{\alpha}_1, \bar{\alpha}_1) - (\bar{\alpha}_2, \bar{\alpha}_2)}$), по своим свойствам также близки.*

Расширяя шаблон, как и в случае пятиточечного шаблона, можно строить области схем высокого порядка аппроксимации, монотонные схемы ($\alpha_\mu^v \geq 0$) и т. д.

Монотонные разностные схемы в пространстве неопределенных коэффициентов занимают некий выпуклый многоугольник, вершины которого определяются довольно просто: это все возможные при данном числе Куранта σ трехточечные разностные схемы, причем для характеристики, проходящей через u_m^{n+1} , одна точка схемы лежит выше (левее) характеристики, а другая ниже (правее).

Метод построения разностных схем в пространстве неопределенных коэффициентов для квазилинейных систем уравнений гиперболического типа (к ним относятся системы уравнений механики сплошных сред, в частности газовой динамики, механики деформируемого твердого тела (МДТТ) и т. п.) допускает обобщение и на многомерные случаи.

Исследовав схемы (13.14) на устойчивость по спектральному признаку, получаем множество устойчивых схем, а потребовав выполнения условия $\alpha_k \geq 0$ для всех точек шаблона, получаем множество схем с *положительной аппроксимацией* (монотонных по Фридрихсу схем). На рассматриваемом шаблоне устойчивые схемы существуют при $2 \geq \sigma > 0$ (для $a > 0$).

Множество схем с положительной аппроксимацией не пересекается с множеством схем с порядком аппроксимации выше первого, как это следует из теоремы С. К. Годунова.

Первое дифференциальное приближение. Дисперсионная и диссипативная ошибки. Поскольку решения дифференциальной задачи и разностного уравнения принадлежат разным функциональным пространствам, что порождает определенные трудности при теоретическом анализе свойств разностных схем, для такого исследования возможно рассматривать разностные операторы в том же пространстве. Будем считать, что разностные схемы

удовлетворяются функциями непрерывного аргумента в каждой точке рассматриваемой области.

Обычно ограничиваются рассмотрением уравнений, в которых оставлены члены в разложении в ряд Тейлора проекции точного решения на сетку по τ и h , порядок которых совпадает с порядком погрешности аппроксимации схемы. Получающиеся при этом уравнения называют первым дифференциальным приближением (ПДП).

Для схемы первого порядка (13.14) при выполнении условия Куранта первым дифференциальным приближением будет

$$u'_t + au'_x = \delta_1 h u''_{xx}, \quad \text{где } \delta_1 = \text{const.} \quad (13.17)$$

Из уравнения (13.17) исключены члены со второй производной u'_{tt} с использованием так называемой продолженной системы:

$$\begin{aligned} (u'_t + au'_x)'_x &= 0, \\ (u'_t + au'_x)'_t &= 0. \end{aligned}$$

Иногда уравнение (13.17) называют П-формой (параболической формой) первого дифференциального приближения. Если производные по времени не исключаются из ПДП, то имеем Г-форму (гиперболическую форму) ПДП, которая, как правило, не применяется в исследованиях как малоинформативная.

При $\delta_1 > 0$ уравнение (13.17) можно трактовать как присутствие в схеме некоторой диссипации (схемной вязкости). Ее наличие проявляется в расчетах в виде размазывания точного решения, причем его интенсивность увеличивается при ухудшении аппроксимации (увеличении шага h). В этом случае говорят, что ошибка схемы носит диссипативный характер. Если схемная вязкость получается отрицательной, то приходим к обратной задаче теплопроводности. Как известно из курсов математической физики, такая задача поставлена некорректно, а соответствующая разностная схема при исследовании по спектральному признаку оказывается неустойчивой — по ПДП можно сделать вывод об устойчивости схемы.

Для более высокого (второго) порядка ПДП имеет вид

$$u'_t + au'_x = \delta_2 h^2 u'''_{xxx}. \quad (13.18)$$

Уравнение (13.18) обладает *дисперсией*, т. е. разные пространственные гармоники разложения начального возмущения в ряд

Фурье распространяются по сетке с разными скоростями. Говорят, что ошибка носит дисперсионный характер. Сеточная дисперсия легко получается, если искать частное решение последнего уравнения в виде комплексной экспоненты: $u = \lambda(t) \exp(ikx)$. Подробнее о ПДП в [45].

Интересна связь ПДП и исследования свойств схем в пространствах неопределенных коэффициентов. Так, для схем первого порядка расстояние от точки в пространстве неопределенных коэффициентов до прямой схем высокого порядка (13.15) по абсолютной величине равно коэффициенту δ_1 в уравнении (13.17), а знак определяется положением внутри области устойчивости.

13.9. Примеры решения задач

1. Для линейного уравнения переноса

$$\frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} = 0$$

предложить схему $(N+1)$ -го порядка аппроксимации.

Указание. Рассмотреть невязку, образующуюся при замене дифференциального уравнения разностным

$$\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - u_m^n}{h} = 0.$$

Решение. Проведем исследование разностного уравнения на аппроксимацию. Для этого представим сеточные функции u_m^{n+1} и u_{m+1}^n в виде разложения проекции на сетку точного решения дифференциальной задачи в ряд Тейлора:

$$u_{m+1}^n = u_m^n + h(u'_x)_m^n + \frac{h^2}{2!}(u''_x)_m^n + \frac{h^3}{3!}(u'''_x)_m^n + \frac{h^4}{4!}(u^{IV}_x)_m^n + \dots + \\ + \frac{h^N}{N!}(u^{(N)}_x)_m^n + O(h^{N+1}),$$

$$u_m^{n+1} = u_m^n + \tau(u'_t)_m^n + \frac{\tau^2}{2!}(u''_t)_m^n + \frac{\tau^3}{3!}(u'''_t)_m^n + \frac{\tau^4}{4!}(u^{IV}_t)_m^n + \dots + \\ + \frac{\tau^N}{N!}(u^{(N)}_t)_m^n + O(\tau^{N+1}).$$

Отсюда получим с учетом того, что $u_t^{(k)} = u_x^{(k)}$:

$$\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - u_m^n}{h} = (u_t' - u_x')_m^n + r_\tau,$$

где r_τ — невязка, вычисляемая в точке (t^n, x_m) по формуле

$$\begin{aligned} r_\tau &= \frac{1}{2!}(\tau - h)u_x'' + \frac{1}{3!}(\tau^2 - h^2)u_x''' + \frac{1}{4!}(\tau^3 - h^3)u_x^{IV} + \dots + \\ &+ \frac{1}{(N+1)!}(\tau^N - h^N)u_x^{(N+1)} + O(\tau^{N+1}, h^{N+1}) = \\ &= \sum_{k=1}^N \frac{h^k}{(k+1)!}(\sigma^k - 1)u_x^{(k+1)} + O(\tau^{N+1}, h^{N+1}), \end{aligned}$$

$\sigma = \tau/h$ — число Куранта.

Аппроксимация частных производных высоких порядков, входящих в выражение для невязки, с помощью конечных разностей приводит к равенству

$$r_\tau = \frac{1}{h} \sum_{k=1}^N \frac{\sigma^k - 1}{(k+1)!} \Delta^{k+1} u_m^n + O(\tau^{N+1}, h^{N+1}).$$

В таком случае после переноса суммы по k в выражении для невязки в левую часть получим разностную схему искомого порядка аппроксимации:

$$\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - u_m^n}{h} - \frac{1}{h} \sum_{k=1}^N \frac{\sigma^k - 1}{(k+1)!} \Delta^{k+1} u_m^n = 0,$$

или

$$u_m^{n+1} = u_m^n + \sigma \Delta^+ u_m^n - \sigma \sum_{k=1}^N \frac{(1 - \sigma^k)}{(k+1)!} \Delta^{k+1} u_m^n = 0.$$

Эта схема легко распространяется на уравнение

$$\frac{\partial u}{\partial t} - a \frac{\partial u}{\partial x} = 0,$$

если учесть, что

$$\frac{\partial^{k+l} u}{\partial t^k \partial x^l} = (-1)^k a^k \frac{\partial^{k+l} u}{\partial x^{k+l}}.$$

2. Доказать устойчивость разностной схемы

$$\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - u_m^n}{h} = f_m^n,$$

$$n = 0, \dots, N-1, \quad m = 0, \pm 1, \dots, \pm(M-1),$$

$$u_m^0 = \varphi_m^n, \quad m = 0, \pm 1, \dots, \pm(M-1),$$

аппроксимирующей задачу Коши для уравнения переноса

$$\frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} = f(t, x), \quad t \in [0; T],$$

$$x \in (-\infty; \infty), \quad u(0, x) = \varphi(x), \quad x \in (-\infty; \infty),$$

используя второе определение устойчивости:

$$\|u_\tau\| \leq C \|f\| \quad \text{при} \quad \sigma = \frac{\tau}{h} < 1.$$

Решение. Перепишем разностную схему в виде, разрешенном относительно следующего слоя по времени,

$$u_m^{n+1} = (1 - \sigma)u_m^n + \sigma u_{m+1}^n + \tau f_m^n,$$

$$u_m^0 = \varphi_m.$$

Определим норму в пространстве сеточных функций как

$$\|u_\tau\| = \sup_{n, m} |u_m^n| = \max_n \sup_m |u_m^n|.$$

Если $1 - \sigma \geq 0$, то справедлива оценка

$$\begin{aligned} \|(1 - \sigma)u_m^n + \sigma u_{m+1}^n\| &\leq |(1 - \sigma) + \sigma| \max_n (|u_m^n|, |u_{m+1}^n|) = \\ &= \max_n (|u_m^n|, |u_{m+1}^n|) \leq \max_m |u_m^n|. \end{aligned}$$

В таком случае

$$|u_m^{n+1}| \leq \max_m |u_m^n| + \tau |f_m^n| \leq \max_m |u_m^n| + \tau \max_{m, n} |f_m^n|.$$

Отсюда видно, что при $f_m^n = 0$ норма решения $|u_m^n|$ не возрастает при возрастании n — выполняется принцип максимума. Поскольку правая часть в полученном неравенстве не зависит от m ,

то $\max_m |u_m^{n+1}| \leq \max_m |u_m^n| + \tau \max_{m,n} |f_m^n|$. Аналогично

$$\begin{aligned} \max_m |u_m^n| &\leq \max_m |u_m^{n-1}| + \tau \max_{m,n} |f_m^n|, \\ \max_m |u_m^{n-1}| &\leq \max_m |u_m^{n-2}| + \tau \max_{m,n} |f_m^n|, \\ &\dots\dots\dots, \\ \max_m |u_m^1| &\leq \max_m |u_m^0| + \tau \max_{m,n} |f_m^n|. \end{aligned}$$

Сложение этих неравенств дает

$$\max_m |u_m^{n+1}| \leq \max_m |u_m^0| + (n+1)\tau \max_{m,n} |f_m^n|,$$

откуда получаем, с учетом того, что $t_n = n\tau$,

$$\begin{aligned} \max_m |u_m^{n+1}| &\leq \max_m |\varphi_m| + t_{n+1} \max_{m,n} |f_m^n| \leq \\ &\leq \|f_\tau\| + t_{n+1} \|f_\tau\| = (1 + t_{n+1}) \|f_\tau\|. \end{aligned}$$

При этом учтено, что

$$\|\varphi_\tau\| = \|f_\tau\| = \max_{n,m} |f_m^n| + \max_m |\varphi_m^n|.$$


Таким образом, получим

$$\|u_\tau\| \leq C \|f_\tau\|, \quad \text{где } C = 1 + t_{n+1}.$$

3. Построить явную разностную схему первого порядка аппроксимации для аппроксимации линейного уравнения переноса $\frac{\partial u}{\partial t} - \frac{\partial u}{\partial x} = f(t, x)$, используя ее запись в общем виде через неопределенные коэффициенты

$$\mathbf{L}_\tau u_\tau = \alpha_1 u_m^{n+1} + \alpha_2 u_m^n + \alpha_3 u_{m+1}^n = f_m^n,$$

на шаблоне «явный правый уголок».



Решение. Будем подбирать коэффициенты α_i таким образом, чтобы выполнялось условие аппроксимации первого порядка $\mathbf{L}_\tau U_\tau = \mathbf{L}u|_{t_n, x_m} + O(\tau + h)$. Разложение сеточных функций проекций точного решения u_m^{n+1} и u_{m+1}^n в ряды Тейлора в окрестности точки x_m, t_n приводит к равенствам

$$u_m^{n+1} = u_m^n + \tau(u'_t)_m^n + O(\tau^2),$$

$$u_{m+1}^n = u_m^n + h(u'_x)_m^n + O(h^2).$$

Подстановка этих разложений в разностную схему с неопределенными коэффициентами дает

$$\begin{aligned} \mathbf{L}_\tau U_\tau &= \alpha_1 u_m^{n+1} + \alpha_2 u_m^n + \alpha_3 u_{m+1}^n = \\ &= (\alpha_1 + \alpha_2 + \alpha_3) u_m^n + \alpha_1 \tau (u'_t)_m^n + \alpha_3 h (u'_x)_m^n + O(\tau^2 + h^2) = \\ &= (\alpha_1 + \alpha_2 + \alpha_3) u_m^n + \alpha_1 \sigma h (\mathbf{L}u)_m^n + (\alpha_1 \sigma + \alpha_3) h (u'_x)_m^n + O(h^2), \end{aligned}$$

поскольку можно считать независимыми переменными шаг по пространству и число Куранта, а для шага по времени получаем очевидное выражение $\tau = \sigma h$, $\sigma = \text{const}$. Здесь использованы очевидные равенства для дифференциального оператора

$$\frac{\partial u}{\partial t} = \mathbf{L}u + \frac{\partial u}{\partial x}, \quad \frac{\partial u}{\partial x} = \frac{\partial u}{\partial t} - \mathbf{L}u.$$

Для выполнения условия аппроксимации первого порядка

$$\mathbf{L}_\tau U_\tau|_{t_n, x_m} = \mathbf{L}u|_{t_n, x_m} + O(h)$$

необходимо выполнение *условий порядка*

$$\begin{aligned} \alpha_1 \sigma h &= 1 + O(h), \\ \alpha_1 + \alpha_2 + \alpha_3 &= 0 + O(h), \\ (\alpha_1 + \alpha_3)h &= 0 + O(h). \end{aligned}$$

Если положить $O(h) = 0$, поскольку это некое число, стремящееся к нулю при измельчении шага, то условия порядка примут вид

$$\begin{aligned} \alpha_1 \sigma h &= 1, \\ \alpha_1 + \alpha_2 + \alpha_3 &= 0, \\ \alpha_1 + \alpha_3 &= 0. \end{aligned}$$

Эта схема линейных алгебраических уравнений имеет единственное решение:

$$\alpha_1 = \frac{1}{\sigma h} = \tau^{-1}, \quad \alpha_2 = \frac{\sigma - 1}{\sigma h} = h^{-1} - \tau^{-1}, \quad \alpha_3 = -h^{-1}.$$

Получили коэффициенты уже известной разностной схемы первого порядка аппроксимации на заданном шаблоне:

$$\frac{u_m^{n+1} - u_m^n}{\tau} - \frac{u_{m+1}^n - u_m^n}{h} = f_m^n.$$

Несложно проверить, что учет $O(h)$ привел бы к незначительной коррекции результата.

Конечно, выбранная разностная схема легко получается и из других соображений. Но с помощью метода неопределенных коэффициентов удастся построить схемы с хорошими свойствами для более сложных уравнений и систем.

4. Исследовать на спектральную устойчивость разностную схему на шаблоне «квадрат»

$$\begin{aligned} \frac{1}{2\tau} \left[(u_{m+1}^{n+1} + u_m^{n+1}) - (u_{m+1}^n - u_m^n) \right] + \\ + \frac{1}{h} \left[(u_{m+1}^{n+1} + u_{m+1}^n) - (u_m^{n+1} - u_m^n) \right] = f_{m+1/2}^{n+1/2}, \end{aligned}$$

аппроксимирующую линейное уравнение переноса

$$\frac{\partial u}{\partial t} + \frac{\partial u}{\partial x} = 0.$$

Р е ш е н и е. После подстановки в схему гармоник Фурье

$$u_m^n = \lambda^n e^{iam}$$

получим выражение для спектра оператора послойного перехода

$$\lambda(\alpha) = \frac{1 - i\sigma \operatorname{tg} \frac{\alpha}{2}}{1 + i\sigma \operatorname{tg} \frac{\alpha}{2}},$$

$\sigma = \tau/h$ — число Куранта.

Тогда $|\lambda(\alpha)| = 1$, и рассматриваемая схема безусловно устойчива. Этого следовало ожидать, так как аппроксимация производной по времени производится как на нижнем, так и на верхнем

временном слое. Однако решение на верхнем слое выписывается в явном виде, поскольку правое условие ставится на левой границе. Поэтому схему иногда относят к явным схемам бегущего счета. Расчетная формула будет

$$u_{m+1}^{n+1} = u_m^n + \frac{\sigma - 1}{\sigma + 1} (u_m^{n+1} - u_{m+1}^n) + \tau f_{m+1/2}^{n+1/2}.$$

Схема обладает вторым порядком аппроксимации по времени и пространственной координате.

5. Получить дисперсионное соотношение для разностных схем первого и второго порядка сходимости для аппроксимации нелинейного уравнения

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} = 0, \quad \text{где } u \neq \text{const},$$

и, вообще говоря, зависит от решения.

У к а з а н и е. Использовать дисперсионное соотношение для данного дифференциального уравнения в виде $e^{\lambda t} e^{ikx}$, где k — волновое число, $\lambda = -uki$.

Решение. Будем искать дисперсионное соотношение для разностного уравнения в виде

$$v_m^n = e^{\lambda(k)t_n} \cdot e^{ikx_m} = e^{\lambda n\tau + ikmh}.$$

После его подстановки в схему правый уголок первого порядка аппроксимации получим

$$\frac{1}{\tau} (e^{\lambda\tau} - 1) + \frac{u}{h} (1 - e^{-ikh}) = 0,$$

откуда следует

$$\lambda(\tau, h, k) = \tau^{-1} \ln \left\{ 1 - \frac{u\tau}{h} + \frac{u\tau}{h} e^{-ikh} \right\}.$$

Сравним дисперсионное соотношение для дифференциального и соответствующих разностных уравнений.

Пусть $u\tau/h = 1$. Имеет место совпадение $\lambda(k)$ и $\lambda(\tau, h, k)$, однако этот случай мало интересен для вычислительной практики, поскольку u может меняться в ходе решения задачи. Для проведения дисперсионного анализа схем положим $kh \ll 1$, имея в виду то, что h — малый параметр, а аппроксимация тем лучше, чем

меньше волновое число, т. е. чем более гладким является исследуемое частное решение. Заметим, что для расчетной сетки с шагом h обычно реализуются волновые числа $k \approx 2\pi h^{-1}$.

В таком случае дисперсионное соотношение будет

$$\lambda(\tau, h, k) \approx -iuk - \frac{uhk^2}{2} \left(1 - \frac{u\tau}{h}\right) = \lambda(k) - \frac{k^2}{2}uh(1 - \sigma),$$

$\sigma = u\tau/h$ — число Куранта, а частное решение примет вид

$$\exp(ik(mh - un\tau)) \exp\left(-\frac{1}{2}uk^2(h - u\tau)n\tau\right).$$

Первый сомножитель совпадает с соответствующим частным решением дифференциального уравнения, второй является особенностью разностного решения; его поведение при различных τ, h, k представляет особый интерес. При $u < 0, h - u\tau > 0$, как видно из этого решения, рассматриваемую схему нельзя использовать для проведения расчетов. Второй сомножитель имеет порядок $\exp(k^2|u|ht_n)$, он быстро растет при $k \sim h^{-1}, h \rightarrow 0, \tau \rightarrow 0$. Аналогичная ситуация получается и при $u > 0, h - u\tau < 0$. При $u < 0, h - u\tau > 0$ второй сомножитель затухает с ростом t_n тем быстрее, чем больше k , или чем меньше λ — длина волны частного решения вида $\exp(ikx)$. Таким образом, численное решение, полученное по схеме «уголок», отличается от точного, в котором все гармоники сохраняют амплитуду с ростом t_n , наличием затухающего множителя для гармоник с большими волновыми числами (или малыми длинами волн). Действие этого сомножителя приводит к сглаживанию решений, имеющих разрыв в начальных данных.

Для разностной схемы Лакса–Вендроффа второго порядка

$$(v_{m+1}^{n+1} + v_m^n) - \sigma(v_m^n - v_{m-1}^n) + \frac{\sigma}{2}(v_{m-1}^n - 2v_m^n + v_{m+1}^n) = 0$$

дисперсионное соотношение будет

$$\lambda = \tau^{-1} \ln \left(1 + \sigma(e^{-ikh} - 1) + 2uh(1 - \sigma) \sin^2 \frac{kh}{2} \right),$$

для длинноволновых гармоник с $kh \ll 1$

$$\lambda(\tau, h, k) \approx -iku + i\frac{k^3u}{6}(h^2 - u^2\tau^2) = \lambda(k) + ik^3\frac{uh^2}{6}(1 - \sigma^2).$$

Из полученных соотношений можно сделать следующий вывод. Решения исходного уравнения переноса имеют вид волн с волновым числом k , которые движутся вправо со скоростью u , так как

$$v(t, x) = \exp(ikx + \lambda(k)t) = \exp(ik(x - ut)).$$

Решения разностного уравнения имеют вид

$$\begin{aligned} v(t_n, x_m) &= \exp(ikx_m + \lambda(\tau, h, k)t_n) = \\ &= \exp\left(ik\left\{x_m - u\left[1 - \frac{k^2}{6}(h^2 - u^2\tau^2)\right]t_n\right\}\right) = \\ &= \exp(ik\{x_m - u[1 + U_k(k)]t_n\}), \end{aligned}$$

где введено обозначение

$$U_k = -\frac{k^2}{6}(h^2 - u^2\tau^2).$$

Последнее выражение означает, что разностные решения уже не имеют вид волн, движущихся с одной и той же скоростью. Теперь каждая волна со своей частотой движется с собственной скоростью $u = U_k[1 + u(k)]$. Разумеется, при малых k и скорости u_k мало отличаются от u , но высокочастотные волны движутся со скоростями, заметно отличающимися от скорости переноса. Кроме того, в схеме Лакса–Вендроффа гармоники со временем не затухают, численное решение не сглаживается со временем. Начальный волновой пакет u и определенный им начальный профиль решения изменяются с течением времени из-за рассогласования фаз. Это приводит к потере монотонности профиля $v(x)$, если он был вначале монотонным, и появлению осцилляций разностного происхождения. Появление *сеточной дисперсии* — одно из проявлений эффекта Гиббса, подробнее об эффекте Гиббса см. в [42].

6. Акустическая система описывает распространение плоских звуковых волн. Поставим для нее задачу Коши:

$$\begin{aligned} \frac{\partial u}{\partial t} + \frac{1}{\rho} \frac{\partial p}{\partial x} &= 0, \quad \frac{\partial p}{\partial t} + \rho c^2 \frac{\partial u}{\partial x} = 0, \\ \rho &= \text{const}, \quad c = \text{const}, \\ u(x, 0) &= u_0(x), \quad p(x, 0) = p_0(x), \\ t &> 0, \quad -\infty < x < \infty, \end{aligned}$$

где u — скорость движения среды, p — давление, ρ — плотность среды, c — скорость звука в среде.

- а) Представить акустическую систему в интегральной форме.
- б) Преобразовать акустическую систему к виду системы с разделенными переменными.
- в) Предложить разностную схему первого порядка аппроксимации для ее решения.

Решение.

а) Проинтегрировав акустическую систему по произвольной области с границей G , получим

$$\oint_{\Gamma} \rho u \, dx - p \, dt = 0,$$

$$\oint_{\Gamma} \frac{p}{c^2} \, dx - \rho u \, dt = 0.$$

б) Умножим второе уравнение на $(\rho c)^{-1}$, затем сложим с первым и вычтем из него. Получим систему двух уравнений

$$\frac{\partial}{\partial t} \left(u + \frac{p}{\rho c} \right) + c \frac{\partial}{\partial x} \left(u + \frac{p}{\rho c} \right) = 0$$

$$\frac{\partial}{\partial t} \left(u - \frac{p}{\rho c} \right) - c \frac{\partial}{\partial x} \left(u - \frac{p}{\rho c} \right) = 0,$$

или, после введения обозначений (инвариантов Римана) $R = u + \frac{p}{\rho c}$, $S = u - \frac{p}{\rho c}$, система запишется в виде двух уравнений переноса:

$$\frac{\partial R}{\partial t} + c \frac{\partial R}{\partial x} = 0,$$

$$\frac{\partial S}{\partial t} - c \frac{\partial S}{\partial x} = 0.$$

Эта система позволяет выписать общее решение:

$$R = f(x - ct), \quad S = g(x + ct).$$

Здесь f, g — произвольные непрерывно дифференцируемые функции, определяемые из начальных условий. В терминах инвариантов Римана можно определить и значения естественных

переменных u, p :

$$\begin{aligned} u &= \frac{1}{2} (f(x - ct) + g(x + ct)), \\ p &= \frac{\rho c}{2} (f(x - ct) - g(x + ct)). \end{aligned}$$

Замечательное свойство инвариантов Римана R, S заключается в их постоянстве вдоль прямых $x - ct = \text{const}$ и $x + ct = \text{const}$, или $\frac{dx}{dt} = \pm c$ — характеристик акустической системы.

Если задавать начальные данные $u(x, 0) = \varphi(x)$, $p(x, 0) = \psi(x)$, $-\infty < x < \infty$, то связь начальных данных и инвариантов Римана будет

$$\varphi(x) = \frac{1}{2} (f(x) + g(x)), \quad \psi(x) = \frac{\rho c}{2} (f(x) - g(x)),$$

откуда получим

$$f(x) = \varphi(x) + \frac{\psi(x)}{\rho c}, \quad g(x) = \varphi(x) - \frac{\psi(x)}{\rho c}.$$

Следовательно, решение системы в этом случае

$$\begin{aligned} u(t, x) &= \frac{1}{2} (\varphi(x - ct) + \varphi(x + ct)) + \frac{1}{2\rho c} (\psi(x - ct) + \psi(x + ct)), \\ p(t, x) &= \frac{1}{2} (\varphi(x - ct) + \varphi(x + ct)) - \frac{\rho c}{2} (\psi(x - ct) + \psi(x + ct)). \end{aligned}$$

Для численного решения системы, записанной в инвариантах Римана, можно применить схему Куранта–Изаксона–Риса:

$$\begin{aligned} \frac{R_m^{n+1} - R_m^n}{\tau} + c \frac{R_m^{n+1} - R_{m-1}^n}{h} &= 0, \\ \frac{S_m^{n+1} - S_m^n}{\tau} - c \frac{S_{m+1}^n - S_m^n}{h} &= 0, \end{aligned}$$

или

$$\begin{aligned} R_m^{n+1} &= (1 - \sigma) R_m^n + \sigma R_{m-1}^n, \\ S_m^{n+1} &= (1 + \sigma) S_m^n - \sigma S_{m+1}^n. \end{aligned}$$

Известно, что данная схема имеет первый порядок аппроксимации и является устойчивой при выполнении условия КФЛ: $\sigma\tau/h \leq 1$.

7. Заменить смешанную задачу для волнового уравнения

$$\frac{\partial^2 u}{\partial t} = c^2 \frac{\partial^2 u}{\partial x^2} + f(t, x), \quad 0 < t \leq T, \quad 0 < x < X, \quad u(0, x) = \varphi_1(x),$$

$$\frac{\partial u(0, x)}{\partial t} = \varphi_2(x), \quad 0 < x < X, \quad u(t, 0) = \varphi_3(t), \quad u(t, X) = \varphi_4(t), \quad 0 \leq t \leq T$$

эквивалентной ему парой уравнений в частных производных первого порядка.

Р е ш е н и е. Введем новые переменные

$$v(t, x) = \int_0^x \frac{\partial u(t, \eta)}{\partial t} d\eta, \quad F(t, x) = \int_0^x f(t, \eta) d\eta.$$

Функции $u(t, x)$, $v(t, x)$, что несложно проверить, удовлетворяют акустической системе уравнений

$$\frac{\partial u}{\partial t} - \frac{\partial v}{\partial x} = 0,$$

$$\frac{\partial v}{\partial t} - c^2 \frac{\partial u}{\partial x} = F(t, x),$$

$$u(0, x) = \varphi_1(x), \quad v(0, x) = \int_0^x \varphi_2(\eta) d\eta,$$

$$u(t, 0) = \varphi_3(t), \quad u(t, X) = \varphi_4(t).$$

Введем в рассмотрение параметрическую схему для численного решения этой системы:

$$\frac{u_{m+1}^{n+1} - u_m^n}{\tau} = \frac{c^2}{h} \left\{ \xi_1 (v_{m+1}^{n+1} - v_m^{n+1}) + (1 - \xi_1) (v_{m+1}^n - v_m^n) \right\} + F_{m+1/2}^{n+1/2},$$


$$\frac{v_m^{n+1} - v_m^n}{\tau} = \frac{1}{h} \left\{ \xi_2 (u_m^{n+1} - u_{m-1}^{n+1}) + (1 - \xi_2) (u_m^n - u_{m-1}^n) \right\},$$

$$0 \leq \xi_1, \quad \xi_2 \leq 1.$$

Исследование полученной двухпараметрической разностной схемы на спектральную устойчивость дает условия устойчивости: $\xi_1 + \xi_2 \geq 1$, $\sigma^2 (2\xi_1 - 1) (2\xi_2 - 1) \geq -1$, $\sigma = c\tau/h$. Отсюда видно, что если $\xi_1 \geq 0.5$ и $\xi_2 \geq 0.5$, то схема устойчива при любых числах Куранта и сеточных параметрах; если $\xi_1 + \xi_2 \geq 1$, но один из параметров меньше 0.5, то схема условно устойчива при $\tau \leq \frac{h}{c} (2\xi_1 - 1)^{-1} (2\xi_2 - 1)^{-1}$. Пусть $\xi_1 = \xi_2 = 0.5$. Тогда полученная

схема является безусловно устойчивой и обладает вторым порядком аппроксимации по обоим переменным.

8. Исследовать на сходимость схему «крест» с шаблоном



для численного решения волнового уравнения

$$\frac{\partial^2 u}{\partial t^2} - \frac{\partial^2 u}{\partial x^2} = 0.$$

Решение. Запишем разностную схему:

$$\mathbf{L}_\tau u_\tau = \frac{u_m^{n+1} - 2u_m^n + u_m^{n-1}}{\tau^2} - \frac{u_{m-1}^n - 2u_m^n + u_{m+1}^n}{h^2} = 0.$$

Исследование на аппроксимацию дает выражение для главного члена невязки

$$r_\tau = \frac{\tau^2}{12} u_t^{(4)} - \frac{h^2}{12} u_x^{(4)} + O(\tau^2, h^2).$$

Схема имеет второй порядок аппроксимации. Исследуем схему на устойчивость по спектральному признаку. Для спектра оператора послойного перехода получается

$$\lambda^2 - 2\left(1 - 2\sigma^2 \sin^2 \frac{\alpha}{2}\right)\lambda + 1 = 0,$$

$\sigma = \tau/h$ — число Куранта.

По теореме Виета произведение корней $\lambda_1 \lambda_2 = 1$, и условие устойчивости выполняется, если $|\lambda_1| = |\lambda_2| = 1$. Для полученного квадратного уравнения с действительными коэффициентами это означает, что его корни являются комплексно сопряженными. Это возможно лишь в случае, если дискриминант

$$D(\alpha) = 4\sigma^2 \sin^2 \alpha \left(\sigma^2 \sin^2 \frac{\alpha}{2} - 1 \right)$$

будет отрицательным. Условие устойчивости будет выполнено для всех гармоник, если $\sigma < 1$.

Библиографический комментарий к Лекции 13

Численное решение систем нелинейных уравнений в частных производных — актуальная задача, к таким уравнениям относятся не только хорошо известные физические модели (sin-Гордон или уравнение Кортевега–де Фриза), но и уравнения механики сплошной среды, газовой динамики, магнитной гидродинамики, теории упругости.

Среди литературы по теме отметим несколько книг. О свойствах квазилинейных систем гиперболического типа рекомендуем классическую работу [44]. В [45] исследованы свойства многих разностных схем методами дифференциального приближения. Изложение в § 13.3 в основном следует [45]. Основы численных методов газовой динамики с упором на консервативные разностные схемы (для которых на сеточном уровне выполняются аналогии тех законов сохранения, которые есть в дифференциальной постановке задачи), описаны в [46]. Теорема С. К. Годунова доказана в [47]. Об осцилляциях как проявлениях явления Гиббса см. книгу [42]. О гибридных схемах, предложенных Р. П. Федоренко, см. [2].

Сеточно-характеристические методы для решения задач гиперболического типа подробно описаны в [43]. Конкретные разностные схемы применительно к уравнениям гиперболического типа (газовой динамики, мелкой воды, магнитной газовой динамики и др.) описаны в [48] — по-видимому, самой фундаментальной русскоязычной работе на сегодняшний день. Отметим, что многие численные методы для задач газовой динамики развивались в научной школе О. М. Белоцерковского, они подробно описаны в [49].

ЧИСЛЕННОЕ РЕШЕНИЕ УРАВНЕНИЙ В ЧАСТНЫХ ПРОИЗВОДНЫХ ЭЛЛИПТИЧЕСКОГО ТИПА НА ПРИМЕРЕ УРАВНЕНИЙ ЛАПЛАСА И ПУАССОНА

В лекции разбираются постановка простейшей разностной задачи для уравнений Лапласа и Пуассона в прямоугольной области (схема «крест»). Дается обзор методов решения сеточных уравнений. Вкратце описываются идеи современных методов решения эллиптических уравнений в области произвольной геометрии — многосеточный метод и метод построения мажорантных разностных схем в пространстве неопределенных коэффициентов.

Ключевые слова: схема крест, разностный принцип максимума, методы решения сеточных уравнений, метод простых итераций, чебышёвский набор параметров, методы Якоби, Зейделя, верхней релаксации, трехслойный итерационный метод, метод переменных направлений, коэффициенты Фурье, попеременно-треугольный итерационный метод, многосеточный метод Р. П. Федоренко, мажорантные разностные схемы.

Среди всех типов уравнений математической физики эллиптические уравнения с точки зрения вычислителей стоят особняком. С одной стороны, имеется хорошо развитая теория решения эллиптических уравнений и систем. Достаточно легко доказываются теоремы об устойчивости разностных схем для эллиптических уравнений. Во многих случаях получаются априорные оценки точности расчетов и числа итераций при решении возникающих систем сеточных уравнений. С другой стороны, системы сеточных уравнений, возникающие при решении уравнений методами сеток, имеют большую размерность и плохо обусловлены. Для решения таких систем разработаны специальные итерационные методы.

14.1. Постановка задачи. Простейшая разностная схема «крест». Устойчивость схемы «крест»

Будем рассматривать двумерное уравнение Пуассона

$$\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = f(x, y)$$

в единичном квадрате $0 \leq x \leq 1$, $0 \leq y \leq 1$ с краевыми условиями первого рода на границе расчетной области Γ :

$$u_{\Gamma} = \varphi$$

(φ — заданная на границе функция).

В случае прямоугольной области граничные условия удобно записать в следующем виде:

$$u(0, y) = \varphi_1(y),$$

$$u(1, y) = \varphi_2(y),$$

$$u(x, 0) = \varphi_3(x),$$

$$u(x, 1) = \varphi_4(x).$$

Для простоты выкладок введем равномерную расчетную сетку с узлами $\{x_m, y_l\}$, $m, l = 0, 1, \dots, M$ с равным количеством шагов по каждому пространственному направлению, сеточную область D — совокупность всех узлов сетки, включая граничные, и сеточную функцию u_{ml} . В этом случае шаги по координатам предполагаются равными. В случае неравных шагов по каждому направлению полученные результаты не изменятся, а запись уравнений станет более громоздкой.




Рис. 14.1

Выбираем простейший пятиточечный шаблон разностной схемы «крест» (рис. 14.1). На этом шаблоне аппроксимирующее разностное уравнение легко выписать. Для этого производные заменим вторыми разностями:

$$\frac{u_{m-1,l} - 2u_{ml} + u_{m+1,l}}{h^2} + \frac{u_{m,l-1} - 2u_{ml} + u_{m,l+1}}{h^2} = f_{ml},$$

где h — шаг по координатам, или в операторной форме

$$\Lambda_1 u_{ml} + \Lambda_2 u_{ml} = f_{ml},$$

здесь

$$\Lambda_1 u_{ml} = \frac{u_{m-1,l} - 2u_{ml} + u_{m+1,l}}{h^2},$$

$$\Lambda_2 u_{ml} = \frac{u_{m,l-1} - 2u_{ml} + u_{m,l+1}}{h^2},$$

$$u_{0l} = \varphi_1(y_l), \quad u_{m0} = \varphi_3(x_m), \quad u_{ml} = \varphi_2(y_l), \quad u_{mM} = \varphi_4(x_m).$$

Эту же разностную схему можно записать в каноническом виде для разностных схем для эллиптических уравнений:

$$u_{ml} = \frac{1}{4}(u_{m-1,l} + u_{m+1,l} + u_{m,l-1} + u_{m,l+1}) + h^2 f_{ml}.$$

Такую каноническую запись не следует путать с канонической формой записи итерационного метода, которая встретится ниже.

Схема обладает вторым порядком аппроксимации по обоим координатам. Это легко показать, применяя разложение в ряд Тейлора функции — проекции точного решения на сетку — вплоть до членов четвертого порядка включительно. Проведем разложение для одного из операторов, стоящих в данном разностном уравнении:

$$\Lambda_1 u_m = \frac{u_{m-1} - 2u_m + u_{m+1}}{h^2} = \left(\frac{\partial^2 u}{\partial x^2} \right)_m + \frac{h^2}{12} \left(\frac{\partial^4 u}{\partial x^4} \right)_m + O(h^4).$$

Здесь учтено разложение проекции точного решения в ряд Тейлора

$$\begin{aligned} u_{m+1} = u(x_{m+1}) &= u_m + h \left(\frac{\partial u}{\partial x} \right)_m + \frac{h^2}{2!} \left(\frac{\partial^2 u}{\partial x^2} \right)_m + \\ &+ \frac{h^3}{3!} \left(\frac{\partial^3 u}{\partial x^3} \right)_m + \frac{h^4}{4!} \left(\frac{\partial^4 u}{\partial x^4} \right)_m + \frac{h^5}{5!} \left(\frac{\partial^5 u}{\partial x^5} \right)_m + O(h^6) \end{aligned}$$

и аналогичное разложение для u_{m-1} . Для рассматриваемого двумерного уравнения получим выражение для главного члена невязки

$$\Lambda_1 u_{ml} + \Lambda_2 u_{ml} = \left[\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right]_{ml} + \frac{h^2}{12} \left[\frac{\partial^4 u}{\partial x^4} + \frac{\partial^4 u}{\partial y^4} \right]_{ml} + O(h^4).$$

Рассмотрим устойчивость полученной схемы. Отметим, что методы исследования на устойчивость, применяемые для эволюционных (зависящих от времени) уравнений, здесь не работают. Действовать приходится на основе определения устойчивости.

Сформулируем и докажем две леммы, которые облегчат процедуру доказательства устойчивости разностной схемы.

Лемма 14.1. Пусть сеточная функция u_{ml} определена на сетке (x_m, y_l) ($m, l = 0, \dots, M$) и во всех внутренних узлах сетки удовлетворяет уравнению

$$\frac{u_{m-1,l} - 2u_{ml} + u_{m+1,l}}{h^2} + \frac{u_{m,l-1} - 2u_{ml} + u_{m,l+1}}{h^2} = f_{ml},$$

причем во всех внутренних узлах сетки правая часть этого уравнения неотрицательная: $f_{ml} \geq 0$. Тогда наибольшее значение сеточная функция u_{ml} достигает хотя бы в одной точке границы сеточной области.

Доказательство. Предположим, что существует такая внутренняя точка области, в которой сеточная функция принимает наибольшее значение. Пусть это точка с индексами i, j . Перепишем разностное уравнение, несколько перегруппировав члены в левой части:

$$\frac{1}{h^2} ((u_{i-1,j} - u_{ij}) + (u_{i+1,j} - u_{ij}) + (u_{i,j-1} - u_{ij}) + (u_{i,j+1} - u_{ij})) = f_{ij}.$$

В силу сделанного предположения, хотя бы одна из скобок в левой части отрицательна, а остальные неположительны. Тогда в левой части стоит отрицательное число, в то время как в правой — положительное (по условиям леммы). Получившееся противоречие возникло из-за предположения о том, что максимальное значение сеточная функция принимает во внутренней точке сеточной области. Лемма доказана. $\square$

Лемма 14.2. Пусть сеточная функция u_{ml} определена на сетке (x_m, y_l) ($m, l = 0, \dots, M$) и во всех внутренних узлах сетки удовлетворяет уравнению

$$\frac{u_{m-1,l} - 2u_{ml} + u_{m+1,l}}{h^2} + \frac{u_{m,l-1} - 2u_{ml} + u_{m,l+1}}{h^2} = f_{ml},$$

причем во всех внутренних узлах сетки правая часть этого уравнения неположительная: $f_{ml} \leq 0$. Тогда наименьшее значение

ние сеточная функция u_{ml} достигает хотя бы в одной точке границы сеточной области.

Доказательство от противного практически повторяет доказательство предыдущей леммы.

Лемма 14.3 (сеточный принцип максимума). Каждое решение разностного уравнения Лапласа

$$\frac{u_{m-1,l} - 2u_{ml} + u_{m+1,l}}{h^2} + \frac{u_{m,l-1} - 2u_{ml} + u_{m,l+1}}{h^2} = 0$$

достигает своего минимального и максимального значения на границе сеточной области.

Доказательство очевидно — это объединение утверждений леммы 1 и леммы 2.

Введем норму сеточной функции как

$$\|u_{ml}\| = \max_{m,l \in D} |u_{ml}|.$$

Для доказательства устойчивости теперь надо доказать однозначную разрешимость разностной задачи для уравнения Пуассона с любой правой частью и любыми граничными условиями, получить оценку

$$\|u_{ml}\| \leq C \|f\|.$$

Здесь в правой части стоит норма правой части задачи, записанной в операторном виде,

$$\|f\| = \max_{m,l \in D} |f_{ml}| + \max_{m,l \in \partial D} |\varphi_{ml}|.$$

Первый максимум в этой сумме берется по всем внутренним точкам, второй — по всем точкам сеточной границы.

Докажем однозначную разрешимость разностной задачи. Рассмотрим сеточное уравнение Лапласа с нулевыми граничными условиями. В силу принципа максимума такая задача имеет лишь тривиальное решение. Но сеточная система — это система линейных уравнений. Если система с нулевой правой частью имеет лишь тривиальное решение, то она однозначно разрешима при любой правой части.

Заметим, что в точной арифметике действие разностного оператора, приближающего дифференциальный оператор Лапласа, на

произвольный полином второй степени совпадает по результату с действием дифференциального оператора — погрешность аппроксимации, как следует из приведенной выше оценки, будет нулевая. Рассмотрим вспомогательную функцию

$$P^h = \frac{1}{4} [R^2 - (x^2 + y^2)] \max_{m, l \in D} |f_{ml}| + \max_{m, l \in \partial D} |\varphi_{ml}|,$$

где R — радиус окружности с центром в точке $(0, 0)$ и включающей в себя рассматриваемую область. В данном случае $R = \sqrt{2}$. Эта функция иногда называется мажорантой Гершгорина.

Индекс h означает, что рассматривается сеточная проекция мажоранты. Обратимся к сеточной функции $w_{ml} = u_{ml} - P_{ml}^h$ и применим к ней разностный оператор Лапласа. Получим

$$\Lambda_1 w_{ml} + \Lambda_2 w_{ml} = f_{ml} + \max_{m, l \in D} |f_{ml}|$$

во всех внутренних точках области. Отсюда следует, что свое наибольшее значение рассматриваемая сеточная функция достигает на границе сеточной области в соответствии с доказанной леммой 14.1. Но, как легко убедиться, на границе области сеточная функция $w_{ml} = u_{ml} - P_{ml}^h$ принимает только отрицательные значения. Тогда $u_{ml} - P_{ml}^h \leq 0$ во всех точках сеточной области, включая граничные.

Рассмотрим сеточную функцию $v_{ml} = u_{ml} + P_{ml}^h$. Проведя такие же рассуждения, придем к неравенству $u_{ml} + P_{ml}^h \geq 0$ во всех точках сеточной области, включая граничные.

Объединяя полученные результаты, находим

$$|u_{ml}| \leq |P_{ml}^h| \leq \frac{1}{4} R^2 \max_{m, l \in D} |f_{ml}| + \max_{m, l \in \partial D} |\varphi_{ml}|,$$

откуда следует неравенство $\|u_{ml}\| \leq \max(1, R^2/4) \|f\|$. Таким образом, устойчивость самой разностной схемы доказана.

14.2. Методы решения сеточных уравнений

При решении эллиптических систем существенная часть вычислительной работы — решение возникающих сеточных уравнений. Фактически для нахождения сеточной функции решения надо по-

лучить решение системы линейных уравнений большой размерности с разреженной матрицей специального вида. При аппроксимации уравнения Лапласа или Пуассона на регулярных сетках матрица системы самосопряженная. Методы решения таких систем рассмотрим ниже. Перед чтением данного раздела рекомендуется посмотреть лекцию 2.

14.2.1. Метод простых итераций. Наиболее эффективные алгоритмы для численного решения полученной СЛАУ — итерационные. Действительно, прямые методы требуют вычисления обратной матрицы, обратная матрица получается заполненной. Пусть u_{ml}^0 — начальное приближение, выбирать которое желательно как можно ближе к искомому решению, $u_{ml}^1, u_{ml}^2, \dots$ — последующие приближения. Верхний индекс в данных обозначениях указывает номер итерации.

Если выполняется условие

$$\|u_{ml}^i - u_{ml}\| \rightarrow 0,$$

где u_{ml} — проекция точного решения на сетку, то итерационный метод является сходящимся. Оценка сходимости при этом может быть получена в виде

$$\|u_{ml}^{i+1} - u_{ml}^i\| \leq cq^i,$$

где c — константа, $0 < q < 1$. Итерации продолжаются до тех пор, пока не выполнено условие $\|u_{ml}^{i+1} - u_{ml}^i\| \leq \varepsilon$, где ε — заданная точность. В таком случае можно оценить количество итераций, необходимое для достижения этой точности $i \approx [\ln(\varepsilon/c)/\ln q] + 1$. Квадратные скобки в этой записи — операция взятия целой части числа.

Метод простых итераций записывается для системы сеточных уравнений в следующем виде: $u_{ml}^{i+1} = u_{ml}^i + \tau(\Lambda u_{ml}^i - f_{ml})$, если точка принадлежит внутренней части сеточной области, и $u_{ml}^i = \varphi_{ml}$, если точка с индексами ml принадлежит границе сеточной области. Здесь $\Lambda = \Lambda_1 + \Lambda_2$, τ — итерационный параметр. Количество арифметических операций при реализации метода простых итераций $\sim O(N^2)$.

Величина $e_{ml}^i = u_{ml}^i - u_{ml}$ называется итерационной погрешностью. Кроме нее существенную роль играет другая величина — $r_{ml}^i = \Lambda u_{ml}^i - f_{ml} = \Lambda u_{ml}^i - \Lambda u_{ml} = \Lambda e_{ml}^i$, называемая невяз-

кой. Итерационную погрешность мы можем только оценить (точное решение системы нам неизвестно). Невязку на каждой итерации нам все равно приходится вычислять для выполнения следующей итерации. Конечно, при решении систем сеточных уравнений в первую очередь нас интересует убывание погрешности. Но, как мы увидим ниже, темпы убывания погрешности и невязки одинаковы. На практике значительно легче следить именно за невязкой.

Получим формулу для эволюции погрешности. Вычтем из итерационной формулы $\mathbf{u}_{ml}^{i+1} = \mathbf{u}_{ml}^i + \tau(\Lambda \mathbf{u}^i - \mathbf{f})_{ml}$ очевидное тождество $\mathbf{u}_{ml} = \mathbf{u}_{ml} + \tau(\Lambda \mathbf{u} - \mathbf{f})_{ml}$ во внутренних точках, а из равенства $\mathbf{u}_{ml}^{i+1} = \mathbf{u}_{ml}^i$ вычтем тождество $\mathbf{u}_{ml} = \mathbf{u}_{ml}$ в граничных узлах.

Отсюда для итерационной погрешности $\mathbf{e}_{ml}^{i+1} = \mathbf{e}_{ml}^i + \Lambda \mathbf{e}_{ml}^i$. Теперь проделаем те же действия, только предварительно правые и левые части всех равенств умножим на матрицу — сеточный оператор Лапласа.

Тогда получим $\mathbf{r}_{ml}^{i+1} = \mathbf{r}_{ml}^i + \tau \Lambda \mathbf{r}_{ml}^i$, $\mathbf{r}_{ml}^{i+1} = 0$ во внутренних и граничных узлах соответственно.

В таком случае для сеточной функции невязки r_{ml} , равной нулю на границе, ее эволюция описывается уравнением

$$r_{ml}^{i+1} = (\mathbf{E} + \tau \Lambda) r_{ml}^i.$$

Для оценки сходимости итерационного процесса необходимо перейти к неравенству для норм, например евклидовых, и оценить норму оператора перехода

$$\|\mathbf{r}_{ml}^{i+1}\| \leq \|\mathbf{E} + \tau \Lambda\| \|\mathbf{r}_{ml}^i\|,$$

откуда получим

$$\|\mathbf{r}_{ml}^i\| \leq \|\mathbf{E} + \tau \Lambda\|^i \|\mathbf{r}_{ml}^0\|.$$

Наиболее простым для этих целей является метод Фурье (или спектральный анализ оператора перехода).

Непосредственной проверкой доказываются два следующих утверждения. Семейство функций $\varphi_m^p = \sin\left(\frac{mp\pi}{M}\right)$ являются собственными функциями оператора Λ_1 ; им соответствуют собственные значения $\lambda^p = \frac{4}{h^2} \sin^2\left(\frac{p\pi}{2M}\right)$. Здесь p — номер собственного значения (собственной функции), m — номер сеточного узла; $p = 1, \dots, M-1$. Для этого необходимо непосредственной подстановкой убедиться в истинности равенства

$$\Lambda_1 \varphi_m^p = -\lambda^p \varphi_m^p,$$

или

$$\frac{1}{h^2} \left[\sin \frac{(m-1)p\pi}{M} - 2 \sin \frac{mp\pi}{M} + \sin \frac{(m+1)p\pi}{M} \right] = \left(-\frac{4}{h^2} \sin^2 \frac{p\pi}{2M} \right) \sin \frac{mp\pi}{M}.$$

Величина в скобках — p -е собственное число оператора.

Семейство функций $\Psi_{ml}^{pq} = \varphi_m^p \varphi_l^q$ является собственными функциями оператора $\mathbf{\Lambda}$, соответствующие собственные значения есть

$$\lambda^{pq} = \frac{4}{h^2} \left(\sin^2 \frac{p\pi}{2M} + \sin^2 \frac{q\pi}{2M} \right).$$

Равенство $\mathbf{\Lambda} \Psi_{ml}^{pq} = -\lambda^{pq} \Psi_{ml}^{pq}$ также проверяется непосредственной подстановкой.

В дальнейшем необходимо будет знать границы спектра $\lambda_{\min} = \lambda^1 = l = \frac{4}{h^2} \sin^2 \frac{\pi}{2M} \approx \pi^2$, так как $M \gg 1$, $h = 1/M$,

$$\lambda_{\max} = \lambda^{(M-1)} = L = \frac{4}{h^2} \sin^2 \frac{(M-1)\pi}{2M} \approx \frac{4}{h^2} \sin^2 \frac{\pi}{2} = \frac{4}{h^2} = 4M^2.$$

Для λ^{pq} имеем $l \leq \lambda^{pq} \leq L$, где $l \approx 2\pi^2$, $L \approx 8/h^2 = 8M^2$. Легко также оценить число обусловленности системы сеточных уравнений.

14.2.2. Метод простых итераций с оптимальным параметром. Представим сеточную функцию r_{ml}^0 , равную нулю на границе, в виде разложения по базису из собственных функций разностного оператора (Ψ_{ml}^{pq} — собственные функции оператора $\mathbf{\Lambda}$)

$$r_{ml}^0 = \sum_{pq} c_{pq} \Psi_{ml}^{pq}, \quad c_{pq} = (r_{ml}^0, \Psi_{ml}^{pq}),$$

при этом выполняется равенство Парсеваля

$$\|r^0\| = (\mathbf{r}^0, \mathbf{r}^0)^{1/2} = \sqrt{\sum_{pq} c_{pq}^2} = \|c\|.$$

Далее, используя это разложение, получим

$$\begin{aligned} \mathbf{r}^1 &= (\mathbf{E} + \tau \mathbf{\Lambda}) \mathbf{r}^0 = (\mathbf{E} + \tau \mathbf{\Lambda}) \sum_{pq} c_{pq} \Psi^{pq} = \\ &= \sum_{pq} c_{pq} (\mathbf{E} + \tau \mathbf{\Lambda}) \Psi^{pq} = \sum_{pq} c_{pq} (1 - \tau \lambda^{pq}) \Psi^{pq}. \end{aligned}$$

Здесь используется то, что $1 - \tau\lambda^{pq}$ являются собственными числами оператора $\mathbf{E} + \tau\mathbf{A}$. Легко получается оценка нормы этой сеточной функции на первой итерации:

$$\|\mathbf{r}^1\| = \sqrt{\sum c_{pq}^2 (1 - \tau\lambda^{pq})^2} \leq \max_{\lambda \in [l, L]} |1 - \tau\lambda| \sqrt{\sum c_{pq}^2} = \max_{\lambda \in [l, L]} |1 - \tau\lambda| \|\mathbf{r}^0\|.$$

Для последовательности итераций также легко получается стандартная оценка нормы

$$\|\mathbf{r}^i\| \leq \left(\max_{\lambda \in [l, L]} |1 - \tau\lambda| \right)^i \|\mathbf{r}^0\|.$$

Отсюда видно, что значение q вычисляется как

$$\max\{|1 - \tau l|, |1 - \tau L|\},$$

а условие сходимости $q < 1$ выполняется при $0 < \tau < 2/L$. Границы спектра разностного оператора уже оценены в предыдущем пункте.

Для определения параметра τ , обеспечивающего максимальную скорость сходимости, необходимо решать следующую оптимизационную задачу:

$$\min_{\tau} \left(\max_{\lambda \in [l, L]} |1 - \tau\lambda| \right).$$

Так как $\max |1 - \tau\lambda|$ достигается на правой или левой границе интервала $[l, L]$, то выполняется равенство

$$\max_{\lambda \in [l, L]} |1 - \tau\lambda| = \max\{|1 - \tau l|, |1 - \tau L|\}.$$

В таком случае необходимо определить τ , при котором достигается $\min_{\tau} \{\max(|1 - \tau l|, |1 - \tau L|)\}$, или $\tau_0 = \arg[\min_{\tau} \max(|1 - \tau l|, |1 - \tau L|)]$, где τ_0 — оптимальный итерационный параметр.

Как показано на рис. 14.2, $\min_{\tau} \max(|1 - \tau l|, |1 - \tau L|)$ достигается при $|1 - \tau l| = |1 - \tau L|$. Справа от точки B при любых τ максимальна функция $|1 - \tau L|$, слева — функция $|1 - \tau l|$, и тогда минимум от искомого максимума достигается в точке B . Отсюда получим $1 - \tau l = -(1 - \tau L)$. Следовательно, значение оптимального итерационного параметра τ_0 равно $\tau_0 = 2/(l + L)$.




Рис. 14.2

Оптимальное значение функции, отвечающей за скорость сходимости, будет

$$\begin{aligned} q_0 = q(\tau_0) &= 1 - \tau_0 l = 1 - \frac{2}{L+l} l = \frac{L-l}{L+l} = \\ &= \frac{1 - \mu^{-1}}{1 + \mu^{-1}} = \frac{1 + \mu^{-1} - 2\mu^{-1}}{1 + \mu^{-1}} \approx 1 - 2\mu^{-1}, \end{aligned}$$

где $\mu = L/l$ — число обусловленности системы сеточных уравнений.

Количество итераций, соответствующее этому методу, легко оценивается:

$$i = \left\lceil \frac{\ln \varepsilon}{\ln q} \right\rceil + 1 = \left\lceil \frac{\ln \varepsilon}{\ln(1 - 2l/L)} \right\rceil + 1 \approx \left\lceil \frac{\ln \varepsilon}{(-2l/L)} + 1 \right\rceil \approx \left\lceil \frac{L}{2l} \ln \varepsilon^{-1} + 1 \right\rceil.$$

Пусть расчеты приводятся с точностью $\varepsilon = 10^{-5}$ на сетке 100×100 , тогда оценка числа итераций при $l \approx 2\pi^2$ и $L = 8N^2$ дает $i \approx \frac{8N^2}{2 \cdot 2\pi^2} \ln 10^5 \approx 2 \cdot 10^4$ итераций.

Показатель сходимости $q_0 = 1 - 2\mu^{-1} \approx 0.9995$. Параметр $\mu = L/l$ — число обусловленности матрицы (см. Лекцию 2); чем оно больше, тем медленнее сходятся итерации.

Таким образом, доказана следующая теорема.

Теорема 14.1. Рассмотрим итерационный метод $u_{ml}^{i+1} = u_{ml}^i + \tau(\Lambda u_{ml}^i - f_{ml})$ с оператором $\Lambda = \Lambda^* > 0$ для численного

решения разностного аналога уравнения Пуассона

$$\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = f(x, y)$$

с помощью аппроксимирующей его разностной схемы

$$\Lambda u_{ml} = f_{ml}.$$

Пусть l и L — минимальное и максимальное собственные числа оператора Λ соответственно.

Если итерационный параметр τ удовлетворяет условию $0 < \tau < 2/L$, то последовательность итераций u^i сходится к проекции решения исходного дифференциального уравнения, причем выполнено неравенство $\|v^i\| \leq q^i \|v^0\|$, где параметр $0 < q < 1$ определяется следующим образом:

$$q = \max\{|1 - \tau l|, |1 - \tau L|\}.$$

Параметр q принимает наименьшее значение q_0 при $\tau = \tau_0 = \frac{2}{L+l}$. При этом $q_0 = \frac{1-l/L}{1+l/L} \approx 1 - 2\frac{l}{L}$.

14.2.3. Чебышёвское ускорение метода простых итераций.

Рассмотрим итерационный метод с выбором параметра τ на каждой итерации:

$$u^{i+1} = u^i + \tau_{i+1}(\Lambda u^i - f).$$

Соответствующие соотношения для эволюции невязки имеют вид

$$\begin{aligned} r^{i+1} &= (E + \tau_{i+1}\Lambda)r^i, \\ r^i &= \prod_{j=1}^i (E + \tau_j\Lambda)r^0. \end{aligned}$$

После разложения невязок на двух соседних итерациях по базису из собственных функций сеточного оператора получим равенство

$$\sum c_{pq}^{i+1} \Psi^{pq} = \sum c_{pq}^i (E + \tau_{i+1}\Lambda) \Psi^{pq} = \sum c_{pq}^i (1 - \tau_{i+1} \lambda^{pq}) \Psi^{pq}.$$

Для коэффициентов разложения и компонентов невязки справедливы следующие равенства:

$$\begin{aligned} c_{pq}^{i+1} &= c_{pq}^i (1 - \tau_{i+1} \lambda^{pq}), \\ c_{pq}^i &= \prod_{j=1}^i (1 - \tau_j \lambda^{pq}) c_{pq}^0, \\ \mathbf{r}^i &= \sum c_{pq}^i \Psi^{pq} = \sum_{pq} c_{pq}^0 \prod_{j=1}^i (1 - \tau_j \lambda^{pq}). \end{aligned}$$

Оценим погрешности на i -м шаге итераций:

$$\|\mathbf{r}^i\| \leq \max_{\lambda \in [l, L]} \left| \prod_{j=1}^i (1 - \tau_j \lambda^{pq}) \right| \left\| \sum c_{pq} \Psi^{pq} \right\| \leq \max_{\lambda \in [l, L]} \left| \prod_{j=1}^i (1 - \tau_j \lambda^{pq}) \right| \|\mathbf{r}^0\|.$$

Вновь приходим к минимаксной задаче: найти такую последовательность итерационных параметров $\{\tau_j\}_{j=1}^i$, чтобы выполнялось

$$\min_{\{\tau_j\}} \max_{\lambda \in [l, L]} \left| \prod_{j=1}^i (1 - \tau_j \lambda^{pq}) \right|.$$

Заметим, что $\prod_{j=1}^i (1 - \tau_j \lambda^{pq})$ есть полином (относительно τ) степени i . Задача — сделать его наименее уклоняющимся от нуля на отрезке $[l, L]$. Эта задача, как известно, решена Чебышёвым, а корни этого полинома являются нулями полинома Чебышёва (см. Приложение 2):

$$\tau_j = \left[\frac{L+l}{2} + \frac{L-l}{2} \cos \frac{\pi(2j-1)}{2i} \right]^{-1}, \quad j = 1, 2, \dots, i.$$

Достаточно громоздкие выкладки, которые мы опустим, дают в результате оценку скорости сходимости метода с оптимальным набором параметров $q \approx 1 - 2\sqrt{1/\mu}$ и числа итераций, необходимого для достижения заданной точности, $i \approx \left[(\sqrt{\mu}/2) \ln \varepsilon^{-1} \right] + 1$. Пусть расчеты приводятся с точностью $\varepsilon = 10^{-5}$ на сетке 100×100 , тогда оценка числа итераций и скорости сходимости есть

$q \approx 0.968$, $i \approx 360$. «Цена» каждой итерации — приблизительно $10M^2$ операций.

Однако метод итераций с чебышёвскими параметрами в таком виде оказывается неустойчивым по двум причинам: рост ошибок округления в расчетах и некоторые свойства нулей полиномов Чебышёва, в частности, сгущение τ_k^{-1} — величин, обратных корням полинома, — к границам спектра. Не останавливаясь на доказательстве неустойчивости чебышёвского итерационного процесса, заметим, что для ее устранения необходимо переставить итерационные параметры не в их естественном порядке, а так, чтобы все частичные произведения $\prod_{j=1}^i (1 - \tau_j \lambda)$ не возрастали бы вблизи границ спектра при любом i . Это необходимо, поскольку частичное произведение, относящееся к правой части спектра со сгущающейся чебышёвской сеткой, очень быстро растет из-за больших величин $1 - \tau_j \lambda$. Задача упорядочения итерационных параметров достаточно сложна, ее решение связано с именами В. И. Лебедева, В. П. Финогенова, А. А. Самарского и Е. С. Николаева [50]. Приведем результат ее решения для $i = 2^r$, где i — количество сомножителей в произведении (число итераций) $\prod_{j=1}^i (1 - \tau_j \lambda)$, r — натуральное число.

При $i = 2$ перебираем корни полинома Чебышёва в их естественном порядке (в фигурных скобках указываем номер корня) $\{1, 2\}$ или в порядке убывания номера $\{2, 1\}$. Далее последовательность номеров корней получаем следующим образом. Каждый номер корня меняется на пару чисел: первое число — номер корня, второе дополняет сумму в каждой паре до значения $i + 1(2^r + 1)$. Таким образом, при $i = 4$ получаем два упорядоченных набора. Из последовательности $\{1, 2\}$ получаем $\{1, 4, 2, 3\}$, а из $\{2, 1\}$ — $\{2, 3, 1, 4\}$. Действуя аналогично далее, имеем при $i = 8$ $\{1, 8, 4, 5, 2, 7, 3, 6\}$ в первой последовательности чебышёвских параметров или $\{2, 7, 3, 6, 1, 8, 4, 5\}$ во второй последовательности. Следующий шаг дает $i = 16$ $\{1, 16, 8, 9, 4, 13, 5, 12, 2, 15, 7, 10, 3, 14, 6, 11\}$ в первой последовательности чебышёвских параметров или $\{2, 15, 7, 10, 3, 14, 6, 11, 1, 16, 8, 9, 4, 13, 5, 12\}$ — во второй. Построение таких упорядоченных наборов легко можно продолжить. Приведенное упорядочение является универсальным — оно обеспечивает устойчивость любых методов, где необходим чебышёвский набор итерационных параметров.

Обычно при реализации чебышёвских методов задаются последовательностью из 32 или 64 параметров и делают серию итера-

ций. Если невязка велика, то результат серии используют в качестве начального приближения для следующей серии итераций, если невязка мала, то решение считается найденным. Такая упрощенная реализация работает несколько медленнее, чем «честное» чебышёвское ускорение, но весьма эффективно.

Приведем итерационные формулы трехслойного метода Чебышёва, который не уступает предыдущему по скорости сходимости, однако не требует изменения порядка выбора итерационных параметров. В качестве платы за удобство использования метода затраты памяти становятся несколько большими. Формулы трехслойного метода будут

$$\mathbf{u}^1 = (\mathbf{E} - \tau \mathbf{A}) \mathbf{u}^0 + \tau \mathbf{f},$$

$$\mathbf{u}^{i+1} = \alpha_{i+1} (\mathbf{E} - \tau \mathbf{A}) \mathbf{u}^i + (1 - \alpha_{i+1}) \mathbf{u}^{i-1} + \tau \alpha_{i+1} \mathbf{f}, \quad i = 1, 2, \dots$$

где $\tau = 2/(l + L)$, $\alpha_1 = 2$, $\alpha_{i+1} = 4/(4 - \rho^2 \alpha_i)$, $\rho = (L - l)/(L + l)$. Можно показать, что погрешность r^i удовлетворяет оценке

$$\|\mathbf{r}^i\| \leq \frac{2q^i}{1 + q^{2i}} \|\mathbf{r}^0\|,$$

где $q = \frac{1 - 1/\sqrt{\mu}}{1 + 1/\sqrt{\mu}}$.

Трехслойный метод Чебышёва можно также представить в следующем виде:

$$\mathbf{u}^1 = (\mathbf{E} - \tau \mathbf{A}) \mathbf{u}^0 + \tau \mathbf{f}, \quad \mathbf{u}^{i+1} = \frac{2\gamma_1 \gamma_i}{\gamma_{i+1}} (\mathbf{E} - \tau \mathbf{A}) \mathbf{u}^i - \frac{\gamma_{i-1}}{\gamma_{i+1}} \mathbf{u}^{i-1} + \frac{2\gamma_1 \gamma_i}{\gamma_{i+1}} \tau \mathbf{f},$$

где $i = 1, 2, \dots$, $\tau = 2/(l + 1)$, $\gamma_i = \gamma_i(1/\mu)$, $\gamma_0 = 1$, $\gamma_1 = (\mu + 1)/(\mu - 1)$, $\gamma_{i+1} = 2\gamma_1 \gamma_i - \gamma_{i-1}$.

Трехслойный метод Чебышёва в настоящее время применяется значительно чаще двухслойного при численном решении уравнений эллиптического типа.

Каноническая форма записи трехслойного итерационного метода (к которым и относится приведенный трехслойный метод Чебышёва) есть

$$\mathbf{B} \mathbf{u}^{i+1} = \alpha_{i+1} (\mathbf{B} - \tau_{i+1} \mathbf{A}) \mathbf{u}^i + (1 - \alpha_{i+1}) \mathbf{B} \mathbf{u}^{i-1} + \alpha_{i+1} \tau_{i+1} \mathbf{f},$$

$$\mathbf{B} \mathbf{u}^1 = (\mathbf{B} - \tau_1 \mathbf{A}) \mathbf{u}^0 + \tau_1 \mathbf{f},$$

$$i = 1, 2, \dots$$

Если оператор $\mathbf{B}$ — единичный, то трехслойный итерационный метод называется *явным*, в противном случае — *неявным*. Заметим, что *каноническая форма* записи *двухслойного* итерационного метода имеет вид

$$\mathbf{B} \frac{\mathbf{u}^{i+1} - \mathbf{u}^i}{\tau_{i+1}} + \mathbf{A} \mathbf{u}^i = \mathbf{f}.$$

Если оператор $\mathbf{B}$ — единичный, то двухслойный итерационный метод называется *явным*, в противном случае — *неявным*.

Каноническая форма записи трехслойного итерационного метода получается из двухэтапного итерационного процесса. На первом этапе (предиктор) используется метод

$$\mathbf{B} \frac{\tilde{\mathbf{u}} - \mathbf{u}^i}{\tau_{i+1}} + \mathbf{A} \mathbf{u}^i = \mathbf{f},$$

где $\tilde{\mathbf{u}}$ — промежуточное значение. Второй этап — корректор:

$$\mathbf{u}^{i+1} = \alpha_{i+1} \tilde{\mathbf{u}} + (1 - \alpha_{i+1}) \mathbf{u}^{i-1}.$$

В трехслойных схемах используются два итерационных параметра: τ_i и α_i , причем при $\alpha_i = 1$ трехслойная схема переходит в двухслойную. Рассмотренные методы основываются на следующих свойствах оператора $\mathbf{A}$: самосопряженность ($\mathbf{A} = \mathbf{A}^*$); положительная определенность ($\mathbf{A} > 0$, $0 < l < \lambda_i < L$). Для реализации алгоритма необходимо знание только границ спектра оператора.

14.2.4. Метод переменных направлений. Еще большие успехи при попытках ускорить итерационные методы были достигнуты при использовании методов *переменных направлений*. Можно показать, что решение нестационарной задачи

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} - f,$$

со стационарными граничными условиями $u|_{\Gamma} = \varphi$ будет стремиться к некоторому стационарному пределу при $t \rightarrow \infty$ или при $n \rightarrow \infty$. Здесь n — количество шагов по времени при решении рассматриваемого дифференциального уравнения в частных производных разностным методом. В этом случае итерационный параметр τ играет роль шага по времени, отличие состоит лишь в том, что итерационный параметр не обязан быть малым, хорошая аппроксимация нестационарного уравнения не требуется.

Представим метод *переменных направлений* в следующем виде:

$$\begin{aligned}\frac{\tilde{u}_{ml} - u_{ml}^i}{\tau} &= \Lambda_1 \tilde{u}_{ml} + \Lambda_2 u_{ml}^i - f_{ml}, \\ \frac{u_{ml}^{i+1} - \tilde{u}_{ml}}{\tau} &= \Lambda_1 \tilde{u}_{ml} + \Lambda_2 u_{ml}^{i+1} - f_{ml}.\end{aligned}$$

Уравнение для эволюции погрешности получается, если из приведенных формул вычесть тождество

$$\begin{aligned}\frac{u_{ml} - u_{ml}}{\tau} &= \Lambda_1 u_{ml} + \Lambda_2 u_{ml} - f, \\ \frac{\tilde{r}_{ml} - r_{ml}^i}{\tau} &= \Lambda_1 \tilde{r}_{ml} + \Lambda_2 r_{ml}^i, \quad \frac{r_{ml}^{i+1} - \tilde{r}_{ml}}{\tau} = \Lambda_1 \tilde{r}_{ml} + \Lambda_2 r_{ml}^{i+1}.\end{aligned}$$

Представим r_{ml} и $\tilde{r}_{ml}$ в виде разложения по базису из собственных функций:

$$r_{ml}^i = \sum_{p,q} c_{pq}^i \Psi_{ml}^{pq}; \quad \tilde{r}_{ml} = \sum_{p,q} \tilde{c}_{pq} \Psi_{ml}^{pq}$$

и рассмотрим эволюцию погрешности за одну итерацию. Как и ранее, Ψ^{pq} — собственные векторы разностных операторов Λ_1 и Λ_2 , c_{pq} — коэффициенты Фурье; невязка r_{ml}^i обращается в нуль на границах области интегрирования.

Используя разностное уравнение для $\tilde{r}_{ml}$, представим связь между невязкой на предыдущей итерации и невязкой на промежуточном слое в виде

$$(\mathbf{E} - \tau \Lambda_1) \tilde{r}_{ml} = (\mathbf{E} + \tau \Lambda_2) r_{ml}^i.$$

Используя представление Фурье, получим

$$(\mathbf{E} - \tau \Lambda_1) \sum_{pq} \tilde{c}_{pq} \Psi_{ml}^{pq} = (\mathbf{E} + \tau \Lambda_2) \sum_{pq} c_{pq}^i \Psi_{ml}^{pq},$$

откуда после действия операторов Λ_1 и Λ_2 на суммы, получаем

$$\sum_{pq} \tilde{c}_{pq} (1 + \tau \lambda^p) \Psi^{pq} = \sum_{pq} c_{pq}^i (1 - \tau \lambda^p) \Psi^{pq}.$$

Здесь λ^p и λ^q — собственные значения разностных операторов Λ_1 и Λ_2 ($0 < l \leq \lambda^p$, $0 < \lambda^q \leq L$, $l \approx \pi^2$, $L \approx 4N^2$), N — число шагов

по каждому пространственному измерению рассматриваемой системы разностных уравнений. В силу единственности разложения сеточной функции по базису Ψ^{pq} , получаем соотношение для коэффициентов Фурье

$$\widetilde{c}_{pq} = \frac{1 - \tau\lambda^q}{1 + \tau\lambda^p} c_{pq}^i.$$

Аналогично, после спектрального анализа второго этапа расчета, получим

$$c_{pq}^{i+1} = \frac{1 - \tau\lambda^p}{1 + \tau\lambda^q} \widetilde{c}_{pq} = \frac{1 - \tau\lambda^p}{1 + \tau\lambda^q} \frac{1 - \tau\lambda^q}{1 + \tau\lambda^p} c_{pq}^i.$$

Введем обозначение

$$\mu(\tau) = \max_{\lambda \in [l, L]} \left| \frac{1 - \tau\lambda}{1 + \tau\lambda} \right|,$$

тогда для коэффициентов разложения справедливо неравенство $|c_{pq}^{i+1}| \leq \mu^2(\tau) |c_{pq}^i|$, следовательно, для нормы невязки имеем условие $\|\mathbf{r}^{i+1}\| \leq \mu^2(\tau) \|\mathbf{r}^i\|$, так как

$$\|\mathbf{r}^{i+1}\| = \left\| \sum c_{pq}^{i+1} \Psi^{pq} \right\| \leq \left\| \sum \mu^2 c_{pq}^i \Psi^{pq} \right\| \leq \mu^2 \left\| \sum c_{pq}^i \Psi^{pq} \right\| = \mu^2 \|\mathbf{r}^i\|,$$

поскольку справедливо равенство Парсеваля. Необходимо обеспечить наиболее быструю сходимость, минимизировав коэффициент $\mu(\tau)$.

Найдем оптимальное значение параметра τ , обеспечивающее $\min_{\tau} \mu(\tau)$. Для этого необходимо решить задачу

$$\tau = \arg \left\{ \min_{\tau} \left[\max_{\lambda \in [l, L]} \left| \frac{1 - \tau\lambda}{1 + \tau\lambda} \right| \right] \right\},$$

которая решается так же, как и ранее. Простой графический анализ функции $\left| \frac{1 - \tau\lambda}{1 + \tau\lambda} \right|$ приводит к результату

$$\max_{\lambda \in [l, L]} \left| \frac{1 - \tau\lambda}{1 + \tau\lambda} \right| = \max_{\lambda \in [l, L]} \left\{ \left| \frac{1 - \tau l}{1 + \tau l} \right|, \left| \frac{1 - \tau L}{1 + \tau L} \right| \right\}.$$

Минимум $\mu(\tau)$ достигается, как и в предыдущем случае, при

$$\frac{1 - \tau_0 l}{1 + \tau_0 l} = - \frac{1 - \tau_0 L}{1 + \tau_0 L},$$

откуда сразу получается $2 = 2\tau_0^2 lL$, $\tau_0 = 1/\sqrt{lL}$. Вычислим значение

$$\mu(\tau_0) = \frac{1 - \frac{l}{\sqrt{lL}}}{1 + \frac{l}{\sqrt{lL}}} \approx 1 - 2\sqrt{\frac{l}{L}}.$$

Погрешность за одну двухэтапную итерацию убывает, таким образом, в $q = \mu^2 \approx 1 - 4\sqrt{l/L}$ раз, $l \ll L$. Количество итераций, необходимое для достижения заданной точности, можно оценить как

$$i \approx \frac{\ln \varepsilon^{-1}}{4\sqrt{\frac{l}{L}}} = \frac{1}{4}\sqrt{\frac{L}{l}} \ln \varepsilon^{-1}.$$

Скорость сходимости итерационного процесса для приведенного метода приблизительно такая же, как и для процесса с чебышёвским набором итерационных параметров. Эти результаты могут быть сформулированы в виде теоремы.

Естественным обобщением приведенного итерационного процесса представляется замена одного итерационного параметра τ набором τ_i . Выбор этих параметров приводит к минимаксной задаче

$$\min_{\tau} \left\{ \max_{\lambda \in [l, L]} \prod_{j=1}^i \left| \frac{1 - \tau_j \lambda}{1 + \tau_j \lambda} \right|^2 \right\},$$

решение которой представляется в виде громоздкого алгоритма, который здесь не приводится. Для этого метода имеем оценку числа итераций для достижения заданной точности $i \approx \ln \varepsilon^{-1} \ln(L/l)$.

14.2.5. Методы Якоби, Зейделя, верхней релаксации. Для системы сеточных уравнений, полученных при использовании схемы «крест»

$$\frac{u_{m-1,l} - 2u_{ml} + u_{m+1,l}}{h^2} + \frac{u_{m,l-1} - 2u_{ml} + u_{m,l+1}}{h^2} = f_{ml},$$

запишем итерационный метод Якоби. Расчетные формулы (верхний индекс, как обычно, показывает номер итерации) для этого метода будут

$$\frac{u_{m-1,l}^i - 2u_{ml}^{i+1} + u_{m+1,l}^i}{h^2} + \frac{u_{m,l-1}^i - 2u_{ml}^{i+1} + u_{m,l+1}^i}{h^2} = f_{ml},$$

$m, l = 1, \dots, M-1$, $hM = 1$, с условиями на сеточной границе $u_{ml}^{i+1}|_{\Gamma} = U_{ml}$. Если в явном виде выразить u_{ml}^{i+1} , получим каноническую форму записи сеточного метода, правую часть берем на предыдущей итерации, левую — на текущей:

$$u_{ml}^{i+1} = \frac{1}{4}(u_{m-1,l}^i + u_{m+1,l}^i + u_{m,l-1}^i + u_{m,l+1}^i) + \frac{h^2}{4}f_{ml}.$$

Количество итераций, требуемое для вычисления решения с точностью ϵ , оценивается по формуле

$$i = \frac{2N^2}{\pi^2} \ln \epsilon^{-1}.$$

Метод Зейделя, учитывающий результаты вычислений на $(i+1)$ -й итерации, записывается для рассматриваемого уравнения Пуассона

$$\frac{u_{m-1,l}^{i+1} - 2u_{ml}^{i+1} + u_{m+1,l}^i}{h^2} + \frac{u_{m,l-1}^{i+1} - 2u_{ml}^{i+1} + u_{m,l+1}^i}{h^2} = f_{ml},$$

$m, l = 1, \dots, M-1$, $hM = 1$, с условиями на сеточной границе $u_{ml}^{i+1}|_{\Gamma} = U_{ml}$. Напомним, что хотя метод Зейделя неявный, но его реализация оказывается простой, если правильно установить последовательность вычислений. В каноническом виде формулы для метода Зейделя есть

$$u_{ml}^{i+1} = \frac{1}{4}(u_{m-1,l}^{i+1} + u_{m+1,l}^i + u_{m,l-1}^{i+1} + u_{m,l+1}^i) + \frac{h^2}{4}f_{ml}.$$

Сначала из последнего уравнения, используя граничные условия $u_{01}^{i+1} = U_{01}$ и $u_{10}^{i+1} = U_{10}$, находим u_{11}^{i+1} . Затем, зная u_{11}^{i+1} , можно аналогично найти u_{12}^{i+1} и т.д. Значения сеточной функции вычисляются в следующем порядке изменения индексов: $(1, 1)$, $(1, 2)$, $\dots$, $(1, M-1)$, $(2, 1)$, $(2, 2)$, $\dots$, $(2, M-1)$, $(M-1, 1)$, $(M-1, 2)$, $\dots$, $(M-1, M-1)$. Оценка количества итераций, необходимых для достижения точности ϵ , есть $i \approx (N^2/\pi^2) \ln \epsilon^{-1}$. Метод Зейделя сходится быстрее метода Якоби, однако число итераций также оценивается как $O(N^2) = O(L/l)$. В случае метода *верхней релаксации* система представляется в виде

$$(\mathbf{L} + \mathbf{U} + \mathbf{D})\mathbf{u} = \mathbf{f},$$

где $\mathbf{L}$ и $\mathbf{U}$ — нижняя и верхняя треугольные матрицы с нулевыми диагоналями, $\mathbf{D}$ — диагональная матрица. Вводится параметр $1 < \tau < 2$, и итерационные формулы записываются в виде

$$\mathbf{L}\mathbf{u}^{i+1} + \mathbf{U}\mathbf{u}^i + \mathbf{D}\left[\frac{\mathbf{u}^{i+1}}{\tau} + \left(1 - \frac{1}{\tau}\right)\mathbf{u}^i\right] = \mathbf{f}.$$

При $\tau = 1$ получаем метод Зейделя.

Рассмотрим реализацию метода верхней релаксации для разностной аппроксимации уравнения Пуассона. Перепишав разностную схему в виде

$$\frac{u_{m-1,l} + u_{m,l-1}}{h^2} + \frac{u_{m+1,l} + u_{m,l+1}}{h^2} - \frac{4u_{ml}}{h^2} = f_{ml} u_{ml} = U_{ml},$$

выпишем расчетные формулы для метода релаксаций:

$$\begin{aligned} \frac{u_{m-1,l}^{i+1} + u_{m,l-1}^{i+1}}{h^2} + \frac{u_{m+1,l}^i + u_{m,l+1}^i}{h^2} - \\ - \frac{4}{h^2} \left[\frac{u_{ml}^{i+1}}{\tau} + \left(1 - \frac{1}{\tau}\right) u_{ml}^i \right] = f_{ml}, \quad u_{ml}^{i+1} = U_{ml}. \end{aligned}$$

Последовательность вычислений в методе релаксаций такая же, как и в методе Зейделя. Уравнения представляются в виде

$$u_{m-1,l}^{i+1} + u_{m,l-1}^{i+1} - \frac{4}{\tau} u_{ml}^{i+1} = -(u_{m+1,l}^i + u_{m,l+1}^i) + 4\left(1 - \frac{1}{\tau}\right) u_{ml}^i - h^2 f_{ml},$$

решение u_{ml}^{i+1} вычисляется так же с левого нижнего угла области интегрирования. Основное преимущество метода верхней релаксации перед методом Зейделя состоит в существенном ускорении скорости сходимости при соответствующем выборе параметра τ . Не проводя исследований на сходимость, приведем их окончательный результат. Необходимое количество итераций для достижения точности ε равно $i \approx (2M/\pi) \ln \varepsilon^{-1}$, $h = M^{-1}$. Отметим также, что для реализации этих трех методов не требуется знания спектра задачи. При оптимальном выборе итерационного параметра в методе верхней релаксации знание границ спектра позволяет ускорить сходимость метода.

14.3*. Попеременно-треугольный итерационный метод

При аппроксимации уравнений Пуассона или Лапласа получается система сеточных уравнений

$$\mathbf{A}u = \mathbf{f},$$

без ограничения общности считаем оператор (матрицу системы) самосопряженным и положительно определенным. Сеточный оператор Лапласа самосопряжен (это легко доказать), но отрицателен. Для того чтобы получить систему уравнений с положительным оператором, достаточно правую и левую части системы умножить на -1 . Здесь $\mathbf{A}$ — квадратная матрица размером $N \times N$.

Зададим матрицу $\mathbf{R} = \{r_{ij}\}$:

$$r_{ij} = \begin{cases} a_{ij}, & i > j, \\ \frac{a_{ij}}{2}, & i = j, \\ 0, & i < j. \end{cases}$$

В таком случае $\mathbf{A}$ можно представить в виде суммы двух треугольных матриц $\mathbf{A} = \mathbf{R} + \mathbf{R}^*$. $\mathbf{R}$ и $\mathbf{R}^*$ — нижняя и верхняя треугольные матрицы, а их диагональные элементы совпадают. Далее будем рассматривать систему сеточных уравнений как операторное уравнение в конечномерном евклидовом пространстве (унитарном в комплексном случае).

Попеременно-треугольный итерационный метод (ПТИМ) может быть представлен в каноническом виде

$$\mathbf{B} \frac{u^{i+1} - u^i}{\tau} + \mathbf{A}u^i = f.$$

Здесь $\mathbf{B}$ — самосопряженный положительный оператор (его часто называют оператором предобуславливания). Для рассматриваемого метода оператор предобуславливания представляется в виде произведения

$$\mathbf{B} = (\mathbf{E} + \omega \mathbf{R}^*)(\mathbf{E} + \omega \mathbf{R}),$$

где $\mathbf{E}$ — единичный оператор, ω — параметр (действительное число).

При известных ω и τ значение u_{k+1} находится в два этапа. Сначала вычисляется невязка на итерации $r^i = \mathbf{A}u^i - f$, а затем

решается система матричных уравнений

$$\begin{aligned}(\mathbf{E} + \omega \mathbf{R}^*) \widetilde{\mathbf{u}} &= \mathbf{B} \mathbf{u}^i - \tau \mathbf{r}^i, \\ (\mathbf{E} + \omega \mathbf{R}) \mathbf{u}^{i+1} &= \widetilde{\mathbf{u}}.\end{aligned}$$

Поскольку матрицы $\mathbf{E} + \omega \mathbf{R}^*$ и $\mathbf{E} + \omega \mathbf{R}$ являются треугольными, то эти уравнения решаются значительно проще, чем исходное.

Для формулирования теоремы о ПТИМ введем понятие операторного неравенства: будем полагать, что $\mathbf{A} \leq \mathbf{B}$, если для любой сеточной функции, не равной нулю тождественно, выполнено неравенство

$$((\mathbf{A} - \mathbf{B})\mathbf{u}, \mathbf{u}) \geq 0.$$

Приведем без доказательства следующую теорему.

Теорема 14.2. Пусть $\mathbf{A} = \mathbf{R} + \mathbf{R}^*$ и существуют положительные постоянные δ и Δ , при которых выполнены неравенства

$$\mathbf{A} \geq \delta \mathbf{E}, \quad 4\mathbf{R}^* \mathbf{R} \leq \Delta \mathbf{A}.$$

Пусть также $\omega = \frac{2}{\sqrt{\delta \Delta}}$, $\tau = \frac{2}{\gamma_1 + \gamma_2}$, где $\gamma_1 = \frac{\delta}{2(1 + \sqrt{\frac{\delta}{\Delta}})}$, $\gamma_2 = \frac{\sqrt{\delta \Delta}}{4}$. Тогда двухэтапный итерационный метод

$$\begin{aligned}\mathbf{r}^i &= \mathbf{A} \mathbf{u}^i - \mathbf{f}, \\ (\mathbf{E} + \omega \mathbf{R}^*) \widetilde{\mathbf{u}} &= \mathbf{B} \mathbf{u}^i - \tau \mathbf{r}^i, \\ (\mathbf{E} + \omega \mathbf{R}) \mathbf{u}^{i+1} &= \widetilde{\mathbf{u}}\end{aligned}$$

сходится, причем для его погрешности справедлива оценка

$$\|\mathbf{u}_i - \mathbf{u}\|_A \leq \rho^i \|\mathbf{u}_0 - \mathbf{u}\|_A,$$

где $\rho = \frac{1 - \sqrt{\delta/\Delta}}{1 + 3\sqrt{\delta/\Delta}}$, $\|\mathbf{x}\|_A = \sqrt{(\mathbf{A}\mathbf{x}, \mathbf{x})}$.

В качестве δ можно взять минимальное собственное значение $\lambda_{\min}$ оператора $\mathbf{A}$ либо любую положительную постоянную

$s \leq \lambda_{\min}$. Можно показать, что $\Delta \geq \lambda_{\max}$, $\Delta > \delta$, где $\lambda_{\max}$ — максимальное собственное значение оператора $\mathbf{A}$.

Рассмотрим применение ПТИМ к численному решению уравнения Пуассона (знак минус ставим для удобства записи)

$$-(\mathbf{A}_1 + \mathbf{A}_2)u_{ml} = f_{ml},$$

с нулевыми граничными условиями

$$u_{m0} = u_{mN} = u_{0l} = u_{Nl} = 0.$$

Эта задача может быть представлена как операторное уравнение, где $\mathbf{A}u_{ml} = -(\mathbf{A}_1 + \mathbf{A}_2)u_{ml}$, $m, l = 1, \dots, N-1$. Оператор будет самосопряженным и положительным.

Далее необходимо представить матрицу $\mathbf{A}$ в виде $\mathbf{A} = \mathbf{R} + \mathbf{R}^*$ и определить константы δ и Δ .

Рассмотрим разностную аппроксимацию уравнения Пуассона по схеме «крест», переписав схему в эквивалентном виде

$$\mathbf{A}u_{ml} = \frac{1}{h} \left(\frac{u_{ml} - u_{m-1,l}}{h} + \frac{u_{ml} - u_{m,l-1}}{h} \right) - \frac{1}{h} \left(\frac{u_{m+1,l} - u_{ml}}{h} + \frac{u_{m,l+1} - u_{ml}}{h} \right).$$

Тем самым мы представили оператор $\mathbf{A}$ как сумму двух операторов $\mathbf{A} = \mathbf{R} + \mathbf{U}$, где

$$\mathbf{R}u_{ml} = \frac{1}{h} \left(\frac{u_{ml} - u_{m-1,l}}{h} + \frac{u_{ml} - u_{m,l-1}}{h} \right),$$

$$\mathbf{R}^*u_{ml} = -\frac{1}{h} \left(\frac{u_{m+1,l} - u_{ml}}{h} + \frac{u_{m,l+1} - u_{ml}}{h} \right).$$

При этом матрица оператора $\mathbf{R}$ является нижней треугольной, а матрица $\mathbf{R}^*$ — верхней треугольной (в этом легко убедиться, записав рассматриваемую систему в виде СЛАУ). Можно также показать, что оператор $\mathbf{U}$ является сопряженным оператором к $\mathbf{R}$, т. е. $\mathbf{A} = \mathbf{R} + \mathbf{R}^*$.

Также показывается, что

$$\delta = \frac{8}{h^2} \sin^2 \frac{\pi h}{2} = \lambda_{\min}(\mathbf{A}), \quad \Delta = \frac{8}{h^2} \geq \frac{8}{h^2} \cos^2 \frac{\pi h}{2} = \lambda_{\max}(\mathbf{A}).$$

Воспользовавшись формулами для τ и ω , получим

$$\omega = \frac{h^2}{4 \sin \frac{\pi h}{2}} \approx \frac{h}{2\pi}, \quad \tau = \frac{h^2 \left(1 + \sin \frac{\pi h}{2}\right)}{\sin \frac{\pi h}{2} \left(1 + 3 \sin \frac{\pi h}{2}\right)} \approx \frac{2h}{\pi}.$$

Оценка количества итераций для этого метода дает

$$i \approx \frac{\ln \varepsilon^{-1}}{2\pi h} = \frac{N}{2\pi} \ln \varepsilon^{-1}.$$

Напомним, что границы спектра для рассматриваемого оператора $L \approx 8N^2$, $l \approx 2\pi^2$ и $N \approx \frac{\pi}{2} \sqrt{L/l}$.

Алгоритм вычисления u_{ml}^{i+1} в соответствии с ранее приведенными формулами двух этапов ПТИМ будет таков.

Первый этап:

$$r^i = \mathbf{A}u^i - f,$$

$$\tilde{u}_{ml} - \frac{\omega}{h} \left(\frac{\tilde{u}_{m+1,l} - \tilde{u}_{ml}}{h} + \frac{\tilde{u}_{m,l+1} - \tilde{u}_{ml}}{h} \right) = \mathbf{B}u_{ml}^i - \tau r_{ml}^i.$$

Второй этап:

$$u_{ml}^{i+1} + \frac{\omega}{h} \left(\frac{u_{ml}^{i+1} - u_{m-1,l}^{i+1}}{h} + \frac{u_{ml}^{i+1} - u_{m,l-1}^{i+1}}{h} \right) = \tilde{u}_{ml},$$

$$u_{0l}^{i+1} = 0, \quad u_{m0}^{i+1} = 0.$$

Уравнение для $\tilde{u}_{ml}$ нужно начинать решать от точки $m = N - 1$, $l = N - 1$, учитывая, что на границе сеточной области сеточная функция равна нулю. Таким образом, вычисления ведутся рекуррентно. Система решается, начиная с правого верхнего угла области до левого нижнего угла. Система линейных уравнений, соответствующая второму этапу, решается аналогично, но вычисления здесь начинаются в точке $m = 1$, $l = 1$ и заканчиваются в точке $m = N - 1$, $l = N - 1$. Метод по своим идеям напоминает схему Саульева, рассмотренную ранее в одномерном варианте при решении уравнений параболического типа.

Использование в ПТИМ набора чебышёвских итерационных параметров приводит к следующему результату. Расчетные фор-

мулы для метода таковы:

$$\mathbf{B} \frac{\mathbf{u}^{i+1} - \mathbf{u}^i}{\tau} + \mathbf{A} \mathbf{u}^i = \mathbf{f},$$

$$\mathbf{A} = \mathbf{R} + \mathbf{R}^*, \quad \mathbf{B} = (\mathbf{E} + \omega \mathbf{R}^*)(\mathbf{E} + \omega \mathbf{R}),$$

$$\tau_j = \frac{\tau_0}{1 + \eta t_j}, \quad \tau_0 = \frac{2}{\gamma_1 + \gamma_2},$$

$$\eta = \frac{1 - \gamma_1/\gamma_2}{1 + \gamma_1/\gamma_2},$$

$$t_j = \cos \frac{(2j-1)\pi}{2i}, \quad j = 1, \dots, i.$$

Для проведенного примера $\gamma_1 \approx 2 \sin \frac{\pi h}{2}$, $\gamma_2 \approx 1 + \sin \frac{\pi h}{2}$, $\frac{\gamma_1}{\gamma_2} \approx \pi h$. Оценка количества итераций будет $i = \frac{\sqrt{N}}{\sqrt{2\pi}} \ln \varepsilon^{-1}$.

14.4. Сводка результатов по итерационным методам решения сеточных уравнений

После рассмотрения самых распространенных методов решения сеточных уравнений получена возможность сравнить итерационные методы по количеству итераций, необходимых для достижения точности ε . Приведем только выражения для сомножителя, пропорционального числу узлов сетки:

$\frac{2M^2}{\pi^2}$ — методы Якоби и простых итераций с оптимальным выбором параметра;

$\frac{M^2}{\pi^2}$ — метод Зейделя;

$\frac{2M}{\pi}$ — метод верхней релаксации;

$\frac{M}{\pi}$ — метод простых итераций с чебышёвским набором параметров;

$\frac{1}{2} \frac{M}{\pi}$ — методы переменных направлений и попеременно-треугольный;

$\frac{\sqrt{M}}{2\sqrt{\pi}}$ — попеременно-треугольный метод с чебышёвским набором параметров;

$\frac{2}{\gamma} \ln\left(\frac{2}{\pi} M\right)$ — метод переменных направлений с чебышёвским набором параметров, $\gamma \approx 3.2$.

14.5. Основные идеи многосеточного метода

Р. П. Федоренко

Вернемся к рассмотренному выше вопросу о сходимости итерационных методов решения систем сеточных уравнений, получающихся при решении уравнений Лапласа или Пуассона. Выше был проведен спектральный анализ итерационных методов решения такой системы. Вернемся, например, к результатам исследования метода переменных направлений. Для него установлено равенство для коэффициентов разложения в конечный ряд Фурье невязки

$$c_{pq}^{i+1} = \frac{1 - \tau \lambda^p}{1 + \tau \lambda^q} \tilde{c}_{pq} = \frac{1 - \tau \lambda^p}{1 + \tau \lambda^q} \frac{1 - \tau \lambda^q}{1 + \tau \lambda^p} c_{pq}^i.$$

Из этого выражения следует, что коэффициенты при высокочастотных составляющих (т. е. при достаточно больших λ при фиксированном τ) убывают достаточно быстро, в то время как при низкочастотных гармониках ($\lambda \approx 0$) коэффициенты убывают медленно. Такой же эффект существует и для других итерационных методов.

Рассмотрим сеточное уравнение Пуассона

$$\Lambda_1 u_{ml} + \Lambda_2 u_{ml} = f_{ml}, \quad (14.1)$$

и, кроме того, уравнение

$$\Lambda_1 e_{ml} + \Lambda_2 e_{ml} = r_{ml}, \quad (14.2)$$

где r — невязка, e — погрешность решения. Если известно приближенное решение задачи (14.1), то, решая (14.2), можно найти решение исходной системы по формуле

$$u_{ml} = \tilde{u}_{ml} + e_{ml},$$

но решение задачи (14.2) по сложности точно такое же, как и решение исходной задачи.

Если применять итерационный метод (14.1), сделав несколько итераций, то приближенное решение задачи будет известно, а невязка станет плавно меняющейся функцией — в разложении

в конечный ряд Фурье будут отсутствовать высокочастотные составляющие. Невязка будет хорошо представляться на более грубой сетке, тогда размерность вспомогательной системы (14.2) понизится.

Введем сетку с шагом $2h$ и рассмотрим на ней задачу (14.2). Размерность системы сеточных уравнений получилась в четыре раза меньше, чем размерность исходной системы. Предположим, что есть средство эффективно решать такие задачи. После этого для восстановления решения надо найти невязку на более подробной сетке. Строим оператор интерполяции с грубой сетки на подробную. Очевидно, что ошибка интерполяции будет иметь высокочастотную компоненту. Тогда используем полученное решение (низкочастотные компоненты погрешности погашены на грубой сетке, остались только высокие частоты) в качестве начального приближения и делаем несколько сглаживающих итераций. Этот этап называется *коррекцией с грубой сетки*.

Схема приближенного построения решения получается следующей:

1) решается уравнение (14.1) на подробной сетке, проводится несколько сглаживающих итераций;

2) по приближенному решению находится невязка $r_{ml} = \Lambda_1 \tilde{u}_{ml} + \Lambda_2 \tilde{u}_{ml} - f_{ml}$;

3) ищется ограничение (проекция) невязки на грубую сетку;

4) на грубой сетке решается уравнение $\Lambda_1 e_{ml} + \Lambda_2 e_{ml} = r_{ml}$;

5) строится оператор интерполяции решения на подробную сетку, значения невязки пересчитываются на подробную сетку;

6) на подробной сетке проводится несколько сглаживающих итераций для уравнения $\Lambda_1 e_{ml} + \Lambda_2 e_{ml} = r_{ml}$;

7) Ищется решение по формуле $u_{ml} = \tilde{u}_{ml} + e_{ml}$.

Выполнение пункта 4 — решения сеточной системы — может оказаться трудоемким, поэтому внутри этого шага алгоритма можно еще раз перейти к более грубой сетке. Многосеточный метод состоит в рекурсивном повторении данной процедуры до тех пор, пока не будет получена система малой размерности, которая может быть эффективно решена прямым методом (например, Гаусса или сопряженных градиентов).

Простейшая реализация многосеточного метода — *каскадный алгоритм*. Он предусматривает последовательное решение задач на сетке со все большим числом узлов, а интерполяция решения с более грубой сетки используется в качестве начального приближения. Для самосопряженных эллиптических задач часто используется V-цикл. Сначала ищется решение на подробной сет-

ке, затем проводится последовательно вычисление невязок на все более грубых сетках, затем — несколько коррекций с грубой сетки и сглаживающие итерации на все более и более подробных сетках. Для несамосопряженных задач лучше зарекомендовал себя W -цикл, когда сначала вспомогательная система решается на последовательности все более и более грубых сеток, затем идут итерации на все более подробных сетках, затем снова итерации на грубых сетках и затем — на подробных вплоть до сетки с максимальным числом разбиений.

14.6*. Построение разностных схем для эллиптических уравнений на нерегулярных сетках. Монотонные схемы (подход А. С. Холодова)

В этом разделе будем следовать статье [53]. Кроме уравнений Лапласа и Пуассона, в этом разделе будем рассматривать произвольные уравнения эллиптического типа. Рассмотрим задачу

$$u_{xx} + e_{12}u_{xy} + e_{22}u_{yy} + e_1u_x + e_2u_y = f(x, y, u)$$

с условиями на коэффициенты

$$e_{ml}(x, y, u) = \{e_{mlj}\}, \quad e_m(x, y, u) = \{e_{mj}\}, \\ m, l = 1, 2, \quad j = 1, \dots, J, \quad e_{22} > \frac{e_{12}^2}{4}.$$

Последнее условие обеспечивает эллиптичность задачи. Задача решается в произвольной замкнутой области с несколькими несвязными границами. Предположим сначала, что область не содержит входящих углов (т. е. таких, величина которых больше π). В случае со входящими углами в решении эллиптических задач возникают особенности, во многих случаях необходимо сочетание численных методов и аналитических (асимптотических методов в окрестности входящего угла). Индекс j — номер узла сетки; для простоты выкладок узлы сетки нумеруются одним индексом.

Запишем разностную схему для аппроксимации приведенного выше уравнения в каноническом виде

$$u_k = \sum_i \alpha_{ki} u_i + f_k, \quad k = 1, \dots, K, \quad i = i_1, \dots, i_I$$

— точки, принадлежащие *шаблону* схемы, $I \geq 5$, причем *неопределенные коэффициенты* удовлетворяют условию монотонности

$\alpha_{ki} \geq 0$. Здесь K — общее число внутренних сеточных узлов с одноиндексной нумерацией, $i_1, \dots, i_I$ — номера расположенных достаточно произвольно в области интегрирования внутренних и граничных сеточных узлов, α_{ki} — неопределенные коэффициенты. Часть этих коэффициентов (или все, если $I = 5$) определяются условиями аппроксимации первого порядка или второго порядка на решениях исходного уравнения. Эти условия получаются стандартно — проекция точного решения на нерегулярную сетку раскладывается в ряд Тейлора в окрестности точки u_k . Обозначим $X_i = x_i - x_k$, $Y_i = y_i - y_k$. После несложных, но громоздких выкладок получаем, что следующие условия обеспечивают первый порядок аппроксимации:

$$\begin{aligned} \sum_i \alpha_{ki} &= 1, \\ \sum_i \alpha_{ki} X_i \left(1 - 0.5 X_i (e_1 - X_i \frac{e_1^2 + f_u - e_{11}}{3} + Y_i e_{12}) \right) &= 0, \\ \sum_i \alpha_{ki} \left(Y_i - 0.5 X_i^2 (e_2 + X_i \frac{e_2 f_u - e_{12} e_2 + e_{21}}{3} - Y_i (f_u - e_{22})) \right) &= 0, \\ \sum_i \alpha_{ki} X_i \left(Y_i - 0.5 X_i (e_{12} + X_i \frac{e_2 + e_{12} - 2e_{12} e_1}{3} + Y_i (e_1 + e_{12})) \right) &= 0, \\ \sum_i \alpha_{ki} \left(Y_i^2 - X_i^2 (e_{22} - X_i \frac{e_{12} e_2 + e_{22} e_1 - e_{22}}{3} + Y_i (e_2 + e_{22})) \right) &= 0, \\ \beta_0 &= -\frac{1}{2} \sum_i \alpha_{ki} X_i^2 \left(1 - \frac{e_1 X_i}{3} \right) = 0. \end{aligned}$$

Суммирование ведется по всем точкам, включенным в шаблон. Если к приведенным выше условиям добавить условия

$$\begin{aligned} \sum_i \alpha_{ki} X_i \left(3Y_i (Y_i - e_{12} X_i) - X_i^2 (e_{22} - e_{12}^2) \right) &= 0, \\ \sum_i \alpha_{ki} \left(Y_i^3 - e_{22} X_i^2 (3Y_i - e_{12} X_i) \right) &= 0, \\ \beta_1 &= -\sum_i \frac{\alpha_{ki} X_i^3}{6}, \quad \beta_2 = -\sum_i \frac{\alpha_{ki} X_i^2 Y_i}{2}, \end{aligned}$$

то схема имеет второй порядок аппроксимации на решениях. Здесь введены обозначения $X_i = x_i - x_k$, $Y_i = y_i - y_k$. В обычных разностных методах шаблон фиксирован (т. е. все внутренние точки сетки имеют одинаковое число соседей). В данном подходе для

каждой рассчитываемой точки $k = 1, \dots, K$ специальным образом подбираются соседи (сеточный шаблон) так, чтобы выполнялись условия неотрицательности коэффициентов α_{ki} в канонической форме записи разностной схемы. Эти условия обеспечивают неотрицательность разностного оператора (мажорантность схемы).

Получающийся в результате решения уравнений для условий аппроксимации первого порядка и неравенств, обеспечивающих монотонность схемы, для каждого $k = 1, \dots, K$ набор коэффициентов α_{ki} приводит к знакопостоянной линейной (или нелинейной для квазилинейных уравнений) системе уравнений

$$\mathbf{A}\mathbf{u} = \mathbf{b},$$

$$\mathbf{A} = \begin{pmatrix} 1 & 0 & \dots & 0 & -\alpha_{1i_1} & 0 & \dots & 0 & -\alpha_{1i_l} & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 & -\alpha_{Ki_1} & 0 & \dots & 0 & -\alpha_{Ki_l} & 1 \end{pmatrix}$$

$$\alpha_{ki} \geq 0, \quad \sum_i \alpha_{ki} \leq 1.$$

Условия неотрицательности неопределенных коэффициентов обеспечивают выполнение достаточных условий сходимости и принципа максимума, в том числе при разрывных граничных условиях. Тогда простейший итерационный метод Якоби

$$u_k^{n+1} = \sum_i \alpha_{ki} u_i^n$$

является сходящимся.

Можно показать, что при весьма слабых ограничениях на расположение сеточных узлов в области интегрирования такие схемы могут быть конструктивно построены. Этот же подход распространен на случай схем со вторым порядком аппроксимации на решениях.

14.7. Примеры решения задач

1. Показать самосопряженность разностного оператора, возникающего при аппроксимации двумерного уравнения Лапласа в прямоугольной области по схеме «крест».

Решение. Для того чтобы показать самосопряженность оператора, введем обычное (при исследовании эллиптических задач) скалярное произведение двух сеточных функций, определенных

во всех сеточных узлах и равных нулю в узлах граничных. Такое скалярное произведение определяется как

$$(u, v) = \sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{ij} h_x h_y.$$

Вычислим теперь скалярное произведение $(u, \mathbf{\Lambda}_1 v_{ml} + \mathbf{\Lambda}_2 v_{ml})$. Учитывая вид операторов, можно записать

$$\begin{aligned} (u, \mathbf{\Lambda}_1 v_{ml} + \mathbf{\Lambda}_2 v_{ml}) &= \\ &= \sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} \left(\frac{v_{i+1,j} - 2v_{i,j} + v_{i-1,j}}{h_x^2} + \frac{v_{i,j+1} - 2v_{i,j} + v_{i,j-1}}{h_y^2} \right) h_x h_y = \\ &= \frac{h_x}{h_y} \left(\sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{i+1,j} + \sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{i+1,j} + \sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{i-1,j} \right) + \\ &\quad + \frac{h_y}{h_x} \left(\sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{i,j+1} + \sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{i,j+1} + \sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{i,j-1} \right). \end{aligned}$$

Поменяем в первой, третьей, четвертой и шестой суммах индексы суммирования, тогда последнюю сумму в предыдущей цепочке равенств можно записать как

$$\begin{aligned} &\frac{h_x}{h_y} \left(\sum_{k=0}^{N-2} \sum_{j=1}^{M-1} u_{k+1,j} v_{k,j} + \sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{i+1,j} + \sum_{k=2}^N \sum_{j=1}^{M-1} u_{k-1,j} v_{k,j} \right) + \\ &\quad + \frac{h_y}{h_x} \left(\sum_{i=1}^{N-1} \sum_{l=2}^M u_{il-1} v_{i,l} + \sum_{i=1}^{N-1} \sum_{j=1}^{M-1} u_{ij} v_{i,j+1} + \sum_{i=1}^{N-1} \sum_{l=0}^{M-2} u_{il+1} v_{i,l} \right). \end{aligned}$$

Теперь заметим, что на границах области функции равны нулю и что значение суммы не зависит от индекса суммирования. Мы

получим далее

$$\begin{aligned}
 & \frac{h_x}{h_y} \left(\sum_{k=1}^{N-1} \sum_{l=1}^{M-1} u_{k+1,l} v_{k,l} + \sum_{k=1}^{N-1} \sum_{l=1}^{M-1} u_{kl} v_{k+1,l} + \sum_{k=1}^{N-1} \sum_{l=1}^{M-1} u_{k-1,l} v_{k,l} \right) + \\
 & + \frac{h_y}{h_x} \left(\sum_{k=1}^{N-1} \sum_{l=1}^{M-1} u_{k,l-1} v_{k,l} + \sum_{k=1}^{N-1} \sum_{l=1}^{M-1} u_{k,l} v_{k,l} + \sum_{k=1}^{N-1} \sum_{l=1}^{M-1} u_{k,l+1} v_{k,l} \right) = \\
 & = \sum_{k=1}^{N-1} \sum_{l=1}^{M-1} v_{kl} \left(\frac{u_{k+1,l} - 2u_{k,l} + u_{k-1,l}}{h_x^2} + \frac{u_{k,l+1} - 2u_{k,l} + u_{k,l-1}}{h_y^2} \right) h_x h_y = \\
 & = (\mathbf{\Lambda}_1 u_{ml} + \mathbf{\Lambda}_2 u_{ml}, v).
 \end{aligned}$$

Это и означает самосопряженность разностного оператора.

2. Найти собственные числа и собственные функции оператора второй разностной производной с нулевыми краевыми условиями:

$$-\frac{y_{n+1} - 2y_n + y_{n-1}}{h^2} = \lambda y_n, \quad n = 0, 1, \dots, N, \quad y_0 = y_N = 0, \quad h = \frac{l}{N}.$$

Решение. Рассмотрим эту задачу как разностное уравнение второго порядка

$$-(y_{n+1} - 2y_n + y_{n-1}) = \lambda h^2 y_n,$$

или

$$-y_{n+1} + (2 - \lambda h^2) y_n - y_{n-1} = 0.$$

Характеристическое уравнение, соответствующее данному разностному, есть

$$q^2 - (2 - \lambda h^2) q + 1 = 0.$$

По теореме Виета имеем

$$q_1 = \frac{1}{q_2}.$$

Тогда общее решение разностного уравнения есть

$$\bar{y}_n = \alpha q_1^n + \beta q_1^{-n}.$$

Подстановка в левое граничное условие дает соотношение $\alpha + \beta = 0$, тогда

$$\bar{y}_n = \alpha (q_1^n - q_1^{-n}).$$

Теперь используем правое граничное условие $\alpha(q_1^N - q_1^{-N}) = 0$.

Если положить $\alpha = 0$, получим тривиальное решение, которое нас не интересует. Следовательно, должно быть выполнено $q_1^N - q_1^{-N} = 0$, или $q_1^{2N} = 1$. Последнее равенство имеет место при $N-1$ различных значениях параметра q_1 :

$$q_1^{2N} = e^{2\pi ki}, \quad q_1 = \exp\left(\frac{\pi ki}{N}\right), \quad k = 1, 2, \dots, N-1.$$

Значения $k = 0$ и $k = N$ приводят к тривиальному решению, а значения k от $N+1$ до $2N-1$ мы не рассматриваем в силу того, что величины q_1 и q_2 являются взаимно обратными.

Подстановка полученного решения в выражение для значения собственной функции в узле позволяет получить решение разностного уравнения в явном виде:

$$\bar{y}_n^{(k)} = \alpha \left(\exp\left(\frac{\pi kni}{N}\right) - \exp\left(-\frac{\pi kni}{N}\right) \right) = \alpha \cdot 2i \sin \frac{\pi kn}{N}.$$

Выбирая $\alpha = (2i)^{-1} \sqrt{2/l}$, получим собственные функции

$$\bar{y}_n^{(k)} = \sqrt{\frac{2}{l}} \sin \frac{\pi kn}{N}.$$

Подстановка собственных функций в исходное разностное уравнение второго порядка позволяет после ряда тригонометрических преобразований найти спектр разностного оператора второй производной при нулевых краевых условиях для $k = 1, \dots, N-1$:

$$\begin{aligned} \lambda_{(k)} &= -\frac{y_{n+1}^{(k)} - 2y_n^{(k)} + y_{n-1}^{(k)}}{y_n^{(k)} h^2} = \\ &= -\frac{1}{h^2} \left(\frac{\sin(\pi k(n+1)/N) - 2\sin(\pi kn/N) + \sin(\pi k(n-1)/N)}{\sin(\pi kn/N)} \right) = \\ &= \frac{4}{h^2} \sin^2 \frac{\pi k}{2N}. \end{aligned}$$

3. Решить задачу на собственные значения сеточного оператора Лапласа в прямоугольнике с краевыми условиями первого рода

$$\begin{aligned} \frac{u_{m-1,l} - 2u_{ml} + u_{m+1,l}}{h_x^2} + \frac{u_{m,l-1} - 2u_{ml} + u_{m,l+1}}{h_y^2} &= \lambda u_{ml}, \\ u_{0l} &= 0, \quad u_{m0} = 0, \quad u_{Ml} = 0, \quad u_{mL} = 0, \\ M &= \frac{X}{h_x}, \quad L = \frac{Y}{h_y}. \end{aligned}$$

Решение. Как и для дифференциального оператора Лапласа, будем искать решение задачи методом разделения переменных. Считаем, что собственная функция задачи может быть представлена как произведение $\varphi_m \varphi_l$. Подставим это произведение в исходное уравнение, тогда получим

$$\varphi_l \frac{\varphi_{m-1} - 2\varphi_m + \varphi_{m+1}}{h_x^2} + \varphi_m \frac{\varphi_{l-1} - 2\varphi_l + \varphi_{l+1}}{h_y^2} = \lambda \varphi_m \varphi_l.$$

У задачи, конечно, есть тривиальное (нулевое) решение, которое нам не интересно. Для поиска нетривиального решения разделим обе части последнего равенства на произведение $\varphi_m \varphi_l$. Тогда получим

$$\frac{1}{\varphi_m} \frac{\varphi_{m-1} - 2\varphi_m + \varphi_{m+1}}{h_x^2} + \frac{1}{\varphi_l} \frac{\varphi_{l-1} - 2\varphi_l + \varphi_{l+1}}{h_y^2} = \lambda.$$

В последнем равенстве первое слагаемое зависит лишь от индекса m , второе — лишь от l . Но это возможно лишь в случае, если

$$\frac{1}{\varphi_m} \frac{\varphi_{m-1} - 2\varphi_m + \varphi_{m+1}}{h_x^2} = \lambda_m, \quad \frac{1}{\varphi_l} \frac{\varphi_{l-1} - 2\varphi_l + \varphi_{l+1}}{h_y^2} = \lambda_l, \quad \lambda = \lambda_m + \lambda_l.$$

Таким образом, мы приходим к двум задачам на собственные значения

$$\frac{\varphi_{m-1} - 2\varphi_m + \varphi_{m+1}}{h_x^2} = \lambda_m \varphi_m,$$

$$\frac{\varphi_{l-1} - 2\varphi_l + \varphi_{l+1}}{h_y^2} = \lambda_l \varphi_l.$$

Воспользуемся решением предыдущей задачи и сразу запишем

$$\lambda_m^{(k)} = -\frac{4}{h_x^2} \sin^2 \frac{k\pi}{2M}, \quad \varphi_m^{(k)} = \sin \frac{k\pi m}{M}, \quad k = 1, \dots, M-1;$$

$$\lambda_l^{(q)} = -\frac{4}{h_y^2} \sin^2 \frac{q\pi}{2L}, \quad \varphi_l^{(q)} = \sin \frac{q\pi l}{L}. \quad q = 1, \dots, L-1.$$

Тогда мы получаем, что собственная функция разностного оператора $\varphi^{kq} = \varphi_m^{(k)} \varphi_l^{(q)} = \sin \frac{k\pi m}{M} \sin \frac{q\pi l}{L}$, а соответствующее собственное число есть $\lambda^{kq} = \lambda_m^{(k)} + \lambda_l^{(q)} = -\frac{4}{h_x^2} \sin^2 \frac{k\pi}{2M} - \frac{4}{h_y^2} \sin^2 \frac{q\pi}{2L}$.

4. Показать, что решение двумерного уравнения Пуассона по схеме «крест» с последующим решением системы сеточных уравнений методом простых итераций равносильно решению на установление задачи для уравнения теплопроводности с помощью простой явной схемы.

Решение. Для записи метода простых итераций будем использовать безматричную запись. Вспомним, что одно из представлений метода простой итерации есть

$$\mathbf{y}^{k+1} = \mathbf{y}^k + \tau \mathbf{r}^k,$$

где τ — итерационный параметр, $\mathbf{r}^k$ — невязка предыдущего приближения.

Очевидно, что в граничных узлах сетки невязка будет равна нулю, их значения на итерациях не изменяются. Вычислим невязку в произвольном внутреннем узле области. Она есть

$$\begin{aligned} r_{i,j}^k &= \frac{u_{i+1,j}^k - 2u_{i,j}^k + u_{i-1,j}^k}{h_x^2} + \frac{u_{i,j+1}^k - 2u_{i,j}^k + u_{i,j-1}^k}{h_y^2} - f_{i,j} = \\ &= (\Lambda_1 + \Lambda_2) u_{i,j}^k - f_{i,j}. \end{aligned}$$

Тогда уточненное значение решения на следующей итерации есть

$$u_{i,j}^{k+1} = u_{i,j}^k + \tau \left(\frac{u_{i+1,j}^k - 2u_{i,j}^k + u_{i-1,j}^k}{h_x^2} + \frac{u_{i,j+1}^k - 2u_{i,j}^k + u_{i,j-1}^k}{h_y^2} - f_{i,j} \right).$$

Сравнивая с расчетной формулой для решения уравнения теплопроводности с помощью явной пятиточечной схемы, убеждаемся, что расчетные формулы совпадают.

5. Для решения задачи Дирихле для уравнения Лапласа в прямоугольнике методом неопределенных коэффициентов построить схему максимально возможного порядка аппроксимации на девятиточечном шаблоне. Считать, что $h_x \neq h_y$. Как изменится порядок аппроксимации при $h_x = h_y = h$?

Решение. Заметим, что в уравнении Лапласа нет выделенных пространственных направлений, следовательно, веса разностной схемы будут зависеть лишь от расстояния от центра шаблона. Тогда возможно записать разностную схему в виде

$$\begin{aligned} u_{m,l} &= \alpha(u_{m-1,l} + u_{m+1,l}) + \beta(u_{m,l-1} + u_{m,l+1}) + \\ &+ \gamma(u_{m-1,l+1} + u_{m-1,l-1} + u_{m+1,l+1} + u_{m+1,l-1}). \end{aligned}$$

Подставим проекцию на сетку точного решения задачи в разностную схему и выпишем разложение в ряды Тейлора в окрестности центральной точки шаблона. Соберем слагаемые с одинаковыми степенями по шагам сетки. Получим следующие условия:

h^0	$1 = 2\alpha + 2\beta + 4\gamma$	h_x^4	$\frac{\alpha}{12} \frac{\partial^4 u}{\partial x^4}$
h_x^2	$\alpha \frac{\partial^2 u}{\partial x^2}$	h_y^4	$\frac{\beta}{12} \frac{\partial^4 u}{\partial y^4}$
h_y^2	$\beta \frac{\partial^2 u}{\partial y^2}$	$h_x^2 h_y^2$	$\gamma \frac{\partial^4 u}{\partial x^2 \partial y^2}$

Коэффициенты при нечетных степенях шагов сетки получают-ся тождественно равными нулю. Члены шестого порядка по шагам сетки мы опускаем.

Так как разностное уравнение должно аппроксимировать уравнение Лапласа, то имеем равенство $\alpha h_x^2 = \beta h_y^2$.

Воспользуемся теперь следствиями уравнения Лапласа:

$$0 = \frac{\partial^2}{\partial x^2} \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right) = \frac{\partial^4 u}{\partial x^4} + \frac{\partial^4 u}{\partial x^2 \partial y^2},$$

$$0 = \frac{\partial^2}{\partial y^2} \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right) = \frac{\partial^4 u}{\partial y^4} + \frac{\partial^4 u}{\partial x^2 \partial y^2};$$

тогда, складывая два приведенных выше выражения, получим

$$\frac{\partial^4 u}{\partial x^2 \partial y^2} = -\frac{1}{2} \left(\frac{\partial^4 u}{\partial x^4} + \frac{\partial^4 u}{\partial y^4} \right),$$

$$\begin{aligned} h_x^4 \frac{\alpha}{12} \frac{\partial^4 u}{\partial x^4} + h_y^4 \frac{\beta}{12} \frac{\partial^4 u}{\partial y^4} + h_x^2 h_y^2 \frac{\gamma}{6} \frac{\partial^4 u}{\partial x^2 \partial y^2} = \\ = h_x^4 \frac{\alpha}{12} \frac{\partial^4 u}{\partial x^4} + h_y^4 \frac{\beta}{12} \frac{\partial^4 u}{\partial y^4} - \frac{\gamma}{2} h_x^2 h_y^2 \left(\frac{\partial^4 u}{\partial x^4} + \frac{\partial^4 u}{\partial y^4} \right) = \\ = \frac{h_x^2}{12} (\alpha h_x^2 - 6\gamma h_y^2) \frac{\partial^4 u}{\partial x^4} + \frac{h_y^2}{12} (\beta h_y^2 - 6\gamma h_x^2) \frac{\partial^4 u}{\partial y^4}. \end{aligned}$$

При неравных друг другу шагах разностной сетки мы получаем схему второго порядка аппроксимации, как и схема «крест»,

но, в зависимости от выбора коэффициентов, невязка будет определяться четвертой производной лишь по одному направлению. При равных шагах сетки коэффициенты определяются системой уравнений

$$2\alpha + 2\beta + 4\gamma = 1,$$

$$\alpha = \beta,$$

$$\alpha = 6\gamma.$$

Главный член невязки определяется при этом шестыми производными, схема будет иметь четвертый порядок аппроксимации.

Библиографический комментарий к Лекции 14

О разностных методах решения эллиптических уравнений подробнее см. [6, 39, 41]. В [1] описаны основные идеи метода разностных потенциалов В. С. Рябенького. Методам решения сеточных уравнений посвящена монография [50]. Многосеточный метод впервые предложен Р. П. Федоренко в [51]. Основные идеи многосеточного метода описаны в [2], некоторые аспекты его реализации для простейшей области — в [11]. О современном состоянии развития многосеточных методов см. статьи в сборнике [52]. Монотонные разностные схемы в пространствах неопределенных коэффициентов были введены в рассмотрение А. С. Холдовым [53].

Для проведения практических занятий по теме рекомендуется использовать задачник [40].

НЕОБХОДИМЫЕ СВЕДЕНИЯ ИЗ ФУНКЦИОНАЛЬНОГО АНАЛИЗА

*Теорию вычисления невозможно представить
без банаховых пространств*
С. Л. Соболев

1. Метрические пространства

Определение. Функциональными пространствами называются пространства, элементами которых могут быть числовые последовательности или функции.

Определение. Множество будем называть метрическим пространством, если каждой паре его элементов x, y в соответствие поставлено неотрицательное число $\rho(x, y)$, называемое расстоянием между элементами x, y , или метрикой пространства X . При этом метрика должна удовлетворять следующим аксиомам:

$$\rho(x, y) = \rho(y, x); \quad (\text{П1.1})$$

$$\rho(x, y) \geq 0 \quad (\text{П1.2})$$

$$\rho(x, y) \leq \rho(x, t) + \rho(t, y); \quad (\text{П1.3})$$

$$\rho(x, y) = 0 \Leftrightarrow x = y.$$

(аксиома (П1.1) — аксиома симметрии, (П1.3) — неравенство треугольника);

Определение. Величина $d(Y) = \sup_{x, y \in Y} \rho(x, y)$ называется диаметром множества Y . Здесь Y — подпространство пространства X , имеющее ту же метрику, что и X . Причем Y является ограниченным, если $d(Y) < \infty$, т. е. $\exists$ элемент $\bar{y} \in X$ и постоянная $C > 0$ такие, что $\rho(x, \bar{y}) < C$ для $\forall x \in Y$.

Определение. Сферой радиуса $R > 0$ с центром в точке y_0 называется множество X всех точек, для которых выполнено условие $\rho(x, y_0) = R$.

Определение. Открытым шаром (шаром) радиуса $R > 0$ с центром в точке y_0 называется множество $D_R(y_0)$ всех точек, для которых выполнено условие $\rho(x, y_0) < R$.

2. Некоторые примеры метрических пространств

2.1. Рассмотрим множество $X = R^1$, где R^1 — множество всех вещественных чисел (числовая прямая). В этом случае вводится метрика $\rho(x, y) = |x - y| \quad \forall x, y \in R^1$.

2.2. $X = R^n$, где R^n — n -мерное пространство вещественных векторов, элементы этого пространства $x = \{x_1, \dots, x_n\}$, $y = \{y_1, \dots, y_n\}$, $x, y \in R^n$. Метрика может быть введена одним из следующих способов:

$$\rho(x, y) = \max_i |x_i - y_i|,$$

$$\rho(x, y) = \sum_{i=1}^n |x_i - y_i|,$$

$$\rho(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2},$$

причем каждая метрика порождает свое метрическое пространство. В связи с этим правильнее было бы метрическое пространство обозначать как $\{X, \rho\}$.

2.3. Для пространства l_1 бесконечных числовых последовательностей $x = \{x_1, \dots, x_n, \dots\}$, $y = \{y_1, \dots, y_n, \dots\}$ таких, что

$\sum_{i=1}^{\infty} |x_i| < \infty$, $\sum_{i=1}^{\infty} |y_i| < \infty$, метрика определяется следующим обра-

зом: $\rho(x, y) = \sum_{i=1}^{\infty} |x_i - y_i|$.

2.4. В случае пространства l_2 для бесконечных последовательностей, в котором $\sum_{i=1}^{\infty} x_i^2 < \infty$, метрика вводится как $\rho(x, y) = \sqrt{\sum_{i=1}^{\infty} (x_i - y_i)^2}$.

2.5. Для пространства l_{∞} ограниченных числовых последовательностей $x = \{x_1, \dots, x_n\}$ (для $\forall x \exists C > 0$ такая, что $|x_i| \leq C$ для $\forall i$) расстояние между элементами x, y (метрика) определяется как $\rho(x, y) = \sup_i |x_i - y_i|$.

2.6. Метрика в пространстве Чебышёва $C[a, b]$ функций, непрерывных на отрезке $[a, b]$, вводится следующим образом:

$$\rho(f_1, f_2) = \max_{x \in [a, b]} |f_1(x) - f_2(x)|,$$

где $f_1(x), f_2(x) \in X$ — элементы множества всех функций, непрерывных на $[a, b]$.

Метрика в пространстве Чебышёва $C^k[a, b]$ функций, непрерывных вместе с k производными, вводится следующим образом:

$$\rho(f_1, f_2) = \sum_{i=0}^k \max_{x \in [a, b]} |f_1^{(i)} - f_2^{(i)}|,$$

где $f_1(x), f_2(x) \in X$ — множество непрерывных на $[a, b]$ функций, имеющих непрерывные производные до k -го порядка ($k \geq 1$) включительно.

2.7. Для пространства функций, интегрируемых на $[a, b]$ с первой степенью $L_1[a, b]$, вводится метрика

$$\rho(f_1, f_2) = \int_a^b |f_1 - f_2| dx.$$

Для пространства функций, интегрируемых на $[a, b]$ с квадратом $L_2[a, b]$, метрика вводится как

$$\rho(f_1, f_2) = \sqrt{\int_a^b (f_1 - f_2)^2 dx}.$$

В общем случае пространства $L_p[a, b]$, $p > 1$, функций, интегрируемых с p -й степенью, можно ввести метрику как

$$\rho(f_1, f_2) = \left(\int_a^b |f_1 - f_2|^p dx \right)^{1/p}.$$

Определение. Точку $x \in X$ назовем пределом бесконечной последовательности $\{x_n\} \in X$, $n = 1, 2, \dots$, или $x = \lim_{n \rightarrow \infty} x_n$, если $\rho(x_n, x) \rightarrow 0$ при $n \rightarrow \infty$ (сходимость по расстоянию).

Теорема. Если последовательность $\{x_n\}$ метрического пространства сходится по расстоянию к некоторому пределу, то этот предел единственный.

Определение. Две метрики на множестве элементов $x \in X$ называются эквивалентными, если сходимость по одной из них означает сходимость и по другой.

Определение. Точка $x \in A$, $A \subset X$ является внутренней точкой множества A , если $\exists \delta > 0$ такое, что шар $D_\delta(x) \subset A$.

Определение. Точка $x \in A$, $A \subset X$ является предельной точкой множества A , если существует последовательность $u_n \in A$ такая, что $u_n \rightarrow x$.

Определение. Множество, полученное присоединением к A всех его предельных точек, называется замыканием множества A и обозначается как $\bar{A}$. Множество A называется замкнутым, если $A = \bar{A}$.

Определение. Множество A называется открытым, если все его точки являются внутренними. Окрестностью точки x является любое открытое множество A , содержащее точку x , например, любой шар $D_\delta(x)$.

Определение. Расстоянием от точки x до множества Y называется число

$$\rho(x, Y) = \inf_{y \in Y} \rho(x, y).$$

Определение. Последовательность $\{x_n\} \in X$ (X — метрическое пространство) называется фундаментальной (или сходящейся в себе), если для $\forall \varepsilon > 0 \exists N(\varepsilon)$ такое, что $\rho(x_n, x_m) < \varepsilon$, если $n, m \geq N(\varepsilon)$.

Теорема. Любая фундаментальная последовательность является ограниченной; если последовательность $\{x_n\}$ сходится к некоторому пределу $\bar{x}$, то она фундаментальна.

Определение. Метрическое пространство X называется полным, если всякая фундаментальная последовательность в нем имеет предел, принадлежащий этому пространству.

В приведенных выше примерах метрических пространств пространства R^1 , R^n , $C[a, b]$, $C^k[a, b]$, l_1 , l_2 — полные, пространства $L_1[a, b]$, $L_2[a, b]$, $L_n[a, b]$ — неполные.

Определение. Множество $X' \subset X$ называется компактным, если из любой последовательности $\{x_n\} \in X'$ можно выделить фундаментальную подпоследовательность.

Следствие. Всякое компактное множество ограничено.

3. Линейные пространства

Определение. Множество L называется линейным пространством, если в нем определены две следующие операции:

1) Каждым двум элементам $x, y \in L$ ставится в соответствие элемент $(x + y) \in L$ — сумма элементов x и y .

2) Каждому элементу $x \in L$ и числу λ ставится в соответствие элемент $\lambda x \in L$ — произведение элемента x на скалярную величину λ .

При этом выполнены следующие аксиоматические свойства суммы и произведения, справедливые для $\forall \lambda, \bar{\lambda}$ и $\forall x, y \in L$:

коммутативность:

$$x + y = y + x;$$

ассоциативность:

$$x + (y + z) = (x + y) + z.$$

дистрибутивность:

$$\lambda(x + y) = \lambda x + \lambda y,$$

$$(\lambda + \bar{\lambda})x = \lambda x + \bar{\lambda}x,$$

$$\lambda(\bar{\lambda}x) = (\lambda\bar{\lambda})x.$$

Нулевой элемент. Говорят, что существует нулевой элемент $0 \in L$: $x + 0 = x$;

В L также определяется *противоположный* элемент $(-x)$; при этом

$$-x = (-1)x; \quad x + (-x) = 0.$$

3.1. Некоторые примеры линейных пространств. Линейными пространствами являются метрические пространства R^1 , R^n , $C[a, b]$, $C^k[a, b]$, l_1 , l_2 , $L_1[a, b]$, $L_2[a, b]$, $L_p[a, b]$.

Также линейными пространствами являются пространства всех полиномов $Q_n(x)$ степени не выше n , прямоугольных матриц A_{ij} порядка $I \times J$.

О п р е д е л е н и е. Сумма вида $\lambda_1 x_1 + \dots + \lambda_n x_n$ называется *линейной комбинацией элементов* $x_1, \dots, x_n \in L$ (λ_i — скаляры).

Элементы $x_i \in L$, $i = 1, \dots, n$ линейно зависимы, если существует такой нетривиальный набор коэффициентов линейной комбинации, что она обратится в нуль, $\exists \lambda_i$, $i = 1, \dots, n$ $\left(\sum_{i=1}^n |\lambda_i| > 0 \right)$,

такие, что $\sum_{i=1}^n \lambda_i x_i = 0$.

Если линейная комбинация элементов обращается в нуль только при условии $\lambda_i = 0$, $i = 1, \dots, n$, то элементы x_i , $i = 1, \dots, n$, назовем линейно независимыми.

Совокупность всех возможных линейных комбинаций вида $\sum \lambda_k x_k$ ($x_{k_i} \in \bar{L}$, где $\bar{L}$ — некое множество в L) называется *линейной оболочкой* множества $\bar{L}$, или *линейным многообразием*. Замкнутое линейное многообразие называется *подпространством*.

О п р е д е л е н и е. *Линейное пространство является конечномерным (n -мерным), если в нем существует система из n линейно независимых элементов, линейная оболочка которых совпадает с L ; всякая линейно независимая система из n элементов представляет базис в L ; пространство, не являющееся конечномерным, — бесконечномерное.*

Пусть $\{e_k\}_1^n$ — базис в n -мерном линейном пространстве, тогда $\forall x \in L$ представляется в виде $x = \sum_{i=1}^n \eta_i e_i$. Это представление называется разложением элемента по базису $\{e_k\}_1^n$; разложение является единственным; η_i , $i = 1, \dots, n$ — координаты элемента x в базисе $\{e_k\}_1^n$.

О п р е д е л е н и е. *Линейным отображением (или линейным оператором) F линейного пространства X называется отображение, для которого для любых $x, x' \in Y$ и постоянных λ, λ' справедливо $F(\lambda x + \lambda' x') = \lambda \cdot F(x) + \lambda' \cdot F(x')$.*

Множество всех линейных отображений (операторов) обозначим $S(Y, X)$.

Пусть $F: X \rightarrow Y$ — линейное отображение. Тогда множество элементов $\{x \in X : F(x) = 0\}$ называется ядром отображения F :

$$\ker F = \{x \in X : F(x) = 0\}.$$

Теорема. *Для того чтобы отображение $F: X \rightarrow Y$ было взаимно однозначно, необходимо и достаточно, чтобы его ядро состояло только из нулевого элемента: $\ker F = 0$.*

О п р е д е л е н и е. *Говорят, что два линейных пространства изоморфны, если между их элементами можно установить взаимно однозначное соответствие, сохраняющее алгебраические операции, т.е. если $x \leftrightarrow y, x' \leftrightarrow y'$ то*

$$x + x' \leftrightarrow y + y',$$

$$\lambda x \leftrightarrow \lambda y.$$

О п р е д е л е н и е. *Назовем совокупность всех точек x отрезком, соединяющим x_1, x_2 , если при $t \in [0; 1]$*

$$x = (1 - t)x_1 + tx_2. \quad (\text{П1.4})$$

О п р е д е л е н и е. *Множество (П1.4) при $t > 0$ называется лучом, исходящим из точки x_1 .*

О п р е д е л е н и е. *Множество $L' \in L$ в линейном пространстве L является выпуклым, если для $\forall x_1, x_2 \in L'$ отрезок (П1.4) принадлежит L' .*

О п р е д е л е н и е. *Линейное пространство X является нормированным, если на множестве его элементов $x \in X$ определена вещественная функция — норма $\|x\|$, удовлетворяющая следующим аксиомам для любых элементов $x, y \in X$ и постоянной λ :*

$$\|x\| \geq 0; \quad \|x\| = 0 \Leftrightarrow x = 0,$$

$$\|x + y\| \leq \|x\| + \|y\|,$$

$$\|\lambda x\| = |\lambda| \|x\|.$$

В нормированном пространстве можно ввести расстояние между элементами $\rho(x, y) = \|x - y\|$, т. е. любое нормированное пространство является метрическим. Все определения, введенные для метрических пространств, справедливы и для пространств нормированных.

Приведем примеры норм в некоторых пространствах.

Нормы векторов в пространстве R^n . Наиболее часто употребляемые нормы приведены в основном тексте книги.

Норма в пространстве l_1 :

$$\|x\| = \sum_{i=1}^{\infty} |x_i|.$$

Норма в пространстве l_2 :

$$\|x\| = \sqrt{\sum_{i=1}^{\infty} x_i^2}.$$

В пространствах $C[a, b]$, $C[\Omega]$, $C^k[a, b]$, $C^k[\Omega]$ можно ввести нормы соответственно:

$$\|f\| = \max_{x \in [a, b]} |f(x)|,$$

$$\|f\| = \max_{x \in \Omega} |f(x)|,$$

$$\|f\| = \sum_{i=0}^k \max_{x \in [a, b]} |f^{(i)}(x)|,$$

$$\|f\| = \sum_{0 \leq |\alpha| \leq k} \max_{x \in \Omega} |D^\alpha f|,$$

где $D^\alpha f(x) = \frac{\partial^{(\alpha)} f(x_1, \dots, x_n)}{\partial x_1^{\alpha_1} \cdot \partial x_2^{\alpha_2} \cdot \dots \cdot \partial x_n^{\alpha_n}}$, $D^0 f(x) = f(x)$. Здесь α — мультииндекс (вектор) с целыми неотрицательными компонентами $\alpha = \{\alpha_1, \dots, \alpha_n\}$, $|\alpha| = \sum \alpha_i$, $\alpha_i \geq 0$. В частности, в $C^k[a, b]$

$$\|f\| = \max \left\{ \max_{x \in [a, b]} |f(x)|, \max_{x \in [a, b]} |f'(x)|, \dots, \max_{x \in [a, b]} |f^{(k)}(x)| \right\}.$$

Нормы в $L_1[a, b]$, $L_2[a, b]$, $L_p[a, b]$ соответственно будут

$$\|f\|_{L_1} = \int_a^b |f(x)| dx,$$

$$\|f\|_{L_2} = \sqrt{\int_a^b |f(x)|^2 dx},$$

$$\|f\|_{L_p} = \left(\int_a^b |f(x)|^p dx \right)^{1/p}.$$

Определение. Норму $\|x\|_2$ в нормированном пространстве X назовем подчиненной норме $\|x\|_1$, если существует постоянная $C > 0$ такая, что для любого x выполнено $\|x\|_2 \leq C\|x\|_1$.

Определение. Нормы $\|x\|_1$, $\|x\|_2$ называются эквивалентными, если существуют постоянные C_1 и C_2 такие, что для любого x выполнено $C_1\|x\|_1 \leq \|x\|_2 \leq C_2\|x\|_1$, в этом случае $C_2^{-1}\|x\|_2 \leq \|x\|_1 \leq C_1^{-1}\|x\|_2$.

В силу эквивалентности норм, если $x_n \rightarrow \bar{x}$ в $\|\circ\|_1$, то $x_n \rightarrow \bar{x}$ и в $\|\circ\|_2$, и наоборот. То есть сходимость последовательности (по расстоянию) будет иметь место независимо от выбора нормы.

Теорема (об эквивалентности норм). В конечномерном пространстве две любые нормы эквивалентны.

В силу этой теоремы нормы в пространствах R^n , $C^k[a, b]$ эквивалентны.

Будем теперь рассматривать функции, имеющие непрерывные производные порядка $K-1$ и обобщенную производную порядка K такую, чтобы и сама функция, и все ее производные были бы интегрируемы с квадратом. Пространства таких функций называются пространством Соболева W_2^K .

Если рассматривать функции, имеющие обобщенную первую производную, такую, чтобы и сама функция, и ее обобщенная первая производная были бы интегрируемы с квадратом, то пространства таких функций называются пространствами Соболева W_2^1 .

Будем рассматривать пространство функций $w \in W_2^1$ (пространство Соболева) с нормой

$$\|w\|_{W_2^1}^2 = \int_0^X (w^2 + (w'_x)^2) dx$$

для одномерного случая;

$$\|w\|_{W_2^1}^2 = \iint_{\Omega} w^2 dx dy + \iint_{\Omega} \left(\left(\frac{dw}{dx} \right)^2 + \left(\frac{dw}{dy} \right)^2 \right) dx dy$$

для двумерного случая.

4. Банаховы и гильбертовы пространства

О п р е д е л е н и е. Полное нормированное (следовательно, и метрическое) пространство называется банаховым (B).

В банаховом пространстве определена линейная комбинация элементов x_i , $i = 1, \dots, n$: $\sum_{i=1}^n \lambda_i x_i$, поскольку B — линейное пространство.

О п р е д е л е н и е. Линейное вещественное пространство называется евклидовым, если любой паре его элементов x, y поставлено в соответствие вещественное число (x, y) , которое называется скалярным произведением. Для него справедливы следующие аксиомы скалярного произведения:

$$(x, x) \geq 0, \quad (x, x) = 0 \Leftrightarrow x = 0, \quad (\text{П1.5})$$

$$(x + y, z) = (x, z) + (y, z), \quad (\text{П1.6})$$

$$(x, y) = (y, x),$$

$$(\lambda x, y) = \lambda(x, y). \quad (\text{П1.7})$$

Норма в нормированном евклидовом пространстве может быть определена следующим образом:

$$\|x\| = \sqrt{(x, x)};$$

для нее справедливо неравенство Коши–Буняковского:

$$|(x, y)| \leq \|x\| \cdot \|y\|.$$

Определение. *Комплексное линейное пространство $\bar{L}$ называется унитарным, если любой паре его элементов поставлено в соответствие комплексное число (x, y) , которое называется скалярным произведением. При этом выполнены аксиомы (1.5), (1.6), (1.7) и аксиома $(x, y) = \overline{(y, x)}$ (здесь черта соответствует комплексному сопряжению).*

Определение. *Полное евклидово, или полное унитарное пространство называется гильбертовым (H).*

Пространство H является линейным, нормированным, банаховым пространством одновременно. Для него справедливы все определения, понятия и аксиомы, введенные ранее для метрических, линейных, нормированных и банаховых пространств.

Определение. *Система $\{x_i\}$, $i = 1, \dots, n$ элементов гильбертова пространства является ортонормированной, если для $\forall i, j$ справедливо равенство $(x_i, x_j) = \delta_{ij}$. Если в H не существует элемента $x \neq 0$, ортогонального всем x_i , такая система называется полной.*

Примерами гильбертовых пространств являются:

R^n со скалярным произведением $(x, y) = \sum_{i=1}^n x_i y_i$,

l_2 со скалярным произведением $(x, y) = \sum_{i=1}^{\infty} x_i y_i$,

$L_2[a, b]$ со скалярным произведением $(f, f') = \int_a^b f(x) f'(x) dx$.

В гильбертовом пространстве выполняется равенство параллелограмма: $\|x + y\|^2 + \|x - y\|^2 = 2(\|x\|^2 + \|y\|^2)$.

5. Линейные операторы

Определение. *Пусть оператор (или отображение) $A: X \rightarrow Y$ где X, Y — два банаховых пространства, ставящий в соответствие каждому элементу $x \in X$ элемент $y \in Y$, определен на множестве $D(A) \in X$ (область определения оператора A). Оператор $A: X \rightarrow Y$ называется линейным, если*

$D(\mathbf{A})$ — линейное пространство и для $\forall x_1, x_2 \in D(\mathbf{A})$ и любых постоянных λ, μ выполнено

$$\mathbf{A}(\lambda x_1 + \mu x_2) = \lambda \mathbf{A}x_1 + \mu \mathbf{A}x_2.$$

При этом $y = \mathbf{A}x$, $x \in D(\mathbf{A})$, $y \in G(\mathbf{A})$, множество элементов $G(\mathbf{A}) = \{y \in Y, y = \mathbf{A}x, x \in D(\mathbf{A})\}$ называется множеством значений оператора $\mathbf{A}$; y — образ элемента x , x — прообраз элемента y ; $G(\mathbf{A})$ при этом есть образ $D(\mathbf{A})$: $G(\mathbf{A}) = \mathbf{A}(D)$.

В пространстве R^n отображение $\mathbf{A}x = y$, где $A = \{a_{ij}\}_{i,j=1}^n$ — квадратная матрица $n \times n$, а x, y — векторы-столбцы из R^n , задает линейный оператор $\mathbf{A}$.

Норма оператора определяется следующим равенством:

$$\|\mathbf{A}\| = \sup_{x \in X} \frac{\|\mathbf{A}x\|}{\|x\|}, \quad (\text{П1.8})$$

при этом оператор будет ограниченным. Такая норма называется согласованной нормой оператора.

Нормы в линейных пространствах могут быть выбраны не единственным образом. Каждая такая норма элементов линейного пространства будет порождать согласованную норму оператора. Если в какой-то норме выполнено $\|\mathbf{A}x\| \leq \|\mathbf{A}\| \cdot \|x\|$, то такая норма называется согласованной.

Суммой операторов $\mathbf{A} + \mathbf{B} = \mathbf{C}$; $\mathbf{C}: X \rightarrow Y$ назовем оператор, определенный для $\forall x \in X$ как $\mathbf{C}x = \mathbf{A}x + \mathbf{B}x$.

Для нормы $\mathbf{C}$ будет выполнено неравенство $\|\mathbf{C}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$.

Если: $\mathbf{A}: X \rightarrow Y$, $\mathbf{B}: Y \rightarrow Z$ то на множестве $D(\mathbf{A})$ определен оператор $\mathbf{C} = \mathbf{B}\mathbf{A}: X \rightarrow Z$ — произведение операторов $\mathbf{B}$ и $\mathbf{A}$ такой, что при этом выполняется неравенство $\|\mathbf{C}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|$.

О п р е д е л е н и е (действия с операторами в банаховых пространствах).

Пусть $\mathbf{A}, \mathbf{B}, \mathbf{C}$ — элементы множества линейных операторов в нормированном пространстве X , пространство Y — банахово. В Y определены операции $(\mathbf{A} + \mathbf{B})x = \mathbf{A}x + \mathbf{B}x$ и $(\lambda \mathbf{A})x = \lambda \mathbf{A}x$, тогда сумма операторов и произведение оператора на число также будут линейными операторами. Множество всех линейных операторов является линейным пространством, поскольку все соответствующие аксиомы для него выполнены.

Теорема. Множество линейных операторов, определенных всюду в нормированном пространстве X со значениями в ба-

наховом пространстве Y , является нормированным пространством.

Это пространство $\bar{l}(X, Y)$ является банаховым.

Сходимостью последовательности операторов $\mathbf{A}_n$ в этом пространстве называется сходимостью по норме, или равномерной сходимостью к оператору $\mathbf{A}$

$$\|\mathbf{A}_n - \mathbf{A}\| \xrightarrow{n \rightarrow \infty} 0.$$

В пространстве операторов $\bar{l}(X_0, Y)$ определен единичный оператор $\mathbf{I}$ такой, что $\mathbf{I}x = x$ для $\forall x \in X$ и $\|\mathbf{I}\| = 1$.

Определим степень оператора $\mathbf{A}^k$ следующим образом. Пусть $\mathbf{A}^2 = \mathbf{A} \cdot \mathbf{A}$. Тогда для любого натурального k будем считать, что $\mathbf{A}^k = \mathbf{A} \cdot \mathbf{A}^{k-1}$. При $k = 0$ положим $\mathbf{A}^0 = \mathbf{I}$. Для степеней оператора всегда верно $\|\mathbf{A}^k\| \leq \|\mathbf{A}\|^k$.

Величина $\rho(\mathbf{A}) = \lim_{k \rightarrow \infty} \|\mathbf{A}^k\|^{1/k}$ называется спектральным радиусом оператора, он не зависит от конкретного выбора норм.

Полиномы от операторов определяются следующим образом:

$$P_N(\mathbf{A}) = \sum_{k=0}^N c_k \mathbf{A}^k.$$

Можно определять функции операторов, например операторную экспоненту $e^{\mathbf{A}} = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}$.

Определение. Оператор $\mathbf{A}^{-1}$ называется обратным к $\mathbf{A}$, а операторы $\mathbf{A}$ и $\mathbf{A}^{-1}$ взаимно обратными, если $\mathbf{A} : X \rightarrow Y$ и $\exists \mathbf{A}^{-1} : Y \rightarrow X$ определенный на $G(\mathbf{A})$ и принимающий значения в $D(\mathbf{A})$, такой, что $\mathbf{A}^{-1}\mathbf{A}x = x$, $x \in D(\mathbf{A})$, $\mathbf{A}\mathbf{A}^{-1}y = y$, $y \in G(\mathbf{A})$. При этом $\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$.

Для оператора, обратного к произведению операторов, верно $(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \cdot \mathbf{A}^{-1}$.

6. Операторы в гильбертовом пространстве

Определение. Оператор $\mathbf{A}^*$ называется сопряженным оператору $\mathbf{A}$, если $\forall x, y \in H$ выполнено $(\mathbf{A}x, y) = (x, \mathbf{A}^*y)$.

Для $\mathbf{A}$ и $\mathbf{A}^*$ выполнено $\|\mathbf{A}\| = \|\mathbf{A}^*\|$. Оператор называется кососимметричным, если $\mathbf{A} = -\mathbf{A}^*$, и симметричным (симметрическим, самосопряженным), если $\mathbf{A} = \mathbf{A}^*$. Если $\mathbf{A}^*\mathbf{A} = \mathbf{A}\mathbf{A}^*$ оператор называется нормальным. Любой оператор представим в виде суммы самосопряженного и кососимметричного операторов $\mathbf{A} = \mathbf{A}' + \mathbf{A}''$, где $\mathbf{A}' = \frac{1}{2}(\mathbf{A} + \mathbf{A}^*)$, $\mathbf{A}'' = \frac{1}{2}(\mathbf{A} - \mathbf{A}^*)$.

Для любого оператора в гильбертовом пространстве верно $\forall x \in H \ (\mathbf{A}x, x) = (\mathbf{A}'x, x), (\mathbf{A}''x, x) = 0$.

Определение. Оператор $\mathbf{A}$, действующий в H , называется положительным, если $\forall x \in H: \|x\| \neq 0 \ (\mathbf{A}x, x) > 0$ (он обозначается $\mathbf{A} > 0$); неотрицательным, если $\forall x \in H \ (\mathbf{A}x, x) \geq 0$; положительно определенным, если $\exists \delta > 0: \forall x \in H \ (\mathbf{A}x, x) \geq \delta(x, x)$.

Аналогично определяются операторы отрицательные, неположительные, отрицательно определенные. Операторное неравенство $\mathbf{A} < \mathbf{B}$ означает, что оператор $\mathbf{A} - \mathbf{B}$ отрицательный, $\mathbf{A} - \mathbf{B} < 0$.

Определение. Число w называется числовым радиусом оператора, если $w(\mathbf{A}) = \sup_{\|x\|=1} |(\mathbf{A}x, x)|, x \in H$.

Числовой радиус оператора связан со спектральным радиусом (см. выше). Всегда справедливо неравенство $\rho(\mathbf{A}) \leq w(\mathbf{A})$. Кроме того, числовой радиус оператора удовлетворяет некоторым аксиомам нормы. В частности, для самосопряженного оператора можно считать $\|\mathbf{A}\| = w$.

Определение. Числа $m = \inf_{\|x\|=1} (\mathbf{A}x, x)$ и $M = \sup_{\|x\|=1} (\mathbf{A}x, x)$ называются границами оператора $\mathbf{A}$.

7. Операторные уравнения. Дифференцируемость операторов

Линейные алгебраические уравнения, линейные интегральные уравнения, линейные дифференциальные уравнения, обыкновенные уравнения, уравнения в частных производных могут быть записаны в виде

$$\mathbf{A}x = y, \quad (\text{П1.9})$$

где $\mathbf{A}$ — линейный оператор, $y \in Y$.

В этом случае решение (П1.9) может быть также записано в операторном виде:

$$x = \mathbf{A}^{-1}y. \quad (\text{П1.10})$$

Определение. Если существуют число λ и элемент $x \in X$ такие, что $\mathbf{A}x = \lambda x$, то x называется собственным элементом (собственной функцией) оператора $\mathbf{A}$, λ — собственным значением (собственным числом).

Определение. Пусть $\mathbf{A}$ — линейный ограниченный оператор и существует обратный линейный ограниченный оператор $\mathbf{A}^{-1}$ (оба оператора определены в нормированных пространствах). Тогда величина

$$\mu(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|. \quad (\text{П1.11})$$

называется числом обусловленности оператора $\mathbf{A}$.

Определение. Пусть X — полное метрическое пространство с метрикой $\rho(x)$; $x, y \in X$, $\Omega \in X$, и пусть в Ω задан оператор $\mathbf{P}$, переводящий множество Ω в себя ($\mathbf{P} : \Omega \rightarrow \Omega$). Элемент $y \in \Omega$ называется неподвижной точкой отображения (оператора) $\mathbf{P}$, если

$$y = \mathbf{P}y, \quad (\text{П1.12})$$

т. е. неподвижная точка является решением уравнения (П1.12).

Определение. Оператор $\mathbf{P}$ назовем сжимающим отображением (оператором сжатия) в Ω , если для $\forall x, y \in \Omega$ выполнено условие (условие Липшица) $\rho(\mathbf{P}x, \mathbf{P}y) \leq \alpha \rho(x, y)$, где $\alpha \in [0; 1)$ — константа.

Теорема (принцип сжимающих отображений). Пусть оператор $\mathbf{P}$, переводящий множество Ω в себя ($\mathbf{P} : \Omega \rightarrow \Omega$) является сжимающим. Тогда в Ω существует единственная неподвижная точка отображения (единственное решение уравнения (П1.12)).

В функциональном анализе известно много теорем о неподвижных точках отображений. Как правило, на их основе строятся доказательства сходимости тех или иных приближенных методов решения задач.

Пусть $\mathbf{A}x = y$ — уравнение, записанное в операторном виде, где $\mathbf{A} : X \rightarrow Y$ — оператор, действующий в метрическом пространстве

Y (обычно X и Y — банаховы или гильбертовы пространства), $x \in X$, $y \in Y$. Задача поиска элемента $x \in X$ в соответствии с данным операторным уравнением называется корректно поставленной по Адамару (или корректной), если:

- 1) для $y \in Y$ существует решение $x \in X$;
- 2) это решение единственное в X ;
- 3) решение уравнения непрерывно зависит от правой части $y \in Y$ (малые изменения в исходных данных поставленной задачи, т. е. в y , вызывают малые возмущения решения x); $\forall \varepsilon > 0 \exists \delta = \delta(\varepsilon): \forall y, y' \in Y: \rho(y, y') < \varepsilon \Rightarrow \rho(x, x') < \delta, x, x' \in X$.

О п р е д е л е н и е. Пусть X, Y — два нормированных пространства над полем R^1 и оператор $F: X \rightarrow Y$. Если для $x, h \in X$ существует предел (сходимость по норме Y)

$$dF(x, h) = \left. \frac{dF(x + th)}{dt} \right|_{t=0} = \lim_{t \rightarrow 0} \frac{F(x + th) - F(x)}{t},$$

то этот предел называется дифференциалом Гато (слабым дифференциалом) оператора F в точке x на приращении h . Ограниченный оператор $F'(x)$, определяемый равенством

$$dF(x, h) = F'(x) \cdot h,$$

называется производной Гато (слабой производной) оператора F в точке x .

Иногда в литературе слабый дифференциал называется также вариацией оператора. Если наряду с уравнением $F(u) = 0$ рассматривается линейное уравнение для приращений $F'(u)h = 0$, то в этом случае говорят об уравнении в вариациях.

Производная Гато любого линейного оператора совпадает с самим этим оператором. Очевидно, что тогда и уравнение в вариациях будет совпадать с исходным уравнением.

О п р е д е л е н и е. Пусть X, Y — два вещественных банаховых пространства; $F: X \rightarrow Y$ оператор, действующий из X в Y . Производной Фреше (сильной производной) в точке $x \in X$ назовем линейный оператор $A: X \rightarrow Y$ такой, что для $\forall x \in X$ выполнено

$$F(x + h) - F(x) = Ah + r_0(x, h),$$

где $r_0(x, h)$ — остаточный член. Для него выполняется

$$\frac{\|r_0(x, h)\|_Y}{\|h\|_X} \rightarrow 0 \quad \text{при } \|h\|_X \rightarrow 0.$$

Оператор $\mathbf{F}$ называется сильно дифференцируемым (или дифференцируемым), линейная часть приращения $\mathbf{A}h$ — дифференциал Фреше оператора $\mathbf{F}$.

Производная Фреше любого линейного оператора также совпадает с самим этим оператором.

Если у оператора существует производная Фреше, то существует и производная Гато. Обе этих производных совпадают.

Из существования производной Гато не следует существования производной Фреше.

СИСТЕМЫ ОРТОГОНАЛЬНЫХ ПОЛИНОМОВ

1. Введение

Определение. *Обобщенным полиномом на отрезке $[a, b]$ называется сумма $Q(x) = \sum_{i=0}^n c_i \varphi_i(x)$, где $\varphi_i(x)$ — элементы заданной системы непрерывных на отрезке $[a, b]$ функций, c_i — постоянные коэффициенты.*

Считаем, что система функций $\varphi_i(x)$ линейно независима. Будем называть эти функции базисными функциями.

При выборе в качестве системы базисных функций системы степенных функций $\varphi_i(x) = x^i$ обобщенный полином переходит в обыкновенный (степенной) полином.

Определение. *Система полиномов $Q_0(x), Q_1(x), \dots, Q_m(x)$ называется ортогональной на отрезке $[a, b]$ с весовой функцией (весом) $\rho(x)$ в смысле введенного скалярного произведения $(Q_i, Q_k) = \int_a^b \rho(x) Q_i(x) Q_k(x) dx$, если $(Q_i, Q_k) = 0$.*

Ниже кратко опишем наиболее употребительные системы ортогональных полиномов.

Многочлены Лежандра $q_n(x)$ — единственные, для которых условие их ортогональности на отрезке выполняется «в чистом виде» без введения весовой функции в скалярное произведение, а именно,

$$\int_{-1}^1 q_n(x) q_m(x) dx = \begin{cases} 0, & n \neq m, \\ \frac{2}{2n+1}, & n = m. \end{cases}$$

Для многочленов Лежандра известна порождающая их явная формула Родрига:

$$q_n(x) = \frac{1}{n! 2^n} \frac{d^n}{dx^n} (x^2 - 1)^n.$$

Многочлены Лежандра подчиняются рекуррентной формуле

$$(n+1)q_{n+1}(x) = (2n+1)xq_n(x) - nq_{n-1}(x),$$

которая позволяет, зная нулевой и первый многочлены, легко определять все последующие. Используя формулу Родрига для первых двух полиномов и рекуррентное соотношение для остальных, можно получить явный вид полиномов Лежандра различных степеней:

$$\begin{aligned} q_0(x) &= 1, & q_1(x) &= x, & q_2(x) &= \frac{1}{2}(3x^2 - 1), \\ q_3(x) &= \frac{1}{2}(5x^3 - 3x), & q_4(x) &= \frac{1}{8}(35x^4 - 30x^2 + 3), \\ q_5(x) &= \frac{1}{8}(63x^5 - 70x^3 + 15x), & \dots \end{aligned}$$

Норма каждого полинома Лежандра на $[-1; 1]$ вычисляется как норма функции, интегрируемой с квадратом,

$$\|q_n(x)\|^2 = \int_{-1}^1 q_n(x)^2 dx = \frac{2}{2n+1}, \quad \text{или} \quad \|q_n\| = \sqrt{\frac{2}{2n+1}}.$$

Полиномы Лежандра являются решениями обыкновенного дифференциального уравнения

$$\frac{d}{dz} \left[(1-x^2) \frac{du}{dz} \right] + n(n+1)u = 0,$$

где z , вообще говоря, — комплексное переменное.

Для внутренних точек отрезка $[-1; 1]$ справедлива оценка

$$|q_n(x)| \leq \frac{\sqrt{\pi}}{\sqrt{2n(1-x^2)}}.$$

2. Многочлены Чебышёва

Одним из самых известных семейств многочленов являются многочлены Чебышёва (первого рода), обычно обозначаемые $T_n(x)$. Многочлены Чебышёва удовлетворяют рекуррентному соотношению

$$T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x), \quad (\text{П2.1})$$

которое позволяет, задав первые два многочлена, определить все остальные:

$$\begin{aligned}T_0(x) &= 1, & T_1(x) &= x, & T_2(x) &= 2x^2 - 1, \\T_3(x) &= 4x^3 - 3x, & T_4(x) &= 8x^4 - 8x^2 + 1, \\T_5(x) &= 16x^5 - 20x^3 + 5x, & \dots\end{aligned}$$

Существует несколько определений многочленов Чебышёва первого рода. Например, определив $T_0(x) = 1$, $T_1(x) = x$, можно использовать (П2.1) в качестве определения многочленов Чебышёва. Можно давать определения на основе различных представлений этих полиномов.

Для многочленов Чебышёва известно много способов представления, одним из самых удобных оказывается тригонометрическое:

$$T_n(x) = \cos(n \arccos x). \quad (\text{П2.2})$$

Действительно, при любом значении угла Θ справедливо тождество

$$\begin{aligned}\cos((n+1)\Theta) &= \cos(n\Theta + \Theta) = \cos\Theta \cos(n\Theta) - \sin\Theta \sin(n\Theta) = \\&= 2\cos\Theta \cos(n\Theta) - (\cos\Theta \cos(n\Theta) + \sin\Theta \sin(n\Theta)) = \\&= 2\cos\Theta \cos(n\Theta) - \cos((n-1)\Theta).\end{aligned}$$

Полагая в этом тождестве $\Theta = \arccos x$, получим

$$\cos((n+1)\arccos x) = 2x \cos(n \arccos x) - \cos((n-1)\arccos x). \quad (\text{П2.3})$$

Сравнивая (П2.1) и (П2.4), убеждаемся, что функция $\cos(n \arccos x)$ удовлетворяет тому же разностному уравнению, что и $T_n(x)$ при начальных условиях

$$\cos(0 \cdot \arccos x) = 1 = T_0(x), \quad \cos(1 \cdot \arccos x) = x = T_1(x),$$

это означает, что две функции совпадают при любом n .

Рекуррентное соотношение является разностным уравнением по n при параметре x . *Этому разностному уравнению соответствует* характеристическое уравнение

$$\lambda^2 - 2x\lambda + 1 = 0, \quad \lambda_{1,2} = x \pm \sqrt{x^2 - 1}.$$

При $x \neq \pm 1$ корни характеристического уравнения простые, следовательно, решение представимо как $T_n(x) = c_1 \lambda_1^n + c_2 \lambda_2^n$. Из начальных условий $T_0(x) = 1$, $T_1(x) = x$ будем иметь, что $c_1 = c_2 = 1/2$. Тогда

$$T_n(x) = \frac{(x + \sqrt{x^2 - 1})^n + (x - \sqrt{x^2 - 1})^n}{2}. \quad (\text{П2.4})$$

При комплексных значениях $x = z$ функция $\sqrt{z^2 - 1}$ не является однозначной. Под $\sqrt{z^2 - 1}$ будем понимать ветвь, которая при действительных $z > 1$ принимает положительные значения и определена в комплексной плоскости с разрезом $[-1; 1]$.

Многочлены Чебышёва можно представить в виде конечного ряда

$$T_n(x) = \frac{n}{2} \sum_{k=0}^{[n/2]} \frac{(-1)^k (n-k-1)!}{k!(n-2k)!} (2x)^{n-2k}.$$

Нули многочленов Чебышёва. Из уравнения

$$\cos(n \arccos x) = 0$$

получаем, что корни многочлена Чебышёва степени n суть

$$x_m = \cos\left(\frac{\pi(2m+1)}{2n}\right), \quad m = 0, 1, \dots, n-1.$$

Точками экстремума $T_n(x)$ будут точки, в которых $|T_n(x)| = 1$, т. е.

$$x_{(m)} = \cos\left(\frac{\pi m}{n}\right), \quad m = 0, 1, \dots, n-1.$$

Из рекуррентного соотношения (П2.1) видим, что коэффициент при старшей степени у многочлена $T_n(x)$ растет как 2^{n-1} .

Приведенный многочлен Чебышёва

$$\bar{T}_n(x) = 2^{n-1} T_n(x)$$

с коэффициентом при старшей степени, равным единице, называют *многочленом, наименее уклоняющимся от нуля*, в силу следующей теоремы.

Теорема (Чебышёва). Из всех многочленов $P_n(x)$ степени n со старшим коэффициентом 1 нормированный многочлен Чебышёва $\bar{T}_n(x)$ наименее уклоняется от нуля на отрезке $[-1; 1]$.

Это означает, что $\max_{[-1;1]} |P_n(x)| \leq \max_{[-1;1]} |\bar{T}_n(x)| = \frac{1}{2^{n-1}}$ т.е. среди всех многочленов степени n многочлен $\bar{T}_n(x)$ минимизирует максимальное расстояние от графика многочлена при $x \in [-1; 1]$ до оси Ox .

Полиномы Чебышёва первого рода удовлетворяют обыкновенному дифференциальному уравнению

$$(1-x^2)T_n''(x) - xT_n'(x) + n^2T_n(x) = 0.$$

Иногда рассматривают многочлены Чебышёва второго рода $U_n(x)$:

$$U_n(x) = \frac{1}{n+1} \frac{d}{dx} T_{n+1}(x),$$

или, в тригонометрическом виде, $U_n(x) = \frac{\sin((n+1)\Theta)}{\sin \Theta}$, $\cos \Theta = x$.

Эти полиномы удовлетворяют обыкновенному дифференциальному уравнению

$$(1-x^2)U_n''(x) - 3U_n'(x) + (n^2 - 4n)U_n(x) = 0.$$

Нули многочленов Чебышёва второго рода совпадают с точками экстремума многочленов Чебышёва первого рода степени на единицу выше. Многочлен Чебышёва второго рода характеризуется как многочлен с коэффициентом при старшей степени 2^n , интеграл от которого по отрезку $[-1; 1]$ принимает наименьшее возможное значение.

Рекуррентное соотношение для многочленов Чебышёва второго рода такое же, как и для многочленов первого рода:

$$\begin{aligned} U_{n+1}(x) &= 2xU_n(x) - U_{n-1}(x), \\ U_0(x) &= 1, \quad U_1(x) = 2x, \quad U_2(x) = 4x^2 - 1, \\ U_3(x) &= 8x^3 - 4x, \end{aligned}$$

.....

$$U_n(x) = \frac{(x + \sqrt{x^2 - 1})^{n+1} - (x - \sqrt{x^2 - 1})^{n+1}}{2\sqrt{x^2 - 1}},$$

$$U_n(x) = \frac{n}{2} \sum_{k=0}^{[n/2]} \frac{(-1)^k (n-k)!}{k!(n-2k)!} (2x)^{n-2k}.$$

Связь многочленов Чебышёва первого и второго рода может быть представлена также в виде

$$(x^2 - 1)U_{n-1}(x) = xT_n(x) - T_{n-1}(x).$$

Для многочленов Чебышёва первого и второго рода имеет место ортогональность с весами:

$$\int_{-1}^1 T_n(x) T_m(x) \frac{dx}{\sqrt{1-x^2}} = \begin{cases} 0, & n \neq m, \\ \frac{\pi}{2}, & n = m \neq 0, \\ \pi, & n = m = 0. \end{cases} \quad (\text{П2.5})$$

$$\int_{-1}^1 U_n(x) U_m(x) \sqrt{1-x^2} dx = \begin{cases} 0, & n \neq m, \\ \frac{\pi}{2}, & n = m \neq 0. \end{cases} \quad (\text{П2.6})$$

Это свойство роднит многочлены Чебышёва с другими системами ортогональных многочленов.

Вне отрезка ортогональности полиномы Чебышёва также обладают экстремальным свойством. Среди всех многочленов данной степени, значения которых на отрезке $[-1; 1]$ не превосходят по модулю единицы, многочлены Чебышёва имеют наибольшее значение в любой точке вне этого отрезка, т. е. функции $T_n(x)$ очень сильно растут вне интервала ортогональности.

Для практических приложений очень важным свойством многочленов Чебышёва является их ортогональность в смысле скалярного произведения, определенного для векторов, заданных как значения этих многочленов в выделенном наборе точек. Оказывается, что на множестве нулей многочлена Чебышёва степени $n+1$ все многочлены меньшей степени образуют ортогональную систему. Это означает, что если $\{x_m\}$ — множество нулей многочлена степени $n+1$, т. е.

$$T_{n+1}(x_m) = 0, \quad m = 0, 1, \dots, n,$$

то

$$\frac{2}{n+1} \sum_{m=0}^n T_k(x_m) T_l(x_m) = \delta_{kl}, \quad k, l = 0, 1, \dots, n.$$

Многочлены Лежандра и Чебышёва 1-го и 2-го рода являются частными случаями многочленов Якоби, ортогональных на $[-1; 1]$ с весовой функцией $\rho(x) = (1-x)^\alpha(1+x)^\beta$:

$$P_n^{(\alpha, \beta)}(x) = \frac{(-1)^n}{2^n n!} \rho^{-1}(x) \frac{d^n}{dx^n} \left[(1-x)^{\alpha+n} (1+x)^{\beta+n} \right]. \quad (\text{П2.7})$$

При $\alpha = \beta = 0$ $P_n^{(\alpha, \beta)}(x)$ являются многочленами Лежандра, при $\alpha = \beta = -1/2$ — многочленами Чебышёва первого рода, при $\alpha = \beta = 1/2$ — второго рода.

3. Некоторые другие системы ортогональных полиномов

Многочлены Лагерра $L_n(x)$ определяются требованием их ортогональности на полубесконечном интервале $[0; +\infty)$ с весовой функцией e^{-x} , обеспечивающей интегрируемость любого многочлена на этом интервале:

$$\int_{-1}^1 L_n(x) L_m(x) e^{-x} dx = \begin{cases} 0, & n \neq m, \\ (n!)^2, & n = m. \end{cases}$$

Многочлены Лагерра также могут быть определены с помощью рекуррентного соотношения

$$L_{n+1}(x) = (2n+1-x)L_n(x) - n^2 L_{n-1}(x).$$

Это позволяет найти все старшие многочлены после нулевого и первого:

$$\begin{aligned} L_0(x) &= 1, & L_1(x) &= -x+1, & L_2(x) &= x^2-4x+2, \\ L_3(x) &= -x^3+9x^2-18x+6, & L_4(x) &= x^4-16x^3+72x^2-96x+24, \\ L_5(x) &= -x^5+25x^4-200x^3+600x^2-600x+120, & \dots \end{aligned}$$

Заметим, что под тем же обозначением $L_n(x)$ в литературе может встречаться многочлен $\frac{1}{n!} L_n(x)$.

Существуют ортогональные многочлены Лагерра более общего вида, их ортогональность может пониматься как ортогональность с весовой функцией $\rho(x) = x^\alpha e^{-x}$, $\alpha > -1$.

Эти полиномы представляются формулой

$$\bar{L}_n^{(\alpha)}(x) = (-1)^n x^{-2} e^x \frac{d^n}{dx^n} (x^{\alpha+n} e^{-x}).$$

Полиномы любых степеней могут также быть получены с использованием рекуррентного соотношения

$$\bar{L}_{n+1}^{(\alpha)}(x) - (x - \alpha - 2n - 1) \bar{L}_n^{(\alpha)}(x) + n(\alpha + n) \bar{L}_{n-1}^{(\alpha)}(x) = 0.$$

Полиномы Лагерра являются решениями обыкновенного дифференциального уравнения

$$x \left(\bar{L}_n^{(\alpha)}(x) \right)' + (\alpha + 1 - x) \bar{L}_n^{(\alpha)}(x) + n \bar{L}_n^{(\alpha)}(x) = 0.$$

Многочлены Эрмита $H_n(x)$ ортогональны на всей числовой оси с весом e^{-x^2} :

$$\int_{-1}^1 H_n(x) H_m(x) e^{-x^2} dx = \begin{cases} 0, & n \neq m, \\ 2^n n! \sqrt{\pi}, & n = m. \end{cases}$$

Многочлены Эрмита удовлетворяют рекуррентному соотношению

$$H_{n+1}(x) = 2xH_n(x) - 2nH_{n-1}(x).$$

Несколько первых полиномов Эрмита будут:

$$\begin{aligned} H_0(x) &= 1, & H_1(x) &= 2x, & H_2(x) &= 4x^2 - 2, \\ H_3(x) &= 8x^3 - 12x, & H_4(x) &= 16x^4 - 48x^2 + 12, \\ H_5(x) &= 32x^5 - 160x^3 + 120x, & \dots \end{aligned}$$

Многочлены Эрмита являются решениями обыкновенного дифференциального уравнения

$$H_n''(x) - 2xH_n'(x) + 2nH_n(x) = 0.$$

Ортогональные многочлены Якоби, Лагерра, Эрмита являются решениями одного семейства ОДУ 2-го порядка. Все ортогональные многочлены $P_n(x)$ одной системы линейно независимы и удовлетворяют рекуррентному соотношению вида

$$\alpha_n P_{n+1}(x) + (\beta_n - x) P_n(x) + \gamma_n P_{n-1}(x) = 0.$$

Общим свойством всех приведенных систем ортогональных многочленов $P_n(x)$ является то, что все n корней — простые и находятся на промежутке ортогональности, при этом корни $P_n(x)$ разделяются корнями $P_{n-1}(x)$. Наименее уклоняются от нуля на отрезке $[-1; 1]$ в норме C многочлены Чебышёва первого рода, в норме L_1 — многочлены Чебышёва второго рода, в норме L_2 — многочлены Лежандра.

ТОЧНЫЕ РЕШЕНИЯ РАЗНОСТНЫХ УРАВНЕНИЙ

1. Скалярные разностные уравнения

Определение. Линейным разностным уравнением порядка n с постоянными коэффициентами назовем уравнение вида

$$a_0 u_k + a_1 u_{k+1} + \dots + a_n u_{k+n} = f_k, \quad k = 0, 1, \dots, \quad (\text{ПЗ.1})$$

или $\sum_{j=0}^n a_j u_{k+j} = f_k$ где коэффициенты $a_1, \dots, a_n$ являются заданными вещественными числами; $a_n \neq 0$, f_k — функция, заданная при $\forall k \in N$.

Порядок разностного уравнения будет определяться количеством значений функции в начальных точках, необходимым для однозначного решения задачи. По аналогии с дифференциальными уравнениями, при решении разностных уравнений можно говорить о задаче Коши (все данные заданы на одном конце отрезка, на котором решается разностная задача) или о краевой задаче.

Ниже мы увидим, что многие свойства линейных разностных уравнений аналогичны свойствам уравнений дифференциальных.

Начальные данные для (ПЗ.1) задаются в виде

$$u(0) = u_0, \quad u(1) = u_1, \quad \dots, \quad u(n-1) = u_{n-1}. \quad (\text{ПЗ.2})$$

Теорема. Решение задачи Коши (ПЗ.1)–(ПЗ.2) существует и единственно.

Приведем примеры часто встречающихся разностных уравнений:

$au_k = f_k$, $a \neq 0$ — уравнение нулевого порядка;

$au_k + bu_{k+1} = f_k$, $b \neq 0$ — уравнение первого порядка;

$au_{k-1} + bu_k + cu_{k+1} = f_k$, $c \neq 0$ — уравнение второго порядка.

Если правая часть (ПЗ.1) тождественно равна нулю, то разностное уравнение называется однородным.

О п р е д е л е н и е. Система n линейно независимых решений φ_{jk} , $j = 1, \dots, n$, линейного однородного разностного уравнения

$$a_0 u_k + a_1 u_{k+1} + \dots + a_n u_{k+n} = 0 \quad (\text{ПЗ.3})$$

порядка n называется фундаментальной системой решений уравнения.

Отметим, что для уравнения при $a_n \neq 0$ всегда можно построить фундаментальную систему решений.

Например, решениями уравнения

$$6u_k - 5u_{k+1} + u_{k+2} = 0$$

будут функции 2^k и 3^k . Они образуют фундаментальную систему решений данного уравнения (проверка проводится непосредственной подстановкой).

О п р е д е л е н и е. Функция

$$u_k = c_1 \varphi_{1k} + c_2 \varphi_{2k} + \dots + c_n \varphi_{nk},$$

где φ_{jk} — фундаментальная система решений однородного уравнения (ПЗ.3), c_j — произвольные постоянные, $k \in N$, называется общим решением (ПЗ.3).

Фундаментальное решение линейного однородного разностного уравнения ищется следующим образом. Будем искать решение в виде геометрической прогрессии

$$u_k = C\lambda^k, \quad (\text{ПЗ.4})$$

где λ — знаменатель геометрической прогрессии — вещественные или комплексное число ($\lambda \neq 0$). Его можно найти, подставляя (ПЗ.4) в (ПЗ.3). После сокращения на $C\lambda^k$, получим алгебраическое уравнение вида

$$\lambda^n + a_1 \lambda^{n-1} + \dots + a_n = 0. \quad (\text{ПЗ.5})$$

Как и для линейных обыкновенных дифференциальных уравнений, это уравнение называется характеристическим. Тогда λ — характеристическое число. Согласно основной теореме алгебры, характеристическое уравнение имеет n корней (считая пары комплексно-сопряженных и кратные корни). Если $a_n \neq 0$, то характеристическое уравнение не может иметь нулевых корней.

Если все корни $\lambda_1, \dots, \lambda_n$ характеристического уравнения вещественные и попарно различные, то решения однородного уравнения (ПЗ.3) $\lambda_1^k, \lambda_2^k, \dots, \lambda_n^k$ линейно независимы. Это утверждение можно доказать, рассмотрев определитель

$$D = \begin{vmatrix} \lambda_1^k & \lambda_2^k & \dots & \lambda_n^k \\ \lambda_1^{k+1} & \lambda_2^{k+1} & \dots & \lambda_n^{k+1} \\ \dots & \dots & \dots & \dots \\ \lambda_1^{k+n-1} & \lambda_2^{k+n-1} & \dots & \lambda_n^{k+n-1} \end{vmatrix}.$$

Его легко вычислить, в результате мы получим

$$D = \lambda_1^k \cdot \lambda_2^k \dots \lambda_n^k W(\lambda_1, \dots, \lambda_n) \neq 0,$$

так как $W(\lambda_1, \dots, \lambda_n)$ — определитель Вандермонда для $\lambda_1, \dots, \lambda_n$.

В этом случае функция

$$u_k = c_1 \lambda_1^k + c_2 \lambda_2^k + \dots + c_n \lambda_n^k,$$

где $c_1, \dots, c_n$ — произвольные постоянные, будет общим решением линейного однородного разностного уравнения (ПЗ.3).

Например, для разностного уравнения

$$-2u_k + u_{k+1} + u_{k+2} = 0$$

характеристическое уравнение будет

$$\lambda^2 + \lambda - 2 = 0,$$

корни которого $\lambda_1 = 1$, $\lambda_2 = -2$. Следовательно, общее решение этого уравнения представляется суммой двух геометрических прогрессий, знаменатель одной из них равен единице:

$$u_k = c_1 (-2)^k + c_2.$$

О п р е д е л е н и е. Число λ_0 называется корнем кратности m ($m \in N$, $1 \leq m \leq n$) характеристического уравнения (ПЗ.5), если его можно представить в виде $L(\lambda) = (\lambda - \lambda_0)^m L_1(\lambda)$, где $L_1(\lambda)$ — многочлен степени $n - m$ и $L_1(\lambda) \neq 0$.

Видно, что λ_0 является корнем кратности m уравнения $L(\lambda) = 0$ тогда и только тогда, когда $L(\lambda_0) = L'(\lambda_0) = \dots = L^{m-1}(\lambda_0) = 0$, $L^m(\lambda_0) \neq 0$.

Теорема. Пусть характеристическое уравнение (ПЗ.5) однородного уравнения (ПЗ.3) имеет корни $\lambda_1, \lambda_2, \dots, \lambda_r$ ($r \in N$, $1 \leq r \leq n$) кратностей $q_1, q_2, \dots, q_r$ соответственно, причем $\sum_{i=1}^r q_i = n$. Тогда общее решение линейного однородного разностного уравнения порядка n будет иметь вид

$$u_k = \sum_{i=1}^r (c_{0i} + c_{1i}k + c_{2i}k^2 + \dots + c_{n,i-1}k^{n-i}) \lambda_i^k, \quad (\text{ПЗ.6})$$

где все c_i — постоянные.

Перепишем (ПЗ.6) в развернутом виде:

$$\begin{aligned} u_k = & c_{11}\lambda_1^k + c_{12}k\lambda_1^k + \dots + c_{1q_1}k^{q_1-1}\lambda_1^k + \\ & + c_{21}\lambda_2^k + c_{22}k\lambda_2^k + \dots + c_{2q_2}k^{q_2-1}\lambda_2^k + \dots + \\ & + c_{r1}\lambda_r^k + c_{r2}k\lambda_r^k + \dots + c_{rq_r}k^{q_r-1}\lambda_r^k, \end{aligned} \quad (\text{ПЗ.7})$$

т. е. каждому корню λ_i кратности q_i соответствует набор частных решений вида $\lambda_i^k, k\lambda_i^k, \dots, k^{q_i-1}\lambda_i^k$. Равенство (ПЗ.7) можно представить в виде двойной суммы:

$$u_k = \sum_{n=1}^r \sum_{j=1}^{q_n} c_{nj} k^{q_j-1} \lambda_{q_j}^k. \quad (\text{ПЗ.8})$$

Например, характеристическое уравнение для однородного разностного уравнения

$$u_k - u_{k+1} - u_{k+2} + u_{k+3} = 0$$

имеет вид

$$\lambda^3 - \lambda^2 - \lambda + 1 = 0.$$

Характеристическое уравнение легко решается. Его корни $\lambda_1 = 1$ кратности 2, $\lambda_2 = -1$. В этом случае общее решение исходного разностного уравнения будет $u_k = c_1 + c_2k + c_3(-1)^k$.

Отметим аналогию между решением линейных дифференциальных уравнений и линейных разностных уравнений. Частное решение задачи Коши для однородного обыкновенного дифференциального уравнения с постоянными коэффициентами

$$a_0 u_x + a_1 u'_x + \dots + a_n u_x^{(n)} = 0$$

ищется в виде $u(x) = e^{\mu x}$. После подстановки частного вида решения в дифференциальное уравнение получаем алгебраическое уравнение — характеристическое уравнение для определения множителей в показателе экспоненты

$$\sum_{i=0}^n a_i \mu^i = 0. \quad (\text{ПЗ.9})$$

Если $\mu_1, \dots, \mu_r$ являются различными корнями кратности $q_1, \dots, q_r$, соответственно, то общее решение однородного дифференциального уравнения представляется двойной суммой, аналогичной (ПЗ.8):

$$\begin{aligned} u(x) = & c_{11}e^{\mu_1 x} + c_{12}xe^{\mu_1 x} + \dots + c_{1q_1}x^{q_1-1}e^{\mu_1 x} + \\ & + c_{21}e^{\mu_2 x} + c_{22}xe^{\mu_2 x} + \dots + c_{2q_2}x^{q_2-1}e^{\mu_2 x} + \dots + \\ & + c_{r1}e^{\mu_r x} + c_{r2}xe^{\mu_r x} + \dots + c_{rq_r}x^{q_r-1}e^{\mu_r x} = \sum_{n=1}^r \sum_{j=1}^{q_n} c_{nj}x^{q_j-1}e^{\mu_n x}. \end{aligned} \quad (\text{ПЗ.10})$$

Вернемся к рассмотрению разностных уравнений. Выше мы говорили только о случае действительных корней характеристического уравнения. Пусть теперь характеристическое уравнение имеет и кратные комплексные корни. Построим для каждого вещественного корня λ кратности p систему функций вида $\lambda^k, k\lambda^k, \dots, k^{p-1}\lambda^k$. Аналогичные системы функций мы будем строить и для пар комплексно-сопряженных корней. Заметим, что каждый комплексный корень мы можем представить в виде $\lambda = |\lambda|e^{i\varphi} = |\lambda|(\cos \varphi + i \sin \varphi)$, $0 \leq \varphi \leq 2\pi$; сопряженный корень будет $\bar{\lambda} = |\lambda|e^{-i\varphi} = |\lambda|(\cos \varphi - i \sin \varphi)$, здесь $|\lambda| = \sqrt{(\operatorname{Re} \lambda)^2 + (\operatorname{Im} \lambda)^2}$. Очевидно, тогда такое же представление имеем и для комплексно-сопряженного корня. Так как мы решаем действительную задачу (уравнение с действительными коэффициентами и действительными начальными условиями), то и решение должно быть действительным. Это достигается в случае, если у двух функций, соответствующих комплексно-сопряженным характеристическим корням, будут выбраны комплексно-сопряженные коэффициенты.

В этом случае можно опустить промежуточные выкладки и сразу считать, что совокупность функций $|\lambda|^k \cos k\varphi, k|\lambda|^k \cos k\varphi, \dots, k^{m-1}|\lambda|^k \cos k\varphi$ и $|\lambda|^k \sin k\varphi, k|\lambda|^k \sin k\varphi, \dots, k^{m-1}|\lambda|^k \sin k\varphi$ образует вещественную фундаментальную систему решений разностного линейного однородного уравнения (ПЗ.3).

В качестве примера приведем разностное уравнение

$$u_k + u_{k+2} = 0,$$

характеристическое уравнение для которого $\lambda^2 + 1 = 0$ имеет корни $\lambda = \pm i$. Тогда общее решение разностного уравнения будет $u_k = \bar{c}_1 i^k + \bar{c}_2 (-i)^k$, где $\bar{c}_1$ и $\bar{c}_2$ — произвольные комплексные постоянные.

Поскольку

$$\lambda = i = \cos \frac{\pi}{2} + i \sin \frac{\pi}{2} \quad \text{и} \quad \lambda^k = i^k = \cos \frac{k\pi}{2} + i \sin \frac{k\pi}{2},$$

то общее решение данного уравнения имеет вид

$$u_k = c_1 \cos \frac{k\pi}{2} + c_2 \sin \frac{k\pi}{2}.$$

Если разностное уравнение (ПЗ.1) неоднородное, то для некоторых правых частей специального вида можно найти его частное решение u_k^0 . Тогда удастся построить фундаментальную систему решений $\varphi_1^k, \dots, \varphi_n^k$ линейного однородного уравнения (ПЗ.3) и представить общее решение неоднородного уравнения в виде суммы общего решения однородного и частного решения неоднородного уравнений:

$$u_k = c_1 \varphi_1^k + \dots + c_n \varphi_n^k + u_k^0. \quad (\text{ПЗ.11})$$

Теорема. Пусть в неоднородном разностном уравнении (ПЗ.1) правая часть имеет вид

$$f_k = P_s(k) \mu^k,$$

где $P_s(k)$ — заданный полином степени s с вещественными коэффициентами, $\mu \neq 0$ — вещественное число. В этом случае, если μ не является корнем характеристического уравнения, то для рассматриваемого неоднородного уравнения существует частное решение вида $u_k^0 = Q_s(k) \mu^k$, где $Q_s(k)$ — полином той же степени s , что и $P_s(k)$.

Если число μ является корнем кратности m характеристического уравнения, то для неоднородного разностного уравнения (ПЗ.1) существует частное решение вида $u_k^0 = k^m Q_s(k) \mu^k$, где $Q_s(k)$ — полином той же степени s , что и $P_s(k)$.

Пример построения общего решения неоднородного уравнения. Рассмотрим уравнение

$$3u_k - 4u_{k+1} + u_{k+2} = k \cdot 2^k.$$

Ему соответствует характеристическое уравнение $\lambda^2 - 4\lambda + 3 = 0$. Его корни $\lambda_1 = 1$, $\lambda_2 = 3$ а общее решение будет $u_k = c_1 + c_2 \cdot 3^k + u_k^0$, где u_k^0 — частное решение неоднородного уравнения. В соответствии с вышеприведенной теоремой $u_k^0 = (ak + b) \cdot 2^k$, где a, b — неопределенные коэффициенты. Эти неопределенные коэффициенты ищутся подстановкой u_k^0 в разностное уравнение. Тогда

$$(a(k+2) + b) \cdot 2^{k+2} - 4(a(k+1) + b) \cdot 2^{k+1} + 3(a(k+b)) \cdot 2^k = k \cdot 2^k.$$

Приравнявая коэффициенты при одинаковых степенях k , получаем систему уравнений относительно a и b , из которой находим $a = -1$, $b = 0$. Общее решение в таком случае будет $u_k = c_1 + c_2 \cdot 3^k - k \cdot 2^k$.

Теорема. Пусть в неоднородном разностном уравнении (ПЗ.1) правая часть имеет вид

$$f(k) = |\lambda|^k [P_s(k) \cos k\alpha + Q_s(k) \sin k\alpha],$$

где $P_s(k)$, $Q_s(k)$ — заданные полиномы степени не больше s с вещественными коэффициентами, λ и α — числа. Тогда разностное уравнение имеет вещественное частное решение вида

$$u_k^0 = k^m |\lambda|^k [\overline{P}_s(k) \cos k\alpha + \overline{Q}_s(k) \sin k\alpha],$$

где $\overline{P}_s(k)$ и $\overline{Q}_s(k)$ — полиномы степени не больше s с вещественными коэффициентами. Здесь $m = 0$, если $\lambda = |\lambda|(\cos \alpha + i \sin \alpha)$ не является корнем характеристического уравнения; m равно кратности λ , если λ — корень характеристического уравнения.

2. Пример построения общего решения

Разностному уравнению

$$u_k + u_{k+2} = \sin \frac{k\pi}{4}$$

соответствует характеристическое уравнение $\lambda^2 + 1 = 0$, корни которого $\lambda_{1,2} = \pm i$. В таком случае общее вещественное решение ис-

ходного уравнения будет

$$u_k = c_1 \cos \frac{k\pi}{2} + c_2 \sin \frac{k\pi}{2} + u_k^0,$$

где u_k^0 — частное решение. По приведенной выше теореме оно ищется в виде

$$u_k^0 = a \cos \frac{k\pi}{4} + b \sin \frac{k\pi}{4},$$

где a, b — неопределенные коэффициенты. Они могут быть вычислены подстановкой частного решения в исходное разностное уравнение:

$$a \cos(k+2)\frac{\pi}{4} + b \sin(k+2)\frac{\pi}{4} + a \cos \frac{k\pi}{4} + b \sin \frac{k\pi}{4} = \sin \frac{k\pi}{4}.$$

Приравнявая коэффициенты при $\cos \frac{k\pi}{4}$ и $\sin \frac{k\pi}{4}$, получаем систему уравнений для определения a, b . Решив ее, находим $a = -b = 0.5$. Следовательно, общее решение задачи будет

$$u_k = c_1 \cos \frac{k\pi}{2} + c_2 \sin \frac{k\pi}{2} + \frac{1}{2} \left(\cos \frac{k\pi}{4} - \sin \frac{k\pi}{4} \right).$$

3. Системы линейных разностных уравнений

О п р е д е л е н и е. Системой линейных разностных уравнений порядка n называется система

$$\mathbf{u}_{k+1} = \mathbf{A} \mathbf{u}_k + \mathbf{f}_k, \quad (\text{П3.12})$$

где $\mathbf{A}$ — невырожденная квадратная матрица $n \times n$, $\mathbf{f}(k)$ — вектор-столбец правых частей (функция переменной k), вектор-столбец $\mathbf{u}_k$ — искомое решение.

В курсе линейной алгебры доказывается, что для систем линейных однородных разностных уравнений n -го порядка

$$\mathbf{u}_{k+1} = \mathbf{A} \mathbf{u}_k, \quad (\text{П3.13})$$

где $\mathbf{A}$ — невырожденная квадратная матрица $n \times n$, всегда можно построить фундаментальное и общее решение.

Нетривиальные решения системы (П3.13) однородных разностных уравнений ищутся в виде $\mathbf{u}_k = \lambda^k \boldsymbol{\omega}$, здесь λ — ненулевое собственное значение матрицы $\mathbf{A}$, $\boldsymbol{\omega}$ — соответствующий ему собственный вектор.

Теорема. Пусть в R^n существует базис из собственных векторов $\mathbf{w}_1, \dots, \mathbf{w}_n$ матрицы $\mathbf{A}(n \times n)$; $\lambda_1, \dots, \lambda_n$ — соответствующие им попарно различные собственные значения $\mathbf{A}$. Тогда общее решение системы $\mathbf{u}_{k+1} = \mathbf{A}\mathbf{u}_k$ имеет вид

$$\mathbf{u}_k = c_1 \lambda_1^k \mathbf{w}_1 + \dots + c_n \lambda_n^k \mathbf{w}_n. \quad (\text{ПЗ.14})$$

Пример. Решить систему линейных однородных разностных уравнений:

$$\begin{cases} u_{k+1} = -5u_k - 2v_k - 2w_k, \\ v_{k+1} = 10u_k + 4v_k + 2w_k, \\ w_{k+1} = 2u_k + v_k + 3w_k. \end{cases}$$

Решение. Выписываем матрицу системы. Собственные числа матрицы $\mathbf{A}$

$$\mathbf{A} = \begin{pmatrix} -5 & -2 & -2 \\ 10 & 4 & 2 \\ 2 & 1 & 3 \end{pmatrix}$$

находятся как решение уравнения $\det(\mathbf{A} - \lambda \mathbf{E}) = 0$ и равны $\lambda_1 = -1$, $\lambda_2 = 1$, $\lambda_3 = 2$. Соответствующие им собственные векторы будут

$$\mathbf{w}_1 = \begin{pmatrix} -1 \\ 2 \\ 0 \end{pmatrix}, \quad \mathbf{w}_2 = \begin{pmatrix} -1 \\ 4 \\ -1 \end{pmatrix}, \quad \mathbf{w}_3 = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}.$$

Тогда решение системы имеет вид

$$\begin{pmatrix} u \\ v \\ w \end{pmatrix}_k = c_1 (-1)^k \begin{pmatrix} -1 \\ 2 \\ 0 \end{pmatrix} + c_2 \begin{pmatrix} -1 \\ 4 \\ -1 \end{pmatrix} + c_3 2^k \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}.$$

В случае кратных собственных значений матрицы $\mathbf{A}$ для построения базиса необходимо учитывать присоединенные векторы.

Определение. Если λ — собственное значение матрицы $\mathbf{A}$, $\mathbf{w}_1$ — соответствующий ему собственный вектор, то векторы $\mathbf{w}_2, \mathbf{w}_3, \dots, \mathbf{w}_r$, называются присоединенными, если выполнено

$$\mathbf{A}\mathbf{w}_2 = \lambda \mathbf{w}_2 + \mathbf{w}_1, \quad \mathbf{A}\mathbf{w}_3 = \lambda \mathbf{w}_3 + \mathbf{w}_2, \quad \dots, \quad \mathbf{A}\mathbf{w}_r = \lambda \mathbf{w}_r + \mathbf{w}_{r-1}.$$

Система векторов $\mathbf{w}_1, \dots, \mathbf{w}_r$ называется жордановой цепочкой для собственного значения λ матрицы $\mathbf{A}$, число r — длиной жордановой цепочки.

Если λ имеет кратность 1, то жорданова цепочка состоит из одного собственного вектора; если λ кратное, то для него может существовать несколько жордановых цепочек, если λ — комплексное, то жордановы цепочки также комплексные.

Теорема (Жордана). Для любого комплексного линейного пространства z^n всегда существует базис, составленный из жордановых цепочек для всех собственных значений λ матрицы $\mathbf{A}$ (жорданов базис). Если все собственные значения λ вещественные, то все жордановы цепочки (и, соответственно, жорданов базис) также являются вещественными.

Теорема. Общее решение однородной линейной системы (ПЗ.13) порядка n имеет вид

$$\mathbf{u}_k = \sum_{j=1}^S \left[c_1 \lambda_j^k \mathbf{w}_{1j} + c_2 (\lambda_j^k \mathbf{w}_{2j} + c_k^1 \lambda_j^k \mathbf{w}_{1j}) + \dots \right. \\ \left. + c_{r_j} (\lambda_j^k \mathbf{w}_{r_j j} + c_k^1 \lambda_j^{k-1} \mathbf{w}_{j-1,j} + c_k^{r_j-1} \lambda_j^{k-r_j+1} \mathbf{w}_{1j}) \right].$$

Здесь $c_k^m = \frac{k!}{(k-m)! m!}$, $m = 1, \dots, r-1$, $r_1 + \dots + r_s = n$, S — число жордановых цепочек.

Для случая, когда $n = 2$, матрица $\mathbf{A}$ имеет одно собственное λ кратности 2, которому соответствует жорданов базис из собственного вектора $\mathbf{w}_1$ и присоединенного $\mathbf{w}_2$, общее решение будет иметь следующий вид:

$$\mathbf{u}_k = c_1 \lambda^k \mathbf{w}_1 + c_2 (\lambda^k \mathbf{w}_2 + k \lambda^{k-1} \mathbf{w}_1).$$

Если матрица $\mathbf{A}$ имеет одно собственное значение λ кратности 3, которому соответствует жорданов базис из собственного вектора $\mathbf{w}_1$ и присоединенных векторов $\mathbf{w}_2, \mathbf{w}_3$, то общее решение будет

$$\mathbf{u}_k = c_1 \lambda^k \mathbf{w}_1 + c_2 (\lambda^k \mathbf{w}_2 + k \lambda^{k-1} \mathbf{w}_1) + \\ + c_3 \left(\lambda^k \mathbf{w}_3 + k \lambda^{k-1} \mathbf{w}_2 + \frac{k(k-1)}{2} \lambda^{k-2} \mathbf{w}_1 \right).$$

НЕКОТОРЫЕ ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ СЛАУ С МАТРИЦАМИ СПЕЦИАЛЬНОГО ВИДА

1. Введение

Во многих приложениях в ходе решения задач возникают СЛАУ — системы линейных алгебраических уравнений (сеточных уравнений) — с матрицами специального вида. Как правило, эти матрицы разреженные, т.е. многие элементы матриц равны нулю. Частные случаи разреженных матриц — блочные матрицы, ленточные матрицы и т.п. В данном разделе мы рассмотрим только некоторые важные частные случаи — системы с ленточными (трехдиагональными, пятидиагональными) и блочно-трехдиагональными матрицами. При построении численных методов для таких задач применяют специальные способы хранения элементов матрицы. Действительно, если размер матрицы $N \times N$, а из N^2 элементов только $O(N)$ ненулевые, то нет необходимости запоминать почти N^2 нулей. Для численного решения СЛАУ с разреженными матрицами тоже часто применяются специальные методы, учитывающие специфику матриц. Опишем несколько таких методов.

2. Метод прогонки

СЛАУ с трехдиагональными матрицами часто возникают при численном решении краевых задач как для обыкновенных дифференциальных уравнений, так и для уравнений в частных производных, например, при аппроксимации вторых производных по пространственным переменным. СЛАУ такого вида встречается и при построении сплайн-интерполяций.

Пусть рассматривается система линейных уравнений $\mathbf{A}\mathbf{y} = \mathbf{f}$, причем матрица системы имеет специальный (ленточный) вид — от нуля отличаются лишь элементы на главной диагонали и на диагоналях, на одну выше и ниже главной.

Традиционно матрицу такой системы записывают в виде

$$\mathbf{A} = \begin{pmatrix} -b_0 & c_0 & 0 & \dots & 0 \\ a_1 & -b_1 & c_1 & \dots & 0 \\ 0 & a_2 & -b_2 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & -b_N \end{pmatrix}.$$

при этом никаких ограничений на знаки элементов не накладывается. Такие обозначения, во-первых, окажутся удобными. Во-вторых, они «наследуют» знаки слагаемых при аппроксимации второй разностной производной, т. е. соответствуют тем случаям, которые чаще всего встречаются в приложениях.

Рассмотрим экономичный вариант метода Гаусса, предназначенный для решения системы. Решение ищется в виде *прогоночного соотношения*

$$y_{n-1} = P_n u_n + Q_n, \quad n = 1, \dots, N, \quad (\text{П4.1})$$

где P_n и Q_n — *прогоночные коэффициенты*, подлежащие определению. Левое краевое условие легко записывается в виде прогоночного соотношения

$$y_0 = \frac{c_0}{b_0} y_1 - \frac{d_0}{b_0},$$

откуда сразу получаем $P_1 = c_0/b_0$, $Q_1 = -d_0/b_0$.

Теперь выведем рекуррентные формулы, позволяющие последовательно вычислить все прогоночные коэффициенты.

Подставим прогоночное соотношение $y_{n-1} = P_n u_n + Q_n$ в уравнение

$$a_n y_{n-1} - b_n y_n + c_n y_{n+1} = d_n,$$

получим

$$a_n (P_n y_n + Q_n) - b_n y_n + c_n y_{n+1} = d_n,$$

или

$$y_n = \frac{c_n}{b_n - a_n P_n} y_{n+1} + \frac{a_n Q_n - d_n}{b_n - a_n P_n}.$$

Сравнивая эту запись с (П4.1), видим, что для прогоночных коэффициентов должны выполняться равенства

$$P_{n+1} = \frac{c_n}{b_n - a_n P_n}, \quad Q_{n+1} = \frac{a_n Q_n - d_n}{b_n - a_n P_n}. \quad (\text{П4.2})$$

Эти формулы определяют прямой ход прогонки. На этом этапе последовательно слева направо определяются прогоночные коэффициенты P_n и Q_n .

Из краевого условия на правом конце

$$a_N y_{N-1} - b_N y_N = d_N$$

и прогоночного соотношения

$$y_{N-1} = P_N y_N + Q_N \quad (\text{П4.3})$$

сразу получим

$$Q_{N+1} = \frac{a_N Q_N - d_N}{b_N - a_N P_N} \quad \text{и} \quad y_N = Q_{N+1}.$$

Далее последовательно справа налево с помощью (П4.1) вычисляются остальные неизвестные y_n , $n = N-1, \dots, 1$ с использованием прогоночных соотношений и найденных при прямом ходе прогоночных коэффициентов. Это — обратный ход алгоритма прогонки.

Теорема. Пусть выполнены условия диагонального преобладания $|b_n| \geq |a_n| + |c_n|$ и хотя бы для одной строки матрицы системы имеет место строгое диагональное преобладание ($|b_n| > |a_n| + |c_n|$). Пусть, кроме того, $0 < P_1 < 1$. Тогда алгоритм прогонки устойчив.

3. Немонотонная прогонка

Пусть условия Теоремы не выполнены, но для каждой строки матрицы верно $|a_j| + |b_j| + |c_j| > 0$.

Тогда алгоритм прогонки можно модифицировать, используя в качестве основы метод Гаусса с выбором главного элемента по строкам.

Снова рассматриваем систему линейных уравнений с ленточной (трехдиагональной) матрицей

$$\mathbf{A} = \begin{pmatrix} -b_0 & c_0 & 0 & \dots & 0 \\ a_1 & -b_1 & c_1 & \dots & 0 \\ 0 & a_2 & -b_2 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & -b_N \end{pmatrix},$$

при этом никаких ограничений на знаки элементов не накладывается.

Рассмотрим метод немонотонной прогонки. Пусть m шагов метода выполнено. Это значит, что для всех уравнений с номером меньше m матрица приведена к двухдиагональному виду.

Рассмотрим три последовательных уравнения

$$-By_\mu + c_my_{m+1} = F, \quad (\text{П4.4})$$

$$Ay_\mu - b_{m+1}y_{m+1} + c_{m+1}y_{m+2} = \Phi, \quad (\text{П4.5})$$

$$a_{m+2}y_{m+1} - b_{m+2}y_{m+2} + c_{m+2}y_{m+3} = f_{m+2}, \quad (\text{П4.6})$$

остальные уравнения системы не изменились. Как мы увидим ниже, немонотонная прогонка сведется к выбору главного элемента по строке, следовательно, к перестановке столбцов. Поэтому в первом и втором из приведенных уравнений $\mu \leq m$.

На первом шаге немонотонной прогонки первое уравнение системы содержит хотя бы один ненулевой элемент. Пусть и после m шагов прямого хода немонотонной прогонки в первом уравнении (П4.4) сумма модулей коэффициентов ненулевая. Тогда возможны два случая.

1. $|B| \geq |c_m|$. Тогда из (П4.4)

$$y_\mu = \frac{c_m}{B}y_{m+1} - \frac{F}{B}.$$

Из уравнения (П4.5) можно исключить y_μ :

$$A\left(\frac{c_m}{B}y_{m+1} - \frac{F}{B}\right) - b_{m+1}y_{m+1} + c_{m+1}y_{m+2} = \Phi,$$

или

$$-\left(b_{m+1} - \frac{Ac_m}{B}\right)y_{m+1} + c_{m+1}y_{m+2} = \Phi + \frac{A}{B}F.$$

Если вместо (П4.5) теперь в системе использовать уравнение вида (П4.4), в новом уравнении

$$-\widetilde{B}y_v + c_{m+1}y_{m+2} = \widetilde{F}$$

положить $v = m + 1$, $\widetilde{F} = \Phi + \frac{A}{B}F$, $\widetilde{B} = b_{m+1} - \frac{Ac_m}{B}$, а в (П4.6)

считать $\widetilde{A} = a_{m+2}$, $\widetilde{\Phi} = f_{m+2}$, то таким образом мы исключим переменное под диагональю еще из одного уравнения и снова придем к системе того же вида.

2. $|B| < |c_m|$. Тогда

$$y_{m+1} = \frac{B}{c_m} y_\mu + \frac{F}{c_m}.$$

Из уравнения (П4.5) можно исключить y_{m+1} :

$$\begin{aligned} Ay_\mu - b_{m+1} \left(\frac{B}{c_m} y_\mu + \frac{F}{c_m} \right) + c_{m+1} y_{m+2} &= \Phi, \\ - \left(\frac{b_{m+1}B}{c_m} - A \right) y_\mu + c_{m+1} y_{m+2} &= \Phi + \frac{b_{m+1}}{c_m} F. \end{aligned}$$

Если снова вместо (П4.5) теперь в системе использовать уравнение вида (П4.4), а в новом уравнении

$$-\widetilde{B}y_v + c_{m+1}y_{m+2} = \widetilde{F},$$

положить $v = \mu$, $\widetilde{F} = \Phi + \frac{b_{m+1}}{c_m} F$, $\widetilde{B} = \frac{b_{m+1}B}{c_m} - A$, а в (П4.6) считать $\widetilde{A} = \frac{a_{m+2}B}{c_m}$, $\widetilde{\Phi} = f_{m+2} - \frac{a_{m+2}}{c_m} F$, то мы также исключим переменное под диагональю еще из одного уравнения и снова придем к системе того же вида.

Мы видим, что кроме рекуррентного вычисления A , B и модификации правых частей соответствующих уравнений нам необходимы еще два целочисленных множества. Первое предназначено для того, чтобы хранить значение μ на каждом шаге прямой прогонки (фактически запомнить порядок перестановки столбцов, дабы затем «раскрутить» найденный вектор неизвестных). Второе множество — для того, чтобы запомнить, от какого компонента вектора решения будет зависеть компонент с индексом μ .

Тогда мы приходим к следующему алгоритму.

1. Из первого уравнения системы $B = b_0$, $F = f_0$, $A = a_1$, $\Phi = f_1$. Для запоминания перестановок введем массив κ , считаем, что $\kappa_0 = 0$. Положим $i = 0$.

2. Для каждого значения i от 0 до $N - 1$ выполняем следующие действия.

Если $|B| \geq |c_i|$, то прогоночные коэффициенты считаем по формулам $P_{i+1} = c_i/B$, $Q_{i+1} = -F/B$. Присваиваем новые значения промежуточным величинам $F = \Phi + \frac{A}{B} F$, $B = b_{i+1} - \frac{Ac_i}{B}$, $A = a_{i+2}$, $\Phi = f_{i+2}$. Запоминаем, что перестановки на этом шаге нет, $\theta_{i+1} = \kappa_i$, и в формулы обратного хода войдет соседнее значение $\kappa_{i+1} = i + 1$.

Если $|B| < |c_i|$, то прогоночные коэффициенты считаем по формулам $P_{i+1} = B/c_i$, $Q_{i+1} = -F/c_i$. Присваиваем новые значения промежуточным величинам $F = \Phi + \frac{b_{i+1}}{c_i}F$, $B = \frac{b_{i+1}B}{c_i} - A$, $A = \frac{a_{i+2}B}{c_i}$, $\Phi = f_{i+2} - \frac{a_{i+2}}{c_i}F$. Запоминаем перестановку на этом шаге, $\theta_{i+1} = \kappa_{i+1}$, и в формулы обратного хода войдет значение $\kappa_{i+1} = \kappa_i$.

Переходим к обработке следующего уравнения.

3. При $n = \kappa_N$ сразу имеем $y_n = -F/B$. Затем используем формулы обратного хода $y_m = P_{i+1}y_n + Q_{i+1}$, где $m = \theta_{i+1}$, $n = \kappa_{i+1}$. Как и для обычной прогонки, индекс уравнения пробегает все значения от $N-1$ до 0.

4. Матричная прогонка

Пусть в результате дискретизации математической модели мы получили систему сеточных уравнений с блочно-трехдиагональной матрицей. Представим задачу в виде системы линейных уравнений

$$\begin{aligned} -\mathbf{B}_0\mathbf{Y}_0 + \mathbf{C}_0\mathbf{Y}_1 &= \mathbf{D}_0, \\ \mathbf{A}_n\mathbf{Y}_{n-1} - \mathbf{B}_n\mathbf{Y}_n + \mathbf{C}_n\mathbf{Y}_{n+1} &= \mathbf{D}_n, \quad n = 1, 2, 3, \dots, N-1, \\ \mathbf{A}_N\mathbf{Y}_{N-1} - \mathbf{B}_N\mathbf{Y}_N &= \mathbf{D}_N, \end{aligned}$$

где $\mathbf{Y}_n$ и $\mathbf{D}_n$ — векторы размера k , $\mathbf{A}_n$, $\mathbf{B}_n$, $\mathbf{C}_n$ — квадратные матрицы размера $k \times k$. Тогда метод прогонки обобщается на этот случай. Такой метод называется матричной прогонкой.

Пусть $\mathbf{q}_1 = \mathbf{B}_0^{-1}\mathbf{D}_0$, $\mathbf{p}_1 = \mathbf{B}_0^{-1}\mathbf{C}_0$. Здесь $\mathbf{p}_n$ — матрица размера $k \times k$, $\mathbf{q}_n$ — вектор размера k . Тогда формулы для прямого хода матричной прогонки будут

$$\begin{aligned} \mathbf{p}_{n+1} &= (\mathbf{B}_n - \mathbf{A}_n\mathbf{p}_n)^{-1}\mathbf{C}_n, \quad n = 1, 2, 3, \dots, N-1, \\ \mathbf{q}_n &= (\mathbf{B}_n - \mathbf{A}_n\mathbf{p}_n)^{-1}(\mathbf{A}_n\mathbf{q}_n - \mathbf{D}_n), \quad n = 1, 2, 3, \dots, N. \end{aligned}$$

Для обратного хода матричной прогонки

$$\mathbf{Y}_N = \mathbf{q}_{N+1}, \quad \mathbf{Y}_n = \mathbf{p}_{n+1}\mathbf{Y}_{n+1} + \mathbf{q}_{n+1}.$$

Можно показать, что матричная прогонка устойчива, если $\|\mathbf{p}_n\| < 1$ для $1 \leq n \leq N$; матрицы $\mathbf{B}_0$ и $\mathbf{B}_n - \mathbf{A}_n\mathbf{p}_n$ невырождены.

На случай системы с блочной матрицей с соответствующим расположением блоков можно обобщить и методы немонотонной прогонки, и периодическую прогонку.

5. Метод редукции (четно-нечетного исключения)

Опишем теперь другой алгоритм решения линейных систем уравнений с трехдиагональной матрицей. Рассмотрим три последовательных уравнения системы

$$\begin{aligned}a_{j-1}y_{j-2} - b_{j-1}y_{j-1} + c_{j-1}y_j &= d_{j-1}, \\a_jy_{j-1} - b_jy_j + c_jy_{j+1} &= d_j, \\a_{j+1}y_j - b_{j+1}y_{j+1} + c_{j+1}y_{j+2} &= d_{j+1}.\end{aligned}$$

Как известно, система линейных уравнений сохраняет равносильность, если одно уравнение системы заменить линейной комбинацией данного уравнения и других уравнений системы.

Умножим первое из этой тройки уравнений на a_j/b_{j-1} , а третье — на c_j/b_{j+1} , после чего сложим со вторым. Вместо второго уравнения из приведенной выше тройки получим

$$\begin{aligned}\frac{a_j a_{j-1}}{b_{j-1}} y_{j-2} - \left(b_j + \frac{a_j c_{j-1}}{b_{j-1}} + \frac{c_j a_{j+1}}{b_{j+1}} \right) y_j + \frac{c_j c_{j+1}}{b_{j+1}} y_{j+2} = \\= d_j + \frac{a_j}{b_{j-1}} d_{j-1} + \frac{c_j}{b_{j+1}} d_{j+1}.\end{aligned}$$

Это уравнение снова имеет подобную структуру, но связывает только значения y_{j-2} , y_j , y_{j+2} .

Заменим получившимся уравнением уравнение с номером j . Если это уравнение имеет четный номер, то оно связывает значение переменной с двумя другими, имеющие четные индексы. Таким образом, можно сначала рассмотреть четную подсистему, и, решив ее, вернуться к определению значений сеточной функции в узлах с нечетными индексами.

Рассмотрим новую сокращенную систему уравнений, связывающих только значения в четных узлах сетки. Она также имеет трехдиагональную структуру, и для ее решения снова может быть применен метод четно-нечетного исключения. Таким образом, исключение носит редукционный характер.

На обратном ходе редукции мы легко восстанавливаем значения в «нечетных» узлах, пользуясь «опущенными» уравнениями с нечетным индексом.

Алгоритм четно-нечетного исключения обобщается на случай матричных коэффициентов.

6. Пятиточечная прогонка

Рассмотрим систему с ленточной матрицей, но с другой шириной ленты. Это система с пятидиагональной матрицей. Примеры задач, где может возникнуть система сеточных уравнений такого вида, приведены ниже.

Как и ранее, запишем систему уравнений не в матричной форме, а в виде последовательности уравнений, связывающих между собой значения сеточной функции в соседних узлах. Первые два и последние два уравнения в записи ниже имеют такую же структуру, как и равенства во «внутренних» точках, но они получаются из аппроксимации граничных условий на правой и левой границах рассматриваемого отрезка.

Итак, рассматривается система сеточных уравнений

$$\begin{aligned} c_0 u_0 - d_0 u_1 + e_0 u_2 &= f_0, \\ -b_1 u_0 + c_1 u_1 - d_1 u_2 + e_1 u_3 &= f_1, \\ a_n u_{n-2} - b_n u_{n-1} + c_n u_n - d_n u_{n+1} + e_n u_{n+2} &= f_n, \quad n=2, \dots, N-2, \\ a_{N-1} u_{N-3} - b_{N-1} u_{N-2} + c_{N-1} u_{N-1} - d_{N-1} u_N &= f_{N-1}, \\ a_N u_{N-2} - b_N u_{N-1} + c_N u_N &= f_N. \end{aligned}$$

Алгоритм решения таких систем — пятиточечная прогонка, формулы которой выводятся аналогично формулам трехточечной прогонки. В прогоночном соотношении теперь будет три коэффициента (p, q, r) :

$$u_n = p_{n+1} u_{n+1} - q_{n+1} u_{n+2} + r_{n+1}.$$

Прогоночные коэффициенты вычисляются по формулам прямого хода. Из «граничных условий» сначала вычисляется $p_1 = d_0/c_0$, затем вспомогательная величина $D_1 = c_1 - p_1 b_1$, стоящая в знаменателе в выражениях для прогоночных коэффициентов,

$$p_2 = \frac{d_1 - q_1 b_1}{D_1}, \quad r_1 = \frac{f_0}{c_0}, \quad r_2 = \frac{f_1 + b_1 r_1}{D_1}, \quad q_1 = \frac{e_0}{c_0},$$

после чего определяются все коэффициенты прямого хода прогонки:

$$\begin{aligned} D_n &= c_n - a_n q_{n-1} + p_n(a_n p_{n-1} - b_n), \quad n = 2, 3, \dots, N, \\ q_{n+1} &= \frac{e_n}{D_n}, \quad n = 1, 2, 3, \dots, N-2, \\ p_{n+1} &= \frac{d_n + q_n(a_n p_{n-1} - b_n)}{D_n}, \quad n = 2, 3, \dots, N-1, \\ r_{n+1} &= \frac{f_n - a_n r_{n-1} - r_n(a_n p_{n-1} - b_n)}{D_n}, \quad n = 2, 3, \dots, N. \end{aligned}$$

При обратном ходе прогонки сначала вычисляются два последних компонента вектора неизвестных

$$\begin{aligned} u_{N-1} &= p_N u_N + r_N, \\ u_N &= r_{N+1}. \end{aligned}$$

Затем с помощью прогоночного соотношения восстанавливается решение системы

$$u_n = p_{n+1} u_{n+1} - q_{n+1} u_{n+2} + r_{n+1}.$$

Достаточными условиями устойчивости пятиточечной прогонки являются условие диагональное преобладания и условия

$$|p_n| + |q_n| \leq 1, \quad n = 1, \dots, N-1, \quad |p_N| \leq 1.$$

7. Периодическая прогонка

Рассмотрим следующую краевую задачу для уравнения Штурма–Лиувилля

$$y'' + p(x)y' + q(x)y = f(x)$$

с условиями периодичности

$$y^{(m)}(0) = y^{(m)}(1),$$

где m принимает значения 0 и 1.

Краевая задача с условиями периодичности решается методом периодической прогонки. Запишем дискретный аналог уравнения:

$$\frac{y_{n+1} - 2y_n + y_{n-1}}{h^2} + p_n \frac{y_{n+1} - y_{n-1}}{2h} + q_n y_n = f_n.$$

Очевидно, что оно аппроксимирует дифференциальную задачу со вторым порядком на равномерной сетке. На случай неравномерной сетки рассматриваемый метод легко обобщается.

В силу периодичности дискретное уравнение должно выполняться во всех точках сетки, включая граничные. Кроме того, в силу граничного условия при $m = 0$, $y_0 = y_{N+1}$. Система сеточных уравнений примет вид

$$\begin{aligned} a_0 y_N - b_0 y_0 + c_0 y_1 &= \Phi_0, \\ &\dots\dots\dots \\ a_n y_{n-1} - b_n y_n + c_n y_{n+1} &= \Phi_n, \\ &\dots\dots\dots \\ a_N y_{N-1} - b_N y_N + c_N y_0 &= \Phi_N, \end{aligned}$$

где $a_k = 1 - 0.5p_k h$, $b_k = 2 - q_k h^2$, $c_k = 1 + 0.5p_k h$, $\Phi_k = f_k h^2$. Матрица системы линейных уравнений получается «почти трехдиагональной» — от трехдиагональной ее отличают всего два элемента в углах матрицы.

Обобщение стандартных прогоночных соотношений (для трехточечной прогонки) на периодический случай будет иметь вид

$$y_{n-1} = \alpha_n y_n + \beta_n + \gamma_n y_N.$$

Из приведенного выше соотношения для y_0 сразу получаем, что $\alpha_1 = c_0/b_0$, $\beta_1 = -f_0/b_0$, $\gamma_1 = a_0/b_0$.

Теперь несложно получить рекуррентную зависимость для прогоночных коэффициентов:

$$\alpha_{k+1} = \frac{c_k}{b_k - \alpha_k a_k}, \quad \beta_{k+1} = \frac{a_k \beta_k - f_k}{b_k - \alpha_k a_k}, \quad \gamma_{k+1} = \frac{a_k \gamma_k}{b_k - \alpha_k a_k}.$$

По приведенным выше формулам получаются значения коэффициентов для всех уравнений с номерами меньше, чем N . Это уже известный прямой ход прогонки слева направо.

Подставим теперь прогоночные соотношения в последнее уравнение линейной системы. В итоге с учетом введенных выше обозначений получаем:

$$a_N (\alpha_N y_N + \beta_N + \gamma_N y_N) - b_N y_N + c_N y_0 = \Phi_N,$$

а это соотношение, сгруппировав члены, можно переписать как

$$y_N = \mu_N y_0 + \nu_N,$$

где введены обозначения

$$\mu_N = \frac{-c_N}{a_N(\alpha_N + \gamma_N) - b_N}, \quad v_N = \frac{\varphi_N - a_N \beta_N}{a_N(\alpha_N + \gamma_N) - b_N}.$$

Теперь выражение для значения сеточной функции y_{n-1} подставляем в прогоночные соотношения. Получается выражение, связывающее y_{n-1} с y_0 :

$$y_{n-1} = \alpha_n(\mu_n y_0 + v_n) + \beta_n + \gamma_n(\mu_N y_0 + v_N).$$

Отсюда получаем следующие рекуррентные соотношения:

$$\mu_{n-1} = \alpha_n \mu_n + \gamma_n \mu_N, \quad v_{n-1} = \beta_n + \alpha_n v_n + \gamma_n v_N.$$

Отметим, что эти коэффициенты вычисляются в обратном порядке справа налево — аналог обратного хода прогонки. Последнее соотношение приводит к явному выражению для y_0 . В результате получаем

$$y_0 = \frac{v_0}{1 - \mu_0}.$$

Теперь информации для определения значений искомой функции во всех точках сетки (еще один ход прогонки) достаточно.

Алгоритм периодической прогонки был предложен А. А. Абрамовым.

8. Потокковая прогонка

Рассмотрим уравнение теплопроводности с переменным коэффициентом

$$\frac{\partial u}{\partial t} = \frac{\partial u}{\partial x} D(x) \frac{\partial u}{\partial x} + f(x, t)$$

с начальным условием

$$u(x, 0) = u_0(x)$$

и граничными условиями

$$u(0, t) = \varphi_0(t), \quad u(1, t) = \varphi_1(t).$$

Для численного решения задачи используется неявная разностная схема

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{1}{h} \left(D(x_{m+1/2}) \frac{y_{m+1}^{n+1} - y_m^{n+1}}{h} - D(x_{m-1/2}) \frac{y_m^{n+1} - y_{m-1}^{n+1}}{h} \right) + f_m^{n+1}.$$

Перепишем разностное уравнение, вводя «тепловые потоки» (с точностью до знака):

$$\frac{y_m^{n+1} - y_m^n}{\tau} = \frac{1}{h} (W_{m+1/2} - W_{m-1/2}) + f_m^{n+1}, \quad (\text{П4.7})$$

где

$$W_{m+1/2} = D(x_{m+1/2}) \frac{y_{m+1}^{n+1} - y_m^{n+1}}{h}, \quad W_{m-1/2} = D(x_{m-1/2}) \frac{y_m^{n+1} - y_{m-1}^{n+1}}{h}.$$

Запишем прогоночное соотношение в виде

$$y_m^{n+1} = P_m W_{m+1/2} + R_m.$$

Как и в «обычной» прогонке, в течение прямого хода вычисляем прогоночные коэффициенты. Из левого граничного условия сразу имеем $P_0 = 0$, $R_0 = \varphi_0(t_{n+1})$. Рекуррентное соотношение для прогоночных коэффициентов получается при подстановке прогоночного соотношения в уравнение для потоков

$$\begin{aligned} W_{m+1/2} &= D(x_{m+1/2}) \frac{y_{m+1}^{n+1} - y_m^{n+1}}{h} = \\ &= D(x_{m+1/2}) \frac{y_{m+1}^{n+1} - (P_m W_{m+1/2} + R_m)}{h}. \end{aligned}$$

Разрешим это уравнение относительно y_{m+1}^{n+1} . Получим

$$y_{m+1}^{n+1} = \left(P_m - \frac{h}{D_{m+1/2}} \right) W_{m+1/2} + R_m.$$

Теперь с помощью первого уравнения выразим тепловой поток в точке $m + 1/2$ через поток в точке $m + 3/2$. Имеем

$$h \frac{y_{m+1}^{n+1} - y_m^{n+1}}{\tau} = W_{m+3/2} - W_{m+1/2} + h f_{m+1}^{n+1}.$$

Подставим значение потока в выражение для решения

$$y_{m+1}^{n+1} = \left(P_m - \frac{h}{D_{m+1/2}} \right) \left(-h \frac{y_{m+1}^{n+1} - y_m^{n+1}}{\tau} + W_{m+3/2} + h f_{m+1}^{n+1} \right) + R_m.$$

Собираем в этом равенстве подобные слагаемые и записываем его в виде прогоночного соотношения. Окончательно для формул прямого хода получим

$$\begin{aligned} A &= 1 + \frac{h}{\tau} \left(P_m + \frac{h}{D_{m+1/2}} \right), \\ P_{m+1} &= \frac{1}{A} \left(P_m + \frac{h}{D_{m+1/2}} \right), \\ R_{m+1} &= \frac{1}{A} \left[\left(P_m + \frac{h}{D_{m+1/2}} \right) \left(\frac{h}{\tau} y_{m+1}^n - h f_{m+1}^{n+1} \right) + R_m \right]. \end{aligned}$$

После прямого хода разрешается правое граничное условие. Затем с помощью (П4.7) и прогоночного соотношения восстанавливаются все значения тепловых потоков и сеточной функции решения на следующем временном слое.

В этом алгоритме введением функции «теплового потока» мы уменьшаем влияние погрешностей округления при вычислении теплового потока по разностной формуле

$$W_{m+1/2} = D(x_{m+1/2}) \frac{y_{m+1}^{n+1} - y_m^{n+1}}{h}.$$

При малых шагах и возможных больших градиентах температуры из-за ошибок округления значение теплового потока может становиться сколь угодно большим, что нефизично.

МНОЖЕСТВА И ОБОЛОЧКИ

Определение. Множество X называется линейным, если для всех $x^1, x^2 \in X$ и для всех $\alpha^1, \alpha^2 \in R^1$ выполняется включение $y = \alpha^1 x^1 + \alpha^2 x^2 \in X$.

Определение. Множество X называется афинным, если для всех $x^1, x^2 \in X$ и для всех $\alpha^1, \alpha^2 \in R^1$ таких, что $\alpha^1 + \alpha^2 = 1$ выполняется включение $y = \alpha^1 x^1 + \alpha^2 x^2 \in X$.

Определение. Множество K называется конусом, если для всех $x \in K$ и для всех действительных $\alpha > 0$ выполняется $y = \alpha x \in K$.

Определение. Множество X называется выпуклым, если для всех $x^1, x^2 \in X$ и для всех $\alpha^1, \alpha^2 \in R^1$ таких, что $\alpha^1 + \alpha^2 = 1$, $\alpha^1 \leq 0$, $\alpha^2 \leq 0$, выполняется включение $y = \alpha^1 x^1 + \alpha^2 x^2 \in X$.

Определение. Множество K называется выпуклым конусом, если для всех $x^1, x^2 \in K$ и для всех действительных $\alpha^1, \alpha^2 \in R^1$ таких, что $\alpha^1 > 0$, $\alpha^2 > 0$, выполняется включение $y = \alpha^1 x^1 + \alpha^2 x^2 \in K$.

Определение. Линейной оболочкой множества $X = \{x^1, x^2, K, x^m\}$ называется множество

$$\text{Li } X = \left\{ x : x = \sum_{i=1}^m \alpha^i x^i, \alpha^i \in R^1 \right\}.$$

Определение. Афинной оболочкой множества $X = \{x^1, x^2, K, x^m\}$ называется множество

$$\text{Aff } X = \left\{ x : x = \sum_{i=1}^m \alpha^i x^i, \alpha^i \in R^1, \sum_{i=1}^m \alpha^i = 1 \right\}.$$

О п р е д е л е н и е. *Конической оболочкой множества $X = \{x^1, x^2, K, x^m\}$ называется множество*

$$\text{Cone } X = \left\{ x : x = \sum_{i=1}^m \alpha^i x^i, \alpha^i \in R^1, \alpha^i > 0 \forall i \right\}.$$

О п р е д е л е н и е. *Выпуклой оболочкой множества $X = \{x^1, x^2, K, x^m\}$ называется множество*

$$\text{Conv } X = \left\{ x : x = \sum_{i=1}^m \alpha^i x^i, \alpha^i \in R^1, \alpha^i \leq 0 \forall i, \sum_{i=1}^m \alpha^i = 1 \right\}.$$

ЛИТЕРАТУРА

1. *Рябенский В. С.* Введение в вычислительную математику. — М.: Физматлит, 2008.
2. *Федоренко Р. П.* Введение в вычислительную физику. — Долгопрудный: Издательский дом «Интеллект», 2009.
3. *Бахвалов Н. В., Жидков Н. П., Кобельков Г. М.* Численные методы. — М.: Лаборатория Базовых Знаний, 2002.
4. *Косарев В. И.* 12 лекций по вычислительной математике. — М.: Физматкнига, 2013.
5. *Амосов А. А., Дубинский Ю. А., Копченова Н. В.* Вычислительные методы для инженеров. — М.: Высшая школа, 1994.
6. *Самарский А. А.* Введение в численные методы. — М.: Наука, 1997.
7. *Иванов В. Д., Косарев В. И. и др.* Лабораторный практикум по курсу «Основы вычислительной математики». — М.: МЗ-Пресс, 2003.
8. *Аристова Е. Н., Завьялова Н. А., Лобанов А. И.* Практические занятия по вычислительной математике: учебное пособие. — М.: МФТИ, 2014.
9. *Воеводин В. В.* Вычислительные основы линейной алгебры. — М.: Наука, 1977.
10. *Голуб Дж., Ван Лоун Ч.* Матричные вычисления. — М.: Мир, 1999.
11. *Деммель Дж.* Вычислительная линейная алгебра. Теория и приложения. — М., Мир, 2001.
12. *Фадеев А. К., Фадеева В. Н.* Вычислительные методы линейной алгебры. — СПб.: Лань, 2002.
13. *Воеводин В. В., Кузнецов Ю. А.* Матрицы и вычисления. — М.: Наука, 1984.
14. *Беклемишев Д. В.* Курс аналитической геометрии и линейной алгебры. — М.: Физматлит, 2009.
15. *Коновалов А. Н.* Введение в вычислительные методы линейной алгебры. — Новосибирск, Наука, 1993.
16. *Годунов С. К.* Лекции по современным аспектам линейной алгебры. — Новосибирск: Научная книга (ИДМИ), 2002. — (Университетская серия. Т. 12).
17. *Тыртышников Е. Е.* Матричный анализ и линейная алгебра. — М.: Физматлит, 2007.
18. *Уоткинс Д.* Основы матричных вычислений. — М., Бином, 2017
19. *Вьюгин В. В.* Математические основы машинного обучения и прогнозирования. — М.: МЦНМО, 2018.
20. http://www.machinelearning.ru/wiki/index.php?Title=Машинное_обучение (курс_лекций_К_В_Воронцова) (режим доступа 22.01.2020).
21. *Калиткин Н. Н.* Численные методы. — М.: Наука, 1978. 512 с.
22. *Бирюков С. И.* Оптимизация. Введение в теорию. Численные методы. — М.: МЗ-пресс, 2003.

23. Жадан В. Г. Методы оптимизации Ч.1: Введение в выпуклый анализ и теорию оптимизации. — М.: МФТИ, 2014.
24. Жадан В. Г. Методы оптимизации Ч.2: Численные алгоритмы. — М.: МФТИ, 2015.
25. Шананин А. А., Обросова Н. К. Экономическая интерпретация двойственности в задачах линейного программирования. — М., Изд-во РУДН, 2007.
26. Каханер Д., Моулер К., Нэш С. Численные методы и программное обеспечение. — М.: Мир, 1998.
27. Лобанов А. И., Петров И. Б. Математическое моделирование нелинейных процессов: учебник для академического бакалавриата. — М.: Юрайт, 2019.
28. Шарковский А. Н., Майстренко Ю. А., Романенко Е. Ю. Разностные уравнения и их приложения. — Киев: Наукова думка, 1986. 279 с.
29. Гавриков М. Б., Локуцкий О. В. Начала численного анализа. — М., ТОО «Янус», 1995.
30. Завьялов Ю. С., Квасов Б. И., Мирошниченко В. Л. Методы сплайн-функций. — М.: Наука, 1980.
31. Калиткин Н. Н., Альшина Е. А. Численные методы. Книга 1. Численный анализ. — М., Академия, 2013.
32. Гавриков М. Б., Таюрский А. А. Функциональный анализ и вычислительная математика. — М.: ЛЕНАД, 2016.
33. Рябенский В. С., Филиппов А. Ф. Об устойчивости разностных уравнений. — М.: Гостехиздат, 1956.
34. Хайрер Э., Нерсетт С., Ваннер Г. Решение обыкновенных дифференциальных уравнений. Нежесткие задачи. — М.: Мир, 1990.
35. Хайрер Э., Ваннер Г. Решение обыкновенных дифференциальных уравнений. Жесткие и дифференциально-алгебраические системы. — М.: Мир, 1999.
36. Lax P. D.; Richtmyer R. D. Survey of the stability of linear finite difference equations // Comm. Pure Appl. Math. 9 (1956). P. 267–293
37. Канторович Л. В., Акилов Г. П. Функциональный анализ. — М.: Наука, 1984.
38. Холодов А. С., Лобанов А. И., Евдокимов А. Е. Разностные схемы для решения жестких систем обыкновенных дифференциальных уравнений в пространстве неопределенных коэффициентов. — М., МФТИ, 2001.
39. Самарский А. А., Гулин А. В. Численные методы математической физики. — М.: Научный мир, 2003.
40. Аристова Е. Н., Лобанов А. И. Практические занятия по вычислительной математике в МФТИ. Ч. II. Учеб. пособ. — М., МФТИ, 2015.
41. Самарский А. А. Теория разностных схем. — М.: Наука, 1983.
42. Жуков А. И. Метод Фурье в вычислительной математике. — М.: Наука, 1992.
43. Магомедов М.-К. М., Холодов А. С. Сеточно-характеристические численные методы. — М.: Наука, 1988.
44. Рождественский Б. Л., Яненко Н. Н. Системы квазилинейных уравнений и их приложения к газовой динамике. — М.: Наука, 1978.
45. Шокин Ю. И., Яненко Н. Н. Метод дифференциального приближения. Применение к газовой динамике. — Новосибирск, Наука, 1985.

46. Самарский А. А., Попов Ю. П. Разностные методы решения задач газовой динамики. — М.: Едиториал УРСС, 2002. .
47. Годунов С. К. Разностный метод численного расчѐта разрывных решений уравнений гидродинамики // Математический сборник. 1959. Т. 47. № 3. С. 271–306.
48. Куликовский А. Г., Погорелов Н. В., Семенов А. Ю. Математические вопросы численного решения гиперболических систем уравнений. — М.: Физматлит, 2001.
49. Белоцерковский О. М. Численное моделирование в механике сплошных сред. — М.: Физматлит, 1994.
50. Самарский А. А., Николаев Е. С. Методы решения сеточных уравнений. — М.: Наука, 1978.
51. Федоренко Р. П. Релаксационный метод решения разностных эллиптических уравнений // ЖВМ и МФ. 1961. Т. 1. № 5. С. 922–927.
52. Современные проблемы вычислительной математики и математического моделирования. Т. 1. — М. Наука, 2005.
53. Холодов А. С. Монотонные разностные схемы на нерегулярных сетках для эллиптических уравнений в области со многими несвязными границами // Математическое моделирование. 1991. Т. 3. № 9. С. 104–113.
54. Холодов А. С. О построении разностных схем с положительной аппроксимацией для уравнений гиперболического типа // Журнал вычислительной математики и математической физики. 1978. Т. 18. № 6. С. 1476–1492.

Учебное издание

Лобанов Алексей Иванович
Петров Игорь Борисович

ВЫЧИСЛИТЕЛЬНАЯ МАТЕМАТИКА
Курс лекций

Набор и верстка выполнены в издательстве «Физматкнига»
Операторы *А. И. Чугуров, А. К. Розанов*

Редактор *А. К. Розанов*

Издательство «Физматкнига».
141701, Московская область, г. Долгопрудный,
ул. Первомайская, д. 3А. Тел. (499) 390-51-38.

Подписано в печать 01.03.2021.
Формат 60×90/16. Печать цифровая.
Усл. печ. л. 16. Уч.-изд. л. 15,0. Тираж 300 экз.

Отпечатано в АО «Т8 Издательские Технологии».
109316, г. Москва, Волгоградский проспект, д. 42, корп. 5.